rogii-wellbore-geology-prediction

6位 - PF, PF, PF, PF, Physics and Row-Level Bagging

Rank	6
Team	k256.dev
Author	k256.dev
Topic ID	733226
Version	Japanese Translation

Source: https://www.kaggle.com/competitions/rogii-wellbore-geology-prediction/discussion/733226
Retrieved with Kaggle CLI on 2026-08-06.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

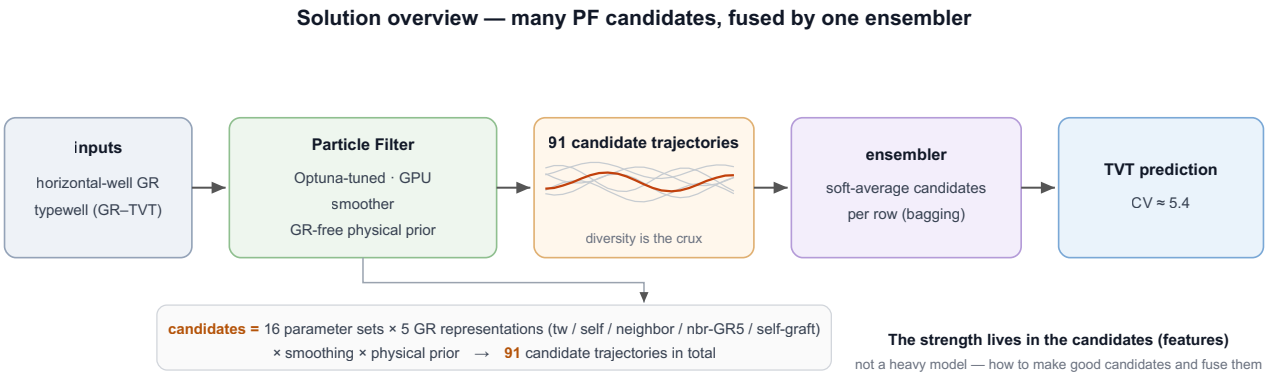
素晴らしいコンペを開催したorganizersに感謝します。ほとんど未開拓の問題で、地質にも時系列解析にも詳しくありませんでしたが、多くを学べました。Public 20位、Private 6位と大きくshake upし、その原因も振り返ります。精度改善の軌跡に沿って解法を紹介します。他participantのSolutionを読むのも楽しみです。

1. Summary

horizontal wellで測定されたgamma-ray log（GR）を別途提供されたreference dataと比較し、wellがrock columnのどの高さ（TVT）を通るかを予測するtaskです。

解法は最初から最後まで**Particle Filter**に依存しました。異なる設定で多数のPFを動かして多くのTVT estimateを作り、**最終91 estimatesをNN modelへ入力**します。NNが91 candidatesをrowごとにfusionする、つまり**row-level bagging**です。約CV 5.4へ達しました。model specialistではないため、model自体より91 inputs（features）の改善を徹底しました。

Final scoreはPrivate 5.984 / Public 5.626 / CV 5.4577です。



---

2. Methods and results

2-0. Starting point

deadlineの2か月前に参加しました。public notebooksのbaseは**Particle Filterとtabular modelの組合せ**で、**Public LBへ強くoverfit**していました。

PFには多数のtunable parametersがあります。このDiscussionから、**PF単体でもかなり高精度**で、**public notebooksはtuning不足**と分かりました。Optunaでparameterを適切に調整したのがfirst stepで、その後の全改善もPF改善へ強く依存します。

2-1. Baseline — CV 7.8 / LB 7.168

Optunaで調整した項目は次です。この段階に**物理要素は全くなく、particle seed countは**`n_seed = 32`**固定**です。

Parameter	Role
`gr_sig` (GR-likelihood σ)	GR matchの許容度（alignmentの厳しさ）
`gr_power`	GR likelihoodのsharpness（exponent）
`init_pos_std`	initial TVT positionのspread
`init_rate_std`	initial slope（rate of change）のspread
`mom / vn / pn`	slope momentumとtransition noise（position/slope random-walk width）
`resamp`	resample threshold（particle degeneracyを防ぐ）
`jump_prob / jump_std`	別solution（branch）へjumpするprobabilityとwidth
`rate_clip / tvt_clip_margin`	slope/position driftのlimit

最初はOptuna-tuned parameter setを**1つ**だけpublic notebookと同じ形で入れました。CV 8.64 / LB 7.862でLB overfitですが、当時のpublic notebookより良好でした。

次に複数PF parameter setsのestimateをconcatenateしてinputにする実験を行いました。3-inputと5-input（互いに別構成）の両方でCV/LBが改善しました。

Configuration	CV	Public	Δ(Pub−CV)	Private
1-input	8.64	7.862	-0.78	8.163
3-input	7.90	7.189	-0.71	7.729
5-input	7.80	7.168	-0.63	7.804

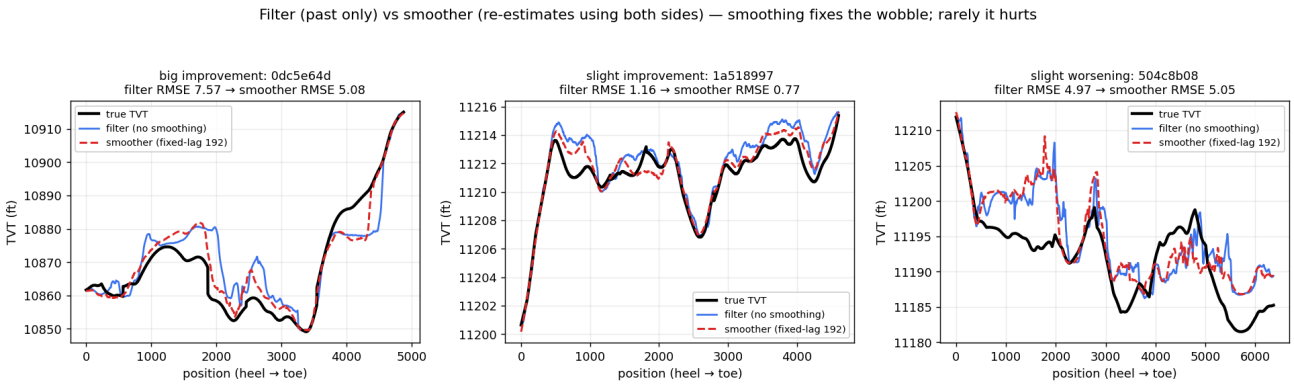
2-2. Particle Filterのhot-rodding（GPU + smoother）— CV 7.5 / LB 6.724

2-1ではseed=32のPFを3つ動かすだけでscoreに約4時間かかり、ほぼPFが占めました。そこで**PFをGPU向けに再構築**し、experiment/inferenceが**約200倍高速化**して多くのtrialが可能になりました。

副産物としてPFへ**smoother mechanism**を追加できました。通常PFは各stepのposition推定に「pastだけ」を使うcausal processです。smootherはparticle ancestryを保持し、少し先のGRを見てpastを再推定します。両側contextを使うためestimateが安定し、一時的にnoiseで迷った箇所を後から修正します。Kitagawa (1996) / Doucet & Johansen (2009)に沿う**fixed-lag particle smoother**です。

tabular modelへ入れると`smooth = 192`で**CV -0.3 / LB -0.4**。ただしlagが長いほど各particleのancestry保持が重くなります。RTX 5070で1 parameter set×tw representationを全773 wellsへ1 passした実測は、**plain PF約4.5分 → fixed-lag 16約4.9分（+約10%）→ fixed-lag 192約13分（plainの約2.9倍）**です。short lagはほぼfreeですが192は明確に重く、GPU portなしでは実用的でありません。

Configuration	CV	Public	Δ(Pub−CV)	Private
5-input	7.80	7.168	-0.63	7.804
5-input + smooth	7.50	6.724	-0.78	7.404



上図はpf_1（tw representation）をno smoothing（filter）とfixed-lag 192（smoother）で動かし、per-well RMSE differenceから3 casesを選んだものです。**左 = 大幅改善:** filterのearly wobble/overshootを両側GR contextで戻します（7.57→5.08）。**中央 = 小改善:** easy wellで効果は小さいが一貫（1.16→0.77）。**右 = 小悪化:** ごく稀に少し悪化（4.97→5.05）。総じてwobble修正が勝ちます。

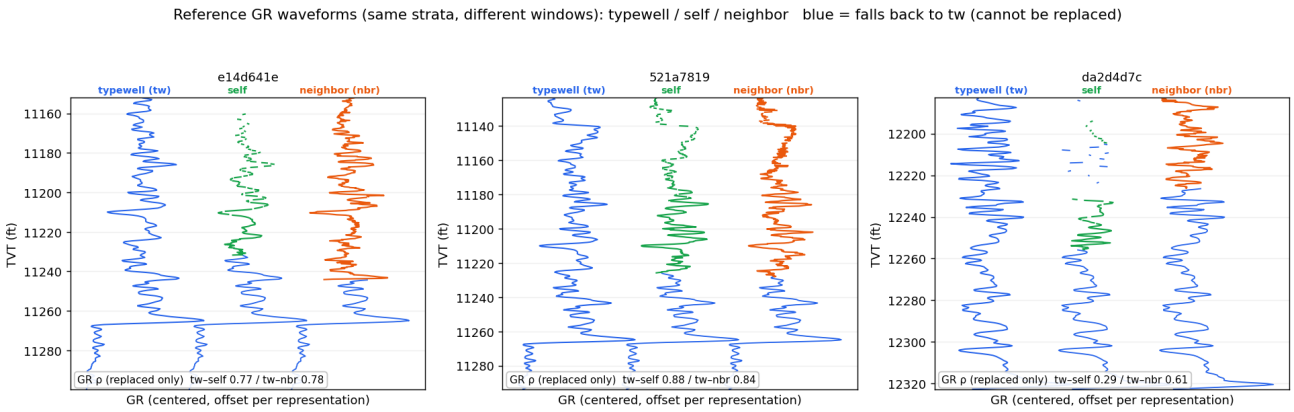
2-3. Alternative GR representations（self / neighbor）— CV 6.98 / LB 6.026

このDiscussionからtypewell GR（以下**twGR**）がnoisyで、**pseudo-typewell**という概念があると学びました。

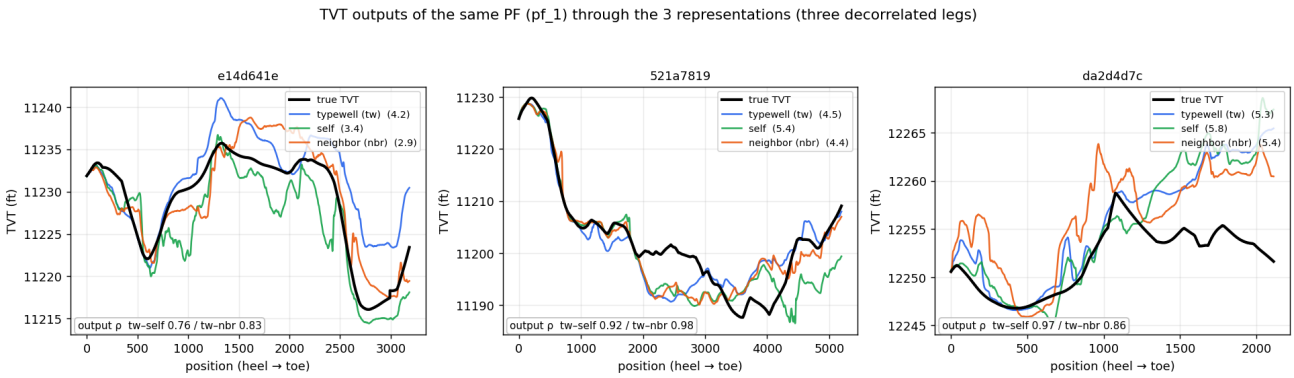
応用を考えると**neighboring train wellsが提供**されています（以下**neighbor**）。1,500 ft以内のtrain neighborのknown GRでtwGRを上書きするとpseudo typewell GR（**nbrGR**）になります。

同種の2つ目が**self**です。well自身のprefix（heel側known interval）ではTVT/GRが両方knownなので同様に上書きします（**selfGR**）。

これらTVT-GR pairからのestimateはtwGR estimateへ**強く complementary**です。twGRに対するcorrelationはselfGR約0.79、nbrGR約0.72で、単体でaccurateながらdecorrelateしています。referenceごとに異なる壊れ方をし、downstreamでerrorがcancelします。



同じwellを3 reference（twGR / selfGR / nbrGR）で見たGR waveformです。**large-scale shape（同じstrata）は共通ですがfine detailが少し違います。** この「別windowから見る同じstrata」がdecorrelation源です。



同じPF（pf_1）を3 representationで動かすと、TVT outputは互いにdecorrelatedな3 legsになります。各々truthをtrackしつつ異方向へ外れるためdownstream ensemblerでcancelします。

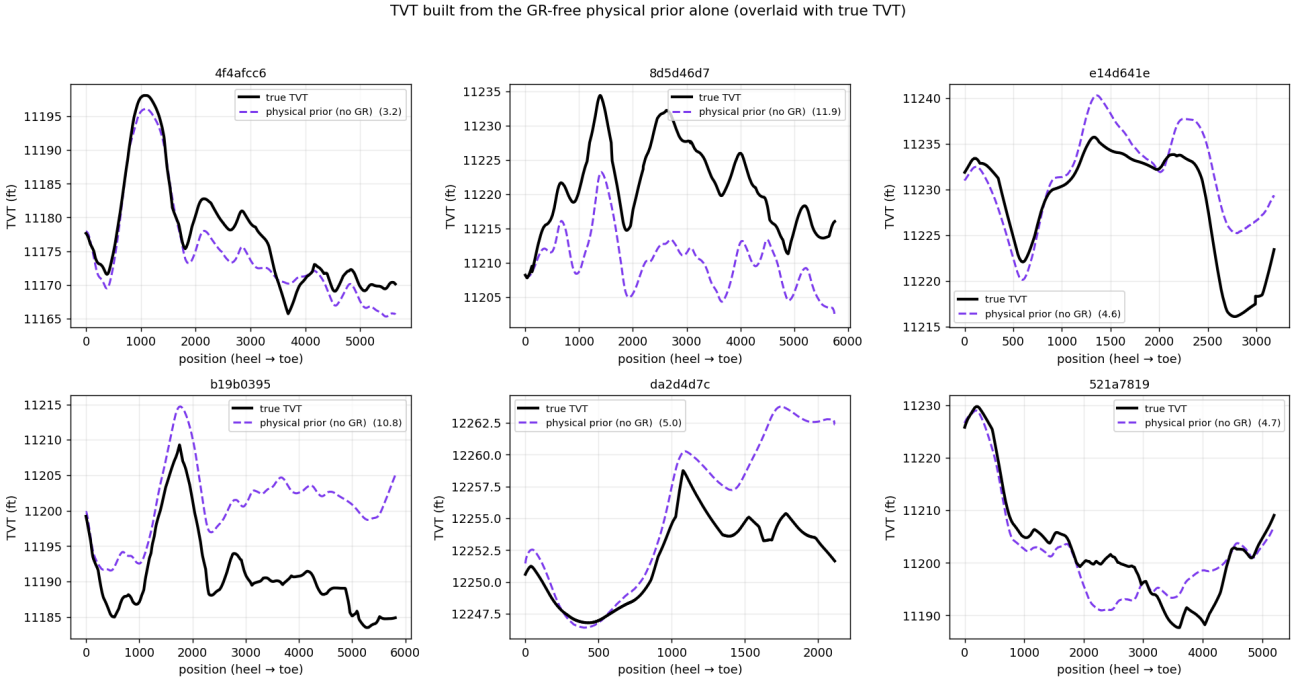
2 representationを追加しtabular modelへのinputを15へすると**CV/LBとも約-0.50**でした。

Configuration	CV	Public	Δ(Pub−CV)	Private
2-2 (5-input + smooth)	7.50	6.724	-0.78	7.404
2-2 + selfGR + nbrGR	6.98	6.026	-0.95	7.112

2-4. Physical constraintの注入 — CV 6.50 / LB 6.43

CV約7.0とPublic 6.0が大きく乖離しました。「**physical constraintsをcombine**」というDiscussionを受け、GRを一切使わず**well geometry** `(X,Y,Z)` **とknown TVTだけからTVT prior**を作りました。

GRがなくてもwellがどの方向へどれだけ進み（geometry）、周囲wellのstrataがどう傾くか（dip）が分かればTVT changeを予測できます。各wellをsegmentsへ分けlocal dipを推定し、空間共有してintegrateしTVT trajectoryを再構築します。重要なのは**strict OOF構築**です。evaluation wellの情報をdip field/calibrationへ混ぜるとCVだけ不正に良くなりPrivateでcollapseし、shake-downの種になります。



GRなしphysical priorだけのTVT waveformとtruthです。**geometryとneighbor dipだけでもlarge-scale TVT undulationをかなりtrack**し、合うwellは3-5 ft、外すwellは10 ft超とspreadがあります。

単体は**CV 10.1 / LB 10.8**と弱いですが、**PF likelihoodへ注入**すると有効です。この前提で2-2へOptuna-tuned parametersを加えると**CV -0.5 / LB +0.5**となり、初めて**CVとLBが一致**しました。

Configuration	CV	Public	Δ(Pub−CV)	Private
physical constraint only	10.1	10.8	+0.70	9.342
twGR-prior PF alone	7.8	7.88	+0.08	7.78
2-3 (selfGR + nbrGR)	6.98	6.026	-0.95	7.112
2-3 + prior PF	6.50	6.43	-0.07	6.67

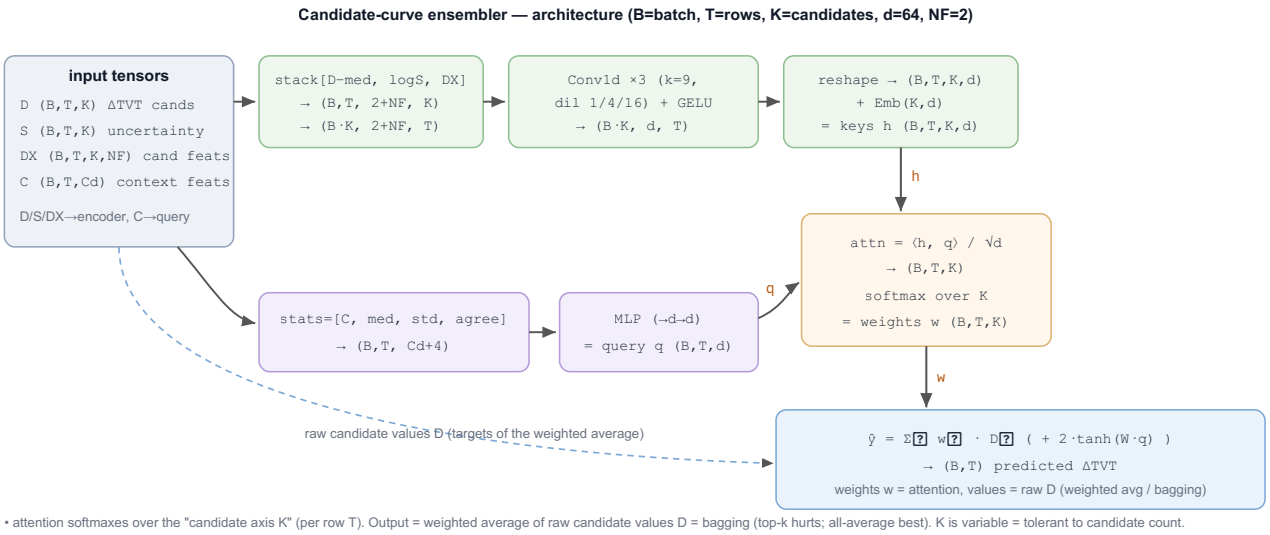
PrivateでもCV 6.50 / Public 6.43 / Private 6.67と正しくtransferしました。Publicが悪く見えてもCVを信じて進む判断が正しかったと分かります。「CVとLBが一致」は最大のturning pointでした。

2-5. 残った多数PFをinput-tolerant ensemblerでfusion — CV 5.94 / LB 6.17

Optunaでtuneしたものの**単体改善につながらず余ったPF**が大量にありました。捨てずに**まとめて全て入力すると精度がjumpし、CV 5.94 / Public 6.17**になりました。

理由をerrorから分解すると、strong PFに対するresidual self-correlationはほぼ1.000でした。**independent per-row signalはほぼ尽き、errorはsegment単位で「どのsolutionへ乗るか」の選択**にあります。row regressionでなく、segmentごとにmany candidatesのどれへ乗るかの問題です。

そこで**PF×representationのTVT trajectoryを1 candidate curveとして並べ、lightweight attentionがrowごとにsoft averageするcandidate-curve ensembler**を作りました。tabular modelはfixed-length concatenateだけでexpressive powerに限界がありますが、ensemblerは任意数candidateを並べられます。単体で効かなかったPFを全て入れられたことが決定的でした。



input candidatesは**6 PFs（pf_1 / pf_2 / pf_3 / r0_seed32 / r1_seed32 / pfA）×5 representations = 30**です。5 representationsはGRを何へmatchするかが違います。

- **typewell**: 提供されたvertical-well template。

- **self**: own known-prefix GRをpseudo-templateにする。
- **neighbor**: spatially near (XY) train wellのGRをpseudo-templateにする。
- **nbr_gr5**: XY distanceでなく**GR similarity、すなわちGR（stratigraphy）が合うtop-5 train wells**を選ぶ。
- **self_graft**: `tw→self` calibrationでknown range外へextrapolate（graft）し、selfがcoverするrangeを拡張。

6 PFのうちphysical（GR-free anchor）constraintを持つのは1つ（pfA）だけです。

重要なdesign findingは、one-of-N selectorでなく**broad soft average（bagging）として働くことです。top-k制限は悪化し、全candidateへのsoftmaxがoptimalでした。GRだけでcorrect solutionを特定できないため、選択を強制せずprobabilistic averageでhedge**するのが正解です。

この段階のfinal predictionは**GBM（tabular）+ sequence net（TCN）+ ensemblerのfixed-weight 3-leg blend**です。standalone CVとweightは次です。

Leg	standalone CV	blend weight
GBM (tabular)	6.65	0.05
sequence net (TCN)	6.32	0.51
candidate-curve ensembler	6.19	0.44
3-leg blend	**5.94**	—

Configuration	Candidates	CV	Public	Δ(Pub−CV)	Private
2-4 (Tabular, 15 candidates)	15	6.50	6.43	-0.07	6.67
leftover PF全投入	30	5.94	6.17	+0.23	6.382

2-6. Legを1つずつstack — Submission A / B（final form）

CV 5.94以降、**decorrelated candidate追加またはstronger smoothing**を1つずつ加えるたびCV/Publicが着実に下がりました。

Addition	Candidates	CV	Public	Δ(Pub−CV)	Private
2-5到達時	30	5.94	6.17	+0.23	6.382
① feature-combine、1 modelをretrain	46	5.75	5.707	-0.04	6.166
② fixed-lag→full smoothing	46	5.70	5.652	-0.05	6.097
③ +5 decorrelated PFs（**Submission A**）	71	5.587	**5.458**	-0.13	5.997
④ dec10 / tw-affine追加（**Submission B**）	91	5.458	5.626	+0.17	**5.984**

① **Feature-combine > ensemble.** separate training後blendするより、features（candidates）をcombineしてsingle modelをretrainする方が約2.6倍効きました。ensemblerの強さがcandidate quality×diversityなので、mixよりcombineが勝ちます。

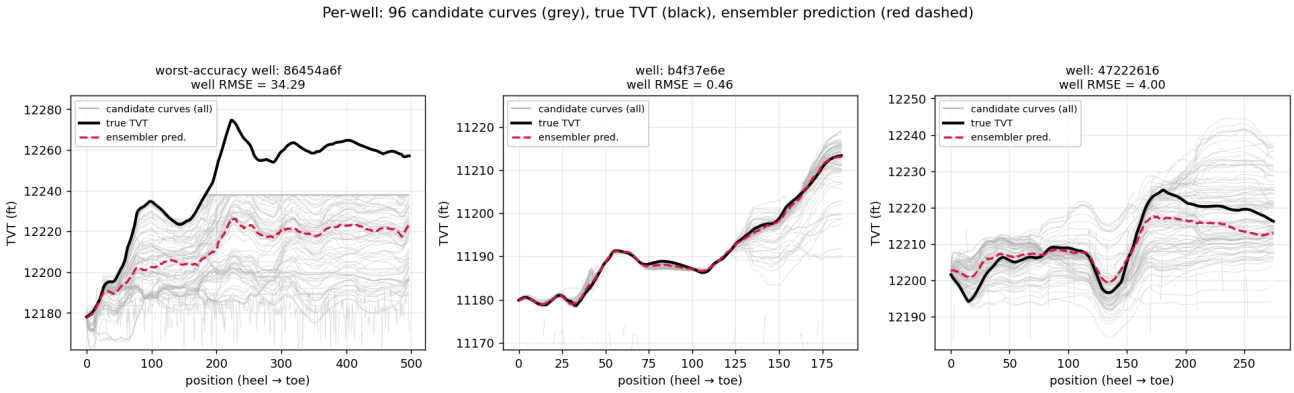
② **Full smoothing.** fixed-lagをwhole-interval ancestral smootherへ置換しました（Kitagawa 1996 / Doucet & Johansen 2009系で、whole intervalはpath degeneracyしやすい）。better candidatesをensemblerが直接享受し、**CV -0.043がPublicへ完全transfer**しました。

③ **Decorrelated PFs stack（Submission A）。** anchorもemissionもない別tuneの5 PFを足し46→71 candidates。**CV 5.70→5.587、Public 5.637→5.458**でCV以上のtransfer（-0.18）。主leverは、**単体で弱くても間違う方向が異なるcandidateだけが効く**ことです。0.99 correlated candidatesは無効でした。

④ **dec10 / tw-affine（Submission B）。** MD-decimated、noise-averaged GRのPFであるdec10と、prefix-calibrated GRのPFであるtw-affineを足し91 candidates、**CV 5.4577 / Public 5.626**です。

Post-processing（de-shrink）。 A/Bともensembler blend後へ**1-parameter global gain** `a≈1.03` **を適用します。soft averageでamplitudeがtruthより少しshrinkするため戻します。約-0.015 CV**と小さいですが、1 global parameterはoverfitしにくくrobustにtransferしました。well-level constant shiftはLBでbackfireしました。

逆にcross-attention、candidate relation、external leg injectionでensembler自体を強くしてもbaseとcorrelation約0.99でsaturateし、ensemble gainになりませんでした。headroomは異なるinformation sourceのdecorrelated candidatesだけでした。



final candidatesを3 wellsで可視化します（gray=all candidate curves、black=true TVT、red dashed=ensembler prediction）。**左=worst well:** truthが全candidateより上で全candidateがdatum branchを誤り、weighted averageでは到達不能です。**中央/右=random wells:** candidatesがtruthをbracketすれば良く当たります。

---

3. Discussion

3-1. Accuracy gain最大のdriver

最大driverは**PF output自体が多様だったこと**です。physical priorあり/なし、typewell/nearby well、prefix由来、full smoothingによるliftなど、思いつく全てをPFへ通しました。各candidate単体はoverall RMSE約10.0-7.8で強くありません。

率直には**大量PF outputのbagging**です。しかし異なる間違い方のcandidateを並べてfusionするだけでここまで精度が上がる好例でした。

3-2. Public LB biasとCV/Public/Private transfer

Discussionで「**ある条件下でPublicはoverfitする**」と述べました。**GR matchだけに依存するmethodがPublicへoverfit**すると考えます。

Configuration	CV	Public	Δ(Pub−CV)	Private	Transfer
5-input + smooth (GR-only)	7.50	6.724	-0.78	7.404	Publicだけ大幅に良い=GR overfit
self + nbr (GR-only)	6.98	6.026	-0.95	7.112	同じ（CV≫Public）
+ physical prior	6.50	6.43	-0.07	6.67	**CV≈Public≈Private**

final Privateで確認できました。CVはB<A（Bが良い）、PublicはA<B（逆）、PrivateはB 5.984<A 5.997でCVと一致しました。Publicだけがoutlierで、Bへ追加したconfigurationはPublic上overfitに見えただけでした。

3-3. Shake-down riskのあるphysical constraintを正しく作る

2-4のconstraintは強い一方、**誤って作るとPublic/CVへoverfitしPrivateで大collapse**します。最重要trickです。

他wellからdip fieldとcalibration coefficientsを作る際、evaluation wellの情報が少しでも混ざればanswerをpeekしCVが不正に良くなります。CV-LB transferを観察できず、Public順を信じたsubmissionがcollapseします。

対策は**必ずstrict 5-fold OOF**。foldのtraining-side wellsだけでdip field、calibration coefficients、neighbor poolを構築し、evaluation wellsを完全除外してfoldごとに再構築します。learned priorを注入するならleakageを**shakeの種**と考えます。

3-4. Per-row regression（tabular alone）が効かない理由

earlyはGBDTがleadingでしたが、精度向上後はsequence model + candidate selectionへ完全に置換されました。

rowごとに解ける問題ではありません。 strong PF後のerrorはsmall per-row wiggleではなく、segment全体がblockとして上下どちらかへshiftします。周期的strataによりGRは上下2箇所でほぼ同じで、segmentがupper/lowerどちらかはGRからcoin flipです。

per-row vectorには「segment全体がどちらへ乗るか」の情報がなくfeature追加でもplateauします。PFのcoherent trajectoryをcandidateとして並べsoft averageすればwhole-segment choiceを自然に表せます。tabularが悪いのではなく、**whole-segment two-way choiceへper-row regressionというframeが不適合**でした。

3-5. Privateでshake downしないCV設計

重視したのは**fold間varianceを小さくすること**です。Train/Public/Privateは完全random splitと考えられ、各約150 wellsと小さいためhard wellsが偶然固まりdownswingします。どちらsplitがbad drawかは制御できません。

だから**どのfold/splitでもcollapseしないdesign**が有効です。同averageでもhigh fold varianceならshake riskがあります。average向上と同じくらいdownswing除去が重要です。

final submissionの5 folds（各約155 wells）は約4-6.7、splitを引き直してもoverall CVは5.40-5.43（std約0.015）しか動きません。early baselineはper-fold 6-10で、大幅にspreadが縮みました。このdownswing resistanceがPrivateでcollapseしなかった理由の1つです。

3-6. Optuna-tuned PF parameterがCV overfitしなかった理由

773 wellsからrandomに600（または150）を選びPF tuningしました。少数wellではoverfitすることも確認しました。

ただしoverfitは**twGR representationに対してだけ**のようです。twGRでtuneしたparameterを性質の違うnbrGR/selfGRへそのまま再利用するとoverfitが薄まったと考えます。

3-7. Shake-upが起きた理由

gold zoneの大入替はPublic overfitが原因ではなく、**CV/Publicで優秀でもPrivateで伸びないmethodがあった**ためです。shake downした方々のmethodこそ価値があり、public-notebook overfitと混同すべきではありません。

surviveした上位を見るとHMM/PFなどphysics-based modelへ寄ったteamがほぼ一様に上がりました。split noiseかdomain choiceか断言できませんが、Public topとPrivate topでdominant solution domainが違いました。

別teamから「physical modelへ依存しないapproachはCV overfitしやすいかもしれない」と聞きました。私がshake-up側へ行けたのはluckも大きく、Public-topの非physics解法は優れていてもPrivate domain shiftを逃れられなかったと見ます。

---

4. What worked

- **PF parameterのOptuna tuning**（GR-likelihood σ、transition noise、resample、jumpなど）。良いcandidateの基盤。
- **複数PF parameter estimateをconcatenate**（3-input、5-input）してstepwise gain。
- **PFのGPU port**（約60倍高速）。より多くのtrialとsmootherを可能にした。
- **Smoother mechanism**。両側GR contextでstabilize。lag 192でCV -0.3/LB -0.4、leak-freeにtransfer。
- **alternative GR representations**。twGRに加えself、XY neighbor、GR-similarity neighbor、self-graftの計5。twGRと約0.7-0.8 correlationでaccurateかつcomplementary。
- **no-GR physical constraintをPF likelihoodへ注入**（常に5-fold構築）。CV/LBを整合しPublicのGR依存leniencyをneutralize。
- **candidateを1 curveずつsoft-averageするensembler**（selectionでなくhedge）。
- **decorrelated configurationのstacking**。異方向へ誤るcandidateだけがlate headroom。
- **feature-combine > ensemble**。別model blendよりcombineしてretrain。
- **full smoothing**。candidate-quality gainをensemblerが完全transfer。
- **sequence-NN（TCN）residual blend**。weak backbone上で最大lift。
- **de-shrink post-processing**。single global gain `a≈1.03` でCV 5.587→5.572（-0.015）。物理的でrobust。
- **FFBS-type particle smoothing（Godsill et al. 2004）**。whole-interval ancestral smootherとして有効だが遅すぎfinal不採用。lighter fixed-lag/full smoothingで代替。
- **PFはplain/singleにしcleverenessをdownstreamへ、tuning seedとinference seedを一致**。overfit回避。

---

5. What didn't work

- **well-category別PF tuning**: overfitしsingle fixed PFに大敗。
- **PF outputsのnaive average**: 別solutionへcommitしたestimateのmidpointになり壊れる。

- **selfGRをoutput blend（prediction）にする**: existing postprocessとdouble countしharmful。featureなら有用。
- **standalone physical/spatial constraintを強化**: CV低下でもLB backfire。prior densityが高いほどtransfer悪化。
- **well-level constant-shift postprocess**: OOF -0.075がLB +0.184。
- **ensembler selectionをsharpen（top-k / cross-attention / candidate-relation / external-leg injection）**: baseと約0.99 correlationでsaturate。
- **tabular row regression alone**: whole-segment two-way choiceへframe不適合。
- **PF-free 2D image CNN（GR-match image→U-Net）**: single CV良好でもLB 9.46へcollapse。
- **physical constraintをtabular featureへbake**: 良いGR-derived transferを殺しtrade-off。
- **two-way choiceへ直接attack（global-MAP / Viterbi / sparse mode-switching）**: GRはbranchを選べず、効いた部分は下のphysical constraintだけ。
- **条件付きでknown valueへpull back**: どのcriteriaもhitせず。
- **blend weightのmeta-learning**: hand-set fixed weightsに負ける。
- **heavy sequence architecture（iTransformer / Mamba / deep TCN / BiGRU）**: 同じcandidate再処理でsaturate、speed/benefitが悪い。
- **neighbor distanceをstratigraphic closeness proxyにする**: distance≠stratigraphy。best GR referenceはmedian約5,800 ft先。
- **backward augmentation（reversed-well synthetic task）**: early weak engineではCV -0.05/LB -0.16、final strong PF/ensemblerでは+0.2悪化。engineが強いほどDA gainが減衰/反転。
- **synthetic wells pretraining**: 失敗。ただしgenerator qualityが悪かった可能性が高く、approach自体を否定できない。

---

6. Additional notes

- **Environment & compute cost**
  - Training/experiments local: RTX 5070、AMD Ryzen 7 7700、32GB DDR5。全PF/NN trainingとexperimentを1 machineで実行し、timingもこの環境。
  - Submission Kaggle: T4×2。GPU generation、VRAM、numerical behaviorが異なり、hidden test OOM、bf16 fallbackなどに注意。
- **Final Submission BのPF parameters**: 16 Optuna-tuned setsを5 GR representations（tw/self/neighbor(XY)/GR-similarity neighbor/self-graft）と複数lagへ通し、合計91 trajectories（prefix affineでtw再calibrateする15 columns、MD-decimated 5 columnsを含む）。commonは `n_seed=32`、whole-interval smoothing、grid step 0.2 ft。`σ_def`=GR likelihood base width、`vn/pn`=rate/position process noise、`resamp`=resampling threshold、`anchor`=GR-free physical constraint strength、`emis`=learned similarity emission temperature `w_nn`。

bank	parts	gr_power	σ_def	vn	pn	resamp	jump	anchor	emis	role
pf_1	600	2.19	114	.0014	.0068	.061	.002	-	.02	original Optuna group

bank	parts	gr_power	σ_def	vn	pn	resamp	jump	anchor	emis	role
pf_2	600	2.00	71	.0011	.0113	.308	-	-	.02	narrow σ, high resamp
pf_3	600	2.07	67	.0007	.0439	.055	.002	-	.02	large pn = high position noise
r0	400	1.78	119	.0006	.0050	.032	.002	-	.02	different seedでre-tune
r1	400	1.46	83	.0012	.0028	.037	.002	-	.02	loose likelihood `gr_power`
pfA	600	1.85	87	.0009	.0061	.186	.002	**✓20**	.01	**physical anchor + emission**、CV=LBを揃えるpillar
pf_1'	800	2.99	131	.0009	.0405	.053	-	-	.02	separately tuned、sharp likelihood
pf_2'	500	2.08	95	.0010	.0366	.064	.002	**✓20**	.02	physical anchorあり
pf_3'	600	1.49	125	.0017	.0028	.212	-	-	.02	loose likelihood, high resamp
pf_4'	700	2.31	92	.0020	.0107	.040	-	**✓20**	.02	physical anchorあり
p_1	700	2.08	103	.0013	.0078	.046	.002	-	**0**	anchor/emissionなしの5 decorrelated PFs。 emission offでdiversityを保ちensembler最大gain
p_2	600	2.01	90	.0009	.0015	.207	.002	-	**0**	同上
p_3	800	2.36	122	.0016	.0086	.220	.002	-	**0**	同上
p_4	800	2.23	110	.0013	.0044	.140	-	-	**0**	同上
p_5	700	2.44	88			.030	-	-	**0**	同上

bank	parts	gr_power	σ_def	vn	pn	resamp	jump	anchor	emis	role
				.0013	.0063					
dec10	600	2.19	114	.0014	.0068	.061	.002	-	.02	pf_1 parameterを**MD×10-decimated** GRへ適用。noise-averaged decorrelated leg

すべて実際にOptunaが見つけた値です。exact full hyperparametersはreleased codeの`pf_banks_config.json`を参照してください。pointはsingle-model performanceでなく**error directionをscatter**することで、σ、gr_power、resample、anchor/emission有無を意図的に変えます。

- **Code**: GitHubで後日共有予定。
- **Submission Notebook**: https://www.kaggle.com/code/k256net/public20th-private6th-particle-filters

整理されておらず読みにくいかもしれません。rough referenceとして見てください。

---

7. Closing

私のapproachは他top finisherとかなり違うと思います。deep model knowledgeはなく、代わりに**PFが作るfeaturesを徹底的に改善**しました。powerful modelより「良いcandidateをどう作り、どうfusionするか」へ集中した変わった解法です。

organizers、Kaggle、Discussionでinsightを共有した皆様に感謝します。本当に新しく魅力的なコンペでした。質問があればcommentしてください。できる限り答えます。

このwrite-upはClaudeと共同執筆したため、欠落や誤りがあるかもしれません。

References

- N. J. Gordon, D. J. Salmond, A. F. M. Smith (1993). Novel approach to nonlinear/non-Gaussian Bayesian state estimation. IEE Proceedings F, 140(2), 107-113. Original bootstrap (SIR) particle filter。
- G. Kitagawa (1996). Monte Carlo Filter and Smoother for Non-Gaussian Nonlinear State Space Models. JCGS, 5(1), 1-25. PFとfixed-lag/whole-interval smootherの基礎。
- A. Doucet, A. M. Johansen (2009). A Tutorial on Particle Filtering and Smoothing: Fifteen Years Later. fixed-lag/ancestral smoothingとpath degeneracyを含むsurvey。
- S. J. Godsill, A. Doucet, M. West (2004). Monte Carlo Smoothing for Nonlinear Time Series. JASA, 99(465), 156-168. FFBS。

rogii-wellbore-geology-prediction

6位解法 — 補足Q&A

Rank	6
Team	k256.dev
Author	k256.dev
Topic ID	733226
Version	Japanese Translation

Source: https://www.kaggle.com/competitions/rogii-wellbore-geology-prediction/discussion/733226
Retrieved with Kaggle CLI on 2026-08-07.

選定済みの技術的Q&Aを日本語へ翻訳した追補です。

補足Q&A

Andrey Chankin（質問・観察）

私も似た解法で、20本だけですがdiverse PFとsupervised rankerを使いました。しかしbestでもPublic/Privateとも約6.2でした。

k256.dev（回答）

私の環境ではNN rankerを適用するとCV約6.0で、このコンペで作ったmodelの出力より悪く、ensemble価値はないと判断しました。PF trajectoryから有用情報を直接推定するのは難しいと思います。重要だったのはrow-level soft-blend baggingで、処理を単純にできました。

model自体はClaudeが作りました。理論上高精度になる理由は理解していますが、TCNやtabular modelよりなぜこれほど良いかは、今も完全には分かりません。

Angus Chang（質問）

私もself referenceとneighbor referenceという同じ2参照へ到達しましたが、逆方向に使いました。1つのPF modelへfoldし、branchとしてevidence-weighted averageでcollapseしました。あなたの2-5を見ると、このcollapseが失敗だったようです。

2-5の30 candidateは単純に6 parameter set × 5 representation、計30 PFですか？ また2-3（selfGR+nbrGR）のCV 6.98は5 parameter ×2 representationの10 candidateをquick blendしたものですか、それとも2-5のensemblerを使ったscoreですか？

k256.dev（回答）

1点目はその通りです。2点目は、`5 parameters × (twGR + selfGR + neighborGR)`の15 representationを2-5の形式で使いました。

`twGR+selfGR`と`twGR+neighborGR`を0.5:0.5でblendし、10 input parameterにする実験もしました。しかし5つのtwGR parameterだけを入力する場合より一貫して悪く、採用しませんでした。

Andrey Chankin（質問）

scoringにはどれくらい時間がかかりましたか？ また測定していればbest single PFのmetricはいくつでしたか？

k256.dev（回答）

総scoring timeは約7時間でした。1本のfull-smoothing Particle Filterを200 wellすべてで走らせると約250秒です。

最強のsingle PF-derived featureは記事中の6にある、twGR由来の`pfA`でした。inferenceでphysical anchorをpriorに使うとRMSE 7.5、ほかのPF variantは通常9.1〜10.5でした。physical anchorの有無は達成性能へ大きく影響します。

ただし記事にも書いた通りPF diversityが不可欠です。final submissionの全PFへphysical anchorを加え、同じinferenceをするとdiversityが失われ、RMSEは6.6になりました。

GR representation別の一般的傾向は次です。

```
twGR = affine-twGR ≥ nbr5GR > nbrGR ≥ selfGR > self_graftGR
```

twGRを上回るrepresentationはありませんでした。複数GRを1入力へ先にblendすると精度が下がりました。重要なのはcomplementaryなGR representationを別々にmodelへ与え、組合せを学習させることです。