rogii-wellbore-geology-prediction

# 11位解法（ソロ）— その井戸自身の既知区間を参照に使う

| | |
|---|---|
| **Rank** | 11 |
| **Team** | IIDA |
| **Author** | IIDA |
| **Topic ID** | 733305 |
| **Version** | Japanese Translation |

Source: https://www.kaggle.com/competitions/rogii-wellbore-geology-prediction/discussion/733305
Retrieved with Kaggle CLI on 2026-08-07.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

まず、物理的で奥深く、最後まで緊張感のあるコンペを開催してくださったROGIIとKaggleチームに感謝します。そして、入賞者の皆さん、おめでとうございます。

Public LBでは、私の最高提出でも6.280、207位でした。実際に最終選択した提出はさらに下で、Public 6.462、順位換算でおよそ1240位でした。しかしPrivateでは6.299となり、11位で終えました。

# 1. タスクとデータ

タスクは、各水平井の後半区間（掘削済みだが正解が隠されている部分）の各点について、地層に対する坑井の深さであるTVTを予測することです。入力は坑井軌跡（`X/Y/Z/MD`）、GRログ、前半区間だけ与えられる正解TVT、そして近傍の垂直井で測定された参照ログ（typewell）です。

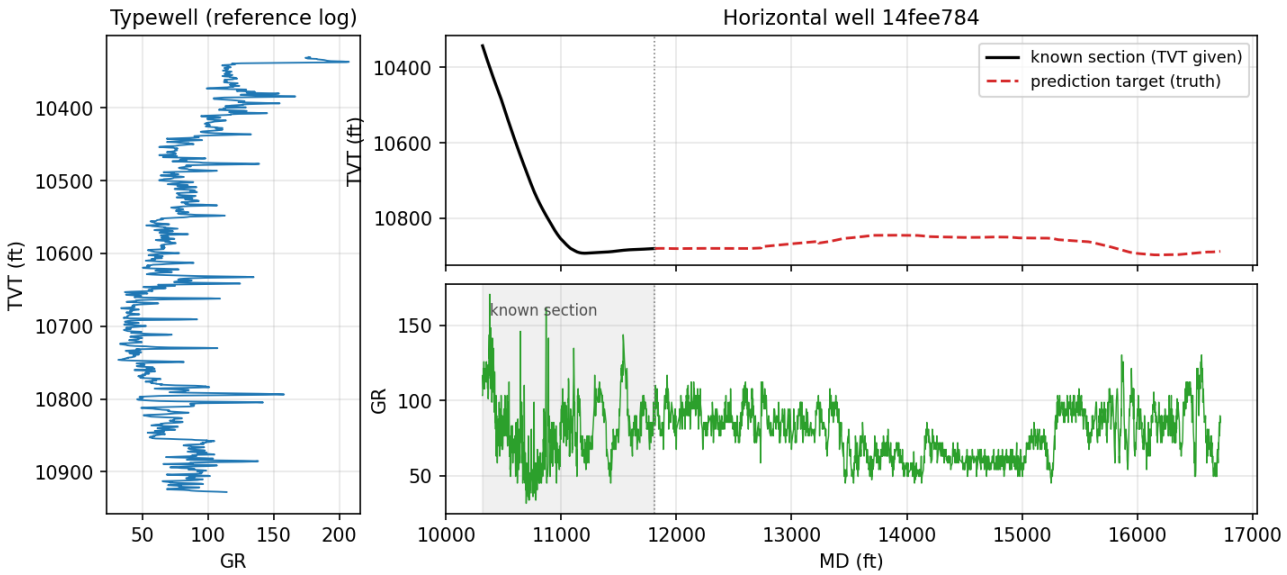



図1：学習用の1井戸。左はtypewell（深さに対するGR）、右上は坑井軌跡（黒がTVT既知区間、赤破線が予測対象）、右下は坑井に沿って測定されたGRです。GRをtypewellへ照合し、赤破線の深さを推定します。

モデルを構築する前に、ラベルとGRを突き合わせました。次の3つの観察が戦略全体を決めました。

## (1) 多くの井戸では、GRだけで深さを一意に決められない

多くの井戸では、GRの形状をほぼ同じに保ちながら、深さが数ftずれた複数の解釈が共存します。easy wellならGRから正しいものを選べますが、hard wellではコイントスに近い状態でした。そこで正解を無理に追わず、もっともらしい複数解釈の間に予測を置き、外したときの損害を抑えることにしました。指標はRMSE（二乗誤差）なので、正解回数を増やす以上に、大外しの幅を小さくすることが重要です。

## (2) typewellは見た目ほど信頼できない

typewellは別井戸で記録されているため、装置差、calibration、横方向の地質変化によって水平井GRからずれます。同じ深さで両者を比較すると、予想をはるかに超えて一致しませんでした。「typewellへもっと強くmatchingする」種類のアイデアはすべて、この壁にぶつかりました。

### (3) test wellはtrain wellより孤立している

test wellは、近くにtrain wellがない位置に置かれる傾向があります。近傍井戸から情報を借りる手法はCVでは効いてもtestでは役に立ちません。この状況をできるだけ再現するため、well単位のGroupKFold CVを使いました。

## 2. 解法の全体像

1つのmodelを磨くより、異なる外し方をする複数modelを混ぜる問題だと判断しました。観察(1)の深さ曖昧性により、どのmodelもどこかで大きく外します。違う場所で外すmodelを平均すれば、その大外しを和らげられます。

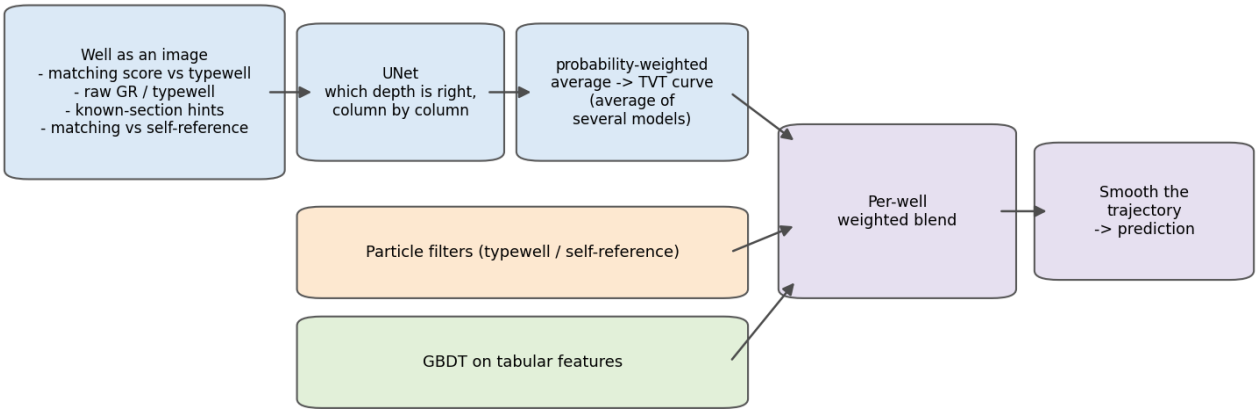



図2：簡略化したpipeline。中心は井戸を画像として解くU-Netで、異なる性質の予測をするParticle FilterとGBDTを加え、wellごとにblendします。

blend weightは一様ではなくwellごとに変えます。model同士が一致するwellでは素直に平均し、予測が割れるwellでは安全側へ寄せます。最後に予測軌跡を緩やかな曲線へsmoothします。真の地層境界は緩やかなので、予測の細かな揺れは誤差でしかありません。

最終版のCVは5.66（773 well、GroupKFold）でした。

## 3. 主model：井戸を画像としてU-Netで解く

この定式化はTucker Arrantsの26位解法と同じ系統で、彼のforum投稿は大いに参考になりました。

縦軸を深さ、横軸を坑井に沿う位置として画像を作ります。各pixelへ「坑井がここでこの深さにあると仮定したとき、そのGRがtypewellとどの程度一致するか」を描くと、正しい軌跡は画像上の暗い谷として現れます。これをU-Netへ渡し、列ごとに正しい深さを選ばせます。出力は各深さのlikelihoodなので、その加重平均を予測値にします。1回のforwardで井戸全体を予測します。

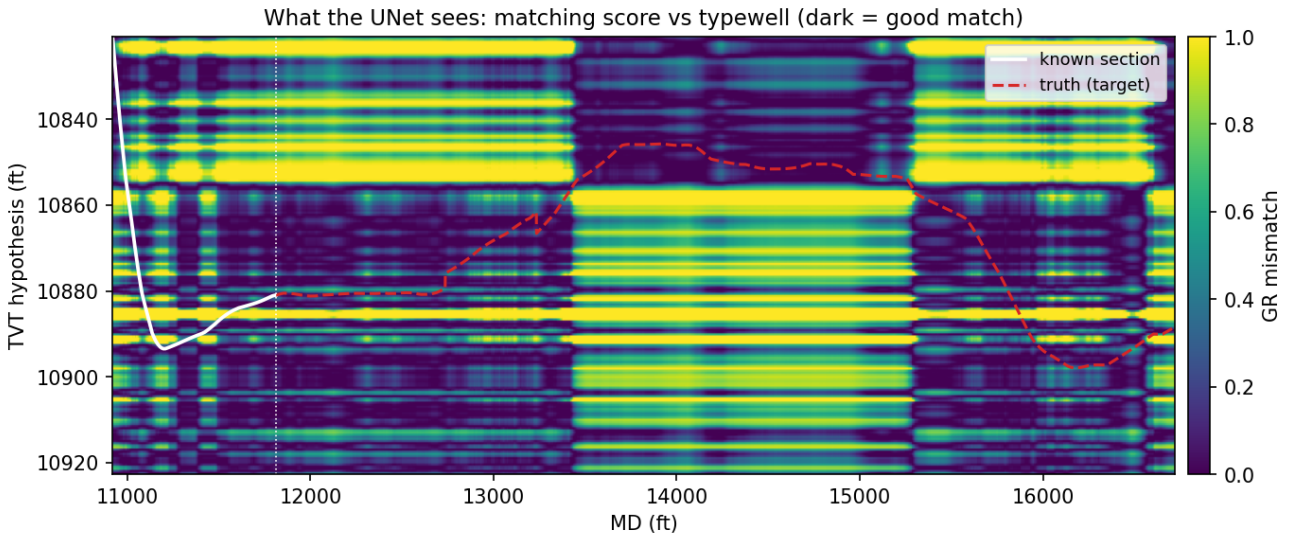



図3：実井戸のmatching-score画像（暗いほどGRがtypewellに一致）。truth（赤破線）は暗いbandの中にありますが、平行する暗いbandがほかにもあります。これが観察(1)の深さ曖昧性であり、modelはどのbandへ乗るかを決められないことがあります。

ここへ3つを追加しました。

- **補助入力**：matching-score画像に加え、生のGRとtypewell、既知区間のhint、軌跡のslopeも入力します。
- **複数modelの平均**：少し異なる設定でmodelを独立に学習し平均しました。華やかではありませんが、もっとも費用対効果が高い改善でした。
- **合成井戸によるpretraining**：人工の地層・軌跡・GRを作ってpretrainし、その後real dataで学習します。generator設定はreal dataの統計へ合わせました。

## 4. 最重要アイデア：typewellでなく、その井戸自身を参照する

このコンペでは、各井戸の前半区間について正解TVTが与えられます。つまり、同じ井戸で測定された`GR-vs-depth`表を手元に持っています。typewellと違い、同じ井戸・同じ装置・同じcalibrationで測られているため、観察(2)の不一致がありません。

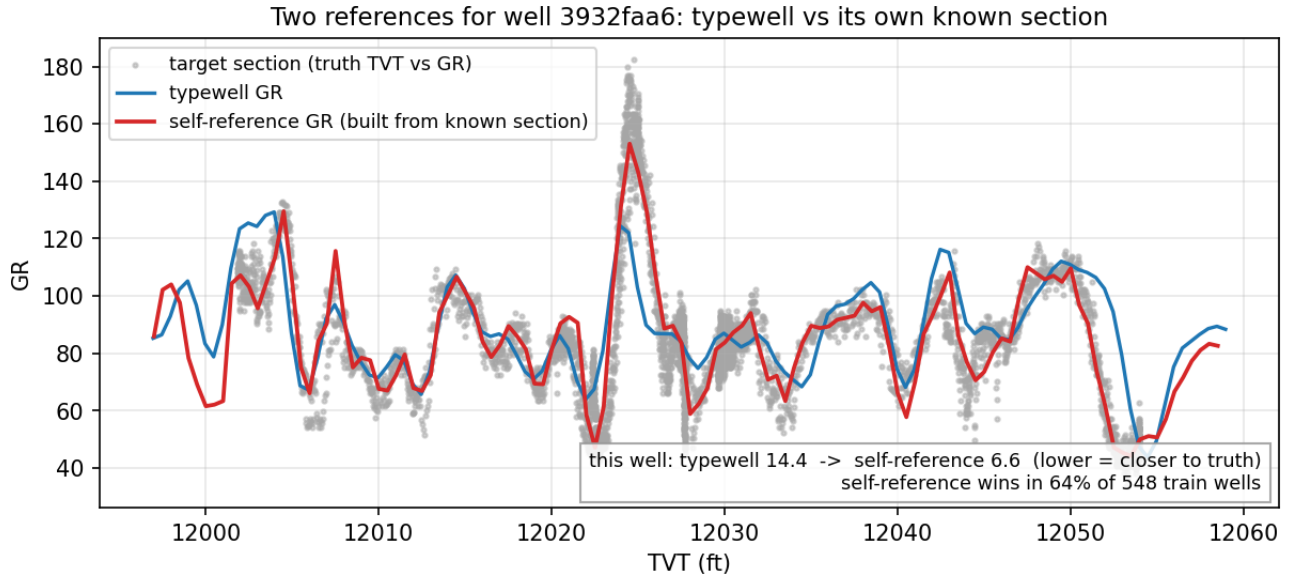


図4：学習井戸の予測対象区間（灰色点は正解の深さ対GR）へ、typewell（青）と既知区間から作ったself-reference（赤）を重ねています。このwellで正解GRへの近さをscore化すると、typewell 14.4に対しself-reference 6.6でした（低いほど良い）。評価できた548 well全体でも、64%でself-referenceの方が近い参照でした。

これを2通りに使いました。第一に、self-referenceに対するmatching画像を追加U-Net入力としました。これは終盤でもっとも有効だった単一改善です。第二に、深さ候補を確率的に追跡するParticle Filterの参照をtypewellからself-referenceへ交換しました。

self-referenceが存在するのは、既知区間が覆う深さ範囲だけです。その範囲外ではtypewellへfallbackします。