rogii-wellbore-geology-prediction

14位: Seed Averagingを使うHierarchical U-Net Stack

Rank	14
Team	keithtyser
Author	ktyser
Topic ID	733201
Version	Japanese Translation

Source: https://www.kaggle.com/competitions/rogii-wellbore-geology-prediction/discussion/733201
Retrieved with Kaggle CLI on 2026-08-06.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

soloで参加し、Public 80位からPrivate score 6.329の14位で終えました。

このwrite-upでは2つのmodelを扱います。実際に提出したものと、その3日前に作りPrivateではより良いscoreだった単純なmodelです。

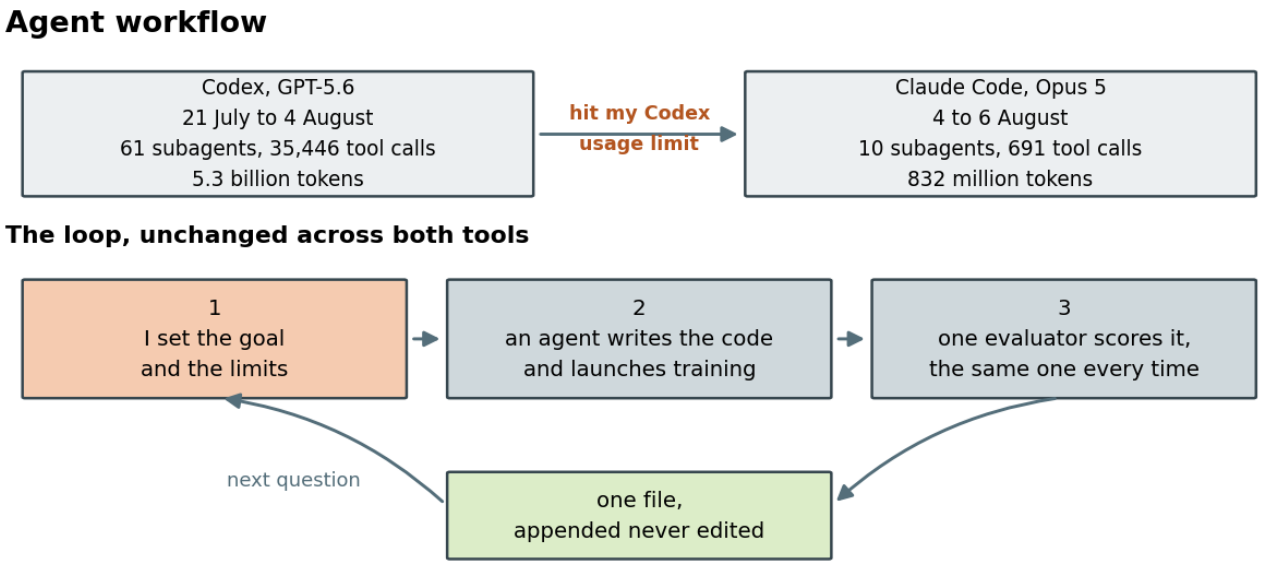
Code

- Training code: https://github.com/keithtyser/rogii-wellbore-geology-solution
- Final submission notebook: https://www.kaggle.com/code/keithtyser/rogii-construction-a-v1-submit?scriptVersionId=340272535

notebookはfrozen checkpointsからinferenceします。repositoryにはcheckpoint生成codeがあり、選んだ2つだけでなく13 submissionsすべてを扱います。

どのように作業したか

soloで参加しました。coding agentsを使ってcodeを書き、trainingをlaunch・monitorし、このwrite-upのdraftも作りました。何を試し何をshipするかは私が決めました。



7月21日からusage limitへ達した8月4日までGPT-5.6でCodexを使い、最後の2日はClaude Code with Opus 5へ移りました。toolは変わってもloop/workflowは同じです。

1つのorchestratorがplanとconstraintsを持ち、実作業が必要になるとfresh context、1つのquestion、読むhistoryなしのsubagentをspawnします。subagentが答え、orchestratorがappend-only ledgerへ記録して次へ進みました。

Agent ledger entries

agentsは1,338 entriesを記録しました。694件にRMSEがありますが、そのうち87件は完了結果ではなくepoch 12、13、20などmid-training readingです。13 entries続くchainも2つありました。完了experimentは607件です。残りはaudit、status note、packaging、infrastructureでした。

607件のsubject別内訳は次の通りです。

- neural network training runs: 302
- stacking, blending, gating: 98
- alignment, cross-well geometry: 50
- gradient boosting, tabular models: 48
- data, diagnostics: 25
- packaging, submission: 24
- その他60: particle filters、Viterbi beam search、spline cost encoders、dynamic-programming slope searches、signed-distance-field CNNsなど

outcome別では74件を採用し237件を棄却、135件は何も変えずに完了しました。

数字で見るagent利用

Codex phaseでは私から543 messages、返答5,411、61 subagents、35,446 tool calls（うち27,871 shell commands）、context compaction 314回でした。使用tokenは53億で、大半は再送され続けるcontextのcached readです。

Claude phaseは36時間、10 subagents、691 tool calls、8.32億tokensでした。

hardwareはRTX PRO 6000 Blackwell 2枚と、全submissionがcountされる前のcheckに使ったKaggle GPUsです。

得意なこと

第一のgainはspeedです。自分なら一晩かかるexperimentをagentは数分でwrite、launch、scoreします。16日間では、試す価値がある範囲自体が変わり、普段なら思い止まる案も試せました。coding agentsなしで16日間に607 experimentsは不可能でした。

第二に、人が止まっても働き続けます。job終了を監視し、resultを取得し、落ちたものをrestartし、queueの次項目へ進みました。睡眠中も仕事中も動きました。

コンペ最後の数日はvacation中でした。CodexとClaude Codeのremote controlでphoneからstateを読み、questionを投げ、次のrunを指定しました。check-inの間も作業は続き、final modelのseed farmはほぼ不在中に動きました。

未解決なのはagent自身にhill-climbさせることです。next stepを任せるとすぐplateauするか、local minimumへ落ち着いて磨き続けます。このコンペの本当の方向転換はすべて私が行いました。autonomous improvement workflowは今も模索中です。

機能させたもの

すべてが使う1つのevaluatorです。全runを同じ5 folds、773 wells、3,783,989 rowsでscoreしました。day 2のresultとday 14のresultを比較できます。これがなければ、agentが何百experimentを走らせても数字付きnoiseになるだけです。

append-only recordも重要です。ledgerは追記だけでeditしません。最終日にbest CVを尋ねたとき、答えは誰かのmemoryではなくfileから来ました。

promotion gateは事前に明文化しました。RMSEを0.01以上改善し、well-level cluster bootstrapの`P(gain > 0)`が0.9以上であること。607件中237件を棄却し、このruleはwrite-up中のどのmodelより価値がありました。それでも何度もoverrideしました。

questionごとにfresh contextを使います。1問しか見ないsubagentは、以前見たresultへ自分を誘導できません。

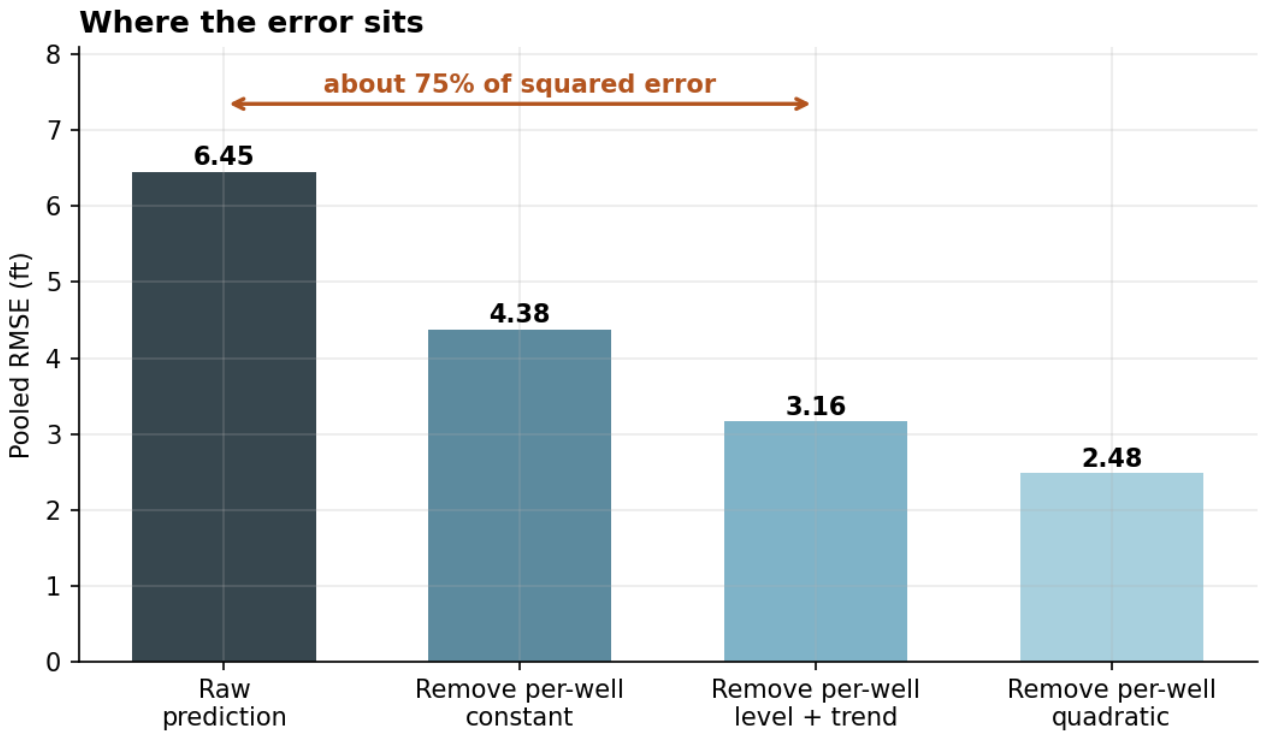
Credit

Tucker Arrantsのpublic workから始めました。wellのU-Net表現、synthetic-well pretraining、depth axis上のexpected value decodeは、彼がコンペ中にforumで共有したideaです。彼のwrite-upはarchitectureについて私のものより優れています。

Discussionで広まったidentityも使いました。`TVT + Z - ANCC`はwell内でconstantで、私のdataでは約0.03 ftまで成り立ちます。

Errorがどこにあるか

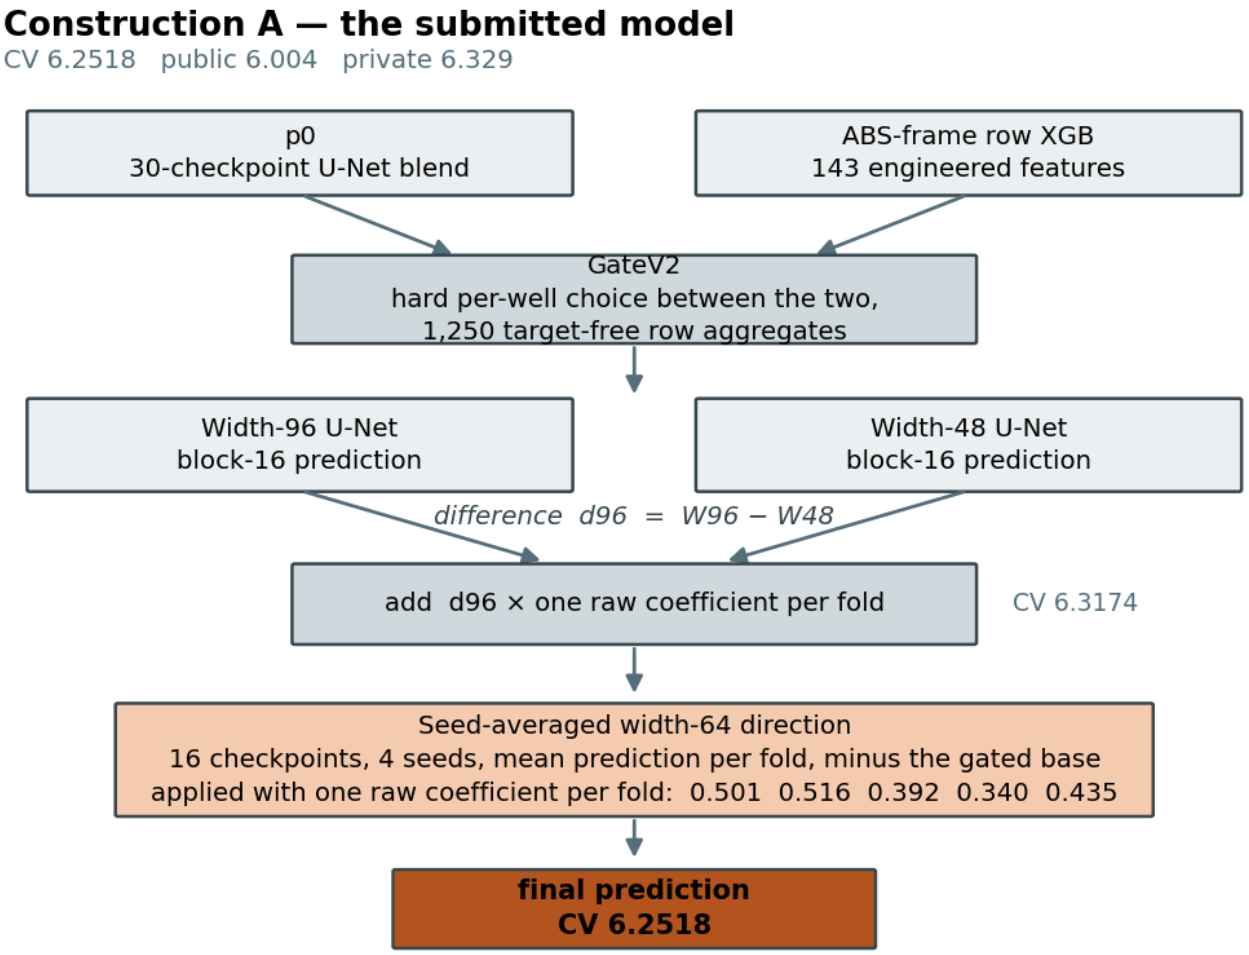
このauditを早期に行い、構築方針を決めました。predictionからfitted per-well constant、line、quadraticを順に除き、何が残るかを見ます。



wellごとに1つの数値を除くと6.45→4.38、lineを除くと3.16です。wellに沿うshapeはほぼ解けていますが、section内のwellのheightが解けず、squared errorの約75%を占めます。

したがって以下の全modelはbase predictionに、そのoffsetを狙うcorrectionを足します。

Submitted model



4 stagesです。

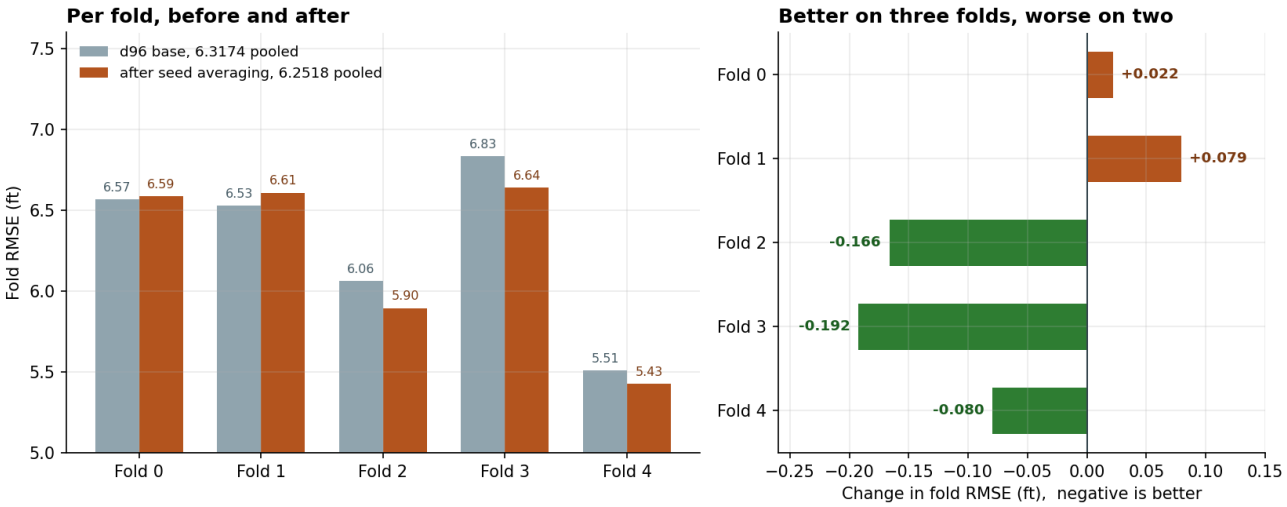
2つのbase predictionがあります。`p0`は30-checkpoint U-Net blend、もう1つはabsolute reference frameで143 engineered featuresを使うgradient-boosted treesです。

GateV2は2つのどちらかをwell単位でhard selectionします。targetに触れないrow featuresの1,250 aggregatesを読み、wellごとにmodelを選びます。単体scoreは6.3358でした。

d96 directionでは同じU-Netをwidth 96と48でtrainingし、block-16 predictionのdifferenceをbaseへfoldごとに1 raw coefficientで加えました。2 widthのdifferenceは単独predictionにないscale informationを持ちます。raw width-96 predictionはbaseより悪く2回rejectしましたが、differenceは改善しました。6.3174でsecond selectionとして提出しました。

seed-averaged directionではwidth-64 U-Netを4 seedsでtrainingし、fold内predictionを平均してgated baseを引き、foldごとに1 coefficientで加えました。合計16 checkpoints、final CV 6.2518です。

per-fold coefficientsは0.501、0.516、0.392、0.340、0.435で、rescaleせずraw directionへ適用します。repositoryでは `train/train_w64_seeds.sh` が16 checkpointsをtrainingし、`stack/fit_seed_direction.py` がcoefficientsをfitします。



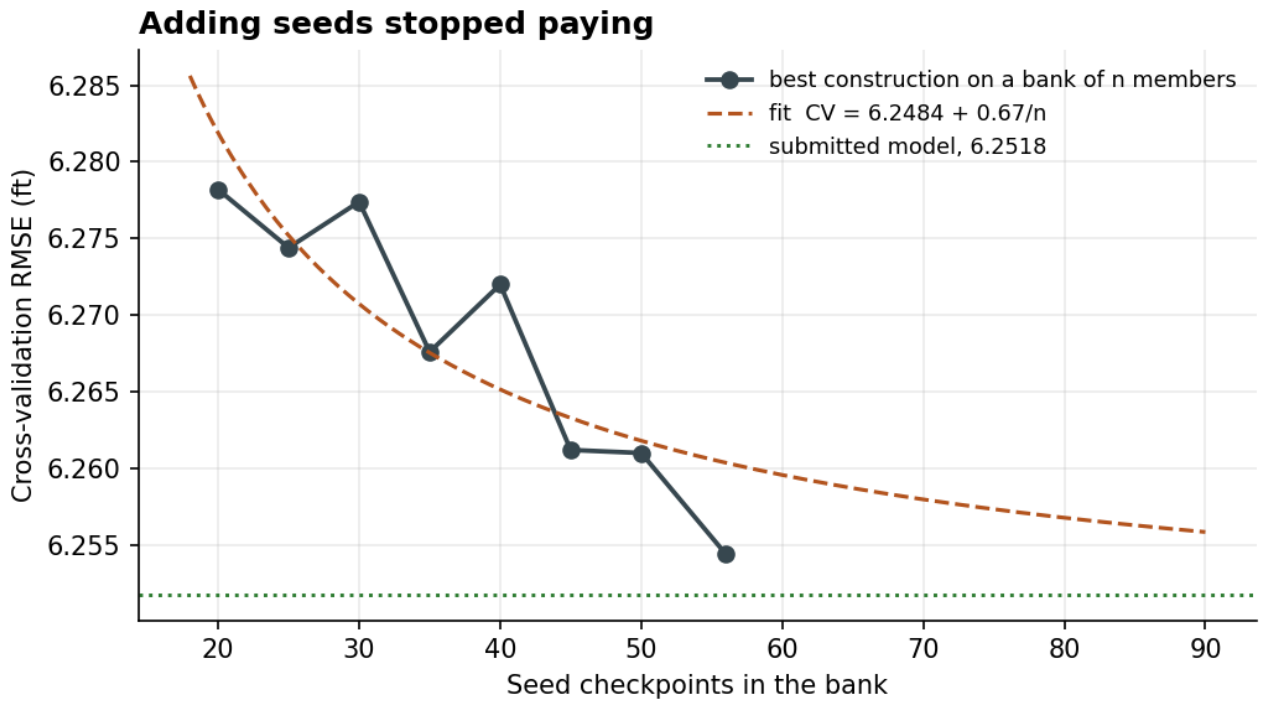
single seed directionは約-0.004、複数平均は+0.030、16-checkpoint rosterは+0.066でした。averageがseed間varianceを削り、合意部分だけが残ります。

late changeでPublicを動かしたのはこれだけで6.102→6.004、Privateは6.341→6.329でした。

ship ruleは0.01以上のCV gainかつwell-level cluster bootstrapの `P(gain > 0)≥0.9` です。seed averagingは0.936、多くのlate candidateは0.6-0.8でしたが、いくつかshipしてしまいました。

Seed averagingが止まった場所

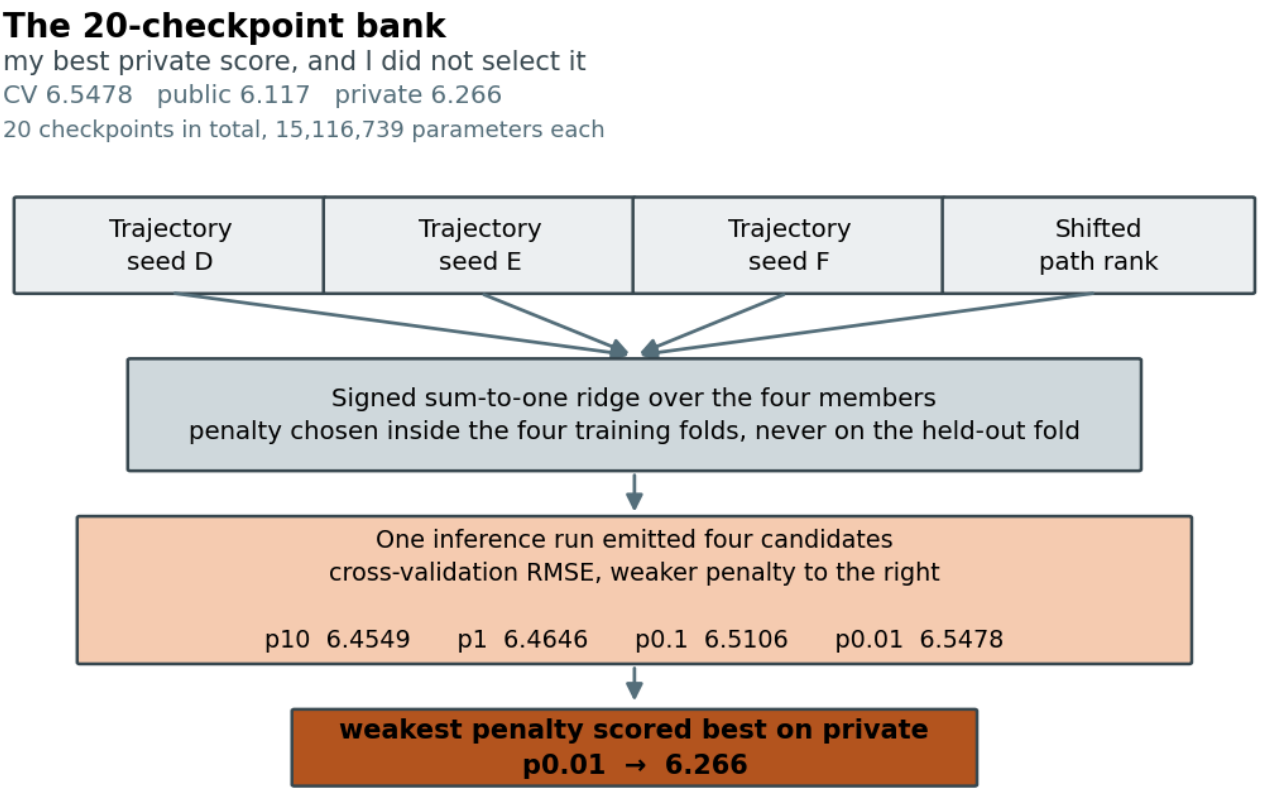
有用なtraining deadline後も58 checkpointsまでseedを増やし、bankを3回scoreしました。



curveはflattenします。`CV = a + b/n`をfitすると`a = 6.2484`なので、無限bankでも16 checkpointsとほぼ同じです。原因はfold 3です。11個のwidth-64 runsのbestは6.957ですが、frozen rosterの2 seedsは一緒に6.641へ達しました。depth追加ではこのpairを再現できませんでした。

Privateで最も良かったmodel

終了3日前にはもっと単純なmodelがありました。



3つのtrajectory seedでtrainingしたU-Netとshifted-path-rank variantの計4 members、20 checkpoints、各15,116,739 parametersです。signed sum-to-one ridgeでcombineし、penaltyはheld-out foldではなく4 training folds内で選びます。

1 inference runから4 penaltiesをshipしました。strongest penaltyはbest CV 6.4549、weakestはworst CV 6.5478でしたが、全submission中best Private 6.266でした。4つすべてでPrivate順序はCVと逆でした。

Validation方法

この部分は変更せず残したいsetupです。

早期に固定し二度と触れない1 split。whole wellでgroupedした5 foldsで、同じwellがtrainingとvalidationに跨りません。773 wells、3,783,989 rowsを全てscoreし、5 fold scoresのmeanではなく全fold rowsを一度にpoolしたRMSEを使います。small foldが数値を振るのを防ぎます。

OOF prediction上でfitするものはすべて4 foldsでfitし5つ目へ適用します。ridge penalties、gate thresholds、per-fold coefficientsも同様です。

gain判定にはcluster bootstrapを使いました。wellをreplacement付きで3,000回resampleしdifferenceを再計算し、改善したresample比率を読みます。well内rowは強く相関するため、row bootstrapではfalse confidenceが出ます。

このCVはPublicをよく追跡しました。10 submissionsでCV対PublicはPearson +0.83、Spearman +0.81。offsetも安定し、CVはPublicより平均0.34高く、CV range 0.43に対するstandard deviationは0.086でした。CV改善は通常Publicにも現れ、submit前にPublic scoreを概算できました。

2 submissionsの選択

first pickは簡単でした。Construction AはCVもPublicもbestで他と差がありました。

second pickは本当のdecisionで、間違えました。構造的に異なるものをhedgeし、2 picksが同じ壊れ方をしないようにしたかったため、別familyのXGBoost（Public 6.094）が候補でした。

そこで測定しました。全3,783,989 aligned OOF rowsで、XGBoostとConstruction Aのcorrelationは0.982、hierarchical d96 stackとは0.994です。tree対convolutionは意味のない区別でした。両方とも同じincumbent predictionへ小さなcorrectionを加え、同じ場所で間違えます。

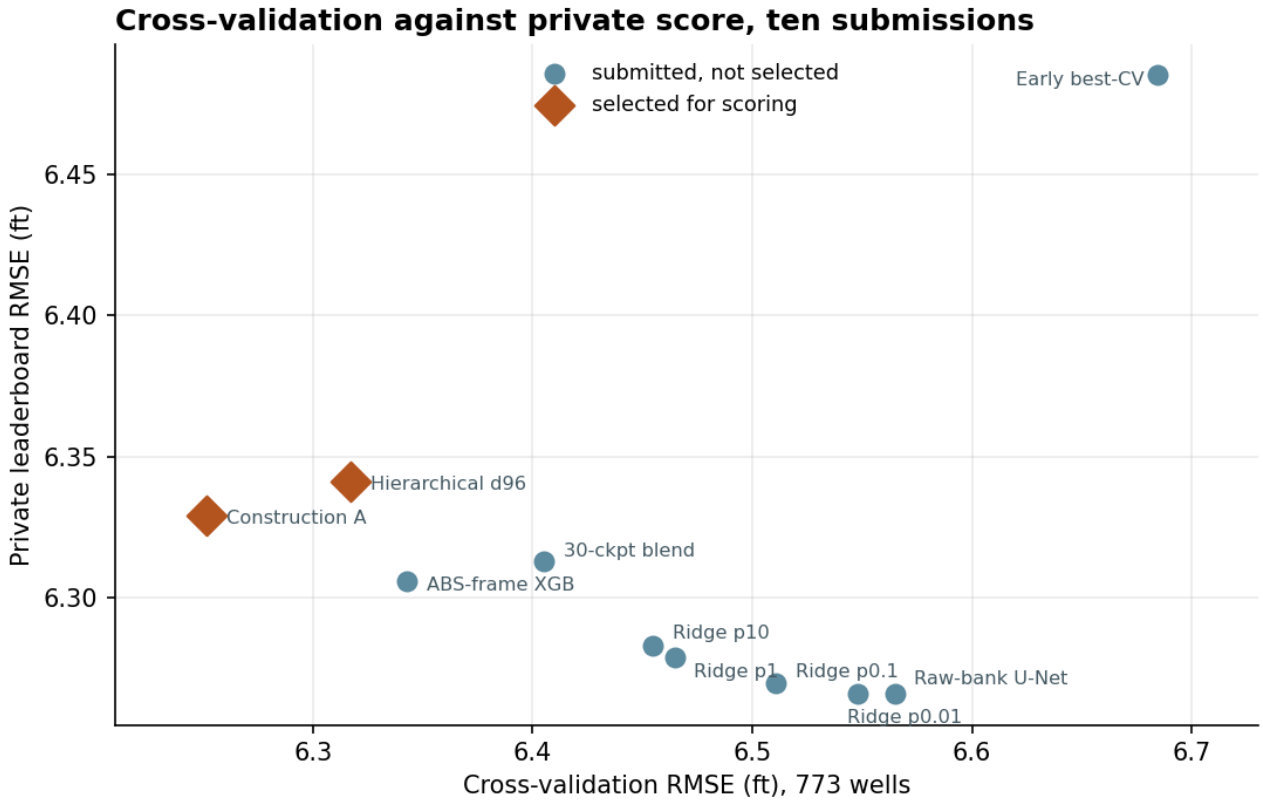
diversityの価値がほぼないためexpected scoreで選びました。148-well drawsのwell-cluster bootstrapでleaderboard同様pairの良い方を取り、d96 pairは6.213、XGBoost pairは6.214。tailもd96がわずかに良好でした。

d96 stackには別の理由もあります。Construction A内部のexact base layerなので、seed-averaged directionが転移しなければ、そのcomponentだけを除き残りを維持できます。異なるbetではなくsurgical fallbackです。

ここでPublicは無視し、再び同じ判断をします。6.093-6.119の9 submissionsは52-well splitのnoise内で、Public順に並べるのはtrapでした。

見逃したのは、両pickともCV ranking上位から選び、そのrankingがPrivateで逆向きだったことです。wrong directionを向くlistの同じ端から2つ選ぶのは、1 pickと同じです。

Final scores



Submission	CV	Public	Private
Construction A (selected)	6.2518	6.004	6.329
Hierarchical d96 (selected)	6.3174	6.102	6.341
ABS-frame row XGB	6.3429	6.094	6.306
30-checkpoint U-Net blend	6.4052	6.110	6.313
Deployable ridge p10	6.4549	6.093	6.283
Deployable ridge p1	6.4646	6.096	6.279
Deployable ridge p0.1	6.5106	6.108	6.270
Deployable ridge p0.01	6.5478	6.117	6.266
Deployable raw-bank U-Net	6.5648	6.119	6.266
Early best-CV U-Net	6.6846	6.258	6.485

Numbers

- 16日で1,338 log entries、うち607 finished experiments
- 54億tokens
- 773 wells、3,783,989 rows、固定5-fold whole-well grouped split、pooled row RMSE

- CV 7.51→6.25、Public 6.554→6.004、Private 6.329
- Compute: RTX Pro 6000 2枚

Thanks

architectureとforumでの回答を共有したTucker（@tuckerarrants）、structural identityとearly baselinesを共有した皆様、そして非常に楽しいコンペを開催したROGIIとorganizersに感謝します。