rogii-wellbore-geology-prediction

18位 Solution

Rank	18
Team	yu4u
Author	yu4u
Topic ID	733250
Version	Japanese Translation

Source: https://www.kaggle.com/competitions/rogii-wellbore-geology-prediction/discussion/733250
Retrieved with Kaggle CLI on 2026-08-06.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

素晴らしいコンペを開催したhostとKaggle staffに感謝します。

Tucker @tuckerarrantsにも感謝します。当初はPF、neighboring wellsのstatistical features、1D/2D CNN featuresを組み合わせた大規模stacking architectureを使っていました。しかしtarget wellのdataだけを使うsingle modelでCV 5.xが可能というTuckerのcommentを見て、single-model solutionの改善へ集中する勇気をもらいました。

TL;DR

- geosteeringを**image-recognition task**へ変換します。lateral GRとtypewell GRのmatching surfaceを2D imageにrenderし、CNNが正しいpath（ridge）を選びます。
- imageのvertical axisを、known well trajectoryから引いたreference line（chord）からの**offset**として定義します。予測rangeを縮め、well全体を**高解像度の狭いvertical window**へ収めます。これが最大のleverです。
- 773 training wellsしかないため、測定したnoise modelでrenderした**synthetic samples**（typewell depth shifts / geology swaps）を使ってtraining dataを多様化します。
- final submissionはbackboneとresolutionが異なるchord modelsの**fixed-weight linear blend**です。

Problem intuition

各wellでは冒頭prefixだけground-truth TVTがあり、残りを予測します。地質は層状なので、「現在のGRがtypewellのどのdepthに似るか」がTVTの証拠です。これがgeosteeringです。

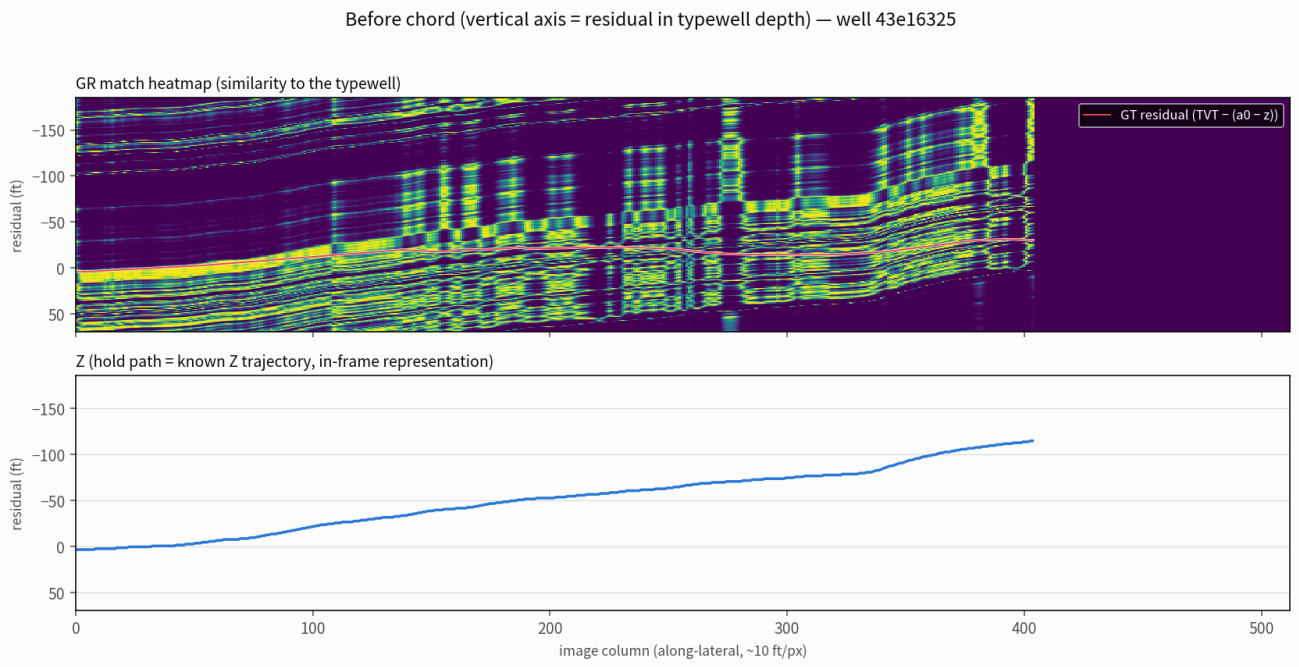
難しさはmatchingの**multimodality**です。GR columnsには自己相似区間が多く、複数candidate depthがparallel ridgeとして並びます。errorの大半は、少数wellが**wrong ridgeへjump**するwrong-modeから生じるため、本当の問題はstep精度でなく正しいridgeの選択です。

Method: 各wellを1枚のimageにしpathを推定する

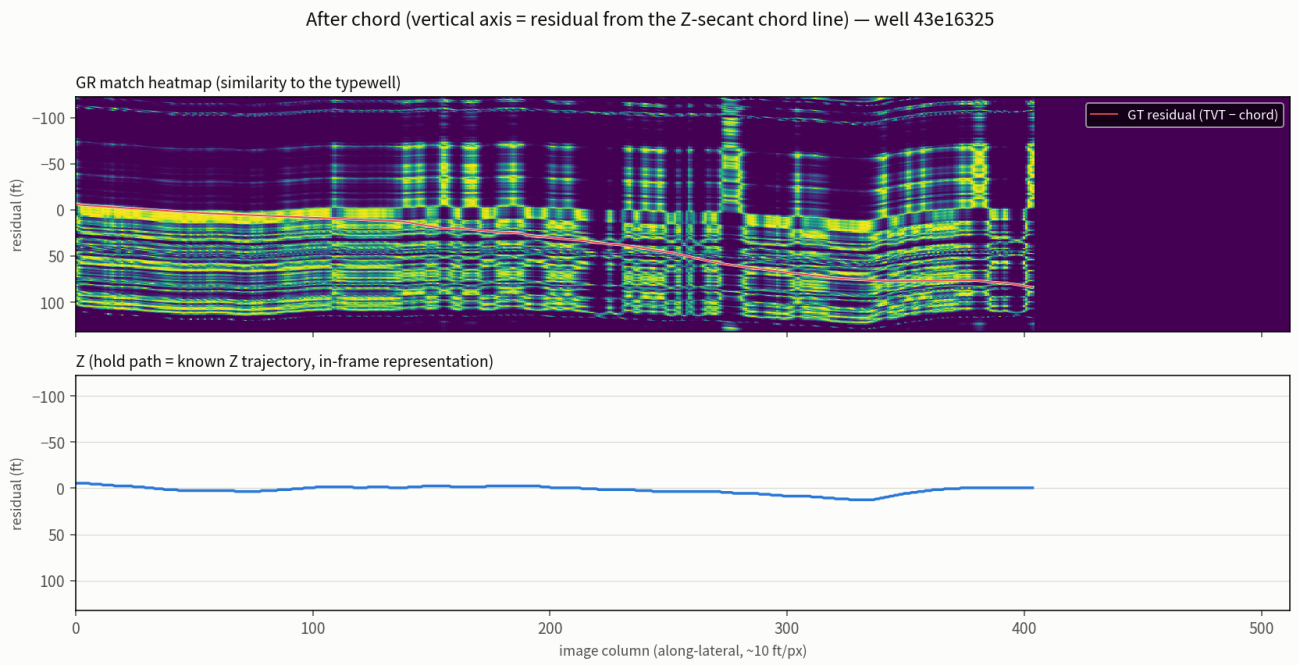
rowごとのregressionではなく、well全体を1枚の2D imageへ変換し、「image上の正しいpathをtraceする」問題として解きます。

Reference line（chord）からのresidualをvertical axisにする — core idea

horizontal axisはwellに沿うposition、vertical axisはcandidate TVTです。狙いは**予測rangeを狭め、その分をvertical resolutionへ使う**ことです。typewell depthをそのままvertical axisにするとtrue pathがimage内を広くdriftし、全wellを覆うには高いwindow、すなわちcoarse resolutionまたは巨大imageが必要です。



代わりにknown well trajectory（Z）のstartとendを直線で結び、**chord**とします。その線からの**offset**をvertical axisにするとrangeが劇的に縮みます。

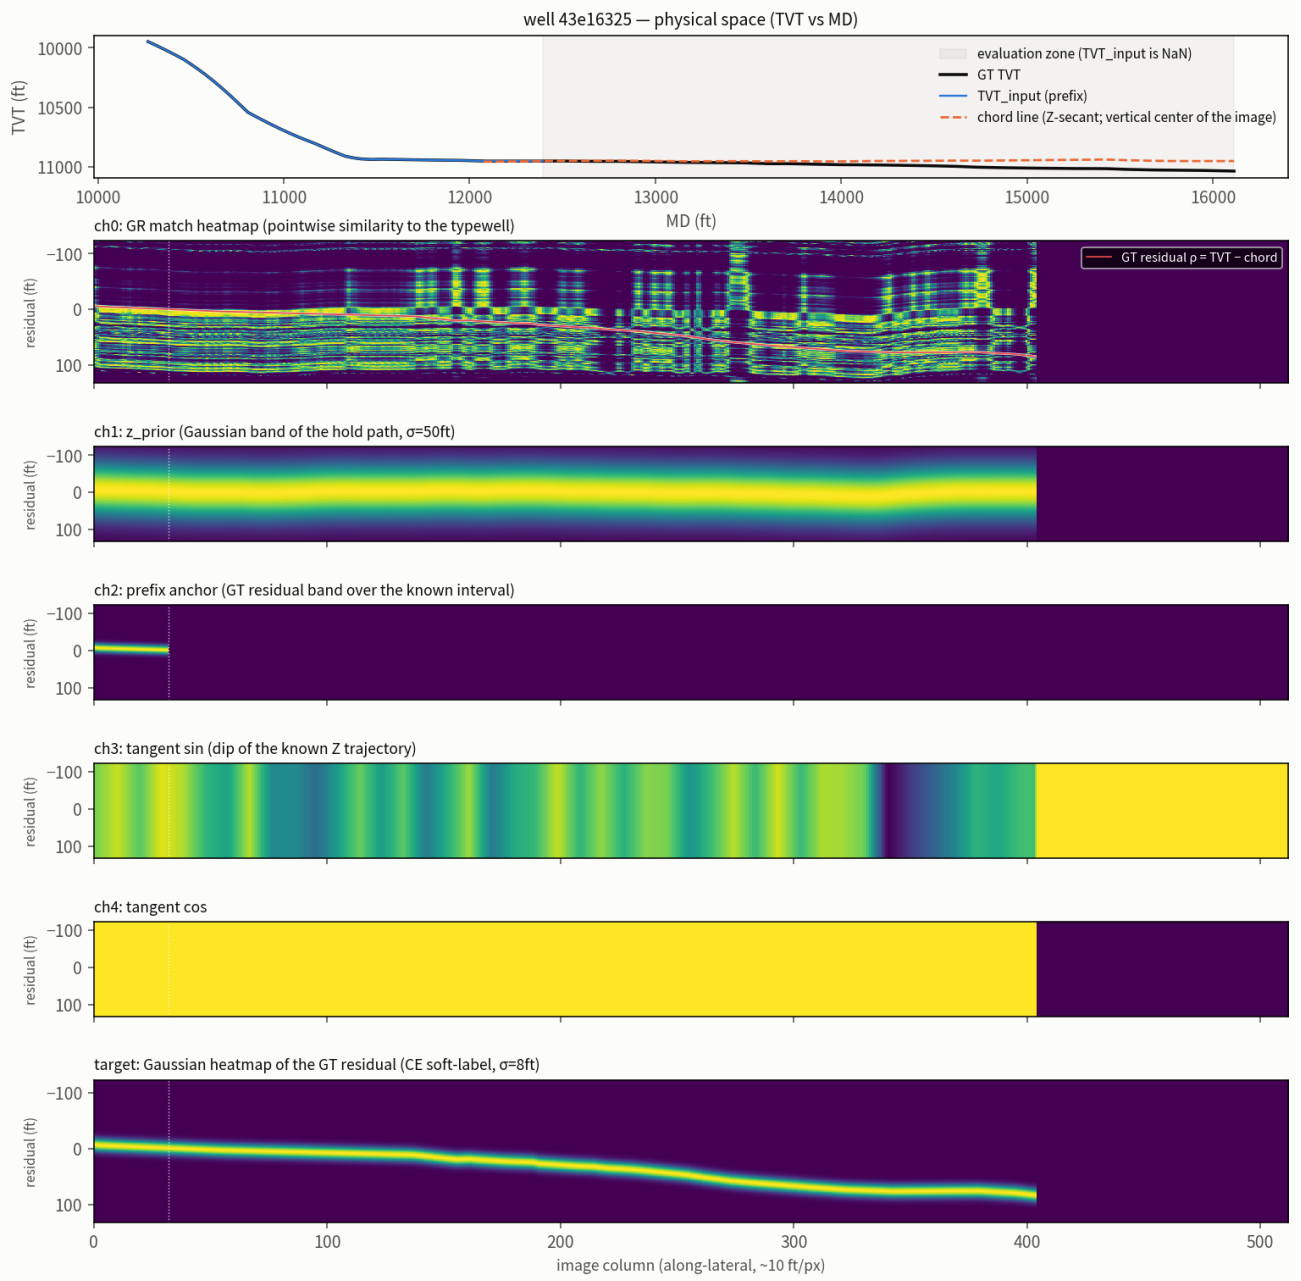


- 同じimage sizeで各vertical pixelを0.5-1 ft/binまで細かくできます。
- GR matching scoresはtypewell depth axis上で一度precomputeし、各columnでchordに沿いvertical shiftして読み直すだけです。`TVT = chord + residual` で物理値を常に復元できます。
- first-stage model predictionからreference lineを引く2-stage setupも試しましたが、resolutionとwindow sizeを直接scaleできるようになると、**known trajectoryから機械的に引く単純なchordが最強**でした。

Input image

horizontal axisはwellに沿うposition（約10 ft/px、512 columns）、vertical axisはchord offset（modelにより0.5-1 ft/bin、±96-128 ft window）です。5 channelsを使います。

- **GR matching score**: 各positionのGRと各candidate depthのtypewell GRの一致度（precomputed）。true pathと誤誘導するfalse pathsが複数ridgeとして見えます。
- **Prior from known trajectory**: TVTがlast known valueに留まると仮定したpathをsoft bandで描画。absolute depth levelのcueです。
- **Ground truth over known interval**: answerが与えられるprefixのtrue path。「ここから始める」というmarkです。
- **Trajectory dip (sin/cos)**: known well trajectoryのlocal inclination。



Model

modelはimageを受け取り、各columnでtrue pathのvertical positionを推定します。2 head typesを使いました。

Heatmap headはcolumnごとのvertical probability distributionを出すUNetです。true position中心のGaussian soft label（σ=8 ft）へcross entropyでtrainingし、inferenceではheatmapの期待値をchordへ足してTVTを復元します。上図bottom panelがtraining targetです。

Detection headはobject detection風です。vertical axisをcoarse cellsへ分け、各columnでtrue pathを含むcellをclassifyし、cell centerからのoffsetをregressします。DINOv3-pretrained ViT backboneと組み合わせ、heatmap modelsとのerror correlationが低いensemble memberになりました。

Synthetic data

real lateralはtypewell columnの約30 ftしかsampleしません。trainingでは次を使います。

- **shift**: typewell内でwellが`s0` ft深く/浅くdrillされたと仮定し、typewellからGRを再render。geometryとground truthはrealのまま、evidence channelだけ多様化。
- **swap**: さらにGR waveform（geology）を別wellのtypewellで置換。
- re-rendered GRへ**measured noise model**（per-well gain + colored noise、real coherenceへcalibrate）を加えます。cleanすぎるsynthetic GRは有害でした。
- training後半にsynthetic fractionを0へlinear annealする**dose decay**も一部modelで有効でした。

Augmentation

- **crop**: vertical window centerとknown/unknown boundaryをjitterし、多様なprefix length/window positionを見せる。
- **vertical flip**: chord residualはsign flip対称なのでinput/targetを一緒にflip（p=0.5）。inferenceとcheckpoint selectionでもflipped viewと平均するvflip TTAを使う。
- **horizontal flip**: drilling directionをreverse。horizontal sectionだけflipするのがbest。
- **horizontal resize**: U(0.7, 1.3)でrandom resize。long wellは512 columnsにcompressするためtrainingでscale variationを覆う。
- **vertical resize**: wellごとにresidual scaleが違うためU(0.8, 1.25)でvertical resizeしmulti-scale training。readoutでphysical mappingを復元。

evaluationはwellでgroupedした5-fold CVです。

Ensemble and final submission

同じinput representation上でbackbone、head、resolutionの異なるmodelを作り、standalone accuracyでなく**error decorrelation**で選びました。single-model CVは2か月で6.4→5.2へ改善し、主因はcoordinate system（chord、resolution、window）とsynthetic dataです。

final submissionは次の4 modelのfixed-weight linear blendです。一部slotは同一configurationのre-training runsを平均してvarianceを下げています（CVは平均後）。

Model	Input size (W×H)	Vertical resolution	Backbone	Head	CV (5-fold pooled)
1	512×384	0.5 ft/bin	EfficientNetV2-L	heatmap	5.19
2	512×256	1.0 ft/bin	EfficientNetV2-L	heatmap	5.20
3	512×512	0.5 ft/bin	ConvNeXt-S	heatmap	5.17
4	512×384	0.5 ft/bin	DINOv3 ViT-L/16	detection	5.48
Ensemble					**4.91**

Public LB 6.249 / Private LB 6.411でした。

What didn't work（抜粋）

- raw GR / learned GR matching / GR denoiserをinputへ追加すると、modelがそれらの「もっともらしいsummary inputs」に依存し、特定foldがcollapseしました（prior amplification）。match heatmapとしてevidenceをそのまま見せるのが最も安全でした。
- explicit ridge decoding（Hough / DP）、particle filterのforward-backward smoother、typewell-specialized models、self-training。
- wrong-mode wellsを救うためposteriorをmultimodalにする試み（CE-only training、mixup）。posteriorは分裂せず、wrong-modeはlossでなくevidenceの性質でした。readout trickより「field quality」（frame、resolution、synthetic data）への投資が勝ちました。