rogii-wellbore-geology-prediction

Private 20位 / Public 3位解法：RAFTでrefineするGR↔typewell matcher

Rank	20
Team	Yannan Chen
Author	Yannan Chen
Topic ID	733845
Version	Japanese Translation

Source: https://www.kaggle.com/competitions/rogii-wellbore-geology-prediction/discussion/733845
Retrieved with Kaggle CLI on 2026-08-10.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

まず、このコンペを開催してくださったROGIIとKaggle communityに心から感謝します。

これまで取り組んだ中でも屈指の楽しいproblemでした。本当に難しく、しかもwide openで、試す価値のある切り口がいくつもありました。過去の多くのコンペでは、ideaを十数個試してすべて失敗し、1つのsimpleな方法へ戻ることがよくありました。このコンペは逆でした。**More really is more**で、驚くほど多くのideaが実際に機能し、stackできました。最終的なmain modelはdeep-learning matcherです。全体を順に説明します。

---

1. Big picture：multi-pathでdecorrelateしたensemble

最も重要なlessonは、**強いmodelが1つあっても、相関しないexpertを加える価値は大きい**ということです。私のmatcher（`grtx`）単体はすでにPublic LB 5.08でgold圏でした。それでも、異なる場所で間違える別pathを加える意味はなくなりませんでした。

3 paths、3 mechanismsです。

- `grtx` — **main force**：single-well GR↔typewell iterative-registration Transformer。neighbor wellもkrigingも使わない純粋なsingle-well情報です。scoreの大部分はここから来ます。
- **Physics path** — `pfnet` + `pftree`：GPU particle filterをphysical baseとし、そのresidualをneural/tree modelが学習します。GRとspatial priorを「physics流」に融合します。
- **Geometric path** — `ancc`（**kriging**）+ `geotx`：GRを全く使わず、geometry / neighbor-well geologyだけを外挿します。単体では弱いものの、GR matcherとorthogonalです。

blendは単純なper-point weighted sumで、残りのweightを`grtx`が受け取ります。

```
out = (1 − w_pf − w_ancc − w_geotx) · grtx
      + w_ancc · ancc  +  w_geotx · geotx      ← geometric path
      + w_pf   · (pfnet / pftree)              ← physics path
```

非自明な点は1つで、geometric pathでは距離に応じてweightを変えます。

`w = W / (1 + (nd/D)²)`で、`nd`はそのpointから最も近いneighbor-well ANCC control pointまでの距離です。

- wellが密なarea（`nd`が小さい）→ geometric legへ実質的なweightを与える（neighbor geologyを信頼できる）
- isolated well（`nd`が大きい）→ weightをほぼ0へ減衰させる（extrapolationを信頼しない）
- `ancc`は速く減衰（`D≈250–700`）、`geotx`は遅く減衰（`D≈1200–1500`）。anccは近距離、geotxは中距離で強く、crossoverは`nd≈300`
- `pfnet`/`pftree`は**fixed weight**。per-well / per-point gatingはCVで素晴らしく見えましたがLBで崩れました（「selection wall」。§5参照）

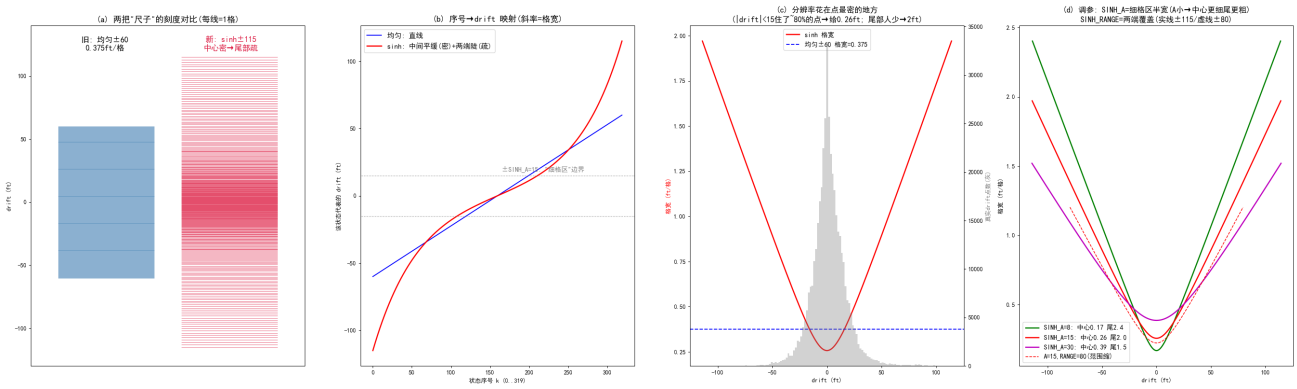
---

2. `grtx` — main force（`grtx-XXX`と表記するmodel群）

これはGR-matching problemです。horizontal-well（**hw**）GR logは、typewell（**tw**）GR profileを歪ませ、shiftしたcopyであり、各pointのvertical `drift`（ΔANCC − ΔZ）を求めます。したがって`grtx`は、2本の1-D log（hwとtw）の間にある**learned image-registration model**です。

2.1 Dataとfeature handling

- **CV strategy**：plain **5-fold random**（well単位GroupKFold）。全LB submissionは5 foldsのmeanです。
- **重要だったdimension選択**：
  - horizontal GRを**16 ft/sample**へcompress（`COMPRESSION=16`）。12 ftと24 ftはいずれも悪化しました。
  - horizontal wellあたり`N=768` samples、typewellを`S=320` statesへresample。**すべてanchor相対でindex化**します（known→eval transitionではdrift=0で、sinh state gridもここをcenterにする）。
  - `INPUT_CLIP=80`：known sectionはanchor±80 ftだけを保持します。遠いknown dataには相関がなく、実際に悪化しました。
- **sinh non-uniform state grid（key trick）**：drift distributionは狭いfunnelで、大半のmassはanchorから数ft以内ですが、tailは±100 ft以上へ届きます。uniform ±60 gridは密なcenterへ解像度を浪費しながらtailをcoverできません。そこで`g = A·sinh(b·t)`上へstateを配置しました。centerでは約0.26 ft/cell、tailでは±115 ftまで伸びます。解析的にinvertでき、cell探索はclosed-form `asinh`なのでbinary searchも不要です。



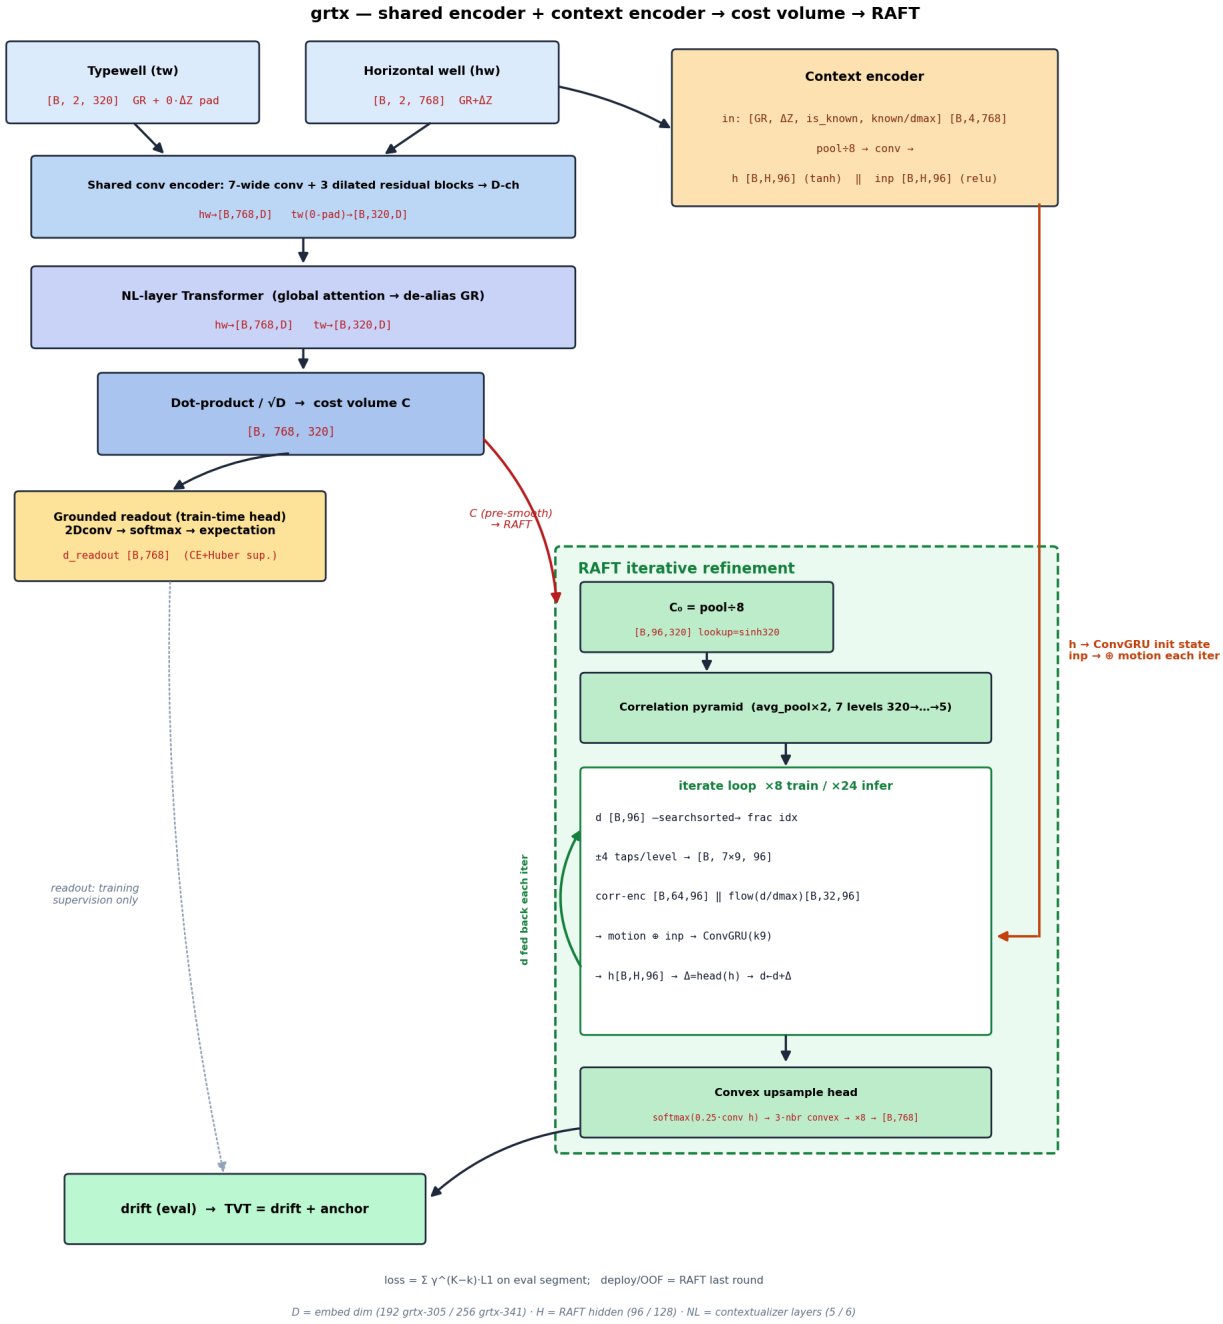
左から右：uniform gridとsinh grid、sinh cellからdriftへのmapping、その理由。drift probability massがある場所へcell resolutionを使います。

- **Per-well joint robust norm**：hwとtwをconcatenateし、**1つの**shared median/MADでnormalizeします。これによりhw↔tw gain relationshipを保ちながら、modelがwell identityをmemorizeし得るpairごとのoffset/scaleを除きます。

2.2 Architecture：shared encoder → Transformer → RAFT

- **Shared encoder（hwとtw）**：両方のlogを**同じ**conv stem（weight shared）へ通します。hwは`[GR, ΔZ]`の2 channelsです。typewellはclean GRのみなので、shapeを2 channelsへ合わせるため**all-zero ΔZ channel**を与え、同一encoderを適用します。weight sharingは重要でした。logごとに別stemを使うとCVが悪化しました。同じfeature spaceに埋め込むことがmatchingを保ちます。

- **Transformer contextualizer**（5–6 layers、dim 192–256）：GRはinjectiveではなく、同じ小さなwiggleが何か所にも現れます。local matchingは曖昧であり、global attentionがdisambiguateします。
- **Grounded readout**：cross-attentionでcorrespondence/cost map `C` を作り、`drift = C @ ref_drift` とします。`C` がtrue drift stateでpeakを持つよう直接supervise（`CE_W=10`）し、cost map上の2-D conv（stereo/optical-flow style）でregularizeします。
- **RAFT iterative refinement**：**RAFT**の1-D adaptationです（Teed & Deng, RAFT: Recurrent All-Pairs Field Transforms for Optical Flow, ECCV 2020 — arXiv:2003.12039）。correlation pyramidは7 levelsで、各roundの±4-tap lookupを合わせると±115 ft state axis全体をcoverします。ConvGRU updateとconvex upsamplingでdrift estimateを反復更新し、deployでは最後のRAFT iterationを使います。



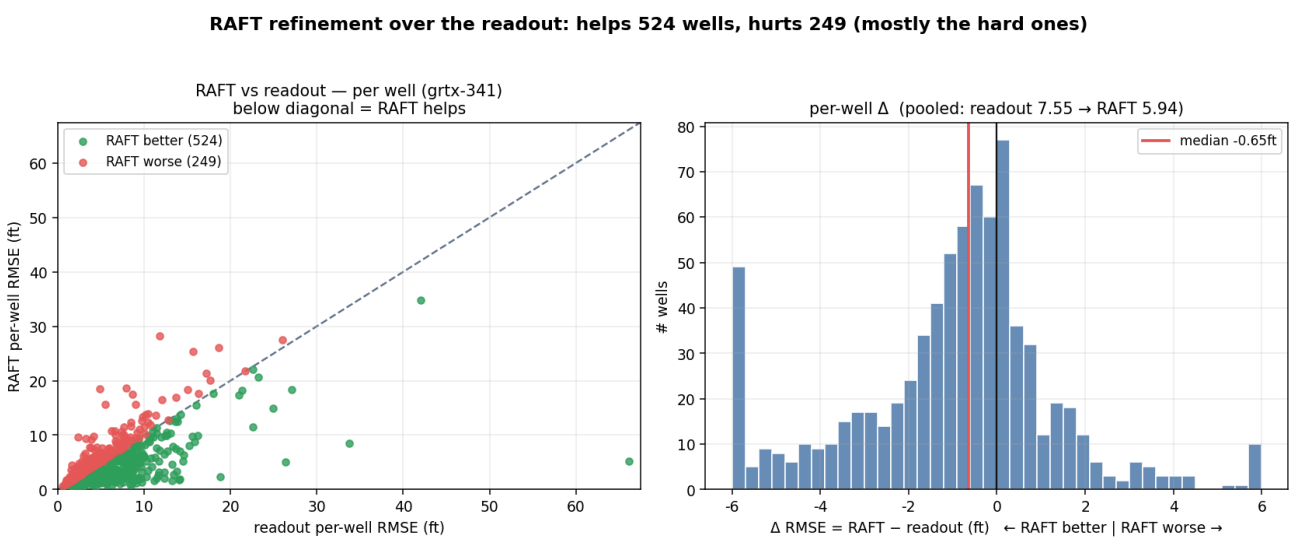
hwとtwはshared conv stem + Transformerを通りcost volumeを作り、grounded readoutでdriftへ変換します。hwを入力する別context encoderがRAFT loopを駆動する `h` / `inp` を作り、driftを反復refineします。

Training loss — 両headをsuperviseします（すべてeval segment上）。

- **Readout head**：true drift stateでcost volume `C` をpeakさせるcross-entropy（weight 10、dominant term）と、readout driftへのHuber（weight 0.2）。cleanなcost volumeを形作ります。
- **RAFT**：すべてのiterationのdriftにL1を与え、後のroundを指数的に強くします（`Σ γ^(K−i)·L1`、`γ=0.8`、weight 1.0）。RAFT sequence lossです。
- 期待値をtruthへ押す小さなHuber「de-damping」termも加えます。

deploy / OOFでは**RAFT last iteration**を使い、readoutはtraining-time headだけです。

RAFTは実際どれだけ効くか？ deploy modelはinferenceで**24 RAFT iterations**を実行します。tuningでは約16がsweet spotで、それ以降はflatになります（24はごくわずかに悪く、noise範囲内）。したがって16以降の正確な回数はほとんど重要ではありません。`grtx-341` OOFでreadout（pre-RAFT）とRAFT outputを比較すると、RAFTは**773 well中524を改善し、249を悪化**させ、pooled RMSEを**7.55→5.94**へ下げました。悪化するのはhard well（§5のspurious-warp well）ですが、大半のwellで約2.4 ft得る効果が、tailで約1.4 ft失う影響を大きく上回ります。



Per-well RMSE、readout vs RAFT（grtx-341）。左：diagonal下がRAFTで改善したwell（green、524）、悪化したwell（red、249）。右：per-well Δ distribution。大半がnegative（RAFTが良い）で、pooled 7.55→5.94。

2.3 Data engine：3つのparallel loader

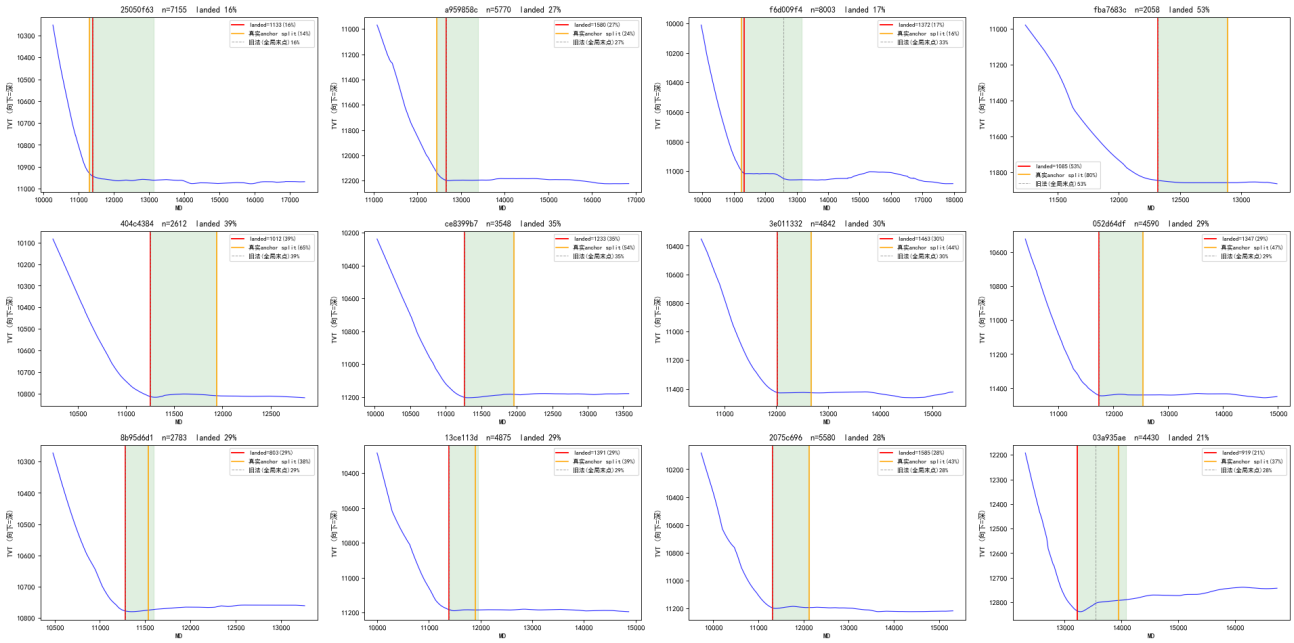
773 wellsはこの表現力のmatcherには非常に少なく、overfitしてplateauします。そこで、各batchでliveにmixする**3 parallel loaders**を作りました（DataLoader workerがsyntheticをon-the-flyで再生成するので、modelが同じwellを2度見ることはほぼありません）。

1. real wells + heavy on-the-fly augmentation
2. **whip** — synthetic drift trajectory
3. **layer** — bulk formation shift

loader 2と3は、後述するforward-GR simulator（「inversion」function）を共有します。

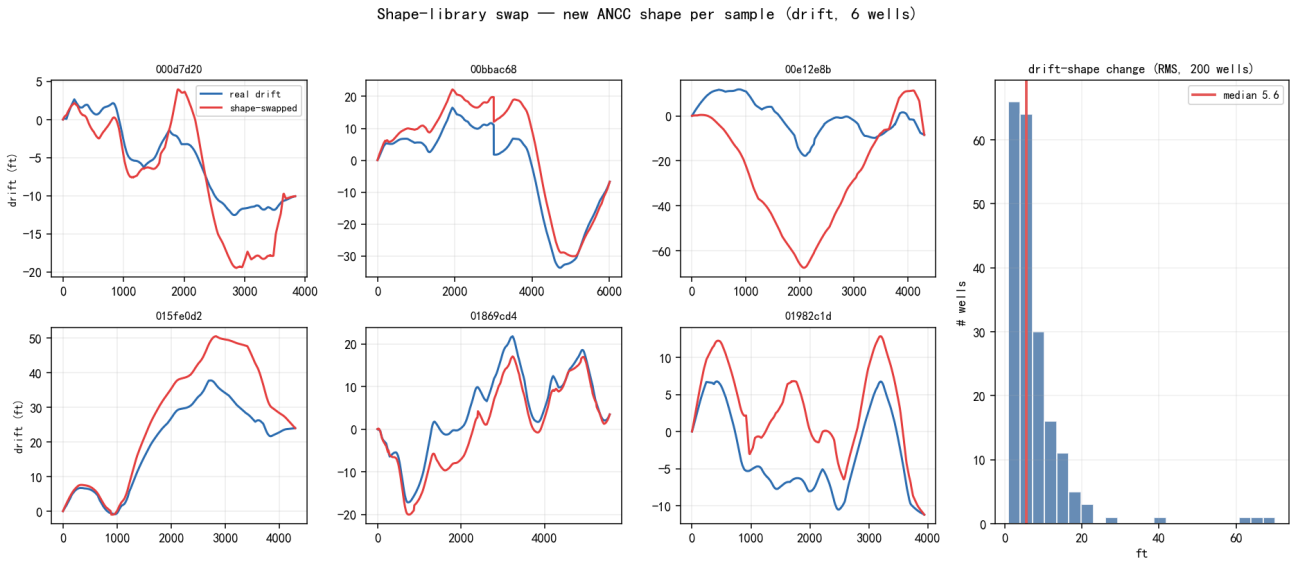
Loader 1 — real wells + augmentation

- **Landing-aware anchor slide**（見た目以上に重要です）：known/eval splitを固定せず、毎epoch、wellのlanding pointからhorizontal方向の任意位置へresampleします。1 real wellが異なるanchor positionとknown-section lengthを持つ多数のtraining exampleになります。ここでは最も安く、最も価値の高いaugmentationでした。



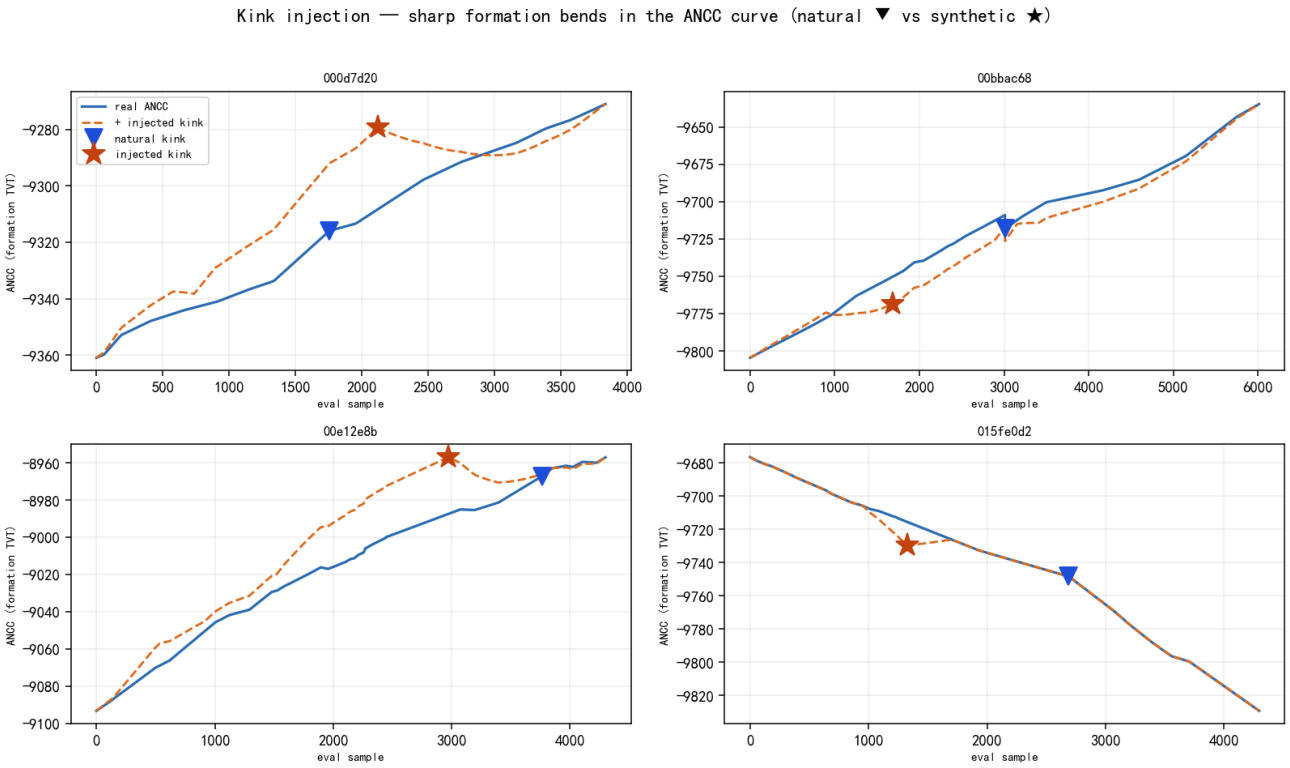
各panelは1 wellのTVT vs MD。red=landing point、orange=「real」anchor split、green band=training中にanchorをrandom sampleする範囲。splitはlanded horizontal section内を自由にslideします。

- **Typewell warp**（`WARP_P=0.8`）：typewellのlayer thicknessを変形し、hw GRを同期してdistortします（drift/geometryは不変）。modelが正確なlog shapeをmemorizeしないようtexture diversityを作ります。
- **ANCC shape-library swap**（`SHAPE_AUG_P=0.8`）：wellのANCC shapeをtraining fold shape libraryからsampleしたshapeへ置換（α-blend、variance-preserving）し、同じgeometry上に新しいdrift shapeを作ります。



6 wellのshape swap（real vs swapped drift）と、well全体におけるdrift-shape change distribution。

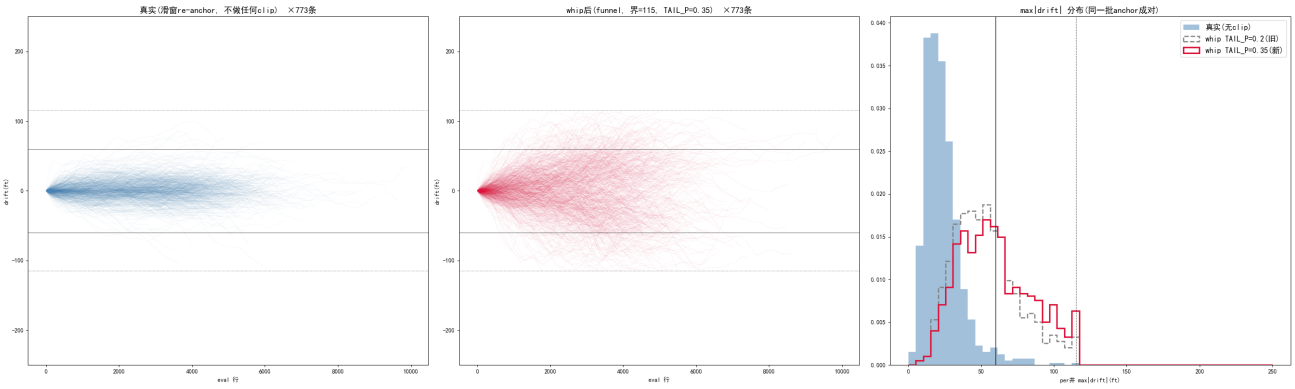
さらにoptionalな**kink injection**を使います。hard wellはsharp formation kinkに支配されますが、raw dataでの自然なbase rateは2–3%しかありません。そこでより多く注入し、wellbore `ΔZ` がbendへ遅れて追従する**steering response**も入れます（real wellはkinkを約0.5 ratioでtrack）。synthetic trajectoryがbendを無視する非現実的なものにならないようにします。



4 wellのANCC（formation-depth）curve。blue=real（▼は自然なkink）、orange dashed=synthetic kinkを注入した同じwell（★）。sharp bendはhard-well failure mode #1でraw dataには少ないため、意図的に増やします。

Loader 2 — whip（synthetic drift）

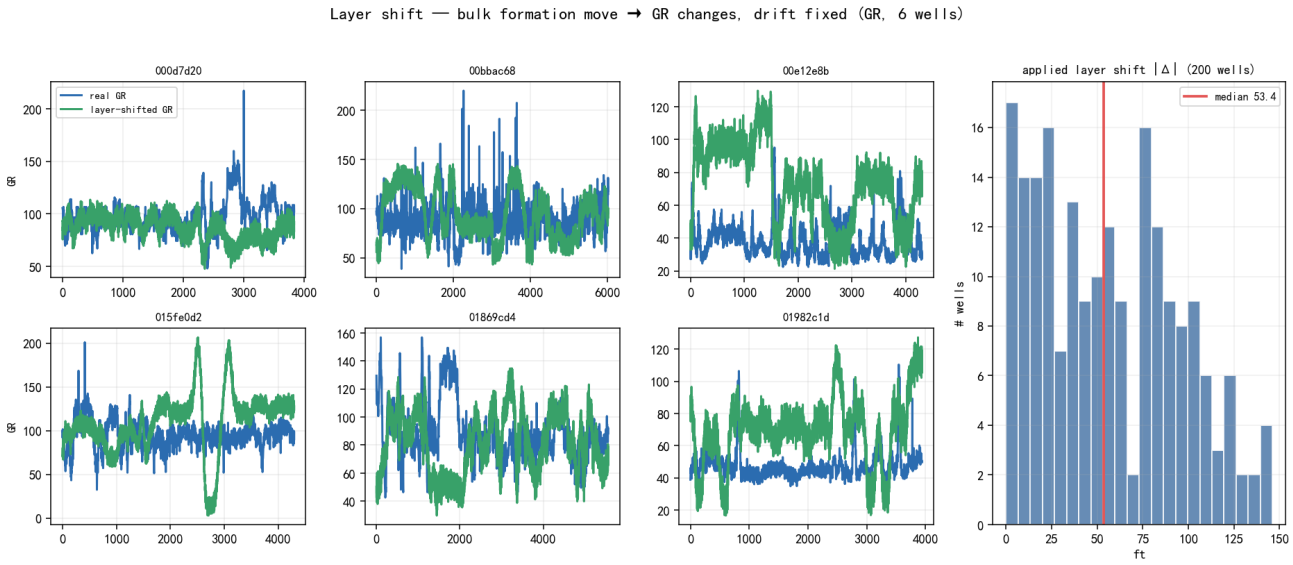
real wellを取り、eval-segment driftをfunnel状に広がるpinned random walkへ置換します。real wellでは稀なtailを意図的にover-sampleし、その後GRを再simulateします。



左：real 773-well drift（narrow funnel）。中央：whip synthetic（より広くtailを埋める）。右：max|drift| distribution。realで不足する領域をwhipがcoverします。

Loader 3 — layer shift

well全体を上下へshiftし、drift/ΔZを固定したまま、GRが別のformation levelをsampleするようにします。whipとはorthogonalです（whipはdriftのshapeを変え、layerはloggingするformationを変える）。

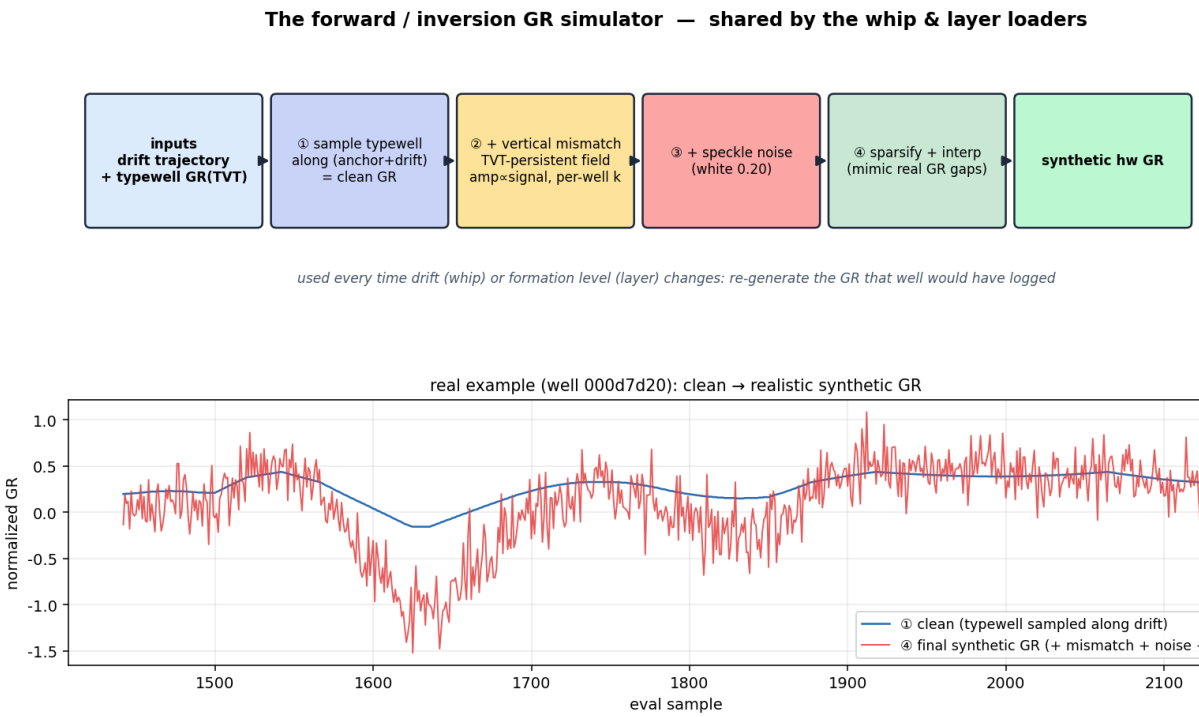


6 wellのlayer shift（real vs shifted GR）と、適用したshift distribution。

Forward / inversion GR simulator（loader 2と3で共有）

drift（whip）またはformation level（layer）を変えたら、そのhorizontal wellが実際に記録するはずのGRを再生成しなければ、`(GR, drift)` pairが不整合になります。それを行うfunctionです。現実的に作ることがsynthetic wellを有効にします。

1. `anchor + drift`に沿ってtypewellを**sample**し、clean GR（perfectly-tracking wellが見るもの）を作る
2. **vertical mismatch**を加える。同じ深度で同じdistortionとなるTVT-persistent fieldで、amplitudeをwell signalへscaleし、wellごとにseverityをrandom化し、real 773-well statisticsへcalibrateする（horizontal warpではなくvertical mismatch。real logはlag 0でalignする）
3. **speckle noise**を加える
4. real GR logのgapを模倣するため**sparsify + interpolate**する



上：simulator steps。下：real example。clean typewell sampling（blue）へmismatch、noise、gapを加え、現実的なsynthetic GR（red）へ変換します。

> Counter-intuitiveなlesson：**「よりrealisticに見える」≠「より良く学習できる」**。見た目が美しいsteep-heel synthetic variantは、実際にはCVを悪化させました。目ではなくCVを信じます。

---

3. Physics path：`pfnet` + `pftree`（`pfnet-XXX`、`pftree-XXX`）

3.1 Particle filterのGPU化（`gen_gpupf`）

classical geosteering toolはANCC state上のparticle filterです。public/CPU PFは遅くて弱いため、**1つのGPU function** `gen_gpupf(Z, **10 params) → {well: drift}` として書き直し、training-base生成とkernel inferenceで**全く同じ**ものを使いました。10 knobs（seeds、particles、momentum `α`、SDE motion、emission width、kriging geo-prior weight `w_geo`、readout modeなど）から1 code pathですべてのPF「expert」を生成します。

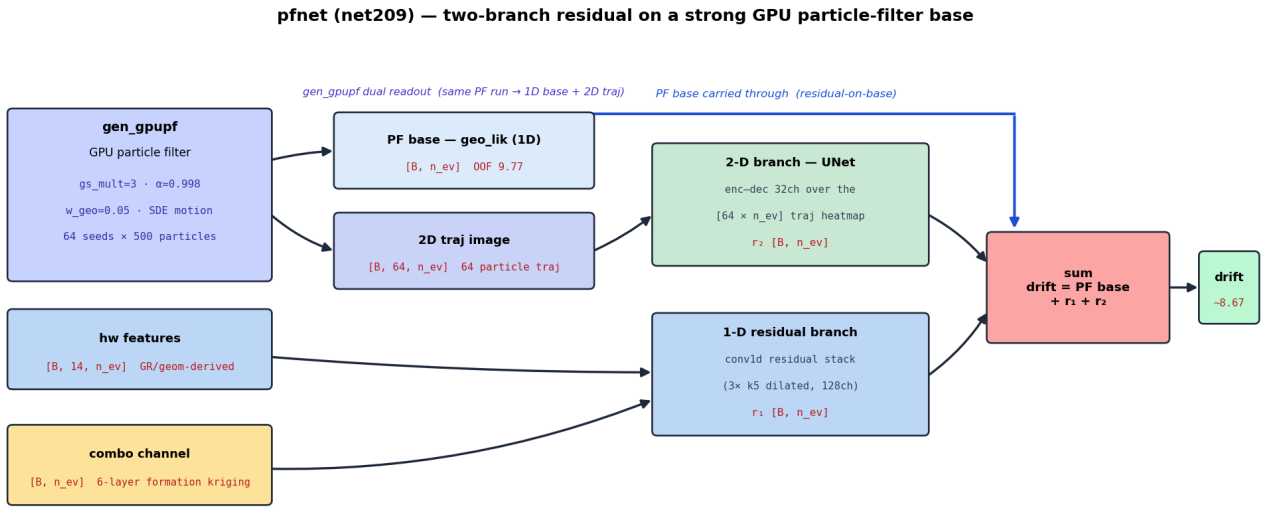
deploy base（`gpupf_g3geo_krig`）は**`gs_mult=3`、`α=0.998`、`w_geo=0.05`、64 seeds × 500 particles、SDE motion**で実行し、raw **OOF 9.77**でした。competition built-in PFは約14.35で、この差がphysics pathの価値の大部分です（ここでの`w_geo`はPF内部のspatial-prior weight、`gs_mult`はemission width、`α`はdip momentumであり、§5の`ancc`/`geotx` blend weightとは別です）。

3.2 `pfnet` architecture

PF base上のtwo-branch netです。

- PF base driftのresidualを学ぶ**1-D branch**
- g3 particle-trajectory image上の**2-D branch**（U-Net）
- formation-kriging「combo」channel

philosophyは**residual-on-a-strong-base**で、physicsと対応します。PF baseがbig pictureを与え、netがlocal errorを直します。さらにtwin（forward-sim）augmentationを加え、single-modelは約8.67です。



GPU particle-filter baseがbig pictureを担い、1-D branchがresidual、2-D U-Netがparticle-trajectory imageを読み、formation-kriging channelがspatial geologyを追加し、baseへsumします。

3.3 `pftree` — tabular residual modelとfeature study

約195-feature bankからdriftを予測するper-point gradient-boosting model（XGBoost + depth-diverse CatBoost → ridge stack）です。「single wellがこのpointについて知るすべて」のfeature setで、family例は次です。

- **Neighbor-geology kriging**：neighboring wellからこのX/Yへleave-one-out krigingしたANCC formation surface（および関連surface）とdistance/reliability feature。formationがneighborから見てどこにあるべきかを示すgeometric prior
- **GR-matching descriptor**：複数のstiffness/windowでhw GRをtypewellとmatchし、implied driftとestimate間agreementを得る（disagreement=low-confidence point）
- **Particle-filter output**：`gpupf` driftとspread
- **Local GR & geometry**：rolling GR statistics、`ΔZ`、heading、anchorからの距離

最大のleverは**residual-on-a-strong-base**でした。driftを直接予測せず`gpupf` PF driftを下に置き、treeにはresidualだけを学ばせると、single-modelで約1.5 ft改善しました。

---

4. Geometric path

- `ancc`：ANCC formation surfaceのspatial IDW kriging（K60、leave-one-out）。base drift CVは約14.6。
- `geotx`：GR-free geometric Transformer（d=160、5 layers、8 heads、約1.6M params）。inputは768-pointへresampleしたwellの**9 channels**（known-drift history、is-known mask、`ΔZ`、dx、dy、heading cos/sin、grid-kriging neighbor geology、nn-distance reliability）で、driftを直接outputします。**sliding-window anchor augmentation**（773-well overfittingへのkey regularizer）で学習し、5 foldsを平均します。single CVは約11.3。

どちらも単体では弱い（11–14 ft。GRなしのgeometryでは見えないirreducible geologyがあります）ですが、mechanismがGR matcherと**完全にorthogonal**なので、blendではsingle-model weight以上に貢献します。

---

5. CV vs LBとsubmission strategy（実際にgoldを得た部分）

5.1 Score progression（すべてPublic LB。ただしsmall scaleではPublic LBが嘘をつく。§5.2参照）

- single `grtx`：**5.08**
- ◦ geometric path（`ancc`）：**5.03**
- ◦ physics path（pfnet）：**4.90**

core ruleはdecorrelation > single-model strengthです。 最も明確な証拠として、residual-on-`pfnet` treeは単体ではより強い8.44でしたが、`pfnet`との相関が0.96でblend gainは**0**でした。一方、単体11–14の弱いGR-free geometric legはblendで-0.4をもたらしました。相関しないlegの追加は、既存legを強化するより常に有利でした。

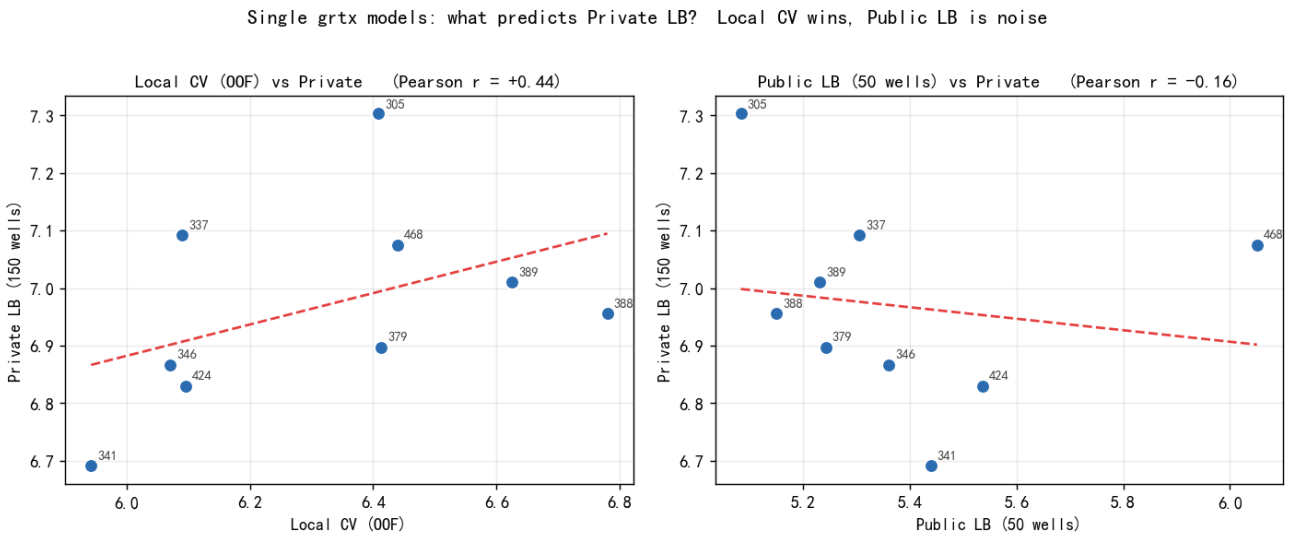
5.2 Trap：Public LBは信頼できない（goldを失いかけた理由）

Public LBは**わずか50 wells**でnoiseが非常に大きいです（50-well scoreのbootstrap σ≈0.9、2 modelの差のσ≈0.6）。model選択に十分なsignalではありません。

single `grtx` modelsで直接確認しました。

model	CV	Public LB	Private LB
grtx-305	6.408	**5.083**	7.303
grtx-337	6.090	5.305	7.092
grtx-341	**5.942**	5.439	**6.691**
grtx-346	6.070	5.360	6.867
grtx-379	6.413	5.242	6.897
grtx-388	6.780	5.150	6.956
grtx-389	6.625	5.231	7.010

model	CV	Public LB	Private LB
grtx-424	6.095	5.536	6.830
grtx-468	6.439	6.051	7.075



Local CVとPrivate LBの相関は+0.44。Public LBとの相関は-0.16で、文字どおりnegative correlationでした。
Public LBを追うと積極的に誤った方向へ進みます。

final blendでも同じでした。

- **最もPublic LBが高かったsubmissionは選択しませんでした**。local CVが平凡なsingle grtx modelとのensembleでした。
- CVは良いがPublic LBは悪い、より大きな2 ensembleを選択しました。candidate間でCVとPublic LBは**anti-correlated**でした。
- final **Private LB（150 wells）**ではCV orderingが正しく、選んだensembleは持ちこたえました。
- さらに、CVをもっと強く信じ、highest-CV / lower-Public submissionを選んでいれば、**さらに良いscore**でした。

strategy	CV	Public LB	Private LB	selected
grtx-305 + pfnet-209·0.15 + ancc·0.05@250 + geotx·0.05@1200	6.03	4.902	6.914	-
grtx-[305+379+388+389] + pfnet-209·0.15 + ancc·0.02@700 + geotx·0.04@1500	5.774	4.939	6.639	✅
grtx-[305+337+341+346+424+468] + pfnet-209·0.10 + pftree-083·0.05 + ancc·0.05@250 + geotx·0.05@1200	5.437	5.197	6.500	✅
grtx-[337+341+346+424+468] + pfnet-209·0.10 + pftree-083·0.05 + ancc·0.10@250	5.398	5.299	6.424	-

Public LBでbestのstrategy（4.902）がPrivateでは**worst**（6.914）です。これを追えばgold圏から完全に落ちていました。CVで選んだsubmissionが持ちこたえました。

local CVを信じてください。overfitしたPublic LBに目を奪われてはいけません。