rogii-wellbore-geology-prediction

21位 Solution

Rank	21
Team	goonew
Author	goonew
Topic ID	733190
Version	Japanese Translation

Source: https://www.kaggle.com/competitions/rogii-wellbore-geology-prediction/discussion/733190
Retrieved with Kaggle CLI on 2026-08-06.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

貴重な機会をくださったorganisersと、discussion forumで知識を共有した皆様に感謝します。

---

1. Solution Overview

解法で最も有効だったcomponentはsynthetic-data generationです。コンペ序盤にDiscussionで確立されていたいくつかの発見から始めました。

- labelsはROGIIのgeosteering softwareであるStarSteerが生成するsparse dip annotationsに由来すると仮定しました。Hengck23はdiscussion 699853で「annotation leak! that is how starsteer works」と指摘しました。同threadでTomは`ANCC`（formation boundary）がpiecewise linearで、wellあたり約15 control points、約323 rowsごとに1つと報告しました。私も`S = Z + TVT`（structural surface elevation）が同じnode数のpiecewise-linear functionでresidual standard deviation 0.88 ftまで再現できると確認しました。
- Hengck23はStarSteerのsearchがpatent上dip rangesとlarge segmentsに対するbeam/Viterbi searchだとも指摘しました（discussion 699289、discussion 699883）。そこで主目的をhorizontal-well GRとcandidate dipに沿ってtype-well logをresampleしたsynthetic logとのsegment-wise Pearson correlationとするgreedy searchを仮定しました。adjacent segment間のdip differenceとregional dipからのdeviationにpenaltyを足し、synthetic-data generationのspecificationにしました。
- 自分のoracleではsingle dip（straight line）はRMSE 7.93、two-segment modelは4.97でした。

これらに基づき、ground-truth generatorを模倣するsynthetic dataでtrainingし、structured decoderでTVTをdecodeしました。ここでdecoderはrowごとに独立値を出すregression modelではありません。「segment内dip一定」「changeはsparse」というstructural constraintの下で、well全体のGRとtype-well logを最も整合させるTVT sequenceを選ぶinference procedureです。

Pipeline

public notebookを再現・強化し、そのbaseline上にdecoder-based correctionsを順に適用しました。

CVはwell-grouped 5-fold cross-validationを2 seeds（42、2026）で測定します。4 metricsは次の通りです。

- **Pooled RMSE**: 全evaluation rowsをpoolする標準RMSE。
- **Iso (iso155) RMSE**: neighboring wellsが最も少ない155 wellsだけのpooled RMSE。
- **Median RMSE**: per-well RMSEのmedian。
- **Crit5 RMSE**: squared error最大の5 wells（1b1eba53、91b301ce、91db7070、f2d4c8c9、fb03ae90）だけのpooled RMSE。

#	Stage	Main mechanism	CV pooled	CV iso	CV median	CV crit5	Public	Private
0	Public notebook再現	particle filterによるGR tracking	10.988	12.609	5.779	39.340	8.988	10.763
1	Baseline強化	neighbour-well transfer + piecewise-linear replay decoder + PF	6.511	7.171	3.815	25.907	6.723	7.506

#	Stage	Main mechanism	CV pooled	CV iso	CV median	CV crit5	Public	Private
2	Synthetic-trained candidate scorer	generatorを模倣するsynthetic wellsだけでcandidate-selection CNNをtraining	6.331	6.979	3.497	26.204	6.436	7.049
3	Cost volume + forward-backward	row×offset latticeでlikelihoodを学習しposterior meanをdecode	5.999	6.878	3.210	26.043	6.397	6.815
4	Reference多様化	reference-free absolute decoder + 自well known intervalのsecond reference log	5.189	6.025	2.818	23.775	5.649	6.557
5	Recombination layer（final）	uncertainty条件付きでstage contributionを再結合	5.028	5.809	2.799	22.161	5.587	6.504

Adoption Criteria

BirdCLEF 2026ではPublic/Private gapが偶然小さく、金メダル獲得に寄与しました。このコンペでもgapを小さくしようとしました。採用判断はpooled CV RMSEだけでなく、median per-well RMSEとimproved well fractionも見て、広いwellへ利益があるか確認しました。pooledを改善してもmedianを悪化させるideaはrejectしました。少数の難wellを大きく直す代わりに多数を少し悪化させる改善を拒否したということです。

実際、pooled CV 4.80とより良いmodelがPrivate 6.57にしかなりませんでした。pooled CVだけならmedalを逃していました。ただし最終Public-Private gapも約1 ftあり、結果にはluckもあったでしょう。

---

3. Stage 1: Baseline強化

最強public notebookはstateを`S = TVT + Z`とvelocity termとするparticle filterを使い、type-well GR profileとのagreementをlikelihoodにhorizontal wellをtrackしてPublic約9.15でした。residual prediction、type-well GRとのNCC matching、複数methodのRidge/NNLS stackingも確立していました。これらを再現して次を拡張しました。

- **Residual regressionへ変更**: 約11,000 ftのraw TVTではなく、known interval末尾から約±16 ftのdriftを予測。public notebook由来。
- **Neighbouring wellsからpairwise transfer**: spatial-neighbourhood consensusなど近傍文脈はforumで提案済みでした。私の変更はtransfer方法です。constant offsetを除くとneighbor wells間で`S`のshapeはMAD 3-7 ftまで一致します。全wellへ1つのspatial fieldをfitせず、各neighborをtargetのknown intervalへ直接alignし、offsetを除いてから情報をtransferしました。standalone CVは21.7→12.2。neighbor bankはleave-one-well-outで構築。
- **Piecewise-linear decoder**: label生成に使われたと仮定するsearchを再実行。「segment内constant dip」「sparse switches」を明示し、segment-wise GR agreement最大のpiecewise-linear pathをsearchします。single highest-posterior pathでなくforward-backwardのposterior meanを使い、between-well errorのheavy tailを減らしてRMSEを0.37改善しました。reference curveは低RMSEだけでなくdip structureを忠実に保つ必要があり、over-smoothingはdip priorをflattenして悪化しました。

合計でCV 6.51、Public 6.723、Private 7.506でした。

---

4. Stage 2: Synthetic Dataで学ぶCandidate Scorer

ground truthのgenerative processを仮定し、parametersをtraining dataから推定しました。dip incrementsはfirst-order autoregressive（100 ftあたり`ϕ = 0.636`）、Brownian noise、300-500 ft correlation length、非周期。trajectory steeringとGR residualもfirst-order AR、type wellとhorizontal wellのmisalignmentはOrnstein-Uhlenbeck processです。

synthetic difficultyを2 statisticsでrealへcalibrateしました。1つ目はmatching-cost curveのlocal minima数です。candidate TVT offsetを数十ft scanすると、horizontal GRとtype-well logのmismatch curveに多数の谷ができます。谷数はplausible solution数、つまりaliasingの程度です。syntheticはwellあたり9.1、realは10.1でした。

2つ目はcurve minimumがground truthと一致する割合で、naive matchingだけで解ける度合いです。synthetic 0.855、real 0.863でした。

これによりground truth付きsynthetic wellsをほぼ無限に生成できます。

Modelに何を学ばせたか

regressionではなくcandidate scoringを学ばせました。base prediction周辺にdip `a`とtranslation `b`でparameterizeした多数のcandidate pathを生成します。normalised GR、candidate dipに沿ってresampleしたtype-well log、mask、trajectory dip、local misfitなど7 channelsの1-D CNNが各candidateをscoreし、final predictionはsoftmax posterior meanです。

1 ft resolution維持が必須でした。decimationやsmoothingはcharacteristic length約3 ftのGR correlation structureを壊し、usable signalが消えます。

regressionを避けたのはerror distributionがbimodalで、correctか1 bundleずれかだったためです。discussion 711878でSouldriveが説明した通り、Eagle Fordのcyclic beddingにより約15 ft離れた2 horizonsでGRが同程度にmatchします。regressionは2 modes間をhedgeして情報を失いますが、candidate scorerなら片方を選べます。

model scaling、複数ensemble、全procedureの2回適用でCV 6.51→6.30、Private 7.506→7.049となり、その後すべてのsubmissionの基盤になりました。

---

5. Stage 3: Cost-Volume Likelihoods and Forward-Backward

Stage 2はwell全体へ1 softmaxでした。ここでは1 ft resolutionのrow-level decodingへ置き換えます。

stereo matchingのcost volumeに似た構造を使います。stereoではpixelとdisparity candidateごとのmatching cost配列からconsistent depth surfaceを抽出します。ここでは各rowとreferenceからのoffset `δ`のlatticeを作り、8-channel 2-D CNNが各lattice pointのlog-likelihoodを出します。trainingはStage 2と同じsynthetic factoryにcalibration errorsを注入します。

lattice valueはHMM emissionです。row `i`のtrue positionが`δ`ずれたときobserved GRがどれほどplausibleかを表します。transition probabilityには測定したheavy-tail OU dip-increment processを使い、exact forward-backwardでposterior meanをdecodeします。

naive適用はrealで悪化しました。forward-backwardはpathに沿い約600 correlated emissionsを積むため、軽いoverconfidenceが増幅します。wellごとに1 softmaxだけのStage 2にはありません。2 countermeasuresを入れました。

- **Emission decimation + entropy gate**: emissionsを32 ftごとへdecimateし、high-entropy positionのcontributionをsmoothに0へ下げます。uniform temperatureより大幅に良好でした。entropyはrealでもcalibrateされ、sharpest 20% positionsでは89%が1.4 ft以内、flattest 20%では39%、7.4 ftでした。
- **Real data fine-tuning**: synthetic-only pretrained networkをfold内real dataで2,000 steps、low learning rateで短くfine-tune。各wellは自分を除くfoldのnetworkで評価されます。foldあたり470,000 pointsのdense supervisionで非常に有効でした。foldをwellでなくregionで再定義するpessimistic protocolでも差は+0.02だけで、neighbour leakageでなくgenuine signalと考えられます。

pretrainingを12k→120k→240k stepsへscaleしたbenefitはpost-fine-tuningにも残りました。このstageだけでCV 6.30→5.60と、単一intervention最大の改善です。

---

6. Stage 4: Reference多様化

ここまでは既存prediction周辺の$\pm\delta$ correctionで、evidenceの多くはtype-well logとのGR matchingでした。2つの質的に異なるsourceを追加します。

1つ目はreference-free absolute decoderです。各rowでtype-well logのdepth binsへprobability distributionを出すTransformerを作りました。Pointer Networkのようにvalueをregressせずreference sequence内positionをpointします。known intervalの`(GR, TVT)` pairsをcontext tokensとし、cross-attentionでevaluation zoneの各rowをtype wellへ直接配置します。synthetic pretrain + real fine-tuneです。

standalone RMSE 14.18で当時のfull chain約5.6より大幅に弱いものの、errorが独立しておりentropy-based per-well gatingでensembleに有益でした。

2つ目はtarget well自身のknown intervalを追加reference logにすることです。他wellをreferenceにする方向は試していましたが、自well known intervalをreference curveにはしていませんでした。known intervalのTVT rangeはevaluation rowsのmedian 68%をcoverしました。

Reference	true positionでobserved GRとのcorrelation（median）
Type well	0.665
Well自身のknown interval	0.666
2つのblend	0.725

known interval単体はtype well同等で、blendの大幅gainは部分的に独立な情報を示します。correlationはheelからのlateral distanceによらずほぼ一定で、0 ftと4,500 ftの両方で0.56-0.59でした。local facies noiseでなくlateralに持続するstratigraphic signatureを捉えています。

scalar featureへ潰さずdecoder emissionへ直接入れました。stateはcurrent predictionから±8 ft offset。emissionは500/800 ft windowsのmulti-scale NCC、transitionはGaussian random walk、final readoutにはposterior meanのshape componentだけを使います。

---

7. Stage 5: Recombination Layer（Final Submission）

5.19→5.028の最終改善はnew informationでなく既計算情報の再利用です。

full chainを18の`stage increments`、つまり前stage outputへ各stageが足すcorrectionに分解しました。sumがsubmitted predictionを最大差`1.8 × 10^-12 ft`で正確に再構築することを確認後、各incrementへcoefficient`c`を掛けます。well`w`のsquared errorは次です。

$$ \mathrm{SSE}_w(c) = ee_w - 2, c \cdot h_w + c^{\top} G_w c $$

`ee_w`は全coefficient 0のerror、`h_w`は各incrementとresidualのinner product、`G_w`はincrementsのGram matrixです。wellごとに3つを計算すればcoefficient vectorのCVをほぼ即時評価でき、数秒で数百configurationをsearchできます。

各stageのlevel/shape componentを、forward-backward posterior spreadやensemble disagreementなどchain自身のuncertaintyへconditionしました。control experimentは次です。

Design	pooled Δ	per-well median Δ	improved well fraction
Stageごとに1 scalar（unconditional）	-0.033	-0.002	0.505
Uncertainty条件付き	-0.065	-0.023	0.567
同じ自由度、covariates randomised	-0.024	+0.013	0.453

random covariatesでもpooled gainの約1/3は回収しますが、median改善は消えます。conditioningはaggregate gainだけでなく改善をwell全体へ広げました。

final submissionはこのlayerのfirst checkpointです。layer自体をfold内refitし、CV 5.028087、median per-well ΔRMSE -0.0245、improved-well fraction 0.571でした。その後CV 4.80まで下げましたがleaderboardは逆方向でした。

---

9. 私には効かなかったこと

candidate path family拡張は効きませんでした。continuous least-squares solutionまで広げるとtruthに最も近いcandidateを選べるoracle RMSEは2.63まで下がりましたが、actual scorerは6.30のままです。gap全体がcandidate-selection qualityで、±1-bundle aliasingのためobservable signalに必要情報がありませんでした。

scorer posterior varianceでwellを3分割すると、most confident thirdのlevel errorは2.51でoracle同等です。flattest thirdでは正しいmode選択がcoin flip同然でlevel error 6.17。そのregimeではmidpoint predictionがBayes-optimalで、これ以上改善できません。これはSouldriveのdiscussion 711878と同じ制約です。

10. Coding Agents

CVを実質改善したideaはすべて私が考えました。このprojectでLLMは有用なmodelling ideaもmajor CV improvementも生みませんでした。一方coding agentsは高速実装とpolished visualization付きHTML experiment reportを一貫して提供し、problem analysisと新ideaへ時間を割けました。