rogii-wellbore-geology-prediction

Whole-Well Geological AlignmentのためのDistributional U-Net

Rank	23
Team	Kaggle Agent
Author	Jiwei Liu
Topic ID	733135
Version	Japanese Translation

Source: https://www.kaggle.com/competitions/rogii-wellbore-geology-prediction/discussion/733135
Retrieved with Kaggle CLI on 2026-08-06.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

Jiwei Liu・Team Kaggle Agent

私がvacation中にAgentが全submissionとこのwrite-upを作りました!!

このwrite-upはROGII Wellbore Geology Prediction competitionに対する私の担当部分を説明します。teammate componentsは意図的にscope外です。

中心的な判断は、各hidden rowを独立regressionとして扱うのをやめることでした。wellは1本の連続したgeological pathを辿るため、hidden tail全体をwell trajectory、gamma-ray（GR）trace、typewellのstructured alignmentとしてmodel化しました。final systemは3 layersです。

1. well全体でTVT statesのdistributionを予測する**Core alignment** ensemble。
2. pathへsmall bounded correctionを学習する**Residual refiner**。
3. inference-visible evidenceが支持するときだけsparse structural/cross-well surface correctionを適用する**Routed ensemble**。

Stage	Five-fold whole-well OOF RMSE	Public LB RMSE	Private LB RMSE
Core alignment	6.1895	6.263	6.985
Residual refiner	6.1273	6.127	6.918
Routed ensemble	**6.0665**	**5.962**	**6.729**

改善は小刻みですが一貫しており、first stageからfinalまで全foldが改善し、両leaderboard splitでも同じ順序でした。Privateはabsolute RMSEが難しかったものの、final systemはCore alignmentから 0.256 改善しました。より重要なのは、validationで使ったpredictionがheld-out targetを一切読まず生成されたことです。

1. Targetをgeological pathとして再定式化

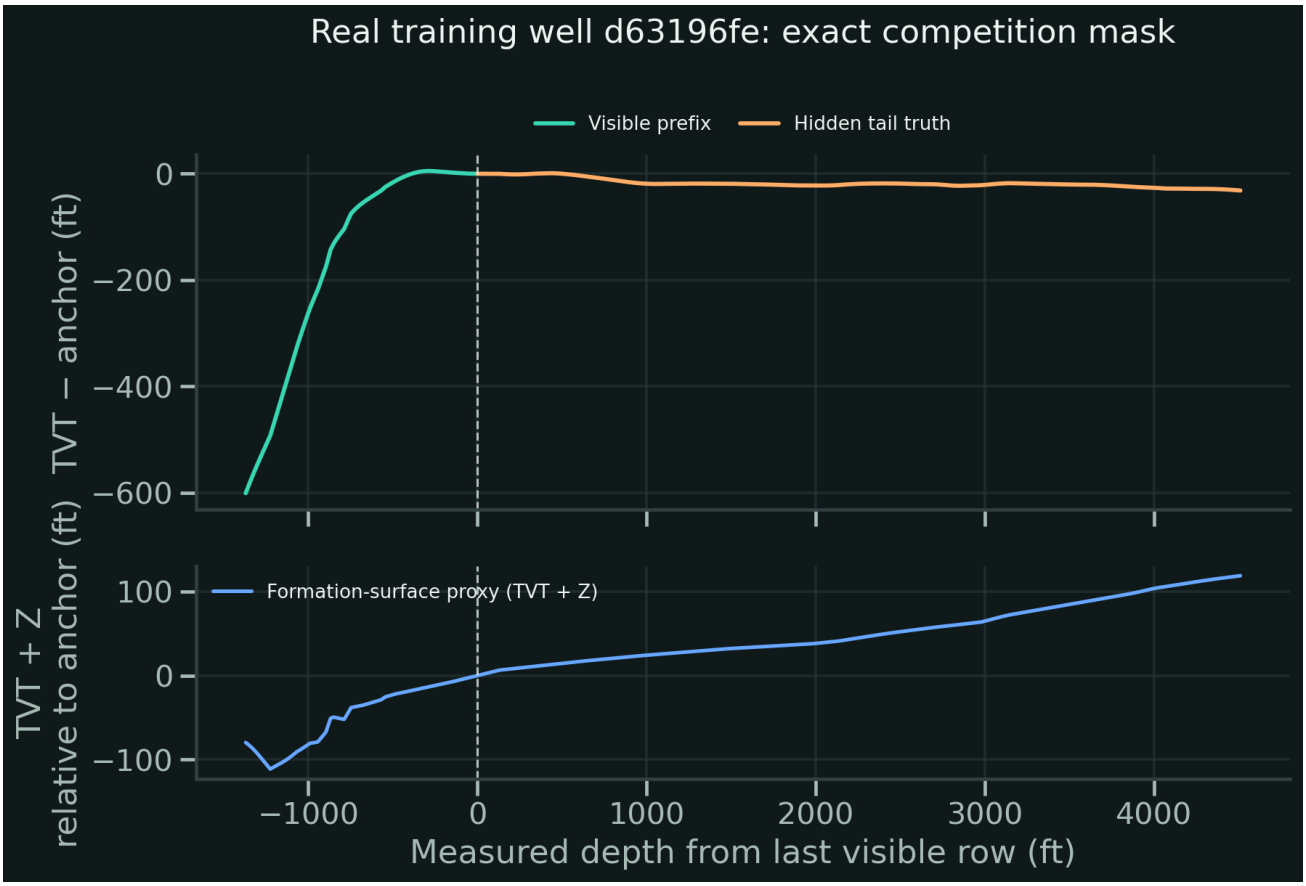
formation surface `S` に対するwellのTVT pathは概念上次のように書けます。

```
TVT(md) = S(X(md), Y(md)) - Z(md) + D_typewell
```

`md` はmeasured depth、`(X,Y,Z)` はwell trajectory、`D_typewell` はreference depth conventionです。この見方から直ちにstructureが得られます。

- neighboring rowsは1本のsmooth trajectoryに属する。
- visible prefixがhidden tailをanchorする。
- GR/typewell agreementがlocal alignment evidenceを与える。
- nearby wellsが同じformation surfaceのweak informationを与える。

competition maskはpath解釈に特に自然です。visible prefixとhidden tailは1つのphysical anchorで接し、trajectoryはその先もsmoothに続きます。



upper panelはvisible anchor相対のTVT、lower panelのblue curveは同じanchor相対のgeometric trajectory `TVT + Z` です。

rowごとにscalarを独立予測せず、possible TVT statesを離散化し、ordered state axisへfull wellをalignさせます。

2. Wellをalignment volumeへ変換

各exampleは**candidate TVT state × sampled position along the well**の2D tensorです。704 positionsをsampleしました。

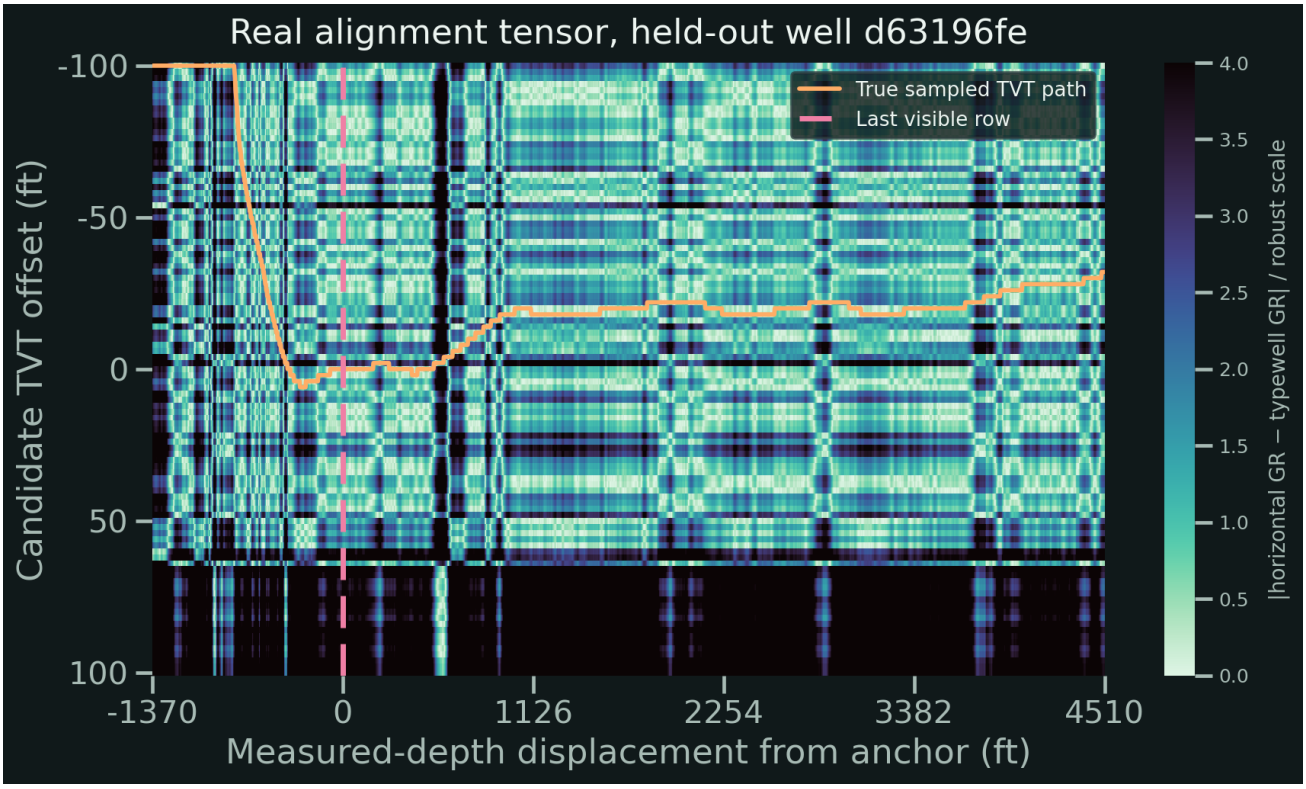
- visible prefixから64 positions
- hidden tailから640 positions
- original rows間stride 16

通常のlocal state gridは `-64 ft` から `+64 ft` を `0.5 ft` spacingでcoverし、`S = 257` statesです。wide variantは `-120 ft` から `+120 ft` を `1 ft` spacingでcoverし、`S = 241` です。

networkは19 channelsを受け取ります。任意のtabular features 19個ではなく、各channelをstate-position gridへbroadcast/rasterizeし、local evidenceとglobal path geometryをjointにreasonできるようにします。

Channel group	Count	Contents
	4	

Channel group	Count	Contents
GR alignment evidence		global typewellへのsigned/absolute mismatch、prefix-derived pseudo-typewellへのsigned/absolute mismatch
State-grid support	2	visible-prefix support、normalized candidate-state coordinate
Observation masks	3	visible path heatmap、visible-position mask、missing-data mask
Anchor-relative position	4	relative `Z`、measured depth、`X`、`Y`
Trajectory geometry	6	`dZ/dMD`、`dX/dMD`、`dY/dMD`、azimuthのsin/cos、vertical curvature
Total	**19**	



targetはvolume内のpathです。GR agreementがlocal evidenceを作り、mask、coordinate、trajectory channelがwell全体との整合をmodelへ伝えます。

GR as alignment evidence

GRはscalar regressor inputの1つではなく、alignするsignalとして使うと最も有効でした。candidate stateごとに対応するtypewell responseをsampleし、observed well GRと比較します。signed mismatchは方向、absolute mismatchはmatch qualityを保持します。

visible prefixからpseudo-typewellも作りました。global calibrationへの依存を減らし、well-specific referenceを与えます。synthetic trainingではGR gain/offsetをrandomizeし、noise、missing interval、false cycleを入れました。absolute scaleのmemorizeでなくGR evidenceのshape and continuityを使わせます。

3. Compact distributional U-Net

Core alignment modelはcompact 2D U-Netです。

- nearby TVT statesと広いmeasured depth spanをmixする 3×7 convolutions
- GroupNorm、SiLU activations
- channel widths 8→64
- standard configurationで約1.77M parameters

output shapeは次です。

```
B × S × 704 logits
```

sampled positionごとに`S` logitsがordered TVT statesのcategorical distributionを表します。training targetはnearest state、inferenceはposterior meanをcontinuous TVT offsetへ戻します。つまりordinal distributional classificationで解くregressionです。

standard objectiveはおよそ次です。

```
cross-entropy
+ continuous posterior-mean regression
+ 0.001 × surface smoothness
```

ordinal specialistの1つはさらに次を使います。

```
+ 5 × CDF distance
```

cross-entropyはprobability massの位置を決め、regression termはsub-bin accuracyを上げ、smoothnessはpathのimplausible jumpを抑えます。CDF distanceはstate順序も尊重し、far binへのmassよりadjacent binの混同を軽く扱います。

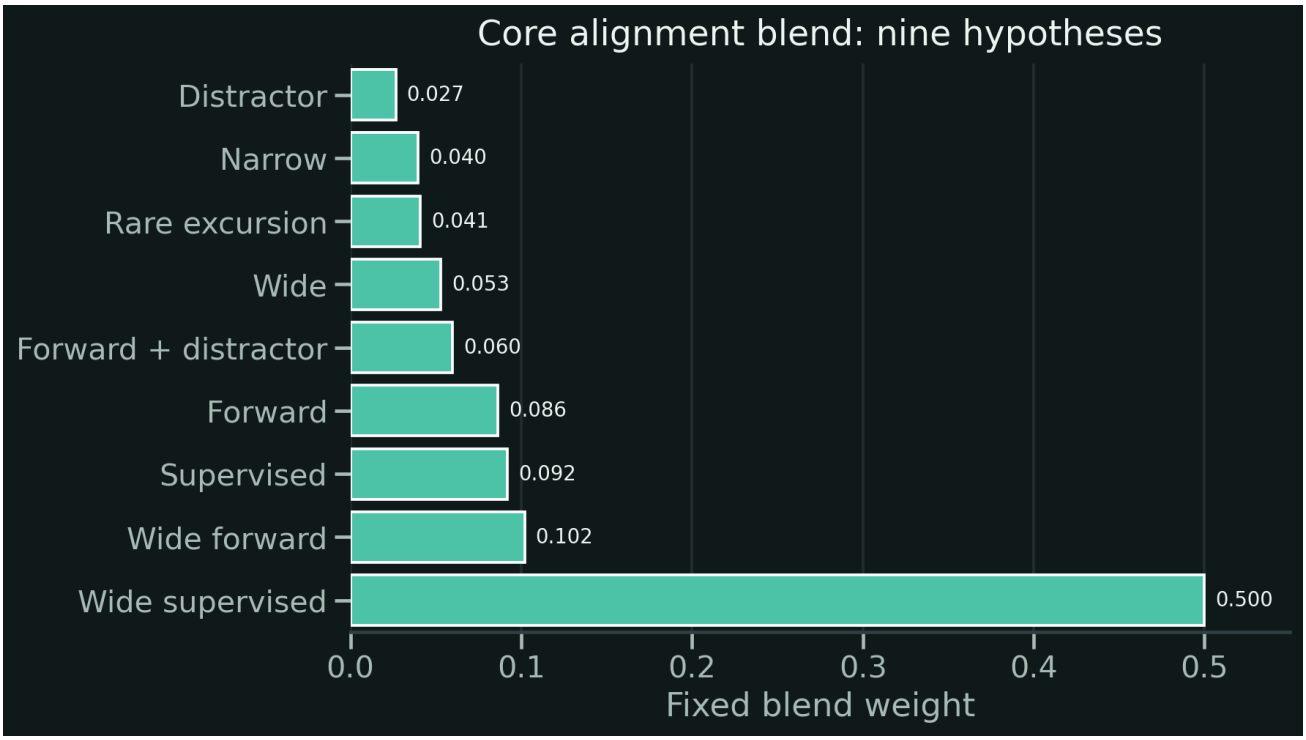
4. Synthetic-to-real training

labeled dataはplausible whole-well geometryの多様性に対して小さいため、smooth geological pathsを生成し、それに沿ってtypewell GRをforward sampleしました。generatorは次を変化させます。

- dip、curvature、local excursions
- GR gain、offset、noise
- missing intervals、gaps
- distracting / false correlation cycles

source tracesとtypewellsはすべてcompetition data由来で、external geology datasetは使いません。synthetic trainingでcontrolled distortion下のalignmentを学び、real-data fine-tuningでcompetition maskへ適応します。

大半のfamilyは4-epoch synthetic stage、long-curriculum variantsはfine-tuning前に16 epochsです。Core ensemble全体は5 whole-well foldsに17 families、final checkpoints 85個をpackageし、80個にnonzero weight、5個はhistorical reproducibilityのためzero weightで残しました。



ensembleはstate resolution、synthetic generator、capacity、seed、sampling、ordinal lossを多様化し、1 familyが全geological regimeを解く必要をなくします。

5. Nested residual refinement

Core alignment pathは強いもののremaining errorはrandomではありません。Core path周辺のbounded correctionを出すsecond distributional networkをtrainingしました。

```
final local search window = Core prediction ± 32 ft
```

各residual-training batchはreal OOF residual recordsとsynthetic local residualsを50/50でmixします。real exampleはfrozen parent特有のmistakeを教え、syntheticはmistakeへのnarrow lookup table化を防ぎます。

nested whole-well CVを使いました。protected outer foldごとにmodel/recipe selectionを他4 foldsだけで行います。reciprocal excluded-pair rolesにより20 logical inner rolesを10 unique pair trainingsで表し、その後予測foldを除く5 outer modelsをtrainingしました。

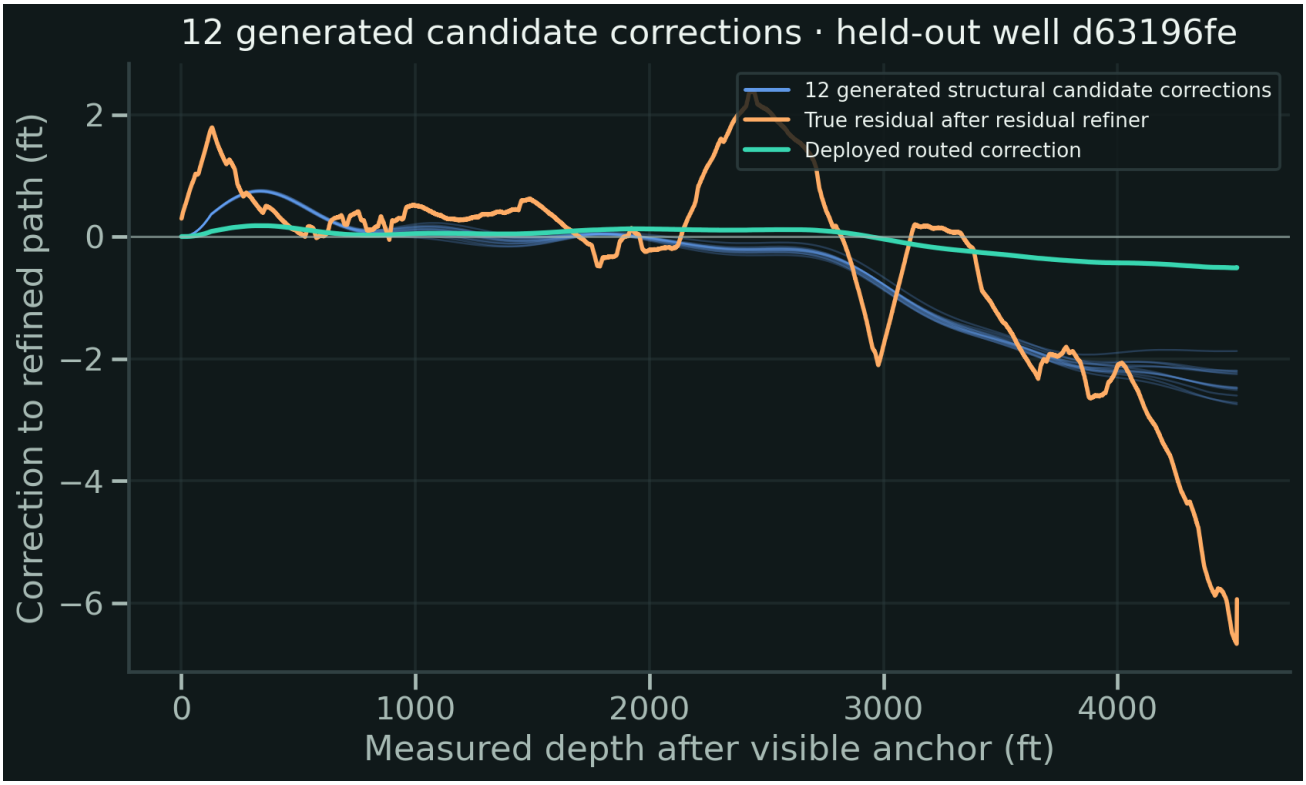
deployed residual stageは5 clean outer pathsを平均します。neural packageはouter roleごと2 seedsの10 local residual networksと1 physical posterior networkです。pooled OOF 6.1895→6.1273、Public 6.263→6.127、Private 6.985→6.918でした。

6. Target wellから作るstructural candidates

residual refinement後もlong coherent errorsが残り、row noiseでなくgeometry問題を示しました。最初のcandidate bankはtarget wellのinference-visible evidenceだけを使います。

`±16 ft` gridを`0.25 ft` resolutionで8,192 smooth particle trajectories sampleしました。hidden-tail GR/typewell agreementでscoreし、momentum、150-row smoothing、visible-prefix support、last visible anchor

から128-row fadeを使います。retained 12 reductionsはtop-64/top-128 particle subset、temperature 10/30、surface bandwidth 4/8/12、uniform mean/median summaryを含みます。



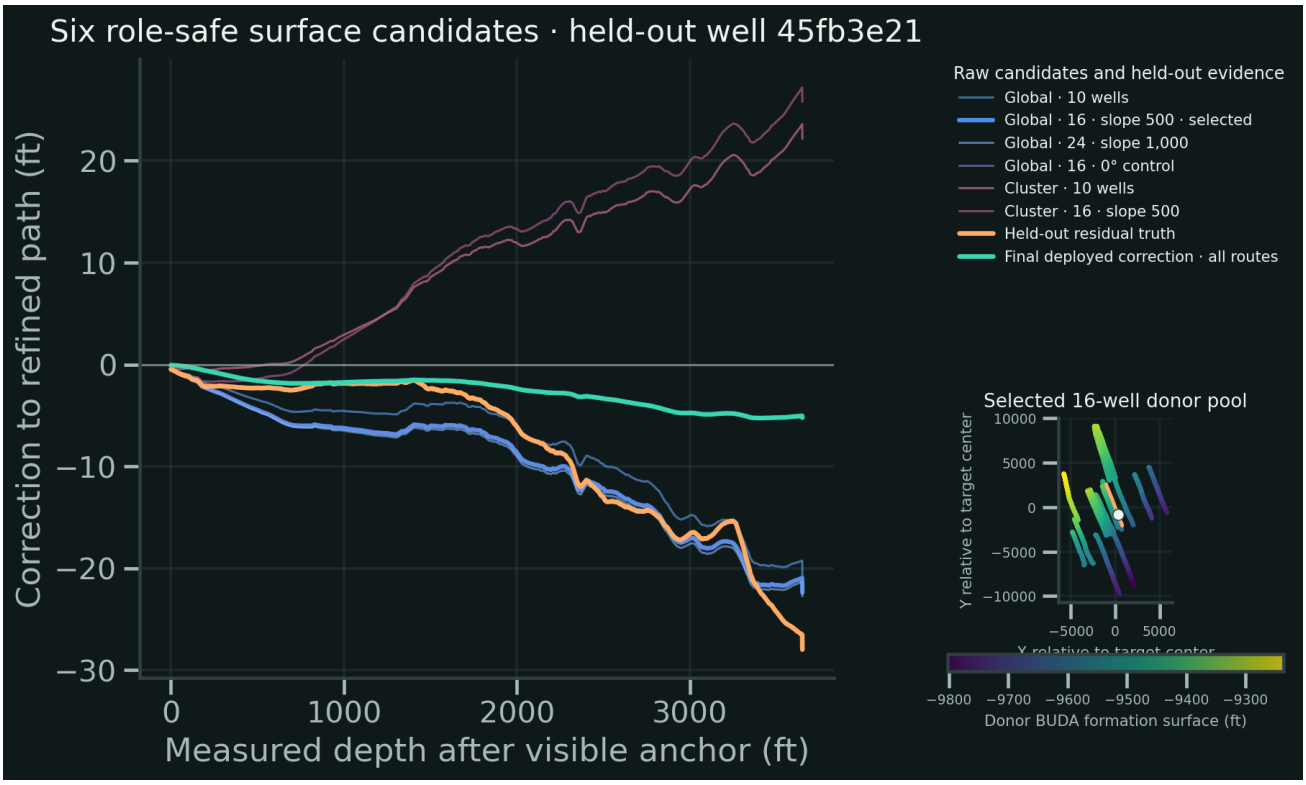
blueは12 candidates、orangeは評価時だけ使うheld-out residual truth、tealはfrozen routerが選んだcorrectionです。

candidateはvisible anchor付近で意図的にconservative、hidden tail奥でslow accumulating correctionを表現できます。自動editではなくhypothesisで、routerはabstainできます。

7. Cross-well surface transfer

second candidate bankはnearby wellsがshared formation surfaceを支持するかを問います。target held-out foldの全wellを除くdonor poolから6 role-purged surface-transfer pathsを作りました。

donor count 10/16/24、global/cluster-local pools、clean development roles内で選ぶ 138° coordinate rotation、unrotated controlを使います。donor geometryへanisotropic quadratic surfaceをfitし、target last visible rowへanchorし、500/1,000 rowsのslope lengthでdecayさせます。



orangeはheld-out target trajectoryでdonor BUDA valuesを提供しません。colored pathsはreal training-well donorsで、colorはBUDA formation-surface valueです。

cross-well transferは強力ですがlocal neighborhoodが本当にinformativeなときだけです。mandatory correctionでなくcandidate sourceとしました。

8. Sparse utility routing

wellごとにbaseline path、GR match quality、trajectory geometry、candidate agreement、donor support、uncertaintyを記述する409 inference-visible featuresを作ります。2 small non-deep routersがcandidate familyのutilityを推定します。

- surface candidates向け600-tree depth-1 XGBoost、cap `0.30`、utility threshold `0.20`
- structural candidates向け700-tree ExtraTrees、minimum leaf size 16、cap `0.20`、threshold `0.01`

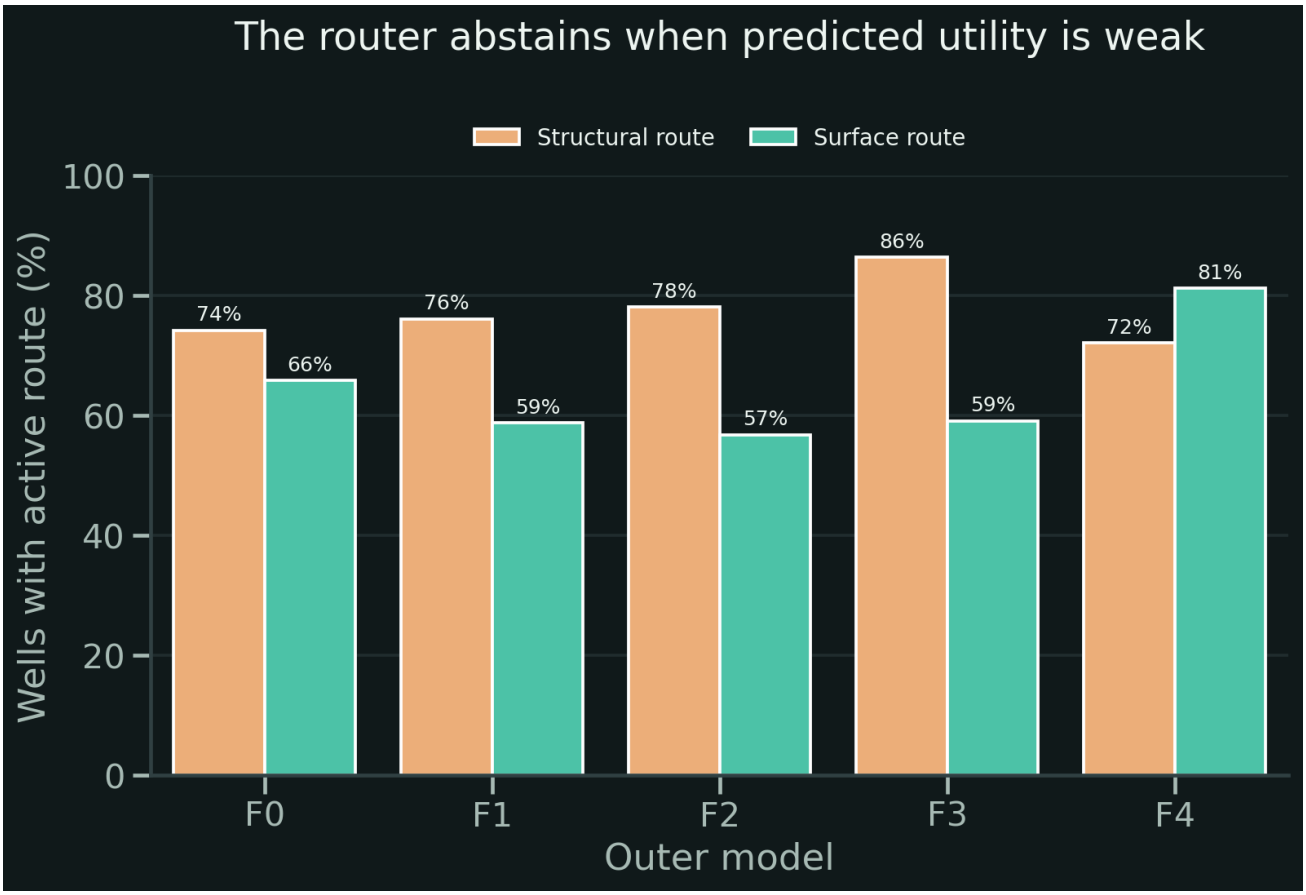
wellごとにsurface routeとstructural routeは最大1つずつactiveです。surface amplitude× `0.625`、structural× `1.25`、complete routed correction× `0.60`です。

outer path `o`、residual-refined path `R_o`、18 candidatesの1つ `C_k` に対するdeployed ruleは次です。

```
prediction[o]
= R[o] + 0.60 × sum_k ((weight[o,k] + route[o,k]) × (C[k] - R[o]))
```

frozen candidate weightsの大半はsmallです。dynamic partはsurface/structural routeを最大1つずつ足し、どちらもexactly zeroになれます。

重要なのはabstentionです。routerがpositive utility evidenceを見つけたときだけcandidateを使い、それ以外はstronger parent predictionを変更せず通します。



route rateはsparseで、全predictionをperturbせず適切なwellだけをselectiveに修正して改善しました。

9. Validation and leakage control

splitはcomplete wellでgroup化しました。held-out wellのrowはtraining dataへ入らず、outer contextごとに同じautomatic pipelineを実行します。hyperparameters、candidate recipes、thresholds、tie-breaksはprotected outer foldを評価する前に4-fold inner pool内で選びます。

outer folds `Fi`,`Fj` についてreciprocal inner rolesは他3 foldsでtrainingしたmodelを共有します。

```
20 logical inner roles
10 unique excluded-pair inner trainings
5 outer trainings
```

Public LBはpromotion後のmonitoringに使い、training/blend selectionには使いません。inferenceはGRとwell geometryを読み、target TVT、ANCC、BUDA、Geologyを読みません。cross-well BUDAはtraining-donor evidenceのみで、OOF構築ではrole-purgedです。

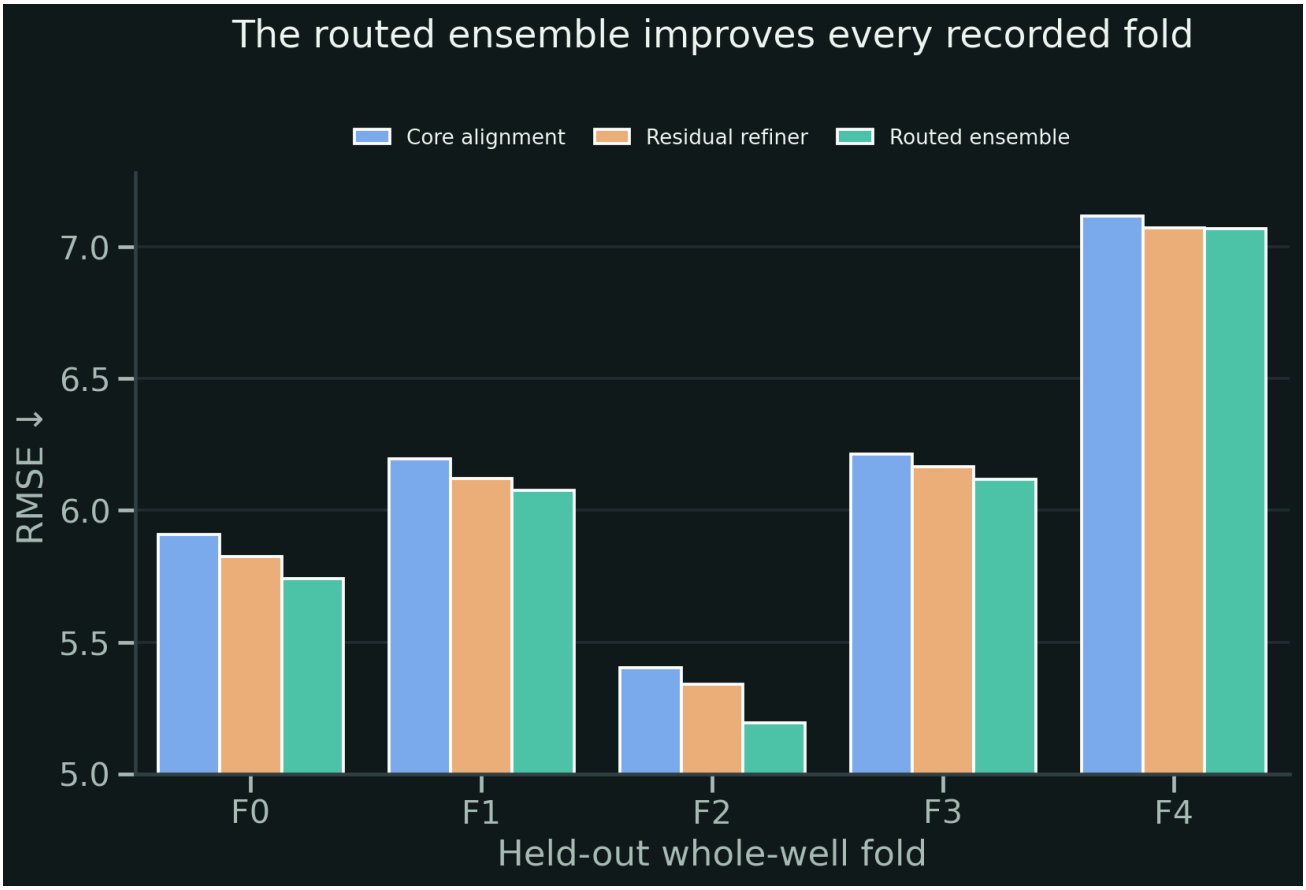
Kaggle inference runtimeはdual T4でneural ensembleを動かし、85 Core checkpoints、11 residual checkpoints、5 router pairsをpackageしました。

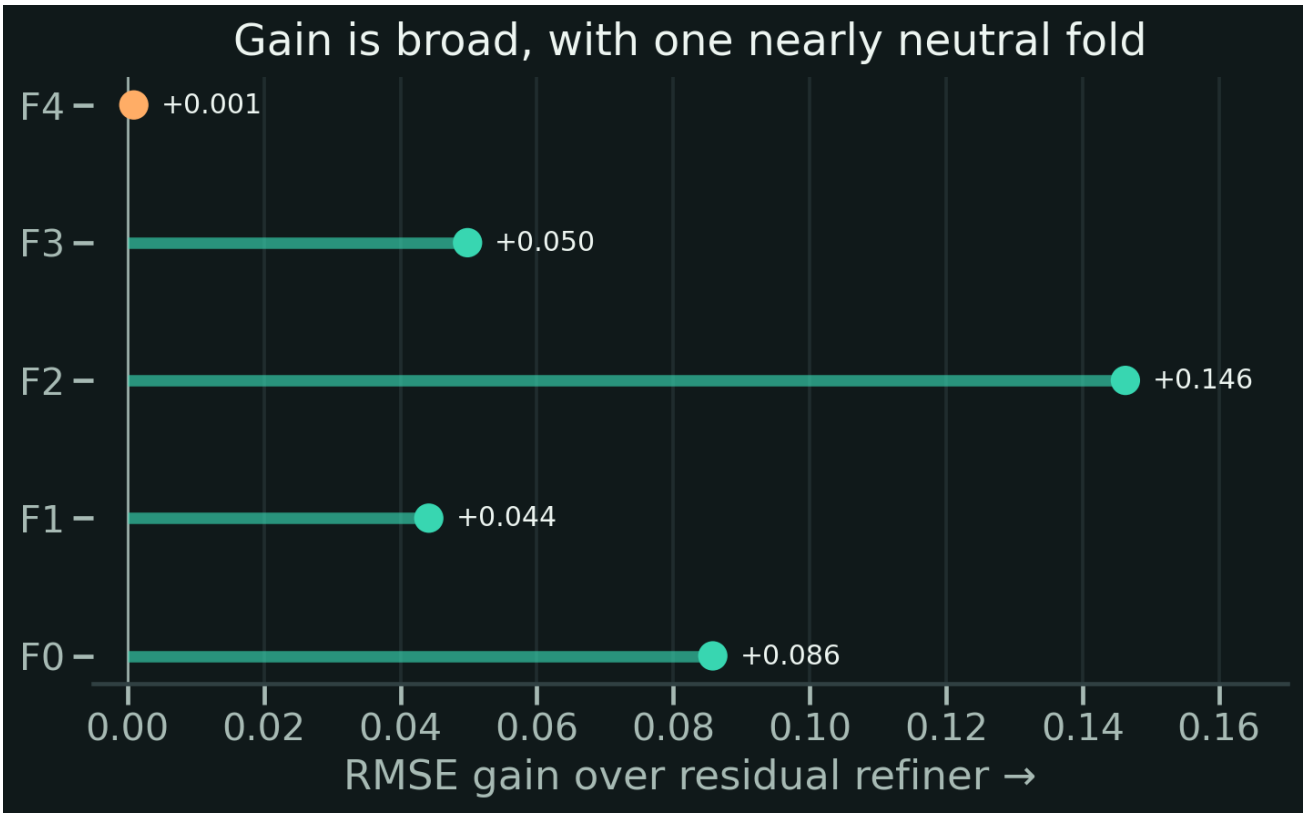
10. Results

final routed correctionは全5 held-out foldsを改善しました。

Fold	Core alignment	Residual refiner	Routed ensemble	Routed gain vs Core
F0	5.9092	5.8258	**5.7400**	+0.1692
F1	6.1954	6.1199	**6.0757**	+0.1197
F2	5.4032	5.3391	**5.1929**	+0.2103
F3	6.2145	6.1666	**6.1168**	+0.0978
F4	7.1159	7.0713	**7.0704**	+0.0455
Pooled OOF	**6.1895**	**6.1273**	**6.0665**	**+0.1230**
Public LB	**6.263**	**6.127**	**5.962**	**+0.301**
Private LB	**6.985**	**6.918**	**6.729**	**+0.256**

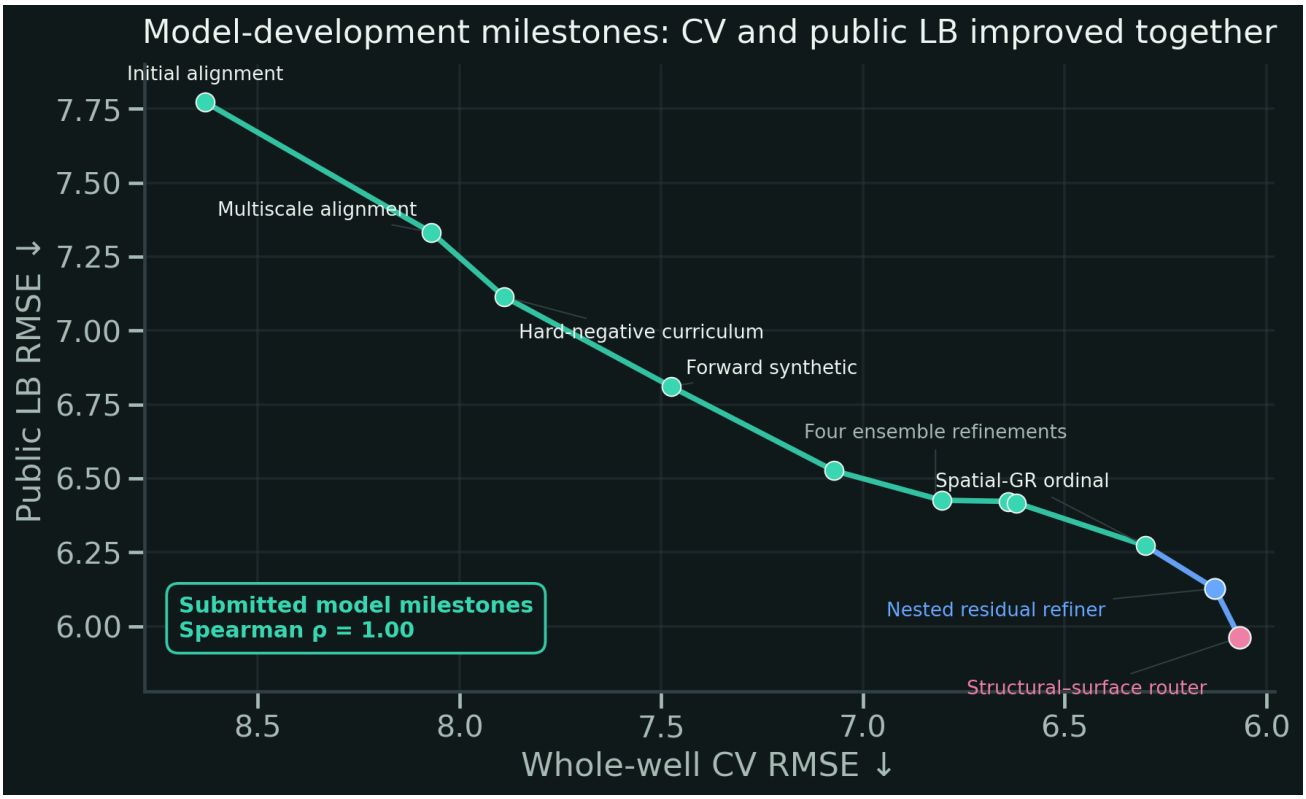
Core alignment、Residual refiner、Routed ensembleのleaderboard scoresはそれぞれKaggle submissions `54893107`、`55115834`、`55147410`です。





11 non-buggy submitted milestonesでCV/Public LBは完全に同じrank order（`Spearman ρ = 1.000`）でした。終了後のPrivateもほぼ同順（`Spearman ρ = 0.991`）で、唯一のinversionは最初の弱い2 milestones間です。3 headline stagesはPrivateでもstrict orderを保ち、Residual refiner→Routed ensembleは`0.189`改善しました。

これらmilestoneのPrivate scoresは一様にPublicより高く、このlineageにはPrivate splitが難しかったと分かります。重要なのはPublic score単独ではなく、leakage-controlled OOF orderingと2 refinement gainがPrivateでも残ったことです。Publicはmonitoringだけで、training/blend selectionには使いませんでした。



11. 最も重要だったこと

最大のlessonはrepresentationでした。targetをalignment volume内のpathへ変えると次が自然になります。

- GRをisolated scalarでなくcorrelation surfaceとして使う。
- categorical state logitsでambiguityを表し、posterior-mean decodeでcontinuous accuracyを維持する。
- synthetic wellsでcontrolled geological distortionを与えてからreal fine-tuningする。
- nested whole-well CVで、learned residual stageがparent OOF errorsをleakなしで使う。
- explicit structural candidatesによりlast correctionをinterpretableかつgateしやすくする。

final systemは1つの巨大modelではありません。whole pathを予測し、localにrefineし、少数のphysically meaningful alternativesを提案し、visible evidenceが正当化したときだけparentを変える、慎重さを増すdecision sequenceです。

training recipes、fold definitions、frozen inference、manifests、verification commandsを含む完全なreproductionはsolution repositoryにあります。

signal processing、geometry、careful validation、machine learningを組み合わせる価値があるコンペを開催したROGIIとKaggleに感謝します。