Biohub - Cell Tracking During Development 上位解法まとめ — 分裂を細胞ごとの証拠で値付けし、系譜グラフ全体で決める

はじめに

Biohub - Cell Tracking During Development は、ゼブラフィッシュ胚の3D顕微鏡動画から細胞核を見つけ、フレーム間でつなぎ、細胞分裂まで含めた「系譜グラフ」を作るコンペでした。2026年9月29日（UTC）に終了し、3,947チームが参加しました。

上位のモデル構成はばらばらでしたが、勝負を分けたポイントは共通していました。結論を先に書きます。

> **注釈が数%しかなく、分裂1件がedge数十本分の価値を持つ評価では、検出精度より「分裂の値付け」が勝負を決めた。この細胞は分裂するか、どれが娘かを細胞ごとの証拠で値付けし、系譜グラフ全体の最適化に渡したチームが上位に来た。**

これを支える前提が2つあります。注釈のない細胞を「負例」にしないことと、学習に使っていない胚で判断することです。本記事はこの3点に絞って、代表的なチームの例で説明します。

対象は最終順位1〜17位で、Kaggle CLIで取得できたDiscussionから14チーム・15本のSolution投稿を読みました。8位・13位・15位のチームについては、調べたKaggle CLI経由のDiscussionの中に本人によるSolution投稿が見つかりませんでした。

コンペ概要

タスク

- **入力**: 1本100フレームの3Dボリューム動画（64×256×256ボクセル）。z方向だけ解像度が4倍粗い。
- **出力**: 各フレームの細胞の位置（**node**）と、t の細胞から t+1 の細胞へのリンク（**edge**）。1つのnodeから2本のedgeが出る分岐（**fork**）が分裂を表す。
- **評価**: `score = adjusted_edge_jaccard + 0.1 × division_jaccard`。予測と正解のnodeを7 µm以内で対応づけ、edgeの正しさと分裂の正しさを測る。

この指標には、直感に反する性質が3つあります。

1. **注釈のある細胞しか採点されない。** 正解の注釈は推定細胞数の約2.8%だけです。注釈のない細胞同士を正しくつないでも加点はありません。一方、予測nodeの総数が推定細胞数を超えると減点されます。
2. **分裂1件がとても重い。** 分裂の重みは0.1ですが、分裂は全部で151件しか注釈がありません。12位の計算では、学習データ上で分裂1件の見逃しはedge約74本の見逃しに相当しました（12位）。
3. **テストは別の胚。** 学習の2胚とは違う胚で採点され、Public LBとPrivate LBもそれぞれ別の胚でした。

提供データ

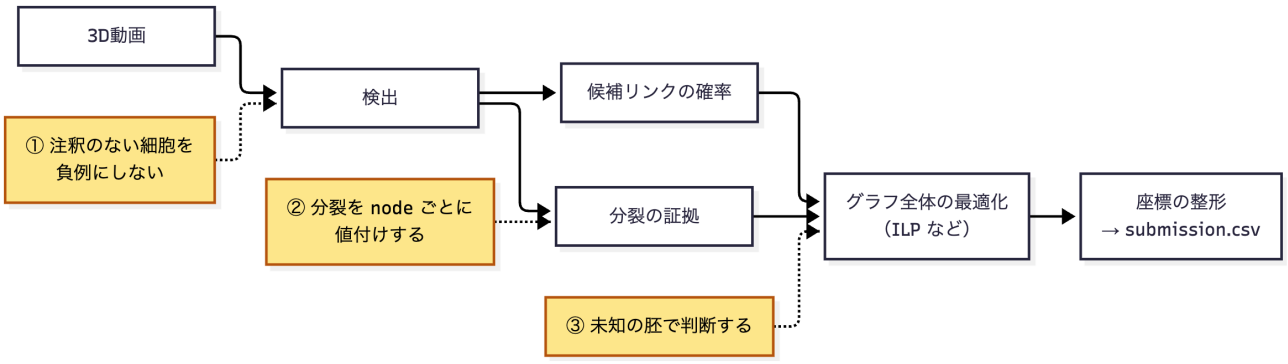
データ	内容
学習動画	2つの胚から切り出した199本（`.zarr`）
正解グラフ	疎な注釈（約133,000 node、分裂151件、`.geff`）
推定細胞数	動画ごとの細胞数の推定値。node数の減点の基準になる
実行環境	インターネットなしのNotebookで12時間以内

このコンペが難しい理由

- 見えている細胞の大半にラベルがないので、「ラベルなし＝背景」と学習させると本物の細胞を消すモデルになる。
- 分裂の教師が151件しかなく、分類問題として素直に学習すると負例ばかり覚える。
- 公開ノートブックの重みは学習データ199本すべてで学習されていて、学習データ上のスコアが当てにならない。
- 胚が変わると、核の大きさも密度も変わる。

上位解法の全体像

ほぼすべてのチームが、「細胞を検出する → 候補リンクに確率をつける → グラフ全体を最適化で確定する → 座標を整える」という同じ骨格を使いました。差がついたのは、下図で色をつけた3か所です。



ここでのILP（整数線形計画法）は、「どのnode・edge・forkを採用するか」を0/1の変数にし、コストの合計が最小になる組み合わせをソルバーで解く方法です。

1. 注釈のない細胞を負例にしない

問題: 正解の位置にだけ「細胞」の印をつけ、残りをすべて背景として学習すると、注釈のない本物の細胞まで「ここには何もない」と教えることになります。

上位の対処: 画像を「注釈あり」「確実に背景」「不明」の3つに分け、「不明」は学習に使わないか、ごく弱くしか使いませんでした。

- **4位**は、暗さで判断した「確実な背景」以外を不明として扱いました。さらに3つのグループの重みをそれぞれの面積で割ってそろえました。そうしないと注釈部分がlossの0.5%未満しか占めず、モデルが「全部背景」と答えるようになったそうです（4位）。
- **6位**は「不明」を学習から外す代わりに、検出の総量を推定細胞数に近づける制約（count prior）を入れて、出しすぎを防ぎました（6位）。

逆をやるとどうなるか: 9位は、注釈のない場所を背景として学習した検出器を試しました。結果はPublic +.002 に対しPrivate −.019 で、全提出の中で最悪でした（9位）。学習した胚の「注釈のつき方」まで覚えてしまい、別の胚で崩れたと考えられます。

同じ考え方は分裂モデルにも当てはまります。4位では、「難しい負例」を集めて学習させるとひどく悪化しました。難しい負例の大半が、実は注釈のない本物の分裂だったからです（4位）。

2. 分裂をnodeごとに値付けし、グラフ全体で決める

この節が本記事の中心です。

公開パイプラインは分裂を1件も作れなかった

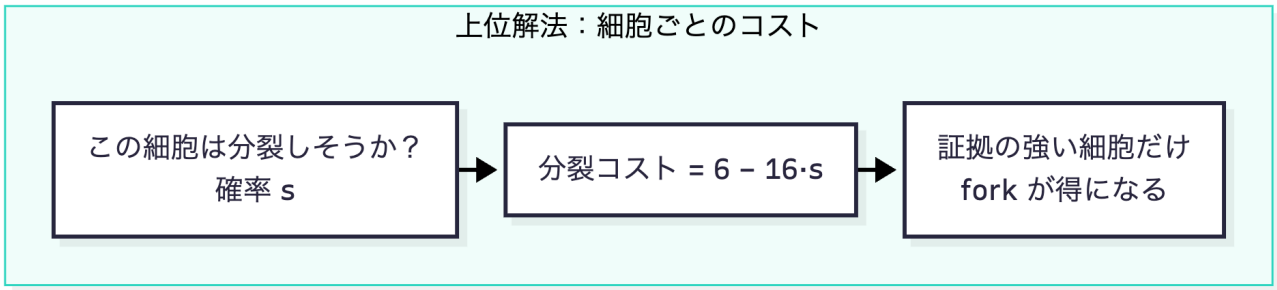
公開ノートブックのILPは、次の設定でした（14位の整理による）。

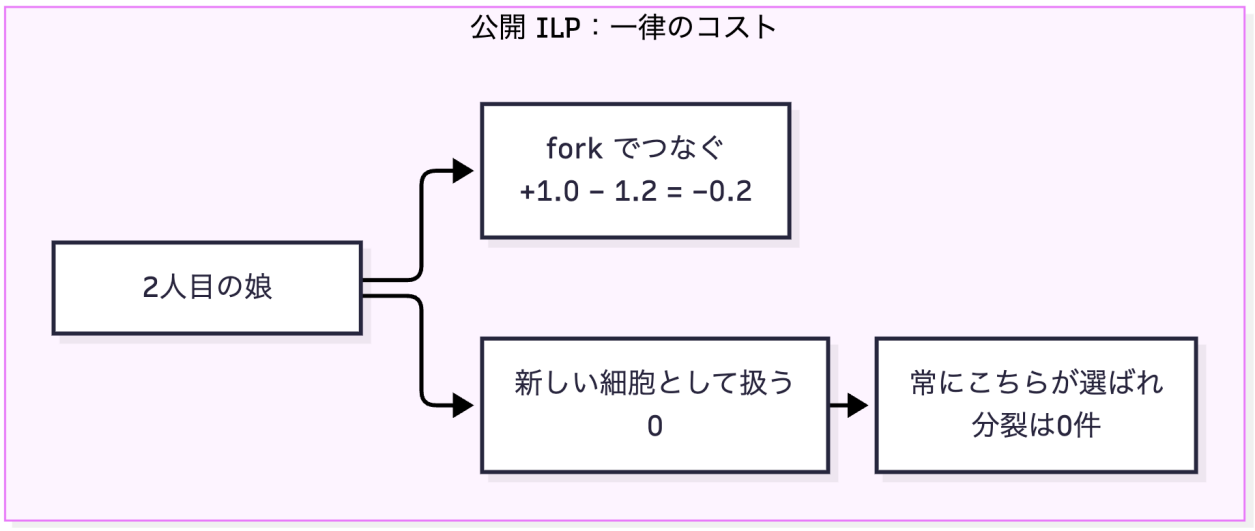
- edgeを1本採用すると、+1.0（報酬）。
- forkを1つ開くと、−1.2（コスト）。
- 細胞が新しく現れたことにするのは、0。

2人目の娘をforkでつなぐと +1.0 − 1.2 = −0.2 になります。一方、新しく現れた細胞として扱えば0です。後者が常に得なので、ILPは**構造上forkを1つも開きません**（14位）。9位は、最良の公開パイプラインが検証の40本すべてでforkを0件しか作らないことを確認し、分裂を後から書き戻すだけで Public +.011 / Private +.013 を得ました（9位）。

一律のコストから、細胞ごとのコストへ

分裂コストが全細胞で同じだと、ソルバーは「forkを一度も開かない」か「近くに細胞があるだけで偽のforkを開く」かの両極端になります（4位）。上位チームはこれを、細胞ごとの証拠で決まるコストに変えました。





代表例が4位です。各細胞について「分裂する母細胞である確率」s を学習し、分裂コストを `6 − 16·s` にしました。s が0.375を超えるとコストが負、つまり分裂が「報酬」に変わります。この変更だけで、LBは0.913から0.948へ（Public/Privateとも +0.035）上がりました（4位）。

「分裂しそうか」は細胞を見れば分かる

s をどう作るかでは、細胞そのものの見た目を使ったチームが強かったです。1位は人手で細胞を追跡しているうちに、分裂直前の細胞が「震え、明るくなり、大きくなり、突然2つに割れる」ことに気づきました。そこで、各細胞の前後3フレームを切り出して「分裂間近か」を判定する小さなモデル（Soon Net）を作り、分裂の改善だけでPublic LBを約0.925から約0.963へ伸ばしました（1位）。

決めるのはグラフ全体で一度に

リンクを先に確定させてから分裂を足そうとすると、正しい娘がすでに別の親に取られていて、手遅れになります。3位はnode・リンク・分裂を1つの最適化で同時に選びました。その段階を加えた時点で、スコアは0.901953から0.964493になり、全工程で最大の伸びでした。ただし、この段階では分裂モデルや確率の調整も同時に入れています（3位）。7位も、1回目の最適化の後に分裂の候補を評価し直し、グラフ全体をもう一度解き直しています（7位）。

3. 未知の胚で判断する

問題: 公開の重みは学習データ199本すべてで学習されていたので、それを使ったパイプラインを学習データで測ると、「答えを見たテスト」の点数になります。

- **12位**の自前ベンチマークは、Privateより約0.03高く出ていました。104組の比較のうち17組で、PublicとPrivateの改善の向きが逆でした（12位）。
- **9位**では、自前で学習したモデルの価値がPublicでは +.004 に見えたのに、Privateでは +.023 でした（9位）。

上位の対処: 片方の胚で学習し、もう片方の胚で評価しました。

- **10位**はこの方法で開発を進め、Publicは1838位でしたが、Privateで10位まで上がりました（10位）。
- **17位**は、変更を設計する動画と確認する動画を分け、確認で落ちた変更は捨てました。それでも、CVでの改善のうちPrivateまで届いたのは23%でした（17位）。

Publicの小さな差は誤差と考えた方が安全です。16位では、乱数seedを変えただけでPublicに0.006の差が出ました（Privateは0.001）（16位）。

補足：そのほかに効いた工夫

3つの勝負所ほどではありませんが、多くのチームが取り入れた工夫です。

工夫	なぜ効くか	代表例
集団の動きを差し引いてからリンクを比べる	胚全体が流れると、止まっている細胞も動いて見える	6位: 試料台のずれを除いた距離で、検証 +0.009（6位）
Linkerに「対応相手なし（新規細胞）」の選択肢を持たせる	ないと、相手のいない細胞まで無理に隣とつながる	5位: 新規細胞・分裂のheadを追加して Public +0.020 / Private +0.024（5位）
擬似ラベルはパイプライン全体の出力から作る	最適化後のつながりは、モデル単体の判断より正確	6位: 最初の自己学習ラウンドで検証 +0.008（6位）
ILPのコストを評価指標で調整する	ソルバーの目的と、コンペの評価はずれている	11位: 再学習とコスト調整を合わせて Public 0.89618 → 0.94905（11位）
座標はグラフを決めた後に整え、整数で書く	先に動かすと正しいリンクが減る。正解は整数座標	9位: 切り捨てを四捨五入に直して Public +.009 / Private +.013（9位）
消えた暗い細胞は「何フレームも続く」ときだけ戻す	1フレームだけの点は誤検出の可能性が高い	2位: 捨てた候補から長い経路を回収し、正しい edge +360本（2位）

上位解法から見えた、特に重要な発見

1. 点数は検出より分裂で動いた

分裂1件はedge数十本分の重さを持つのに、公開ILPはコストの設定上、分裂を作れませんでした。分裂を細胞ごとに値付けする変更が、4位・9位で最大級の改善になり、3位でも最大の伸びを含む段階になっています。

2. 「分からない」を「違う」として学習させない

検出でも分裂でも、注釈のない対象を負例にすると、別の胚で崩れました。ラベルのない場所は「不明」として、学習から外します。

3. 物差しを間違えると、良い手法でも負ける

学習データ上のスコアやPublicの小さな差で選んだ改善は、Privateで消えることが多くありました。見ていない胚で測ったものだけを信じたチームが、Privateで順位を上げています。

うまくいかなかったアプローチ

- **注釈のない場所を背景として学習する**: 9位でPrivate −.019。不明領域は学習から外す（9位）。
- **分裂モデルで難しい負例を集める**: 4位で大きく悪化。難しい負例の多くは、注釈のない本物の分裂だった（4位）。
- **合成データで事前学習した検出器をメインにする**: 7位ではPublicが上がる一方、Privateは0.956から0.947に下がった。補助として使う方が安全（7位）。
- **見逃しを減らすためにnodeを足す**: 17位では、ごく狭い例外を除き、node数の減点か誤ったリンクで帳消しになった（17位）。
- **学習データ上のベンチマークで判断する**: 12位はPrivateを約0.03高く見積もった（12位）。

どれも、「多い方が良い」「学習データで良い方が良い」という直感が、この評価条件では成り立たなかった例です。

まとめ

上位解法の流れを5行にまとめると、次のとおりです。

1. 注釈のない領域を「不明」として扱い、時間方向の文脈も使って細胞を検出する。
2. 集団の動きを差し引いて、候補リンクに確率をつける。
3. 細胞ごとの「分裂しそうか」の証拠から、分裂コストを決める。
4. node・リンク・分裂を、グラフ全体の最適化で同時に決める。
5. 学習に使っていない胚で評価して、最終提出を選ぶ。

> **稀で価値の高いイベントを、一律の閾値やコストで扱ってはいけない。そのイベントに固有の証拠で1件ずつ値付けし、他の決定と同じ最適化の中で決める。そしてラベルがないことを、負の証拠として扱わない。**

この考え方は、注釈の少ない多物体追跡や、稀なイベントを含むグラフ構築など、評価が稀なイベントに大きな重みを置くタスク全般に使えます。

参照した上位Solution

各チームの要点を一言でまとめています。詳しく知りたいチームは、リンク先の投稿を参照してください。

順位	チーム	一言で言うと	投稿
1位	Sergio Alvarez	細胞を3フレーム見て分裂状態と行き先を予測し、学習済みLinkerで分裂を判定	1st Place Solution
2位	Soheil Ayati	弱い検出を捨てずに保持し、何フレームも続く暗い細胞を後から回収	2nd Place Solution
3位	yu4u	flow・対応・分裂を別々に学習し、node・リンク・分裂をLP/MILPで同時に選択	3rd Place Solution
4位	Barry	生物学の観察を小さなモデルに落とし込み、細胞ごとの分裂コストで +0.035	4th Place Solution
5位	Tang	公式baselineに「新規細胞」と分裂のheadを足し、多段のILPで仕上げ	5th Place Solution
6位	Cyrus	検出とリンクを1つのネットワークで行い、パイプライン全体を先生にして自己学習	Detect, Link, Solve, Repeat、A Tracker That Teaches Itself
7位	tatsutaka	単一の強い検出器と専用の分裂パイプライン、2段階のILP	7th Place Solution
9位	yuto083	公開パイプラインが作れなかった分裂を書き戻し、自前モデルでPrivateを伸ばした	9th Place Solution
10位	Kaggle Agent	胚単位の検証を徹底し、Public 1838位からPrivate 10位へ	10th place solution
11位	tanbo	検出・動き・分裂を同時に学習し、ILPのコストを評価指標で調整	11th Place Solution
12位	Corwin	公開パイプラインに修復処理を重ね、in-sample評価の落とし穴を詳しく分析	12th Place Solution
14位	Vibes & Edges Trade-Off	失敗の仕方が違う2本のパイプラインを動画ごとに統合し、分裂は対応関係の回帰で検出	14th place solution
16位	r3takahashi	自前の検出器を自己学習で育て、公開のリンク処理と組み合わせ	16th Place Solution
17位	ibyyue	胚単位の検証と、評価指標への影響を教師にした後処理の学習	17th Place Solution

8位（Amin）、13位（The Boys）、15位（Yapay Hücre）は、調べたKaggle CLI経由のDiscussionの中に本人によるSolution投稿が見つかりませんでした。