biohub-cell-tracking-during-development

3位 Solution

Rank	3
Team	yu4u
Author	yu4u
Topic ID	744484
Version	Japanese Translation

Source: https://www.kaggle.com/competitions/biohub-cell-tracking-during-development/discussion/744484
Retrieved with Kaggle CLI on 2026-10-04.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

主催者の皆様、そしてディスカッションやノートブックを共有してくださったすべての方に感謝いたします。私たちのソリューションは、疎なアノテーションから細胞を検出することと、移動と分裂の証拠を組み合わせて整合性のある lineage graph を構築することに注力しました。

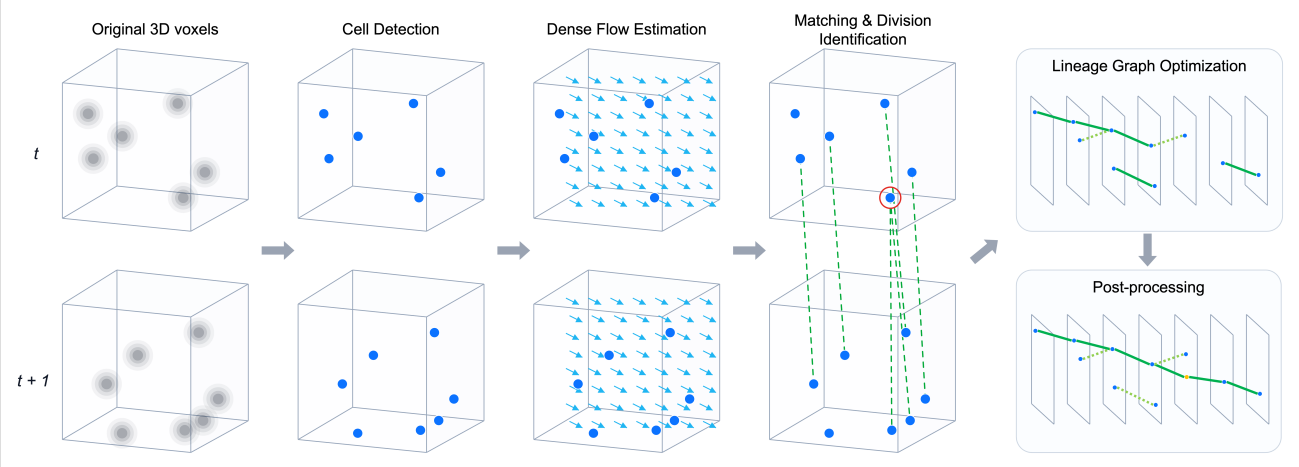
1. 概要

私たちのパイプラインは6つのステージで構成されています。

1. **細胞検出:** 2.5D U-Net と 3D SegResNet の heatmap をアンサンブルして細胞中心を検出します。
2. **Dense flow:** 連続するフレーム間の 3D 変位場を推定します。
3. **細胞マッチング:** 画像特徴量と、動きを補正した位置を用いて対応候補をスコアリングします。
4. **分裂の識別:** 元画像と動きで位置合わせした画像から分裂する親細胞を識別し、分裂前後のステージ用の補助モデルも併用します。
5. **Lineage graph 最適化:** 通常のリンクと division イベントを同時に選択します。
6. **後処理:** 短いギャップを埋め、小さな連結成分を除去し、ノード座標を精緻化します。

下流のすべてのステージが検出された細胞に依存するため、私たちは検出精度に特に力を入れました。トラッキングについては、flow、マッチング、division の各モデルを個別に学習し、それらの出力をグラフ最適化で組み合わせて細胞間の接続を決定しました。最終サブミッションでは比較的大きな検出バックボーンのアンサンブルを使用しており、検出が総実行時間の55%を占めていました。

最終ソリューションは CV スコア **0.977801 (0.540107)**、Public LB スコア **0.977 (0.52)**、Private LB スコア **0.967 (0.47)** を達成しました。括弧内の値は Division Jaccard を示します。



2. データと検証

学習セットには、2つの胚から切り出された199本の動画が含まれています。各動画は 64 × 256 × 256 ボクセルのフレームが100枚からなります。ボクセル間隔は z 方向が 1.625 µm、x および y 方向が 0.40625 µm であるため、距離は物理座標で計算しています。

主な課題は、アノテーションが細胞のごく一部しかカバーしていないことです。アノテーションされたノードは約133,000個で、主催者が推定した総数の約2.8%にすぎません。明らかに見えている細胞の多くにアノテーションがなく、学習セットにはアノテーションされた分裂が151件しか含まれていません。

この疎さは評価においても重要です。公式スコアは、ノード数で調整された edge Jaccard と division Jaccard の0.1倍との和です。アノテーションのない領域内に完全に収まるリンクは自動的に false positive になるわけではなく、アノテーションされた接続と競合する誤ったリンクがペナルティを受けます。予測ノード数については別途調整が入ります。したがって、検出の precision や局所的なリンク分類の精度だけでは最終スコアを説明できません。

私たちは動画単位の5-fold 交差検証を用い、両方の胚の動画を各 fold に分散させ、1本の動画の全フレームは同じ fold にまとめました。検出器、matcher、division モデルについて out-of-fold (OOF) 予測を生成しました。下流のキャリブレーションモデルも、評価 fold を除外して学習しました。

2つのテスト胚はどちらも学習胚とは異なります。一方の胚で学習してもう一方で検証することも検討しましたが、CV と Public LB で観測された改善傾向に基づき、モデル選択には動画単位の5-fold CV を使用しました。同じ胚からの切り出しは fold 間で空間的・時間的に重なり得るため、この検証は完全に独立ではありません。また、Public LB との一致は Private テスト胚への汎化を保証するものでもありません。

4つの胚を以下にまとめます。学習データの prefix と動画数は提供データに基づくもので、テストデータの prefix、動画数、密度の範囲、および Public/Private の分割割り当ては probing によって特定したものです。

胚の prefix	動画数	分割	密度 p10	密度 p50 (中央値)	密度 p90
`44b6`	71	Train	134	355	627
`6bba`	128	Train	54	114	445
`fdad`	60	Public test	[40, 60)	[160, 260)	[260, 420)
`ea36`	106	Private test	[40, 60)	[60, 100)	[160, 260)

ここでの密度は **フレームあたりの検出数** を意味し、細胞数の代理指標として使用しています。すべての動画に対して同じ初期バージョンの検出器を用い、各動画で等間隔に選んだ4フレームの検出数を数えて平均し、動画間でパーセンタイルを計算しました。学習データの値は丸めた実測値であり、テストデータの値は probing から推定した区間です。Public と Private のテスト胚では細胞密度が大きく異なります。

3. 細胞検出

バックボーン

2.5D と完全な 3D の検出器を組み合わせました。

2.5D モデルには、私たちの CZII - CryoET Object Identification solution のバックボーンアーキテクチャを再利用しました。事前学習済みの 2D エンコーダが z スライスから特徴量を抽出し、各ステージで特徴量を z 方向にプーリングし、3D デコーダがそれらを統合します。エンコーダには EfficientNetV2-L と EfficientNet-B7 を使用しました。

各エンコーダの入力は隣接する3枚の z スライスをチャネルとして積み重ねたもので、最初の層が局所的な深さ情報を利用できるようにしています。これらのスライスは空間的なコンテキストのみを提供するもので、時間的な情報はトラッキングパイプラインの後段で導入されます。

完全な 3D 検出器には MONAI の SegResNet 実装を使用しました。これは 3D 畳み込みで構成された residual encoder-decoder です。初期チャネル数32、ステージごとに1つの residual block を持つ4つのエンコーダステージ、そして Group Normalization を使用しました。

サブミッションでは以下のアンサンブルを使用しました。

検出器	アーキテクチャ	Heatmap の重み
EfficientNetV2-L	2.5D U-Net	0.3
EfficientNet-B7	2.5D U-Net	0.4
SegResNet (MONAI)	3D residual encoder-decoder	0.3

疎なアノテーションでの学習

ターゲットの heatmap は、アノテーションされた各中心に標準偏差 2 µm のガウシアンを配置したものです。このターゲットに直接 MSE を適用すると、アノテーションのない細胞でもゼロを予測するよう検出器を学習させてしまいます。

これらの細胞を負例として扱わないよう、低い閾値の Difference of Gaussians (DoG) を用いて候補中心を抽出しました。マッチしなかった候補から 6 µm 以内の領域は loss から除外しました。アノテーションされた中心から 2 µm 以内にある DoG 候補は重複とみなし、除外領域は作成しませんでした。アノテーションされた中心周辺の正例領域は、除外領域と重なる場合でも教師信号を与え続けました。つまり DoG は、正例の pseudo-label を追加するのではなく、マスクすべき不確かな背景領域を特定するために使われました。

MSE は正例領域と背景領域で別々に平均し、背景の重みを0.5としました。これにより、はるかに大きな体積を持つ背景が細胞中心周辺の教師信号を圧倒してしまうことを防ぎます。

画像の輝度は、各動画の0.1パーセンタイルと99.9パーセンタイルを用いて正規化しました。学習時のクロップは 48 × 192 × 192 ボクセルです。Augmentation には xy 平面での反転と回転、輝度変化、ブラーを含めました。

私たちの実験では、スケーリングと回転の augmentation は性能を低下させました。

推論

各検出器について、5つの fold モデルの heatmap を平均し、2つの test-time view(元画像と、x と y の両方で反転した画像)を使用しました。検出器の heatmap を上記の重みで組み合わせた後、$(3, 7, 7)$ カーネル、閾値0.2の non-maximum suppression で中心を抽出しました。

A0: 幾何的リンクによる検出

表1のベースラインは、物理距離と 7 µm の距離ゲートを持つ1対1の Hungarian 割り当てを用いて、連続するフレームの検出をリンクします。マッチした点の変位の中央値から集団的な並進(drift)を推定し、drift 補正と割り当てを2回繰り返します。

このベースラインは dense flow、学習済み matcher、division 予測、後処理のいずれも使用しません。単純なリンクは評価の出発点となります。検出だけでは true positive の edge を生成できませんが、通常のリンクは division を予測しなくても edge スコアを獲得できます。

4. Dense Flow と細胞マッチング

A1: Dense flow

細胞は個別にも集団的にも移動します。各細胞が次のフレームでどこへ移動するかを予測するため、連続する 3D 画像から flow を推定します。

`(z, y, x) = (1, 4, 4)` でダウンサンプリングすると、1.625 µm 間隔の等方的なグリッドが得られます。このグリッド上で小さな 3D encoder-decoder を動作させます。局所相関と soft-argmax により初期変位を生成し、ネットワークが residual 予測でそれを精緻化します。エンコーダは正規化層なしで 32、64、128 チャネルを使用します。

実際の画像ペアに対しては、warp 後の画像および局所特徴量の一貫性、forward-backward 一貫性、平滑化の loss を組み合わせて学習します。また、既知の並進と滑らかな変形で生成した合成ペアに対しては、変位を直接教師あり学習します。アノテーションされたリンクは endpoint-error の評価とチェックポイント選択に使用しますが、学習の loss には使用しません。

推定した flow は、対応点探索と、division モデルに入力する画像の位置合わせの両方に使われます。

A1 では、元の座標に dense flow を加え、残差 drift を2回推定し、A0 と同じ 7 µm ゲートと1対1の割り当てを維持します。これにより、division のモデリングを導入する前の動き補正の効果を測定します。

A2: 細胞マッチング

Matcher は連続する2フレームとその検出結果を受け取り、時間をまたいでどの細胞が対応するかをスコアリングします。外観と flow で補正した位置を用いて、対応候補のスコアと、マッチが存在しないことを表す null スコアを予測します。これらのスコアは候補集合を絞り込むもので、最終的な接続は後段のグラフ最適化で選択されます。

Matcher は検出器とは別に、EfficientNetV2-S エンコーダを持つ独自の 2.5D U-Net を持っています。flow モデルと同じ `(1, 4, 4)` ダウンサンプリングを使用します。中間デコーダステージから各検出位置の64チャネルの特徴量をサンプリングすることで、フル解像度のデコーダ出力の計算を回避しています。

Self-attention と cross-attention が細胞の特徴量と位置情報を処理します。マッチングヘッドは外観の cosine similarity に基づいてスコアを精緻化し、role embedding を用いて2つのフレームを区別します。また、null オプションも予測します。

学習では、アノテーションされた細胞にマッチした検出をアンカーとし、アノテーションされた edge を双方向の cross-entropy のターゲットとします。アノテーションのない細胞は競合候補として残りますが、アノテーションがないからといって null ターゲットにはしません。分裂する親細胞については、各娘細胞ごとにターゲットを構築し、もう一方の娘細胞は負例集合から除外します。

通常のリンクについては、matcher の確率上位5件のうち、flow 補正後の距離が 12 µm 以下の候補を保持します。それらの順位、順方向・逆方向の確率、競合候補に対するマージンを次のステージに渡します。

A2 では、これらの候補とスコアを Hungarian 割り当てに使用します。A0 と A1 は drift 補正後に 7 µm 以内にあるすべてのペアを考慮しますが、A2 は同じゲートを matcher の候補に適用します。したがって、A1 から A2 への変化には候補のフィルタリングが含まれます。完全なパイプラインでは、同時グラフ最適化がこの局所的な割り当てを置き換え、12 µm の flow 距離ゲート内の候補を使用します。

5. 分裂の識別 (A3)

Division モデルは、隣接する時刻の 3D 画像を用いて、検出された細胞が次のフレームで2つの娘細胞に分裂するかどうかを予測します。これを **parent モデル** と呼びます。その出力はマッチングスコアや娘細胞の幾何情報と組み合わされ、グラフ最適化が親から娘への接続を選択します。

分裂も通常の移動も、局所的な画像領域の見た目を変化させます。両者を区別しやすくするため、隣接フレームを中心フレームに位置合わせしてからモデルに入力します。また、単一の変位場では1対2の分裂を完全に表現できないため、元画像も保持します。

メインの parent モデルは、3つの時刻から5つのボリュームを受け取ります。

```
[original t−1, t−1 aligned to t, t, t+1 aligned to t, original t+1]
```

Division モデルは $(1, 2, 2)$ ダウンサンプリングを使用します。flow をこのグリッドに変換する際には、変位の単位と、プーリングによって生じるボクセル中心のオフセットの両方を考慮します。次のフレームは forward flow を用いてサンプリングします。前のフレームについては、直前の forward flow 場の符号を反転することで逆変位を近似します。

共有の EfficientNetV2-S エンコーダが各入力を処理します。対応するステージの特徴量を入力順に連結し、Group Normalization を持つ 3D デコーダに渡します。デコーダは各検出位置で parent スコアを予測します。Flow モデルは凍結したままです。

正例は、次のフレームに2つの子を持つアノテーションされた親細胞です。負例には、通常に継続する細胞と、分裂直後の娘細胞が含まれます。GT にマッチしない検出は負例の loss に含めません。正例と負例の BCE は別々に平均します。学習時には、サンプルの25%を正例の親細胞を含むフレームから、25%を分裂周辺の hard-negative フレームから、残りを通常のサンプリングから取得します。AdamW を学習率 1e-4、20 エポック、EMA decay 0.995 で使用します。

さらに、独立した **pre** モデルと **post** モデルも使用します。親細胞が時刻 t、娘細胞が t+1 にある分裂について、pre は t−1 における前駆細胞を識別し、post は t+1 における娘細胞を識別します。各モデルは、細胞の評価時刻を中心とした3枚の元フレームを受け取ります。これらのスコアは division 候補に対する追加の証拠となります。

サブミッションでは、元画像と位置合わせ画像の両方を用いる parent モデルで、主要な division 候補プールを構築します。2つ目の parent モデルは3枚の元フレームのみを入力とします。そのスコアは、pre および post のスコアとともに、通常リンクのキャリブレーションと、半径 16 µm の追加 division 候補プールに利用されます。2つの division プールは別々にキャリブレーションされます。Division の推論では5つの fold モデルと xy 平面での4つの回転を平均し、OOF 評価では各動画に対応する hold-out モデルを使用します。

6. Lineage Graph 最適化 (A3)

候補スコアのキャリブレーション

距離とモデル出力を組み合わせて、通常リンクと division 候補の確率を推定します。これらの確率により、グラフ最適化器は競合する選択肢を比較できます。

候補は、通常リンクか、1つの親と2つの娘からなる division イベントのいずれかです。Division 候補の生成は parent スコアの閾値0.1で制御し、最終的な選択は最適化器が行います。

キャリブレーションの特徴量には、距離、双方向のマッチングスコア、候補の順位、マージン、検出の信頼度、parent/pre/post スコアが含まれます。Pre の証拠は、複数の可能な前駆細胞にわたって集約します。例としては、pre スコアとマッチング確率の積の最大値や、マッチング確率で重み付けした平均などがあります。

疎なアノテーションに対処するため、2つの確率を推定します。

- **評価される確率:** 利用可能なアノテーションのもとで、候補がスコアリングの対象となるかどうか。
- **正解である条件付き確率:** 評価されるという条件のもとで、それが true positive であるかどうか。

これらを a と q と書くと、`a × q` を期待 true positive 寄与、`a × (1 − q)` を期待 false positive 寄与として使用します。これにより、学習中に評価されないすべての候補を誤りとして扱うことを避けられます。

通常リンクにはロジスティック回帰を使用します。Division の条件付き確率については、線形モデルの初期 logit から LightGBM と XGBoost を学習し、それらの予測確率を等重みで平均します。主要および追加の division プールはそれぞれ別のモデルを持ちます。特徴量には、集約した前駆細胞の証拠、動き、娘細胞間の距離が含まれます。初期グラフの構築には LightGBM の確率を保持し、最適化中の選択肢の評価には平均した確率を使用します。Division のキャリブレーションターゲットは親と両方の娘への完全一致を要求しており、これは公式指標の局所的な lineage 基準とは異なります。

リンクと division の同時選択

通常リンクを先に固定してしまうと、正しい娘細胞が別の親に割り当てられ、後から有効な division を追加できなくなる可能性があります。そこで、どのノードを保持するか、どの通常リンクを使用するか、どの娘細胞ペアを division として選択するかを同時に決定します。

主な制約は以下のとおりです。

- 各細胞の親は高々1つです。
- 各細胞の出力イベント(通常リンクまたは division)は高々1つです。
- Division は両方の娘細胞をまとめて選択します。
- 分裂する親細胞は通常の入力リンクを持たなければならず、各娘細胞は通常の出力リンクを持たなければなりません。
- 娘細胞は直後の時刻境界で再び分裂することはできません。

最後の2つの制約は、このデータセットの時間分解能を反映したものです。また、ありえない division 同士が互いを支え合うことを防ぎ、LP 緩和を強化します。

目的関数は、期待 true positive、false positive、ノード数から計算されるコンペティション指標の代理(surrogate)です。現在の解の周りで線形化し、true positive に対する報酬と、false positive およびノードに対するコストを得ます。これらの係数を用いて各動画を最適化し、動画全体で期待カウントを集計し、最大3ラウンドまで係数を更新します。更新後の解は、代理目的関数が改善する場合にのみ採用します。

HiGHS を使用し、まず線形計画 (LP) 緩和を解きます。分数解の決定変数が残る場合は、division 変数をバイナリとした混合整数線形計画 (MILP) を解きます。時間制限に達した場合は実行可能解を保持します。最適化は予測確率を用いて行い、得られたグラフは公式のスコアリング実装で別途評価します。

7. 後処理

A4: ギャップの補完

一時的に見逃された細胞を回復するため、トラックの終点を後続トラックの始点に接続します。選択されたリンクから集団的な動きを推定して補正し、Hungarian 割り当てを用いて接続を選択します。

欠損フレームが1、2、3のギャップをこの順に処理します。g 個のフレームが欠損している場合、距離ゲートは $3\sqrt{(g+1)}$ μm です。元の終点座標間を線形補間してノードを挿入します。

A5: 短い連結成分の除去

ギャップ補完の後、ノード数が6未満の弱連結成分を除去します。欠損した検出が埋められると短い断片が長いトラックの一部になる可能性があるため、ギャップ補完を先に行います。

A6: 検出座標のアフィン精緻化

接続が正しくても、位置推定の揺らぎ(jitter)が GT 点とのマッチングに影響することがあります。そこで、グラフの接続を固定したまま座標を精緻化します。

連続するフレームの各ペアについて、通常リンクを用いて位置から変位を予測するアフィンモデルをフィッティングします。次に、二次最適化によって、予測された動きとの一貫性と、元の検出座標に近い位置に留まることとのバランスを取ります。リンクの重みは、キャリブレーションされた正解である条件付き確率です。

Division の親細胞と娘細胞、ギャップの終点、補間ノードは固定します。精緻化した位置は整数のボクセル座標に丸めます。ボリュームの外に出る変更や、フレーム内で座標の衝突を生じる変更は棄却します。ノード数と edge は変化しません。

A7: 補間座標のアフィン精緻化

次に、ギャップに挿入したノードを、座標精緻化前の通常リンクからフィッティングした同じアフィン運動場を用いて精緻化します。一方の終点から始めて運動場を通じて位置を伝播させ、最終的な終点のずれをギャップ全体に線形に配分することで、両方の終点を保持します。

このステップで動くのは補間ノードのみで、検出ノード、ギャップの終点、グラフの接続は固定されたままです。ここでも座標を丸め、範囲外の位置と衝突は棄却します。サブミッションでは A6 と A7 の両方を使用しています。

8. サブミッションと結果

検出器と division モデルへの TensorRT の適用、mixed precision、2つの GPU での並列実行により推論を高速化しました。Matcher は必要な中間特徴量のみを計算し、flow 場はマッチングと division 用画像の位置合わせで再利用します。Division モデルでも、重なり合う時間窓の間で元フレームのエンコーダ特徴量を再利用します。これらの特徴量は、3枚の元フレームを入力とするモデルと、parent モデルの元フレーム側のブランチで再利用されます。後者はさらに位置合わせ画像も処理します。

最終ソリューションは CV スコア 0.977801 (0.540107)、Public LB スコア 0.977 (0.52)、Private LB スコア 0.967 (0.47) を達成しました。括弧内の値は Division Jaccard を示します。

表1. 完全なパイプラインの構築。 A0 から始めて、ステージを段階的に追加または置き換えて最終構成に到達します。すべての行は、199本の学習動画すべてに対する同じ OOF 検出から開始し、動画、fold、スコアリング実装は固定しています。最適化と後処理によって、保持されるノードが変わったり、補間ノードが追加されたり、座標が精緻化されたりすることがあります。

ID	構成 / 変更	Adjusted edge Jaccard	Division Jaccard	Total score
A0	検出 + drift 補正付き Hungarian 割り当て	0.890211	0.000000	0.890211
A1	+ 動き補正のための Dense flow	0.901919	0.000000	0.901919
A2	+ Matcher による候補フィルタリングと対応スコア	0.901953	0.000000	0.901953
A3	+ Division モデルとキャリブレーション。Hungarian 割り当てをリンク/division の同時最適化で置き換え	0.911017	0.534759	0.964493
A4	+ ギャップ補完	0.916111	0.534759	0.969587
A5	+ ノード数6未満の連結成分の除去	0.918105	0.531915	0.971297
A6	+ 検出座標のアフィン精緻化	0.923141	0.540107	0.977151
A7	+ 補間座標のアフィン精緻化: 完全なパイプライン	0.923790	0.540107	0.977801

Total score は `Adjusted edge Jaccard + 0.1 × Division Jaccard` です。A0–A2 は分岐を生成しないため、division スコアはゼロです。通常リンクのキャリブレーションでも parent、pre、post の特徴量を使用するため、A3 では division のモデリングとグラフ最適化を同時に導入しています。

Hungarian のコストは、A0 と A1 では補正後の距離 d、A2 では `d + 12(1 − p)` です(p はマッチング確率)。A0–A2 は孤立したものも含めてすべての検出を保持します。A2 から A3 への移行では、キャリブレーション、division のモデリング、ノード選択、同時最適化に加えて、候補ゲートも 7 µm から最終的な 12 µm の flow 距離ゲートに変更されています。

Hungarian 割り当てに flow とマッチングスコアを加えた効果は控えめでした。より大きな改善は、division モデル、キャリブレーション、同時最適化を導入した A3 で得られました。Flow 補正後の距離とマッチングスコアは下流のキャリブレーションモデルへの証拠にもなり、それが LP による接続の選択を導きます。したがって、A1 と A2 単独での改善は、パイプライン内でのそれらの役割全体を表しているわけではありません。私たちは、A3 での改善をこれらの特徴量、division の証拠、グラフ制約を組み合わせた効果であると解釈しています。ギャップ補完、連結成分の除去、座標の精緻化によって、最終スコアはさらに改善しました。