biohub-cell-tracking-during-development

4位 Solution

Rank	4
Team	Barry
Author	BarryZhou
Topic ID	744673
Version	Japanese Translation

Source: https://www.kaggle.com/competitions/biohub-cell-tracking-during-development/discussion/744673
Retrieved with Kaggle CLI on 2026-10-04.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

Public 0.969 / Private 0.962。 Notebook: kaggle.com/code/songqizhou/biohub-4th-place-solution

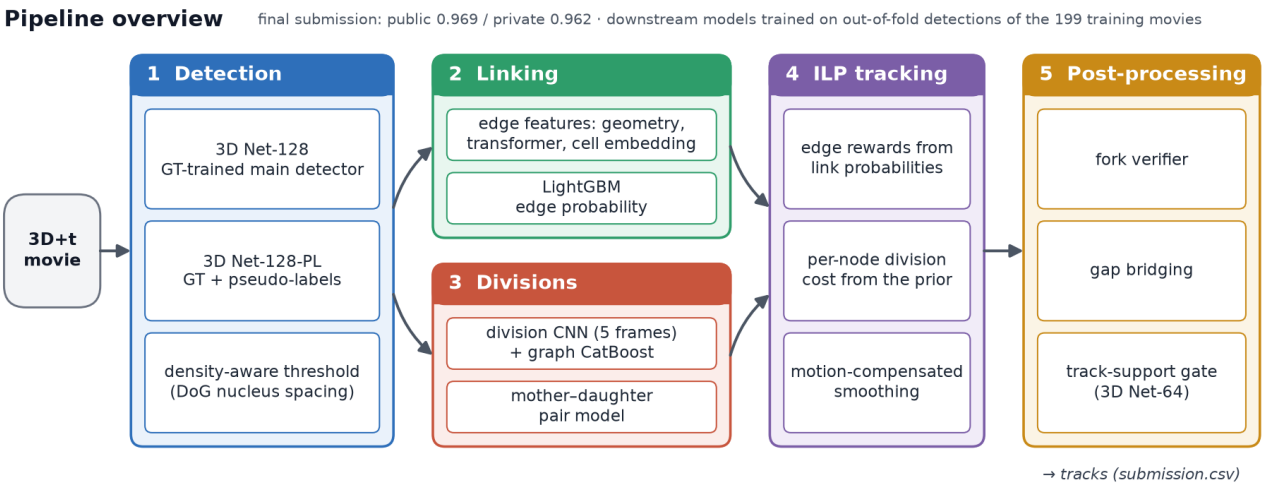
挑戦的でよく設計されたコンペティションを開催してくださった主催者の皆様、そしてフォーラムでノートブック、サポートパック、アイデアを共有してくださったすべての方に心より感謝いたします。

概要

私たちのトラッカーは5つのステージで構成されています。検出、リンク、division のための学習済みモデル、それらを統合するグローバルな ILP、そしてルールベースの後処理です。

ステージ	内容	セクション
1. 検出	3D Net が核を検出し、pseudo-label モデルがそれを精緻化する。疎な動画にはより厳しい閾値を適用する	2
2. リンク	すべての候補リンクに学習済みの確率を付与する	3
3. Division	すべてのノードに学習済みの division スコア `s` を付与する	4
4. ILP	トラックを解く。各ノードは自身の division コスト `6 − 16·s` を支払う(疎な動画ではベース 5)	4, 5
5. 後処理	fork verifier、平滑化、ギャップの橋渡し、疎な動画向けの track-support gate	4, 5

ILP におけるノードごとの division コストが、単一の要素としては最大の改善(+0.035)でした。



私たちのアプローチ: 生物学をモデル化する

私たちの計算資源は控えめでした。パイプライン内のネットワークはすべて小さく(最大の 3D Net でも 18 M パラメータ)、証拠を統合するモデル(edge モデル、division の graph モデルと pair モデル、fork verifier)はすべて CPU 上の勾配ブースティング木です。そのため、改善の大部分は生物学と評価指標を注意深く観察し、それぞれの観察を小さく的を絞ったモデルに落とし込むことから得られました。

観察	構築したもの	セクション
細胞の約1%しかアノテーションされておらず、実際の細胞や実際の分裂の大半にはラベルがない	アノテーション済み、背景、未アノテーションのボクセルに別々の tier を設けた loss。division ラベルはアノテーション済みトラックからのみ取得	2.1, 4.2
接触している2つの核は1つの明るい塊を形成するが、その中心は別々である	各ボクセルからそれ自身の中心を指すベクトル場	2.1
核のサイズと間隔は胚によって大きく異なる	動画ごとに検出閾値を設定する DoG 密度ルーター	2.3
母細胞は丸くなって明るくなり、クロマチンが分かれ、2つのコンパクトな娘細胞が現れる	これらの手がかりから構築した division スコアを、ILP のノードごとの division コストとして使用	4
本物の娘細胞は数フレームにわたって離れ続ける	生画像上で両方の娘細胞を追跡する fork verifier	4.3
組織全体がフレーム間でドリフトする	トラックの動き補正付き平滑化	5.2
より多くの(pseudo-)label で学習したモデルはより多くの細胞を見つけるが、新しい胚では存在しない細胞も作り出してしまう	独立したモデルが同意する箇所でのみ、そのトラックを保持する	2.2, 5.3

1. データ、評価指標、検証

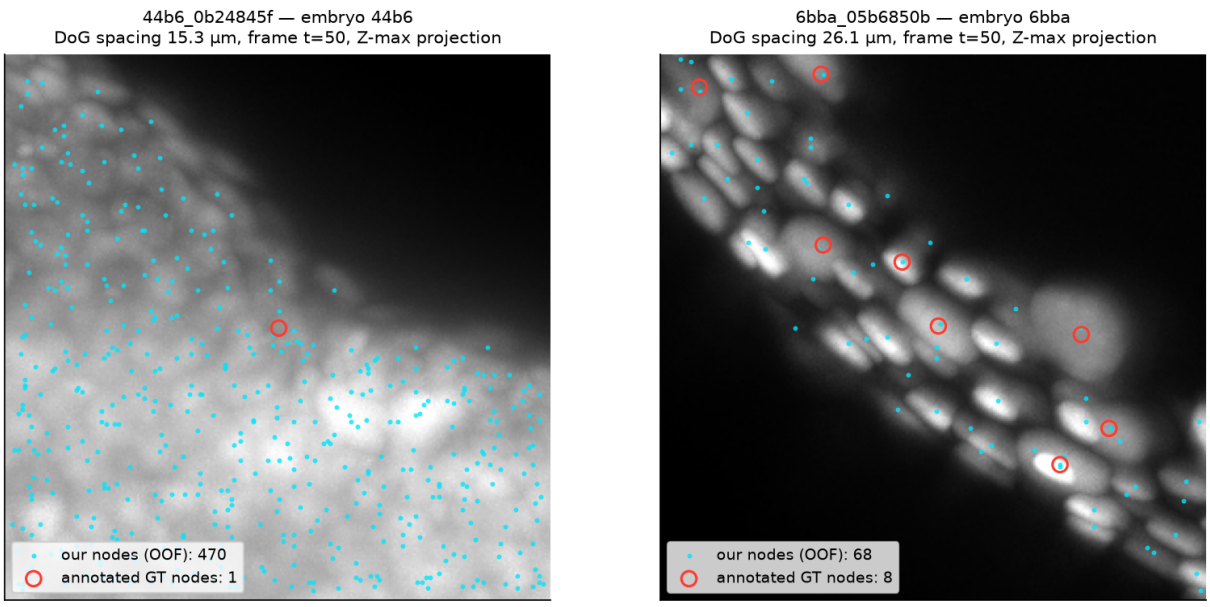
データ。

- 2つの胚からの199本の学習動画(71本と128本)。
- 各動画は 64 × 256 × 256 ボクセル、1.625 × 0.406 × 0.406 µm のフレーム100枚からなります。
- 各動画でアノテーションされている lineage はわずかで、細胞の約1%です。学習セット全体でも **アノテーションされた分裂は151件** しかありません。
- 一方の胚は小さな核で密(DoG による核の間隔は約 13–19 µm)、もう一方は大部分が大きな核で疎(約 17–31 µm)です。

評価指標。 `adjusted edge Jaccard + 0.1 · division Jaccard`。

- 予測された edge は、アノテーションされたノードに接している場合にのみ false positive となるため、アノテーションのない細胞の大半は「無料」です。
- ノード数による調整は、推定細胞数より多くのノードを予測することにペナルティを課すため、ノード数は依然として重要です。

Dense vs sparse movies: only a few lineages per movie are annotated (red); the metric counts an FP edge only if it touches an annotated node



検証のルール。

1. すべてを公式の評価器でスコアリングする。初期に使っていた独自のノードレベルの指標では、私たちの結論のうち2つが逆転していました。
2. すべてを out-of-fold で行う。199本すべての動画の検出は各検出器の5-fold のコピーから得たもので、下流のすべてのモデルはこれらの out-of-fold 検出で学習しています。実際にデプロイする検出器は199本すべての動画で学習しています。
3. 検出器の変更は、ランダムな fold だけでなく、胚をまたいで(一方の胚で学習し、もう一方でテストして)確認する。同じ胚での検証は、既に見た胚によりよくフィットする変更を過大評価していました。
4. 一度に1つのコンポーネントだけを変更し、デプロイ済みのチェーン自身の出力と比較する。

2. 検出

2.1 3D Net

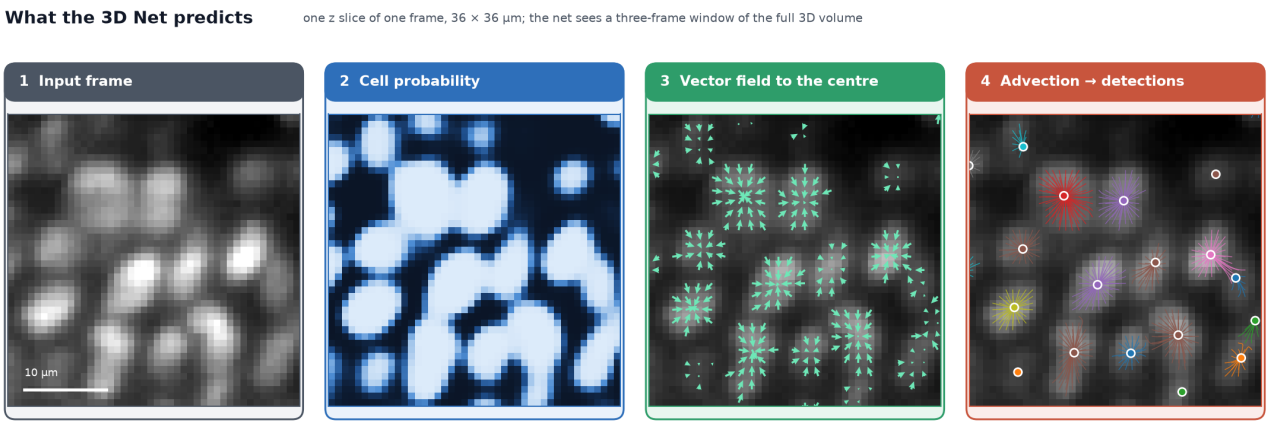
アイデア。 各ボクセルについて、細胞である確率と、その核の中心を指す単位ベクトル(Cellpose の flow のアイデア)を予測し、そのベクトルを辿って核を見つけます。

ネットワーク。 文献にある、temporal attention を持つ dual-encoder 3D U-Net を改良したものです。一方のエンコーダは現在のフレームを、もう一方は次のフレームと前のフレームの差分を見ます。隣接フレームを加えることは明らかに有効で、この入力を除くと胚をまたいだ検証で検出スコアが 0.93 から 0.73 に低下しました。一方、5 フレームに広げたウィンドウではそれ以上の改善はありませんでした。

デコード: 私たちの選択。

- **厳しい seed。** 確率が 0.97 を超えるボクセルのみを辿ります(疎な動画では 0.99、セクション 2.3)。これにより、暗い背景が核になることはめったにありません。
- **短い、ビン分けした収束。** Seed は 0.5 µm のステップで40ステップ移動します。終点が同じ 1 µm のセルに入った seed が1つの核を形成し、重複は NMS に任せます。

- **確率でランク付けした適応的な NMS。** 核は最大確率でランク付けし、NMS の半径は動画ごとに設定します。通常は 4 µm、最近傍距離の中央値が 10 µm 以上の場合(大きな核)は 7 µm です。



Loss: 私たちの選択。 ベクトル場には L1 loss を、確率には3つの tier を持つ重み付き BCE を使います。3つの tier とは、アノテーションされた核、確信度の高い背景、そしてそれ以外のすべて(背景方向へのごく弱い押し込みのみ)です。重要なのは tier の作り方です。

- **Tier の正規化。** 各 tier の重みをそのボクセル数で割ることで、重みが各 tier 全体としての寄与度を決めるようにします。ボクセルごとの重みでは、数少ないアノテーション済みボクセルが loss の 0.5% 未満しか担わず、確率ヘッドがゼロ方向に崩壊してしまいました。
- **ベクトルを教師あり学習する場所。** 各アノテーションは、自身に最も近く、5.5 µm 以内で、かつフレーム内で明るさ上位5%に入るボクセルを担当し、加えて常に保持される 2 µm のコアを持ちます。この上限により、アノテーションのない隣接細胞がその領域に引き込まれるのを防ぎます。
- **局所的な背景。** 3.5 µm 以内の局所最大値の 0.4 倍より暗いボクセルのみを確信度の高い背景とします。これにより、密なフレームにおける実際の細胞の縁が背景としてラベル付けされることを防ぎます。

3つの 3D Net を学習しました。

モデル	学習データ	役割
3D Net-128 (XY を 2 でプーリング)	ground truth	メインの検出器
3D Net-128-PL	ground truth + pseudo-label	ノードを精緻化 (2.2)
3D Net-64 (XY を 4 でプーリング)	ground truth	疎な動画での独立したチェック (5.3)

学習。 デプロイするモデルは、199本すべての動画で学習率 3e-4 で学習しています。各検出器は複数回学習する(out-of-fold 検出用の5 fold に加えて最終モデル)ため、限られた GPU 計算資源の中ではどの実行も短くしました。128 モデルは10エポックで、**エポック 7–10 の重みの平均** を使用し、64 モデルはエポックあたり約4倍安価なため50エポックとしました。10エポックが最適だと主張するつもりはありません。多くのチームは数百エポック学習しています。しかし私たちの実行では、未知の胚に対する recall は学習の早い段階でピークに達したため、短期間学習した検出器は recall 寄りになり、実際の細胞数よりやや多く(約9%多く)ノードを予測します。パイプラインの残りの多くの部分は、これらの余分なノードを下流で除去するためのものです。厳しい seed 閾値、pseudo-label によるチェック (2.2)、短いトラックのフィルタを伴う ILP、そして track-support gate (5.3) です。その意味で、これらのステップのいくつかは短い学習を補っています。より多くの GPU 計算資源があれば、その労力はむしろ検出器自体に注ぎたいところで、そのほうがよりエレガントな道筋でしょう。

解像度。 同じ単純なリンカーを用いてランダムな1つの fold で簡易的に確認したところ、128 × 128 の XY グリッドは 0.856、64 × 64 のグリッドは 0.853 でした。64 では、密な組織で混み合った核が統合されてしまいます。しかし疎な動画では、ローカルでは 64 グリッドが最良でした。ノード数が変わってしまう動画ごとの検出器の切り替えではなく、そこでは 3D Net-64 を独立したチェックとして使用しています (5.3)。フル解像度 (256 × 256) は 128 の4.4倍の計算量がかかり、より小さなバッチが必要です。1つの fold で10エポック、一度しか学習できず、その1回の短い実行では明確な改善は見られませんでした。収束まで学習させた場合に効果があるかどうかは未解決のままです。

Heatmap 検出器は不使用。 公開されている heatmap U-Net は収束までに数百エポックが必要で、私たちの計算資源を超えていたため、独自の fold で学習することはできませんでした。その公開重みは199本すべての学習動画で学習されていたため、それを含めたアンサンブルを交差検証する手段がありませんでした。信頼できるローカルスコアがない以上、私たちにとってはリスクが期待される改善を上回ると判断し、採用しませんでした。

3D Net の test-time augmentation は不使用。 4ビューまたは8ビューの TTA は、すべての検証実行のコストを倍増させます。私たちのチェーンで簡易的にテストしたところ信頼できる改善は得られなかった(ローカルではノイズの範囲内、リーダーボードでは低下)ため、採用しませんでした。他のチームは TTA による改善を報告しているので、これはパイプラインに依存するのかもしれません。

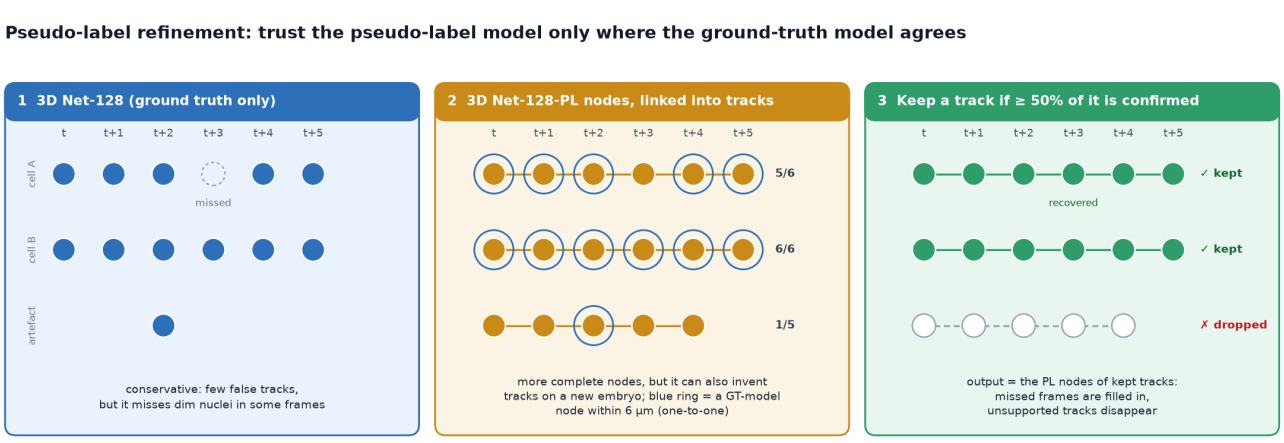
2.2 Pseudo-label による精緻化

問題。 Ground truth のみで学習したモデルは保守的です。偽のトラックは少ないものの、一部のフレームで暗い核を見逃します。Pseudo-label で学習したモデルはより多くの核を見つけますが、単独で使うと新しい胚で存在しないトラックも作り出してしまいます(リーダーボードで −0.003 〜 −0.004)。

Pseudo-label。 199本すべての動画の out-of-fold 検出に加えて、ラベルのない外部の Zebrahub の胚1つに対する検出です。3D Net-128-PL は ground truth とこれらの pseudo-label で学習しています。

手法。 Pseudo-label モデルのノードを使いますが、ground truth モデルが同意するトラックに限ります。

1. 動画に対して両方のモデルを実行します。
2. Pseudo-label のノードは、同じフレーム内で 6 µm 以内にある ground truth モデルのノードと1対1でマッチした場合に **確認済み** とします。
3. Pseudo-label のノードをフレーム間でリンクしてトラックにします(greedy マッチング、7 µm ゲート)。
4. **ノードの少なくとも50%が確認済み** のトラックのみを保持します。出力は保持されたトラックの pseudo-label ノードです。



効果。 Ground truth モデルが核を見逃したフレームが補われ、ground truth モデルが一度も見ていないトラックは消えます。アンサンブルではなく追加の学習1回分のコストで、リーダーボードで +0.004 となりました。

2.3 密度を考慮した閾値 (DoG ルーター)

問題。 疎な動画では、通常の閾値だと大きな核が余分な seed を生み出します。

手法。

1. 単純なルールベースの DoG blob トラッカーで核を数え、各動画に核の間隔を割り当てます。
2. 間隔が 19.7 µm 以上の動画は、より厳しい seed 閾値(0.97 の代わりに 0.99)で再検出します。

なぜ DoG か。 最初のバージョンでは、判断に検出器自身のノード数を使っていました。しかし検出器のノード数は未知の胚ではずれていくものであり、ルーターはそれが振り分けるモデルに依存すべきではありません。検出器に依存しない DoG ルーターは、ローカル検証に変化がないまま public で +0.002 の改善となりました。

3. リンク

3.1 候補リンク

フレーム t の各ノードについて、t+1 で 10 µm 以内にあるすべてのノードと、最も近い5つの後続ノードを候補とします。さらに、t+1 の各ノードは最も近い3つの先行ノードとリンクされます。

3.2 各リンクの証拠

- **幾何情報 (26 特徴量)。** 変位、両方向の競合候補間での距離の順位とギャップ、最近傍距離、検出の信頼度とクラスタサイズ、最初の greedy リンクで得たノードの速度に対する残差、局所的な組織の flow(確信度の高い近隣リンクの変位の中央値)に対する残差、そしてノードが過去/未来へ続いているかどうか。
- **Transformer 確率。** コンペティションのベースラインのリンカーアーキテクチャ(temporal U-Net エンコーダと、連続する2フレームのすべてのノードペアをスコアリングする node transformer)を、199本すべての動画で再学習しました。両方向で実行し、softmax で正規化した2つの確率とその重み付き調和平均を特徴量とします。
- **Cell embedding。** 小さな 3D CNN が各ノード周辺の 16 × 32 × 32 の生パッチをエンコードします。t と t+1 における同じアノテーション済み細胞が、競合候補よりも近くなるように InfoNCE で学習します。リンクの両端の cosine similarity を特徴量とします。

3.3 Edge モデル

上記すべて(47 特徴量)を用いた LightGBM を out-of-fold 検出で学習し、下流のあらゆる箇所で使用するリンク確率 `p` を出力します。

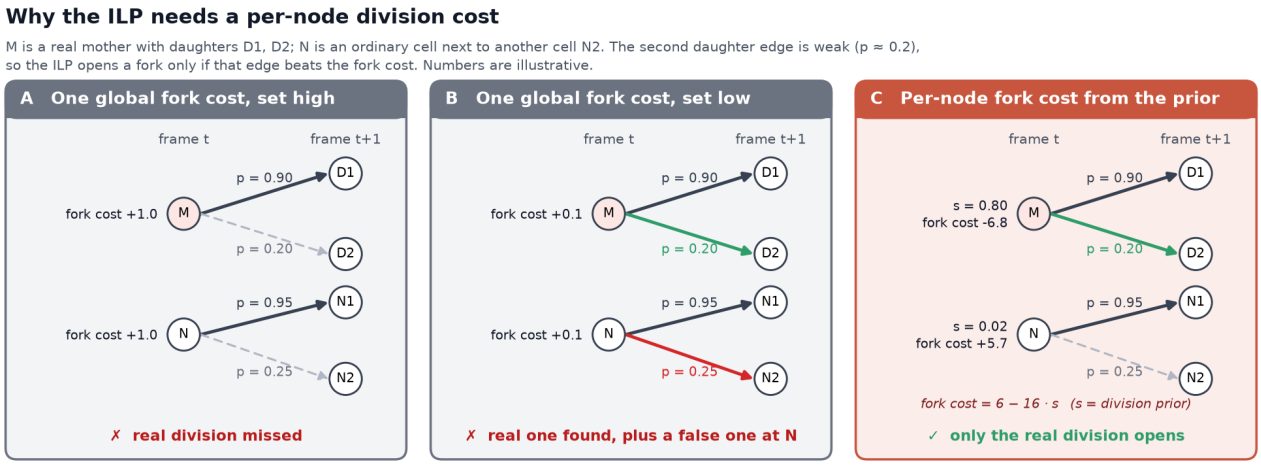
教訓。 Out-of-fold スタッキングは、全データで学習したモデルからの証拠を過小評価します。ローカルでは、より少ないデータで学習した fold 版の transformer しか使えず、その特徴量はほとんど価値がないように見えました。リーダーボードでは、199本すべての動画で学習したバージョンが +0.005 の価値を持っていました。

4. Division

4.1 なぜノードごとの division コストなのか

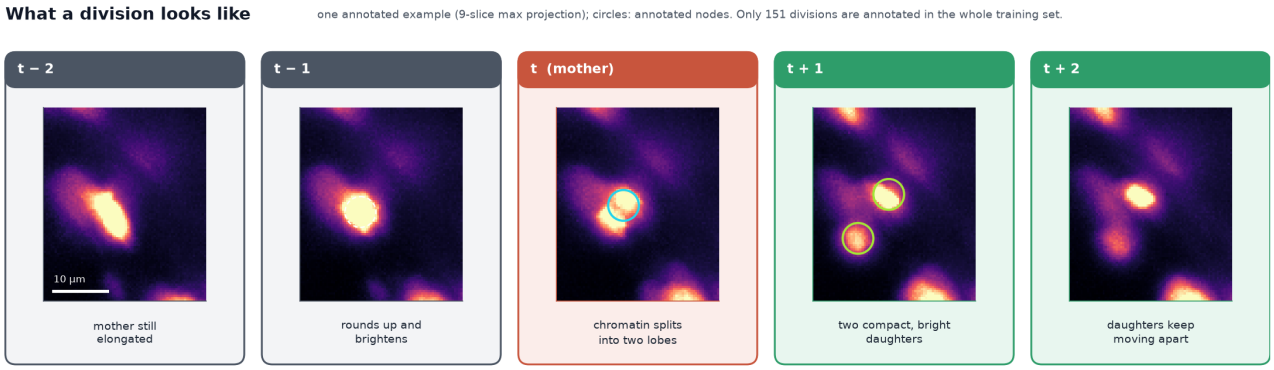
ILP において division とは、1つのノードが2本の出力 edge を持つことを意味します。2つ目の娘細胞の edge は通常弱いものです。その娘細胞はより遠くにあり、母細胞とは見た目も異なるからです。グローバルな division コストを1つだけ使うと、ソルバーは fork を一切開かないか、2つの細胞が近接している箇所で誤った fork を開いてしまいます。

そこで、**各ノードに独自の division コスト** `cost = 6 − 16·s`(疎な動画では `5 − 16·s`)を与えます。ここで `s` は、そのノードが分裂する母細胞である学習済みの確率です。Fork は証拠が支持する箇所でのみ開かれます。



4.2 Division スコア `s`

分裂はまれで、とらえにくいものです。母細胞は丸くなって明るくなり、クロマチンが分かれ、コンパクトで明るい2つの娘細胞が現れ、数フレームにわたって離れ続けます。



ラベル。 アノテーションされた子を2つ持つノードを正例、アノテーションされた子を1つ持つノードを負例とします。実際の分裂の大半はアノテーションされていないため、アノテーションのないノードは負例として一切使いません。同じ理由で、hard-negative mining は大きく悪化させました。「最も難しい負例」の大半は、実際にはアノテーションされていない本物の分裂だったのです。

3つのスコアラー。

スコアラー	入力	モデル
Division CNN	ノード周辺の 9 × 33 × 33 ボクセルの5フレームクロップ (t−2 … t+2)	6つの CNN(3 seed、copy-paste augmentation あり/なし)、4 flip
Graph モデル	候補グラフにおけるノードの53特徴量: 最良のリンクとそれがどれだけ競合しているか、候補娘細胞の位置(距離、反対側にあるか、対称性)、それらが継続しているか、動き、局所密度、CNN スコア	CatBoost
Pair モデル	174 の画像特徴量を持つ候補 (母細胞, 娘細胞, 娘細胞) トリプレットに加え、両方の娘細胞 edge の graph、embedding、リンクの特徴量	LightGBM + CatBoost

Pair モデルの仕組みは以下のとおりです。

1. 各ノードについて、次のフレームから候補の娘細胞ペアを取得します。条件は、両方が 13.5 µm 以内、姉妹細胞間が 4.5–17 µm 離れている、母細胞がそれらの中点付近にある、娘細胞が反対側にある、です。
2. 174 の画像特徴量は生物学に従っています。母細胞の直近7フレームにわたる明るさ、テクスチャ、コンパクトさ、サイズ、分裂時点での母細胞の位置における輝度低下、両方の娘細胞の最初の3フレーム、姉妹細胞間の距離とその増加、分裂軸に沿った移動です。
3. ノードのスコアは、その最良のペアのスコアです。

最終スコアは `s = max(pair model, graph model)` で、graph モデル単独に比べて +0.003 の改善となりました。

4.3 ILP 内および ILP 後の division

- **緩和した受け入れ。** リンクは `p > 0.3 − 0.5·s` の場合に ILP グラフに入ります。これにより、母細胞らしいノードは弱い2本目のリンクを保持できます。
- **2つ目の娘細胞の救済。** `s ≥ 0.2` のノードについて、そのノードの最良リンクでないリンクには `max(p, transformer probability)` を用います。Transformer は2つ目の娘細胞についてより確信度が高いことが多いためです。
- **Fork verifier。** ILP の後、すべての fork の両方の娘細胞を、fork の3フレーム前から5フレーム後まで生画像上で追跡します(動き補正付きの DoG ピーク探索)。157 の特徴量で、時間経過に伴う娘細胞間の距離、ピークの質、変位を記述します。CatBoost モデルは、スコアが 0.25 未満の場合に弱い方の娘細胞 edge を除去します。ただし、2つの娘細胞が fork 軸に沿って明確に離れていく場合は除去しません。+0.002、閾値のチューニングでさらに +0.003 の改善でした。
- **Division のベースコスト。** 最適値は 5–6 付近の広い範囲にあり、密な動画では 6、疎な動画では 5 を使用しています。

効果。 Division スコアを有効にすると、リーダーボードのスコアは **0.913 から 0.948 に(public と private の両方で +0.035)** 向上しました。

5. トラッキングと後処理

5.1 ILP

SCIP ソルバーを用いた tracksdata を、1プロセスにつき1動画で使用します。

- edge 報酬 `p`
- 出現コスト 0.5、消失コスト 3.2
- ノードごとの division コスト `6 − 16·s`、疎な動画では `5 − 16·s` (セクション 4)

5.2 トラックのクリーニング

- **短いトラックのフィルタ。** 孤立した単一ノードを除去します。
- **動き補正付き平滑化。** フレームごとの組織の並進を、確信度の高い非分裂リンクから推定します。その並進を取り除いた後、各トラックに沿って局所的な直線フィッティング(±3 フレーム)で座標を平滑化します。
- **ギャップの橋渡し。** t で終わるトラックと、近くで t+2 または t+3 に始まるトラックを、線形補間したノードを介して結合します(+0.002)。

5.3 Track-support gate(疎な動画)

問題。 疎な動画では、残っている主な誤りは過剰なカウントです。つまり、実際の核ではない長く暗いトラックです。

手法。 2.2 と同じ原理を、今度は2つの独立した検出器、3D Net-64 と高感度の DoG 検出器を用いて最終トラックに適用します。

1. トラックを division を含まないセグメントに分割します。
2. 同じフレーム内の近くに独立した検出がある場合、そのノードを確認済みとします。
3. 確認済みのノードが少なすぎるセグメントを除去します。

動画の間隔	ノードが確認済みとなる条件	確認済みの割合が次の値未満ならセグメントを除去
19.7–25 µm	4 µm 以内に DoG の検出がある **または** 5 µm 以内に 3D Net-64 のノードがある	40%
> 25 µm	5 µm 以内に DoG の検出がある **かつ** 5 µm 以内に 3D Net-64 のノードがある	20%

密な動画には手を加えません。

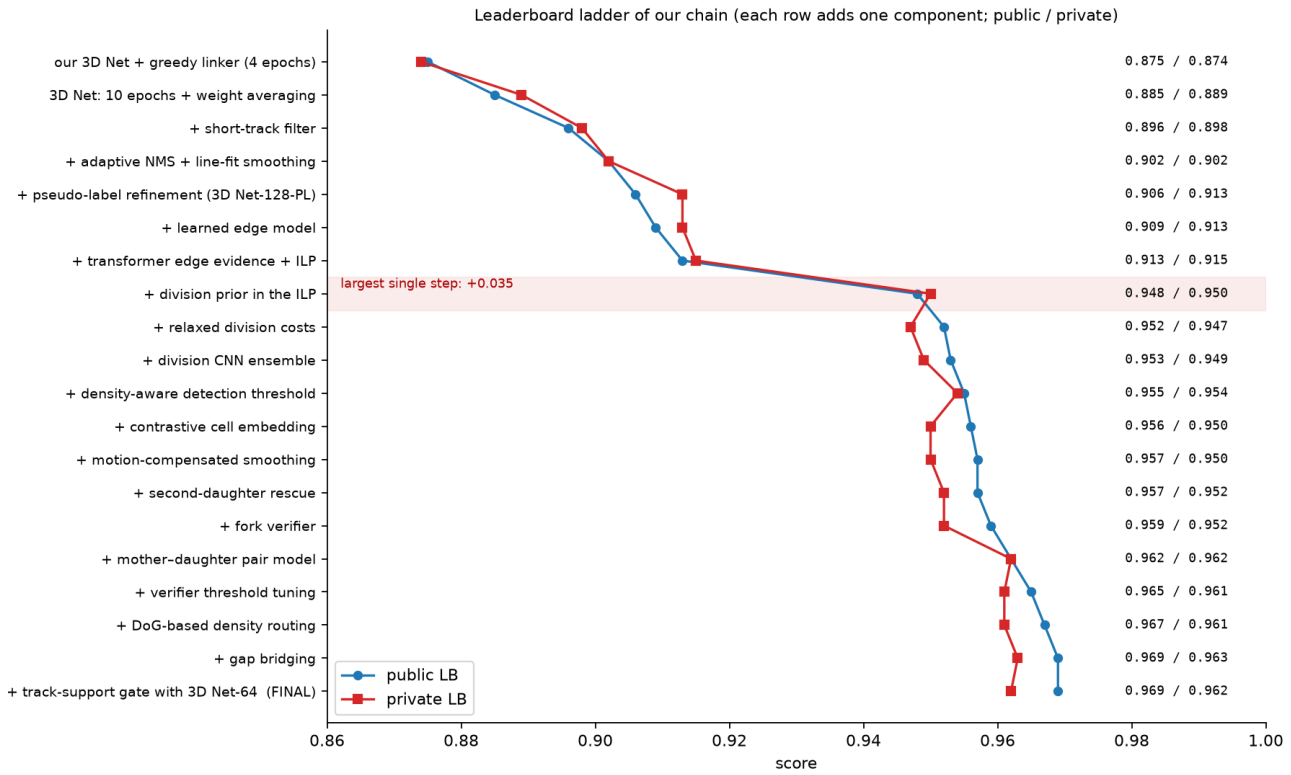
効果。 ローカル検証ではプラス、public では中立(0.969)だったため、最終サブミッションに採用しました。Private では 0.001 の損失となり、より緩い設定では 0.001 の改善となっていました。ノード数を変える他の変更と同様に、パイプラインの他の部分に比べて新しい胚への転移が予測しにくいものでした。

5.4 モデルサイズとコスト

モデル	サイズ	入力
3D Net-128 / 3D Net-128-PL / 3D Net-64	それぞれ 18 M パラメータ (10 / 10 / 50 エポック)	ボリューム全体の3フレームウィンドウ
Edge transformer	2.1 M パラメータ	ダウンサンプリングした連続する2フレーム
Division CNN	1.4 M パラメータ × 6	9 × 33 × 33 ボクセルの5フレームパッチ
Cell embedding	0.24 M パラメータ	16 × 32 × 32 パッチ
Edge モデル、division の graph モデルと pair モデル、fork verifier	勾配ブースティング木 (CPU)	テーブル特徴量

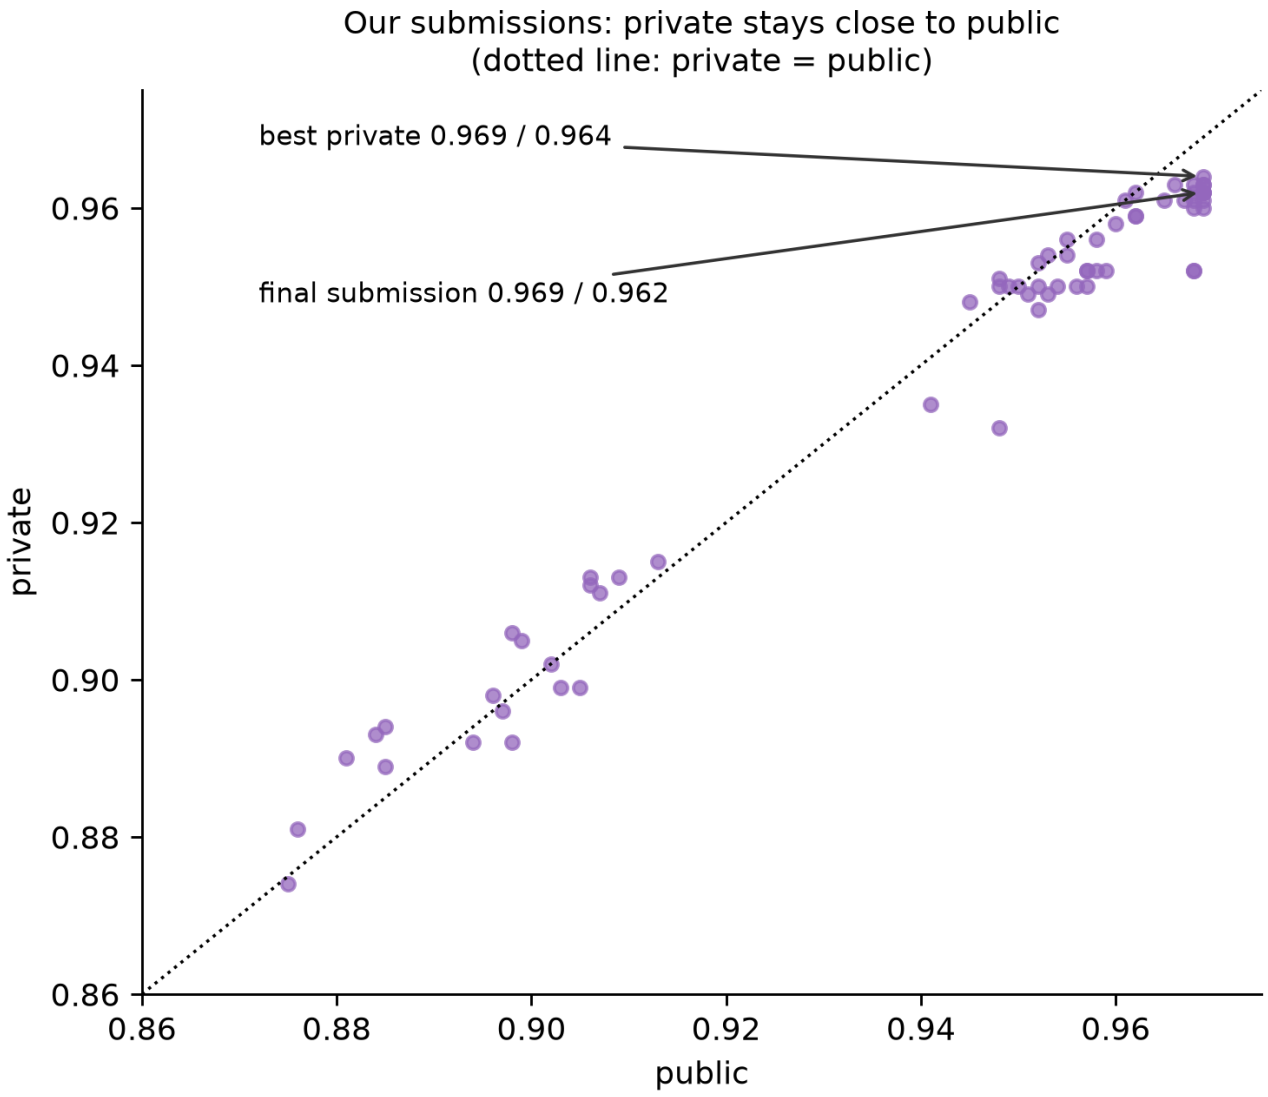
チェーン全体は 2 × T4 の1つの Kaggle notebook で動作し、表示されている4本の動画で約31分かかります。最も重い部分は、division CNN(ノード数に応じて両方の GPU に分割)、transformer によるリンクのスコアリング、そして ILP です。

6. 結果



- 各行は1つのコンポーネントを追加したもので、どの行も1回のサブミッションに対応します。
- 検出器の改善 (0.875 → 0.906) と division スコア (0.913 → 0.948) が2つの大きなブロックです。リンクと後処理が残りを上積みしています。
- 最終サブミッションのスコアは **0.969 / 0.962** でした。Private での最高スコアは **0.969 / 0.964** でした。これは同じ track-support gate のより緩い設定によるもので、public では同点だったため選択しませんでした。

私たちのチェーンのすべてのサブミッションを通じて、private は public に近い値を保っていました。



7. うまくいかなかったこと

アイデア	リーダーボードへの影響
Pseudo-label の 3D Net をそのまま検出器として使用	−0.003 〜 −0.004
リンクの幾何情報を計算する前にフレームを位置合わせ	−0.003
DoG のみの support gate(3D Net-64 なし)	public −0.001、private −0.011
すべてのネットワークに TensorRT FP16 を適用	42% 高速化、−0.001。fp32 を維持
Division モデルでの hard-negative mining、ILP が落としたノードの再受け入れ、座標への一定オフセット	ローカル検証でマイナス

8. 得られた教訓

1. **まず生物学を見る。** 最大の改善は、単純な観察(分裂がどう見えるか、核が密度に応じてどうスケールするか、組織がどうドリフトするか)を小さく的を絞ったモデルに落とし込むことから得られました。
2. **テストセットの違い方に合わせて検証する。** 新しい胚が対象であることから、検出器には胚をまたいだ分割を、下流のすべてには out-of-fold スタッキングを用いました。
3. **Division 項は戦う価値がある。** ILP 内での学習済みのノードごとの division コストが単一要素として最大の改善であり、それはアノテーション済みトラックから厳密に取得したラベルでのみ機能します。
4. **2つ目のモデルは置き換えではなくチェックとして使う。** Pseudo-label による精緻化も track-support gate も、独立したモデルが同意する場合にのみトラックを保持します。
5. **出力するノード数を変える変更には注意する。** それらはローカル検証からリーダーボードへの転移が最も悪く、特に疎な動画で顕著でした(5.3 の track-support gate とセクション 7)。