biohub-cell-tracking-during-development

5位：3D U-Net + Transformer リンカー + 多段 ILP トラッキング

Rank	5
Team	Tang
Author	Tang
Topic ID	744549
Version	Japanese Translation

Source: https://www.kaggle.com/competitions/biohub-cell-tracking-during-development/discussion/744549
Retrieved with Kaggle CLI on 2026-10-04.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

概要

パイプラインは3つの部分からなります：

- **検出器（Detector）**：細胞を見つける 3D U-Net。
- **リンカー（Linker）**：2つのフレーム間で細胞をリンクする transformer。
- **トラッキング（Tracking）**：トラックを構築する ILP。

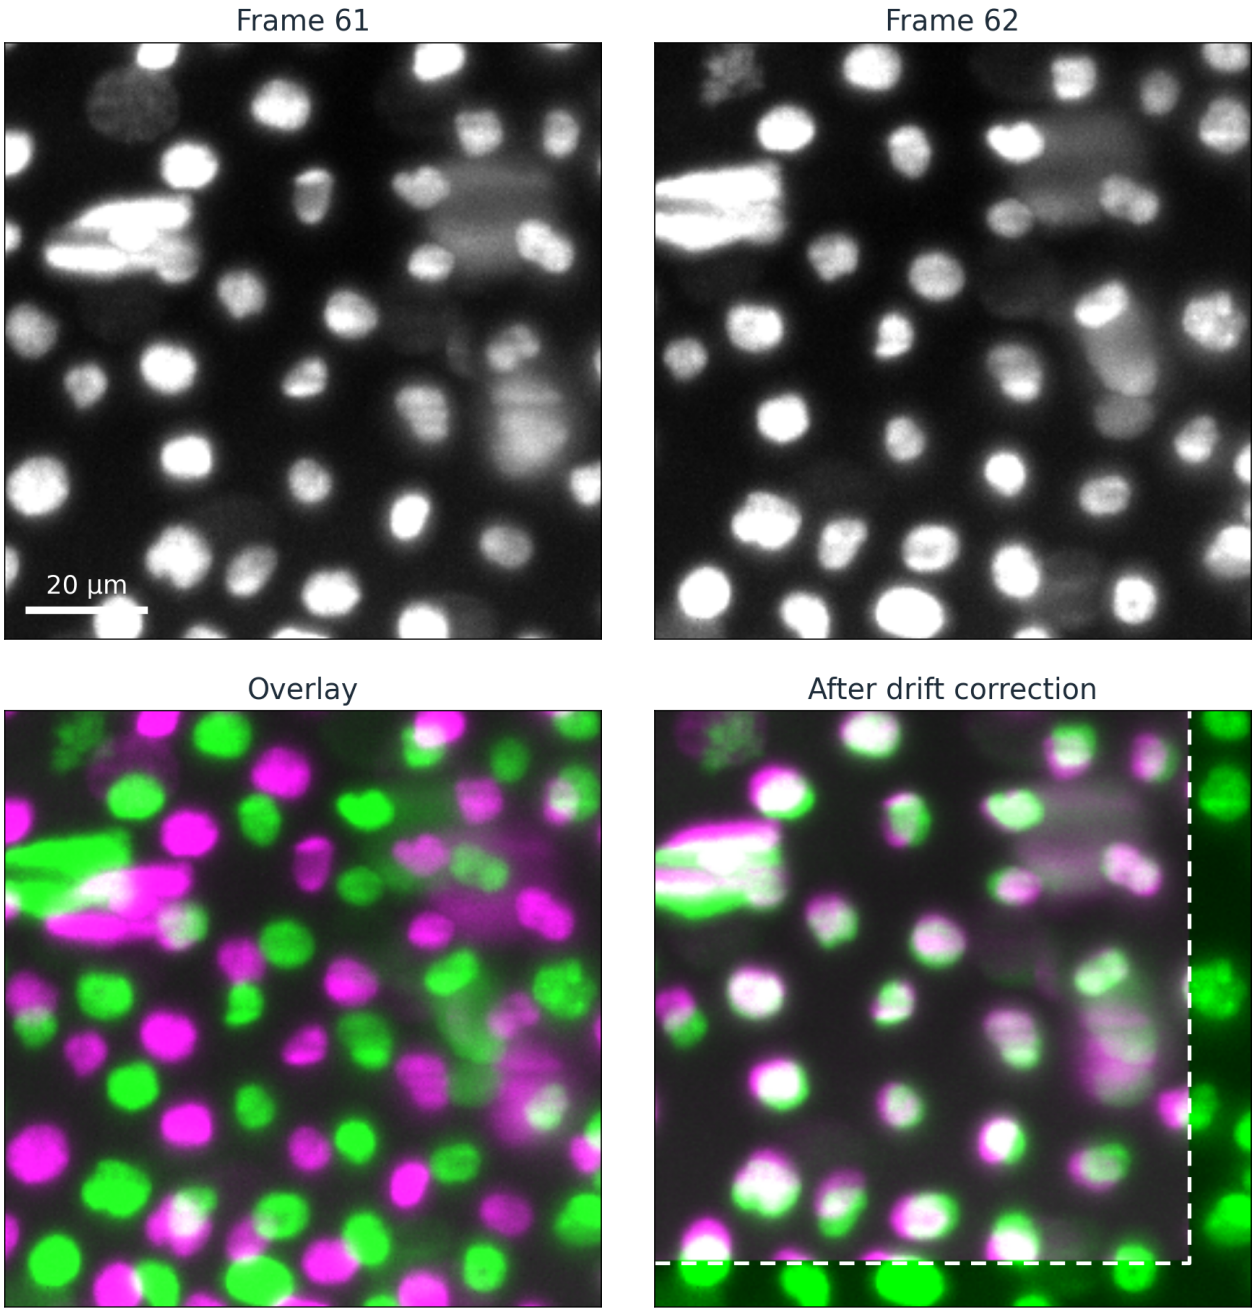
検出器とリンカーは、TTA 付きの 5-fold アンサンブルとして使います。5つのモデルと8つの TTA view の出力を平均します。

Validation の設計

クリップ単位の 5-fold CV で、クリップの種類（44b6 または 6bba）とクリップごとの division 数で層化しています。

学習データには2種類の問題のあるフレームがあります：

- **重複フレーム（Duplicated frames）**：あるフレームが次のフレームと完全に同一。
- **ドリフトフレーム（Drift frames）**：図のように、2つのフレーム間で画像全体がジャンプする。



magenta: frame 61　green: frame 62

2つのフレーム間のドリフト。14 µm 戻すようにシフトすると、細胞が一致します。

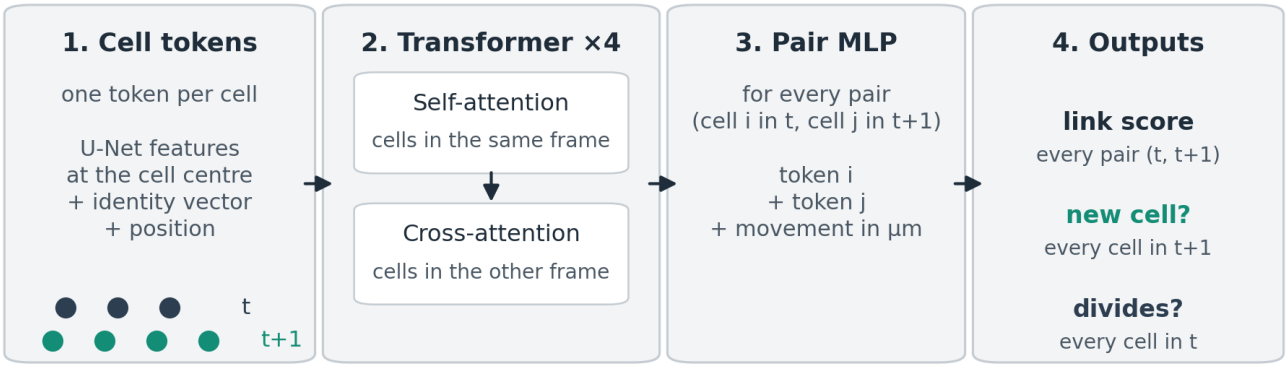
validation では、これらのフレームのリンクを予測と ground truth の両方から除外しました。私のドリフト補正は CV では大きな改善をもたらしましたが、LB では改善がありませんでした。つまり hidden test データには大きなドリフトはありません。これも、多くの人が CV と LB の不一致を経験した理由の1つだと思います。

私の実験では、重複フレームを除き、ドリフトを補正して学習すると、同じ fold-0 モデルの private スコアが 0.011 上がりましたが、public スコアは下がりました。そのため最終モデルでは使いませんでした。

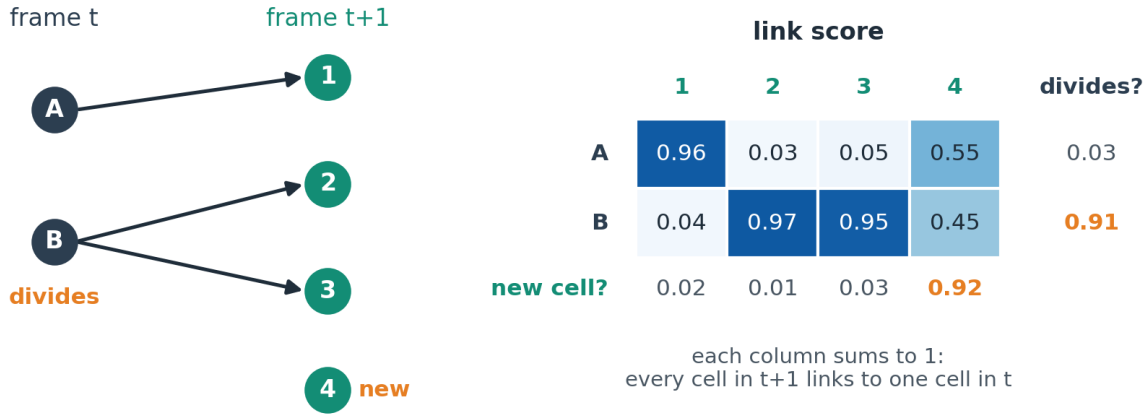
モデル

- **U-Net**：public baseline の temporal 3D U-Net です。U-Net に入れる前に、average pooling で各フレームを X と Y 方向に4分の1（4×小さく）にしています。
- **リンカー**：フレーム t と t+1 の細胞に対する transformer です（各フレーム内で self-attention、2つのフレーム間で cross-attention）。4つのことを学習します：
  - **リンクスコア**：t と t+1 の細胞のすべてのペアについて、同じ細胞かどうか。
  - **Identity 類似度**：2つの細胞の見た目が似ているか。各細胞は U-Net の特徴量から16次元の見た目ベクトルを得て、t と t+1 の同じ細胞は似たベクトルを持つべきとします。これは近接した細胞を見分けるのに役立ちます。
  - **新規細胞（New cell）**：t+1 のこの細胞は、t に対応する細胞がない新しい細胞か（例えば、ちょうど視野に入ってきた場合）。
  - **Division**：t のこの細胞は2つに分裂するか。division はまれで見逃しやすいため、loss で division の例に高い重みをかけた別のヘッドを設けることで、division に対する直接的なシグナルが得られます。

Structure



What it predicts (example)



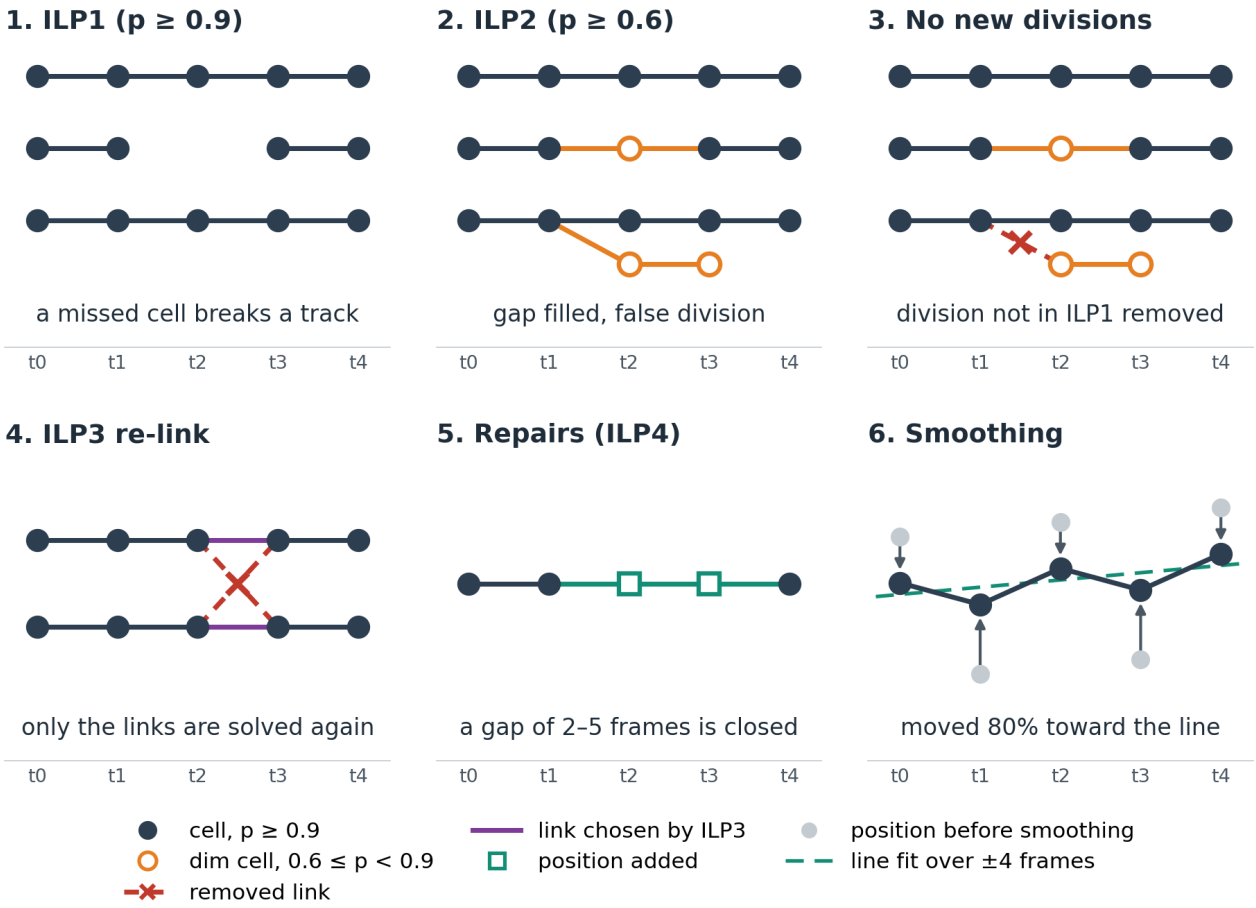
リンカー。上：構造。下：小さな例での3つの出力。細胞 B が 2 と 3 に分裂し、細胞 4 は新規細胞です。

- **事前学習**：まず4つの公開 ZebraHub データセットで学習しました。その後、コンペデータで fine-tune しました。

- **学習**：AdamW、lr 1e-4、cosine スケジュール、バッチサイズ 8。Augmentation：XY 方向の flip と回転、ガンマと明るさのシフト。

トラッキング

ILP は、どの細胞とリンクを残すか、そしてトラックがどこで始まり、終わり、分岐するかを選びます。確信度の高い細胞、スコアの高いリンク、identity ベクトルが似た細胞間のリンクほど、残すコストが安くなります。トラックの開始は new-cell スコアが高いほど安く、分岐は division スコアが高いほど安くなります。



1. **ILP1**：確信度の高い細胞のみ（検出確信度 p ≥ 0.9）で解きます。
2. **ILP2**：より多くの細胞（p ≥ 0.6）で再度解きます。ギャップを埋めますが、誤った division もいくつか追加してしまいます。
3. **新しい division なし（No new divisions）**：ILP1 になかった division をすべて削除します。余分な細胞は自身のトラックを保持します。
4. **ILP3（再リンク）**：細胞と division は固定し、リンクだけを再度解きます。弱いリンク（スコア 0.2〜0.3）は求解中には役立つことがあり、その後で削除されます。
5. **修復（Repairs）**：
   - ILP4 は、2〜5フレーム離れたトラックの終点とトラックの始点を接続し、欠けている位置を補完します。
   - 不明瞭なリンクは、細胞の見た目の類似度を用いて再マッチングします。
   - フレーム t で終わるトラックと t+1 で始まるトラックは、細胞の見た目が似ていれば、弱いリンク（スコア 0.1〜0.3）で接続します。

6. **Smoothing**：検出された位置はフレームごとに少しずつ揺れます。各細胞について、4フレーム前から4フレーム後までのトラックの位置に直線をフィットします。新しい位置は、直線80%、元の位置20% とします。その後、トラックが1フレーム欠けている場合は、欠けた位置を補完します。

結果

主な改善を、LB スコアの変化として示します：

手法	Public LB	Private LB
リンカー：New cell と Division のヘッド	+0.020	+0.024
ZebraHub での事前学習	+0.014	+0.016
5-fold アンサンブル	+0.008	+0.007
8つの flip と回転による TTA	+0.007	+0.005
トラッキング：ILP の細胞コストとして検出確信度を使用	+0.008	+0.020
トラッキングのステップ2–3：ILP2 と No new divisions	+0.003	+0.007
トラッキングのステップ5：修復	+0.001	+0.002
トラッキングのステップ6：Smoothing	+0.004	+0.005