biohub-cell-tracking-during-development

6位: 検出し、リンクし、解き、繰り返す

Rank	6
Team	Cyrus
Author	Cyrus
Topic ID	744582
Version	Japanese Translation

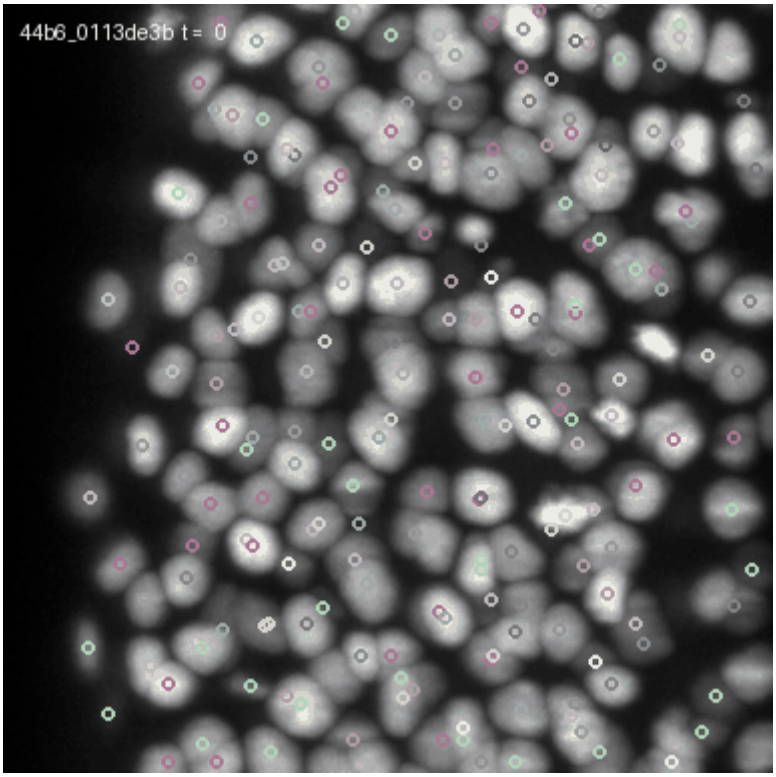
Source: https://www.kaggle.com/competitions/biohub-cell-tracking-during-development/discussion/744582
Retrieved with Kaggle CLI on 2026-10-04.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

Biohub Cell Tracking During Development: 6位解法

Private 0.953(6位)、public 0.961 です。同じパイプラインで best-validation チェックポイントを使った2つ目の提出は private 0.955 を記録しました。

コード(GitHub)	https://github.com/jamal-saeedi/biohub_cell_tracking_kaggle
モデル(Kaggle Models、MIT)	https://www.kaggle.com/models/jamalsaeedi/biohub-cell-tracking
コードデータセット(パッケージ + バージョン固定の wheel)	https://www.kaggle.com/datasets/jamalsaeedi/biohub-cell-tracking-kaggle
推論ノートブック(Kaggle)	https://www.kaggle.com/code/jamalsaeedi/biohub-cell-tracking-inference
コンペティション	https://www.kaggle.com/competitions/biohub-cell-tracking-during-development



public テストムービー `44b6_0113de3b` 上の予測トラック(z 方向投影、1フレームおきに表示)。色ごとに1本のトラックを表し、赤い輪は division を示します。

設計を方向づけた観察が2つあります。第一に、アノテーションされているのは細胞の約 3 % にすぎないため、画像の大部分は既知の細胞でも既知の背景でもなく、アノテーションのみで学習したモデルは、細胞を誤った(アノテーションされていない)隣接細胞にリンクしても、そのことを一切教えられません。第二に、リンクの難しい部分

は見た目のよく似た隣接細胞同士を見分けることであり、座標しか見ないリンカーにはそれができません。そこで次のようにしました。

- **1つのネットワークで検出とリンクを行う。** ネットワークはネイティブ解像度で3フレームを読み込み、そのリンカーは、細胞を見つけたのと同じ画像特徴からサンプリングした特徴を用いて候補リンクをスコアリングします。
- **ネットワークはソルバーがそのまま使える確率を出力する。** 明示的な「新規細胞(new cell)」クラスも含むため、グローバル ILP に手作業で調整した修復ルールは不要です。
- **パイプライン全体が次のモデルの教師になる。** 学習用ムービーに対するパイプラインのトラックが、誰もアノテーションしていない 97 % の細胞に対する擬似ラベルになります。

1. タスク

入力。 発生中の胚の3D タイムラプスムービーです。64 × 256 × 256 ボクセルのフレームが 100 枚あり、ボクセル間隔は異方性で z 方向 1.625 µm、y および x 方向 0.406 µm、1フレームあたり最大約 400 個の細胞が含まれます。

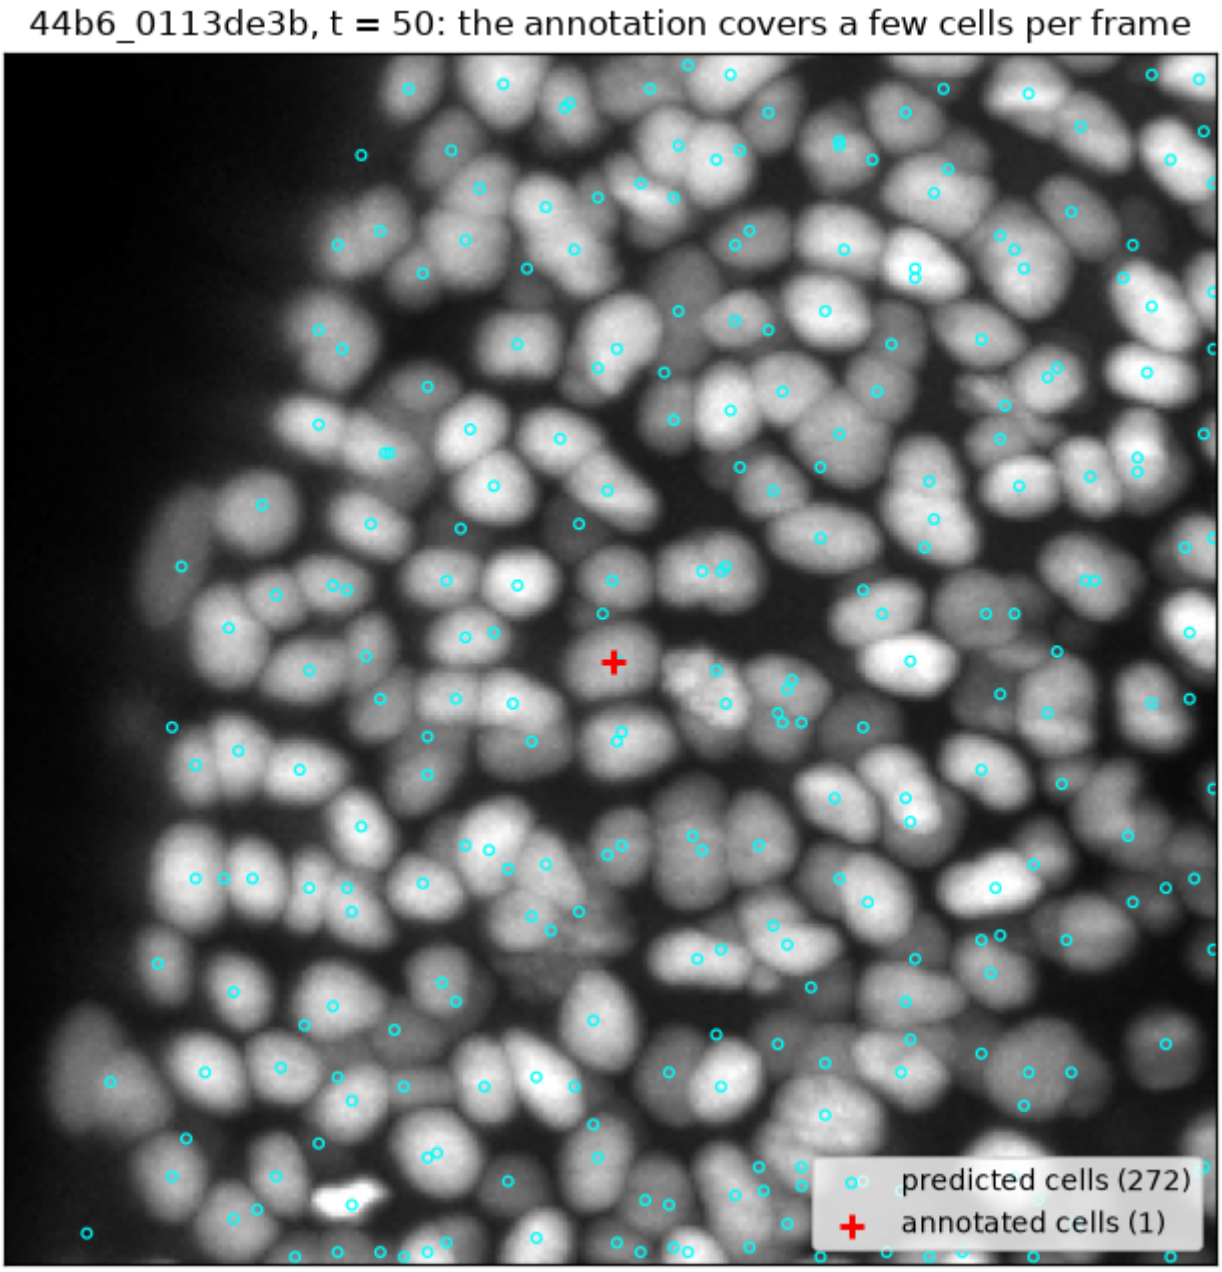
出力。 すべてのフレームにおけるすべての細胞の中心と、時刻 t の各細胞から t + 1 におけるその後継細胞へのリンクです。後継細胞を2つ持つ細胞は分裂(division)したことになります。これは Cell Tracking Challenge [2] の設定を Kaggle コンペティション [1] として実施したものです。

評価指標。 ムービーごとに、ノード数に対するペナルティ付きの edge Jaccard 指数を計算し、それをムービー間で重み付き平均し、さらに division の項を加えます。

$$J_{adj} = \max\left(0,; J_{edge} \cdot \left(1 - 0.1,\frac{N_{pred} - N_{est}}{N_{est}}\right)\right) \qquad \text{score} = \overline{J_{adj}} + 0.1 \cdot J_{div}$$

N_{est} は主催者によるムービー内の細胞数の推定値です。

アノテーションは極めてスパースです。 199 本の学習用ムービーには 133k 個のアノテーション済み細胞があり、これは存在する細胞の約 **3 %** にあたります。アノテーションは系譜(lineage)単位で付けられており、division はわずか 151 件です。



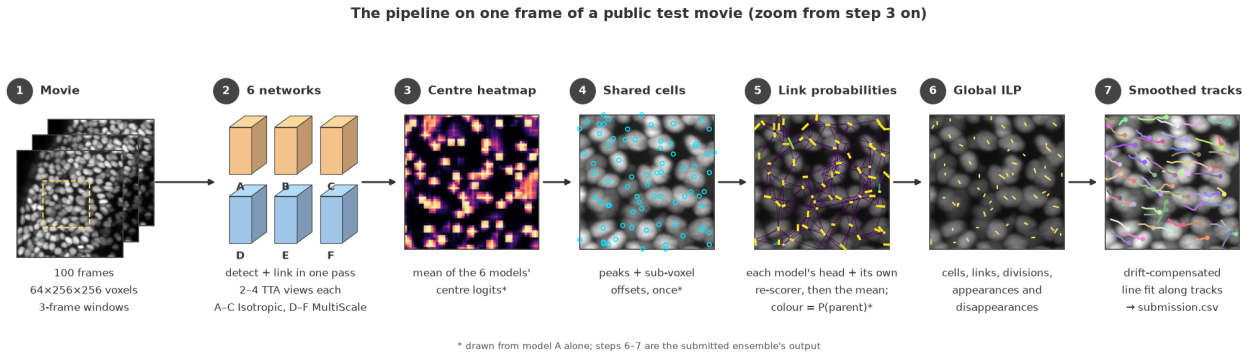
public テストムービーの1フレーム。最終パイプラインが見つけた細胞(シアン)とアノテーション済みの細胞(赤)。

ここから生じる2つの帰結が、すべてを方向づけました。

1. 画像の大部分は既知の正例でも既知の負例でもないため、通常の密な検出ターゲットを用いると、検出器は実在する細胞を抑制するよう学習してしまいます。
2. リンクの誤りの大半はアノテーションされていない隣接細胞とのアイデンティティスワップであり、正解データだけではこれが一切ペナルティを受けません。

---

2. パイプラインの概要

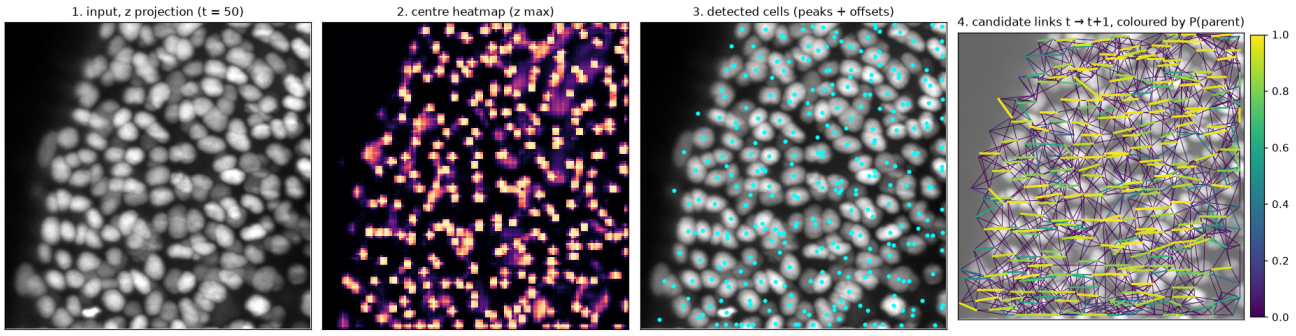


- **2種類のアーキテクチャによる6つのネットワーク。** それぞれが1つのモデルの中で細胞を検出し、かつ 前フレームへのリンクをスコアリングします。
- **共有される1つの細胞集合。** 6つの中心マップを平均します。その後、各ネットワークが同じ候補リンクを自身のヘッドと自身の勾配ブースティング再スコアラーでスコアリングし、6つのリンク分布を平均します。
- **グローバルな整数線形計画(ILP)** が、細胞とリンク確率をトラックと division に変換します。ドリフト補正付きのスムーザーが位置を精緻化します。
- **学習** は、教師 → 生徒のラウンドを何度か繰り返して進めました。ここでの教師は上記のパイプライン全体です。

---

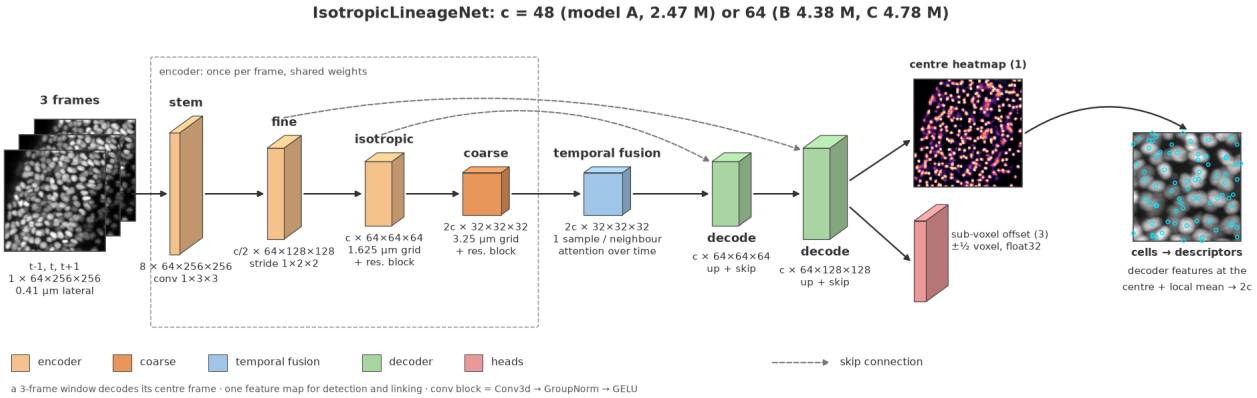
3. モデル

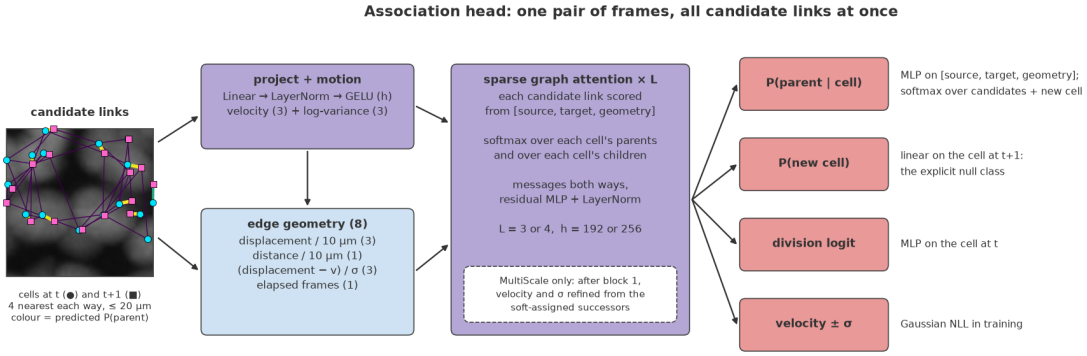
3.1 共通設計



最初の各段階を通過する1フレーム。入力、中心 heatmap、検出された細胞、そして予測された親確率で色分けした次フレームへの候補リンク。このフレームペアはステージのジャンプをまたいでいるため、ほとんどのリンクが長く平行になっています。

どちらのアーキテクチャも、**3フレームのウィンドウ**$(t-1, t, t+1)$をネイティブ解像度で読み込みます。推論時にはリサンプリングもクロップも行いません。各フレームは個別に min–max スケーリングと z-score 化を行います。ネットワークは2つの部分から成ります。**検出器**(時間方向の融合を備えた 3D U-Net 風 [3, 4] のエンコーダ–デコーダ)と、連続する2フレームの検出細胞同士をリンクする **association head** です。

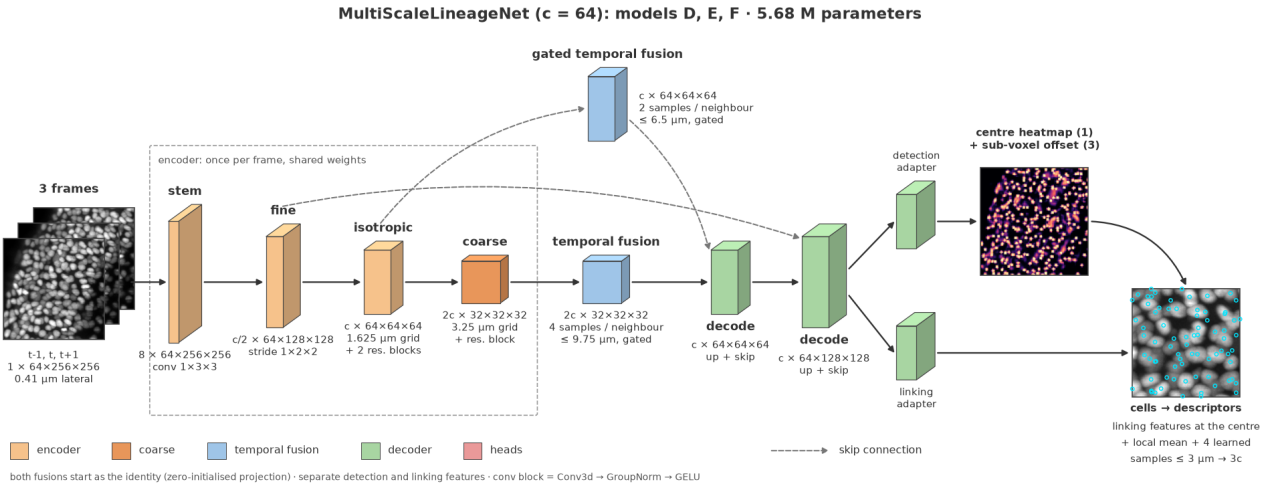




1. **エンコーダ(フレームごと)。** 3D 畳み込みのスタック(Conv3d → GroupNorm [5] → GELU [6])で、4:1 の異方性を2段階で処理します。横方向のみの縮小を2回行ってほぼ等方的な 1.625 µm グリッドに到達し、その後 3D の縮小で粗い 3.25 µm グリッドに到達します。フレームは独立にエンコードされるため、推論時には各フレームは一度だけエンコードされ、そのフレームを含む3つのウィンドウで再利用されます。
2. **時間方向の融合。** 粗いグリッド上で、フレーム t の各ボクセルが隣接する各フレームへの有界な変位を予測し、その位置で隣接フレームの特徴をサンプリングし、自身の特徴と照らし合わせて attention で重み付けします。これにより、比較する前に移動する細胞の位置が揃えられます。初期化時には変位はゼロで、attention は一様です。
3. **検出。** デコーダはスキップ接続を用いて 64 × 128 × 128 グリッドに戻り、中心 heatmap(細胞 = 0.5 を超える non-maximum suppression 後のピーク)と、細胞ごとのサブボクセルオフセットを予測します。この2つのヘッドは float32 で実行されます。
4. **Association head(トラッキング)。** 連続する各フレームペアについて:
   - 各細胞記述子(細胞の連続的な中心位置でサンプリングした特徴)が、速度と軸ごとの不確かさを予測します。
   - 各候補リンクには、幾何特徴として変位と、不確かさで正規化した残差(変位 − 速度)が与えられます。
   - 双方向のスパースなグラフ attention [7, 8] を数層、候補リンク上で実行し、t と t + 1 の細胞が互いを更新します。
   - ヘッドは細胞ごとに、候補となる親 **および「新規細胞」クラス** に対する softmax、親ごとの division スコア、娘細胞ペアごとのスコア、そして速度を出力します。

明示的な「新規細胞」確率はよく較正されており、ソルバーの出現(appearance)コストになります(§ 6.5)。細胞記述子に対する attention でリンクをスコアリングする手法は Trackastra [9] と関連がありますが、我々のものはスパースで、k-NN 候補グラフ上で動作し、検出器と共同で学習されます。

3.2 2つのアーキテクチャ



	IsotropicLineageNet	MultiScaleLineageNet
時間方向の融合	隣接フレームごとに学習済みサンプル1つ、粗いグリッド	2スケール(粗い + 等方的)での融合、隣接フレームごとに複数の学習済みサンプルとボクセルごとのゲート。恒等写像から開始(ゼロ初期化した射影)
検出用とリンク用の特徴	共有	別々の残差タスクアダプタ
細胞記述子	中心サンプル + 局所平均	+ 学習済みオフセット(各軸 ± 3 µm 以内)での attention プーリングしたサンプル(deformable sampling [10] と同様)
Association head	attention ブロック	+ グラフ内の動き精緻化: 候補後継細胞へのソフトな割り当てにより、途中で速度と不確かさを更新
リンカーの学習入力	0.5 µm のジッターを加えたアノテーション位置	マッチしたアノテーション細胞の 75 % を検出器自身の検出位置に移動
パラメータ数	2.5–4.8 M	5.7 M

3.3 アンサンブルの6モデル

	モデル	アーキテクチャ	チャネル / リンカー	パラメータ数	学習	TTA ビュー数
A	R3-ft24-noisy-lc-s1	Isotropic	48 / 192 × 3	2.5 M	3回目の教師 → 生徒ラウンド	4
B	B3-v11-ft32-noisy-lc-s31	Isotropic、wide	64 / 256 × 3	4.4 M	アンサンブルラベルで2回ファインチューニング	4
C	D2-v11-ft32-noisy-lc-s33	Isotropic、wide + deep	64 / 256 × 4	4.8 M	v10 ラベルで学習し、v11 でファインチューニング	4
D	EX-ms-lc-s5	MultiScale	64 / 256 × 4	5.7 M	アンサンブルラベルでスクラッチから学習	3
E	FX-ms-lc-s6	MultiScale	64 / 256 × 4	5.7 M		2

	モデル	アーキテクチャ	チャネル / リンカー	パラメータ数	学習	TTA ビュー数
					アンサンブルラベルでスクラッチから学習	
F	GX-ms-lc-s7	MultiScale	64 / 256 × 4	5.7 M	アンサンブルラベルでスクラッチから学習	2

すべてのモデルが **独自のランダムな、ムービー単位で互いに素な train/validation 分割** を持っているため、メンバーごとに異なる誤りをします。モデルごとの完全な表は §10 にあります。

3.4 コンポーネントごとのパラメータ数

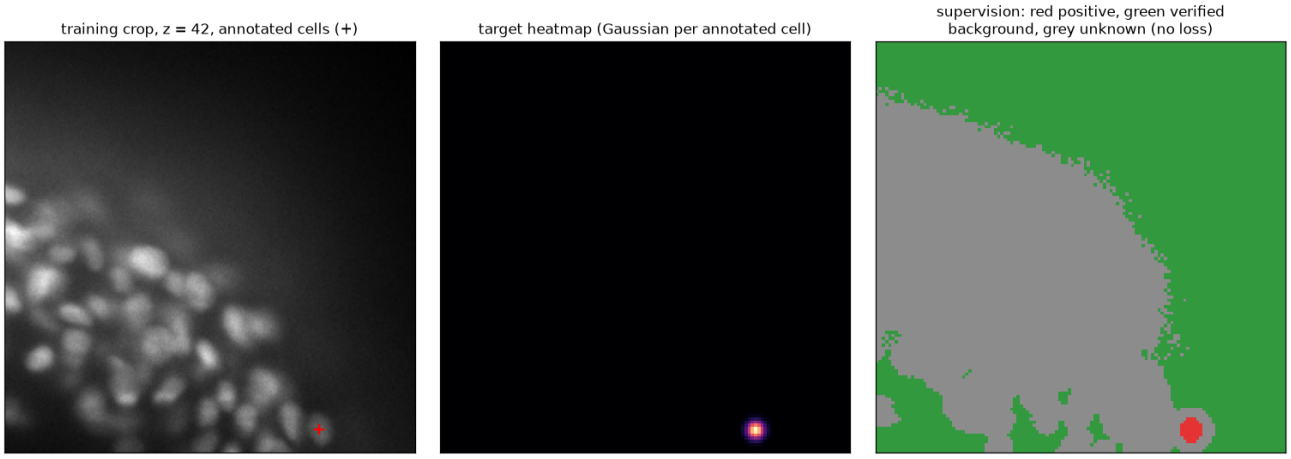
コンポーネント	A (Iso, c 48, h 192, L 3)	B (Iso, c 64, h 256, L 3)	C (Iso, c 64, h 256, L 4)	D–F (MultiScale)
エンコーダ(stem → coarse)	0.78 M	1.39 M	1.39 M	1.61 M
時間方向の融合	0.51 M	0.91 M	0.91 M	1.13 M (coarse 0.90 + isotropic 0.23)
デコーダ、アダプタ、中心 / オフセットヘッド	0.28 M	0.50 M	0.50 M	0.72 M
association head	0.90 M	1.59 M	1.99 M	2.22 M
うち娘細胞ペアヘッド(学習時のみ)	0.11 M	0.20 M	0.20 M	0.20 M
合計	**2.47 M**	**4.38 M**	**4.78 M**	**5.68 M**

c = 特徴チャネル数、h = association の幅、L = グラフ attention ブロック数。

---

4. 3 % のアノテーションでの学習

4.1 3状態の検出ターゲット



学習用クロップの例。アノテーション済みの細胞にはガウシアンのターゲットが与えられます(中央)。損失を持つのは赤(正例)と緑(確認済みの背景)のボクセルだけで、アノテーションされていない細胞が存在する灰色の領域は無視されます。

状態	定義	損失の重み
正例	アノテーションされた中心から 3 µm 以内。ガウシアンターゲット(σ 1.5 µm)で、最も近いグリッドセルで 1.0	フル
確認済みの背景	フレームの中央値より暗く、かつどのアノテーションからも 6 µm より離れている	フル
不明	それ以外すべて	0

不明領域に欠けている情報は **個数事前分布(count prior)** で補います。各クロップフレームの heatmap の総和を、主催者によるムービーごとの細胞数推定値(クロップに合わせてスケーリングしたもの)に近づけるようにします。これがないと、検出器は不明領域で過剰に発火します。

4.2 リンクのサンプル

- リンカーは k-NN 候補グラフ(双方向に k = 4、≤ 20 µm)で学習します。これは推論時と同じグラフで、さらに k-NN グラフが取りこぼしたアノテーション済みの親リンクを加えます。
- **ディストラクター:** アノテーションのない明るい輝度ピーク(1フレームあたり最大 256 個。最後のファインチューニングである B と C では 64 個)をノードとして加えます。ソースとしては、ディストラクターは確認済みの誤った親です。ターゲットとしては、その親は不明です。
- **アノテーション済みの親の 15 % をソース集合から除去** し、「新規細胞」とラベル付けします。これにより明示的な null クラスを学習させます。
- 損失はフレームペアごとに、バッチ化せずに計算します。

4.3 損失

中心の損失と親の損失は、正解データと擬似ラベル(§5)で別々に計算し、**L = L_GT + 0.5・L_pseudo** として組み合わせます。これにより、スパースな正解データが埋もれることはありません。サブボクセルオフセット、division、娘細胞ペア、速度の各項は正解データのみを用い、個数事前分布は主催者の細胞数推定値を用います。

損失	重み
中心に対する penalty-reduced focal loss [11, 12]	1.0
サブボクセルオフセット(smooth L1、アノテーション済み細胞のみ)	1.0
候補 + 「新規細胞」に対する親の cross-entropy	1.0
division BCE(正例の重み 20、正解データのみ)	0.5
娘細胞ペア BCE	0.25
速度のガウシアン NLL(正解データのみ)	0.1
個数事前分布	1.0

4つの association 損失は、最初の 300 オプティマイザステップではオフにし、続く 300 ステップで徐々に導入します(スクラッチからの学習の場合)。これにより、リンカーがまだ何も位置特定できない特徴で学習することはありません。

4.4 サンプルとデータ拡張

- **サンプル:** フレーム全体の3フレームクロップ(64 × 256 × 256)。15 % は一様に配置し、残りのうち 25 % は division を中心に、それ以外はアノテーション済みの細胞を中心に配置します。
- **データ拡張:**
  - 横方向の D4 のみ(z は決して反転しません。光の減衰により方向性があるためです)
  - ガンマと Gaussian ノイズ
  - 合成的なステージドリフト: フレームを横方向にランダムウォークでシフトし、1ステップあたり最大 6 µm(ほとんどのモデル)
  - noisy-student ノイズ [13]: ショットノイズ、平均を保存する深さ方向のゲイン、そしてファインチューニングした isotropic モデルでは channel dropout 0.2 と weight decay 0.01
  - **低コントラストのヘイズ:** 各フレームを、それ自身に 17 µm のボックスブラーをかけたものとランダムなコントラストでブレンドし、霞んだ深いムービーを模倣します(validation で +0.005)。

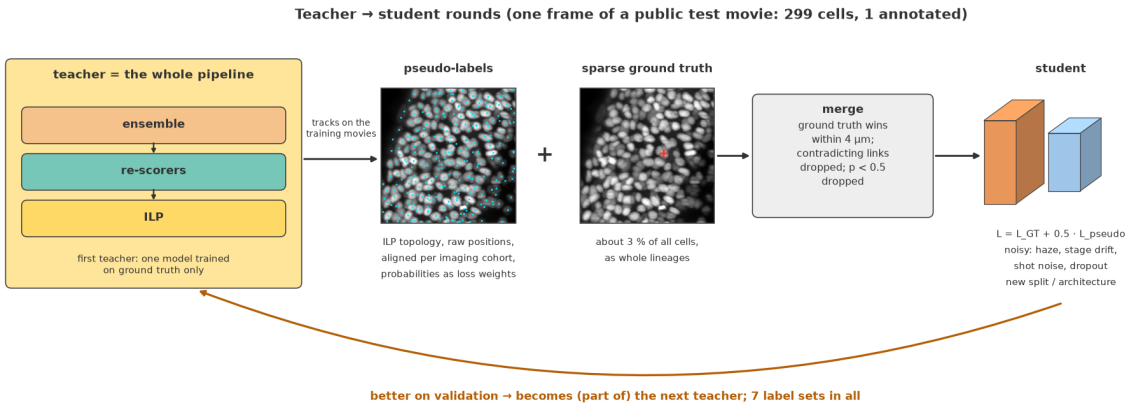
4.5 最適化

AdamW [14]、線形ウォームアップとコサイン減衰 [15]、1 での勾配クリッピング、そして推論時に使うモデルとなる重みの EMA [16](減衰率 0.999)。RTX 3090/4090 上で bf16 混合精度 [17]。スクラッチからの学習: 学習率 1e-4、2,048 クロップ × 32 エポック(DX は 48、F は 24 で停止)。ファインチューニング: 3e-5、24–48 エポック。チェックポイントは validation loss で選択します(B2 と DX は validation の親損失で、early stopping あり)。

---

5. 擬似ラベルと教師 → 生徒ラウンド

細胞の 3 % しかアノテーションされていない状況では、正解データのみで学習したモデルは接触した細胞を分離することを学ばず、アノテーションされていない隣接細胞にリンクしてもペナルティを受けません。オフラインの noisy-student 自己学習 [13, 18] がその両方を解決しました。**教師は1つのネットワークではなく、パイプライン全体です。**



5.1 ラベルセットの作り方(`biohub-pseudo-labels`)

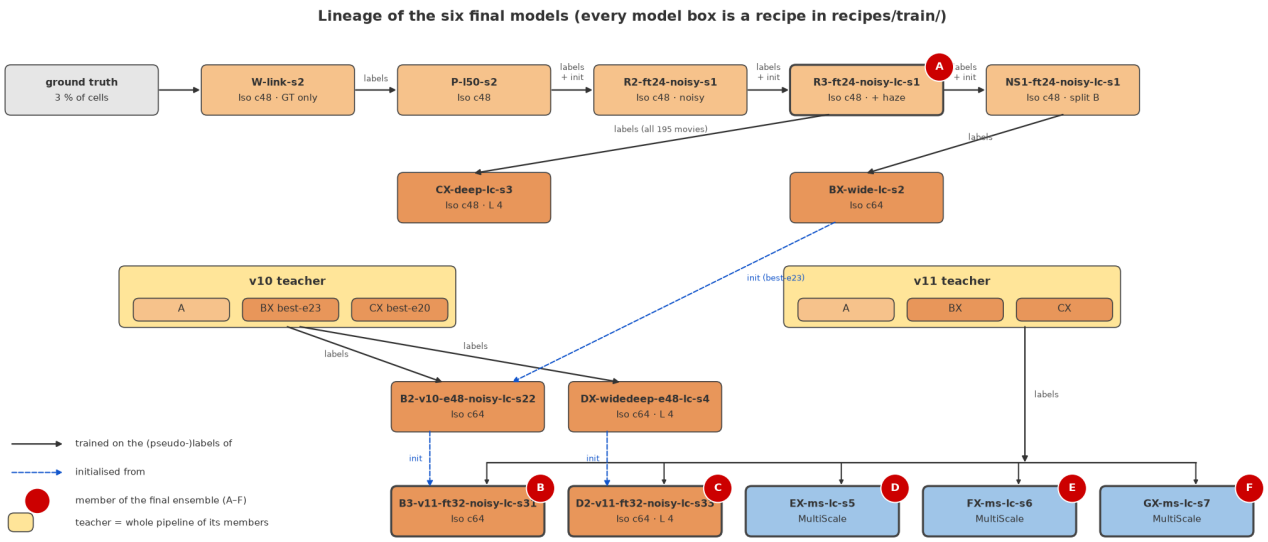
1. **教師パイプラインを実行する。** すべての学習用ムービーに対し、推論時とまったく同じようにデコード、リンク、再スコアリング、ILP の求解を行います。
2. **トポロジーは ILP の解から取る。** その解のリンクは、ネットワークの細胞ごとの argmax よりもはるかに正確です(アノテーション済み系譜で 0.949 対 0.885)。
3. **位置は平滑化後のトラックではなく生の検出から取る。** スムーザーは指標には役立ちますが、点を真の中心から遠ざけてしまいます。
4. **撮像コホートごとに位置を揃える。** 教師の細胞は、アノテーターが同じ細胞に置いた位置から小さな系統的オフセット(z 方向で最大 0.5 µm、コホート依存)だけずれています。これを validation ムービーで測定して差し引きます。
5. **教師の確率を保持する**(細胞ごとの中心確率、リンクごとの親確率)。これらを損失の重みとして使います。

5.2 学習時のラベルのマージ方法

- 同じフレーム内でアノテーション済み細胞から 4 µm 以内にある擬似細胞は、その細胞 そのもの とみなします。
- アノテーション済みの親または子と矛盾する擬似リンクは破棄します。
- 確率が 0.5 未満の擬似細胞と擬似リンクは破棄します。
- division、速度、サブボクセルオフセットは正解データのみで教師付けします。
- 4本の public テストムービーには決してラベルを付けません。

最終的なラベルセットは 195 本のムービーにわたって約 5.0 M 個の細胞と 4.9 M 本のリンクを含み、アノテーション済み細胞の約 38 倍になります。

5.3 最終モデルの系譜



- 最初のラウンドが単独で最大の改善をもたらしました。正解データのみのモデルに対し validation で +0.008 です。その後、単純な自己蒸留は頭打ちになり、以降の改善は新しいアーキテクチャ、新しい分割、そして **アンサンブル教師** から得られました。

- 2つのアンサンブル教師(v10、v11)は、メンバー固有の再スコアラーを備えた3モデルのパイプラインです。提出時の public leaderboard スコアはそれぞれ 0.958 と 0.959 でした。

各ステップには `recipes/` にレシピがあり、`tools/reproduce_training.sh` がこの系譜を順に実行します。

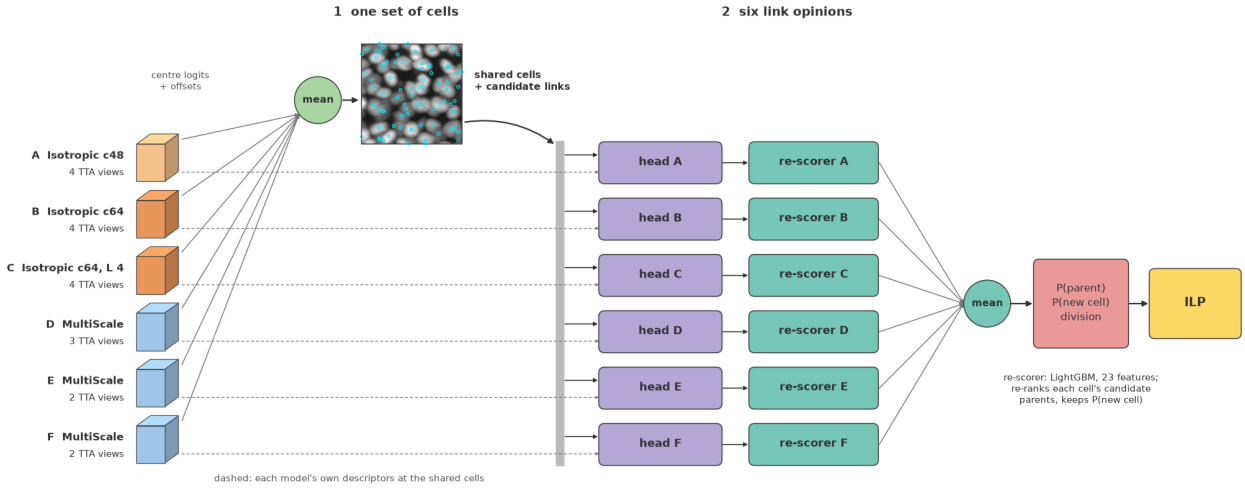
---

6. 推論の手順

6.1 デコードとテスト時データ拡張

- 各フレームは、そのフレームを中心とする3フレームウィンドウからデコードします。
- 各モデルは 2–4 個の横方向ビュー(90° 回転)を実行します。オフセットベクトルを含む出力は元の向きに戻し、logit 空間で平均します。記述子はビュー平均した特徴からサンプリングするため、リンクも TTA の恩恵を受けます。初期の単一モデルで 1 ビューから 4 ビューにすると、スコアが +0.05 向上しました。
- フレームごとのエンコーダ出力はキャッシュし(T4 上と同様に fp16 autocast 下では fp16 で)、ウィンドウ間およびビュー間で再利用します(デコードが 1.4–1.9 倍高速化)。

6.2 1つの細胞集合と、6つのリンクの意見



- **細胞:** 6モデルの中心 logit とオフセットを平均し、ピークを一度だけ抽出します。
- **リンク:** 各モデルは共有された細胞の位置で自身の記述子をサンプリングし、同じ候補リンクを自身のヘッドでスコアリングし、自身の再スコアラーで並べ替えます。6つの親分布(「新規細胞」を含む)は確率空間で平均します。

6.3 候補リンク

t + 1 の各細胞に対する t での最近傍 4 細胞と、t の各細胞に対する t + 1 での最近傍 4 細胞の和集合を、20 µm 以内で取ります。アノテーション済みリンクの約 99.4 % で、真の親が候補に含まれます。候補は確率で枝刈りしません。softmax にすでに「新規細胞」の選択肢があるためです。

6.4 メンバー固有の edge 再スコアラー

隣接細胞間のアイデンティティスワップが最大の誤りの種類です(validation における edge の誤りの 51–57 %)。各モデルは、各細胞の候補親を並べ替える LightGBM [19] のリランカー(300 本の木、31 リーフ、二値分類の目的関数)を持ち、候補リンクごとに 23 個の特徴を使います。

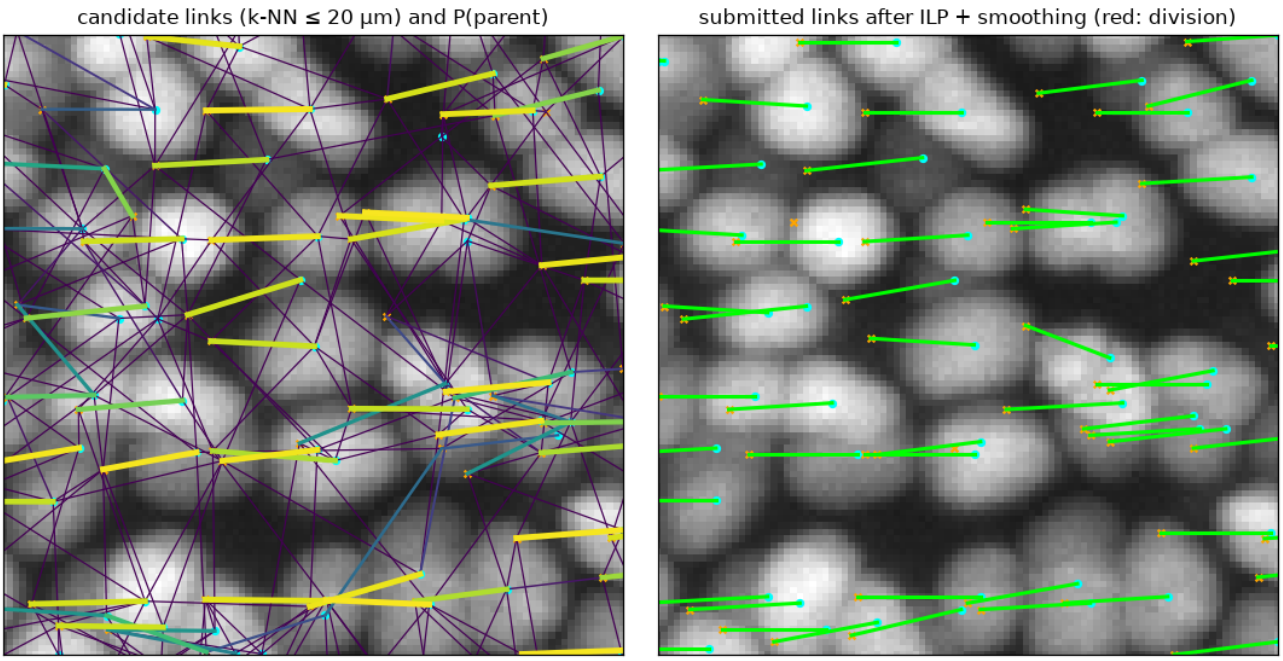
次元数	特徴
5	モデルの対数確率、その細胞の候補内での順位、最良の対抗候補とのマージン、候補数、「新規細胞」の対数確率
2	距離(生の値とドリフト補正後)
4	z 方向と横方向の変位(生の値と、そのフレームのステージドリフトを除去した後)
2	速度残差(全体と z 方向)
3	両細胞の中心 logit、親の division logit
3	親をめぐる競合: 他の細胞に対するその親の最良スコア、その親を1位とする細胞の数、その親の候補子細胞の数
2	両細胞の周囲の局所密度(10 µm 以内の細胞数)
2	細胞の深さ(z)とムービー内の相対時刻

並べ替え後の分布は「新規細胞」の確率をそのまま保ちます。

$$\log P'(\text{parent}) = \log(1 - P_{new}) + \text{log-softmax}(\text{tree scores over the candidates})$$

学習(`biohub-train-rescorer`)。 各メンバーは自身の木を持ち、それはアンサンブルの共有細胞上でのそのメンバー自身のスコアに対して、自身のホールドアウト validation ムービー上で学習されます。1行は、アノテーション済み細胞とアノテーション済みの親の両方がデコードされた細胞と 7 µm 以内でマッチする細胞の、1つの候補親に対応し、真の親が正例です。validation 時には木を out-of-fold で適用する(ムービー単位で 5 fold)ため、どのムービーも自身を見た木でスコアリングされることはありません。validation でモデルごとに +0.004 から +0.007 の効果がありました。推論時には木をフラットな配列からコンパイル済みの木探索 [20] で評価するため、勾配ブースティングのライブラリは不要です。

6.5 グローバル ILP



シアンの点: 時刻 t の細胞、オレンジの×印: 時刻 t + 1 の細胞。左: 候補リンクとその確率。右: ILP と平滑化を経た提出リンク(このウィンドウには division はありません)。

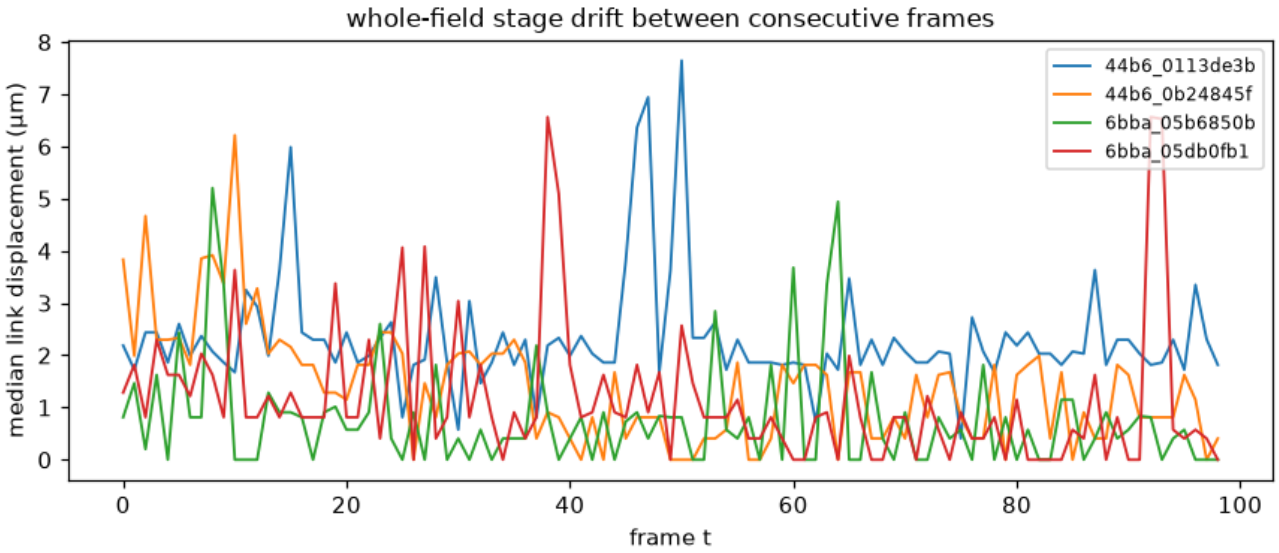
各細胞は二値変数 exists、appears、disappears、divides を持ち、各候補リンクは1つの変数を持ちます。これは conservation tracking 系のモデル [21, 22] です。フロー保存則は次のとおりです。

$$\text{appear}j + \sum_i \text{edge}{ij} = \text{node}_j \qquad \text{disappear}i + \sum_j \text{edge}{ij} = \text{node}_i + \text{div}_i \qquad \text{div}_i \le \text{node}_i$$

項	コスト
細胞	− 中心 logit(p = 0.5 で損益分岐)
出現	− log P_T(new cell) + 0.5(最初のフレームの細胞は無償で出現)
消失	12
division	max(0, − division logit)
リンク	− log P_T(parent) + 0.2 · ドリフト補正後の距離(µm)

P_T は、再スコアリングしアンサンブル平均した分布を温度 T = 0.9 で調整したものです。

ドリフト補正後の距離。 顕微鏡のステージはフレーム間でドリフトし(中央値 1.3 µm、99 パーセンタイル 7.3 µm)、アイデンティティスワップはそうしたフレームに集中します。各フレームペアについて、確信度の高いリンク(P ≥ 0.7)の変位の中央値としてグローバルなシフトを推定し、各リンクはそのシフトを除去した後の距離に対してコストを払います(validation で +0.009)。



4本の public テストムービーにおける、連続フレーム間の視野全体の変位。

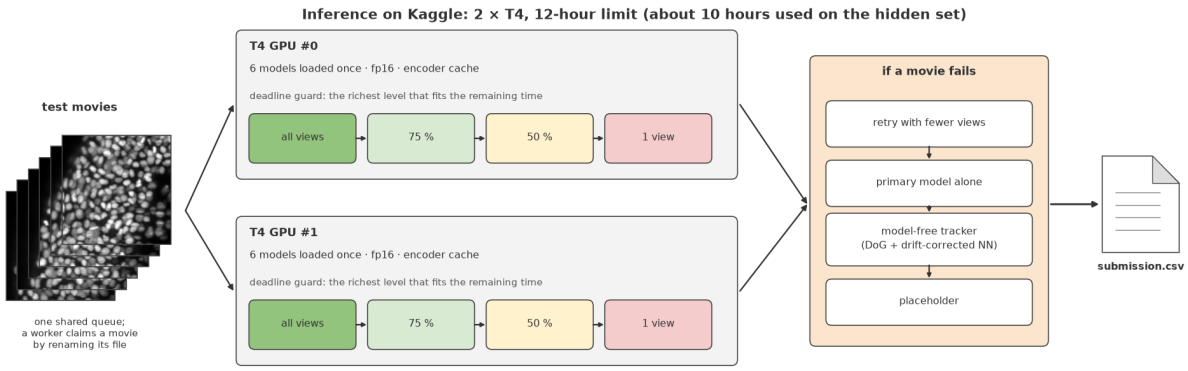
LP 優先の求解。 division の行を除けば制約行列はネットワーク行列なので、LP 緩和はほぼ整数解になります。HiGHS [23] で LP を解き、整数値になった変数をすべて固定し、小数値の変数とその近傍に対する小さな MILP で仕上げます。これは SCIP [24] による分枝限定法より 38–166 倍高速で、LP 下界との差は 0.5 % 以内です(そうでない場合は SCIP を実行します)。最後の手段として貪欲法ソルバーがあります。すべての細胞とすべての出現にコストが付いているため、ILP は宙ぶらりんの断片を残さず、修復ヒューリスティクスは不要です。

6.6 ドリフト補正付きの平滑化

z は 1.625 µm で量子化されており、位置特定誤差の大部分を担っているため、位置をトラックに沿って平滑化します。各細胞について、トラックに沿って前後それぞれ最大 2 個の近傍(division で打ち切り)を取り、軸ごとに直線フィットを行い、細胞を 0.2 · 元の位置 + 0.8 · フィット値 へ移動します。平滑化は累積ステージドリフトを除去した後に行い、その後ドリフトを戻します(単純な平滑化に対して +0.005)。位置はボリューム内にクランプし、丸めます。

---

7. 2台の T4 で 12 時間以内に実行する



- **GPU ごとに1ワーカー、共有キューは1つ。** 各ワーカーは6モデルを一度だけロードし、ムービーごとのファイルをアトミックにリネームすることでムービーを確保します。
- **T4 では bf16 ではなく fp16**(ネイティブの bf16 がないため)[17]: エミュレートされた bf16 より予測が 3.5 倍高速です。
- **締め切りガード。** 各ムービーの前に、ワーカーは直近の履歴からそのコストを見積もり、収まる範囲で最もリッチな設定を選びます。すべてのビュー、75 %、50 %、そして 1 ビューの順です。
- **すべてのムービーに予測を出す。** 失敗したムービーは次に安いレベルで再試行し、次に 1 ビューで、次にプライマリモデル単独で、次にモデルを使わないトラッカー(difference-of-Gaussians による検出 [25] とドリフト補正付きの最近傍リンク)で再実行し、最後にプレースホルダーを出力します。
- 4本の public テストムービーは約 15 分、非公開セットは約 10 時間で実行されました。

---

8. 検証と結果

- **ローカル指標:** ムービーごとの重み付けも含めた公式指標の我々による再実装(このリポジトリには含まれていません)。Kaggle ノートブックが4本の public テストムービーに対して書き出す CSV は、ローカルでもまったく同じスコアになります。
- **分割:** 各モデルは 165 本のムービーで学習し、自身の 30 本で検証します。4本の public テストムービーはすべてのモデルからホールドアウトされています。アンサンブルを含むすべての変更は、モデル A の 30 本の validation ムービーで順位付けしています。
- **チューニング:** モデルや推論の変更ごとに、小さなソルバーのグリッド(消失、出現バイアス、距離の重み、温度、平滑化)を探索し、validation ムービー上での 2-fold 交差検証と、ムービー単位の対応のあるブートストラップで比較します。

提出	validation (adj. J)	4本の public テストムービー	public LB	private LB
`fin` (選択)	0.940	0.928	0.961	**0.953**
`best`	0.939	0.933	0.958	0.955

ローカルの数値からは division の項を除いています。コーパス全体で division が 151 件しかないため、変更の順位付けに使うにはノイズが大きすぎるからです。

---

9. 効いたこと

変更	測定された改善
テスト時データ拡張、1 → 4 ビュー(単一モデル)	スコア +0.05
最初の教師 → 生徒ラウンド	validation +0.008
ドリフト補正後のリンク距離	validation +0.009
メンバー固有の edge 再スコアラー	モデルごとに +0.004 から +0.007
ドリフト補正付きの平滑化(単純な平滑化に対して)	+0.005
低コントラストのヘイズ拡張	+0.005
異なる分割とアーキテクチャのモデルのアンサンブル	public 0.954 → 0.959(1 → 3 モデル)
T4 でエミュレートされた bf16 の代わりに fp16	予測が 3.5 倍高速

主な教訓:

1. **ネットワークにはソルバーが使える確率を出力させる。** 明示的な「新規細胞」クラスにより、出現とリンクのコストが較正され、修復ヒューリスティクスが不要になります。
2. **擬似ラベルはパイプライン全体から取る**(ILP のトポロジー、生の位置、正解データを優先)。そして、その時点で最良のパイプラインから再生成する。
3. **アーキテクチャだけでなく分割も多様化する。**
4. **細胞だけでなくカメラもモデル化する:** ソルバー、スムーザー、データ拡張におけるステージドリフト。
5. **時間予算を設計する:** fp16、エンコーダキャッシュ、2 GPU へのシャーディング、段階的な締め切りガードにより、TTA 付きの6モデルアンサンブルを 12 時間に収めることができました。

---

10. モデルのまとめ

全ラン共通: 3フレームのフレーム全体クロップ(64 × 256 × 256)、1エポックあたり 2,048 クロップ、実効バッチサイズ 8、AdamW、EMA 0.999、個数事前分布の重み 1.0、擬似ラベルの重み 0.5、低コントラストのヘイズ 0.3(R3 以降)、ショットノイズ 0.2 と深さ方向のゲイン 0.15(R2 以降)。

ラン	アーキテクチャ	ch / リンカー	パラメータ数	分割シード	初期化	ラベル	エポック	lr	dropout	ドリフト	検出位置上のリンカー	用途
W-link-s2	Iso	48 / 192×3	2.47M	314159	–	正解データ	32	1e-4	0	0.5	–	ラウンド0の教師
P-l50-s2	Iso	48 / 192×3	2.47M	314159	–	W-link-s2	32	1e-4	0	0.5	–	教師
	Iso						24		0.2	0.5	–	教師

ラン	アーキテクチャ	ch / リンカー	パラメータ数	分割シード	初期化	ラベル	エポック	lr	dropout	ドリフト	検出位置上のリンカー	用途
R2-ft24-noisy-s1		48 / 192×3	2.47M	314159	P-l50-s2	P-l50-s2		3e-5				
R3-ft24-noisy-lc-s1	Iso	48 / 192×3	2.47M	314159	R2	R2	24	3e-5	0.2	0.5	–	**A**、教師
NS1-ft24-noisy-lc-s1	Iso	48 / 192×3	2.47M	271828	R3	R3(195ムービー)	24	3e-5	0.2	0.5	–	教師
BX-wide-lc-s2	Iso	64 / 256×3	4.38M	271828	–	NS1	32	1e-4	0	0.5	–	v10/v11 教師のメンバー
CX-deep-lc-s3	Iso	48 / 256×4	3.55M	898	–	R3(195ムービー)	32	1e-4	0	0.5	–	v10/v11 教師のメンバー
B2-v10-e48-noisy-lc-s22	Iso	64 / 256×3	4.38M	271828	BX (best-e23)	v10	≤ 48*	3e-5	0.2	0.5	–	B の初期値
DX-widedeep-e48-lc-s4	Iso	64 / 256×4	4.78M	816	–	v10	≤ 48*	1e-4	0	0.5	–	C の初期値
B3-v11-ft32-noisy-lc-s31	Iso	64 / 256×3	4.38M	271828	B2	v11	32	3e-5	0.2	0	–	**B**
D2-v11-ft32-noisy-lc-s33	Iso	64 / 256×4	4.78M	816	DX	v11	32	3e-5	0.2	0	–	**C**
EX-ms-lc-s5	MS	64 / 256×4	5.68M	1895	–	v11	32	1e-4	0	0.5	0.75	**D**
FX-ms-lc-s6	MS	64 / 256×4	5.68M	2693	–	v11	32	1e-4	0	0.5	0.75	**E**
GX-ms-lc-s7	MS	64 / 256×4	5.68M	756	–	v11	32 中 24	1e-4	0	0.5	0.75	**F**

* validation の親損失による early stopping(patience 10)。

2つの提出のチェックポイント: `fin` は B–E の最後のチェックポイントを、`best` はそれらの best-validation-loss チェックポイントを使います。A と F は両方で同じです。F のランは予定していた 32 エポックのうち 24 エポックで停止し、その最後のチェックポイントが最良のチェックポイントでもあったためです。各提出はそれぞれ独自の6つの再スコアラーを持ちます。`best-e23` / `best-e20` は、BX / CX の 24 / 21 エポック目までにおける最良チェックポイントで、v10 教師用のスナップショットとして保持したものです。

計算資源: 1ランにつき RTX 3090/4090 を1台。isotropic のランは1回あたり 4–10 時間、MultiScale のランは1回あたり約 17 時間(バッチサイズ 1 で 15 GiB)。推論: 6モデルアンサンブルで T4 1台あたり1ムービー約 7 分。

---

11. コード

ステップ	コマンド	コード
予測(`fin` / `best`、または自分のモデル)	`biohub-predict`	`cli.py`, `isotropic/`
レシピから1モデルを学習	`biohub-train --recipe recipes/train/<run>.json`	`training/`
教師アンサンブルから擬似ラベルを生成	`biohub-pseudo-labels --ensemble recipes/ensembles/<set>-teacher.json`	`labels.py`
メンバー固有の再スコアラー	`biohub-train-rescorer --ensemble recipes/ensembles/<spec>.json --names ...` (モデルごとに1つの名前。`tools/reproduce_training.sh` を参照)	`training/rescorer.py`
学習の系譜全体	`bash tools/reproduce_training.sh`	`recipes/`
合成データ上で全ステージを CPU 実行	`python tools/smoke_test.py`	`notebooks/training.ipynb`

モデルは Kaggle Models に、推論ノートブックは Kaggle にあります。

参考文献

1. Biohub. Biohub - Cell Tracking During Development. Kaggle competition, 2026. https://www.kaggle.com/competitions/biohub-cell-tracking-during-development
2. M. Maška et al. The Cell Tracking Challenge: 10 years of objective benchmarking. Nature Methods 20, 1010–1020, 2023.
3. O. Ronneberger, P. Fischer, T. Brox. U-Net: Convolutional Networks for Biomedical Image Segmentation. MICCAI 2015.
4. Ö. Çiçek, A. Abdulkadir, S. S. Lienkamp, T. Brox, O. Ronneberger. 3D U-Net: Learning Dense Volumetric Segmentation from Sparse Annotation. MICCAI 2016.
5. Y. Wu, K. He. Group Normalization. ECCV 2018.
6. D. Hendrycks, K. Gimpel. Gaussian Error Linear Units (GELUs). arXiv:1606.08415, 2016.

7. P. Veličković, G. Cucurull, A. Casanova, A. Romero, P. Liò, Y. Bengio. Graph Attention Networks. ICLR 2018.
8. A. Vaswani et al. Attention Is All You Need. NeurIPS 2017.
9. B. Gallusser, M. Weigert. Trackastra: Transformer-based cell tracking for live-cell microscopy. ECCV 2024. arXiv:2405.15700.
10. J. Dai, H. Qi, Y. Xiong, Y. Li, G. Zhang, H. Hu, Y. Wei. Deformable Convolutional Networks. ICCV 2017.
11. H. Law, J. Deng. CornerNet: Detecting Objects as Paired Keypoints. ECCV 2018.
12. X. Zhou, D. Wang, P. Krähenbühl. Objects as Points. arXiv:1904.07850, 2019.
13. Q. Xie, M.-T. Luong, E. Hovy, Q. V. Le. Self-training with Noisy Student improves ImageNet classification. CVPR 2020.
14. I. Loshchilov, F. Hutter. Decoupled Weight Decay Regularization. ICLR 2019.
15. I. Loshchilov, F. Hutter. SGDR: Stochastic Gradient Descent with Warm Restarts. ICLR 2017.
16. B. T. Polyak, A. B. Juditsky. Acceleration of Stochastic Approximation by Averaging. SIAM Journal on Control and Optimization 30(4), 838–855, 1992.
17. P. Micikevicius et al. Mixed Precision Training. ICLR 2018.
18. D.-H. Lee. Pseudo-Label: The Simple and Efficient Semi-Supervised Learning Method for Deep Neural Networks. ICML 2013 Workshop on Challenges in Representation Learning.
19. G. Ke, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye, T.-Y. Liu. LightGBM: A Highly Efficient Gradient Boosting Decision Tree. NeurIPS 2017.
20. S. K. Lam, A. Pitrou, S. Seibert. Numba: A LLVM-based Python JIT Compiler. LLVM-HPC 2015.
21. B. X. Kausler, M. Schiegg, B. Andres, M. Lindner, U. Köthe, H. Leitte, J. Wittbrodt, L. Hufnagel, F. A. Hamprecht. A Discrete Chain Graph Model for 3d+t Cell Tracking with High Misdetection Robustness. ECCV 2012.
22. M. Schiegg, P. Hanslovsky, B. X. Kausler, L. Hufnagel, F. A. Hamprecht. Conservation Tracking. ICCV 2013, 2928–2935.
23. Q. Huangfu, J. A. J. Hall. Parallelizing the dual revised simplex method. Mathematical Programming Computation 10, 119–142, 2018.
24. S. Bolusani et al. The SCIP Optimization Suite 9.0. arXiv:2402.17702, 2024.
25. D. G. Lowe. Distinctive Image Features from Scale-Invariant Keypoints. IJCV 60(2), 91–110, 2004.

引用方法

```
@misc{saeedi2026biohubtracking,
  author       = {Saeedi, Jamal},
  title        = {Biohub - Cell Tracking During Development: 6th Place Solution},
  year         = {2026},
  howpublished = {Kaggle competition write-up},
  url          = {https://www.kaggle.com/competitions/biohub-cell-tracking-during-development}
}

@software{saeedi2026biohubtrackingcode,
  author       = {Saeedi, Jamal},
  title        = {biohub\_cell\_tracking\_kaggle: 6th place solution to Biohub - Cell Tracking
                  During Development},
  year         = {2026},
  license      = {MIT},
```

```
  url          = {https://github.com/jamal-saeedi/biohub_cell_tracking_kaggle}
}
```