biohub-cell-tracking-during-development

7位 Solution

Rank	7
Team	tatsutaka
Author	tatsutaka
Topic ID	744937
Version	Japanese Translation

Source: https://www.kaggle.com/competitions/biohub-cell-tracking-during-development/discussion/744937
Retrieved with Kaggle CLI on 2026-10-04.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

Biohub Cell Tracking During Development で7位になりました。主催者の皆さま、データ提供者の皆さま、そしてコンペ期間中にディスカッションやコードを共有してくださったすべての方に感謝します。

私のアプローチは、**単一の 3D nnU-Net（ResEncM）で細胞の位置と動きを予測し、専用モデルで細胞分裂（division）を評価し、整数線形計画法（ILP）で大域的に整合した系譜（lineage）グラフを構築する**というものです。その後、検出漏れ、短い偽のトラック、位置のジッター（揺らぎ）に対処するための後処理を適用しました。

より大きな検出アンサンブルを構築するのではなく、単一の検出器と、その予測を正しい接続へと変換するステップの改善に注力しました。

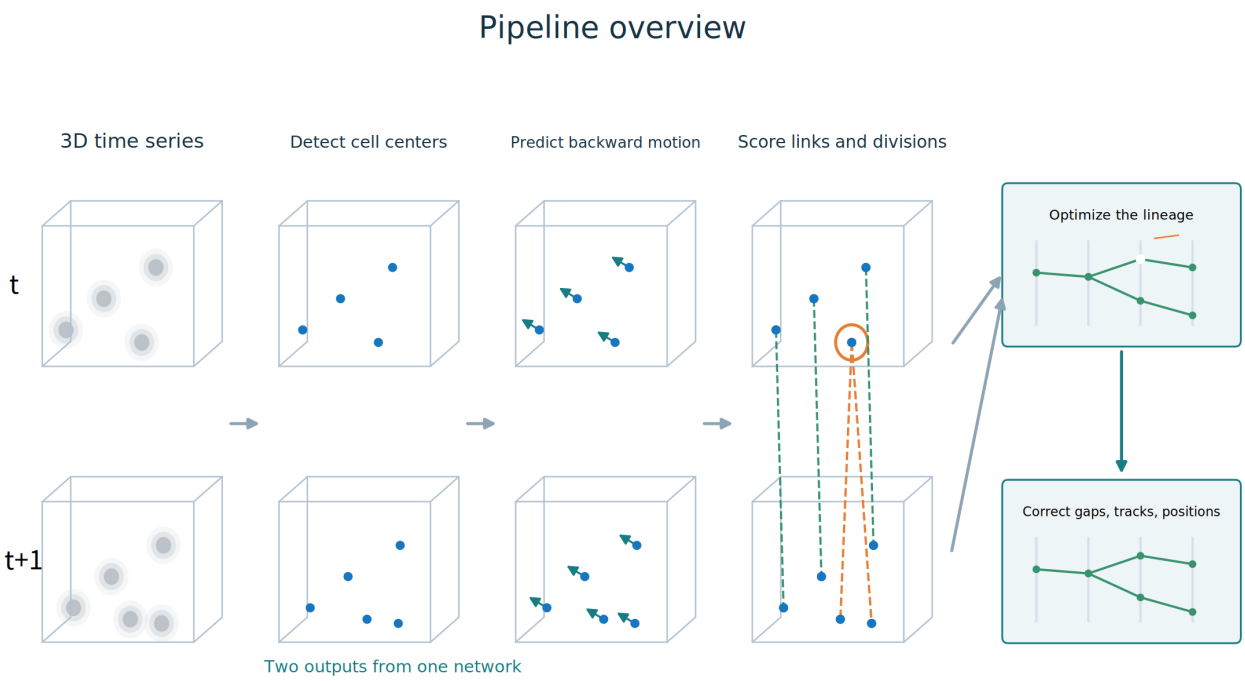


図1: パイプラインの概要。複数時点のボリューム画像を用いて細胞中心と動きを予測し、継続（continuation）と分裂の候補リンクを構築します。系譜の整合性を最適化した後、後処理でギャップ、短い偽トラック、座標に対処します。細胞と系譜は模式図です。

1. 細胞検出と動き予測

1.1 3D nnU-Net（ResEncM）による同時学習

バックボーンは nnU-Net で、residual encoder presets の 3D ResEncM 構成を使用しました。前後の時点を含む3枚の3D画像と、フレーム間隔をエンコードしたチャネルを入力とします。出力は細胞中心の heatmap と、前の時点へ向かう3Dの後方変位（backward displacement）です。

細胞中心の候補は heatmap から抽出し、動きの予測がフレーム間のリンクを導きます。検出と動きで特徴抽出器を共有することで、ネットワークは細胞の見た目と時間的変化を一緒に学習できます。

学習時のパッチサイズは **48 × 128 × 128（Z, Y, X）** としました。最高解像度のデコーダステージを省略し、検出と動きの出力を XY 方向に半分の解像度で出力し、元の解像度へ補間して戻しました。これにより計算量を削減でき、また小さなアノテーションのずれに過度に敏感になるのを避ける狙いもありました。

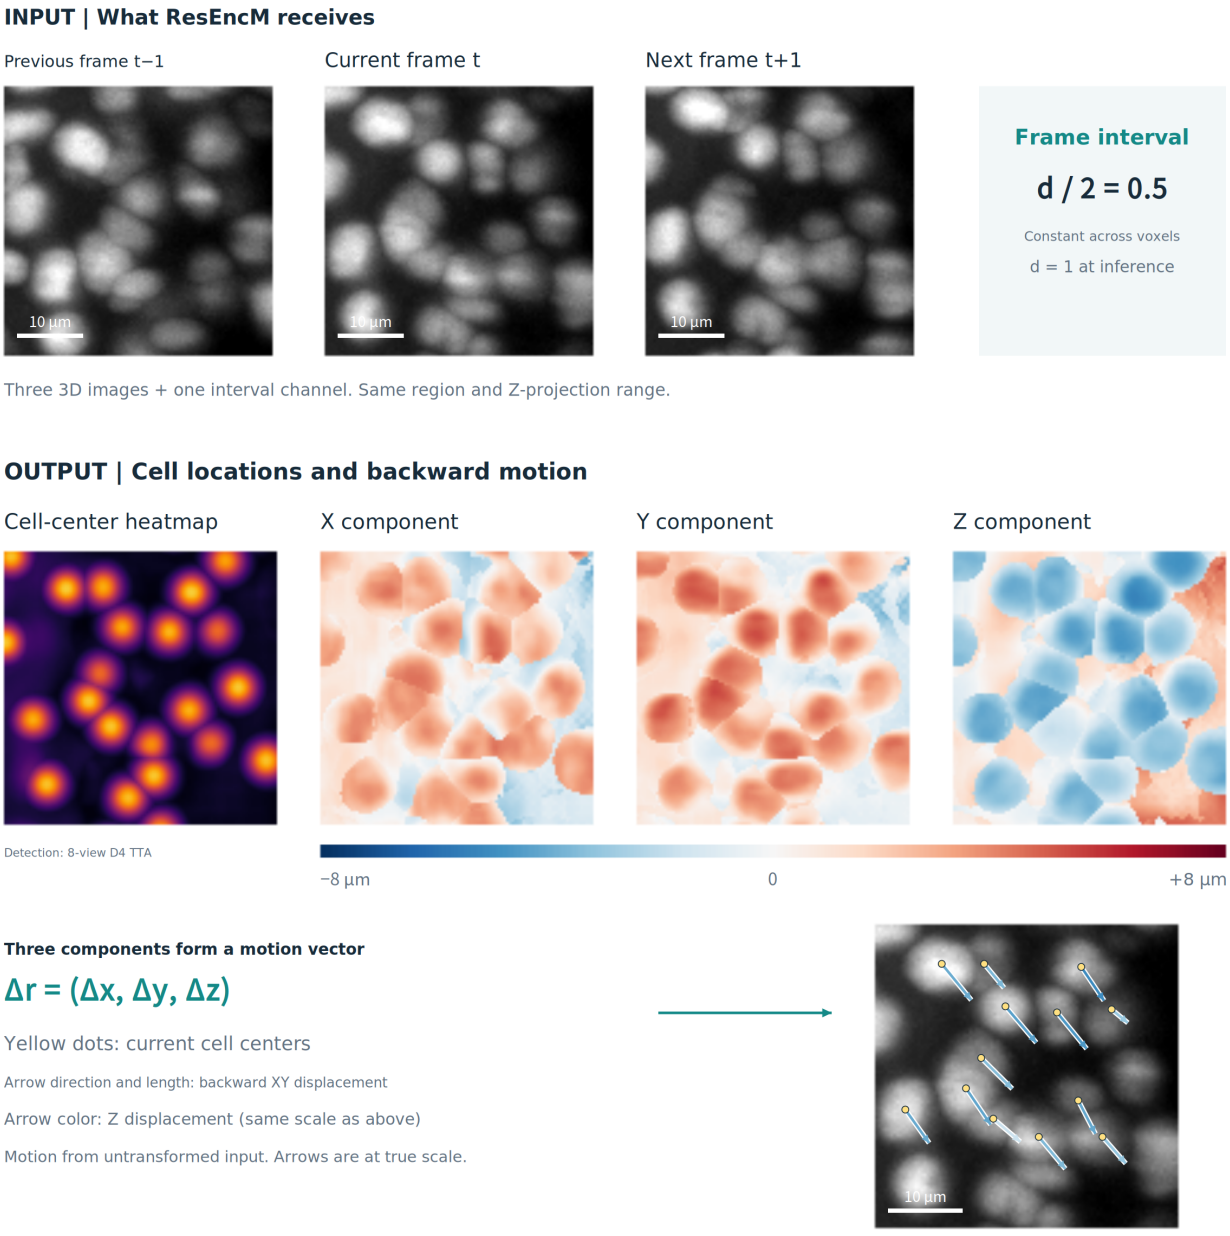


図2: 実際の推論例で、入力と出力を分けて示しています。入力は前・現在・次の3D画像とフレーム間隔です。出力は細胞中心の heatmap、X/Y/Z の動き成分、そしてそれらから得られるベクトルです。画像と heatmap は同じ Z 範囲での最大値投影（MIP）です。各ピクセルにおいて、動き成分は検出確率が最も高い Z 位置から取っています。矢印は現在から過去への XY 変位を実スケールで示し、色は Z 成分を表します。検出には8ビューの TTA を使い、動きには変換なしの入力を使っています。

1.2 ターゲット heatmap とスパースなアノテーション

検出のターゲットは、アノテーションされた各細胞中心の周りのガウシアン heatmap です。しかし、アノテーションされていない領域をすべて負例として扱うと、単にアノテーションがないだけの実在の細胞を抑制するように検出器を学習させてしまう可能性があります。

そこで、アノテーションのない細胞を背景として強く教師付けするのではなく、アノテーションに基づいて損失に寄与する領域を制限しました。

また heatmap の幅も調整しました。ガウシアンが広すぎると隣接するピークが重なり、細胞を分離しにくくなります。狭すぎると位置のずれに対する許容度が下がり、アノテーションのばらつきに敏感になるため、学習が不安定になりうると考えました。検証に基づき、**ガウシアンの標準偏差 σ = 2 µm、3σ = 6 µm で打ち切り**としました。

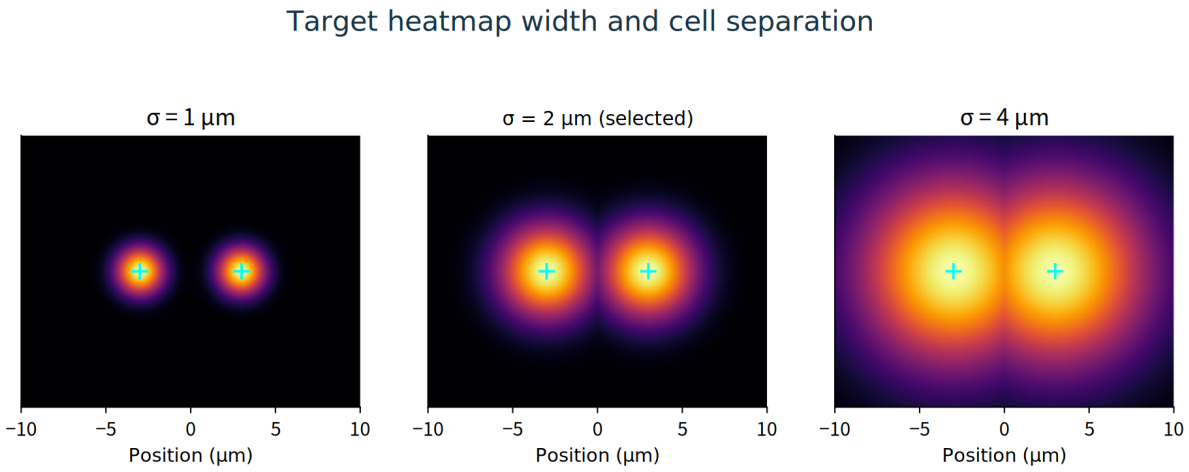


図3: 同じ2つの細胞中心について、ガウシアン幅を変えた heatmap の模式図。中央のパネルが採用した σ = 2 µm です。狭いターゲットはアノテーションのずれへの感度を高め、広いターゲットは隣接細胞の分離を難しくします。

1.3 動きのターゲットと損失

動きの教師には、現在の細胞と、それより前の時点におけるその親または祖先の位置を使います。これらの対応関係は正解の系譜から分かっています。フレーム間隔を d、物理座標を p とすると、後方の動きのターゲットは **v = (p[t−d] − p[t]) / d** です。d で割ることで、より離れた画像で学習する場合でも、ターゲットは1フレームあたりの変位のまま保たれます。さらに数値スケーリングのため 8 µm で割り、ネットワークにはこの正規化された値を回帰させました。推論時には 8 µm を掛け、フレーム間隔を1として直前フレームでの位置を予測します。

動きの損失は、**対応関係が既知の細胞中心から 2 µm 以内**で計算します。σ = 1 µm のガウシアン重みで中心付近の位置を強調します。**XYZ 成分に対する重み付き Smooth L1 損失（正規化単位で β = 0.25）** を検出損失に加算します。教師領域が重なる場合は、より近い中心のターゲットを使用します。

対応点には画像と同じ回転・反転を適用し、変換後の座標から動きのターゲットを構築します。対応関係が不明な細胞や、クロップや変換によって対応関係が得られなくなった細胞は、動きゼロを割り当てるのではなく動きの損失から除外します。分裂については、2つの娘細胞が共通の親に対応するという関係を保持する表現にしています。**動き予測は候補リンクの構築を助けるものであり、それ単体で分裂が起きたかどうかを決めるものではありません。**

1.4 Augmentation

空間的な augmentation には、XY 平面での回転、スケーリング、反転を含めました。Z の解像度は XY より粗いため、補間を伴う回転は XY 平面に限定し、反転は Z 方向にも使いました。空間変換は時点間で一貫して適用しました。

コンペのディスカッションでも指摘されていたように、一部のシーケンスには **freeze 区間** が含まれており、その間は画像がほとんど変化せず、その後に細胞が大きく動きます。これに対処するため、連続フレームよりも離れたフレームを使う時間方向の augmentation を用いました。狙いは、モデルをより大きな変位にさらし、freeze 区間の後でも細胞を対応付けられるようにすることです。

間隔 d のとき、時刻 t における入力は t−d、t、t+d です。学習は d = 1 から始め、次に d = 2、その後 d = 3 を導入します。間隔は入力チャネルとしても与えるので、モデルは異なる時間間隔で観測された見かけ上同じ変位を区別できます。

1.5 合成データでの事前学習

José Freitas さん（josefreitasalvesneto）が共有したコードを使って合成データを生成しました。これは彼の 3D 顕微鏡合成データに関するディスカッション と Biohub Synthetic Dataset notebook によるものです。分裂を含むラベル付き合成データを提供していただいたことに感謝します。

事前学習ありの構成では、検出器を合成データで1,000エポック事前学習し、その後実データで1,500エポック学習しました。



Left: synthetic-data illustration, not the shared dataset. Center/right: real data and trained-model output.

図4: 合成データでの事前学習と、それに続く実画像での学習。左の画像は学習プロセスの模式図、中央は実データ、右は学習済みモデルが出力した heatmap です。合成データの生成は José Freitas さんの共有コードに基づいています。

事前学習に関して、Public と Private のリーダーボードは同じ結論にはなりませんでした。分裂モデリング、グラフ最適化、後処理を固定した比較で、Public スコアは **0.960 から 0.966** に上がった一方、Private スコアは **0.956 から 0.947** に下がりました。総学習量を含むすべての要因を完全に統制した比較ではありませんが、事前学習によって未知データへの汎化が改善したとは言えませんでした。

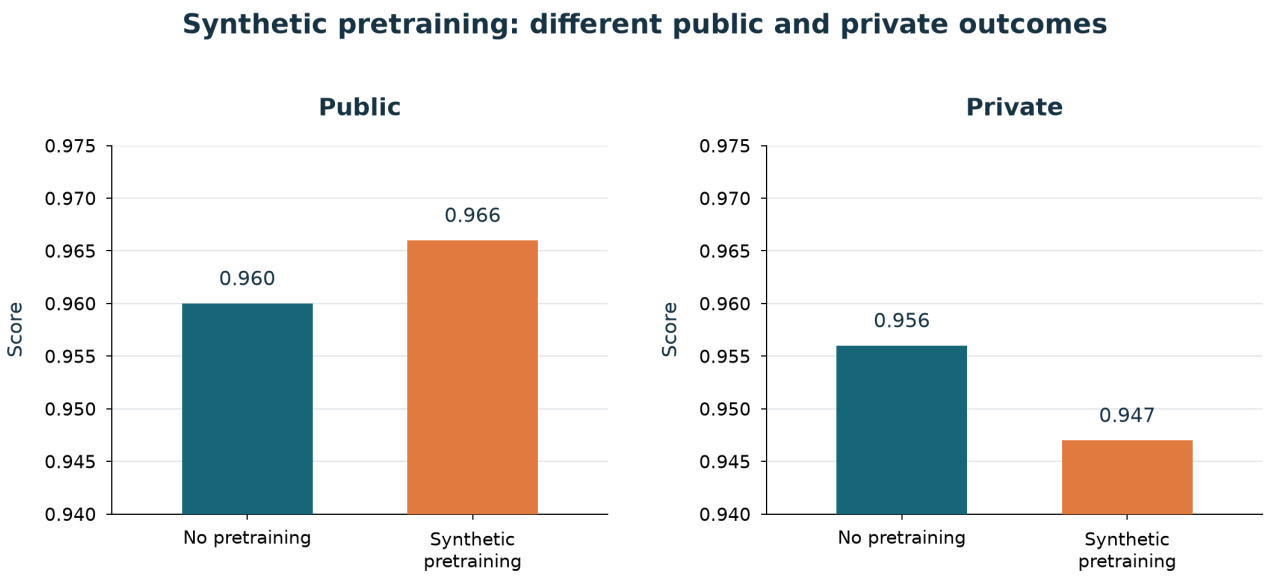


図5: 合成データでの事前学習あり・なしで学習したモデルの比較。検出・動きモデル以外の条件は固定しましたが、事前学習を含む総学習量は異なります。

1.6 推論

検出には、XY 平面での回転と反転による8ビューを使用しました。予測を元の座標系に戻した後、heatmap の logit（確率に変換する前の値）を平均しました。単一検出器のこの test-time augmentation（TTA）は、検出モデルを追加するよりも有用でした。

同じ平均化戦略を動きベクトルに適用しても結果は改善しませんでした。動きについては、変換なしの入力からの予測を使いました。

各フレームは Z-score 正規化し、推論時の時間間隔は1に固定します。細胞中心は heatmap の局所最大値から抽出し、その後 **2 µm** の物理距離で non-maximum suppression を行います。動きの出力は µm 単位の変位に戻され、検出を前フレームの候補と対応付けるのに使われます。

検証と Public リーダーボードの結果に基づき、**ベースラインの検出しきい値として 0.30** を使いました。後に 0.28 を含むより低い値を試し、追加の後処理と組み合わせて 0.28 を採用しました。コンペ終了後に振り返ると、Private リーダーボードではしきい値が低いほど良い傾向がありました。一つの可能性として、より難しい細胞によって heatmap の出力が低い確信度側にシフトしたことが考えられますが、Private の画像や予測分布を確認できなかったため、これは仮説にとどまります。

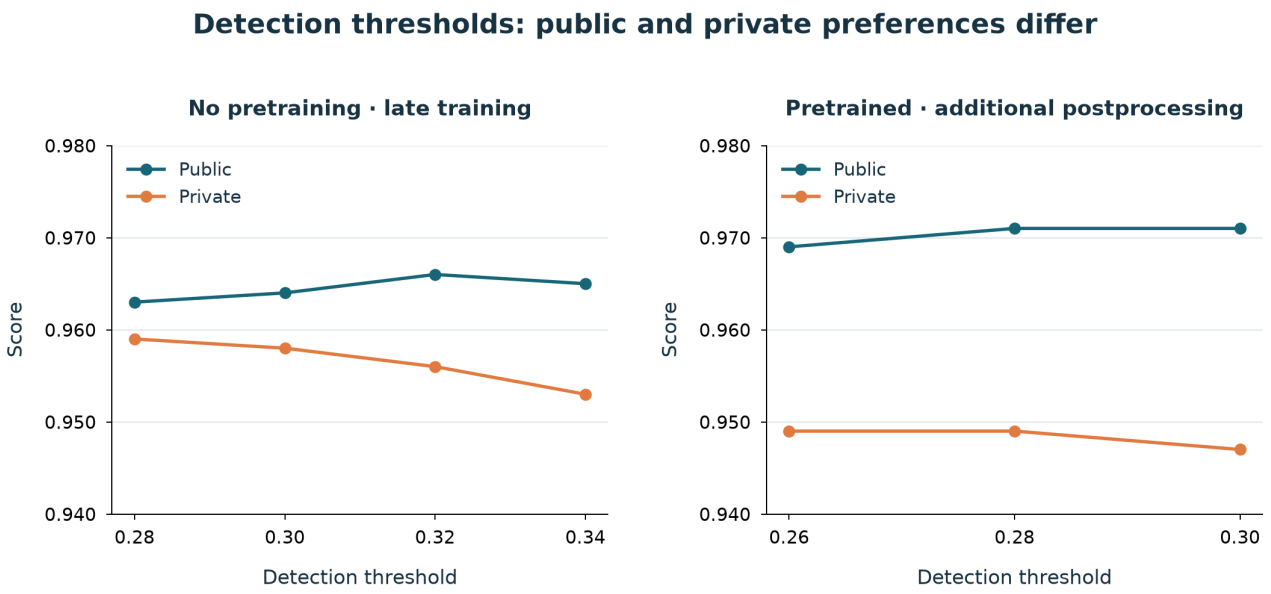


図6: 検出しきい値ごとのサブミッションスコア。左のパネルは事前学習なしの学習後期のモデル、右のパネルは追加後処理ありの事前学習済みモデルです。右パネルの 0.30 の点は実行構成も異なるため、しきい値だけの比較ではありません。Public と Private のリーダーボードで好まれる設定は常に一致するわけではありませんでした。

1.7 動き予測からの時間方向リンク候補の構築

各フレームで細胞を検出した後の問題は、現在の各細胞が前フレームのどの細胞に対応するかです。現在位置に最も近い細胞を選ぶ方法は、大きな動きや混雑した領域で失敗することがあります。そこで、**動きで投影した位置と、前フレームで実際に検出された細胞との距離**を使いました。

モデルは現在のフレームから前のフレームへ向かう後方3D変位を予測します。各検出中心の周りの動き場をガウシアン重み付きでサンプリングし、得られたベクトルを現在位置に加えます。これにより、前フレームにおける予測対応位置が得られます。距離は Z、Y、X で異なるボクセル間隔を考慮して µm 単位で計算します。

投影位置から 7 µm 以内にある最も近い検出を最大5つ保持します。この 7 µm のゲートは**予測からの残差距離**に適用されるもので、細胞が移動してよい総距離に対するものではありません。

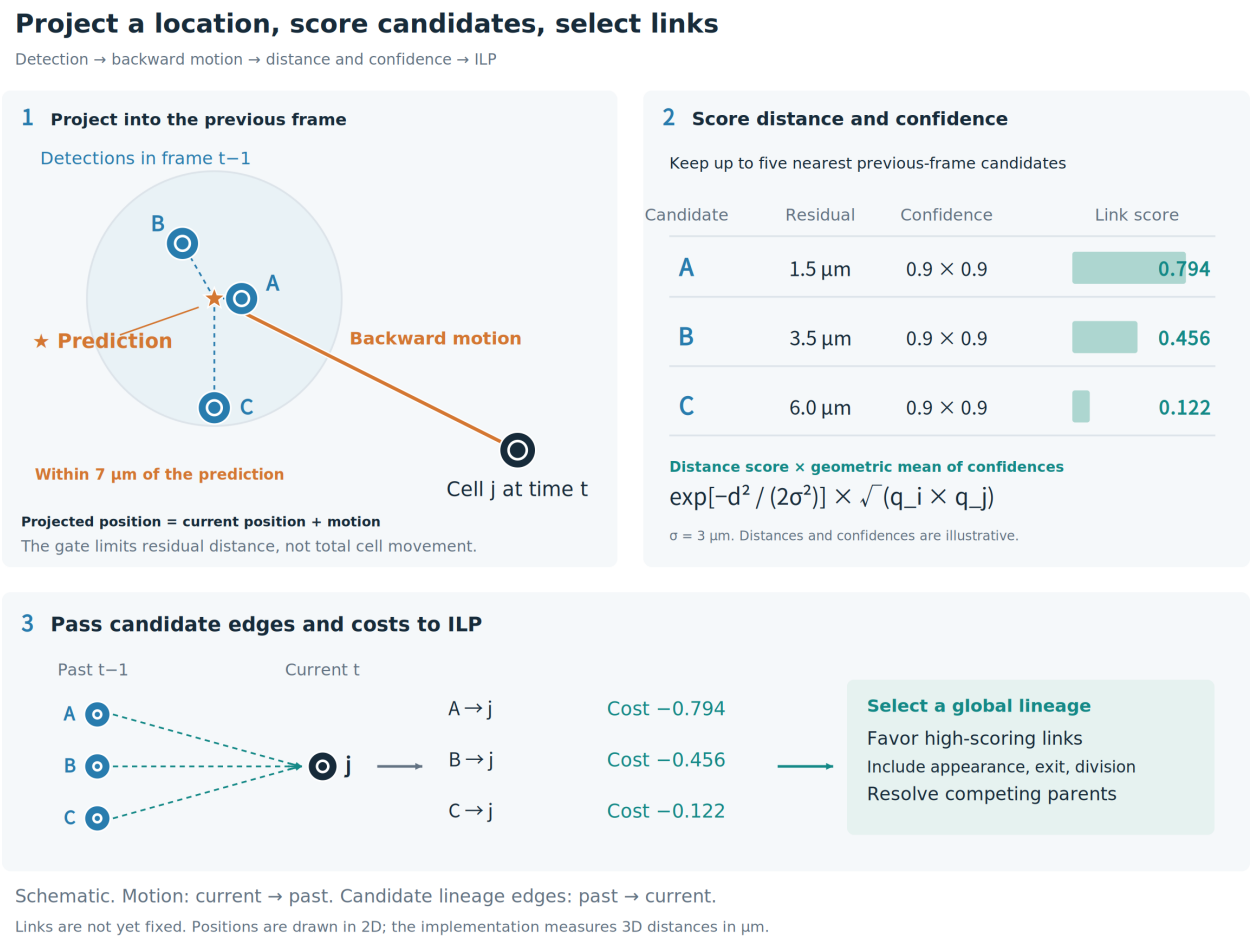


図7: 現在の細胞を前フレームに投影し、近傍の検出への残差距離を評価します。複数の候補 edge とスコアを保持し、最終的な選択は ILP に任せます。動きの矢印は現在から過去を指し、系譜の edge は過去から現在を指します。図中の距離、確信度、スコアは例示であり、測定値ではありません。実装では3D距離を使用しています。

リンクスコアは、残差距離のガウシアン関数に、両端点の検出確信度の幾何平均を掛けたものです。前フレームの候補 i と現在の細胞 j について、残差距離を d_ij、検出確信度を q_i と q_j とすると、スコアは次のとおりです。

$$s_{ij} = \exp[-d_{ij}^2 / (2 \times (3\ \mu m)^2)] \times \sqrt{(q_i \times q_j)}$$

最も近い候補をすぐに選ぶことはしません。候補 edge i→j とそのスコアをグラフに保持し、**$-s_{ij}$ をそのリンクコスト**として ILP の目的関数に渡します。スコアの高いリンクが優先される一方で、出現・消失・分裂のコストや、複数の親を持つことを禁じる制約が系譜全体で同時に考慮されます。以下のセクションで、分裂の評価とグラフ最適化をより詳しく説明します。

2. 細胞分裂専用のパイプライン

分裂を完全に検出ネットワーク内で解決できればシステムは単純になります。しかし分裂の例は限られており、通常の細胞や動きを学習しながら分裂を十分に重視させるのは難しいと感じました。そこで、**分裂の学習に特化した別のパイプライン**を構築しました。

主な役割は3つあります。

1. 候補となる親の周りの局所画像が分裂を示唆しているかを評価する。
2. 候補となる娘細胞のペアをランク付けする。

3. 軌跡と幾何情報を用いて、分裂と通常の継続のどちらがより妥当な説明かを評価する。

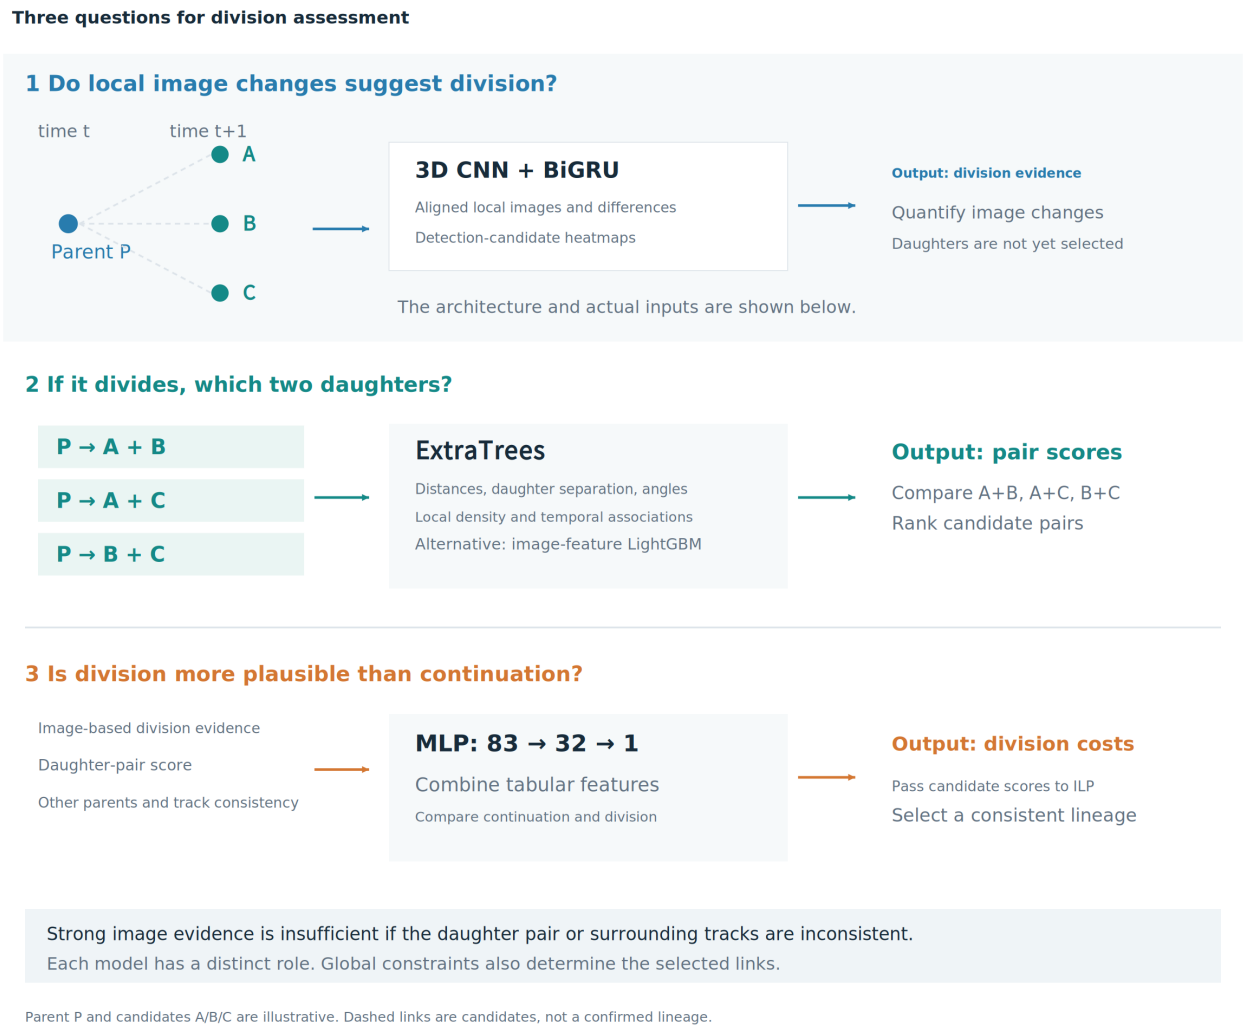


図8: 親 P と娘候補 A、B、C の模式例。局所画像が分裂の証拠を与え、娘の組み合わせは別途評価され、MLP が画像・ペア・軌跡の特徴を統合します。これらの出力は候補を評価するものであり、最終的な接続は ILP の制約の下で選ばれます。

2.1 画像差分を取る前に動きを揃える

分裂周辺の画像を観察すると、明るさや形状に特徴的な変化が見られました。しかし、単純な時間差分には通常の細胞の動きによる強い信号も含まれていました。

画像ベースの分裂分類では、まず周囲の細胞から局所的な動きを推定し、前後の3D画像を位置合わせします。位置合わせ後に差分を取ることで、通常の並進による信号が抑えられ、分裂に関連する形状や明るさの変化が見やすくなります。

入力には、**複数時点の位置合わせ済み画像、符号付き時間差分、その絶対値、検出候補から再構成した heatmap** が含まれます。生画像は形状を表し、符号付き差分は強度が増減した場所を示し、絶対差分は変化の大きさを表します。heatmap は検出された中心とその確信度スコアから再構成したガウシアンで、候補の位置と周囲の細胞配置に関する情報を与えます。

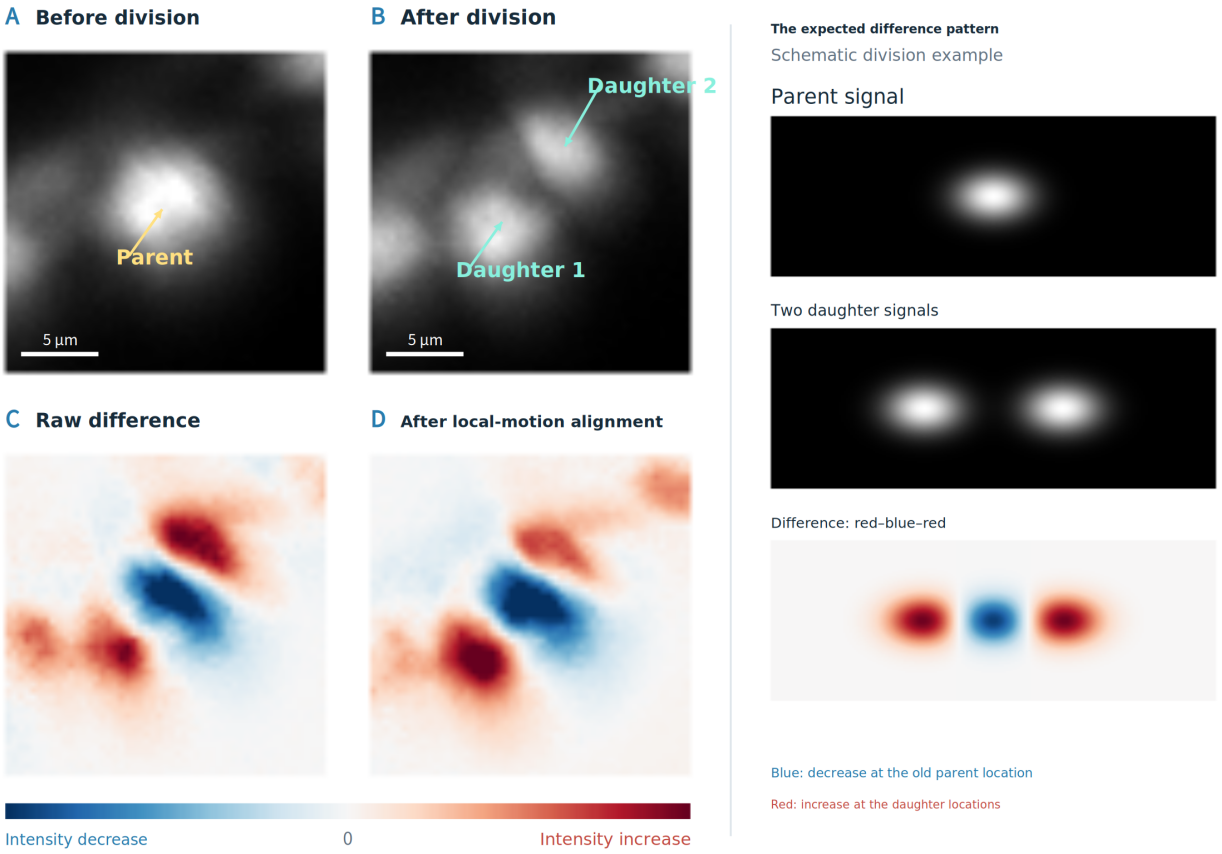


図9: 左上: 分裂前後の実画像。黄色の矢印が親、シアンの矢印が娘細胞を示します。左下: 生の差分と、提出パイプラインで使ったものと同じ3D局所動き推定を、保存済みの検出候補を用いて適用した後の差分。表示のため、差分は Z 方向の最大値投影から共通のカラースケールで計算しています。右のガウシアンの模式図は、古い親の位置での負の信号と、2つの娘の位置での正の信号を示しています。実際のパターンは分裂の向きや強度変化に依存します。

2.2 分裂画像分類器と補助的な教師

画像分類器は、**小さな 3D CNN の後に双方向 GRU（BiGRU）を続けたもの**です。候補となる親の周りの **12 × 48 × 48（Z, Y, X）** のクロップを入力とします。t−2 から t+2 までの5時点で、重なり合う3フレームのウィンドウを3つ作ります。狙いは、単一の静的な形状ではなく、1つの細胞から2つへの遷移を捉えることです。

各ウィンドウには、7つの画像チャネル（画像3枚、符号付き差分2つ、絶対差分2つ）と、検出 heatmap から同じ方法で構築した7チャネルが含まれ、合計 **14チャネル** になります。heatmap チャネルは t−1、t、t+1 を使い、3つの画像ウィンドウで共有されます。

共有の 3D CNN が各ウィンドウを128次元の特徴ベクトルに変換します。BiGRU が時間方向の情報を統合し、それを中央ウィンドウの特徴に残差的に加えます。CNN は 24→48→96→128 チャネルの4ブロック、空間プーリング、global average pooling で構成されています。

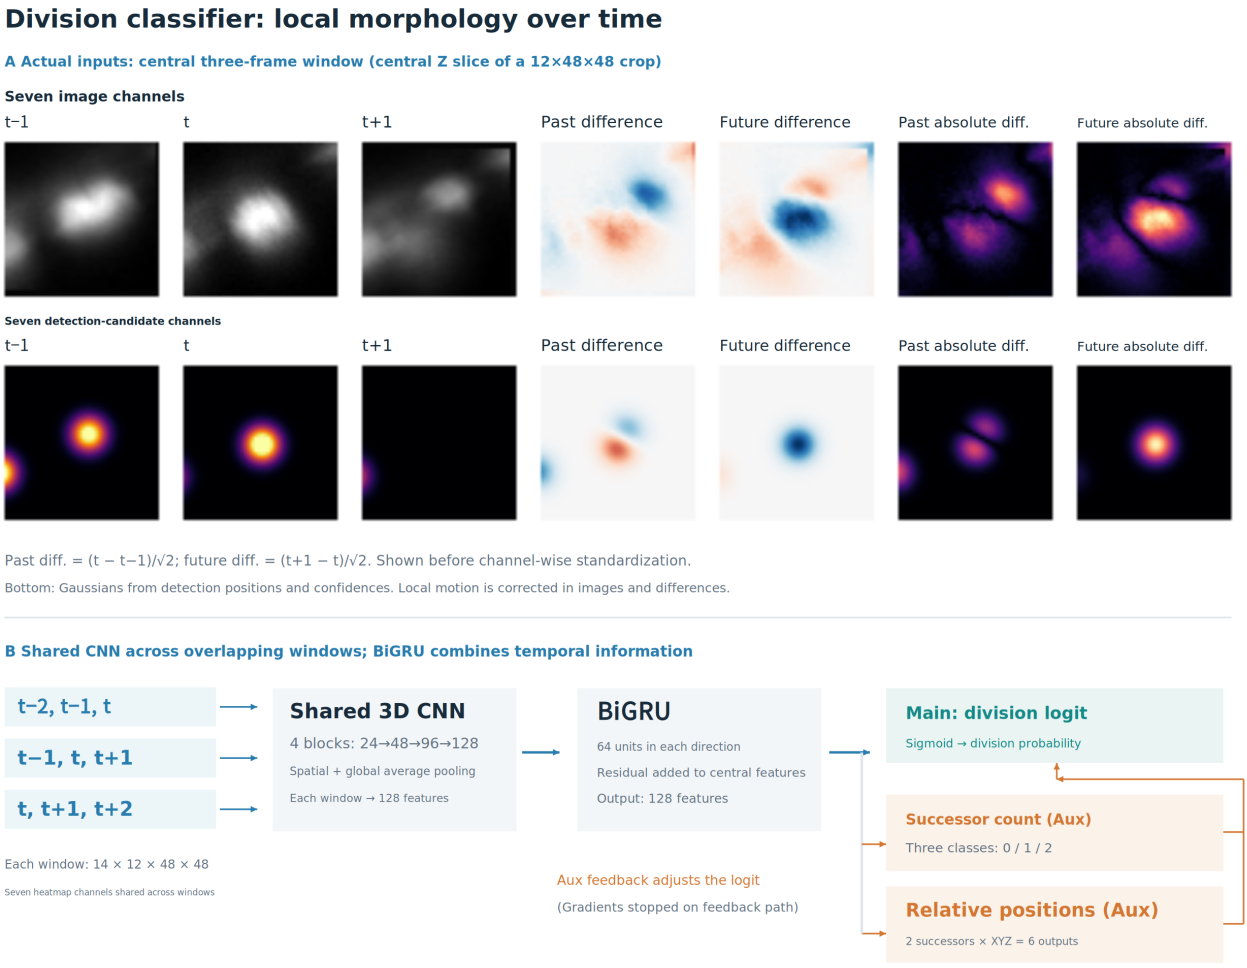


図10: 上のパネルは、提出時の前処理コードを使い、保存済みの検出と実画像から再構成した実際の14入力チャネルを示しています。中央の3フレームウィンドウの Z スライスで、チャネルごとの標準化前のものです。下のパネルは1つのモデルのアーキテクチャです。主出力は分裂の logit で、補助出力は後継細胞の数と相対位置を予測します。「(Aux)」と記された出力は補助的な教師を受けます。

形態変化を捉える特徴を促すため、分裂だけでなく、**次フレームにおける後継細胞の数（0、1、2）** と **最大2つの後継細胞の相対 XYZ 位置** も教師付けしました。損失は、分裂の BCE 損失に、数の cross-entropy と位置の Smooth L1 をそれぞれ重み 0.25 で加えたものです。アノテーションがスパースなため、補助損失は有効なターゲットがある場合にのみ計算します。

また、数と位置の予測を主分類器にフィードバックし、分裂の logit を調整しました。このフィードバック経路では、補助予測への勾配は止めています。**補助出力は分裂分類を支援するものであり、その予測位置が最終的な娘細胞や edge として直接採用されるわけではありません。** 実際の娘細胞は検出された候補から選ばれます。

2.3 分裂する親の特定と2つの娘細胞の選択は別の問題

分裂の判定が正しくても、娘細胞の一方を取り違えていれば系譜イベントとしては誤りです。そこで、親の評価には画像分類器を使い、**娘ペアのランク付けには ExtraTrees 分類器**を使いました。ペアは、同じ候補の親の周りにある次フレームの検出から作られます。

重要な特徴量には、親から娘への距離、娘同士の距離、2つの親→娘方向がなす角度、親と娘の中点とのずれ、近傍の細胞数、検出確信度が含まれます。隣接時点から得られる特徴量は、娘たちがもっともらしく共通の親を持つのか、それとも別々のトラックとして説明した方がよいのかを表します。幾何・時間特徴量は合計73個です。

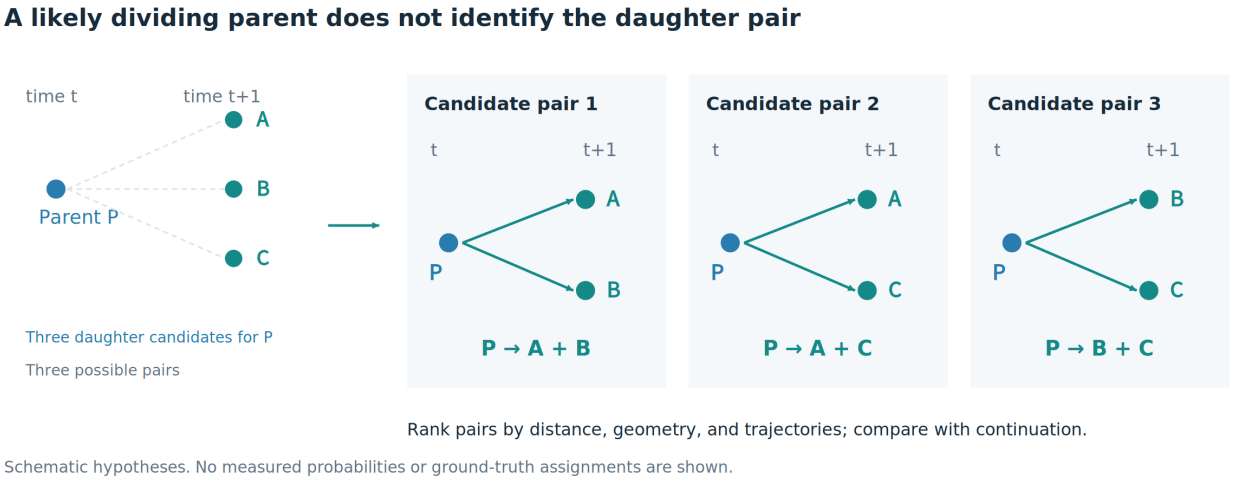


図11: 3つの娘候補がある模式図。親が分裂するという確信度が高くても、正しい娘ペアは別途評価する必要があります。

初期の追跡グラフですでに選ばれた分岐に分裂の評価を限定すると、そこで見逃されたイベントは回復できません。そこで、既存のリンク候補にも評価を広げました。この変更で Public スコアは 0.969 から 0.971 に上がりましたが、その比較での Private スコアはどちらも 0.947 でした。

2.4 局所画像と軌跡・幾何情報の統合

局所画像だけでは、周囲の細胞との整合性や軌跡の妥当性を十分に評価できません。そこで、**83入力、隠れユニット32、SiLU 活性化、1出力の小さな MLP** を使い、娘ペアを含む分裂仮説をさらに評価しました。

83入力の内訳は、73個の幾何・時間特徴量、別の候補親までの距離や通常継続による説明のコストなどの追加特徴量7個、親の検出確信度、画像分類器の分裂 logit、ExtraTrees のペアスコアです。例えば、提案された2つの娘がそれぞれ別の親に近い場合、見かけ上の分裂は実際には2本の通常のトラックかもしれません。こうした代替的な説明を、画像ベースの分裂の証拠とともに評価します。特徴量は標準化し、極端な値はクリップします。

MLP の出力は分裂仮説のコストに変換され、ILP に渡されます。個々の仮説のスコアが高くても、それだけでリンクが決まるわけではありません。選ばれるグラフは、1つの娘に複数の親を割り当てないといった大域的な制約も満たす必要があります。

別の構成では、娘ペアのランカーを LightGBM に置き換え、73個の幾何・時間特徴量に **娘付近の明るさとコントラストを表す18個の画像特徴量** を加えた、合計91特徴量を使いました。

画像特徴量には、各娘の中心強度、小さな近傍内の平均・最大・標準偏差、周囲領域の平均、局所と周囲のコントラストが含まれます。2つの娘にわたる最小値・最大値・差の絶対値を取ることで、これらの特徴量は娘の順序に依存しなくなります。MLP は分裂イベントを評価し、画像特徴量付きの LightGBM は娘ペアをランク付けします。

この構成は Public スコア 0.970、Private スコア 0.952 を達成しました。ただし、他のモデルや最適化の選択も異なっていたため、このサブミッション単独では個々のコンポーネントの寄与を切り分けられません。

3. 整数線形計画法による整合した系譜の選択

候補を独立に選ぶと、1つの娘に複数の親を割り当てるなど、整合しないグラフが生じることがあります。候補の評価をコストに変換し、整数線形計画法（ILP）で接続を同時に選択しました。

3.1 1回目の ILP で暫定的な系譜を生成する

1回目の ILP では、検出と動きからの候補 edge を、画像ベースの分裂スコアおよび娘ペアのスコアと組み合わせます。**この段階ですでに分裂が**通常の継続とともに**含まれています**。出現・消失・分裂のコストを、各細胞が複数の親を持たないといった制約と組み合わせて、動画全体で整合した暫定的な系譜を生成します。

3.2 分裂仮説の再評価

暫定系譜の分岐から出発して、代替の娘ペアを評価します。例えば、P が A と B に分裂したように見えても、別の親 Q が B に近ければ、通常のリンク P→A と Q→B の方が自然な説明かもしれません。MLP は、画像の証拠、娘ペアの幾何、代替の親までの距離、通常継続による説明のコストを使って分裂仮説を再評価します。

選ばれた分岐だけを評価すると、1回目の ILP で見逃された分裂を回復できません。そこで、まだ再評価されていない既存の分裂候補も含めます。これらの追加仮説も、検出と動きから構築した候補 edge と整合する親–娘の組み合わせでなければなりません。

3.3 コストを更新して再度最適化する

MLP の出力は娘ペアに対する報酬またはペナルティに変換され、親–娘の2本の edge を同時に選ぶコストに加算されます。もっともらしい分裂は促進され、通常の継続で説明した方がよい仮説にはペナルティが課されます。その後、元の候補グラフ上で再び ILP を解き、競合するリンクを再検討します。重要なのは、**1回目の系譜を固定してその分岐を局所的に編集するのではなく、更新されたスコアで大域的に再最適化すること**です。

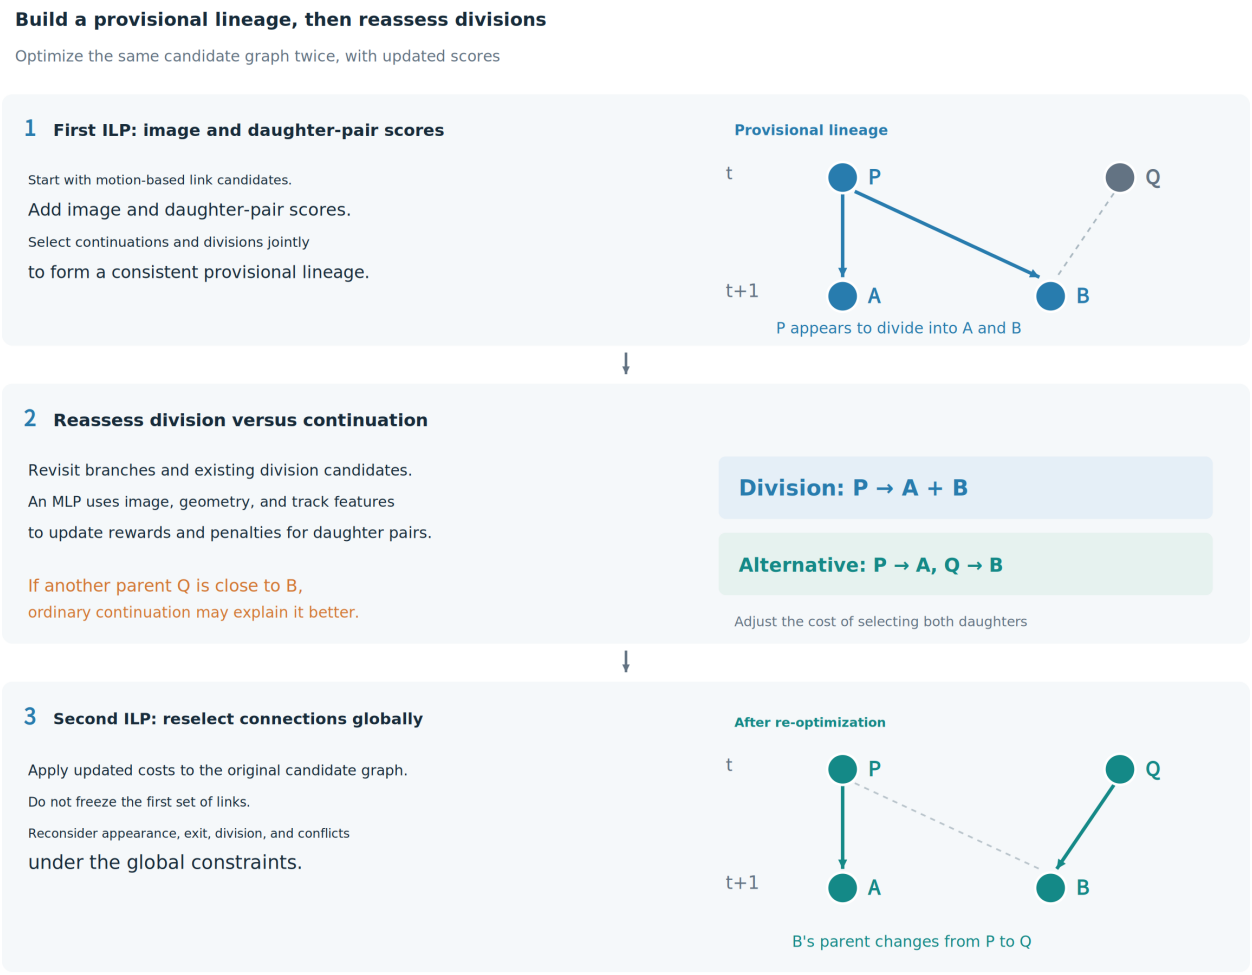


図12: 2段階 ILP。1回目の求解ですでに分裂を含み、暫定的な系譜を生成します。その後、分裂仮説と代替案を再評価し、同じ候補グラフ上でリンクを再び選択します。右の例では、P による見かけ上の分裂が、別の親 Q からの継続として再解釈されています。これは仮想的な例示であり、測定結果ではありません。

別の構成では、分裂候補を含めた単一段階の最適化を使いました。1段階に切り替えると選ばれるグラフが変わりうるため、単なる実行順序の変更ではありません。したがって、構成間のスコアの差には、分裂モデルの違いだけでなく最適化の違いも含まれます。

4. 後処理で対処したエラー

観察されたエラーに対応して、公開 notebook も参考にしながら後処理を追加しました。主な対象は、短時間の検出ギャップ、弱い短いトラック、分裂付近や動画の境界付近のトラック、そして freeze 区間中を含む座標のジッターでした。

4.1 ギャップ補完、短いコンポーネントの選別、座標補正

追加後処理ありの構成では、以下の操作を使いました。短いトラックの判定では、個々の分岐の長さだけでなく、連結成分のノード数を考慮します。

対象	判定と補正	安全策
1フレームの欠落	t でのトラック終端と t+2 でのトラック始端を、端点間 9 µm 以内で1対1にマッチングします。補間した中点から 3.2 µm 以内に孤立ノードがあればそれを再利用し、なければ中点付近の画像を用いて位置を精緻化したノードを挿入します。	始端ノードや中間ノードを2回以上再利用しない。新規ノードは元のノード数の約2%まで、かつ最大2,000に制限。
短い孤立コンポーネント	デフォルトでは、ノード数が9未満の連結成分を削除します。	分裂を含むコンポーネントは保護。8ノードのコンポーネントは、平均リンクスコアが0.5以上なら保持可能。
境界および内部の短いコンポーネントの復元	最初または最後のフレームに接する3〜8ノードのコンポーネントを、近傍の検出に比べて確信度が高い場合に復元します。5〜7個の連続ノードからなる内部コンポーネントも、リンクスコアと相対的な検出確信度が高い場合に考慮します。	平均確信度比が1以上で、かつ過半数のノードで比が1以上であることを要求。内部の復元は、既存グラフとノードを共有しないコンポーネントに限定。
過剰な復元	境界および8ノードの復元候補について、ノードの過半数が同じ時点のベースライングラフのノードから 7 µm 以内にある場合、そのコンポーネントを削除します。	内部の8ノードコンポーネントが8個以上ある場合、平均検出確信度が25パーセンタイルのしきい値を下回るものも削除。
トラックに沿った座標ジッター	一意にたどれる近傍（各方向に最大4ステップ）に直線をフィットし、元の座標40%とフィットした座標60%をブレンドします。	過剰な変位を避けるため、各ノードの補正を 2 µm に制限。

すべての短いトラックを削除すると、分裂直後や動画境界付近の実在する細胞も捨ててしまいます。そこで、**偽のコンポーネントの削除と、証拠に支えられた短いコンポーネントの保護・復元を組み合わせました**。表はこの追加後処理の構成について記述したもので、これらの設定はすべての実験で共通だったわけではありません。

4.2 接続を変えずに freeze 中の座標を揃える

隣接する3D画像がピクセルレベルで完全に一致する場合に freeze と判定します。そのような区間内では、分岐点とその直近の隣接ノードを除いて、1対1のチェーンを最初の実際の検出の座標に揃えます。ノード数、タイムスタンプ、edge は変更せず、ギャップ補完で挿入されたノードは座標のアンカーとして使いません。

正しい接続であっても、freeze 中には座標のジッターが生じることがあります。この場合、グラフのリンクを追加せずに座標を補正することが有用でした。同じ40本の開発用動画で、ノード数や分裂数を変えることなく、総合スコアが 0.960897 から 0.962707 に改善しました。座標補正は正解とのマッチングも変化させ、Edge TP が17増え、FP が34減りました。これは開発中に使用したセットでの比較であり、未知データでの独立した評価ではありません。

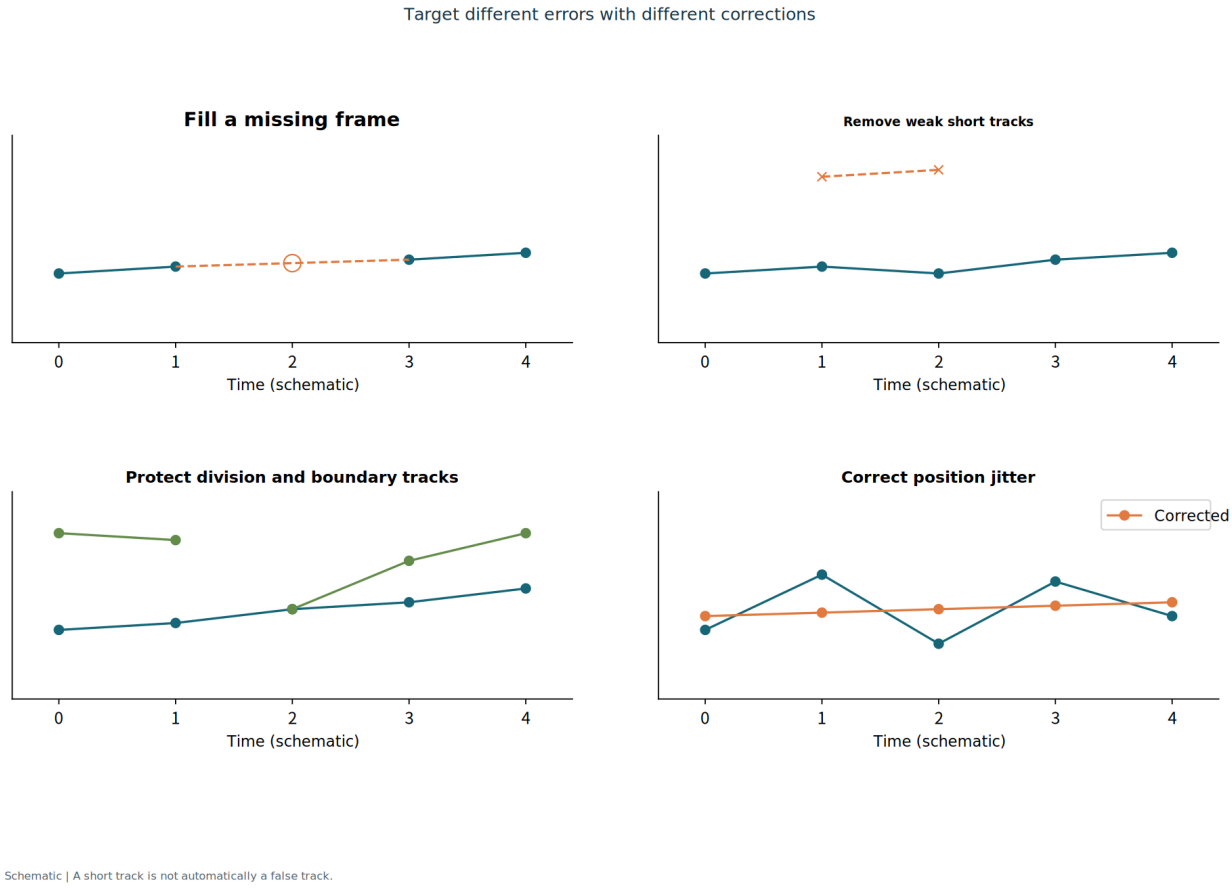


図13: 後処理の目的の模式図。実際の予測の前後や、選択した正確なパラメータを示すものではありません。

しきい値 0.28 での2つのサブミッションは、どちらも Public リーダーボードで 0.971 でした。Private スコアは追加後処理ありで 0.949、なしで 0.947 でした。ただし、検出器を変えた後では、同じ後処理が必ずしも効果的ではありませんでした。検出漏れや偽陽性のパターンが変わりうるため、end-to-end での評価が重要です。

5. 動き予測の平均化が役に立たなかった理由

検出の TTA だけでなく、動きの TTA も試しました。元の座標系に戻した後にベクトルを平均する方法に加え、変換ごとの予測が示す親候補に投票する方法や、その投票を距離で重み付けする方法も試しました。

異なるビューが異なる親を指している場合、それらの平均ベクトルは候補の間を指すことがあります。**その平均終点の近くに別の細胞があると、平均化によって元の予測が支持していない接続が優先される可能性があります。** ベクトルの分散を減らすことは、正しい親を特定することと同じではありません。最終的な接続は他のコストや ILP の制約にも依存するため、平均終点の近くの細胞が必ず選ばれるわけではありません。

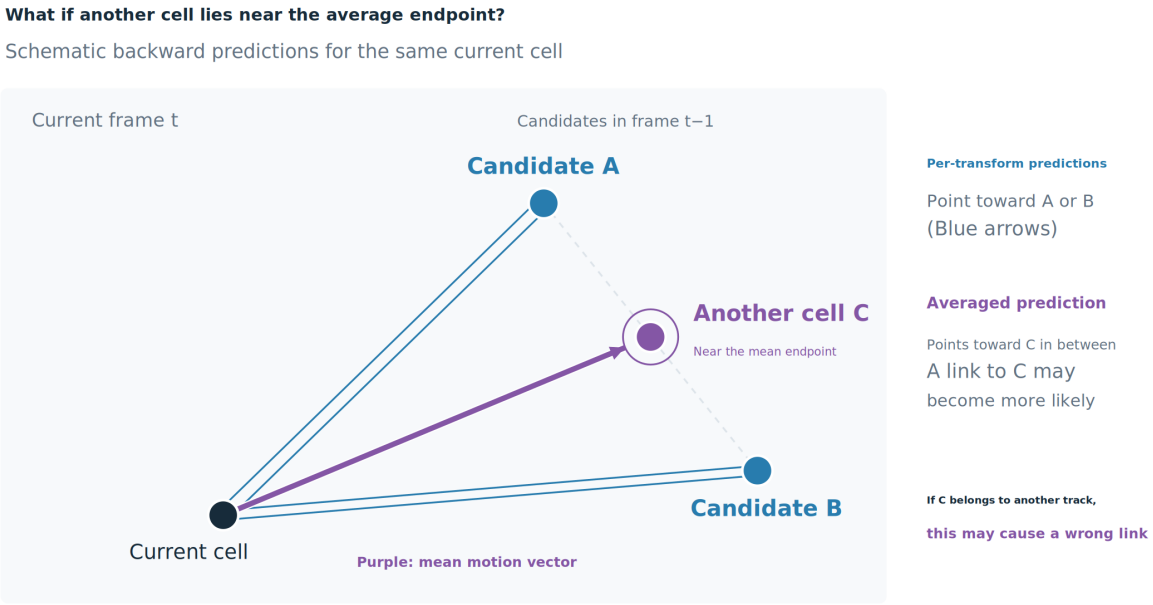


図14: 個々の変換による予測は A または B を指していますが、別の細胞 C がその平均終点の近くにあります。紫の矢印は平均化された動き予測であり、確定したリンクではありません。C が別の軌跡に属する場合、平均化によって誤接続のリスクが高まる可能性があります。配置は例示であり、測定された性能低下の主因を立証するものではありません。

12本の開発用動画で、動画ごとに100フレームを使い、分裂候補のスコアを固定してこれらの方法を比較しました。ノード数補正を含む動画間の平均 Edge Jaccard は、変換なしの予測で 0.91931、ベクトル平均で 0.91619、親への投票で 0.90218、距離重み付き投票で 0.91433 でした。変換なしの動き予測が最も良い結果でした。これは開発データでの診断的な比較であり、未知データでの評価ではありません。

これらの方法で結果が改善しなかったため、変換なしの動き予測を使いました。検出と時間方向の対応付けでは、予測の平均化に対する反応が異なっていました。

6. Public と Private の結果の違い

コンペ終了後にサブミッション履歴を振り返ると、Public リーダーボードでの改善が必ずしも Private での改善につながっていなかったことが分かりました。

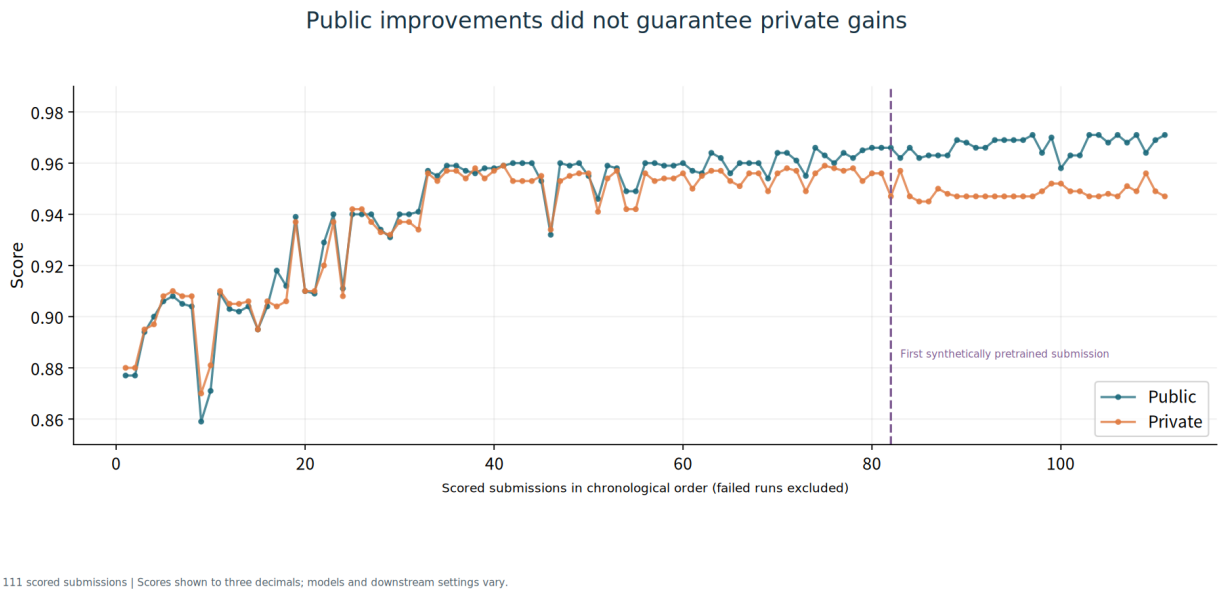


図15: スコアが付いた111件のサブミッションを時系列順に並べたもの。失敗した実行などスコアのないサブミッションは除外しています。これらは同じ評価セットへの繰り返しのサブミッションであり、独立した実験ではありません。

開発プロセスは大まかに以下の期間に分けられます。日付は UTC です。スコアは代表的な構成の Public/Private のペアであり、各期間内の別々のベストスコアを組み合わせたものではありません。

期間	主な取り組み	代表的な Public/Private スコア	観察されたパターン
7月下旬〜8月	検出と動き、8ビューの検出 TTA、ギャップ補完、座標補正	.877/.880 → .909/.910	両方とも改善し、差は小さい。
9月7日〜12日	分裂コスト、画像ベースの分裂分類、娘ペアの選択、2段階最適化	.939/.937 → .957/.956 → .959/.959	分裂の扱いの改善が、両方の大きな改善と同時に起きた。
9月13日〜16日	分裂分類器の比較、誤ったペアの棄却、境界処理と後処理	.960/.956	Public での一部の改善は Private に引き継がれなかった。
9月17日〜21日	事前学習なしでの学習後期の調整、検出しきい値の探索	.964/.957 → .966/.956	Public は改善したが、Private はほぼ横ばい。
9月21日〜22日	合成データで事前学習した検出・動きモデルへの切り替え	ペア比較: .960/.956 → .966/.947	差が大きく広がった。
9月23日〜24日	分裂分類器の再学習、評価対象の分裂候補の拡大	.969/.947 → .971/.947	Public は改善、Private は変化なし。
9月26日〜29日	分裂と娘ペアの改良、最適化と実行時間の変更、追加後処理	例: .970/.952 と .971/.949	一部の構成で Private スコアが部分的に回復した。

事前学習なしの学習後期モデルでは、しきい値 0.28 で **.963/.959**、しきい値 0.32 で **.966/.956** でした。したがって、事前学習に切り替える前から、Public と Private が異なる設定を好む兆候がありました。このタイムラインは記述的なものであり、各期間の変化を単一の要因に帰属させるものではありません。

Private の大きな改善と関連した初期の変更には、分裂コストの調整や、グラフ選択における娘ペアの明示的なモデリングがありました。対照的に、事前学習や分裂評価の拡大など、Public スコアを上げた後期の変更は、ペア比較において対応する Private の改善をもたらしませんでした。

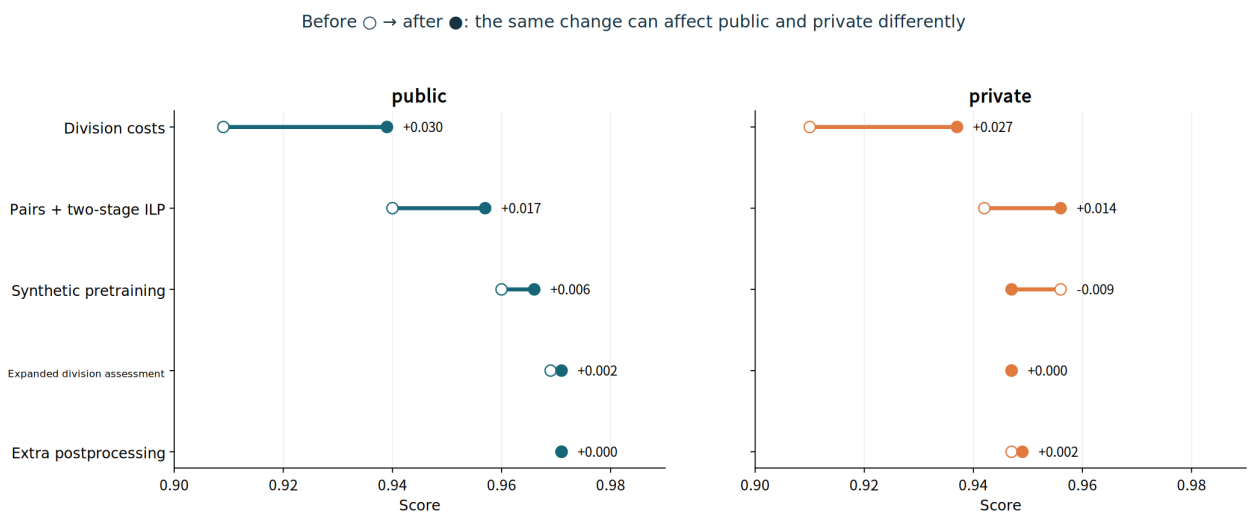


図16: 変更前後のサブミッションの比較。分裂コストの調整で Private は 0.910 から 0.937 に上がり、娘ペアのモデリングと2段階最適化を含む変更で 0.942 から 0.956 に上がりました。後者を含め、複数のコンポーネントを変更した比較では、単一コンポーネントの寄与を切り分けることはできません。

7. おわりに

このソリューションの主眼は、個々の細胞や分裂の候補を、完全な系譜の中でどのように選択するかにありました。スパースなアノテーションを考慮した検出学習、時間間隔の augmentation、専用の分裂モデル、大域的に整合したグラフ選択、そして観察されたエラーに合わせた後処理を組み合わせました。

また、モデルの追加、予測の平均化、Public スコアの改善が、必ずしも未知データでの性能向上につながらないことも分かりました。検出・継続・分裂を個別に検査し、そのうえで実際に出力されるグラフを end-to-end で評価することが重要でした。

参考文献

- Isensee et al. (2021). **nnU-Net: a self-configuring method for deep learning-based biomedical image segmentation.** Nature Methods, 18, 203–211. Paper · Code
- Isensee et al. (2024). **nnU-Net Revisited: A Call for Rigorous Validation in 3D Medical Image Segmentation.** Paper。この研究では、本ソリューションで使用した ResEncM を含む residual encoder presets が導入されています。
- José Freitas さんの 合成データに関するディスカッション と 生成 notebook。

「模式図」と記した図は基本的な考え方を示すものです。実際の画像や評価結果を示す図については、対応するデータと比較条件をキャプションに明記しています。