biohub-cell-tracking-during-development

11位 Solution

Rank	11
Team	tanbo
Author	tanbo
Topic ID	745092
Version	Japanese Translation

Source: https://www.kaggle.com/competitions/biohub-cell-tracking-during-development/discussion/745092
Retrieved with Kaggle CLI on 2026-10-04.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

まず、公式実装を共有してくださった Biohub の主催者の皆さまと、コード、論文、ディスカッションを共有してくださった参加者の皆さまに感謝します。

私のソリューションは**11位で金メダルを獲得**しました。選択した2つのサブミッションのうち良い方のスコアは **0.94905 Public / 0.94743 Private** です。未知の胚（embryo）への転移、学習中に tracking 用の密な検出特徴量を保持すること、そして学習後の系譜（lineage）選択のキャリブレーションに注力しました。

1. 概要

検出、後方の動き（backward motion）、分裂（division）の予測を1つのモデルとして同時に学習しました。 共有の時間方向 3D U-Net が3つのヘッドに特徴量を供給し、それらを合わせた損失で1回の学習ステップでネットワークを更新しました。検出器の事前学習が初期値を与え、同時学習と実データでの fine-tuning の間、バックボーンとすべてのヘッドは学習可能なままにしました。

パイプラインは3つの学習ステージと、それに続くスコアベースのキャリブレーションとグラフ最適化で構成されていました。

1. 実データのアノテーションと合成データを使って検出器を学習する。
2. 動きと分裂のヘッドを追加し、実データと合成データの教師を使って検出・動き・分裂のコンポーネントを同時に学習する。
3. スパースにアノテーションされた実データで fine-tuning する。
4. 学習済みモデルを固定し、キャリブレーションスコアを最大化するように検出しきい値、候補設定、ILP のコストと制約を調整する。
5. ILP で系譜を再構成し、グラフと座標の後処理を適用する。

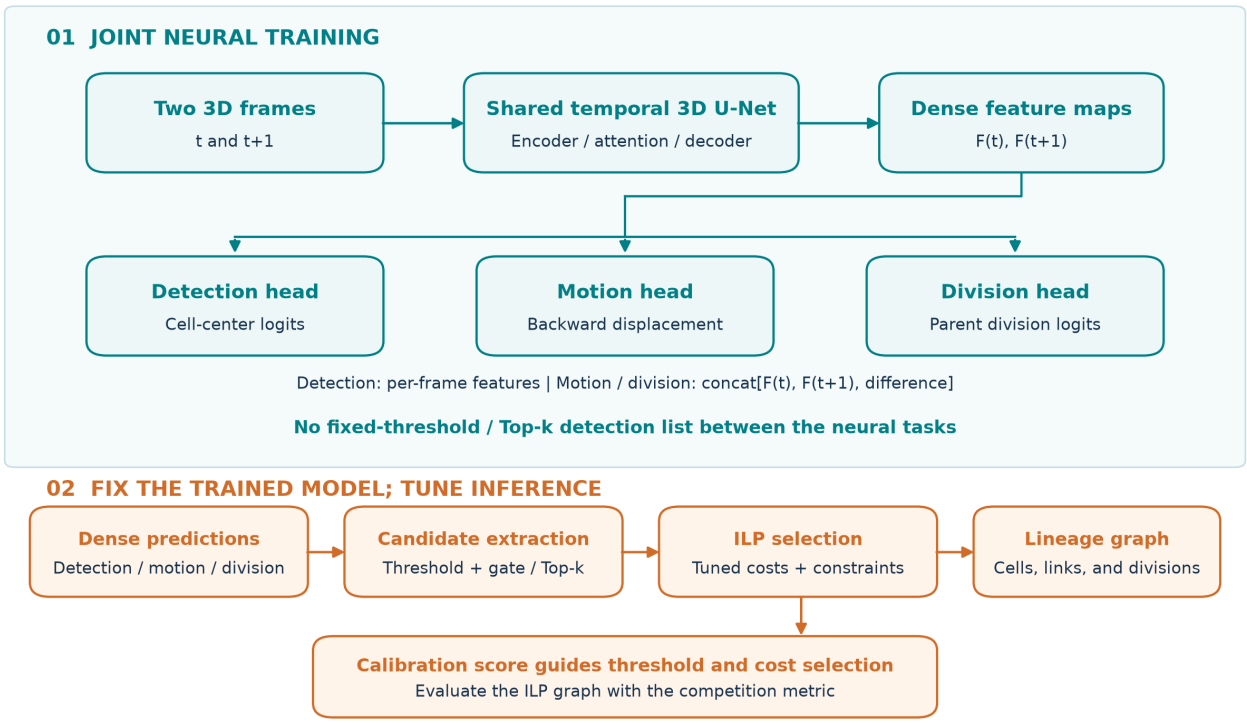


図1. ニューラルネットワークの同時学習の後、キャリブレーションされた候補選択と ILP による系譜再構成を行います。しきい値と親候補数の上限は学習後に適用されます。

2. Validation: 別の胚への転移を優先する

ラベル付きの学習データは2つの胚からのみ得られており、隠されたテストデータは別の胚からのものでした。そのため、アーキテクチャ、合成データ、augmentation を比較する際には、一方の胚で学習してもう一方の胚で評価する実験を使いました。

検出しきい値とグラフのパラメータは、学習後にキャリブレーションデータで調整しました。それらの設定を固定したうえで、得られたパイプラインを validation データで評価し、最終的な性能を見積もりました。

最終実験では両方の胚を使いました。データセットが大きくなることと利用可能な計算資源を考慮し、5-fold の交差検証はコストが高すぎると判断して、代わりに hold-out 分割を使いました。199本の動画を、学習用159本、キャリブレーション用20本、validation 用20本に分け、各分割に両方の胚が含まれるようにしました。

重要な制約があります。後期の validation 動画の一部は、それ以前の検出器の選択やキャリブレーションにすでに関わっていました。これらの結果はその後の変更を比較するのには有用でしたが、パイプライン全体の汎化性能について完全に手つかずの推定値ではありませんでした。また、もう一方の胚で変更を繰り返し比較することで、その胚もモデル開発の一部になってしまいます。

3. 検出と時間方向の予測

2フレームの時間方向 3D U-Net が細胞中心のスコアを予測しました。Linajea にならい、動きのヘッドは後のフレームの各細胞が前のフレームのどこから来たかを推定しました。この予測位置と前駆細胞候補との残差が、対応付けの証拠となりました。

学習中、ニューラルタスク間で固定しきい値や Top-k による検出の選択はあえて避けました。動きと分裂のヘッドには、フィルタリングされた検出リストや最終的な検出スコアではなく、**密な共有特徴量**を与えました。これにより、本来なら tracking で使われる前に捨てられてしまう証拠を保持できました。

動きと分裂の損失は共有の U-Net 特徴抽出器を更新し、最終的な検出ヘッドは検出損失を受け取りました。3つのタスクはすべて学習可能なままでした。ハードなピーク抽出とキャリブレーションされたしきい値は、学習後にグラフ候補を作る際に適用しました。ILP は独立した最適化ステップであり、ソルバーを通した勾配はありません。

スパースな実データのアノテーションについては、アノテーションのない位置を信頼できる背景として扱うのではなく、重みを下げました。ある学習構成では、検出の重みを positive/background/unannotated で 4/1/0.03 としました。合成データの例は、既知のレンダリングされた細胞と系譜から密な教師を提供しました。

4. 合成データと FOCUS-3D の役割

スパースなアノテーションは、ボリューム内のすべての細胞を記述しているわけではありません。学習画像に対する **FOCUS-3D** の中心推定を使って合成シーンを設計し、以下のソースからの統計量を用いました。

合成データの特性	ソース
細胞数、空間的な占有率、最近傍間隔	学習動画に対する FOCUS-3D の中心推定
移動速度と方向の持続性	アノテーションされた学習用軌跡
分裂頻度と娘細胞間の距離	アノテーションされた学習用の分裂
おおよその細胞の見た目、背景、ノイズ	学習画像からの計測値

FOCUS-3D の中心推定は、実際の時間方向リンクや分裂イベントの正解としては使っていません。空間統計量の参考にしたのみで、動きと分裂の統計量はアノテーションされたグラフから得ました。

生成器は、中心、リンク、分裂が既知の動画をレンダリングしました。12フレーム版では動画あたり11組の隣接2フレーム学習ペアが得られ、スパースな実データのアノテーションに加えて密な系譜の教師を追加できました。

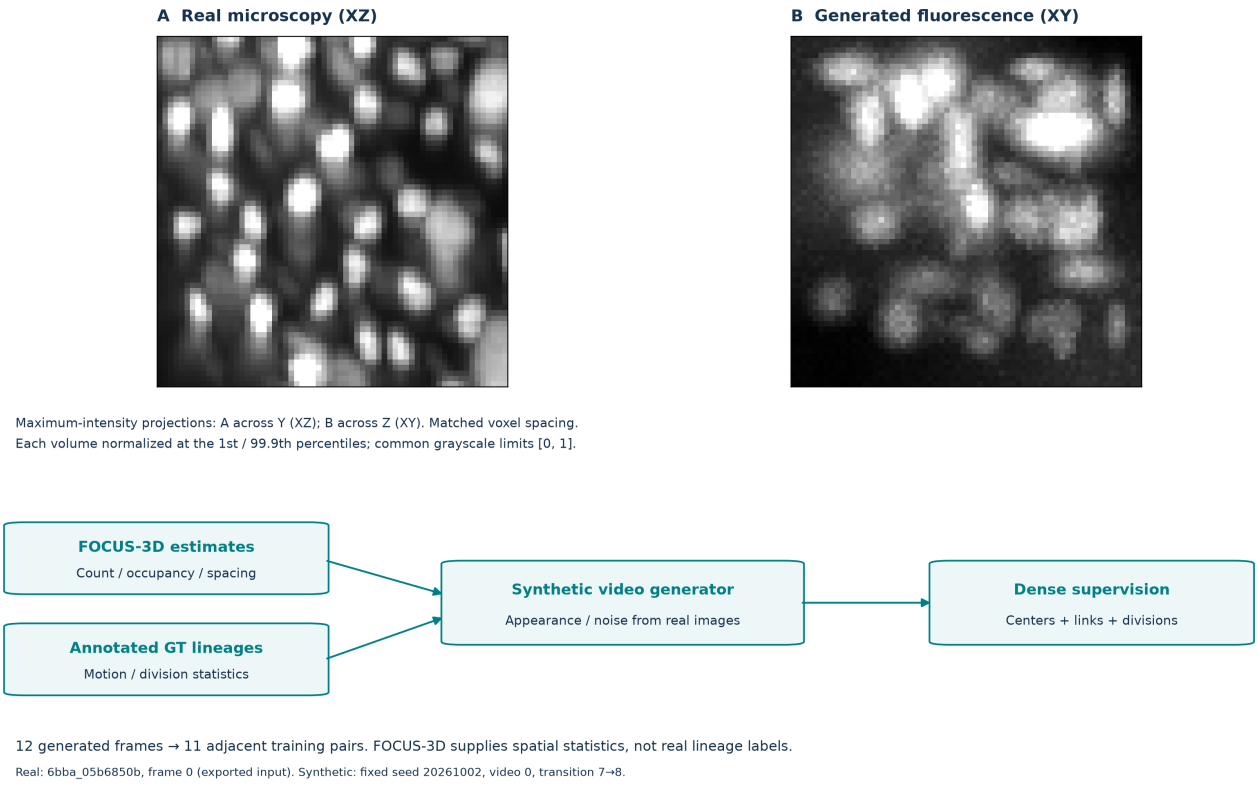


図2. A: 実際の顕微鏡画像、Y 方向にわたる XZ 最大値投影。B: 合成蛍光画像、Z 方向にわたる XY 投影。投影方向が異なります。どちらのボリュームもボクセル間隔を揃え、強度正規化は個別に行っています。合成側のパネルは説明のために保存済みの学習統計量から再生成したもので、精度の比較ではありません。

FOCUS 由来のアフィンストリームも使いました。画像とそのアフィン変換で2フレームのサンプルを作り、対応関係は変換後の中心の ID から得ました。このストリームは合成の対応関係を提供しましたが、分裂の正例ラベルは提供しませんでした。

合成レンダラーは実際の見た目を近似したものでした。インスタンスマスクを正確に再構成したものではなかったため、その有用性は、別の胚への転移を含む実動画での tracking 評価で判断しました。

5. 学習された分裂の事前分布

密な分裂ヘッドは、親が次のフレームで2つの娘細胞を生むかどうかを予測しました。

2つのフレームの特徴マップについて、ヘッドは前のフレームの特徴、後のフレームの特徴、およびその差分を連結したものを使いました。分裂のターゲットはアノテーションされたグラフから導出しました。

- アノテーションされた出力 edge が2本: 分裂 positive。
- アノテーションされた出力 edge が1本: 分裂 negative。
- アノテーションされた出力 edge がない: この損失から除外。

分裂の損失はアノテーションされた親の位置で評価しました。ある同時学習の構成では次を使いました。

```
loss = detection_loss + motion_loss + 2 × division_loss
```

分裂 positive の BCE 重みは10でした。これらは実験的に選んだ値です。

このヘッドは**親ごとの分裂の事前分布（prior）**を提供しました。それ単体で娘細胞を特定するものではありません。分裂を構成するには、依然として娘細胞の候補 edge とグラフの制約が必要でした。

6. 実データでの fine-tuning

混合した教師で学習した後、スパースな実データで fine-tuning を行いました。このステージでは検出、動き、分裂を学習可能なままにしつつ、レンダリングされた合成データと FOCUS 由来の学習ストリームを除外しました。

ある実データのみの fine-tuning 実行では、同時学習のエポック30から再開し、optimizer の状態を引き継ぎ、学習率 1e-4 から cosine decay で開始しました。その修正版サブミッションでは、累積エポック40のチェックポイントを使いました。fine-tuning の後、推論のキャリブレーションのためにモデルを固定しました。

7. 学習後: スコアに合わせて選択と ILP を調整する

公式実装のデフォルトの ILP コストでは、私のモデルにとって最良のコンペスコアが得られないと感じました。ソルバーはグラフのコストを最小化しますが、コンペでは得られた系譜を別の指標で評価します。

学習済みモデルを固定したうえで、ILP の目的関数を最適化するとキャリブレーションデータでより高スコアの系譜が得られるように、リンク、出現、消失、分裂のコストを調整しました。検出しきい値と候補設定もキャリブレーションしました。

このように ILP のコストを調整し始めた途端に、スコアが改善し始めました。 モデルを再学習せずに系譜の選択方法を変えたことが、大きな転機になりました。

例えば、ある修正版の構成では、予測された前の位置と前駆細胞候補との間の後方動き残差を使いました。

```
edge cost = 0.1 × backward-motion residual in μm − 0.25
appearance cost = 0.2
disappearance cost = 0.2
division cost = 0.5 − predicted division probability
```

この構成では 13 μm の候補ゲートと最大5つの親候補を使いました。これらの制限は推論時のグラフに適用したもので、ニューラルネットワークの学習インターフェースには適用していません。分裂には2本の娘 edge が選ばれる必要があり、学習された親の事前分布が、母細胞である可能性が高い位置で分裂コストを下げました。

コストと制約の組み合わせを探索し、それぞれ ILP を解いて、得られた系譜をコンペの評価指標で評価しました。指標はパラメータの選択に使ったのであって、ILP の目的関数を置き換えたわけではありません。

8. サブミッション結果

ステージ	Public	Private	Public–Private の差の絶対値
ベースライン	0.82022	0.79007	0.03015
実データ fine-tuning 前の完成したアーキテクチャ	0.89618	0.89609	0.00009
fine-tuning 済みモデル + 調整済み ILP	**0.94905**	**0.94743**	0.00162

ステージ	Public	Private	Public–Private の差の絶対値
追加の後処理	0.94846	0.94703	0.00143

完成したアーキテクチャから fine-tuning と ILP 調整を加えた段階まで、Public は **0.05287**、Private は **0.05134** 改善しました。これは2つの変更をまとめて測ったもので、それぞれの寄与を切り分けたものではありません。

Optuna で後処理も調整しましたが、提出したバージョンは、fine-tuning 済みモデル + 調整済み ILP と比べて **Public で 0.00059、Private で 0.00040 低い**スコアでした。このサブミッション比較では改善は見られませんでした。

私の解釈としては、別の胚への転移を重視したことが Public と Private のスコアを近く保つのに役立ち、ILP のコストをキャリブレーションしたことがモデルの予測を活かすのに役立ちました。サブミッション履歴は両者を合わせた改善を裏付けていますが、各コンポーネントについて個別の因果的な効果を立証するものではありません。

9. AI コーディングエージェントとの作業

AI コーディングエージェントを使い、関連論文、公式実装、ディスカッションのコピーをリポジトリに置いて、変更を実装する前にエージェントが参照できるようにしました。

これにより、実装上の判断を検証しやすくなりました。スコアへの寄与は測定していません。

10. 改善したい点

両方の胚を使った学習をもっと早く始める。 転移実験は有用でしたが、1つの胚での開発が長引いたことで、より広いデータでの学習が遅れ、完成したサブミッションのための時間が少なくなりました。

独立した最終評価セットを確保する。 開発全体を通じて、検出器の選択やキャリブレーションから隔離された状態を保つ。

条件を揃えた ablation を行い、その効果を記録する。 密な同時学習と離散的な検出を介した学習インターフェースを比較し、さらに fine-tuning、ILP のキャリブレーション、個々の後処理操作を条件を揃えて比較する。これにより、アーキテクチャによる改善とその後の選択による改善を区別でき、複雑さを増すことの正当性を示せます。

参考文献

- Biohub — Cell Tracking During Development
- Official U-Net baseline inference notebook
- Linajea: Automated reconstruction of whole-embryo cell lineages by learning from sparse annotations