biohub-cell-tracking-during-development

12位 Solution：チューニングした公開トラッカーを、計測済みかつフェイルセーフな修復ステージで拡張する

Rank	12
Team	Corwin
Author	Corwin
Topic ID	744501
Version	Japanese Translation

Source: https://www.kaggle.com/competitions/biohub-cell-tracking-during-development/discussion/744501
Retrieved with Kaggle CLI on 2026-10-04.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

Team Corwin（corwin1979, mathisbaguette）· Biohub Cell Tracking During Development

Private LB	Public LB	最終順位	提出	最終カーネル
0.946（私たちの110個の private スコアのうち最良）	**0.970**	**4,017チーム中12位**、金メダル（終了時点の public ボードでは14位）	52日間で112回（スコア付きは109回）	2 x T4、提出からスコアまで6.8〜8.4 h

TL;DR. pilkwang さんの公開検出・リンキングモデルと prvsiyan さんの公開チェーンを（再学習ではなく）チューニングし、その上に独自の4つのステージと1つのライターを構築しました。いずれも計測済みかつフェイルセーフです：グラフの統合（consolidation）、mitosis（細胞分裂）スペシャリスト、学習済み identity link を含む最終修復ブロック、2つのガードを備えた学習済み recentring（再中心化）、そして安全な CSV ライターです。Public は 0.887（8月8日）から 0.970（9月28日）になり、private は 0.946 でした。最大の誤りは validation でした。私たちのフルチェーンのベンチは in-sample であり、private を約 0.03 過大評価していました。それでも、終了後に読んだ全提出の private スコアは、ベースチャンピオン以降に追加したステージが public よりも private で2倍の価値を持っていたことを示しています（+0.013 vs +0.006）。

物差し（Rulers）. すべての数値には、それを測った物差しを明記します。**public** / **private**：リーダーボードの値、小数3桁、ノイズは約 0.003（private スコアは終了後に読んだもので、112回の提出のうち110回分）。**in-sample**：公開ネットワークを用いて199本の学習動画上で公式 metric を再現したもの。公開ネットワークはこれらの動画で学習されています。**OOF**：同じ再現を、fold ごとに再学習した、より弱い独自ネットワークで行ったもの。**cf**：コピーフレームを含まない85本の学習動画（どちらの hidden split にもコピーフレームはありません、2.1節）。**visible**：4本の可視テスト動画で、学習動画のバイトコピーです。**GT**：アノテーション。**world**：ある1つのパイプライン設定による199本の動画上の予測。

---

1. 概要

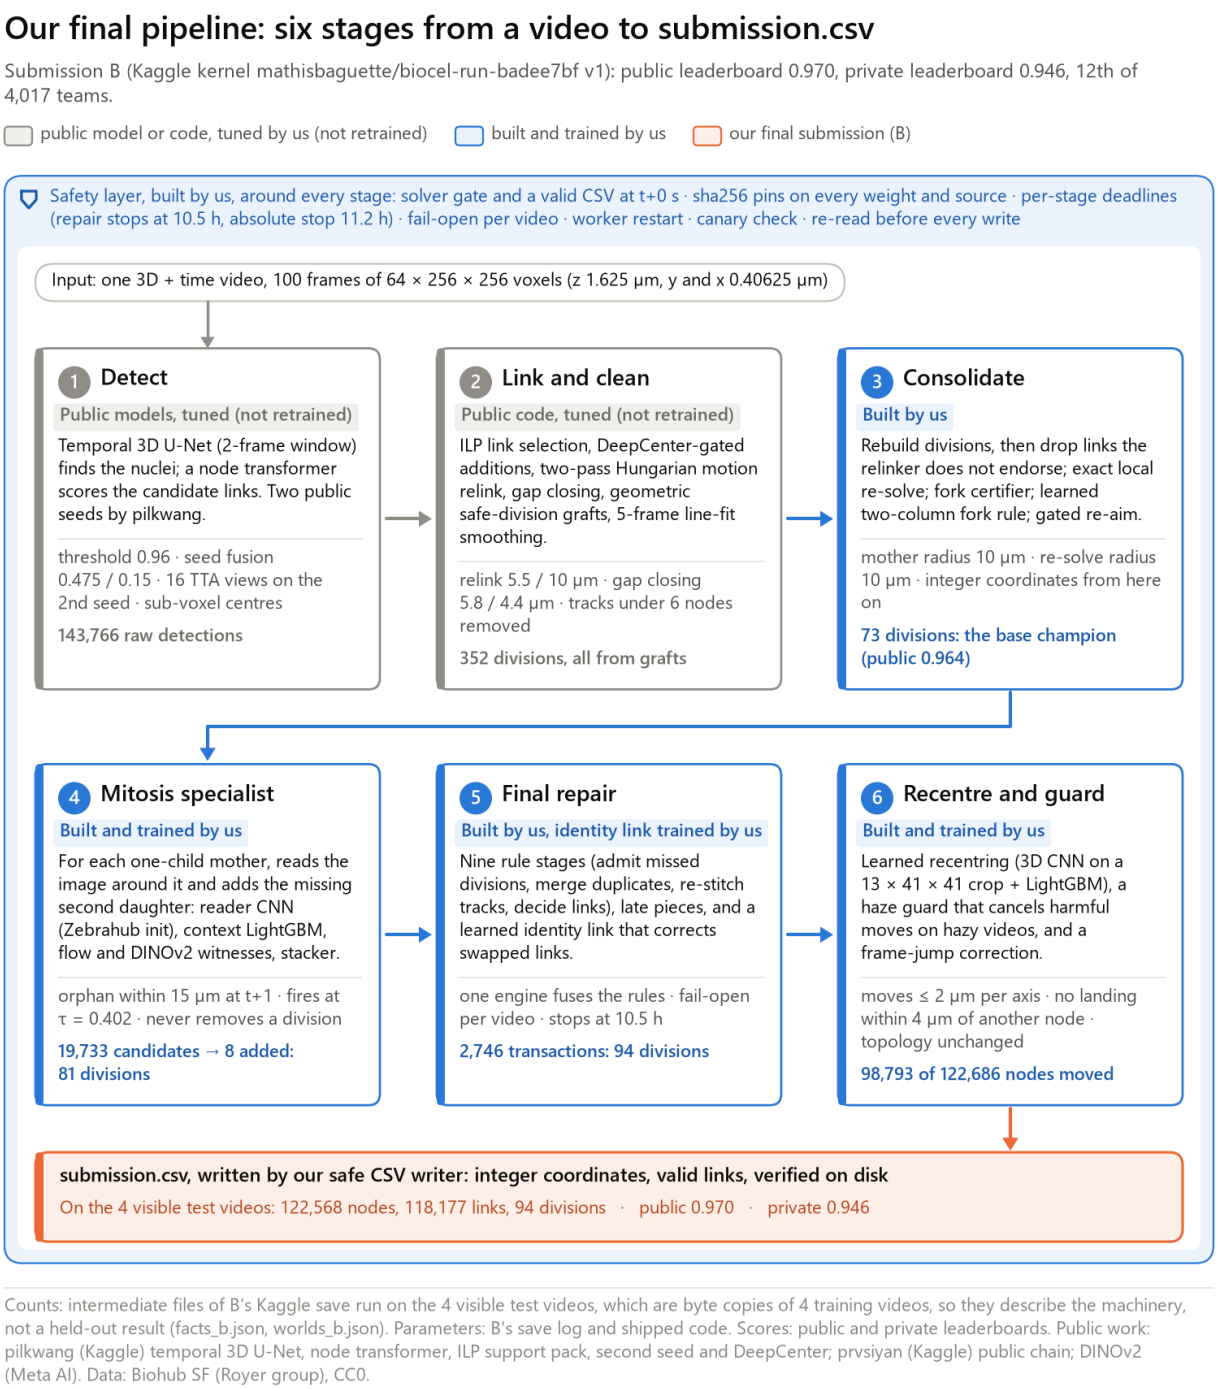


図1. 最終提出 B：6つのステージの後に安全な CSV ライター、全体が安全レイヤーの内側にあります。グレー：公開モデルとコード（pilkwang, prvsiyan）で、私たちがチューニングしたもの（再学習はしていません）。青：私たちが構築・学習したもの。カウントは B の Kaggle save run における4本の可視動画上のものなので、held-out の結果ではなく、仕組みを説明するものです。

各ステージは前のステージのグラフを読み込みます。ステージ1と2は公開のもので、ステージ3〜6とライターは私たちのものです。

#	ステージ	由来	役割
1	検出：temporal 3D U-Net + node transformer、2 seeds、16-view TTA、サブボクセル中心	公開（pilkwang）、チューニング（再学習なし）	核を見つけ、候補リンクをスコアリング
2	リンキングと後処理：ILP、motion relink、gap closing、safe divisions、短トラックフィルタ、smoothing	公開（pilkwang / prvsiyan）、チューニング	トラックを構築
3	Consolidation（出力 = 私たちのベースチャンピオン、public 0.964）	私たちが構築	division の再構築、曖昧なリンクの再求解、fork の認証、整数座標
4	Mitosis スペシャリスト	私たちが構築・学習	子を1つしか持たない母細胞に2つ目の娘細胞を与える
5	最終修復：9つのルール、後段修復パス、identity link	私たちが構築、identity link は私たちが学習	見逃した division の採用、重複の統合、トラックの再接合、リンクの再決定
6	学習済み recentring、haze ガード、frame-jump 補正	私たちが構築・学習	ノード中心の移動、有害な移動の取り消し、smoother による引きずりの解消
その後	安全な CSV ライター	私たちが構築	整数座標、有効なリンク、検証済みの書き込み

2つの最終提出を A と B と呼びます。B は A に学習済み identity link を加えたものです。どちらも public 0.970、private 0.946 でした。可視動画上で division 数は 352（公開チェーン）→ 73（ベースチャンピオン）→ 81（スペシャリスト）→ 94（最終ファイル）と推移し、`submission.csv` には 122,568 ノードと 118,177 リンクが含まれます。スコアの大部分は公開された成果によるものです。ステージ1と2だけで再現したものが public 0.913（private 0.897）でした。

---

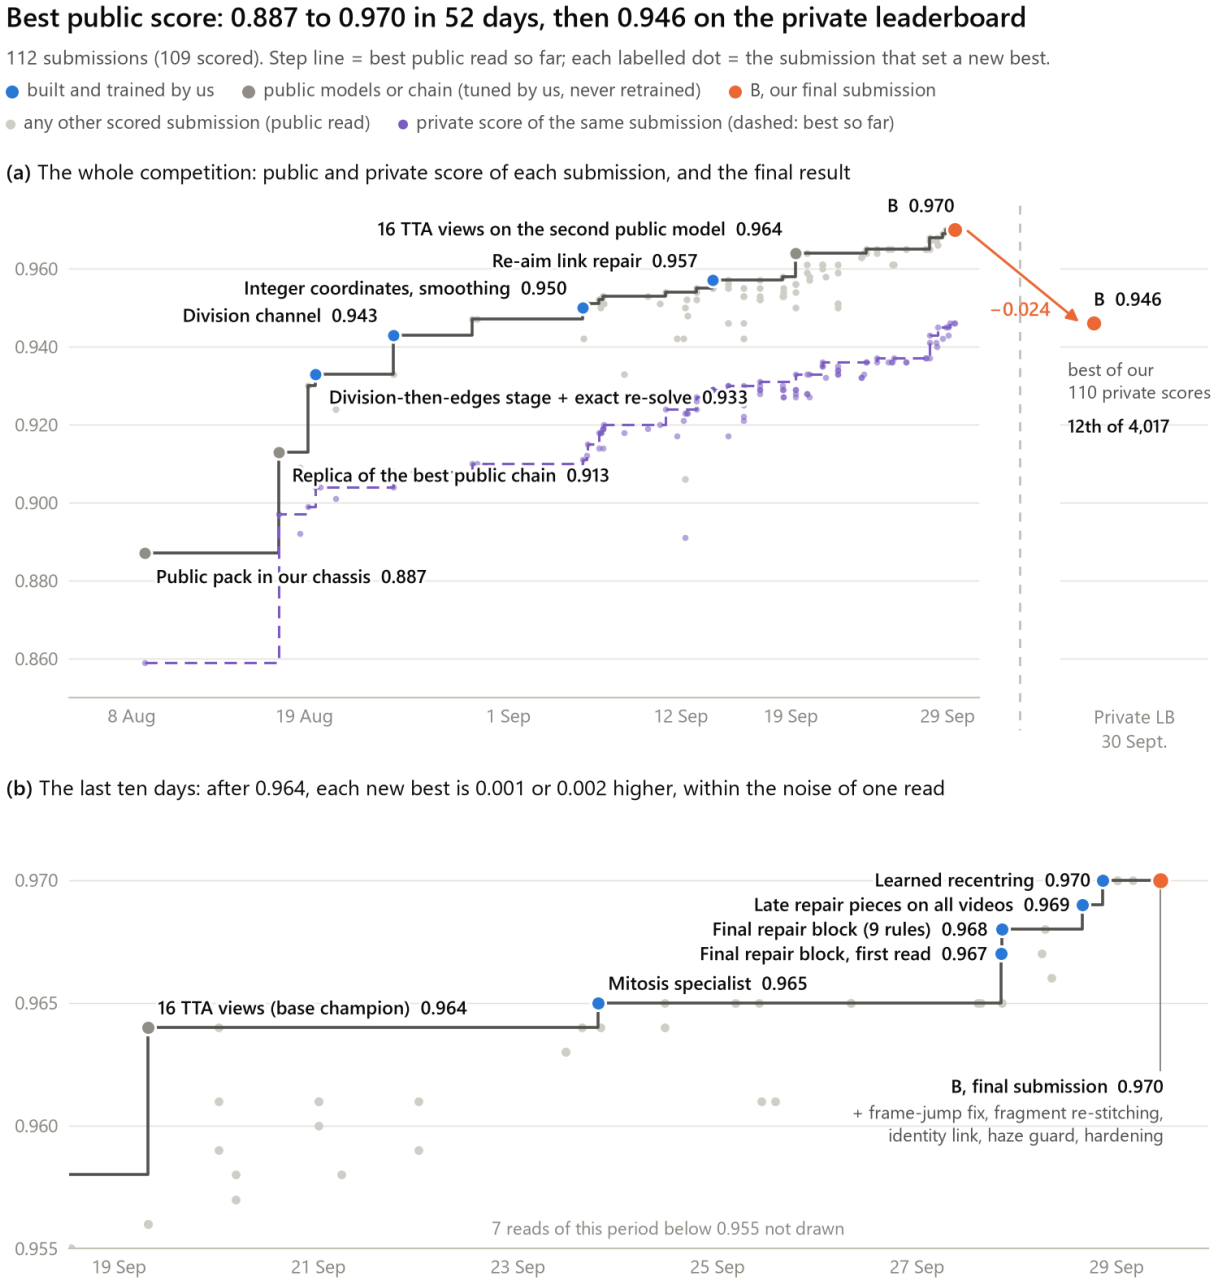
2. データ、metric、validation

2.1 私たちが計測したデータ

	44b6	6bba	all
学習動画	71	128	199
アノテーション済みノード / edge	20,197 / 19,826	113,121 / 109,057	133,318 / 128,883
アノテーション済み division	26	125	151
ホストの核数推定に対するアノテーション割合	0.77 %	5.37 %	2.82 %
バイト単位で同一のコピーフレームを含む動画	0	114	114（947フレーム）
ヘイズ（かすみ）のかかった動画（コントラスト中央値 < 1.6）	38	35	73

動画は (T, Z, Y, X) = (100, 64, 256, 256)、ボクセルは 1.625 x 0.40625 x 0.40625 µm で、約 104 µm の立方体です。

> **すべてを形作る事実.** アノテーションは疎（2.82 %）である一方、私たちのベースチェーンは 44b6 動画でフレームあたり中央値256個、6bba 動画で97個の核を予測しました。アノテーション済みの核1つに接する edge はスコア対象になるため、アノテーション済みの核から誤った隣接核へのリンクは false positive になります。アノテーションされていない2つの核の間の edge は見えませんが、予測されたすべての核はノード数の係数（node-count factor）にカウントされます。アノテーションされていない division は誤りの division ではありません。



Public leaderboard: about 29 % of the hidden videos, one embryo, 3 decimals (noise about 0.003). Private leaderboard: the other 71 %, a different embryo, read after the close for 110 of our 112 submissions (0.859 to 0.946, plus one 0.000 from a version mismatch). Public minus private: 0.031 for the base champion (19 Sept.), 0.024 for the finals.

図2. 可視動画 6bba_05db0fb1、フレーム40：生画像 (a)、このクロップ内の私たちの99個の核（フレーム全体では739個）とその直前12フレームのトラック (b)、そしてこのスラブで metric が見る3個のアノテーション済み核 (c)。動画全体では予測核 70,224個、アノテーション済み核 1,229個です（ホスト推定は 69,800）。

分かったこと：

- **コピーフレーム.** 114本の 6bba 動画中の947フレームは直前のフレームとバイト単位で同一で、取得時のアーティファクトです。これらの動画には151個の division のうち100個が含まれます。コピー処理を外したプローブは 0.965 / 0.936 で、両ボードとも親と同じでした。つまりどちらの hidden split にもコピー動画は含まれていません（私たちの解釈）。14位チームも同じ947フレームを報告しています。
- **スタック全体のフレームジャンプ.** ボリュームが1フレームだけジャンプし（大半は z 方向に 3.3〜8.1 µm）、元に戻ります。6bba では36本の動画に52個の GT ジャンプフレーム、44b6 では11個。連続する大きなジャンプの間隔は、23ケース中12ケースで54または55フレームでした。そこではベースチャンピオンのノードは GT から中央値 2.63 µm 離れており、t±1 での 1.86 µm と比べて大きくなっています。
- **重なり合うクロップ.** 44b6 の80組のクロップがバイト単位で同一で、ボクセルを共有する6つの連結成分をなしています。44b6 の26個の division のうち2個は同じイベントを2回数えたものです。動画単位の fold はリークし得ます。
- **アノテーションの z 規約.** 6bba の GT は各核の z 中心より +0.675 プレーン上に、44b6 では +0.115 上にあります。約23 % のノードを1プレーン z 方向に持ち上げる処理は、public での値（-0.001）で却下しましたが、private では +0.004 でした（実行カバレッジと交絡しています。z 自体による寄与は +0.002〜+0.004 と推定）。規約は胚（embryo）に依存するので、ヘッジすべきであり、public でチューニングすべきではありません。
- **整数座標.** GT 座標は整数のボクセルインデックスです。同じ world が **整数で 0.950、浮動小数で 0.942** でした（public。private では 0.911 vs 0.906）。

2.2 metric の再現

ホストの scorer を復元し、sha256 で固定しました。私たちの再現は、ベースチャンピオン（199本の動画で 0.949472029742）でも各動画でも、1e-12 の精度で一致し、カウントも同一です。Score = ノード調整済み edge Jaccard + 0.1 x division Jaccard（最大 1.1 なので、一部のサブセットのスコアは1を超えます）。私たちの予測ではどの項もクリップされないため、不足分は正確に分解できます：

```
1.1 - score = FN_e/E_tot + FP_e/E_tot + node term + 0.1 FN_d/D_tot + 0.1 FP_d/D_tot
```

ここで E_tot = 一致 + 見逃し + 誤りの edge 数（ベースチャンピオンでは 133,795）、D_tot は division について同様（181）です。In-sample では、ベースチャンピオンの不足分 0.1505 は edge 0.0759、division 0.0768（51 %）、そして node 項のボーナス -0.0022 に分解されます。edge の不足分の83 % は3つのメカニズムによるものです：7 µm 以内の隣接核がリンクを奪う（0.0295）、GT の端点から 7 µm 以内にノードがない（0.0211）、リンクの入れ替わり（0.0122）。

イベント	値	物差し
見逃しまたは誤りの edge 1本	7.47e-6（1 / 133,795）	厳密な分解、in-sample
見逃した division 1個	5.5e-4（0.1 / 181）、edge 74本分に相当	厳密な分解、in-sample
division Jaccard J、public / private	約 0.47 / 最大でも約 0.33	推定：すべての fork を切った提出は public で 0.906 vs 0.954、private で 0.891 vs 0.924 となり、この切断のコストは 0.1 x J
public 上の真の division 1個	約 +0.002	推定。約58本の public 動画に約42個のアノテーション済み division があると仮定

イベント	値	物差し
追加する division の損益分岐 precision、J / (1 + J)	public 32 %、private 約 25 %	上記の推定から導出

14位チームは自分たちのハーネス上で division の TP 1個を +0.000585 と計測しており、私たちの 5.5e-4 と同じオーダーです。これらの比率から、2つの出荷ルールを定めました。ベースチャンピオンが199本の動画上で正しく当てた division は1つも失ってはならない（毎回の提出前に監査）、そして division の変更はベースグラフ上の最終パスとしてのみ出荷し、計画用の事前分布（transport discount 0.65）で計算した public 上の期待値が +0.002 以上であること。ベースの真の division を失った8回の提出のうち、public で上昇したものは1つもありませんでした（6回は下降、2回は同値）。

2.3 Validation と、それが失敗した箇所

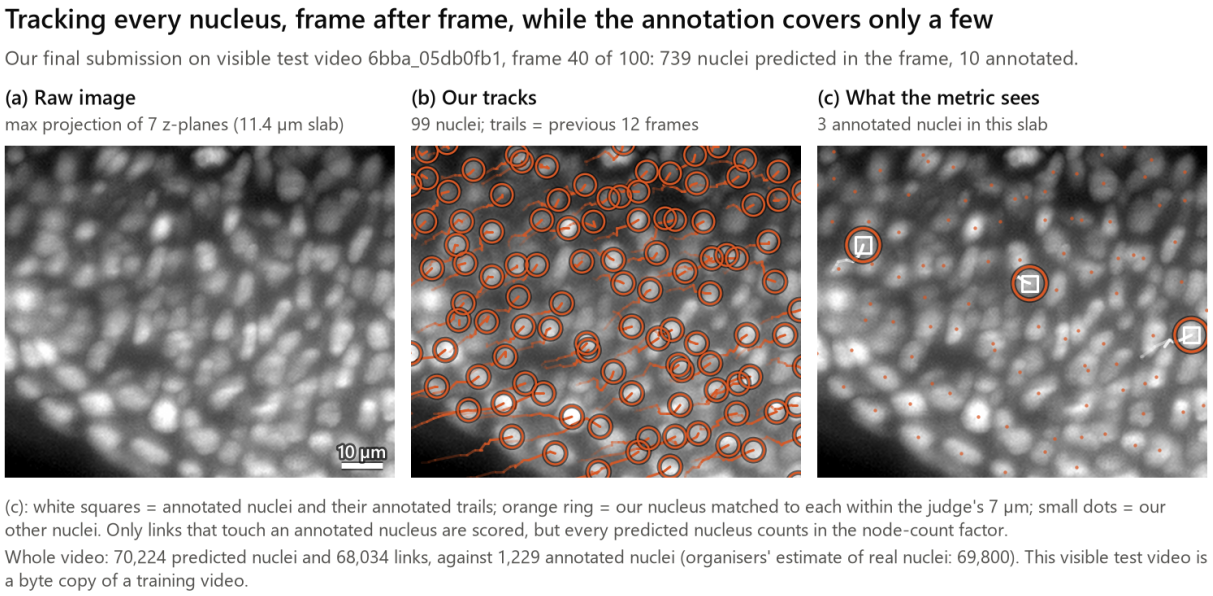


図3. フルチェーンのベンチは in-sample（0.975 / 0.979）で、private（0.946）を約 0.03 過大評価しました。3位チームの OOF CV は彼らの private を 0.011 過大評価していました。私たちの OOF world（より弱いネットワーク、最終修復ルールなし）は private より約 0.06 低い値でした。

> **はっきり言えば.** 私たちが土台にした公開ネットワークは199本すべての学習動画で学習されていたため、それらを使ったフルチェーンの値はすべて in-sample でした。私たちは9月10日からそれを認識していましたが、OOF world が完成したのは9月27日でした。

最終チェーンの値	A	B（最終）	種類
199本の学習動画	0.975	0.979	in-sample
199本の学習動画	0.881	0.888	OOF（377 に対して37〜57 epoch、最終修復ルールなし）
リーダーボード	0.970 / 0.946	0.970 / 0.946	public / private

私たちのコンポーネント（mitosis スペシャリスト、identity link、recentring）は胚をまたいで双方向に評価しましたが、in-sample のベースネットワークで構築したグラフ上での評価でした。Out of fold では、7 µm を超える

位置誤差が3.8倍に増えます。in-sample のベンチは記憶された動画の誤りを修復していたのであり、符号が反転しました（secondary TTA off：in-sample で +0.0143、public で -0.012、private で -0.003）。OOF のカードは public の符号を予測できていました（ILP 閾値のプローブ：OOF -0.0172、public -0.020）。

---

3. 検出（公開モデル、チューニングのみ、再学習なし）

検出器は学習していません。pilkwang さんの公開 temporal 3D U-Net（2つの入力フレーム、(1, 4, 4) のダウンサンプリング）が閾値を超えるピークを見つけ、node transformer が候補リンクをスコアリングし、ILP（edge -1.0、appear 0.0、disappear 1.5、division 1.0）がそれらをリンクします。公開されている両方の seed を使い、4つのノブをチューニングしました：

ノブ	私たち	公開プリセット	Public（代替 vs 私たち）	Private、同じペア
検出閾値	0.96	0.96875	0.965: 0.954 vs 0.958	-0.002
2つ目のモデルの融合（検出 / リンク）	0.475 / 0.15	同じ	0.70: 0.946 vs 0.957; 0.30: 0.953 vs 0.957; モデル off: 0.948 vs 0.954	-0.001; +0.001; -0.001
2つ目のモデルの TTA	16 views（D4 + z-flip）	8 views、yx のみ	8 views: 0.958 vs 0.964（9月19日）	0.929 vs 0.933
サブボクセル中心の精緻化	on（平均シフト 0.28〜0.74 µm）	off	off: 0.954 vs 0.955	0.926 vs 0.927

同じ16 views を primary モデルに適用すると 0.950 vs 0.958 でした（private -0.002）。このステージは後段のステージのために 15 µm 以内のすべての候補ペア（可視動画で 1,335,158個）もエクスポートします。生の出力は 143,766 検出で、274 s かかります。

> **private で効果が持続したもの.** z-flip view は持続しました（public +0.006、private +0.004）。0.475 の融合重みと、後から試した横方向の TTA 位相は、public の胚にとってだけの最適値でした。

---

4. リンキングと公開後処理（公開、チューニング）

公開チェーンは ILP の出力を5つのパスでトラックに変換します。5つすべてを残し、半径を再調整し、それぞれをオフにすることで価値を見積もりました。ペアで比較できた3つのオフ化は、両ボードで損失となりました。

- **DeepCenter gate**（pilkwang）：追加（gap fill、safe division）は中心が見えている場所でのみ許可されます。9月18日に safe-division の拒否権付きで有効化：public 0.958。
- **Motion relink**：5.5 µm、次に 10 µm での2パスの Hungarian（プリセットは 6.0 / 10.0）。Off：public 0.909 vs 0.913、private 0.892 vs 0.897。
- **Gap closing**：1〜2フレーム（1ステップあたり 5.8 µm、次に 4.4 µm）。Off：public 0.953 vs 0.957、private 0.922 vs 0.929。
- **Safe divisions**：幾何学的な接ぎ木（B のログでは、母細胞が 9 µm 以内、姉妹細胞が 14 µm 以内）。
- **短い連結成分のフィルタ**：gap closing の後に、6ノード未満の連結成分を削除します。

- **直線フィットによる smoothing**：0.2 p + 0.8 x 5フレームの線形フィット。Off：public 0.955 vs 0.957、private 0.925 vs 0.929。

> **知っておく価値のある性質.** division コスト 1.0 に対して appearance 0.0 という設定では、公開 ILP は199本の動画上で fork を一度も形成しません。可視動画上のこのステージの352個の division は、すべて幾何学的な接ぎ木によるものです。14位チームも自分たちの重みについて同じ性質を証明しています。

このフィルタにはコストがあります。xy でトラックを見逃した279個の細胞と、GT の division で欠けていた28個の娘細胞のうち9個を消してしまいました。私たちの再接合ステージはこの後に動いたため、手遅れでした。14位チームも同じ失敗を報告しています。

---

5. Consolidation（私たちが構築）：ベースチャンピオン

8つのステップで公開グラフを私たちのベースチャンピオン（public 0.964、private 0.933、9月19日）に変換します。カウントは可視動画上のものです。

ステップ	内容	可視動画でのカウント	根拠（public; private）
division then edges	division を再構築し（母細胞が 10 µm 以内）、その後 fork を保護しつつ、relinker が支持しないリンクを削除	-6,121 / +1,899 リンク	0.930 vs 0.913; 0.899 vs 0.897（単一変数）
厳密な局所再求解	10 µm 以内の曖昧なリンクを再決定	+2,573 リンク	0.933 vs 0.930; 0.904 vs 0.899
fork 認証器	fork を認証または切断	292個を確認、124個を切断	これら3ステップを off: 0.942 vs 0.957; 0.921 vs 0.929
安全な追加	孤立した division、top-K	+22 リンク、+12 fork	
smooth、purge、insert	ここから先は整数座標	29,881 ノードを移動	整数 vs 浮動小数: 0.950 vs 0.942; 0.911 vs 0.906
起こりにくいリンクの削除		-46 リンク	
2列の学習済み fork ルール	リンク確率と母細胞スコアの両方が一致したときに枝を切断	62 リンクを切断	親に対して +0.001; +0.005
re-aim	ゲート付きのリンク修復	4,602件の提案のうち873件を適用	0.957 vs 0.955; 0.929 vs 0.927

ベースチャンピオンは 122,824 ノード、117,704 リンク、73 division を出力します。In-sample では 0.9495 で、151個の GT division のうち42個を正解としています（109個見逃し、30個誤り）。

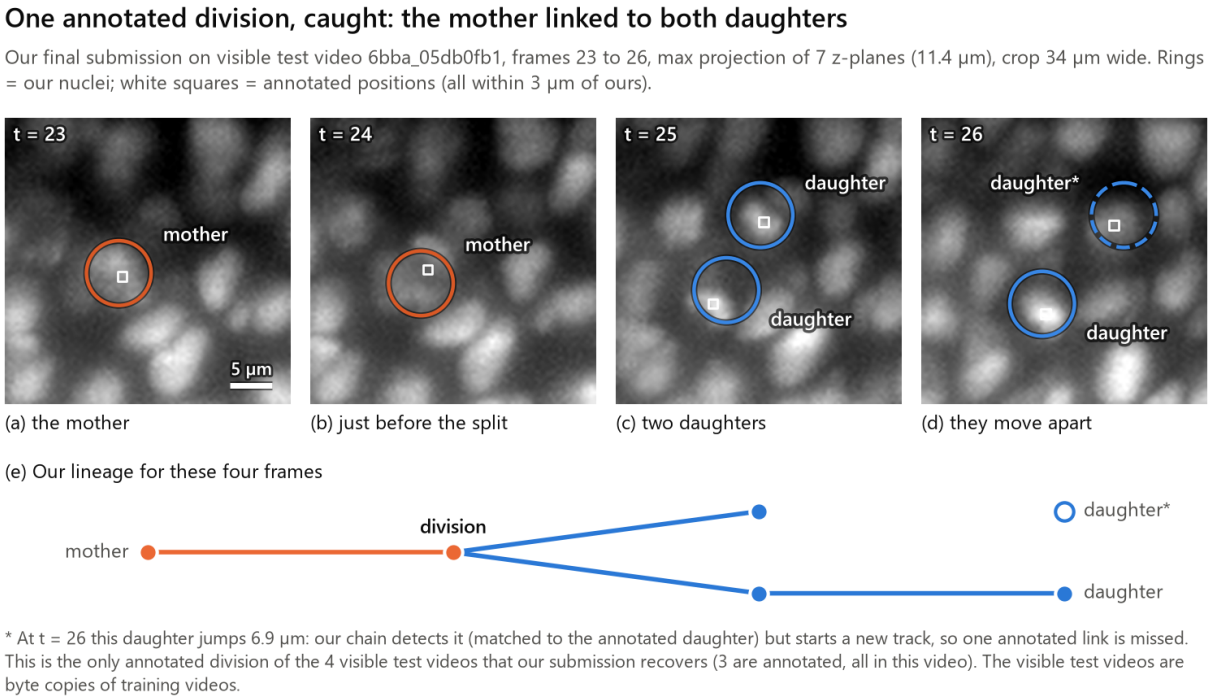


図4. チェーンに沿った division (a)、3つの時点での動画ごとの division (b)、mitosis スペシャリストのファネル（対数スケール）(c)。この図は各ステージが何をするかを示すもので、何個の division が正しいかを示すものではありません。

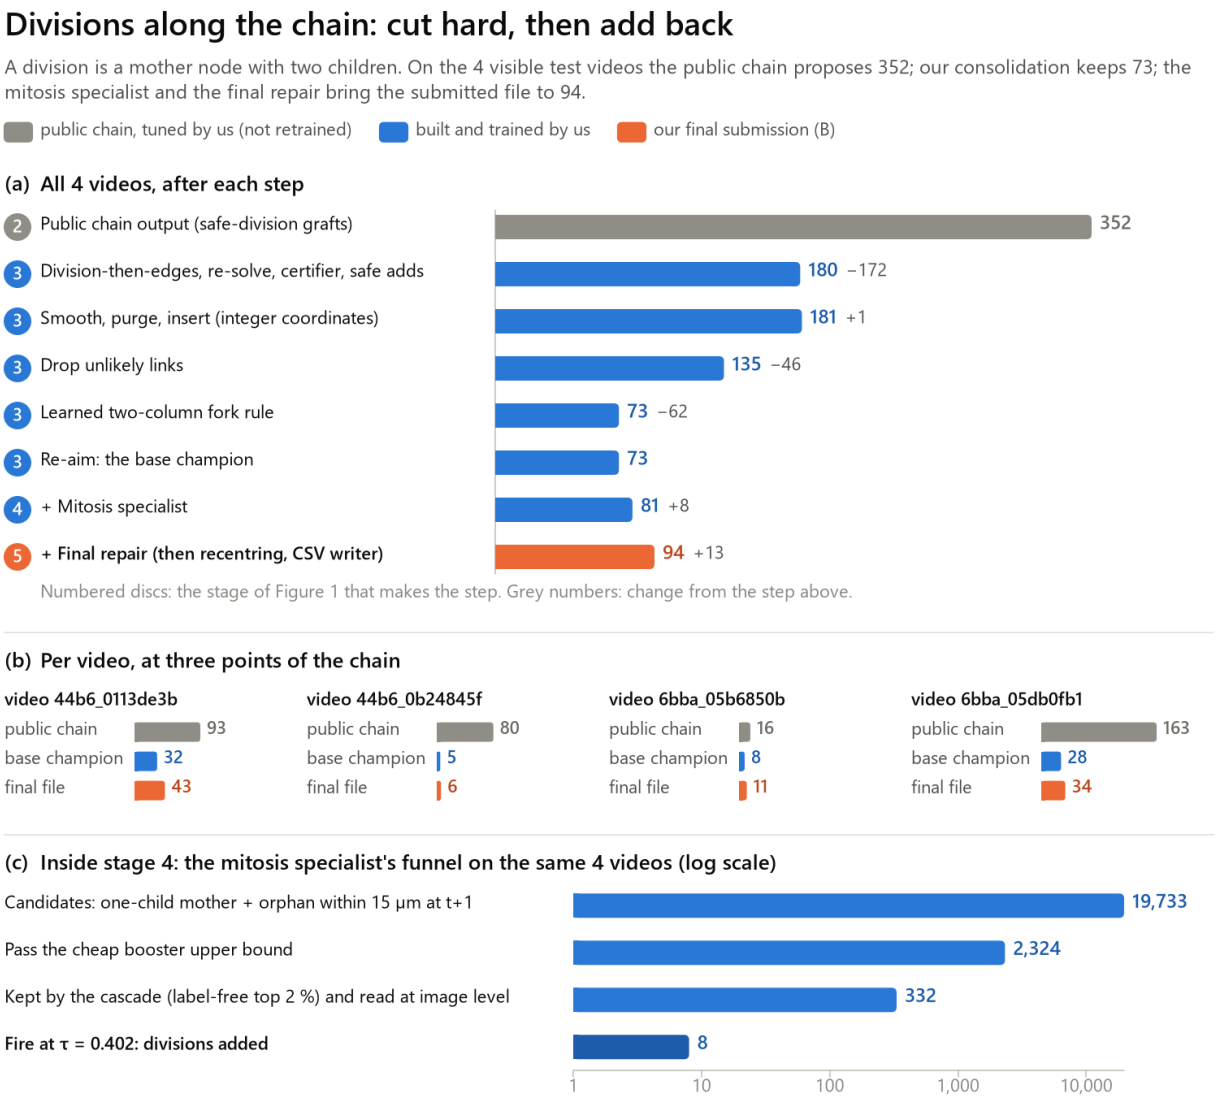


図5. 最終提出が復元した、1つのアノテーション済み division（可視動画上の3個のうち）：6bba_05db0fb1 のフレーム23〜26 (a〜d) と私たちの系譜 (e)。t = 26 で娘細胞の1つが 6.9 µm ジャンプします。それを検出はしていますが新しいトラックを開始してしまうため、アノテーション済みリンクが1本見逃されます。

---

6. Mitosis スペシャリスト（私たちが構築・学習）

ベースグラフ上の最終パスで、既存の division を削除したり移動したりすることは決してありません。**候補**：子を1つしか持たないすべての母細胞と、t+1 で 15 µm 以内にある孤児ノード（親のないノード）。**アクション**：その孤児ノードがすでに取られている、または母細胞がすでに2つの子を持っている場合を除き、母細胞を最も近い孤児ノードにリンクします。

可視動画上のファネル：**19,733** 候補 → 安価な booster の境界を通過する **2,324** → **332** を保持（chooser のスコアで上位2 %。ラベルを使わないルール）し、画像レベルで読み取り → **8** が発火。division は 73 → 81 となり、失われたリンクは0、308 s。すべてのヘッドは動画でグループ化した 5-fold です：

1. **Division reader CNN**（2.8 M パラメータ）：2つのスケールの時空間クロップを入力とし、Zebrahub（ホスト承認済み）で初期化し、150個の正例で fine-tune。OOF AUC 0.9125（6bba）、0.844（44b6）、外部の linajea セットで 0.829。
2. **Context chooser**：70個のラベル不要な列（division の波、細胞周期の経過時間、姉妹細胞、12 µm の球内の blob 仮説、孤児ノードのトラック履歴）に対する25個の LightGBM booster。
3. **3つの画像 witness**（上位2 % のみに適用）：中心の空き具合の比率、TV-L1 フロー変形 witness、そして t-2..t+2 の薄い XY / XZ / YZ スラブに対する **frozen DINOv2 ViT-S/14**（Meta AI）とロジスティック回帰ヘッド（イベント AUC 0.942 OOF）。
4. **Stacker**：すべてを入力とする LightGBM。デプロイしたルールは5つの外側スタックの平均です。

私たちの動作点である R10 は、ベースチャンピオンが見逃している109個のアノテーション済み division の10 %（11イベント）をランキングが復元する閾値です。

Validation の値	値	物差し
R10 での precision	stack 84.6 %（13 発火）; chooser 単体 32.4 %（34 発火）; reader 単体 5.2 %（213 発火）	nested OOF モデル、in-sample グラフ
パイプライン全体でラベルを置換	R10 で 0.3〜2.8 %	対照実験
デプロイルール、厳密な scorer	283 fork; アノテーション済み母細胞上で17個、うち13個が正解（76.5 %）; ベースチャンピオンに対して +0.0066	in-sample グラフ
リーダーボード	public 0.965 vs 0.964; private 0.936 vs 0.933（9月23日）	public, private

出荷した時点では、ベースチャンピオン以降の division 追加の中で public で上昇した唯一のものでした（表示単位1つ分）。private では +0.003 でした。

---

7. 最終修復と identity link（私たちが構築）

最終修復ブロックは、2.2節の3つの edge 誤りと、見逃した division を対象とします。これは最もコストの高いステージです（747 s、save run の44 %）。GPU の前処理パスで組織フロー場とノードごとの画像特徴量を計算します。その後、1つのエンジンが **9つのルール** を融合します：見逃した division の採用（ヘイズのかかった動画向けのバリアントあり）、重複の統合（双子、z 方向に積み重なった双子、xy 境界面）、トラックの再接合（消失するトラック、橋渡し、動画端のチェーン）、そして学習済みの decider によるリンクの決定です。その後に **後段修復パス** が続きます：2回見えている核、z 方向に積み重なった双子、文脈の中で再決定されるセグメント、ヘイズ内の穴、そしてフラグメントの再接合（セグメントとフラグメントのパスは GPU の組織変形場を共有します）。

Identity link. 候補リンクごとの LightGBM 確率で、幾何・見た目・変形の特徴量、identity-CNN の埋め込みと NCC、隣接パターンを記述する33個の「constellation」列、そして decider のリンク確率から計算します。確率の低いリンクを切断します（最小 0.3、マージン 0.2）。fork と曖昧なノードは凍結され、ノードや fork を追加することは決してなく、外側の2つの z スライス付近や 3.5 µm の xy 帯の中での編集は拒否し、動画あたり最大1,500件の編集しか適用しません。T4 でのコスト：5.94 + 0.772 k 秒（k = ノード数（千単位））。

値	値	物差し
identity link	+0.0031（q05 +0.0020; 71本の動画で上昇、10本で下降）; in-sample で +0.0003; 移動した division は0	OOF cf; in-sample
identity link、B vs A	0.970 = 0.970; 0.946 = 0.946	public; private
修復ブロック、2つのバリアント、スペシャリスト world との比較	0.967 と 0.968 vs 0.965; 0.943 と 0.941 vs 0.936	public; private
フルカバレッジでの後段パス	+0.0031; public 0.969、private 0.942	OOF cf; リーダーボード

可視動画上では：適用された編集 2,746件、元に戻された動画0本、division 81 → 94。

---

8. Recentring、ガード、CSV ライター（私たちが構築・学習）

学習済み recentring. 3D CNN（3 → 24 → 32 → 64 → 96 チャネル）が、各ノード周辺のネイティブ解像度 13 x 41 x 41 のクロップ、そのフレームの他のノードのマップ、ボリューム内マスクを読み込み、軸ごとにノードから GT へのオフセットを Laplace スケール付きで予測します。軸ごとの LightGBM stacker が、トラック・混雑度・境界面の文脈を加えます。学習には3つの world（1つは OOF、2つは in-sample）からの 930,452 ノードサンプルに加え、46k の合成ジッターを使い、連結成分で閉じた fold で行いました。出荷した重みは199本すべての動画で再学習したものです。移動量は軸ごとに 2 µm に制限され、他のノードから 4 µm 以内には決して着地せず、両方の時間的隣接ノードから 0.5 µm を超えて離れることはなく、トポロジーを変えることもありません。コスト：T4 で 1,000ノードあたり約 0.4〜0.6 s（RTX 2000 Ada での実測値からスケーリング）。可視動画上の 122,686 ノードのうち 98,793 ノードを移動しました。

値：私たちの別の refiner に対して OOF cf で +0.0024、in-sample で +0.0003。recentring なしの world に対しては public 0.970 vs 0.969、**private 0.945 vs 0.942**（このペアでは CSV ライターのバージョンも変わっています）。private では別の refiner にも 0.002 勝っていました。終了前は、学習済みの移動器は OOF での価値の 0.18〜0.30 しか保てないと予想していましたが、これはそれよりもよく転移しました。

Haze ガード. ヘイズのかかった動画（コントラスト < 1.6）のみで、フロー補償後の親・子への残差が 1 µm を超えて増える recentring の移動をキャンセルします：2本のヘイズ可視動画で 2,665 ノードを元に戻し、OOF cf で +0.0007、in-sample で +0.0007。そのルーティングは OOF の値を見た後に決めたため、名前付きの賭けとして出荷しました。B はこれの有無にかかわらず、どちらも 0.970 / 0.946 でした。

Frame-jump 補正. 公開の5フレーム smoother は1フレームのジャンプの 0.36 しか保たず、4つの隣接フレームを引きずります。5 µm のジャンプは、画像に追従する GT に対して約 3.2 µm のオフセットを残します。私たちはチェーン自身の生の検出からジャンプを検出し、その引きずりを元に戻します。リンクやノードには一切触れません：可視動画上で2フレーム、71ノード、OOF cf で +0.0016、両ボードでは判定不能でした（0.970 = 0.970、0.945 = 0.945）。14位チームは同じシフトを FFT 位相相関で補正していました。

安全な CSV ライター. 整数座標、有効なリンク、孤立ノードと画像外ノードの削除、置き換える前のファイル再読み込み：118 ノードと 7 リンクを削除（OOF cf で +0.0004）。

---

9. 堅牢性と実行時間

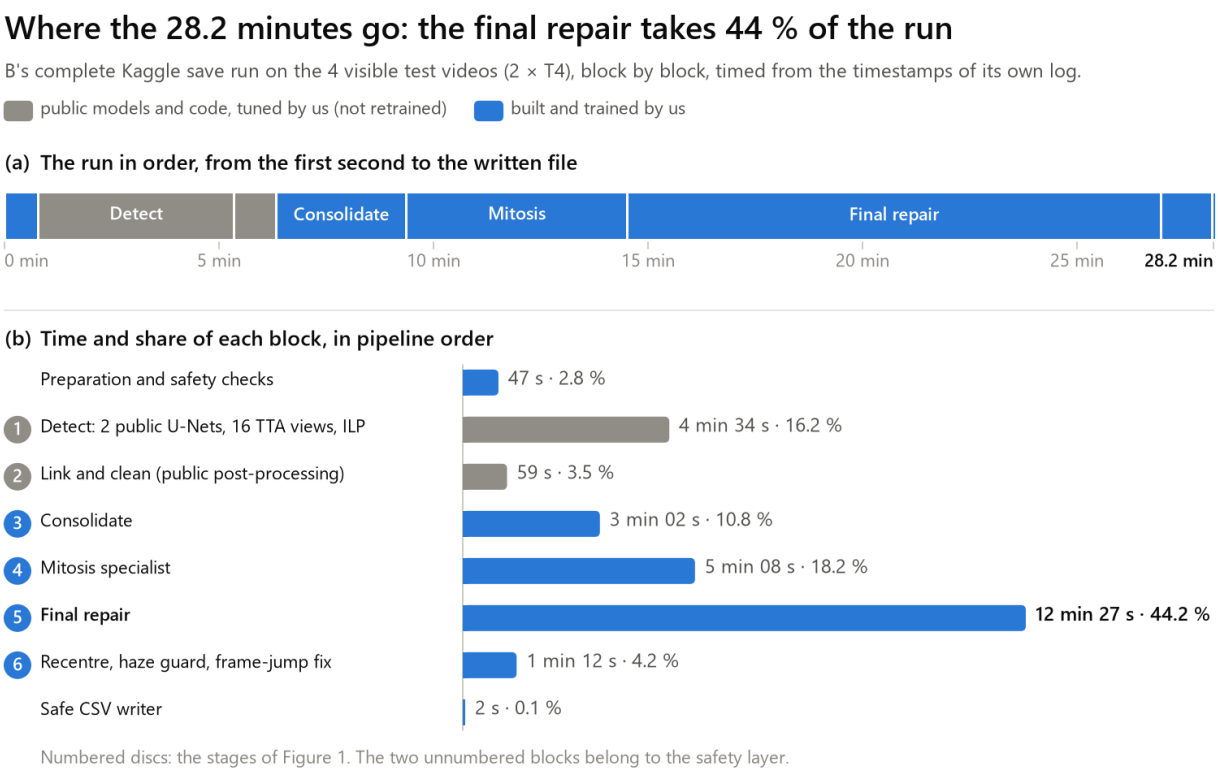


図6. 4本の可視動画に対する B の save run、2 x T4：検出と ILP 16.2 %、mitosis スペシャリスト 18.2 %、最終修復 44.2 %。hidden セットでは、提出からスコアまで6.8〜8.4 h かかりました。

後段のステージがクラッシュしても、提出を失ってはなりません：

- **計算の前に**：厳密な MILP ソルバーをチェックし、t+0 s で有効な `submission.csv` を書き出し、32個のオフライン wheel をインストールし、すべての重みとソースの sha256 を検証します。
- **デッドラインとフェイルオープン**：最終修復は 10.5 h で停止、全体は 11.2 h で停止し、後段のすべてのステージはエラーやタイムアウト時に動画ごとに入力をそのまま返します。死んだワーカーや詰まったワーカーは再起動されます（26 / 26 のユニットテストと障害注入テストに合格。ソークテスト 4 レーン x 50 動画でエラー 0）。
- **作業の証明**：カナリアが、計画された各ステージが各動画上で実行されたことを証明し、最後の3つのステージは書き込む前に再読み込みします。

初期の提出の1つは、検証したものとは異なるカーネルバージョンを提出してしまったため 0.000 になりました。最終提出で失敗したものはありません。

---

10. 結果

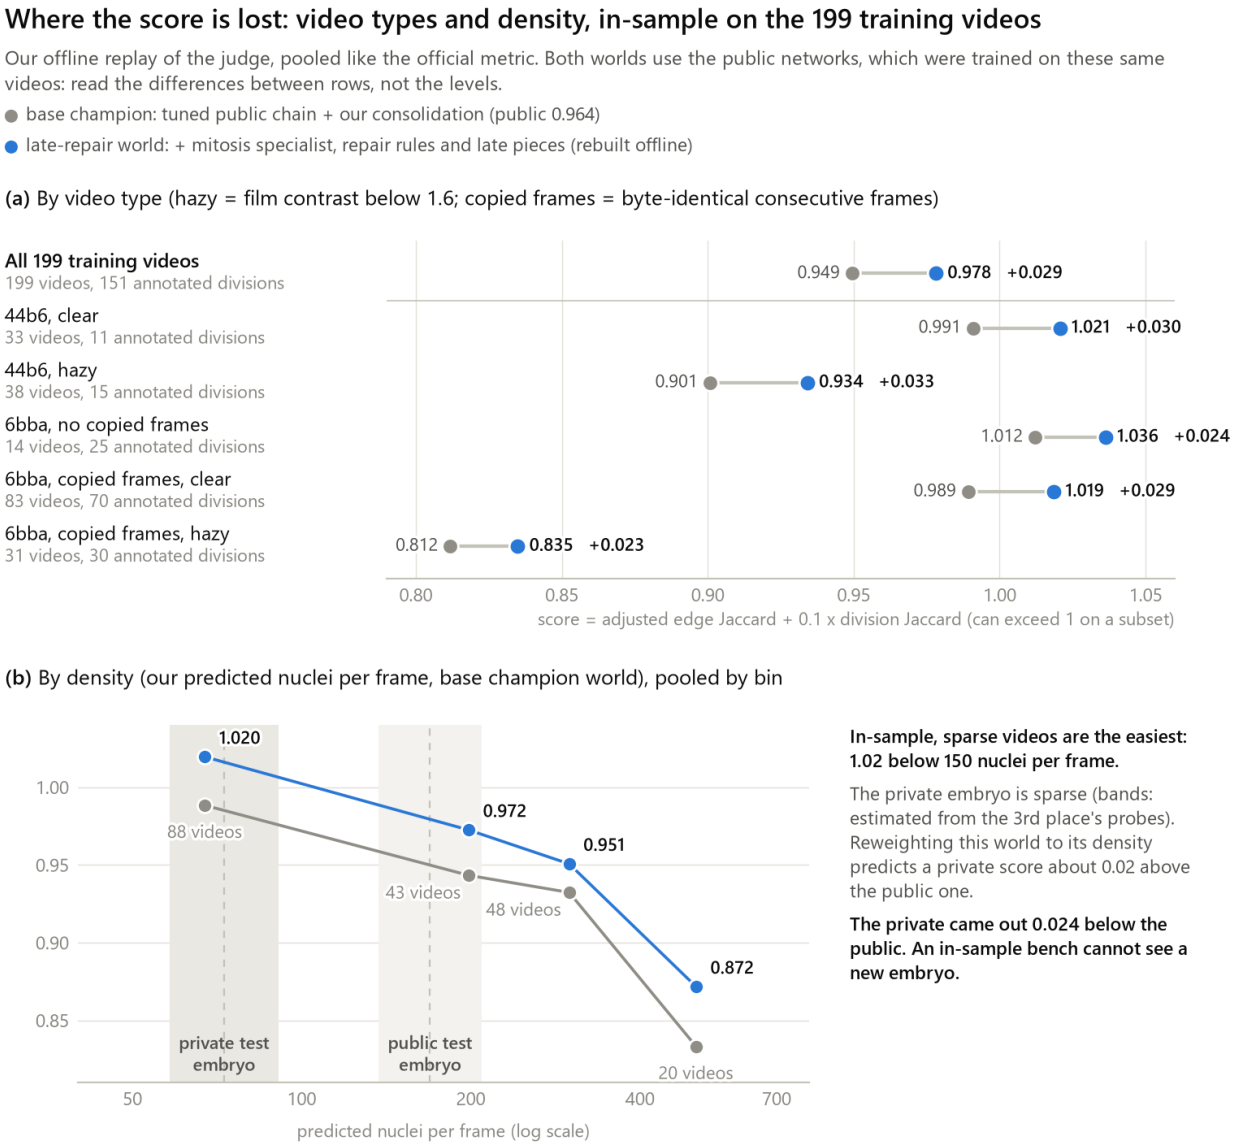


図7. (a) 最良 public スコア（ステップ線）は 0.887（8月8日）から 0.970（9月28日）へ。スコア付きの各提出を灰色の点で、終了後に読んだ同じ提出の private スコアを紫で、その時点までの最良線とともに示しています。B は 0.946 で、私たちの110個の private スコアの中で最良でした。(b) 最後の10日間：新しい public ベストはそれぞれ直前より 0.001 または 0.002 高いだけで、1回の読み取りのノイズの範囲内です。

表1. チェーンの構築過程、両リーダーボード上で（各行は新しい public ベスト。制御されたアブレーションではなく履歴です）。

日付	Public	Private	変更内容	単一変数？
8月8日	0.887	0.859	独自の推論ノートブック内で pilkwang さんの公開モデル	
8月17日	0.913	0.897	prvsiyan さんの公開チェーンの忠実な再現	no

日付	Public	Private	変更内容	単一変数？
8月19日	0.930 / 0.933	0.899 / 0.904	私たちの「division then edges」ステージ、続いて厳密な局所再求解	yes, yes
8月24〜29日	0.943 / 0.947	0.908 / 0.910	consolidation ステージ内の division チャネル; 2つの division 追加	yes, no
9月5〜7日	0.950〜0.953	0.911〜0.919	整数座標、smoothing、誤り fork の除去; 弱い誤り fork のガード付き削除	一部
9月11日	0.954	0.924	2列の学習済み fork ルール	yes
9月13〜18日	0.955〜0.958	0.927〜0.929	公開ノブ + サブボクセル中心; re-aim パス; DeepCenter 有効化	no
9月19日	**0.964**	0.933	2つ目のモデルに16 TTA views：**ベースチャンピオン**	yes
9月23日	0.965	0.936	mitosis スペシャリスト	yes
9月27日	0.967 / 0.968	0.943 / 0.941	最終修復ルール、2つのバリアント	no
9月28日	0.969 / **0.970**	0.942 / 0.945	フルカバレッジでの後段修復パス; 学習済み recentring	no, ほぼ
9月29日	0.970（x4）	0.945〜**0.946**	frame-jump 修正; フラグメントと identity link; haze ガードと実行時の堅牢化（= A と B）	

public から private への低下はどこから来たか. 公開チェーンの再現は 0.016 低下しました。in-sample のベンチと public ボードの上で構築した consolidation ステージとノブのチューニングは、ベースチャンピオンまでに public を +0.051 押し上げましたが、private は +0.036 にとどまり、低下幅は 0.031 に拡大しました。その最初のステップ単体では public +0.017、private +0.002 でした。ベースチャンピオン以降のステージは public +0.006、**private +0.013** で、低下幅は 0.024 に縮まりました。（8月8日の最初の公開パックも 0.028 低下していました。）

表2. 主要な単一変数ペア（1回の読み取りあたり約 0.003 のノイズと ±0.001 の丸めがあるため、結論はペアの集まりに基づいています）。

変更	Public	Private
整数 → 浮動小数座標	-0.008	-0.005
2つ目のモデルに16 views（z-flip）	+0.006	+0.004
2つ目のモデルの TTA off	-0.012	-0.003
融合 0.475 → 0.70 / → 0.30	-0.011 / -0.004	-0.001 / +0.001
横方向の TTA 位相シフト（重複除去あり）	-0.013	+0.001
motion relink / gap closing / smoothing off	-0.004 / -0.004 / -0.002	-0.005 / -0.007 / -0.004
すべての fork を切断（計測用）	-0.048	-0.033
mitosis スペシャリスト	+0.001	+0.003

変更	Public	Private
division 採用ルールを削除	+0.001	-0.001
約23 % のノードを1プレーン z 方向に持ち上げ	-0.001	+0.004
学習済み recentring	+0.001	+0.003
identity link（B vs A）; コピー処理を除去	0.000; 0.000	0.000; 0.000

104組の親子ペア（うち76組が単一変数）のうち、17組は符号が逆でした。15組は public で負・private で正、残り2組は division 採用ルールの2回の削除です。連続性に関わる要素は public での大きさの 1.3〜3 倍で持続し、public でチューニングした検出器のノブは private では平坦でした。3つの最終候補はすべて 0.946 で、私たちの110個の private スコアの最大値でしたので、最終選択によるコストはありませんでした。public の14位から private の12位に上がりました。public で私たちより上にいた13チームのうち9チームが、私たちより下で終わりました。

---

11. うまくいかなかったこと

アイデア	Public またはベンチ	Private	理由
他の TTA views（32 views、横方向および z の位相シフト）	public -0.003〜-0.014	0〜+0.002	16 views は public の胚における局所最適だった
独自の secondary 検出器（199動画 / OOF の重み）	public 0.950 / 0.942 vs 0.954	-0.001 / -0.007	公開重みよりデータが少なく、epoch も少ない
アノテーションされていない細胞に対する loss マスク、10 epoch の fine-tune	recall -0.0154 と -0.0015	n/a	fine-tune のみ。疎ラベル用の完全なレシピは試していない
集団運動を用いたリンカー再求解（5バリアント）	in-sample +0.009; public は上昇0、横ばい1、下降4	-0.001〜+0.002	public の胚でのみ損失
大量の再検出（位置の28〜33 % を移動）	public -0.004 / -0.003	+0.002 / +0.003	199本での edge 項でも一度もプラスにならなかった
一括での division 追加（13回の public 読み取り）	上昇1、横ばい3、下降9	12ペアで平均 +0.0002	public の損益分岐を下回る。private の損益分岐はさらに低い
ボリューム境界面付近の fork の切断	public -0.004、失われたアノテーション済み division は0	0.000	「アノテーションされていない」は「誤り」を意味しない
リンクと division の同時再求解（厳密な MILP）	見逃した96個の division のうち22個で正しい fork、オラクルの手がかりありなら67個	n/a	限界はソルバーではなく division の witness だった
public 値を見る前に書いた予測	0.968 → 0.965、0.970 → 0.967、0.972 → 0.969	n/a	ベンチから public への換算に out-of-sample の予測力がなかった

これらのいくつかは public の胚でのみ失敗したものです。private では横ばいかわずかにプラスでした。

12. 振り返りと教訓

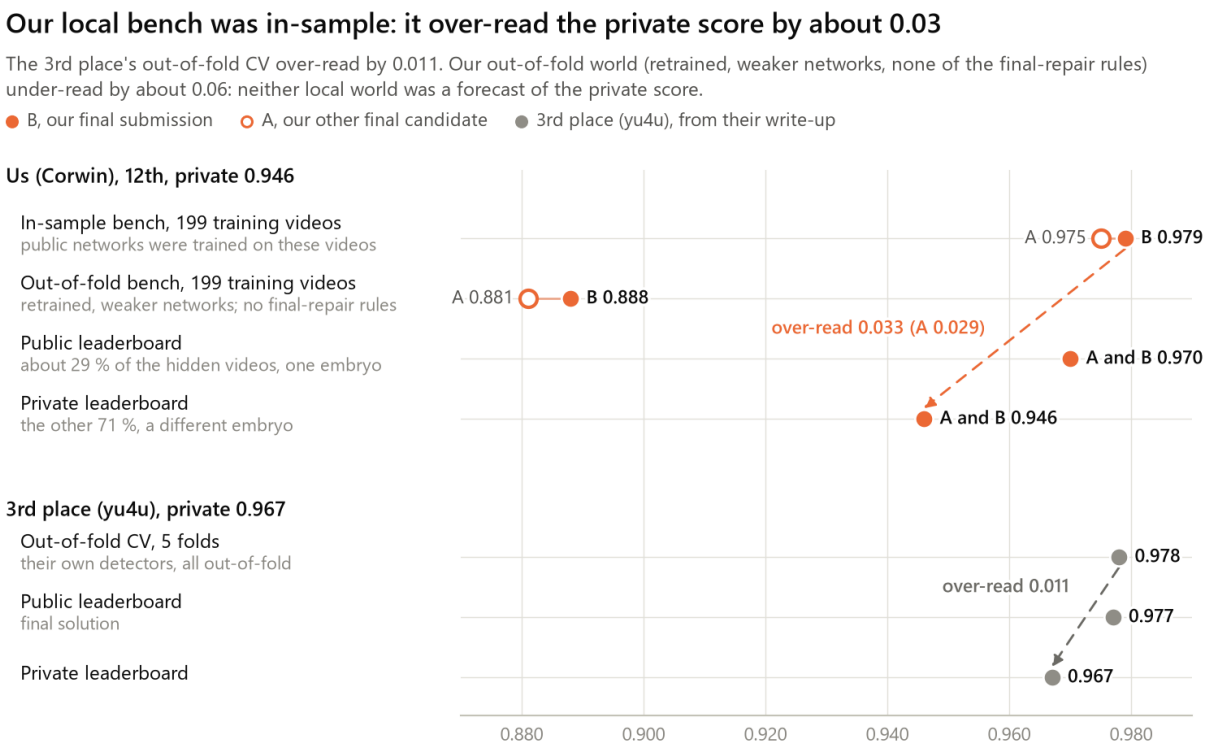
3位（yu4u さん）は、**public で 0.007**（最終解法で 0.977、最良 public は 0.978）、**private で 0.021**（0.967 vs 0.946）私たちより上です。私たちの public から private への低下は 0.024、彼らは 0.010 でした。私たちの抽出では、public 0.965 以上のチームの低下幅の中央値は約 0.027 でした（下限値）。彼らが違ったこと：

- 独自の検出器（ImageNet 事前学習済みの 2.5D エンコーダーと 3D SegResNet）を、疎ラベル用に設計した loss でコンペデータ上で学習；
- 生フレームとフロー整列済みフレームを読む教師ありの親モデル；
- metric の代理指標上でノード・リンク・division を同時に選ぶ1つの LP / MILP；
- 固定した OOF 検出の上で、公式 metric でスコアリングする1本のアブレーションの梯子。

Validation は私たちの誤った判断の最も裏付けのある原因ですが、差のすべてではありません. 彼らの OOF CV は private を 0.011 過大評価し、私たちの in-sample ベンチは約 0.03 過大評価しました。そして10節は、in-sample と public の値でチューニングしたステージとともに私たちの低下幅が大きくなったことを示しています。これを、彼ら独自の検出器の方が汎化するという別の解釈から切り分けることはできません。彼らの division Jaccard は CV で 0.540、private で 0.47 でした。私たちは in-sample で 0.409、OOF で 0.194、9月11日のチェーンの private では最大でも約 0.33（推定）でした。これが最終チェーンでも成り立つなら、division 項だけで private の差 0.021 のうち約 0.014 を説明できます。

彼らのアイデア	私たちの試み	結果
OOF 検出器を出荷	約99本の動画で50 epoch	public 0.942（-0.012）、private -0.007
「評価される確率」	学習した傾向スコア、胚をまたいで AUC 0.645 / 0.715	decider のヘッドで 0.49; 組み込まなかった
短い連結成分の削除	同じフィルタ、同じ順序	私たちの場合は本物の細胞も消してしまった
座標の精緻化	学習済み recentring、出荷	OOF cf で +0.0024、private +0.003; 彼らのものは学習なしのアフィン運動モデル

密度. 3位チームのプローブにより、private の胚は両方の学習胚よりも疎であることが分かりました（フレームあたりの検出数の中央値 60〜100、学習胚は 114 と 355）。私たちの in-sample 動画は疎であるほど簡単なので、その密度に向けて再重み付けすると、private は public より約 0.02 高い と予測されました。実際は 0.024 低い結果でした。この再重み付けは重みの81 % を 6bba に、75 % をコピー動画に置くため、密度・胚・コピーが交絡しています。in-sample の world を再重み付けしても in-sample のバイアスは補正できません。



Kinds of read. In-sample: the 199 training videos scored with our exact replay of the judge, with the public networks that had been trained on them. Out-of-fold: the same videos with our fold-retrained networks (37 to 57 epochs instead of 377) and without the final-repair rules. Leaderboard reads are shown at 3 decimals.

図8. In-sample、動画タイプ別 (a) と密度別 (b)、ベースチャンピオン vs 後段修復 world（保存してある world のうち最終チェーンに最も近いもの。in-sample で 0.978 vs 0.979：代理であり、出荷した提出そのものではありません）。疎な動画は in-sample で最も簡単であり、疎な private の胚に向けて再重み付けすると符号を誤って予測します。

教訓：

1. **ベースモデルを自分で持つか、初日に OOF world を構築すること。** 1つのステージが動画を見てしまっているベンチでは、何も決めるべきではありません。
2. **1つの固定した OOF world 上で、1本のアブレーションの梯子を維持すること。** 公式 metric でスコアリングします。私たちは要素の価値を異なる world で見積もっており、そのうち1つは修復ブロック全体を欠いていました。
3. **メカニズムはベンチよりも転移をよく予測し、胚ごとに評価が異なる。** public の胚では、連続性の追加は約 1:1 で効き、統合・再リンク・上流の再チューニングはゼロ以下、本物の構造を壊すことは学習時の価値の3〜10倍のコストがかかりました。private では、連続性の要素は public での大きさの 1.3〜3 倍で持続し、リンカーの再求解は平均してほぼゼロでした。
4. **metric の最適化は1か所で、強力な division witness とともに行うこと。** 1つずつ validation した後段パスは edge と division をトレードオフできません。また「奪われた」娘細胞39個のうち37個は2つの細胞体に対して1つのノードしかないケースで、同じノード上で動くソルバーでは修正できません。
5. **検出器のノブを public ボードでチューニングしないこと。** private で持続したのは z-flip view だけでした。横方向の位相と 0.475 の融合重みは private では平坦でした。
6. **表示単位1つ分で判断しないこと。** division 採用ルールを +0.001 の public 値に基づいて2回削除しましたが、private は -0.001 と -0.002 動きました。これは17組の逆符号ペアのうち、public 側がプラスだった唯一の2組です。

7. **実行の規律は安上がり。** t+0 での有効な CSV、sha256 による固定、フェイルオープンなステージ、カナリア、そして検証したバージョンをそのまま提出すること：初期の 0.000 が1回あった後、最終提出で失敗したものはありません。

---

13. 注意事項

箇所	主張	実際
OOF world	「out-of-fold」	より弱いネットワークで最終修復ルールなし：チェーンの下限
mitosis スペシャリスト、76.5 %	nested OOF モデル	in-sample のグラフ上で読んだもの。新しい胚では一度も計測していない
private のペア	それぞれ単一変数	recentring のペアは CSV ライターのバージョンも変えている。z-lift のペアは実行カバレッジと交絡している
ローカル scorer vs Kaggle	同じコード	浮動小数は in-sample で +0.0004（9月5日）、public で -0.008。切り捨てのプローブは符号を再現する（in-sample で -0.0023）が、大きさは再現しない
TTA の梯子 1 / 8 / 16 / 32 views	0.952 / 0.958 / 0.964 / 0.958	32-view の値は別の親（0.961）に基づく。きれいなステップは 8 → 16 だけ

---

14. 私たちの取り組み方

これは AI と協働するという個人的な実験でもありました。Guillaume が方向性を定め、生物学者が核をどうアノテーションするかを学び、動画を 3D で確認し、すべての戦略的判断を下し、すべての提出を承認しましたが、自分ではコードを一切書きませんでした。コード、metric の再現、計測、提出は、1つのメインの AI コーディングエージェント、Claude Code（Anthropic）によって行われ、私たちはそれを ATHENA と呼んでいました。それは厳格なルールの下で動いていました：メインエージェントがすべてを実行・調整し、プロジェクトの各部分に対する Claude skills と、厳密な権限およびリソース制限を通じて作業します。サブエージェントやマルチエージェントワークフロー（ビルダー、敵対的な検証者、審判）に委任し、8月23日以降、4,200回を超えるサブエージェント実行と478個のワークフローを実行しました。ChatGPT（OpenAI）は外部の研究アドバイザーとして機能し、Gemini Deep Research と NotebookLM（Google）は文献調査を助けました。Guillaume の息子で Kaggle 上のチームメイトである Mathis は補助を務め、モデル学習のためにゲーミング PC を貸してくれました。52日間で112回の提出。これに必要だった規律は上記に表れています：再現した metric、事前登録した読み取りルール、そして注意事項に挙げた誤りも含め、すべての判断の監査証跡です。

謝辞

データ（CC0）を提供してくださった Biohub SF（Royer group）、そしてホスティングしてくださった Kaggle に感謝します。公開の temporal 3D U-Net、node transformer、ILP サポートパック、2つ目の seed、DeepCenter を提供してくださった **pilkwang** さんに感謝します。私たちが再現した公開チェーン（8月17日に 0.913）を提供してくださった **prvsiyan** さん、DINOv2（Apache-2.0。公式重みの boymagic さんによるコピーをマウントしました）を提供してくださった **Meta AI**、そして Zebrahub と linajea の著者の方々に感謝します。3位（yu4u さん）と14位（Vibes & Edges Trade-Off）の write-up は、私たちの事後分析を形作ってくれました。