biohub-cell-tracking-during-development

Vibes&Edges Trade-Off による14位解法

Rank	14
Team	Vibes & Edges Trade-Off
Author	Tom
Topic ID	744486
Version	Japanese Translation

Source: https://www.kaggle.com/competitions/biohub-cell-tracking-during-development/discussion/744486
Retrieved with Kaggle CLI on 2026-10-04.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

このような素晴らしいコンペを開催してくださったホストに感謝します。以下は Vibes&Edge Trade-Off による解法のまとめです。

TL;DR

私たちは1つのパイプラインをチューニングするのではなく、**同じボリュームに対して2つの独立したトラッキングパイプラインを実行し、それらを動画ごとに統合**しています。

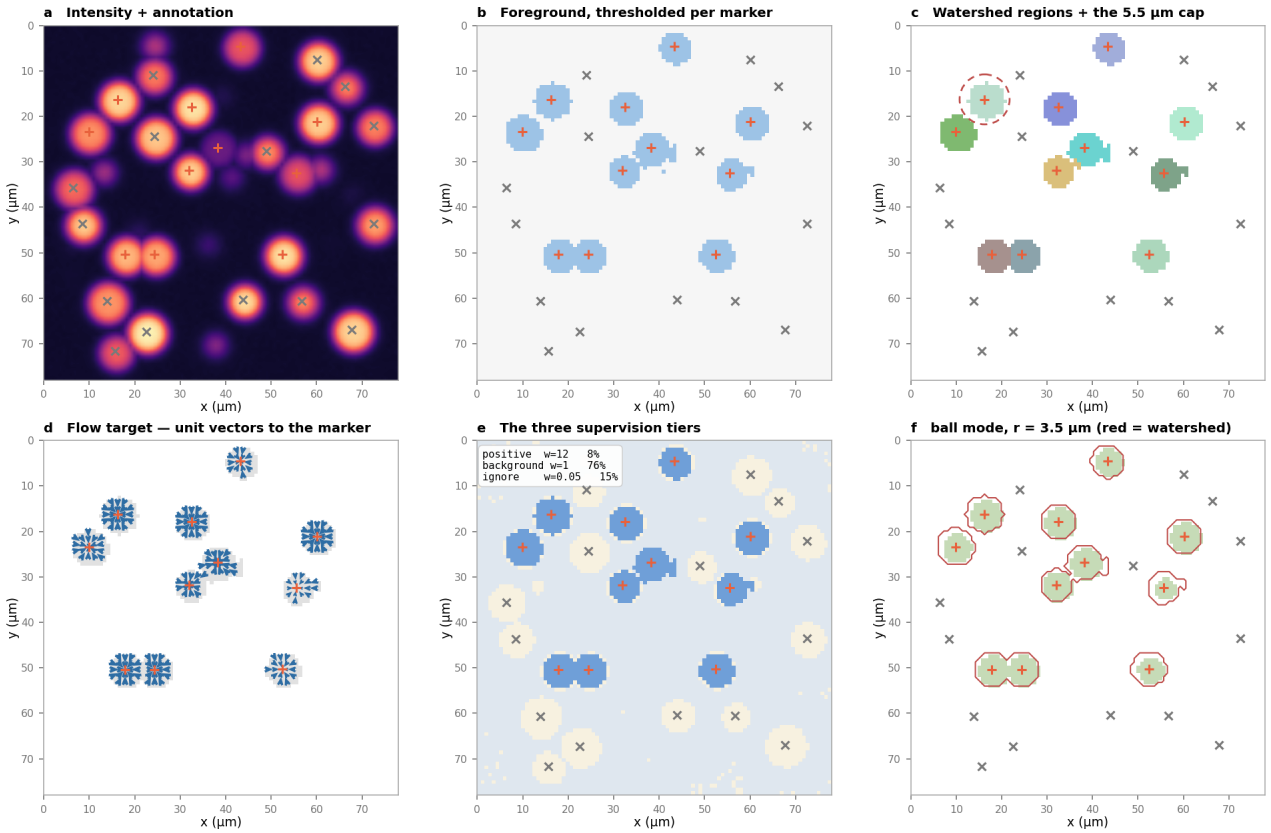
- **Detection（検出）。** flow-field セグメンタ（FlowSeg）が、すべてのボクセルについてそのボクセル自身が属する細胞中心を指すベクトルを予測します。この場を積分することで、どんな閾値でも分離できない接触した核を分離します。異なる seed で学習した2つ目の TemporalUNet3D 検出器を並行して実行し、2つが異なる場所で失敗するようにしています。
- **Edge。** 一方のパイプラインはグローバルな ILP でリンクし、もう一方は形状特徴量に基づく 5-fold GNN でリンクします。ゲートはフレーム全体の剛体運動を除去した後の残差変位に適用し、3つのギャップクローザーが、検出器が見てはいたが信じなかった細胞を回復します。
- **Division。** 121 件のラベル付きイベントから「これは division か？」を分類する代わりに、divflow は**対応関係を回帰**します。後のフレームのすべてのボクセルが、その親がどこにいたかを予測します。すると division は幾何学的な一致、すなわち2つのインスタンスが親空間では収束しつつ、観測空間では離れたままである状態となります。その後はすべてフィルタリングです。
- **Merge（統合）。** 2つのグラフは平均するのではなく接ぎ木（graft）し、ある動画で私たちの検出器が崩壊した場合には、動画単位のサーキットブレーカーがより強いグラフにフォールバックします。

スコアを最も動かした2つの判断はモデルではありませんでした。ノード位置の **linefit スムージング**（オフにすると −0.01914）と、すべてのグラフ判断の後に適用する**パラメータゼロの定数座標シフト**（リーダーボードで +0.002）です。

Detection（検出）

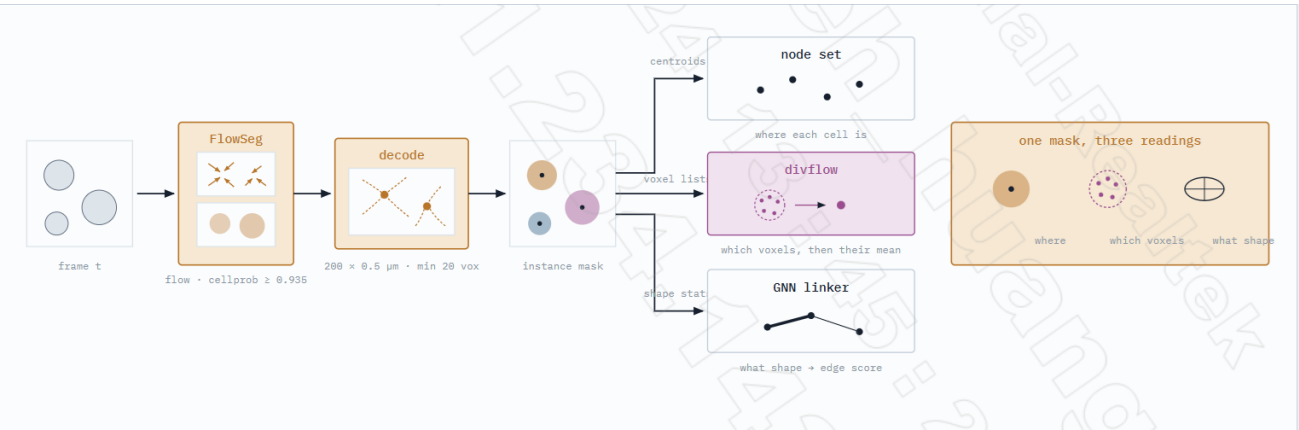
Flowseg

- 問題：これらのボリュームは核が密集しています。確率マップを閾値処理してセグメンテーションする手法はどれも、まさに重要な場所で失敗します。接触した2つの細胞の間には輝度の谷がないので、1つのブロブに統合されてしまうのです。境界を直接予測するのは 3D ではさらに悪く、境界は薄く質量の小さいターゲットであり、境界に1か所でも隙間があれば2つの細胞が統合されてしまいます。
- アイデア：物体ではなく場を予測します。各ボクセルについて、ネットワークはそのボクセルが属する細胞の中心に向かうベクトルを回帰します。するとセグメンテーションはラベリング問題ではなくなり、力学的な問題になります。各 foreground ボクセルを解放し、場に沿って積分するのです。同じ細胞のボクセルは同じアトラクタに収束し、異なる細胞のボクセルは異なるアトラクタに収束します。分離を担うのは画像のコントラストではなく場の方向なので、物理的に接触している2つの細胞でもきれいに分離されます。共有面ではフローが逆方向を向いており、この不連続性は閾値には見えませんが、積分器は即座に解決します。



- 実現方法：cellprob ≥ 0.935 でどのボクセルを解放するかを決めます。デコーダは 0.5 µm のステップを 200 回進めます。1つのシンクに到達したボクセルが1つのインスタンスを形成します。20 ボクセル未満のインスタンスは破棄します。4つの flip ビューを独立にデコードし、そのシンクをコンセンサスで統合するので、1つのビューだけが生成したシンクは生き残りません。

見落としやすい部分。出力は一度だけ消費される「セグメンテーション」ではありません。同じマスクが3つの異なるモジュールによって3通りに読まれます。そのセントロイドはトラッキングのノード集合になり、インスタンスごとのボクセル所属は divflow が平均を取るサポートになり、その形状統計量（体積、等価半径、3つの固有値）は GNN linker のノード特徴量になります。1回の forward pass で、下流に3つの異なる意味を持つのです。



Hungarian によるシンク統合と UNet との積集合

検出器は、アーキテクチャは共通だが異なる時間的証拠で学習した2つの FlowSeg チェックポイントで2回実行します。sym（diff_mode="symmetric"）は3フレームの中心化ウィンドウ [t−k, t, t+k] を見て、差分エンコーダに単一の中心差分を与えます。stack4（diff_mode="stack4_mixed"）は5フレームのウィンドウ [t−2k, t−k, t, t+k,

t+2k] を見て、4つの差分をチャネル軸に積み重ねます。2つの対称スパン（t+k − t−k、t+2k − t−2k）と2つの非対称クロススパン（t+k − t−2k、t+2k − t−k）です。短い対称ウィンドウはフレーム間であまり動かない細胞に対してシャープであり、混合5フレームスタックはより長い基線で動きを捉え、短い差分がノイズに支配されるフレームでも持ちこたえます。両者は異なる細胞で失敗し、これこそが両方を実行する理由のすべてです。

各モデルはフレームごとに、それぞれのフローフィールドを独立にシンクへデコードします。そして2つのシンク集合を、近接投票ではなく Hungarian コンセンサスで統合します。各フレームについて、マイクロメートル単位（ボクセルスケール (1.625, 0.40625, 0.40625)）で完全なペアワイズ距離行列を構築し、r = 6.0 µm を超えるすべてのペアを候補から除外する価格を付け、1対1の割り当てを解き、それでもソルバーが半径を超えて取らざるを得なかったものは破棄します。シンクが投票を獲得するのは、それがもう一方のモデルにとってグローバルに最適な排他的パートナーである場合のみで、単なる最近傍であるだけでは不十分です。

この排他性が要点です。以前の統合は多対一のソフトな逆距離投票でした。一方のモデルが1つの細胞を2つの断片に分割すると、両方の断片がもう一方のモデルの同じシンクから投票を集めることができ、両方とも生き残ってしまいます。このパイプラインの支配的な失敗モードは過検出なので、1つの証拠が無制限の数の検出を支持できるルールは誤ったルールです。Hungarian のもとでは、1つのシンクが支持できるのは最大1つのシンクです。

割り当ては常に最初のリストのシンクに蓄積されるため、アンカーが提案しなかったクラスタを作ることはできません。そのため、統合は各モデルをアンカーとして2回実行します。2つの結果の和集合を取り、4.0 µm で重複を除去します。クォーラムは 0.75 × n_entries で、エントリが2つの場合は切り上げで全会一致となるため、検出が生き残るには両方のモデルに見られている必要があります。生き残った位置はマッチしたペアの平均で、ここで融合により位置推定精度もわずかに向上します。

unettf は投票ではなく拒否権として

融合された FlowSeg のノード集合は、次に完全に別の検出器である unettf（異なるアーキテクチャ、異なる正規化、異なる学習スクリプト）との arm-D 積集合を通ります。フレームごとに unettf の検出の KD-tree を問い合わせ、INTERSECT_UM = 6.0 µm 以内に unettf の検出が1つでもあれば FlowSeg のノードを残します。

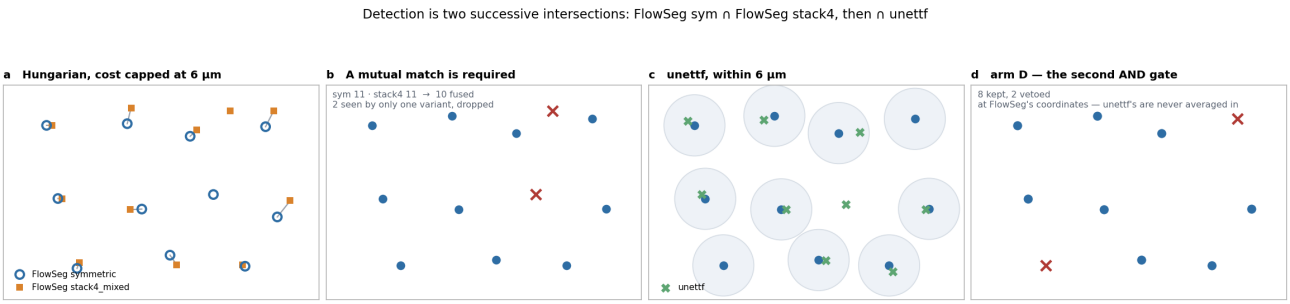
このステージの2つの性質は、見た目以上に重要です。

残されたノードは FlowSeg の座標を保持します。unettf の位置が平均に入ることは決してありません。FlowSeg の方が位置推定に優れており、2つの座標ソースを混ぜる試みはすべてマイナスと測定されました。

unettf は拒否権を行使できるだけで、投票も、シードの提供も決して行いません。unettf だけが見た細胞はグラフに入りません。これは意図的に非対称にしています。unettf の役割は recall ではなく precision であり、その固有の検出を受け入れるとロスになると測定されました。同じ理由で、unettf の fold は、各 fold のピークを連結するのではなく、ピーク検出の前に要素ごとの logit 平均で融合します。ピークの和集合を取ると、fold を追加するたびに arm-D ゲートの通過が厳密に容易になってしまい、これは裏付けのためのゲートがすべきことの正反対だからです。

同じ排他性の議論が当てはまるにもかかわらず、ここでは arm-D の多対一の形式を残しました。Hungarian と相互最近傍の両バリアントを構築して測定しました。相互最近傍は arm-D の 0.89980 に対して 0.89730 でした。division の FP は 12 から 10 に減りましたが、division の TP を1つ失い（15→14）、ノードの recall も 0.9652 から 0.9579 に低下しました。相互マッチングでは、unettf ノード自身の最近傍がたまたま別の誰かである場合に、まったく問題のないペアを捨ててしまうからです。これはグローバルな問題に対するローカルなテストであり、この段階では precision のために recall を失う価値はありませんでした。

最終的な形は2段階の裏付けです。2つの FlowSeg ビューが互いに排他的に合意しなければならず、生き残ったものはさらに異なるアーキテクチャによって独立に証言されなければなりません。下流のすべて、すなわち GNN linker、divflow、修復レイヤー、filter_output_graph は、得られたノード配列上で変更なしに実行されます。



Dual-seed TemporalUNet3D

- 問題：FlowSeg は細胞の位置についての1つの意見にすぎません。単一の検出器の見逃しはランダムではなく系統的です。動画のすべてのフレームで、同じ暗い細胞、混み合った細胞、ボリューム端の細胞を落とし、トラッカーは一度も検出されなかった細胞を回復することはできません。求められているのは、失敗の形が異なる2つ目の検出器です。
- アイデア：一度に複数のフレームを見てボクセルごとの検出ヒートマップを出力する時間的 U-Net と、それに続いてすべての (t, t+1) ノードペアを cross-attention でスコアリングする transformer です。細胞中心はヒートマップの局所最大値なので、手動チューニングの検出器が適用するであろう閾値と non-maximum suppression は、代わりにヒートマップ自体の形状に吸収されます。
- Dual seed：同じアーキテクチャを異なる seed で2回学習し、推論時には両方を実行します。それらの候補 edge は調和確率ルール（重み 0.15）で融合し、ペアが forward と reverse の両パスで支持されることを要求します。また保持率の下限を 0.90 とし、融合によってあるフレームの候補の大半が密かに捨てられることがないようにしています。

事後的な座標補正

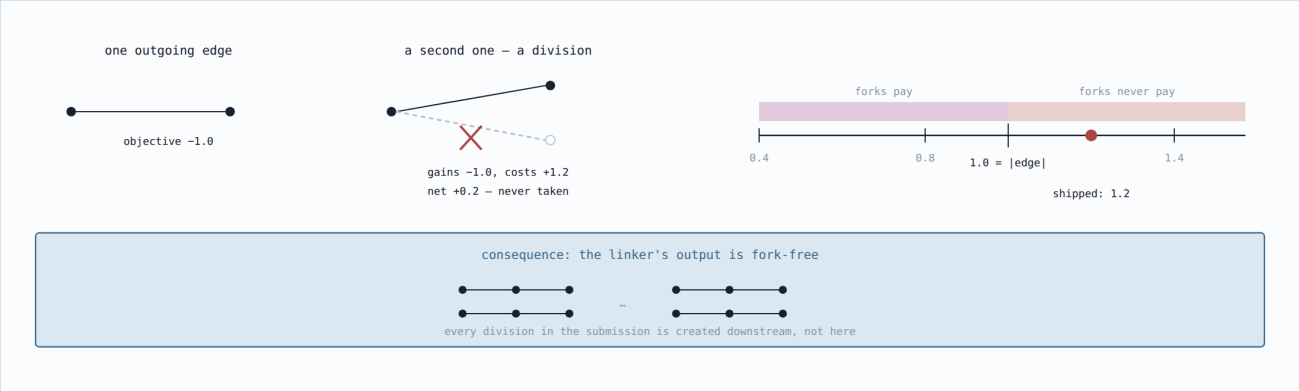
- 問題：私たちの検出には、アノテーションの慣習からの小さな系統的オフセットがあります。試した学習型の補正ヘッドはどれも、division を1つ壊すことと引き換えに edge 項での改善を得ていました。
- アイデア：1つの定数ベクトル、パラメータはゼロです。GT − 予測の残差の平均として推定し、fold 1–4 のみでフィットするので、評価 fold は決して見ません：`(+0.6807, +0.2067, +0.1725) µm`、これはボクセルでは `(+0.419, +0.509, +0.425)` です。
- どこで適用するか、そしてそれがなぜ要点のすべてなのか：**すべてのグラフ判断の後**です。両方の方法で測定したところ、このシフトは**スコアラーで +0.01116、グラフに対しては −0.00573** の価値がありました。リンク前に検出を動かすと、linker が描く真の edge が 73 本減るのです。最後に適用すれば、良い半分だけを確保できます。リーダーボードでは **+0.002** の価値がありました。

Edge

ILP linker

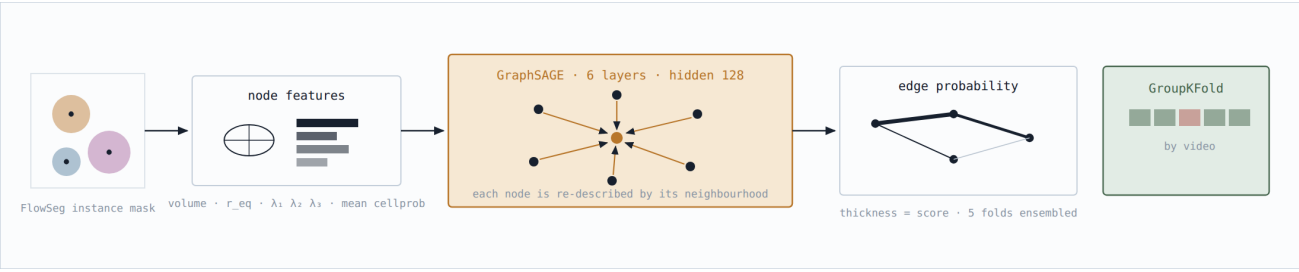
- 問題：確率付きの候補 edge が与えられたとき、有効な系譜フォレストを形成する部分集合を選ぶこと。greedy や Hungarian マッチングは各フレームペアを個別に判断するので、局所的に魅力的な誤った edge が見直されることはありません。

- アイデア：動画全体を1つの整数計画として書き、ソルバーにすべての判断を一度に行わせます。各候補 edge には報酬があり、出現と消失にはコストがあり、1つのノードからの2本目の出力 edge（division）にはそれ自身の価格があります。
- はっきり述べておく価値のある部分：`edge = −1.0` と `division = 1.2` では、2本目の出力 edge は 1.0 を得て 1.2 のコストがかかります。損益分岐点はちょうど `|edge| = 1.0` にあるため、**1.2 では fork は決して割に合わず、ILP の出力には構造上 division がゼロになります**。これが、最終サブミッションのすべての division が linker ではなく後段のステージによって作られている理由です。`appearance = 0.0` と `disappearance = 2` により、トラックを終えることは高く、始めることは無料になり、ソルバーは弱い証拠でもトラックを切るよりは継続する方向にバイアスされます。



GNN linker

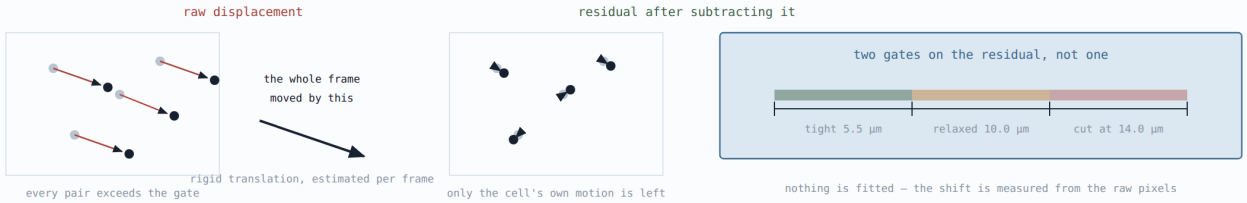
- 問題：検出器の edge ヘッドは2つのノードしか見ません。提案された edge が隣接ノードを取り残してしまうことや、同じターゲットが1細胞隣のよりマッチするソースから主張されていることは見えません。
- アイデア：(動画, フレーム) ごとに1つのグラフを構築し、message passing で分類することで、各判断が孤立してではなく近傍の文脈の中で行われるようにします。
- 学習方法：GraphSAGE、hidden 128、6 層、`jk='cat'`、dropout 0.3、(動画, フレーム) ごとに1グラフ、**動画単位**の 5-fold GroupKFold。ノード特徴量は FlowSeg マスク自身の形状統計量（体積、等価半径、3つの共分散固有値、平均 cellprob）で、これがそのマスクの3通りの読み方のうちの3つ目です。
- 予測方法：候補 edge ごとの確率で、5つの fold をアンサンブルします。



Motion relink

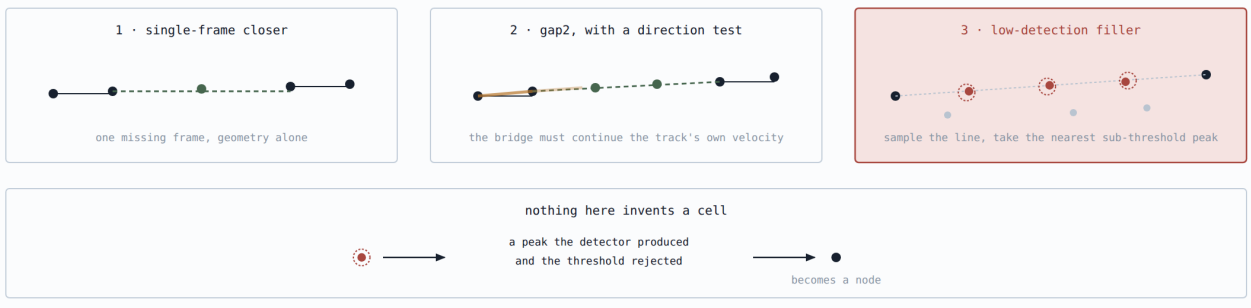
- 問題：胚は動きます。「細胞はフレーム間で X µm より多く移動できない」と表現されたゲートは、実際には2つのもの、すなわち細胞自身の動きとボリューム全体のドリフトを同時に測っており、2つ目の項が1つ目を支配することがあります。

- アイデア：フレーム全体の剛体並進を推定し、それを差し引き、残差に対してゲートをかけます。するとゲートは本来測るべきものを測るようになります。何もフィットしておらず、生のピクセルからの純粋な測定です。
- 予測方法：ゲートは1つではなく2つで、確信度の高いペアには厳しい 5.5 µm、残りには緩い 10.0 µm を使い、14.0 µm をハードな上限とします。連続しないフレームにまたがる edge は即座に除去します。



3つのギャップクローザー（安価なものから順に）

- 問題：検出器が1フレームだけ細胞を見逃すと、1つのトラックが2つに分かれ、両方の半分が誕生と消滅のように見えます。スコアラーはその両方にペナルティを課します。
- アイデア：単一フレームのクローザーは、幾何的に曖昧さがない場合に、t での終端と t+2 での始端をつなぎます。2つ目のパスは、トラック自身の速度に対する方向テストを使って2フレームのギャップを処理します。それでも開いたままのものは低検出フィラーに回ります。検出器の閾値未満のピークは予測時にダンプされており、開いた終端から開いた始端への直線を欠落した各フレームでサンプリングし、ピーク半径内で最も近い空きピークを取ります。見られてはいたが信じられなかった細胞は、一度も見られなかった細胞よりもはるかに安く回復できます。
- Readmit（再受け入れ）：同じ閾値未満のプールが、より単純なルールにも供給されます。スコアが 0.965 以上の破棄されたピークで、出力 edge を持たない、または入力 edge を持たないノードから 4 µm 以内にあるものを戻し、その後グラフを再リンクします。
- 刈り込み：edge を持たないまま残ったノードは削除し、6 フレームより短い連結成分全体も削除します。6フレームの断片は、視野に入って出ていった細胞であるよりも、検出器のアーティファクトである可能性の方がはるかに高いのです。
- 意図的にしていないこと：これらはいずれも細胞を捏造しません。追加されるすべてのノードは、検出器が生成し閾値が棄却した実在のピークです。

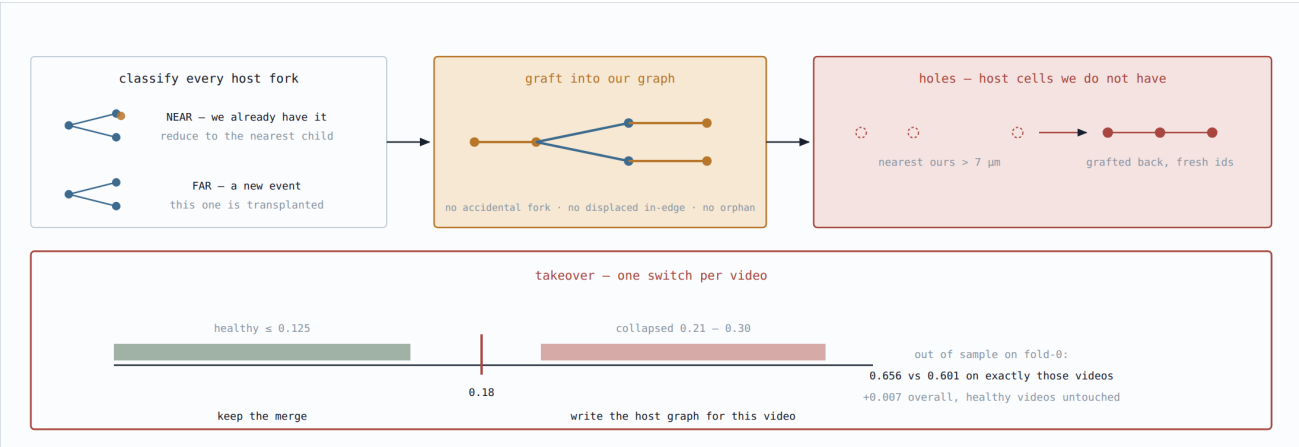


Linefit スムージング

- アイデア：ノードの位置は各フレームで独立に測定されるため、トラックは検出器のフレームごとのジッターを受け継ぎます。各ノードを自身の近傍を通る直線に再フィットし、フィットした点を採用します。このフレームレートでは細胞は滑らかに動くので、このフィットは信号ではなくノイズを除去します。
- なぜ独立した見出しにしているのか：オフにすると **−0.01914** の損失となり、私たちのチェーンの中で単独で最大のメカニズムだからです。

2つのグラフの統合

- 問題：2つの独立したパイプラインが、同じ動画について2つの完全なトラックグラフを生成します。それらはどの細胞が存在するか、どれがリンクされているか、division がどこにあるかについて食い違います。どちらも一様に優れているわけではありません。
- アイデア — 平均せずに接ぎ木する：2つのグラフの平均は定義されません。一方のグラフが骨格となり、もう一方は特定の名前付き構造を提供します。もう一方のグラフが持つすべての fork はまず、near（既に持っているのと同じ division イベント）か far かに分類されます。near のものは最も近い子に縮約され、接ぎ木でイベントが重複しないようにします。移植されるのは far のものだけです。移植は3つの拒否ルールに従います。偶発的な fork を決して作らない、元の fork の入力 edge を決して置き換えない、ノードを孤立させるような形でセグメントを決してスキップしない、です。
- Holes（穴）：もう一方のグラフのノードで、同じフレーム内に私たちのノードが 7 µm 以内に1つもないものは hole、つまりそちらが見つけて私たちが持っていない細胞です。これらは新しい id で接ぎ戻されます。同じパスで `hole_fraction = holes / its nodes` を報告し、これはその動画における私たちの検出器の不足分です。
- テイクオーバー：いくつかの動画では私たちの検出器が崩壊し、hole fraction がそれを直接測定します。健全な fold-0 の動画はすべて ≤ 0.125、崩壊したものは 0.21–0.30 です。≥ 0.18 では、その動画について統合を完全に破棄し、代わりにもう一方のグラフを書き出します。fold-0 での out-of-sample では、まさにそれらの動画で勝ち（0.656 vs 0.601、全体で +0.007）、健全な動画には一切触れません。これはメカニズムというよりフォールバックで、最悪でも一握りの動画でベースラインを出すだけです。

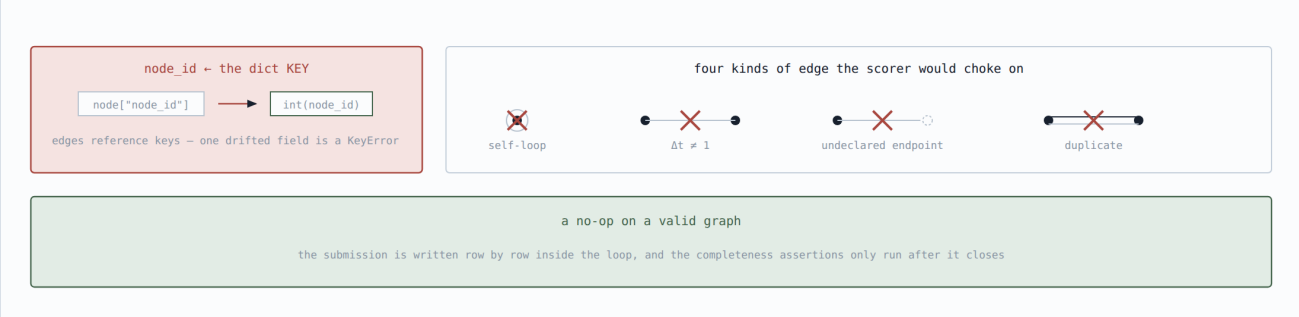


フォーマットガード

- アイデア：サブミッションは動画ごとのループ内で1行ずつ書き出され、完全性のアサーションはそのループが閉じた後にしか実行されません。そこで、ライターの直前の最後の処理として、スコアラーが詰まるであろう

ものを正確に除去するガードを置きます。自己ループ、宣言されたノードではない端点、重複 edge、そしてフレーム差が 1 でない edge です。また、edge はキーを参照し、1つのフィールドのずれがスコアラーの id マップ内で `KeyError` になるため、辞書のキーを格納されたフィールドではなく `node_id` として書き出します。

- なぜ上流での修正ではなくガードなのか：有効なグラフに対しては何もしません。コストはゼロで、その価値は、稀でデータ依存の不整合がスコアラーに到達し得ないことです。



Division

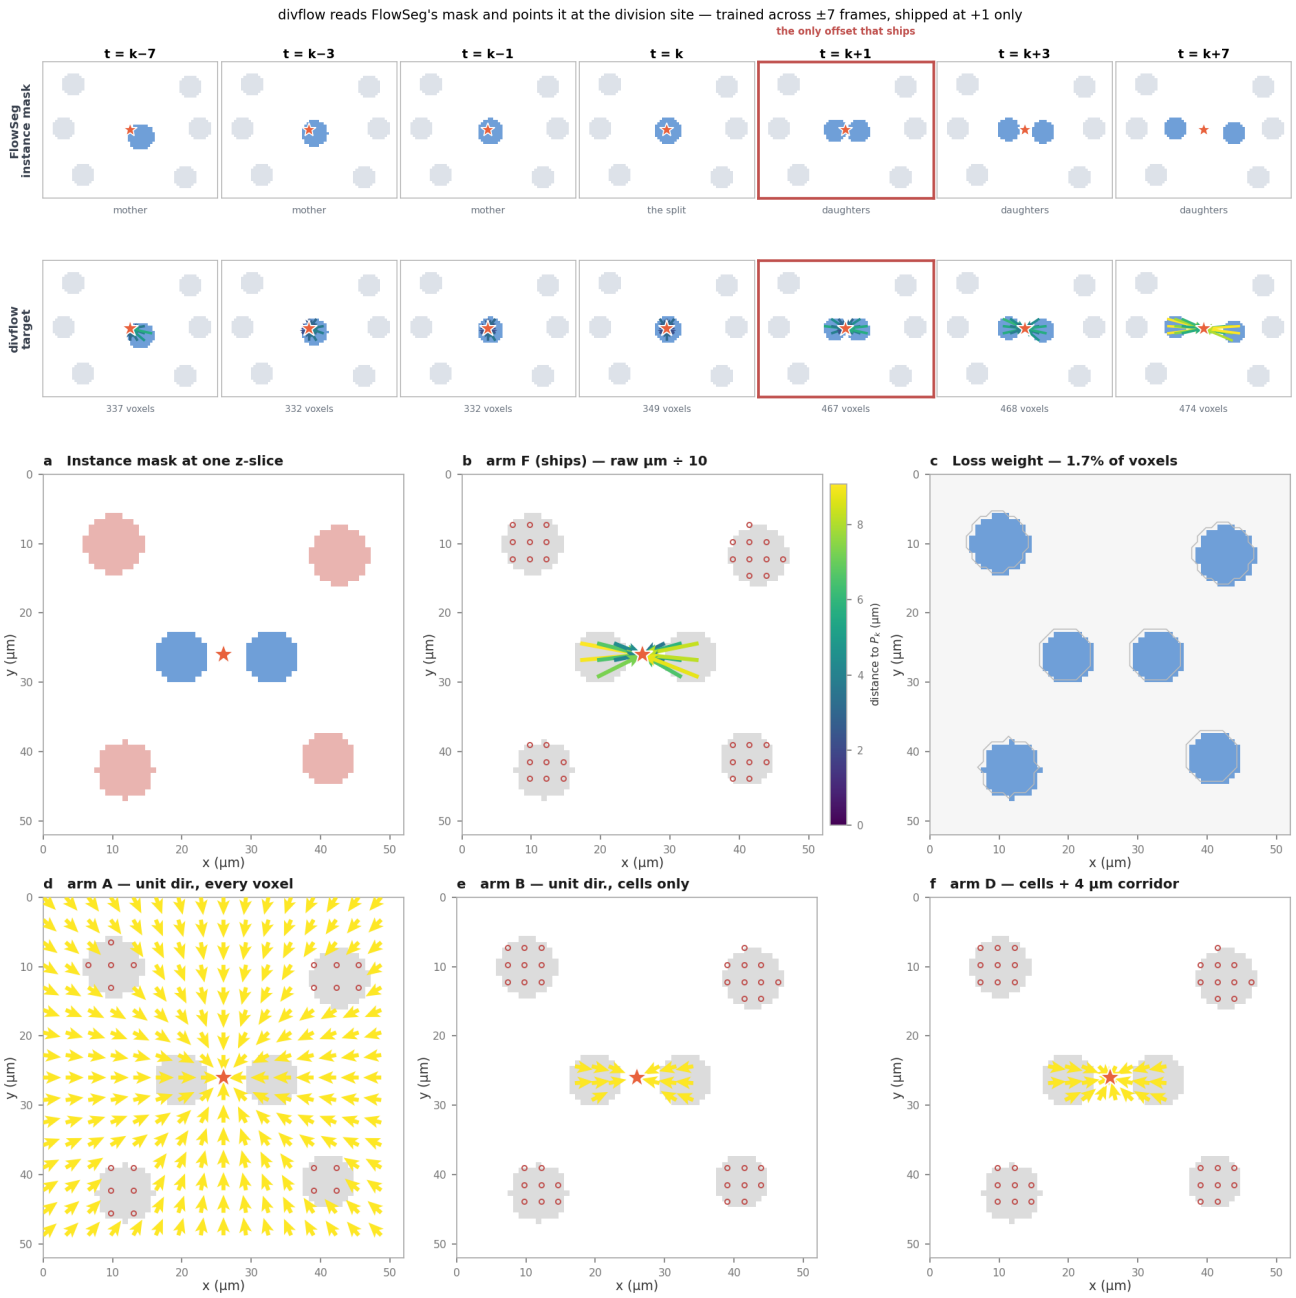
Divflow

- 問題：細胞が分裂したかどうかを判定すること。「これは division か？」という分類として扱うと、教師が非常に少ない稀なイベントの問題になります。学習セットには実際の division イベントが 121 件しか含まれていません。121 件の正例を大規模な負例プールに対して学習した分類器は、負例を学習してしまいます。
- アイデア：対応関係を回帰し、あとは幾何学に判断させます。division を分類する代わりに、ネットワークは後のフレームのすべてのボクセルについて、その親がいた場所への変位を予測します。すると division が分類されることは一切ありません。それは成り立つか成り立たないかのどちらかである一致です。

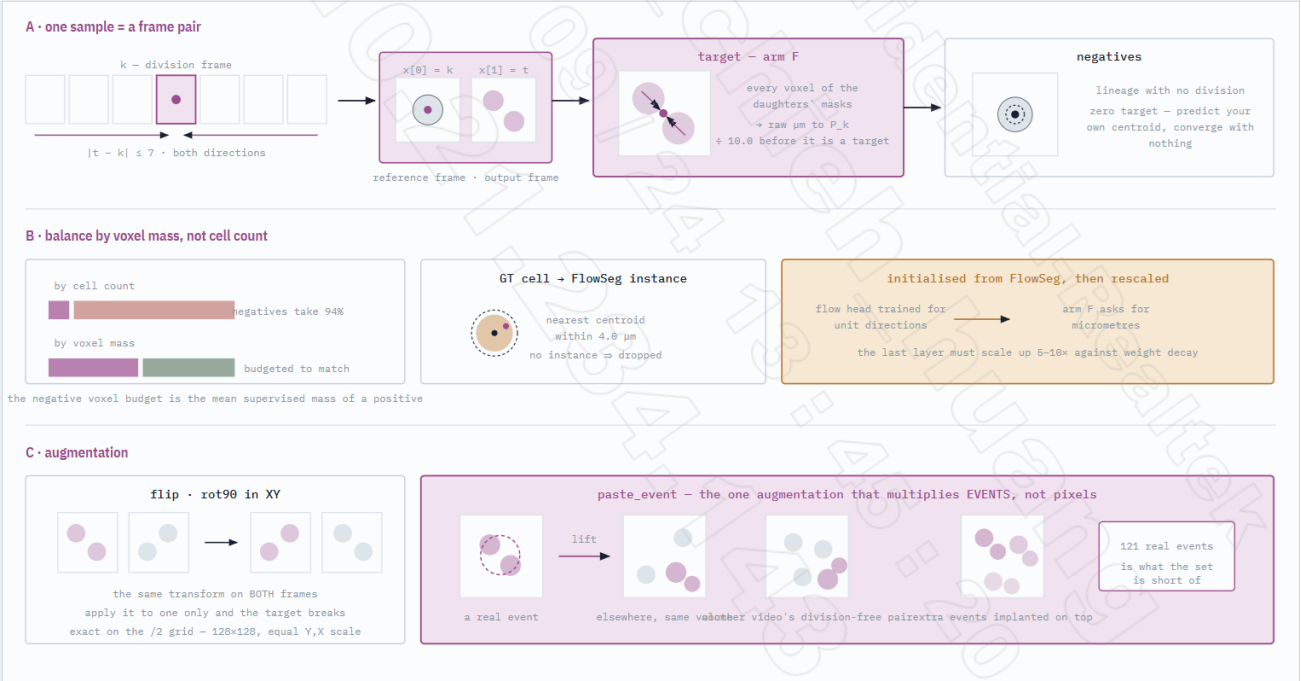
親空間での収束。フレーム k+1 の2つのインスタンスで、予測された親の位置が互いに 4 µm 以内に収まるものは、共通の起源を主張しています。 観測空間での分離。その同じ2つのインスタンスは、現時点で 3–16 µm 離れていなければなりません。

どちらの条件も、ネットワークが生成した量に対する純粋な距離テストであり、判定ヘッドは関与しません。

- なぜこの定式化が強いのか：稀なイベントの分類問題を密な回帰問題に変換します。イベントごとに1つのラベルではなく、教師付きのすべての細胞のすべてのボクセルが勾配に寄与します。そして2つの条件は互いの失敗モードを捕捉できる程度に独立しています。1つの細胞が2つの断片に過分割された場合は収束しますが、断片同士は 3 µm より近いので棄却されます。無関係な2つの細胞を同じ場所に写すフローの誤りは収束しますが、それらは 16 µm より離れているので棄却されます。どちらのテストも単独では信頼できませんが、組み合わせれば信頼できます。異なる方向に失敗するからです。



- 学習：サンプルは両方向に $|t-k| \le 7$ のフレームペア (k, t) です。チャネル 0 はターゲットが表現される division フレーム、チャネル 1 は出力が置かれるフレームです。採用したアームは、division 中心に向かう生のマイクロメートル変位を回帰し、娘細胞のインスタンスマスク内でのみ教師を与え、ターゲットにする前に 10 で割ってスケールダウンします。負例は系譜全体に division を含まない細胞で、ターゲットはゼロです。自身のセントロイドを予測する細胞は何とも収束せず、これはまさに「division なし」が意味するところです。loss はボクセル重み付けなので、バランスは細胞数ではなくボクセル質量で取ります。細胞数でバランスを取ると、負例が勾配の 94% を占めてしまいます。そして希少な資源はピクセルではなくイベントなので、重要な唯一のデータ拡張は、division イベント全体を持ち上げて別の場所に貼り付けることです。別の領域へ、別の動画の division のないフレームペアへ、あるいは1つのボリュームに複数積み重ねて貼り付けます。
- 意図的にしていないこと：出力は division ではなく投票です。クラスタリング、親の探索、そして xgboost / catboost / verifier のフィルタはすべて下流にあります。divflow の役割は、幾何学的に妥当な候補を安価かつ密に提案することであり、どれが生き残るかを決めるのは他の誰かの仕事です。



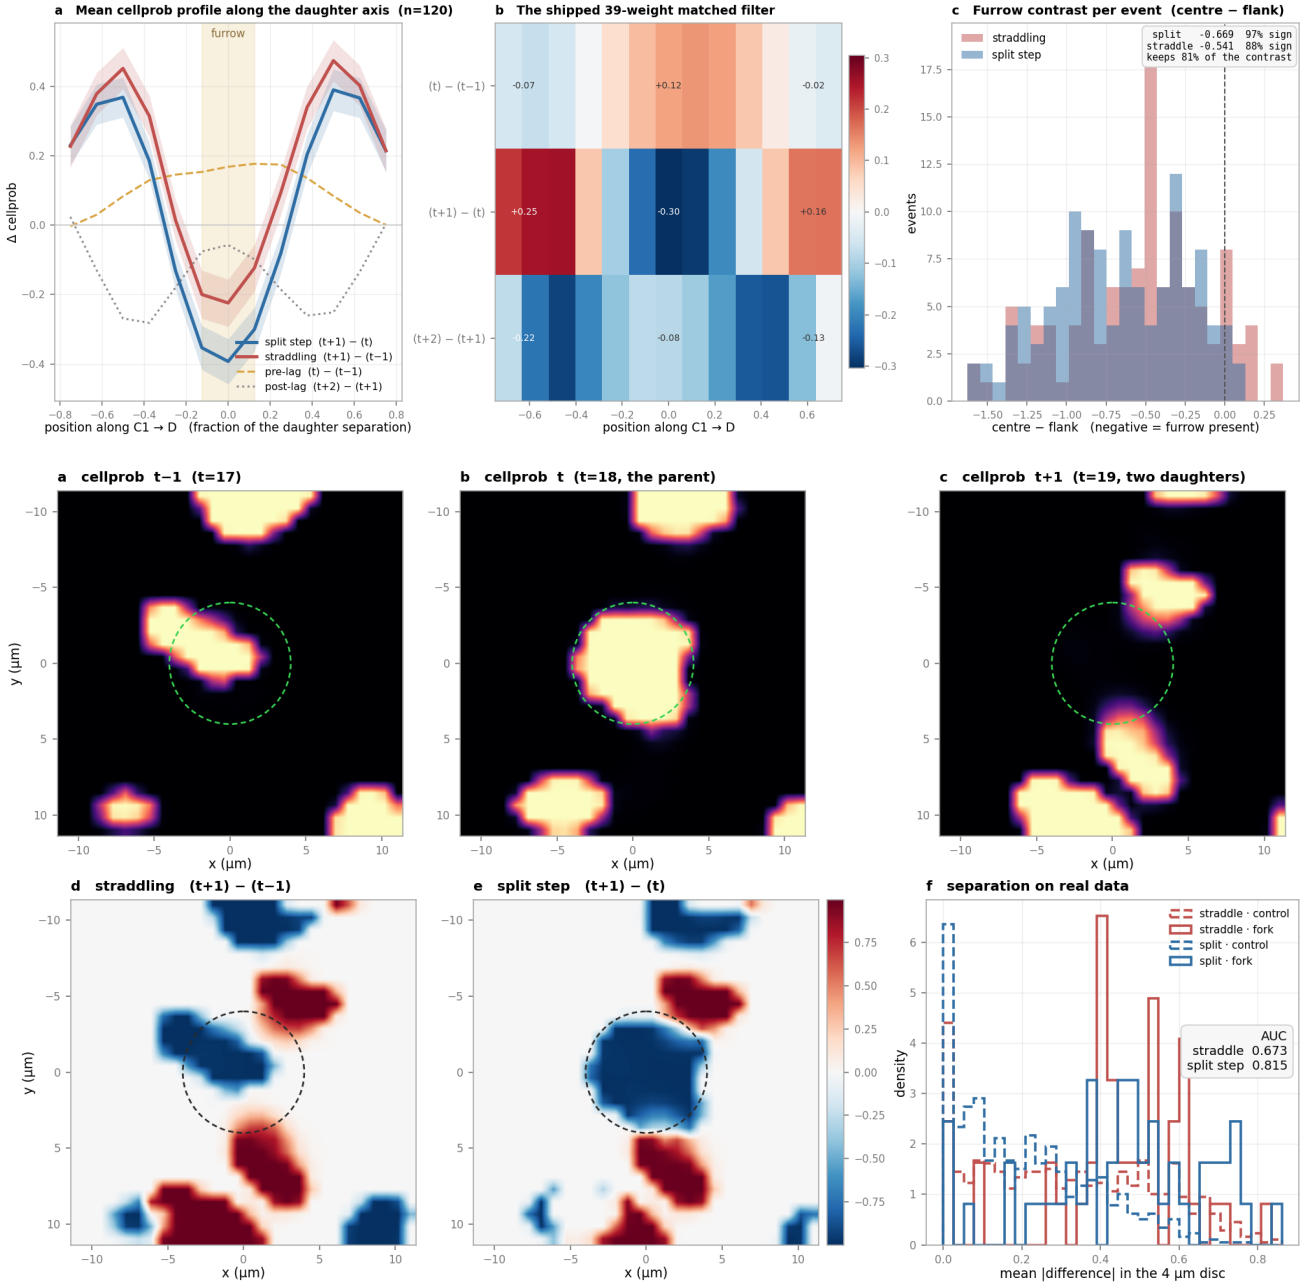
学習型の拒否権付き Safe-division 修復

- 問題：ILP は fork を一切出力しないので、何かがそれを提案しなければなりません。
- アイデア：幾何学に基づいて提案し、モデルで拒否します。他の2つのトラックの始端の近くにあるトラックの終端が候補です。2つの候補娘細胞は母細胞から離れる方向に分岐し、母細胞に関しておおよそ釣り合っていなければなりません。また、1フレームあたりおよび1動画あたりに追加できる数に上限を設け、1つの悪い動画がグラフを氾濫させないようにしています。
- 拒否権：生き残った各候補を center-prior ネットワークでスコアリングし、閾値未満なら棄却します。実際の実行ログがその比率を明示しています。176 件の幾何学的候補のうち、142 件が拒否権で棄却され、34 件が生き残り、32 件が追加されました。幾何学は意図的に寛容にしており、識別はモデルが行います。
- なぜこの順序なのか：幾何学は安価で過学習するものがありません。モデルは高価で、イベントが非常に少ないです。安価な方で提案し、高価な方でフィルタリングすることで、それぞれが強いところで使えます。

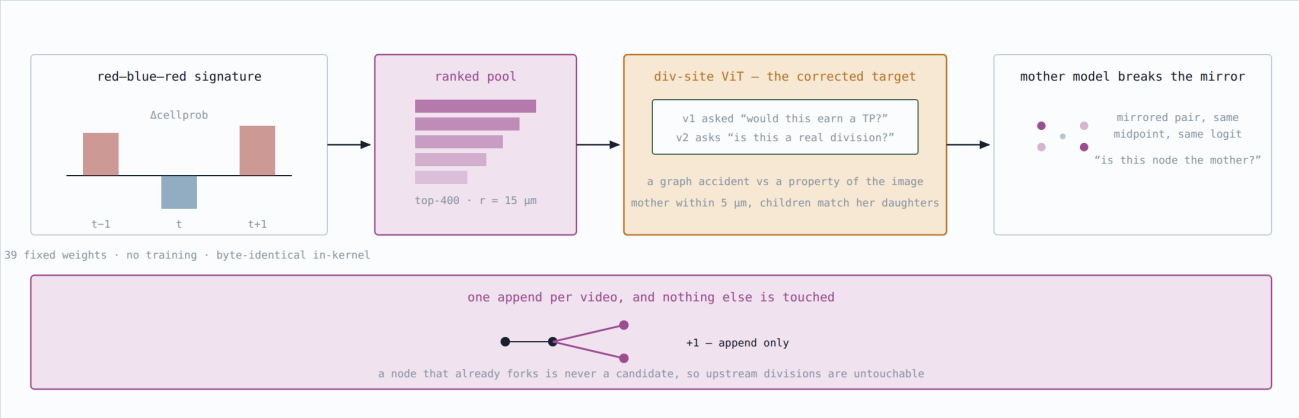
RBR adder と div-site ViT

- 問題：チェーンの最後まで来ても依然として欠けている division は、どの幾何学的ルールも提案しなかったものです。それらには画像の証拠が必要です。
- アイデア — 赤–青–赤の事前分布：分裂中の核は、3つの時点にわたって特徴的な輝度シグネチャを通過します。これを複数のラグでの Δcellprob に対する固定の 39 重みの方向付き事前分布として計算します。学習は不要で、オフラインとカーネルでバイト単位で同一であり、ランク付けされた候補サイトのプールを生成します。
- セレクタと、修正が必要だったターゲット：ViT がそのプールを再ランク付けします。最初のバージョンは「ここに挿入すると division の真陽性を得られるか？」で学習していましたが、これは画像ではなくグラフの性質であることが判明しました。TP をもたらした4つの挿入のうち2つは、FP の中央値を下回るスコアだったのです。採用したモデルは代わりに div-site ラベルで学習しています。この候補は実際の division 上にあり、

その母細胞がアノテーションされた母細胞から 5 µm 以内にあり、その子がその娘細胞とマッチするか。これは画像についての問いであり、画像から答えられます。

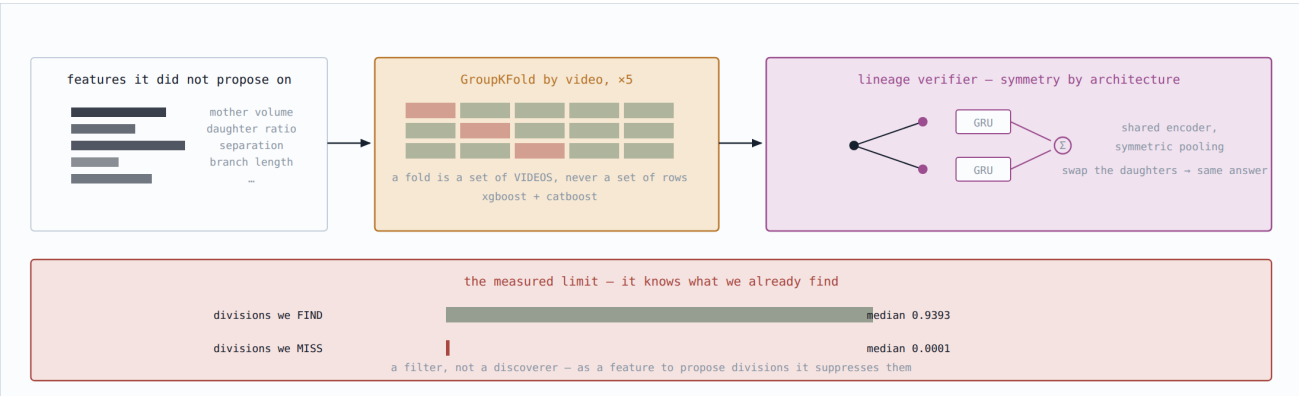


- 母細胞モデルと、それが存在する理由：娘細胞ペアを中心とするすべての信号は鏡映対称なので、鏡像の候補ペアは中点を共有し、div-site ViT は両方に同じ logit を与えます。別のモデルが「このノードは t → t+1 における division の母細胞か」を問うことで、対称性を破り、このレイヤーに方向を与えます。
- 予測方法：動画ごとに最大1件の追加で、追加のみです。何も削除されることはなく、既に fork しているノードには触れないので、上流で予測されたすべての division は、慣習ではなく構造上不可侵です。



Division 分類器と系譜 verifier

- 問題：提案された fork は、それを提案するのに誰も使わなかった特徴量、すなわち母細胞と娘細胞の体積、それらの分離距離、各ブランチがどれだけ長く生き残るかに照らして確認できます。
- テーブルモデル：xgboost と catboost、それぞれ5 fold、**動画単位**の GroupKFold。行単位ではなく動画単位でグループ化することは些細なことではありません。同じ動画からの2つの候補は検出器、フレーム、胚を共有しており、行単位の分割ではリーダーボードで決して再現されないスコアが報告されます。
- 系譜 verifier：家系木上の意図的に小さな GRU で、パラメータは数百万ではなく数千です。コーパスにはアノテーションされた division が約 151 件しかないからです。娘細胞入れ替えの対称性は、データ拡張ではなく、共有エンコーダと対称プーリングによってアーキテクチャ的に課しています。これにより実効的なデータ要件が半分になり、ある種の見せかけの学習が丸ごと排除されます。胚単位の GroupKFold を唯一の誠実な分割として扱っています。
- 測定された限界（使い方を変えたので記しておきます）：チェーンが見逃す division に対する verifier のスコアの中央値は 0.0001 で、全体では 0.9393 です。verifier は私たちが既に見つけている division を知っているのです。これは発見器ではなくフィルタであり、division を提案するための特徴量として使うと、むしろそれらを積極的に抑制してしまいます。



興味深い発見

ILP は決して分裂させない。 採用した重みでは、fork は 1.0 を得て 1.2 のコストがかかるので、価格面で完全に排除され、linker が生む division はゼロです。サブミッションのすべての division は下流で作られています。これを知ったことで、コンペの残りの時間をどこに費やすかが変わりました。

細胞数ではなくボクセル質量でバランスを取る。 ボクセル重み付けの loss では、細胞数で数えると負例に勾配の 94% を渡すことになります。これが divflow の学習が成立するか崩壊するかの違いであり、エポックごとの実現された質量を出力してみるまで目に見えません。

中央値がゼロでも効果がないとは限らない。 私たちの事後シフトは、ローカルのハーネスで動画ごとの中央値がちょうどゼロでしたが、それでもリーダーボードでは +0.002 をもたらしました。現在では、中央値が動いたかどうかではなく、動画ごとの勝率とそのばらつきで候補を判断しています。

位置推定はスコアラーを助け、グラフを害する。 同じ座標補正が、マッチングのステップでは +0.01116、linker に対しては −0.00573 です。リンク前に検出を動かすと真の edge が 73 本失われるからです。検出を動かすものはすべて両側で価格を評価し、良い半分だけが効く場所で適用する必要があります。

Out-of-fold は採用モデルを過小評価し得る。 out-of-fold のスコアベクトルは k 個の異なるキャリブレーションのモデルの混合であり、単一の絶対閾値はそれを k 個の動作点で切ることになります。これはまさに、削除や選択のレイヤーが働くランキングの上位部分をぼかしてしまいます。互いに素な動画集合で再学習して一度だけ適用すると、同じレイヤーは自身の OOF 推定よりも実質的に良い結果と測定されました。

verifier は既に見つけているものしか知らない。 検出した division では中央値 0.9393、見逃したものでは 0.0001。これはフィルタです。division を提案するための特徴量として使うと、むしろそれらを積極的に抑制してしまいます。

意図的に採用しなかったもの。 steal レイヤーと insertion レイヤー。どちらも division 項を動かしましたが、構造を削除または挿入するため、すべての数値がチェーンの残りが測定時とまったく同じであることを条件とするものになってしまいます。2つ目の divflow オフセット。これは実行時間予算のうち 0.7–1.05 h を消費し、すべての単一オフセット候補のスコアの分母を変えてしまいます。そして、リンク用の学習型アピアランスモデル。これはこのデータに含まれる2つの胚ファミリー間で転移しませんでした。