biohub-cell-tracking-during-development

16位 Solution

Rank	16
Team	r3takahashi
Author	r3takahashi
Topic ID	744671
Version	Japanese Translation

Source: https://www.kaggle.com/competitions/biohub-cell-tracking-during-development/discussion/744671
Retrieved with Kaggle CLI on 2026-10-04.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

素晴らしいコンペを開催してくださった CZ Biohub と Kaggle、そしてノートブックやディスカッションを共有してくださった皆さんに感謝します。これは私が初めて提出した Kaggle コンペでした。選択した 2 つの submission は **Public leaderboard で 0.963 と 0.960、Private leaderboard ではどちらも 0.943** で、16位となりました。1 つ目は 2 つの detector のブレンド、2 つ目は ResEnc-L 単体です。

TL;DR

- Detection: 2 つの 3D U-Net による中心 heatmap detector、すなわち nnU-Net ResEnc-L と Kinetics 事前学習済み ResNet3D-18 U-Net です。コンペの疎なアノテーション (Gold) と pseudo-label (Silver) を用いて、複数ラウンドの self-training で学習しました。Silver は最初は teacher の検出結果から、その後は自分自身の tracking 出力から作成しました。最終ブレンドでは 2 つの detector の logit を平均しています。
- Linking: 公開されている UNet-Transformer edge predictor + ILP tracking スタックを使い、edge head を自前の候補で fine-tune しました。
- Private でより大きな改善をもたらしたのは detector への変更でした。

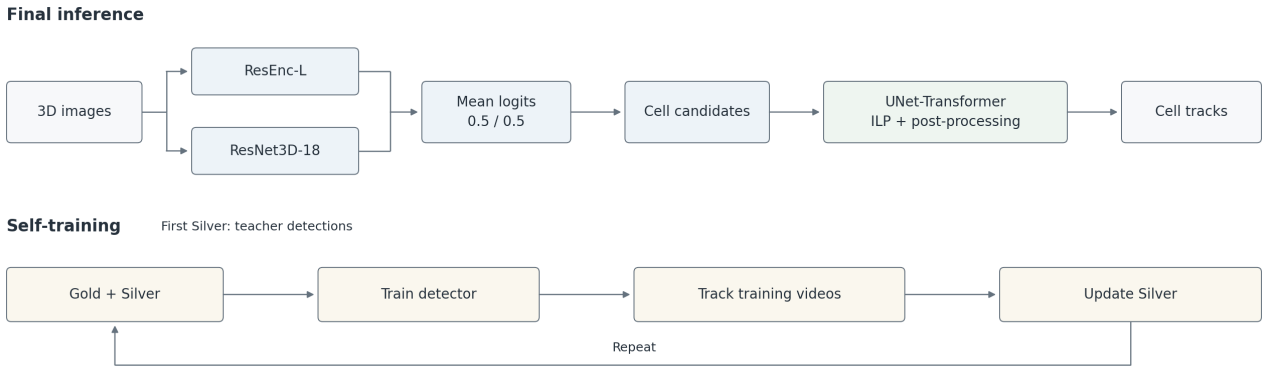


図 1. 最終推論 (上) と self-training ループ (下)。

---

1. パイプライン

Detection. 各 3D フレームの形状は 64×256×256、voxel spacing は 1.625×0.40625×0.40625 µm (z, y, x) です。x と y 方向にダウンサンプリングしてから、細胞中心の周りの Gaussian heatmap を予測する 3D U-Net に入力しました。面内 pooling を 4× (64×64) から 2× (128×128) に変更すると、同じ学習レシピでの対比較で Public が 0.946 から 0.951 に上がりました。候補抽出には、抑制半径 3 µm の局所最大値、面内 flip による 4 ビュー TTA、放物線フィッティングによるサブ voxel 精緻化を用いています。

疎なラベルでの学習. Gold ラベルは一部の細胞しかカバーしていないため、ラベルのない領域をすべて背景として扱うことは避けました。Gold heatmap に対して重み付き binary cross-entropy (BCE) loss を使用し、重みは Gold 中心付近で 12、選択した背景領域で 1、それ以外の大部分の voxel で 0.02 としました。heatmap の Gaussian 幅は σ = 1.625 µm です。

student では、Silver pseudo-label に対する別の BCE loss を 0.25 倍のスケールで追加しました。

背景の教師信号に FOCUS-3D を活用. 背景は暗い領域から選択しました。student ではさらに、外部の事前学習済みセグメンテーションモデル FOCUS-3D によるインスタンス重心を参照点として用い、Gold・Silver・FOCUS-3D

のいずれの点からも 5 µm 以上離れた位置を追加の背景として選びました。狙いは、ラベルのない核を背景として扱ってしまうのを避けることです。6bba 胚の学習動画 124 本において、Gold 中心の 88% は 4 µm 以内に FOCUS-3D の点があり、difference-of-Gaussians (DoG) detector の 78% を上回りました。アノテーションされた細胞のうち最も暗い 20% に対する FOCUS-3D のカバー率は 82% でした。これらは最近傍点によるカバー率であり、コンペの 7 µm マッチング指標とは別物です。

疎なアノテーションのため全体の precision を評価するのは難しく、最終レシピではこれらの点を背景の参照点としてのみ使用しました。誤検出があると有用な背景の教師信号が失われる可能性はありますが、正例のターゲットになることはありません。これは追加の背景マスクにのみ適用され、FOCUS-3D 重心付近の voxel も元の暗い背景マスクには含まれ得ます。

別途行った Gold のみの teacher 実験では、この背景項を加えるとキャリブレーション動画での recall が低下しました (0.945 vs 0.973)。そのため teacher のレシピからはこの項を外し、Gold とマッチしなかった DoG 候補の近くにある不明な voxel を無視するという既存のルール (positive-unlabeled 的な扱い) を維持しました。

Self-training. 最初の Silver ラベルは、連続 3 フレームにわたる Conv1D temporal mixer を持つ Gold のみで学習した R(2+1)D U-Net teacher から得ました。2 つの teacher seed の検出結果をマージしています。その後、各 student を Gold + Silver で学習し、その student 自身の tracking 出力 (ILP と後処理を経た最終ノード) を次ラウンドの Silver とします。各 student ファミリー内では、学習レシピと seed はラウンド間で固定し、Silver だけを変えています。各ラウンドは同じ初期化方式でゼロから学習し直します。R(2+1)D teacher と ResNet3D-18 には Kinetics-400 事前学習済みエンコーダ、ResEnc-L にはランダム初期化を使いました。以下のラウンド番号は pseudo-label の系譜に従っているため、ResEnc-L はラウンド 2 から登場します。

Round	Detector	Silver (pseudo-label) の作成元	後処理[1]	Public	Private	最終ブレンドに使用
0 (teacher)	R(2+1)D temporal U-Net, 2 seeds, 4× pooling	— (Gold のみ)	—	—	—	
1	ResNet3D-18	teacher の検出結果	old (relink on)	0.947	0.935	
2	ResNet3D-18	round 1 の tracking 出力	old (relink on)	0.953	0.942	
2	ResNet3D-18 (上と同じ重み)	round 1 の tracking 出力	new (relink off + 設定変更)	0.959	0.940	✓
2	ResEnc-L	round 1 の tracking 出力 (上と同じ Silver)	new (relink off + 設定変更)	0.955	0.944	
3	ResEnc-L	ResEnc-L round 2 の tracking 出力	new (relink off + 設定変更)	0.960	0.943	✓
4	ResEnc-L	ResEnc-L round 3 の tracking 出力	new (relink off + 設定変更)	0.959	0.941	

[1] "old" = motion relink を on にした公開スタックのデフォルト、"new" = motion relink を off にし、公開ノートブック `biohub-x138` から採用した後処理パラメーター式を加えたもの (Section 2)。

最終ブレンドは ✓ の 2 モデルの logit を等しい重み (0.5/0.5) で平均したもので、もう 1 つの選択 submission は ResEnc-L round 3 単体です。同じ後処理の行同士で比べると、ResNet3D-18 の round 2 は Public・Private の両方

で round 1 を上回りました。ResEnc-L では round 3 で Public が上がりましたが、Private では round 3 も round 4 も round 2 を超えませんでした。

この系譜は実験を追加するにつれて拡大していったものです。当初は 3D ResNet の teacher を学習し、その Silver から各 detector について 2 ラウンドずつ回すつもりでした。実際には、初期の実験で使った R(2+1)D temporal U-Net teacher をそのまま使い、ResEnc-L は ResNet3D-18 の round 1 の tracking 出力から開始しました。これにより同一の pseudo-label で student アーキテクチャを比較できましたが、ResEnc-L が teacher の Silver で直接学習されることはありませんでした。

Linking と後処理. 公開されている tracking スタック (UNet-Transformer edge predictor + ILP + division と gap-closing の後処理) を使い、その detector を自分のものに置き換えました。detector を変更するたびに、新しい候補で edge head を fine-tune しました (transformer 部分のみ、5 epoch、最終 checkpoint を使用)。最終モデルでは、6bba 胚の 4 本のキャリブレーション動画において固定の候補数目標に合うように候補の閾値を再キャリブレーションしました。これらの動画は detector の学習と edge head の fine-tune からは除外しましたが、同じ胚の他の動画は学習に使用しています。

---

2. 変更点と Public・Private スコア

各行は、submission とその変更元の構成とを比較したものです (括弧内が Δ)。これらの変更はすべて最終ブレンド submission に含まれています。self-training のラウンドについては上の表を参照してください。Private スコアは締め切り後に公開されたため、これらの選択には影響していません。

変更	比較対象	Public (Δ)	Private (Δ)
面内 pooling を 4× → 2× (ResNet3D-18 単体)	4× pooling	0.951 (+0.005)	0.939 (+0.004)
motion relink を無効化	relink on	0.958 (+0.005)	0.943 (+0.001)
公開ノートブックの後処理パラメータ	relink off のみ	0.959 (+0.001)	0.940 (−0.003)
ResEnc-L + ResNet3D-18 の logit ブレンド	ResEnc-L 単体 (round 3)	0.961 (+0.001)	0.944 (+0.001)
linefit smoothing を弱める (0.8 → 0.4)	ブレンド	0.963 (+0.002)	0.943 (−0.001)

Private スコアを踏まえて振り返ると:

- **ResEnc-L が際立っていました:** Silver と後処理が同一の条件で、Public では ResNet3D-18 より低いスコアでしたが、Private では上回りました。
- **Public での後処理による改善は、ほとんど Private には持ち越されませんでした。**

motion relink を無効化した理由: これは ILP の後に、運動の外挿を使って track の端点を再リンクするものです。学習用の胚の動画を使ったローカル診断では、隣接する細胞 (7–11 µm 離れたもの) の間の誤リンクが edge エラーの主な原因でした。relink を無効化するとこれらのエラーが減少しており、この構成では relink が修正するよりも多くの誤リンクを生んでいたことが示唆されます。ただし Private では、観測された差は小さいものでした (+0.001)。

---

3. パイプラインの改善につながらなかったこと

多くのアイデアは Public スコアをほとんど変えないか、悪化させました。Section 5 の seed によるばらつきを考えると、0.003 程度以下の Public の差はあまり重視すべきではないと考えます。この範囲の変更の一部は採用しま

した。ローカル診断では設定変更後の後処理と弱めの smoothing が有利であり、ブレンドは異なるアーキテクチャを組み合わせたもので、当時最も高い Public スコアだったためです。

これらのローカル診断は学習に含まれる胚を使っているため、未知の胚への汎化を示すものではありません。以下のアプローチは私のセットアップでは明確な効果が見られませんでした。一部は leaderboard に提出せず、ローカル診断の段階で却下しています:

- 同じレシピの seed アンサンブル、detector メンバーの追加、8 ビュー TTA。
- 合成学習データ (物理シミュレーションによる核と division)、学習ベースの division head。
- ILP コスト、候補抑制半径、候補数のチューニング。
- 学習ベースの座標精緻化 head (一部の公開ノートブックにあるもの) と、linking 前に適用するいくつかの学習ベースの位置回帰器 (ローカル評価のみ)。
- Gold ラベルのみでの detector の fine-tune (キャリブレーション動画で recall が低下したため未提出)。

---

4. 分析: 大きな位置ずれは、試したモデル間で共通している

位置が重要な理由: 評価指標は、予測ノードとアノテーションを 7 µm 以内でマッチングします。予測 edge が正解とみなされるには、その端点が対応するアノテーション edge の端点とマッチしている必要があります。私が調べた曖昧なケースでは、隣接する核が 7–11 µm しか離れていないことがあり、数 µm ずれた検出はマッチを失うか隣の核とマッチしてしまい、関連するリンクが無効になり得ます。

4 本のキャリブレーション動画 (私の学習からは除外したが、学習にも含まれる胚のもの) では、モデル間で recall を揃えたとき、**アノテーションされた細胞位置の約 14%** が 2.5 µm 以上離れた検出とマッチしていました。この割合は ResNet3D-18、ResEnc-L、そのブレンド、異なる self-training の系譜の間で同程度でした。4 モデルの比較では、モデル間の位置ごとの誤差の相関は **0.93–0.96** でした。4 モデルのうち少なくとも 1 つで大きなずれがあった 413 個のアノテーション位置のうち、274 個 (~66%) は 4 モデルすべてで大きなずれがありました。

誤リンクを調べると、アノテーションが約 9 µm 離れた 2 つの検出の間に位置しているケースが見つかりました。一部のペアは z 方向に並んでおり、画像上に明確な境界が見えませんでした。

実験として、linking の前にマッチした検出を ground-truth 座標に移動させてみました。これにより 71 本の動画でローカルスコアが約 0.05 上がりました。この実験は detector の学習時に見た胚の ground truth を使っているため、その改善が実用的なモデルに持ち越されるとは限りません。それでも、位置推定と対応付けには改善の余地があることを示唆しています。

試したアンサンブルや self-training のバリエーションでは大きなずれの割合はほとんど減らず、位置回帰でも tracking スコアは改善しませんでした。この点はコンペ終了時点でも未解決のままでした。

---

5. Public vs Private

締め切り後、Private スコア上位 31 個の submission は **0.939 から 0.946** の範囲で、同じ submission の Public は 0.943 から 0.963 でした。同じ学習レシピで random seed だけを変えたある比較では、Public で 0.006、Private で 0.001 の差が生じました。1 ペアだけですが、Public の差は私が追い求めていた改善の多くと同じくらいの大きさでした。

Private スコアが最も高かった submission (0.946) は、MAE 事前学習済みエンコーダを持つ ResEnc-L detector を使ったものでした。Public では 0.953 で、私はこれを選択していませんでした。別の submission では、teacher を 2× pooling (128×128) で再学習し、self-training のチェーンを繰り返しました。同じ後処理で Public は 0.947 となり、元の系譜の 0.959 に対して (−0.012) だったため、これも外しました。Private ではこの比較は逆になり、

0.944 vs 0.940 (+0.004) でした。振り返ってみると、近い構成同士を選ぶうえで、Public の小さな差は信頼できる基準ではありませんでした。

---

6. 謝辞

- @pilkwang さん: 公開 tracking スタックと、私の最終ノートブックで使用したそのデータセット `biohub-tracking-support-pack-50ep-v1` (UNet-Transformer edge predictor と tracking コード)、`biohub-temporal-unet3d-seed314159-v1`、`biohub-deepcenter-unet3d-center-prior-v1` (DeepCenter)。
- @anvithpothula さん: ノートブック `biohub-x138`。ここから後処理パラメーター式を採用しました。
- 私の submission ノートブックは nusrati/0-936 のコードをベースにしており、これは rishabhr0y/933-biohub-bidir30 と stephennedumpally/pls-upvote-share-higher-scoring-ideas から派生したものです。@nusrati さん、@rishabhr0y さん、@stephennedumpally さんに感謝します。
- @hengck23 さん: このコンペに FOCUS-3D を紹介してくださいました (discussion 738217)。また FOCUS-3D の著者の皆さん (yu-lab-vt/FOCUS-3D、BSD-3-Clause、重みは Hugging Face の `Qinghua-thu/FOCUS-3D`)。その検出結果を参照点として使用しました。
- nnU-Net / dynamic_network_architectures (ResEnc-L アーキテクチャ)。
- torchvision の Kinetics-400 事前学習済み R(2+1)D-18 および ResNet3D-18 の重み。