biohub-cell-tracking-during-development

17位 Solution

Rank	17
Team	ibyyue
Author	by
Topic ID	744930
Version	Japanese Translation

Source: https://www.kaggle.com/competitions/biohub-cell-tracking-during-development/discussion/744930
Retrieved with Kaggle CLI on 2026-10-04.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

Private 0.942・Public 0.966. 3D U-Net detector のアンサンブル、augmented LAP として解く gradient-boosted linker、gradient-boosted な division head、そして小規模な学習ベース／ルールベースのグラフ編集の連鎖による tracking-by-detection です。

使用したのはコンペのデータのみで、すべてのモデルはスクラッチから学習しました。

1. 設計を方向づけたもの

- **テスト胚は新しい胚です。** 学習データには 2 つの胚があります。44b6 (71 動画、密で小さな核、動画あたり約 4 本のアノテーション済み track) と 6bba (128 動画、より大きな核、動画あたり約 29 本の track) です。public と private の leaderboard は、さらに別の 2 つの胚を使っています。動画単位の CV では転移性能が過大評価されたため、検証はすべて胚単位で hold out しています。
- **アノテーションは疎で、余分なノードにはペナルティがかかります。** アノテーションされている核は約 2.5% のみで、それらに接する edge だけがカウントされます。edge Jaccard には `1 − 0.1·(N_pred − N_est)/N_est` が乗算され、これは符号付きでクリップされません。余分なノードはほぼ必ずこのカウント項を支払う一方で edge を獲得することはまれなため、「recall を増やす」系のアイデアの大半はこれで除外されました。
- **Division Jaccard は動画全体で micro-pool されます。** 最終 submission 1 の 199 学習動画での 46 TP / 54 FP / 105 FN の場合、division を 1 つ回復すると約 +0.0005 の価値があります。重み 0.1 の division 項が単一の損失としては最大でした (約 0.078)。
- **データには 3 つの罠があります:**
  - 44b6 で学習した detector は、より大きな 6bba の核で二重ピークを出し、平行な重複 track を生成します。すると、フレームごとの 7 µm マッチングがそれらの間を行き来し (hop)、hop ごとに FN 1 つと最大 FP 2 つのコストが生じます。
  - 6bba にはバイト単位で同一の、前方補完されたフレームが約 950 枚あります。
  - どちらの胚にも、5 µm 以上の視野全体のステージジャンプがあります (6bba の動画あたり中央値 4 回)。

2. 検証

- **胚をまたぐ CV:** 199 本の学習動画すべてを、もう一方の胚で学習したモデルでスコアリングします。学習ベースのコンポーネントは、フィッティングした smoothing kernel を除いてすべてこの方法で学習しています。その kernel (KSM、Section 3.4) は両方の胚の design half の位置でフィッティングしました。厳密に胚をまたぐバージョンでは、199 本全体で +0.0008 でした。
- **Design half と confirmation half:** 後期の変更はそれぞれ、動画の固定された半分 (89 本) で設計しました。その後、コードとモデルのハッシュ、および合格ルール (プールした改善量の最小値と、各胚ごとの下限) を凍結し、もう半分 (110 本) で一度だけ実行しました。Figure 1 にある、design half で勝った 19 個の変更のうち 7 個は、confirmation の結果却下されました。
- **Leaderboard:** public と private は異なる胚なので、public LB はノイズの多いチェックでしかありませんでした。最終的な 2 つの division head は、5 回の対になった submission すべてで public では +0.005–0.006 の差がありましたが、private では差は最大 0.001 でした。

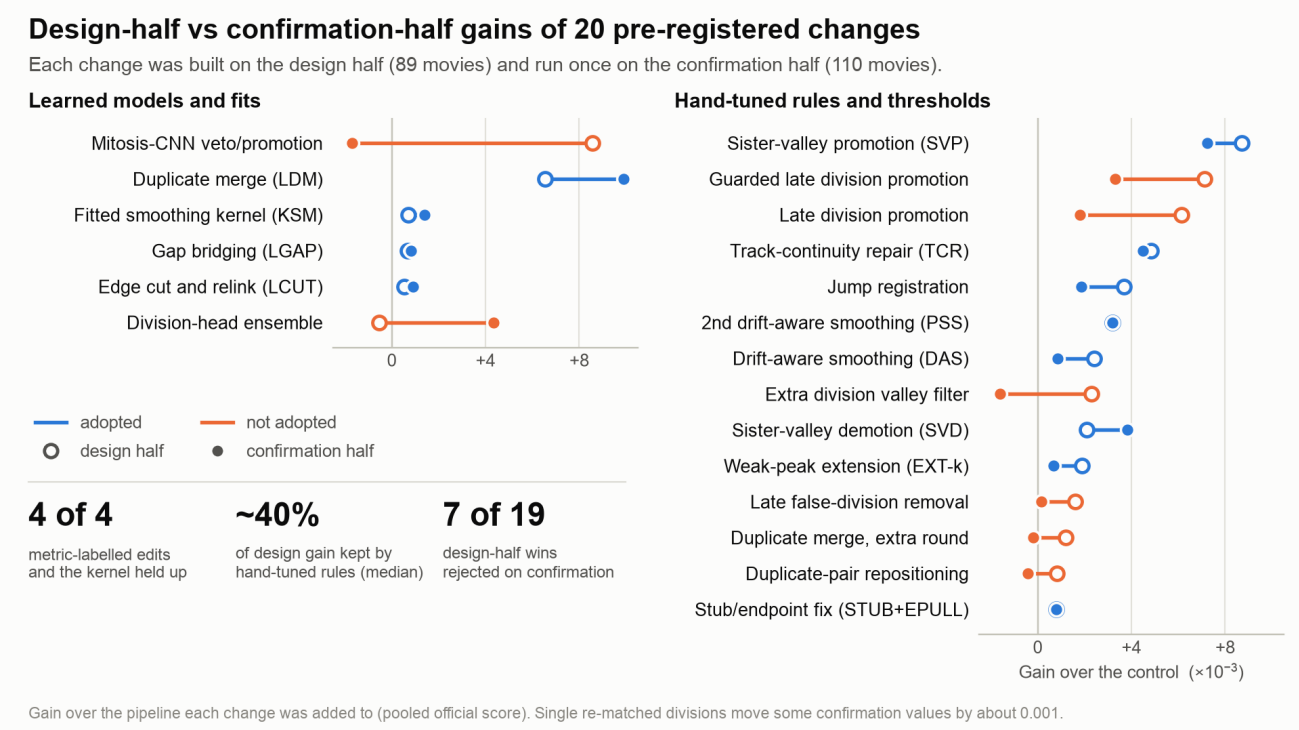


Figure 1. 事前登録した変更のうち 20 個についての、design half (白抜き) と confirmation half (塗りつぶし) での改善量。

- **学習ベース:** metric でラベル付けした編集 (LDM, LGAP, LCUT) とフィッティングした kernel (KSM) は、confirmation でも design と同等以上の改善を示しました。mitosis CNN は逆転しました。
- **手動チューニングのルール** は、design での改善量の中央値で約 40% を維持しました。division が 1 つ再マッチするだけで、confirmation の値が約 0.001 動くことがあります。
- **Division ルール:** sister-valley ルール (SVP, SVD) は維持されました。後から追加した division ルールは、改善量の大半を失うか逆転しました。

3. パイプライン

```
raw 64×256×256 (1.625 / 0.406 / 0.406 µm)
 → 4×4 mean-pool in y/x → 64³ isotropic, percentile-normalised
 → detection: 2 × 3D U-Net + flip TTA → centre heatmap → peaks ≥ 0.18   [adaptive down-scaling for large nuclei]
 → staging: distance bootstrap → learned linker ×2 on all peaks → drop components < 5 frames (< 3 at t=0/T−1)
 → linking: learned linker + augmented LAP (pass 2) → 1-frame gap closing
 → divisions: D2 triple classifier + sister-valley promotion/demotion → track-continuity repair
 → prune (span ≥ 8; ≥ 2 if mean link p ≥ 0.95; ≥ 20 if mean link p < 0.7; components with a fork kept)
 → drift-aware smoothing
 → post-edits: LDM → LGAP → LCUT → EXT-k → PSS → STUB+EPULL → KSM → CSV
```

以下で使う名称:

名称	意味
D2	mother–daughter の triple に対する division 分類器

名称	意味
SVP / SVD	sister valley による division の昇格 / fork の降格
DAS	drift-aware smoothing
TCR	track-continuity repair (track 連続性の修復)
LDM	学習ベースの重複マージ (learned duplicate merge)
LGAP	学習ベースのギャップ橋渡し (learned gap bridging)
LCUT	学習ベースの edge 切断と再リンク (learned edge cut and relink)
EXT-k	弱い detector ピークに沿った track の延長
PSS	2 回目の drift-aware smoothing
STUB+EPULL	短い断片 (stub) の除去と端点の引き寄せ (endpoint pull)
KSM	フィッティングした smoothing kernel

3.1 Detection

- **ネットワーク:** Gaussian の中心 heatmap (σ = 2.2 µm) を予測する 3D U-Net (4 レベル、32–256 チャネル、InstanceNorm、SiLU)。
- **Loss:** 疎なアノテーション用マスク付きの CenterNet 風 focal loss。アノテーション済み細胞の周りの球内では完全な教師信号を与え、暗い背景では弱い負例とします。それ以外はすべて教師なしとしています。ラベルがないことは負例を意味しないためです。
- **Checkpoint 選択** は hold-out したクロップで行いました:
  - 最初のモデル: 期待ノード数の 1.25× における recall。
  - 再学習: 1.5 µm 以内での一対一の recall。
- **アンサンブル:** 全データで学習した 2 モデル (短い学習と、より長い再学習) の確率マップを平均。6bba ではこのペアがどちらの単体モデルよりも良く (CV 0.844 vs 0.829 / 0.826)、代わりに 44b6 では 0.006 のコストがありました。
- **推論:** 4 種類の flip、0.18 を超える 3×3×3 の局所最大値、二次関数によるサブ voxel 精緻化。
- **適応的スケール:** フレームの 2 番目の最近傍間隔の中央値が基準値を超えた場合、ボリュームを 基準値/間隔 の比率で縮小し (最大 0.6× まで)、detection を再実行します。
  - これにより核サイズのミスマッチが解消されました。単一 fold の detector とそれ自身の基準値 (9.5 µm) で、6bba の CV が 0.717 から 0.829 に上がりました。
  - 実運用した全データ detector では 13.6 µm を使っています。
  - 拡大とマルチスケール平均はどちらも負けました。

3.2 Linking

- **Linker:** 13 µm 以内の各候補ペアに 47 個の特徴量を与え、HistGradientBoosting モデル (400 本の木) でスコアリングします。特徴量は次のとおりです:
  - 変位、および track 自身の速度と k-NN による局所運動場に対するその残差 (z と xy を分離);
  - detector のスコア;

    - 競合する候補間での競合順位とマージン;
    - 局所密度とパッチ記述子の類似度;
    - 距離のみの bootstrap linking との一致。
- **割り当て:** フレームペアごとの Jaqaman augmented LAP。コストは −log p、birth/death コストは −½ log 0.35、各側で上位 5 候補とし、scipy の疎行列版 `min_weight_full_bipartite_matching` で解きます。
- **2 パスの staging:** 学習ベースの linker をすべての検出に対して実行し、次に自身のリンクを運動場として使って再度実行します。最終パスの前に 5 フレーム (時間境界では 3 フレーム) より短いコンポーネントを除去するので、短命な紛らわしい検出がターゲットを奪い合うことはありません。最初の学習ベースのパスは、距離のみの linking による prune を置き換えたもので、+0.0126 の改善でした。2 回目のパスと境界ルールは後のステップで追加しました。
- **重複フレーム:** バイト単位で同一のフレームはハッシュで検出します。速度と bootstrap は Δt を考慮し、smoothing 時にコピーを 1 つのノードにまとめます。
- **視野全体のジャンプ (+0.0026):** 遷移ごとのグローバルなシフトを、ピーク変位の投票によって推定します。5 µm 以上のシフトでは、ターゲットフレームを位置合わせし、運動特徴量を残差化します。

3.3 Divisions

- **D2 head (+0.0061; 2 パスのグラフでのみ機能):**
    - **候補:** linker の候補ペアから構築した triple (時刻 t の mother と、t+1 の 2 つの daughter)。各 mother にはリンク確率順に最大 5 個の daughter を割り当て、条件は mother–daughter ≤ 14 µm、sister 同士が 2.5–20 µm 離れていること、daughter の中点が mother から ≤ 8 µm であることです。
    - **分類器:** 38 個のスケール不変な特徴量 (リンク確率と競合、局所間隔で正規化した幾何、見た目、track の履歴) に対する HistGradientBoosting モデル。
    - **デコード:** ±2 フレーム / 8 µm の抑制付きの greedy。daughter は他の track から取ってくることもできます。
- **SVP (+0.0078):** 0.1·thr ≤ p < thr の triple を、両方の daughter が未使用で、t+1 と t+2 において強度の谷 (比 < 0.8) が両者を分けている場合に採用します。
- **SVD (+0.0030):** 採用された fork のうち、t+1 と t+2 の両方で谷がない (比 ≥ 0.95) ものは、弱い方の daughter edge を失います。
- **TCR (+0.0046):** ≤ 2 ノードの末尾が途切れるリンクを、親のない長い track の開始点に付け替えます (linker p ≥ 0.1)。≤ 6 ノードの短い先頭部分については鏡像的に扱います。
- **2 つの最終 head:** 2 つの最終 submission は D2 head のみが異なります。
    - 1 つはパイプラインの以前のバージョンのテーブルで学習したものです。
    - もう 1 つは現在のパイプラインの 199 動画すべてのテーブルで再フィットしたものです。胚をまたぐチェックでは不合格 (+0.0004) でしたが、public ではリードしていました。
    - ヘッジとして両方を残し、private では同点 (0.942) でした。

3.4 Smoothing と事後編集

Smoothing. 位置を CSV のグリッドに丸め、一対一のチェーンに沿って `[w, 1−2w, w]` で平滑化し、再度丸めます。このフィルタは fork をスキップし、重複コピーをまとめ、共動座標系 (位置から累積ジャンプシフトを引いたもの) で動作します。ノードを GT に近づけるわけではなく、隣接細胞間でのフレームごとのマッチングの入れ替わりを止めることで効果を発揮します。

学習ベースの編集: metric によるラベル付け. 3 つの学習ベースのグラフ編集 (LDM, LGAP, LCUT) では、各候補をその metric への局所的な影響 `u = ΔTP − 0.87·ΔFP` (ノードを追加する編集ではこれにカウント項を加えたもの) でラベル付けします。「重複かどうか」のような意味的なラベルは使いません。LDM では、厳密な重複ラベルはオフラインで AUC 0.78–0.82 に達しましたが、適用すると 0.004–0.074 悪化しました。metric ラベルにすると、同じ特徴量で利益が出るようになりました。これらの編集はラベルに依存しない特徴量に対する小さな GBM を使い、CV 用には胚をまたいで学習し、実運用用には全データで再フィットしています。

ステップ	内容	Confirmation での改善量
LDM	平行な tracklet ペア (< 14 µm、≥ 2 フレーム) を 22 個の特徴量でスコアリングします: 分離の統計量、共動性、ペア軸に沿った強度の谷、detector スコア、近傍での birth/death。p ≥ 0.40 のペアは、各フレームで中点の 1 ノードになります	**+0.0099**
LGAP	時刻 t の track 終端を、t+1 の track 開始点に直接、または t+3 の開始点に 2 つの合成ノードを介して橋渡しします。49 特徴量、4 つの GBM、p ≥ 0.40	+0.0008
LCUT	false-positive 確率が ≥ 0.6 の edge を切断し、≤ 0.1 の箇所に 1 フレームのリンクを追加します	+0.0009
EXT-k	閾値未満のピーク (スコア ≥ 0.06、予測位置から ≤ 3 µm、最大 25 フレーム、≥ 3 ピークまたは橋渡し) のチェーンに沿って track 終端を延長します	+0.0007
PSS	2 回目の drift-aware smoothing (w = 0.35)。2 番目の最近傍間隔の中央値が ≥ 9 µm の動画のみ	+0.0032 (edge 由来が +0.0021)
STUB+ EPULL	3 フレームより短いコンポーネントを削除し、各 track 端点を同じ track の隣接ノードの方向に 25% 引き寄せます	+0.0008
KSM	±3 フレームの kernel (z と xy で別の重み、track 端では片側) による追加の smoothing。design half の GT 位置に最小二乗でフィッティング	+0.0014

順序が重要です。LCUT を LGAP の前に置くと、改善量の大半が失われました。

4. 結果

CV は、199 本の学習動画全体での胚をまたぐスコアです。各行は上の行にステップを 1 つ追加したものです。

パイプライン	CV	Public	Private
出発点: 適応的スケール付き detector アンサンブル、学習ベースの linker、より単純な division モデル	0.8413	0.930	0.927
+ 2 パスの staging	0.8539	0.930	0.924
+ 2 回目の staging パス、丸め優先の smoothing、D2 divisions	0.8659	0.952	0.930
+ 重複フレームの処理、境界を考慮した staging	0.8712	0.951	0.931
+ TCR		0.954	0.933

パイプライン	CV	Public	Private
	0.8759		
+ SVD	0.8789	0.957	0.934
+ ジャンプの位置合わせ	0.8814	0.957	0.933
+ SVP	0.8893	0.956	0.940
+ drift-aware smoothing	0.8908	0.956	0.940
+ LDM	0.8999	0.958	0.939
+ LGAP, LCUT, EXT-k, PSS, STUB+EPULL	0.9063	0.961	0.941
+ KSM: **最終 submission 1**	0.9074	0.961	**0.942**
同上、再フィットした division head 版: **最終 submission 2**	0.9075	0.966	**0.942**

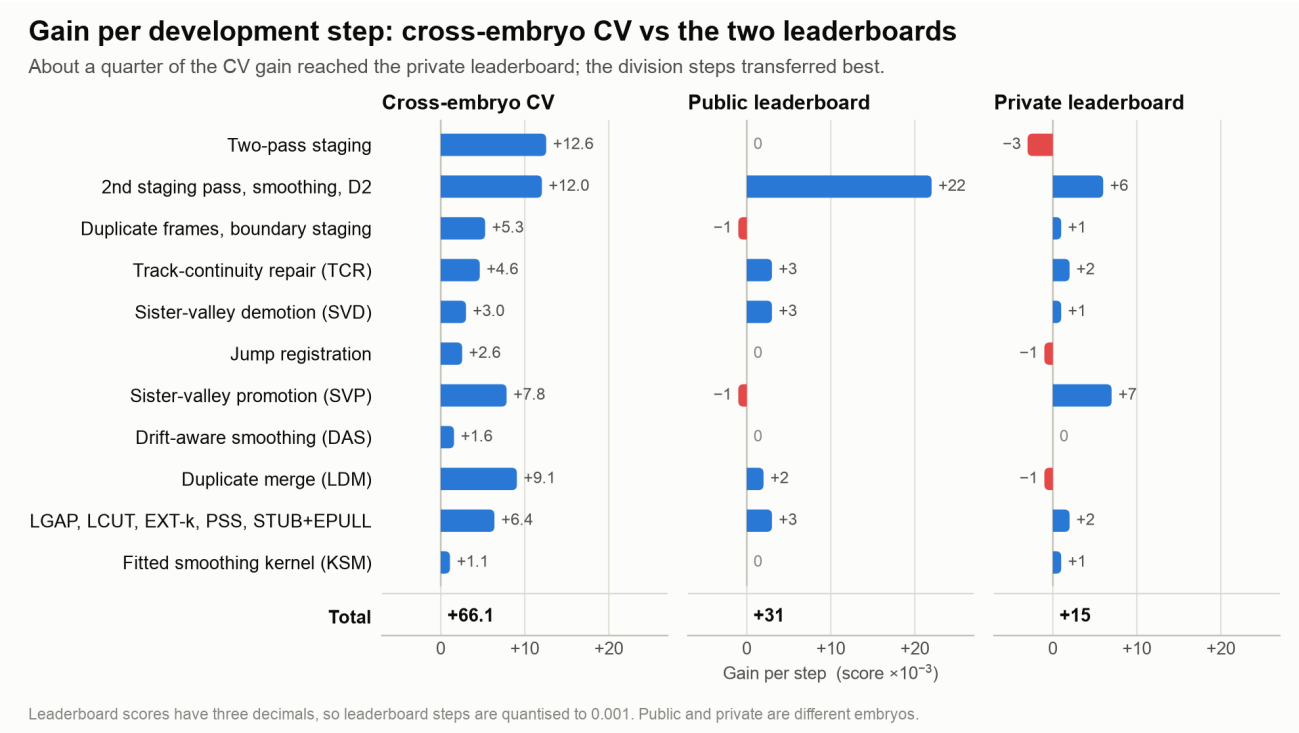


Figure 2. 各開発ステップの、CV と両 leaderboard での改善量。

- **転移:** CV での改善量のうち 23% が private に届きました (+0.066 のうち +0.015)。

- **最もよく転移したもの:**
  - SVP: private で +0.007;
  - 2 回目の staging パス、smoothing、D2 divisions を追加したステップ: +0.006。
- **転移しなかったもの:**
  - 2 パスの staging: private で −0.003;
  - LDM とジャンプの位置合わせ: それぞれ −0.001;
  - drift-aware smoothing と重複フレームのステップ: 横ばい。

5. 残された改善余地はどこにあるか

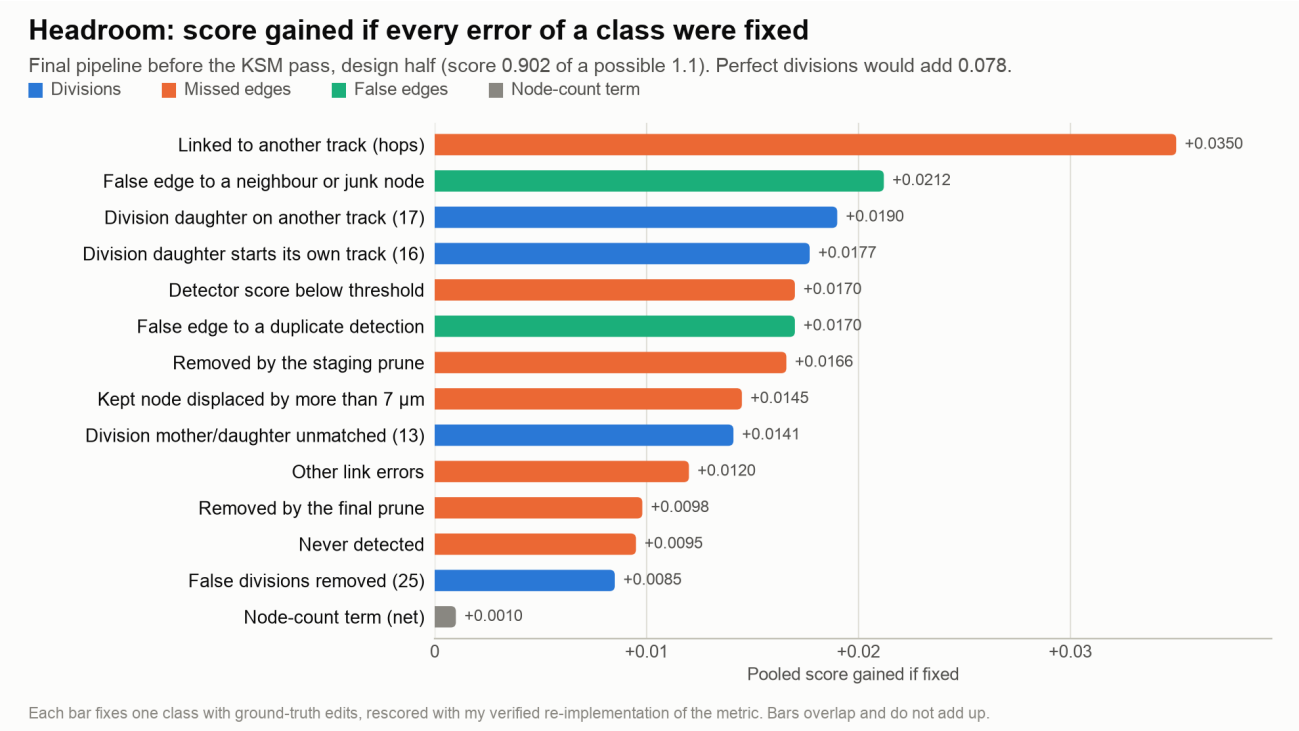


Figure 3. 最後の smoothing パスの前の最終パイプラインにおいて、各エラー種別を ground-truth による編集で修正した場合に得られるスコア (design half)。

- **Divisions:** すべての division エラーを修正すると 0.078 上がります。
  - 見逃した division は、回復するとそれぞれ約 +0.0011 の価値があります。17 個は daughter が別の track にリンクされており、16 個は 2 つ目の daughter が独自の track を開始していました。
  - 25 個の誤った fork をすべて除去しても +0.0085 にしかなりません。誤った fork は Jaccard の分母を大きくするだけだからです。
- **Edges:** 最大の種別は、両端が検出されているのに別の track にリンクされている edge です (+0.035、大半は 1 つの細胞の 2 つの検出間の hop)。detector に起因する種別はそれぞれ +0.009–0.017 の価値があります: スコアが閾値未満、staging で除去、そもそも未検出。これらについては分離可能なシグナルを見つけられませんでした (Section 6)。

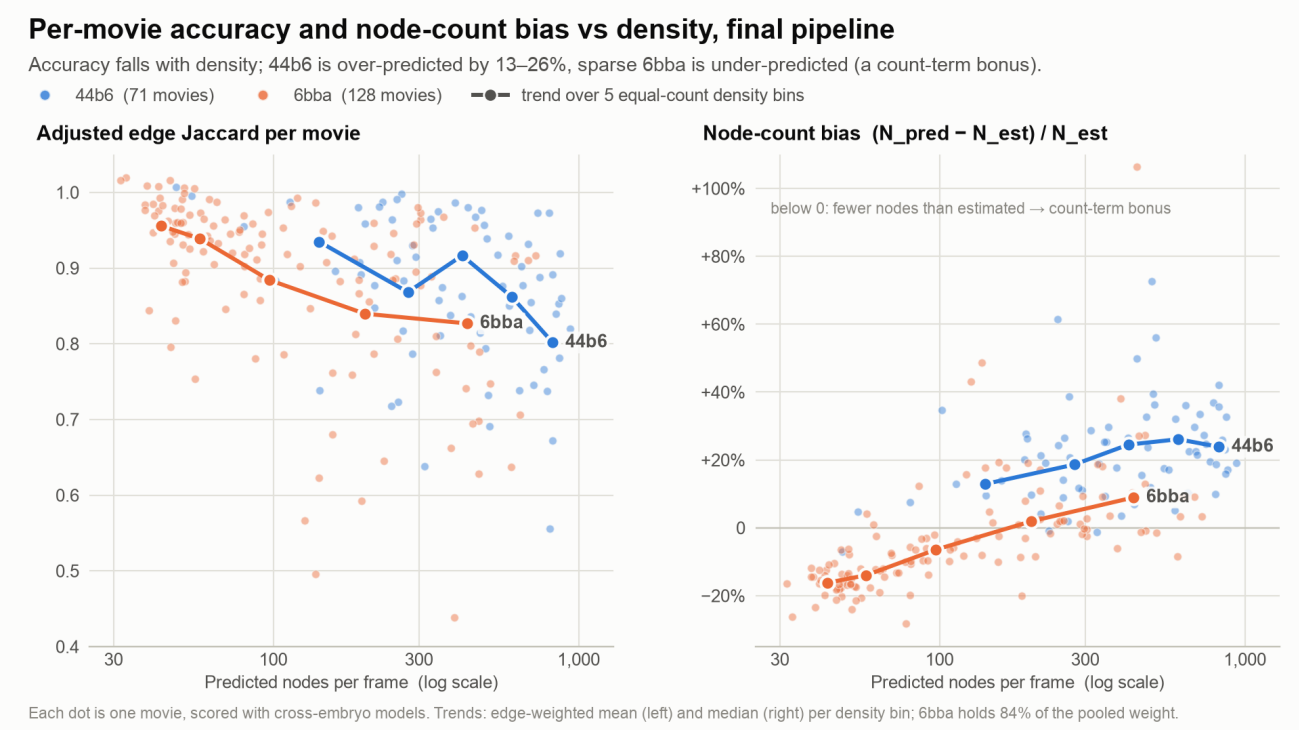


Figure 4. 動画ごとの精度とノード数のバイアスを密度に対してプロットしたもの。

- **精度:** edge で重み付けした調整済み Jaccard は、最も疎な 3 分の 1 の動画から最も密な 3 分の 1 にかけて低下します。6bba では 0.947 から 0.837、44b6 では 0.908 から 0.836 です。
- **ノード数:**
  - 44b6 は 13–26% 過剰予測されており (ビンの中央値)、カウント項のコストは約 2% です。
  - 6bba は最も疎な 5 分の 1 での −16% から、最も密な部分での +9% までの幅があります。符号付きのカウント項により、過小予測はボーナスになります。

6. うまくいかなかったこと

- **ノードの追加:** 範囲の狭い EXT-k のチェーン、LGAP の橋渡し、時間境界の staging ルール以外では、ノードを追加するものは検証を通過しませんでした。検出閾値の引き下げ、staging で除去したピークの復元、prune したコンポーネントの復元、track 端への単一ピークの挿入、2 フレームの gap closing を試しました。増えた recall は、カウント項か誤リンクによって相殺されました。
- **ノードの削除:** 推定ノード数に向けて削減すると常に悪化し、LDM と STUB 以外の学習ベースのジャンク track 除去では利益の出る候補群が見つかりませんでした。
- **linking 前の重複マージ** (強度の谷によるルール) は 6bba の CV では改善しましたが、両 leaderboard で悪化しました (同じベースで public 0.910 vs 0.930、private 0.849 vs 0.916)。これは適応的な detection スケールに置き換え、後に LDM が linking 後に重複を除去するようになりました。
- **Linker の再フィット** を現在のパイプラインのテーブルで行っても、ほぼ 0 でした (胚内で +0.0002、胚をまたいで −0.001)。
- **画像 CNN:**
  - fork の却下と昇格に使った mitosis CNN は、division の判断をより保守的にし、recall を失いました (Figure 1)。

    - 重複判定用のペア画像 CNN と、確率マップの鞍点特徴量は、GBM の特徴量に対して何も上乗せしませんでした。
- **Division ルールとアンサンブル:**
    - 追加の谷フィルタと、後期の 2 つの division 昇格ルールは、design half での改善量の大半を失うか逆転しました (Figure 1)。後期の昇格ルールは 6bba で +0.003–0.004 改善しましたが、44b6 で悪化しました。
    - D2 の augmentation、容量のチューニング、bagging はチェックを通過しませんでした。
    - 2 つの division head のアンサンブルは confirmation を通過しました (+0.004)。しかし design half ではマイナスで、全体でも +0.002 にとどまったため、採用しませんでした。
- **位置推定:** 強度重心へのスナップや z の精緻化は、胚をまたぐと効果がありませんでした。GT とのオフセットはアノテーションの慣習 (たとえば胚ごとの z バイアス) によるものだからです。同じ理由で、サブ voxel オフセット head も学習しませんでした。
- **Hops:** 2 つの検出が 1 つのアノテーション済み細胞にまたがり、GT がそれらの中点にあるケースです。こうしたまたがりペアを、接触している 2 つの細胞と区別できる特徴量はありませんでした (AUC 0.45–0.61)。また、GT がどちらの検出にマッチするかの予測器もチャンスレベルでした。

7. 教訓

1. 動画ではなく胚を hold out すること。division head の再フィットは、胚内 CV では +0.0074 良く見えました (一部は学習動画が増えたことによるもの) が、胚をまたぐと +0.0004 で、private では同点でした。
2. 事後編集を学習する際は、各候補を競技の metric への影響でラベル付けすること。編集がノードを追加する場合はカウント項も含めます。metric でラベル付けした編集は、すべて confirmation で維持されました (Figure 1)。
3. 半分で設計し、ルールを凍結し、もう半分で一度だけ確認すること。design half で勝った 19 個のうち 7 個は confirmation の結果却下され、手動チューニングのルールは design での改善量の中央値で約 40% しか維持しませんでした。