rsna-knee-abnormality-detection

1st place solution — Better labels, anatomy-aware MRI models（日本語訳）

Rank	1
Team	Team Kangaroo
Author	sakaku
Topic ID	752474
Version	Japanese Translation

Source: https://www.kaggle.com/competitions/rsna-knee-abnormality-detection/discussion/752474
Retrieved with Kaggle CLI on 2026-10-27.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

開催したRSNA、放射線科医、Kaggle、そして多くを学ばせてくれたチームメイト@tascj0に感謝します。（@tascj0）

私の3つの主な貢献、高品質Astraラベル、解剖BBox注釈、最終アンサンブル用モデルを説明します。相方の担当は@tascj0の投稿を参照してください。（@tascj0's write-up）

学習4,407 MRI検査にレポートがあり、人の正解は58件、残る4,349件には利用可能な根拠から教師が必要でした。レポートには12要素のラベル以上の情報があります。不確実な所見、別の解剖区画の所見、基準に届かない所見を、画像モデルが学べる教師へ変えることが課題でした。

高品質Astraラベル：GPT-6 Astraが各検査を調べ、追加画像を要求し、12連続確率を出します。ラベルと確率付与手順はチーム共通資産になりました。同じCoAtNet（224 px）の比較で、以前の複数情報源ラベルをAstraに置き換えるとPublic AUCは0.922→0.935でした。

解剖BBox：断面識別付き領域を供給する注釈・検出器を開発しました。全体文脈を残し、関連解剖へ分類器を導きます。相方の別の病変注釈も私のモデルに採用しました。検査ラベルと空間注釈で「何を予測するか」と「どこを見るか」を教えます。

最終への貢献：異なる教師のMaxViT v2 Base 2つとCoAtNet-rMLP-2の3モデルを学習しました。等重み混合が最終予測の50%、相方が残り半分です。全体はPublic 0.969 / Private 0.960で1位。本稿は注釈、学習、統合の流れを説明します。

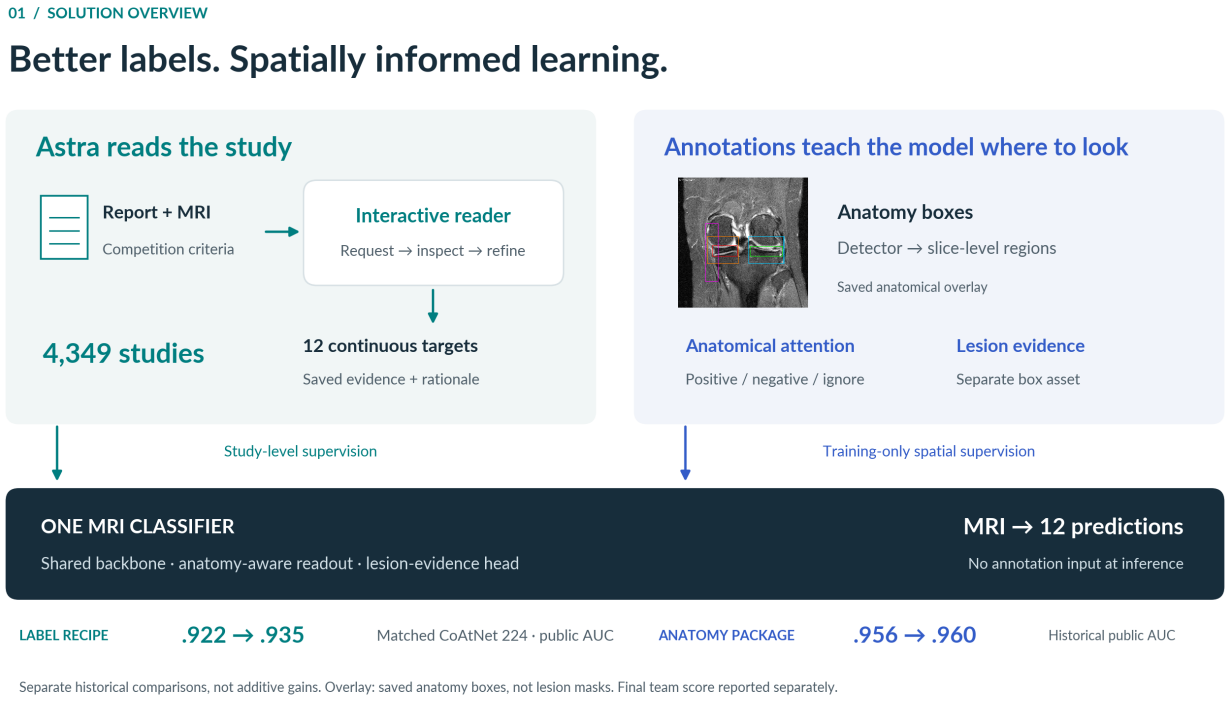


図1：同じMRI分類器へ、検査の連続教師と学習専用の空間教師を供給します。解剖と病変のボックスは別資産です。2つのスコア差は別々の過去比較で、加算可能な改善や最終チーム性能ではありません。

最終チーム推論Notebook（Final team inference notebook）

1. GPT Astraによる高品質ラベル

Hulu・Qwenの単発ラベル付けから、GPT Astraのエージェント型へ進みました。初期作業で所見の判断規則とプロンプトを磨き、Astraは追加画像を求め複数段階で判断を確認できるようにしました。画像分類器はラベルから学び、推論に文章も注釈エージェントも不要です。

まず所見の判断方法を学ぶ

Astra以前はClinFusion、Hulu、Qwenへレポートと固定21断面（矢状7、冠状7、横断7）を渡しました。HuluとQwenは与えた資料に基づく1回の要求で各スコアを出し、推論はできてもビューアーで追加証拠を取得できませんでした。

読影器	ラベル生成法	残したもの
ClinFusion-32B	所見別YES/NOトークンスコア	初期ベースラインと構造化診断説明
Hulu-Med-Flash-Preview-27B	制約付きyes/noトークン採点	滑膜炎専用設定を含む確率源
Qwen3.8-Flash-Next-FP8	所見別推論後に連続値を出力	補完的な確率源

Huluの滑膜炎専用は同じ断面を元解像度に近い詳細で示し、レポートの一部の滑膜表現を除いて思い込みを抑えました。Qwenは自前サーバーで検査あたり12要求。ClinFusionの説明で根拠が文章か画像かを確認しましたが、確率は最終混合に不使用です。Huluはthinkingなしのyes/no確率、Qwenは推論後の連続値を使います。Huluの確率採点と診断文章抽出は別の呼び出しです。

この開発から、コンペ定義に従う、文章と画像根拠を分ける、記載なしを陰性にしない、不確実さを残すという課題の定め方を学びました。Astraのプロンプトはゼロからでなく、この経験を引き継ぎました。

次は、さらに何を見るべきかを読影器自身に決めさせました。Astraは断面要求、別シリーズの同領域確認、判断の見直し後に確率を返します。これがエージェント型の注釈です。HuluとQwenも最終混合の補完教師として残しました。

確率を求める前に対象を定義する

Astraは各コンペ陽性基準を満たす確率を推定します。文章の異常抽出だけでは足りません。軽微なACL信号変化は高度断裂ではなく、少量の関節液は中等量・大量のEffusion基準ではありません。内側・外側・膝蓋大腿の所見も正しい区画に対応させます。

文章は文脈として有用ですが、沈黙は明示的陰性ではなく、曖昧な表現は確実な陽性ではありません。画像と照合し、証拠がなければ不確実さを残すよう求めました。この対象別解釈は各確率源で共通です。

次にAstra自身が根拠を集める

固定一覧画像だけでは解決できない所見もあります。Astraなら隣接断面、拡大像、補完シリーズを追加確認できます。

本番はGPT-6 Astraで検査ごと1会話。人手なしでAstraと閲覧ツールが対話します。レポート、12定義、シリーズ概要を渡し、詳細画像を先に固定せず、回数制限付きの閲覧操作を提供しました。

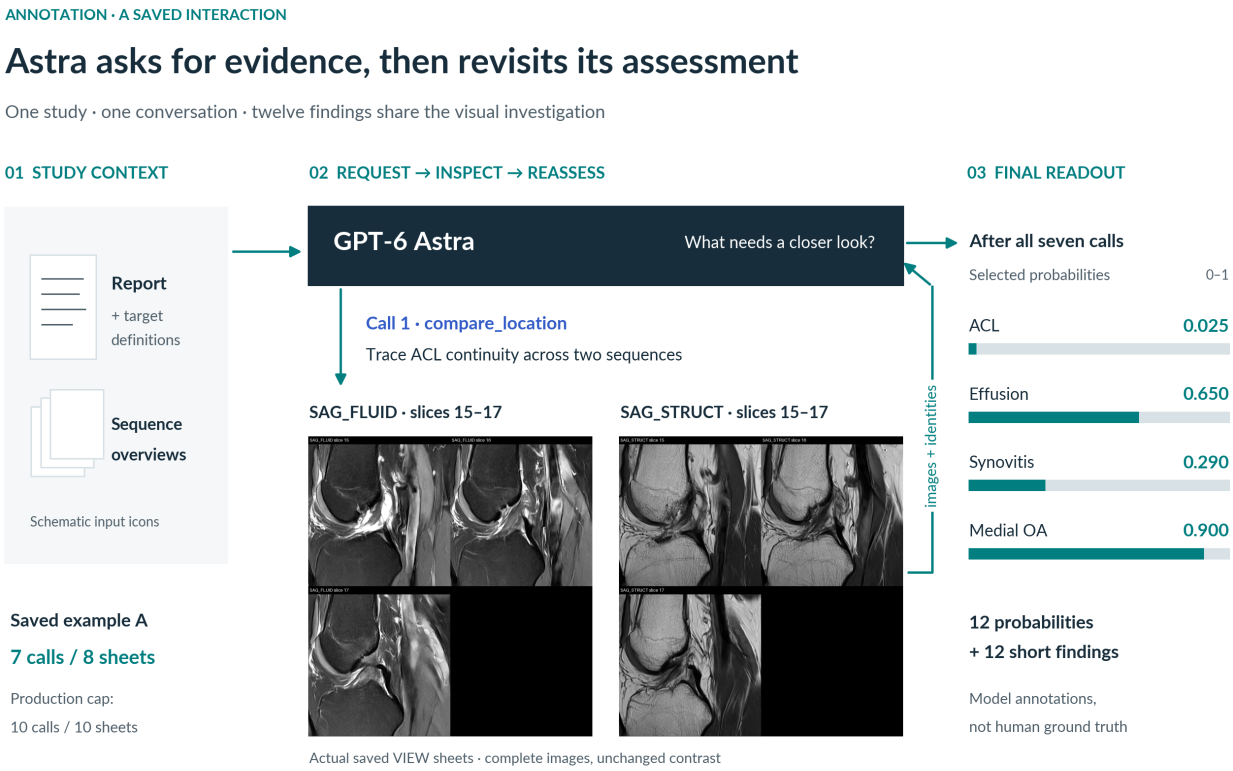


図2：実セッションの要求、MRI応答、連続出力。2シートは最初の閲覧呼び出し、確率は全7呼び出し・8シート後の最終値です。専門医正解ではなくモデル注釈です。本番上限は1検査10呼び出し・10シートでした。

主要操作は2つです。

操作	できること
view_slices	断面選択、領域切り出し、表示濃度調整。元画像も併記
compare_location	別シリーズの候補位置周辺の隣接断面を要求

画像とシリーズ・断面IDを返します。シリーズ間位置はDICOM幾何からの候補なので、解剖を再確認する必要があります。Astra v1は検査全体で10ツール呼び出し、詳細10シートまで。最後に12確率と12の短い所見を返します。

保存した注釈セッション

図2の最初の要求は、ACL連続性のためスライス16付近の矢状液体強調と構造像を比較し、両方の15–17を取得しました。後に冠状・横断、半月板、軟骨、液体関連を確認。合計7呼び出し、8詳細シートでした。

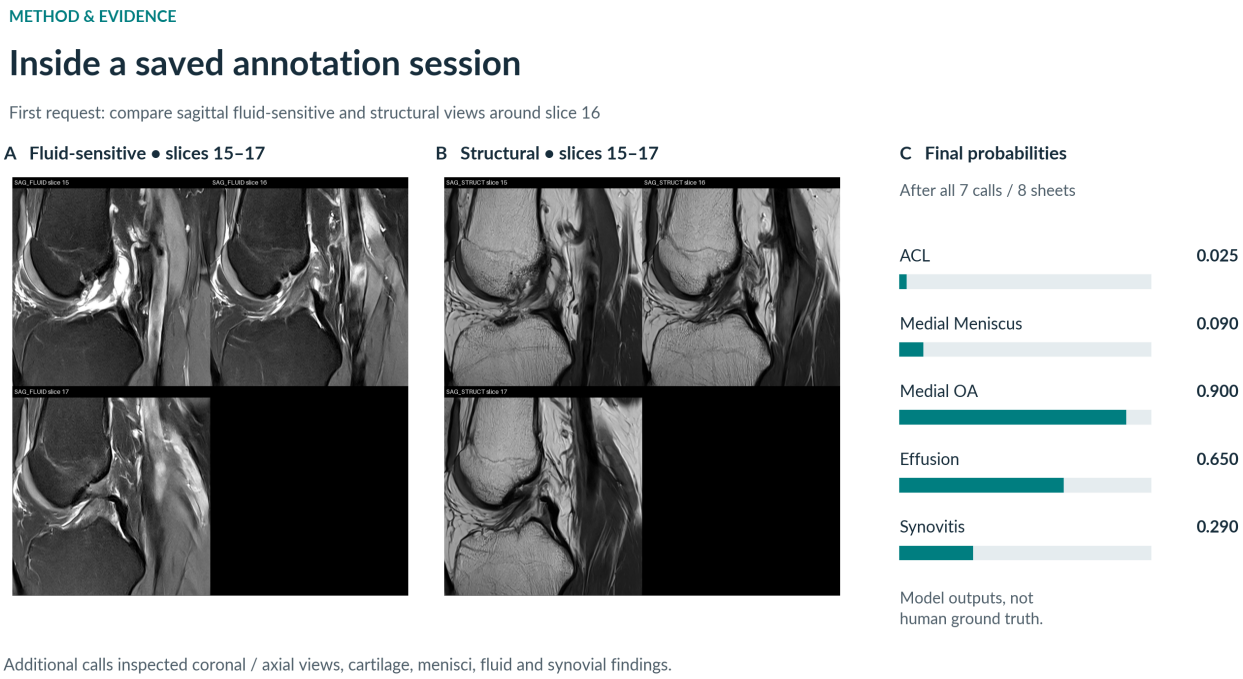


図3：最初の呼び出しが返した補完的な2枚のMRIシート。確率は7呼び出し完了後の最終出力の抜粋で、専門医正解ではありません。

確率を残す理由が最終出力に表れます。ACL 0.025、Effusion 0.65、Synovitis 0.29でした。文章は液体量の閾値と滑膜肥厚の確証に不確実さを示しており、学生は強制的な3つの二択でなく、その違いを受け取ります。

注釈器は見る証拠と表す確信の両方を制御します。これは対話例であり、下の学生比較がラベル生成系全体の価値を測ります。

連続確率

レポートを学習時だけの豊かな情報として使い、各注釈源の前処理を固定しました。Astraでは特定の滑膜表現を一貫して削除し、文章への思い込みを減らしました。短い診断文は点検用で、画像モデルは確率を学びます。

同じ取得証拠で出力形式を比べると、6区分は開発AUC 0.8832、連続値は0.9363でした。連続方式全体の再実行は0.9392。そのため連続値を維持し、順位と確率品質の両方を確認しました。

注釈セッションから学習データへ

検査ごと1会話で12所見の文脈を共有します。出力は確率と簡潔な所見に絞り、キャッシュ入力、非キャッシュ入力、出力トークンを別計測。解剖・病変座標は別タスクで作りました。採用例を出典ID付きで保存し、中断後は未完了だけを再開しました。

公開元データは4,349検査 × 12 = 52,188の確率・文章ペアです。検査・所見キーの一意性、有限確率、全件網羅、画像IDを確認しました。生応答と見た画像を各記録に結び付け、不一致を実際の証拠まで追跡できます。

私の元のAstra本番では、各会話を当該症例の文章・画像・閲覧ツールに限定し、履歴・shell・webを無効化しました。独立監査ではGold58の答えや事前情報の直接注入は見つかりませんでした。ただし後の相方提供データは監査対象外です。以前のプロンプト・文章処理は開発評価を使っており、注釈スコアは開発結果です。

注釈源の比較

同じ58件の人手評価付き開発検査での結果：

注釈源	Macro AUC
ClinFusion	0.8737
滑膜炎専用を含むHulu	0.9093
Qwen Next	0.8955
Astra v1	0.9364
Astra v2	0.9383

Astra v2は初期画像表示と推論予算を変えました。小さな向上の統計的確証はありません。文章補助の各注釈源の値であり、学習への有用性は下流モデル比較と予測の補完性で判断しました。

下流モデルの証拠

同条件CoAtNet（224 px）の比較です。対照も既にHulu（滑膜炎専用を含む）と骨挫傷用GPT-5.6 Solの複数情報源ラベルを使っていました。Astraへの置換で下の主な改善が得られました。



図4：最終モデル以前の同条件学生実験。主改善は教師強化です。初期混合の追加0.001は確証のある優位ではなく、優勝全体の累積アブレーションでもありません。

最終ラベル構成

最終は2種類。主なMix5は全所見共通重みで生確率を平均します。

情報源	重み	版の違い
Astra v1	30%	Medium推論、概要・一覧画像
Astra v2	20%	Low推論、初期に個別画像を提示
相方のAstra	30%	別途作成した注釈
Hulu	10%	追加の画像・文章情報源
Qwen Next	10%	追加の画像・文章情報源

第2は@tascj0が共有した確率校正済みfocus-guided Astraです。これだけのMaxViT v2 Baseは特に良く、開発用学習版がPrivate 0.955で、後述5単体中の最高でした。全データ版を最終に残し、backboneだけでなく教師の多様性を増やしました。生成方法は相方の投稿を参照。最終3モデルにClinFusion確率や診断文章は使いません。（@tascj0 / his write-up）

混合式は全検査・所見で同じです。以前の融合監査で、柔軟な所見別重みの見かけの優位がleave-one-outで消えたため、調整自由度の少ない全体混合を選びました。最終重みが唯一最適と証明したわけではありません。

2. 位置の教師：BBoxから学習信号へ

検査ラベルは存在を教えても、画像の場所を教えません。6つの位置依存所見の解剖領域と、12所見の病変証拠という別々の空間データを作りました。正常半月板にも解剖領域があり、病変ボックスとは意味が違います。

初期の半画像モデルでは、半月板headへ対応側半分を見せると外側半月板の開発AUCが0.8236→0.8820、Public 0.936→0.938でした。ただしbackbone画像評価数は約2.2倍で、小標本ゆえ差は不確実です。それでも位置情報を追う動機になり、最終では共有特徴マップ上の読み出しを注釈で導き、追加backboneなしで全体文脈を保ちました。

位置推定は診断文章とは別に検証しました。初期座標読影器は画像を差し替えてもレポート由来の似た出力を返すことがありました。もっともらしい診断説明だけで座標を受け入れず、画像内容との対応を確認しました。

解剖BBox注釈

GPT-6.1 Sol、low effortで448 pxの1断面ずつを読みました。方向・左右別のプロンプトで含める構造を説明し、病変の有無ではなく、所見を評価する可視の解剖領域を求めました。見えない構造は省きます。

JSONリストにクラス名とbbox_2d=[x1,y1,x2,y2]、[0,1000]整数座標を返します。左上原点、x右向き、y下向き。元画像と変換を保存し、正規化座標を実際の表示画像経由で標準物理座標へ写しました。直接画素座標とは扱いません。

プロンプトは8候補クラスでしたが、検出器はMCL、内外半月板、内外OA、PF OAの6つです。ACLとベーカー領域は含みません。使用版は3,823検査の39,415画像。手描きマスクでなく機械生成の粗い領域です。

検出器で全断面へ拡張

深度をずらし可変ウィンドウを使う学生には、少数の固定位置の注釈だけでは不足します。実際に選ばれる断面IDに空間教師が必要でした。

事前学習済み検出器を出発点に、DINOv3 ConvNeXt-B + adapter + 6層DETRを学習しました。検査が重ならない2foldで4,349検査のOOFボックスを作り、各検出器は未学習検査を予測します。分類器の開発分割とは別です。

検出器は512 px・140 mm、batch16、ピークLR 10^{-4}、cosine減衰。全注釈拡張は最大16 epochs、保留mAP50でEMAを選択。弱い拡大縮小・移動・濃度拡張を使い、解剖規約を保つため反転・Mosaic・MixUpは無効にしました。

選択foldの注釈参照mAP50は0.952と0.944。中心一致、画像置換、左右、背景予測、クラス・シリーズ役割別の網羅も確認しました。AI注釈との一致を専門医の解剖正解とは扱いません。



図5：疎なGPT注釈を断面ID付き教師へ拡張。採用した対象・役割の組だけを監督し、空欄は陰性でなく無視です。

陽性、確かな陰性、無視

出力は673,215断面。断面・対象の各要素は3状態です。

状態	損失での意味
陽性領域	採用した解剖ボックスが空間的根拠を与える
確かな陰性	このビューには構造がないと判断し、根拠のないattentionを抑える
無視	空間損失を加えない

17の対象・役割の組を採用。内側半月板は冠状液体強調・構造像、外側はさらに矢状液体強調です。横断の半月板・脛骨大腿OAは除外。空の検出結果は別途確認した不在ルールを満たす場合だけ確かな陰性とし、それ以外は不明にしました。

全ての空出力を陰性にすれば検出器の見逃しを教え、すべて無視すれば構造がないビューへのattentionを抑えられません。後からボックスの有無で推測せず、状態を明示保存しました。

512・384・256 px版は同じ物理範囲です。CPU/GPU拡張で学生画像と一緒にボックスを変換し、元シリーズ・断面IDで参照します。

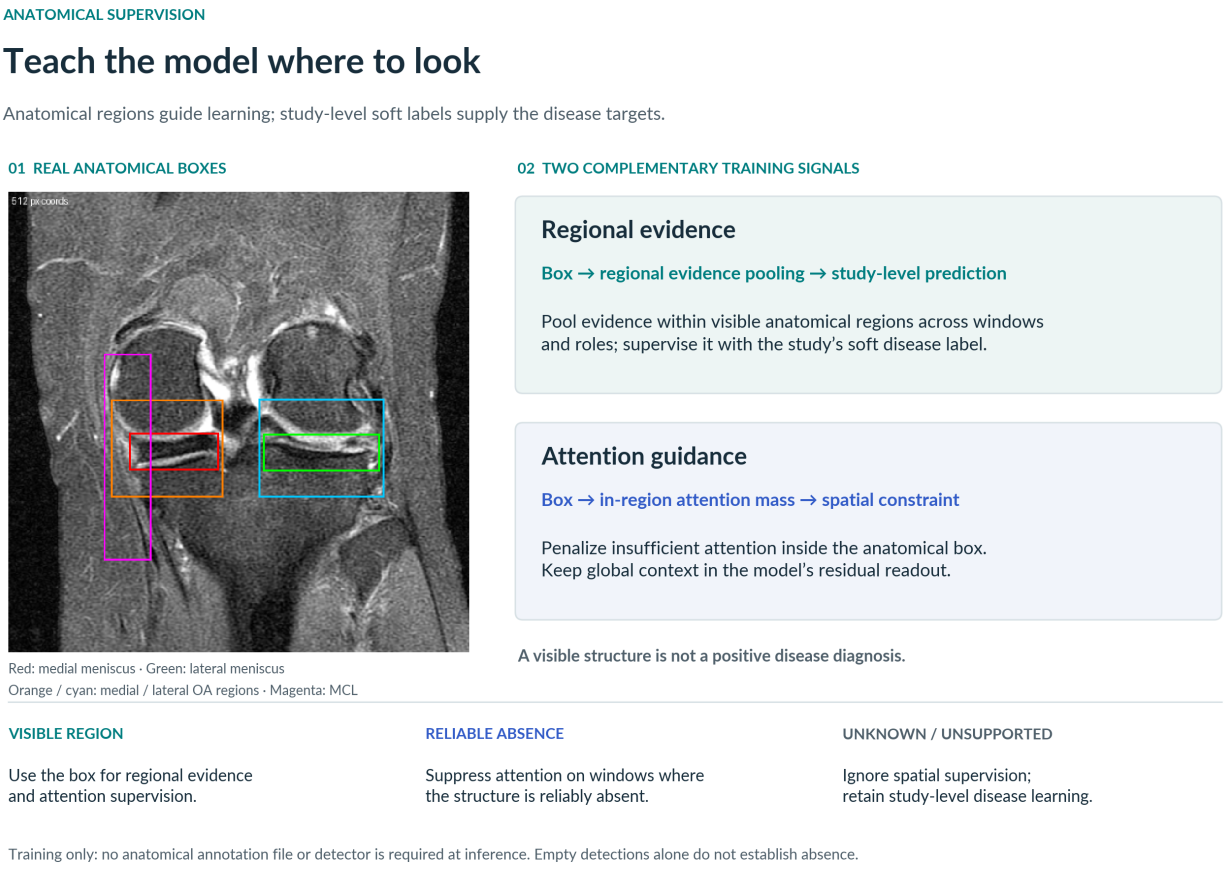


図6：左は保存した実際の冠状重畳像、右は領域poolingとattention指導。構造が見えることは病変陽性ではありません。確かな不在はattentionを制約し、不明は監督しません。病変分割でなく解剖領域です。

病変BBox：12所見の直接根拠

相方はGPT-6.1 Sol highによる1,800検査、3,616病変、111,029断面ボックスを提供しました。選択した液体強調シリーズの個別断面で指定所見を注釈し、シリーズUID、SOP instance UID、所見ID、元画像の正規化座標、可視性を記録しました。

未注釈と不在の区別が特に重要です。要求した所見だけを扱うため、対象外検査、未要求所見、not_visibleは負例ではありません。

病変損失の条件は、対象となるレポート付き学習検査、要求所見、幾何の一致、固定Astra由来の症例陽性適格スコア0.5以上です。focus-guidedを含め主教師を変えても、この適格性源は固定しました。3断面ウィンドウの中央だけがボックスを供給し、3枚すべて有効・別ID・非dropoutを要求します。複数ボックスの和集合をMIL領域にします。適格症例内の明示的陰性所見は不在教師にでき、欠損ボックスは無視しました。

病変索引は正確な学習補集合ごとに作り直し、Gold58を除外しました。病変・解剖データは学習資産で、私の分類器はテスト時に注釈ファイルも検出器実行も必要ありません。

3. 解剖を考慮したMRI分類

共有2D backboneと対象別の空間・深度集約を組み合わせます。検査確率が病変予測を、解剖・病変資産が学習時に証拠を集める場所を教えます。

画像詳細と物理幾何を保つ

元DICOMを残し、復号シリーズを幾何メタデータ付きuint16 volumeに保存しました。DICOM rescale、可能なら患者座標順序、濃度極性統一を適用。非ゼロ有限濃度を0.5/99.5パーセンタイルで切って量子化します。正規化済みで可逆ではありませんが、早期のJPEG化・固定resize・ROI切り出しを避けました。

物理視野とモデル変換は後段です。学習・提出の前処理を共有し、キャッシュとオンラインの比較で入力差を検出しました。

5つのシリーズ役割で検査を表す

矢状・冠状・横断の液体強調脂肪抑制と、矢状・冠状の構造像に分けます。DICOM幾何で順序と方向を決め、共通140 mm視野を384×384に縦横比を保って切り出し・余白処理します。

各役割の中央12–88%から32断面を選び、重なる3断面ウィンドウ30個を作ります。共有2D backboneへの3チャネル入力です。学習は役割あたり8ウィンドウ、推論は30全部。隣接する抽出位置であり、元断面が連続とは限りません。

局所の深度文脈を残しつつ強い事前学習2Dモデルを再利用できます。各特徴を256次元へ射影し、役割とウィンドウ位置の学習埋め込みを追加。幾何は平均正規化深度、深度幅、有効断面率、有効断面中の非重複率の4値です。5役割の集約特徴から対象ごとの1,280次元表現を作り、欠損役割はマスクします。

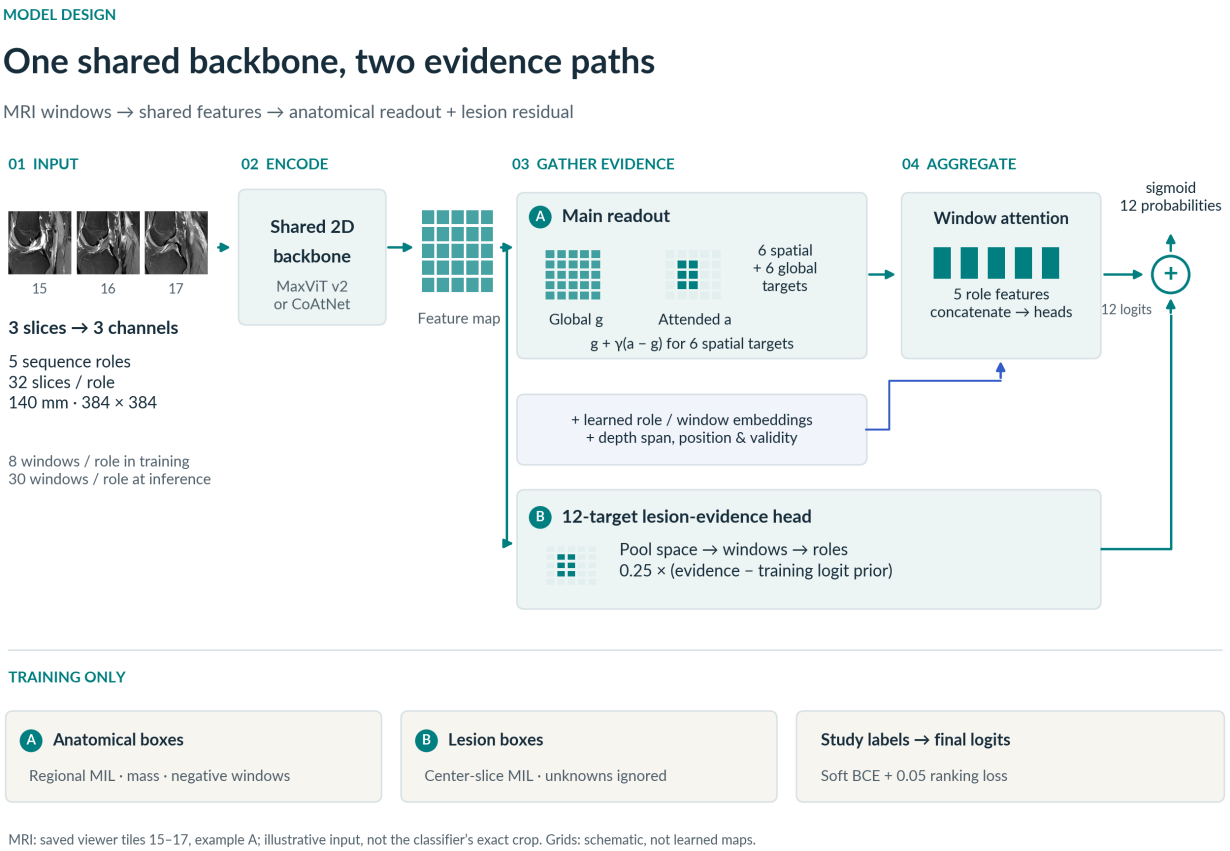


図7：全ウィンドウがbackboneを共有。6所見は全体と解剖誘導の読み出し、残る6所見は全体pooling。役割・位置・幾何も検査表現に入ります。並列の病変headが有病率中心化残差を最終logitへ足します。空間教師は学習のみ。特徴図は概念で、実測活性ではありません。

全体文脈を保って解剖根拠を加える

MCL、内外半月板、内外・膝蓋大腿OAの6所見に対象別空間attentionを使います。注目特徴から全体平均への残差補正：

$$h_{target} = g + \gamma \times (a_{target} - g)$$

gは全体pooling、a_targetは空間attention特徴、学習可能γは0.1から開始。他6所見は全体空間poolingです。次に役割内のウィンドウを対象別attentionで集約し、5役割特徴を連結して分類します。

全体poolingに近い状態から、局所根拠へどれだけ移るかを学びます。解剖ボックスは領域MIL、attention量の制約、明示的陰性ウィンドウの教師として使い、画像と注釈の変換を同期します。

初期MaxViT v2 Base（384 px）の比較では、解剖を考慮した一式でPublic 0.956→0.960でした。手元差は不確実なので、1つの補助損失の効果でなく一式への肯定的証拠と考えます。

同じ特徴マップに12所見の病変証拠headも加えました。正規化log-sum-expで空間・有効ウィンドウを集約し、利用可能役割で平均します。最終logits：

$$z = z_{main} + 0.25 \times (e_{lesion} - \mathrm{logit}(p_{train}))$$

p_trainはレポート付き学習検査の有病率です。残差を中心化し、事前確率を二重加算しないようにします。補助MIL損失の重みは空間損失スケジュール下で0.1。不明は無視し、未注釈を負例にはしません。

追加backboneなしで局所証拠から検査予測への直接経路を作ります。2節の学習専用適格性・幾何規則を使い、有病率もレポート付き学習検査だけで計算します。

4. 学習と検証

公開事前学習重み、ソフトBCE、重み0.05の順位損失、空間補助損失を使います。空間・濃度・深度ずれ、断面・ブロック・役割dropoutで拡張。再現用の主要設定を以下にまとめます。

事前学習backboneを適応させる

重要な変更はbackboneピークLRの増加です。同条件の初期CoAtNet（224 px）で8×10^{-6}→8.944×10^{-5}にするとPublic 0.936→0.944。一方Gold58開発AUCは0.9283→0.9215と逆でした。この不一致も、より広い開発参照を探す理由でした。

最終も高いピークLR、層別減衰0.9、新層は別のピーク10^{-3}を維持しました。過去比較は停止規則により学習も長くなったため、LR介入とその学習経路の有効性を示すもので、内部機構1つを分離した結果ではありません。

信頼できるCVを作る

初期Gold58は不安定で開発を導けませんでした。私が問題提起した後、@tascj0主導で残りの期間に使うCVを共同開発しました。後期はLBをよりよく追い、教師・モデル比較の決め手となりました。役立つ検証信号が得られたことは、追う変更を判断する大きな転機でした。

後期はレポート付き検査を10foldにし、過去LBとの相関で1foldを選び、以後固定しました。保留435、学習はレポート付き3,914 + 人手58です。Astra v1・v2・相方Astraの等平均という固定参照で教師設定を比べ、学習教師を変えても評価の物差しを変えません。

参照確率を二値化しない確率重み付きAUC（SoftAUC）を使います。対象ごとに異なる検査(i,j)へq_i × (1−q_j)の重みを付け、正順は全点、同点は半点。総ペア重みで正規化して12所見平均します。検証でも不確実さを保ちますが、コンペの二値AUCとは数値尺度が異なります。

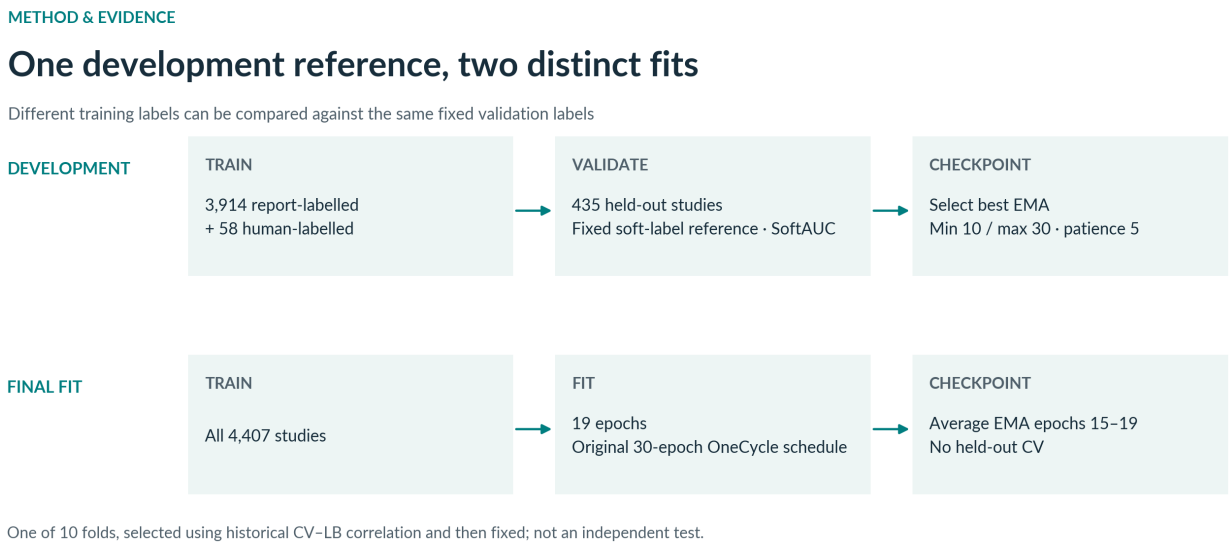


図8：開発選択と最終学習は分割・checkpoint規則が異なります。全データ最終モデルに保留CVはありません。

最低10 epochs、patience5、最大30でSoftAUC最高のEMAを選びました。10fold平均でなく固定1foldです。過去LBで選んだため独立テストではありません。

全データ学習

最終3モデルは全4,407検査で、58件は元の人手正解を保持しました。30-epoch OneCycleの19 epochsで止め、EMA epoch15–19を一様平均。BatchNorm再校正はしません。

Gold58は注釈開発にも使用。解剖教師の適格性はその画像上のGPT・検出器一致を使いますが、疾患正解は使いません。小さな手元差は開発上の証拠であり、関連注釈を参照する検証は同源教師のモデルを優遇し得ます。

学習設定

パラメータ	値
解像度 / batch	384 / 8
最適化 / weight decay	AdamW / 0.02
ピークLR：backbone / 新層	8.944×10^{-5} / 10^{-3}
層別LR減衰	0.9
スケジュール / EMA減衰	OneCycle、30 epochs予定 / 0.995
空間補助係数	各項0.1、最初1epochのwarmupと後期減衰
学習精度 / メモリ	BF16 / activation checkpointing
最終学習 / 重み平均	19 epochs / EMA epoch15–19
提出推論精度	FP16

解剖MIL、attention量、陰性ウィンドウ、病変MILに共通の倍率を使います。最初のepochで0→1へ線形増加、epoch10まで1、その後1 − 0.7 × (e − 10) / 19（eは0始まり）です。各項係数は0.1 × 倍率。最終は30予定の途中19で停止します。病変logit残差0.25は別係数です。checkpoint化したbackboneは逆伝播再計算時にBatchNorm統計を保持しました。

5. 結果と最終への貢献

開発の経緯

大きく3段階です。まず学生の教師を改善し、初期複数情報源CoAtNetのPublic 0.922からAstraで0.935、初期Astra/Hulu/Qwen混合で0.936。次に学び方と見方を改善し、高LRで0.944、後の384 px設定で0.956、解剖pooling・教師一式で0.960。最後に補完的根拠を合わせ、後の教師・入力・病変教師で単体0.962となり、全データ群へ進みました。

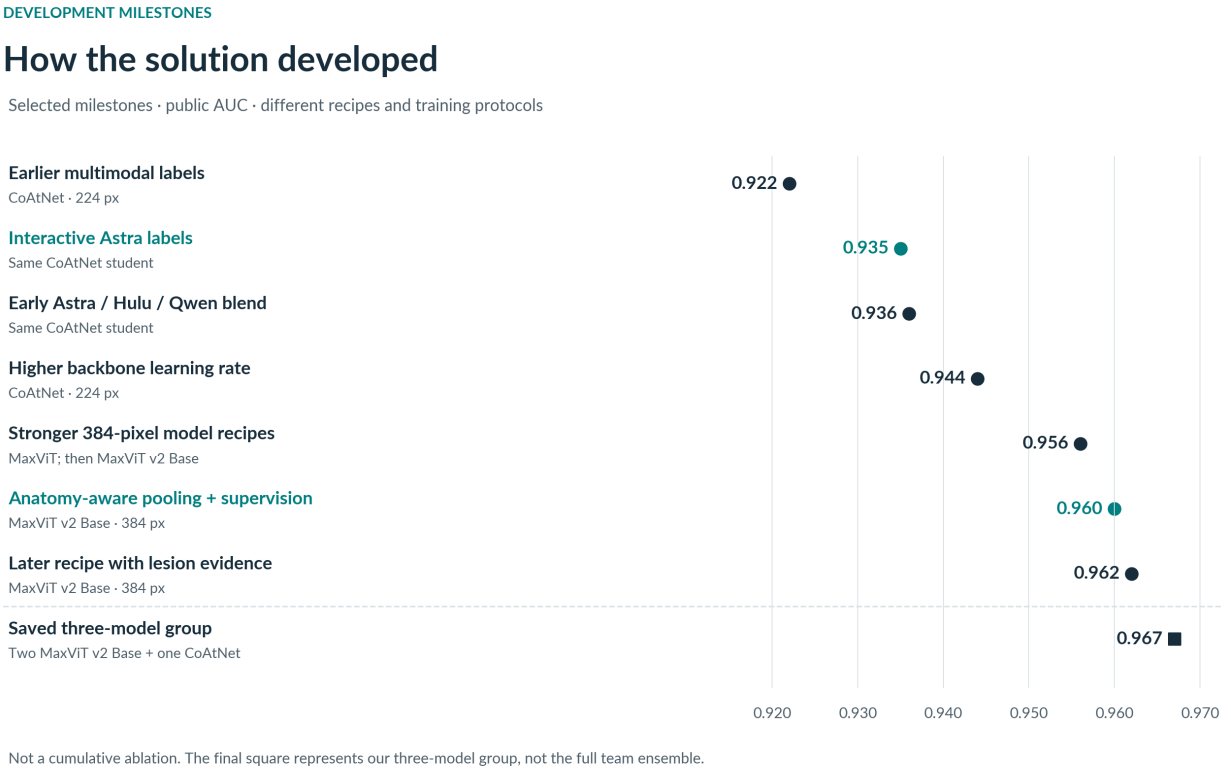


図9：Publicの主要段階。教師比較は同じ学生、LRは学習期間も変化。後の行はモデル・入力・教師・検証も変わるため、隣接差を単独効果とはいえません。最後の四角は保存3モデル群のPublic 0.967 / Private 0.957で、チーム全体ではありません。

すべての追加が効いたわけではありません。初期混合はAstraより0.001だけ高く未確証、LRはPublicを上げ小標本開発値を下げました。位置研究も高価な半画像から共有特徴へ進みました。こうした観察は、単なるハイパーパラメーター一覧以上に最終解法を説明します。

最終3モデル

私の最終担当は次の3モデルです。

Backbone	ラベル	私の群内重み
MaxViT v2 Base (384 px)	Mix5	1/3
MaxViT v2 Base (384 px)	Focus-guided Astra	1/3
CoAtNet-rMLP-2 (384 px)	Mix5	1/3

CVとLB

開発予測と対応LBが両方ある5単体を比較します。



図10：各行はCV/LBで同じ版。MaxViT BaseとCoAtNetは384 px、Nanoは256。強調したfocus-guidedは最上段よりCVが低くPrivateが高い値です。CVは連続参照SoftAUC、LBはコンペAUC。10月23日は保存モデルの終了後確認で、CoAtの同日値は過去提出の再現です。

MaxViT Baseは両評価で強い一方、僅差のCV順位は非公開順序を決めませんでした。focus-guidedは3源・Mix5よりCVが低いのに、5モデル中Private最高0.955でした。これは小さな事後比較で、開発中に見た広いCV–LB相関の測定ではありません。新CVは僅差をすべて解決できなくても、開発には非常に有用でした。

補完予測も直接評価しました。同じ435件でMix5のMaxViT Base + CoAtNet-rMLP-2等平均は0.880561、focus-guided追加で0.881571。対応bootstrap差区間は[+0.000133,+0.002008]ですが、複数組み合わせの選択補正はしていません。事前設定した実質差0.002未満の小さな局所寄与で、下の全データモデルとは別です。

全データ3モデルの確認

同じbackboneの異なる教師と、同じ教師の異なるbackboneを組み合わせました。終了後、保存した全データ各モデルと等平均を別々に評価しました。



図11：すべて10月23日の事後測定。Public 0.967 / Private 0.957は私の3モデル群で、優勝チーム全体ではありません。全データモデルに保留CVはありません。

3モデル群はPublic・Privateとも各単体を上回りました。CV版と全データ版は学習範囲・期間・重み平均も違うので、差を追加データだけには帰せません。

最終チームアンサンブルへの貢献

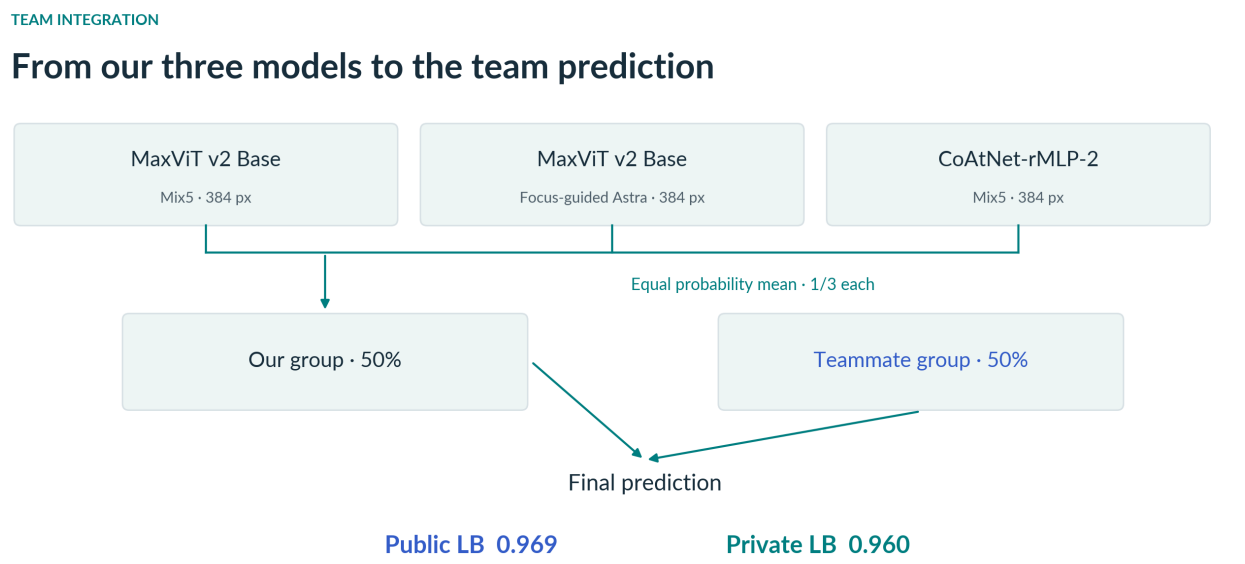


図12：群内等平均、その後2チーム群を等平均。最終Public 0.969 / Private 0.960。

私の群は最終予測の50%。他方は@tascj0の説明を参照。Notebookで検査・対象を整列し、2群を平均してoffline T4×2で実行します。私の系統は推論にMRIだけを使い、注釈ツールと空間表は学習資産です。統合前にcheckpointと入力設定・予測器を対応付け、読み直した後の予測、提出と学習実装の一致を確認しました。正しい重みでも前処理が違えば別モデルになるため重要です。（@tascj0's own description）

最後に

高品質Astraラベル、解剖BBox、補完モデル群を結び付けました。注釈を設計・検証・改善できる対象として扱うことが最大の学びです。レポート補助の読影器は提出モデルより豊かな根拠を調べ、その成果を連続ラベルと空間教師で渡せます。

学びは、教師が対象定義と合うか、位置が画像に根拠を持つか、学生が活用できるかを検証することです。流暢な説明や補助タスクの成功だけでは不十分。同条件学生比較と空間介入で注力先を決め、注釈機構を推論に持ち込まず成果を統合しました。

RSNA、放射線科医、Kaggle、特に@tascj0に感謝します。共同開発、議論、課題解決から多くを学びました。保存した注釈例と実装詳細が役立てば幸いです。 （@tascj0）

学習ラベルと空間注釈 （Training labels and spatial annotations）