rsna-knee-abnormality-detection

1st Place Solution（日本語訳）

Rank	1
Team	Team Kangaroo
Author	tascj
Topic ID	752468
Version	Japanese Translation

Source: https://www.kaggle.com/competitions/rsna-knee-abnormality-detection/discussion/752468
Retrieved with Kaggle CLI on 2026-10-27.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

コンペを開催したRSNA、注釈者、Kaggle、チームメイトの@liushuzhiに感謝します。 （@liushuzhi）

Team Kangarooの解法の私の担当部分です。@liushuzhiの担当部分はリンク先です。 （@liushuzhi / here）

0. 概要

学習4,407検査のうち12ラベルがあるのは58検査だけです。全学習検査に自由文の読影レポートがありますが、テストにはありません。

そこで主にラベル付けのコンペと考えました。最先端LLMエージェントから、12所見の確率、所見ごとのROIボックス、断面ごとの病変ボックスという異なる教師を得ました。

1. エージェントによるラベル付け

1.1 12所見

ラベル付けの仕組み

各ラベルは1つの非対話型エージェントセッションから得ます。検査・試行ごとに独立した作業領域を作り、CLIの非対話モード（`codex exec --json`、`claude -p --json-schema …`、`pi --print`）を起動し、指定スキーマの最終回答を回収します。CLIやモデルは設定1行で切り替えられ、以下は同じ条件で比較しました。

作業領域：

```
<workspace>/
├── AGENTS.md                  # task, definitions and grades of the 12 findings, reading
requirements, series table, full report, answer format
├── overviews/                 # an overview image per fluid-sensitive series (up to 48 slices, 6 per
row)
│   ├── SAG_FLUID.png
│   ├── COR_FLUID.png
│   └── AX_FLUID.png
├── series/
│   ├── S1_pd_tse_fs_sag/slices/001.png …
│   ├── S2_pd_tse_fs_cor/slices/001.png …
│   ├── …
│   ├── geometry.json          # DICOM geometry of each series
│   └── roles.json             # SAG_FLUID / COR_FLUID / AX_FLUID / SAG_STRUCT … → which series
├── tools/
│   ├── view_slices.py         # 1–4 slices of a series, cropped to a box and zoomed, adjustable
window
│   └── compare_location.py    # maps a point to the other series by DICOM geometry (states that the
series are not registered)
└── scratch/views/             # the only writable directory, for the output of the viewing commands
```

回答は根拠が先、確率が後です。各所見について、レポートの引用、画像の根拠（確認したビュー、シリーズ、スライス）、要約、最後に`present_probability`を求めます。出力例：

```
"acl": {
  "report_evidence": ["ACL is ruptured."],
  "image_evidence": [
    "VIEW 1 SAG_FLUID 14-17: markedly disorganized ACL with abnormal horizontal distal
     remnants and loss of normal bridging fibers toward the femoral attachment.",
    "VIEW 7 SAG_STRUCT 15-18: structural images confirm architectural disruption ..."],
  "present_probability": 0.98 },
"contusion": {
  "report_evidence": ["There are bone contusions in the weightbearing portion of the lateral
     femoral condyle and posterior aspect of both tibial condyle."],
  "image_evidence": [
    "VIEW 2 SAG_FLUID 8-10 ...: extensive lateral femoral and posterior lateral tibial marrow
     edema in an impaction distribution.", ...],
  "present_probability": 0.98 }
```


この検査は7回のツール呼び出しで16画像を確認しました。検査単位の中央値は約2.5分、15画像でした。

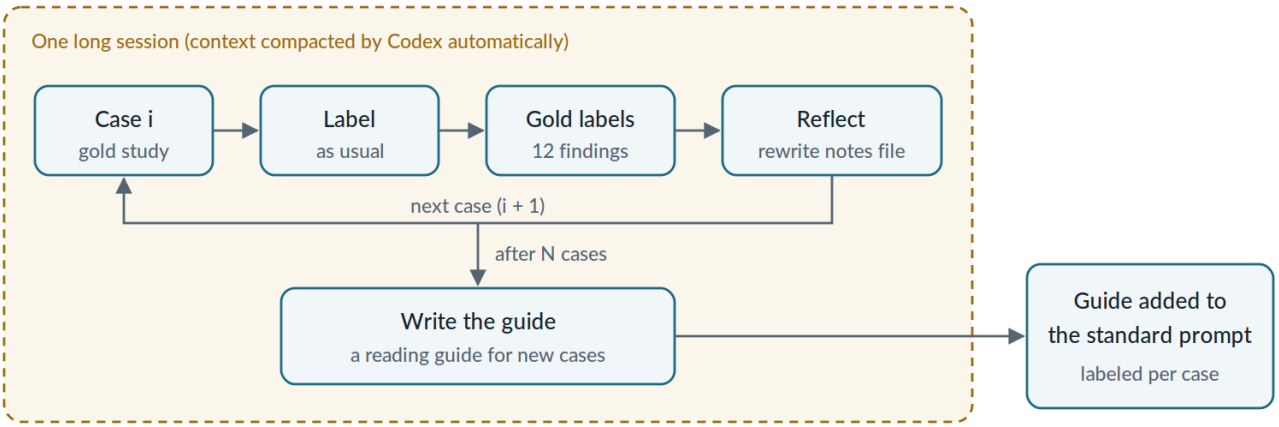
モデルと手順

最初は`pi + gpt-6-luna`を使い、Gold58のAUCを改善する手順（指示、拡張、ツール、スキルなど）を`/goal`でCodexに作らせました。その後`gpt-6.1-sol`で全学習データをラベル付けしました。チーム合流後、相方のラベルが私よりはるかに強いと分かりました。確率を割り当てる指示が優れていたので、その手順とCodexへ切り替えました。

モデル	手順	AUC	log loss	自信の強い誤り
GPT-6 Luna	tascjの手順	0.904	0.555	92
GPT-6 Luna	sakakuの手順	0.891	0.465	61
GPT-6.1 Sol	tascjの手順	0.928	0.492	63
GPT-6.1 Sol	sakakuの手順	0.932	0.350	44
GPT-6 Astra	sakakuの手順	0.936	0.329	35

運のよい試行ではGold58のAUCが相方と並びましたが、log lossと自信の強い誤りには大きな差がありました。以後はそれらでもラベルを評価しました。

学習させたガイド



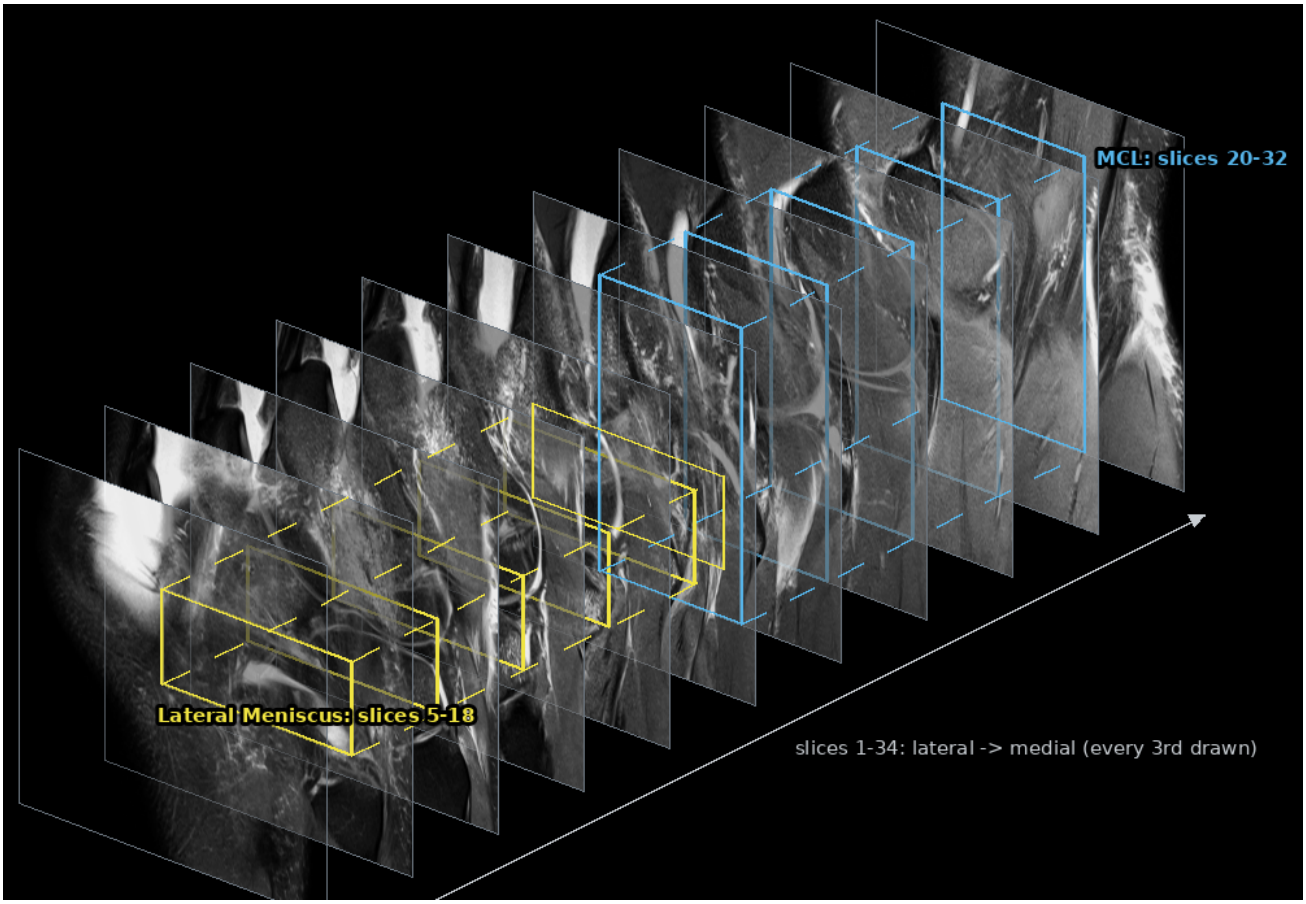
手順が重要なので、Goldからガイドを「学習」させました。長いCodexセッションで、sakakuの手順を基に通常どおりGold検査をラベル付けし、正解を見せ、振り返ってメモを書き直させ、次へ進ませます。N例後に読影ガイドを作り、他の検査のプロンプトに追加します。`gpt-6-astra-medium`でのGold58の結果：

	AUC	log loss	自信の強い誤り
sakakuのラベル	0.936	0.329	35
+ 学習ガイド（5分割、OOF）	0.936	0.307	19
+ 学習ガイド（同じ58検査で学習・適用）	0.943	0.300	16

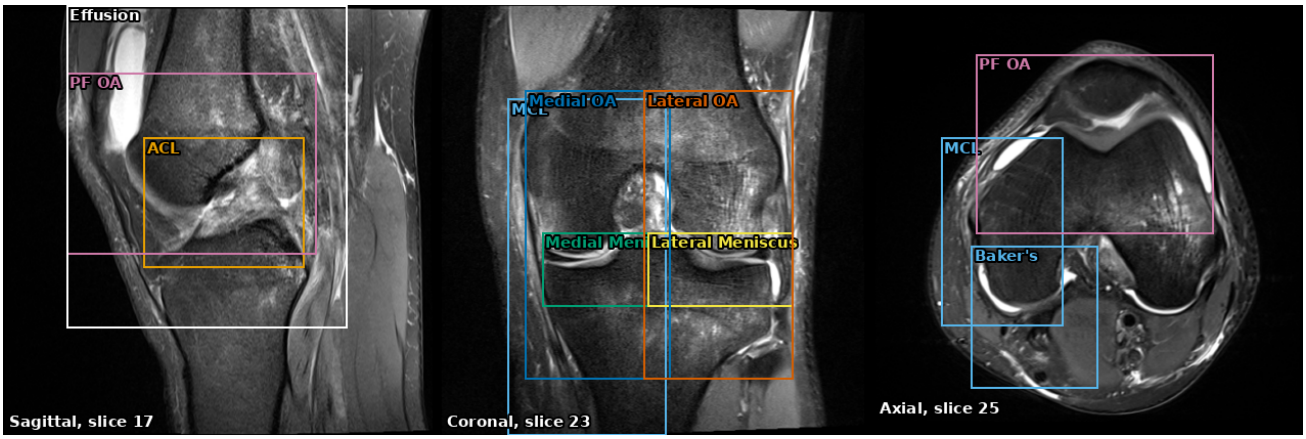
このガイドで全学習データをラベル付けし、提出モデルの一部の学習に使いました。

1.2 ROIボックス

ROIは病変そのものではなく、所見に関係する解剖構造を囲む、シリーズ・所見ごとに1つの3Dボックスです。ACLは靱帯全体、PF OAは膝蓋骨と滑車、関節液貯留は陥凹部を覆います。



上の検査の矢状断・液体強調シリーズ（外側から内側へ34枚、3枚おきに表示）とROIの例です。外側半月板はスライス5–18、MCLは20–32です。同じ矩形を連続断面に繰り返して直方体を作ります。所見ごとに断面範囲が異なります。

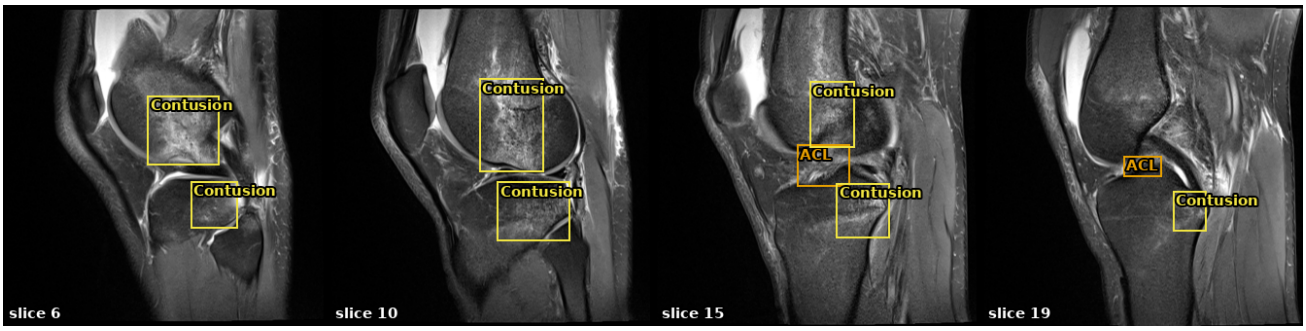


同じ検査の3方向のROI。各断面には、そのスライスと交わる所見のボックスの一部を表示しています。

長いCodexセッションで3D ROIを得ました。メインセッションが指示に従い21の並列サブセッションを開き、それぞれ検査バッチを順番に処理しました。751検査、4,092シリーズのボックスを得ました。テストの各シリーズの12ボックスを予測する検出器も学習しました。断面単位ConvNeXt-T（160 px）と3D融合で、保留した551シリーズの平均IoUは0.714でした。それ以上調整せず、以後の実験では予測ROIを使いました。

1.3 病変ボックス

病変はスライス単位の2Dボックスです。液体強調シリーズで病変が見える各断面を密着して囲みます。1断面の離れた領域（関節液の複数の溜まりなど）には別々のボックスを付けます。



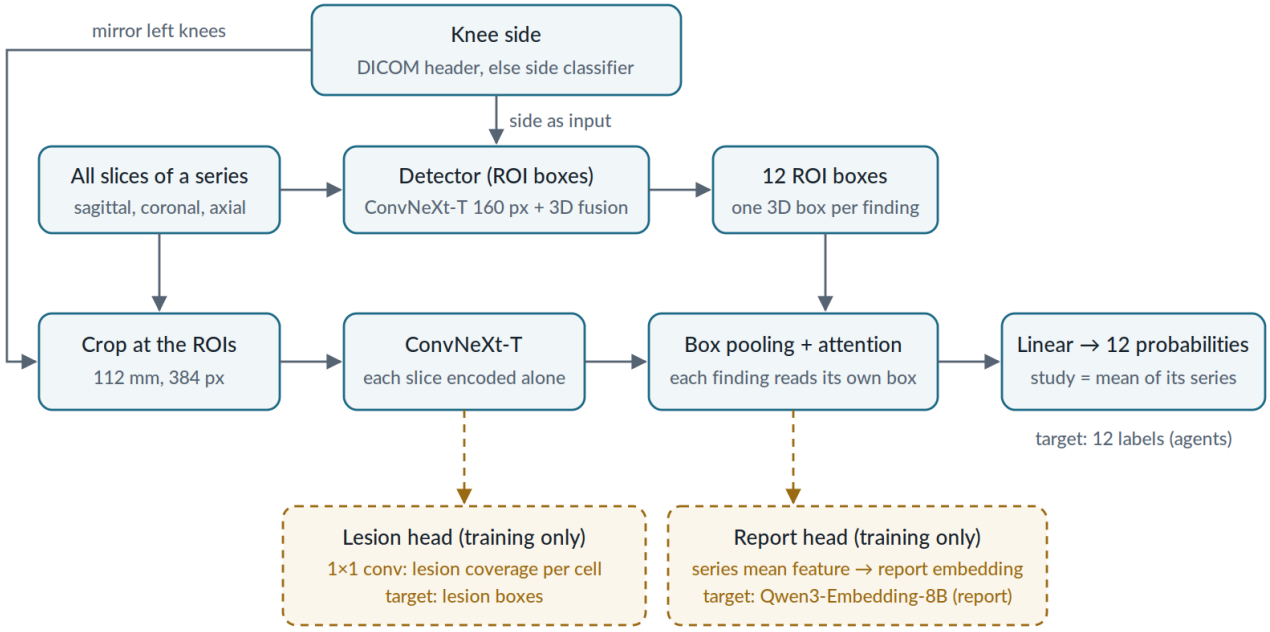
同じ検査のSAG_FLUIDにある骨挫傷（大腿骨外側顆、脛骨後外側）とACL断裂です。GPT-6.1 Solのボックスは、Astraが独立に挙げたスライス14–17（ACL）、6–12（骨挫傷）と整合しています。

12所見と同様、検査ごとに非対話セッション（`codex exec`、`gpt-6.1-sol-high`）を使いました。閲覧2コマンドに`check_boxes`を加え、正常組織を含めすぎず病変全体を覆うか提出前に確認させました。1,800検査、3,616病変、111,029ボックスを作りました。

2. モデル

シリーズ単位で学習し、検査のラベルを各シリーズに割り当てました。1シリーズを1サンプルとして単一断面の2Dエンコーダで処理し、検査予測はシリーズ平均です。検査単位のモデル化、2.5D、3Dでは改善しませんでした。3D ROIにより、それらが重要でなくなったのかもしれません。

最終構成は次のとおりです。



モデル構成。実線は推論経路、破線は学習時だけの補助教師。

入力

- 1シリーズが1サンプルです。画素間隔に従い各断面を140 mmの視野（512 px）へ変換し、シリーズの0.5 / 99.5パーセンタイルで濃度調整します。元の断面は最大64枚です。
- 左膝の冠状断・横断像を反転し、すべて右膝にそろえます。検出器には代わりに左右を入力します。DICOMヘッダー（左右、シリーズ説明）とROI注釈から、4,407検査中2,853検査の左右が分かります。その検査で学習した小型分類器（冠状断・横断像のResNet18-D）で残りを補い、保留検査で検査単位99.3%の正解率でした。 （RSNA 2026 Knee Side Classifier）
- ACL、両半月板、内側・外側OAのROI全体を囲むボックスを中心に112 mmで切り出し、384 pxに変換します。

ROIの利用：box pooling

- ConvNeXt-Tの最終特徴マップで、所見kのROIとの重なりを各セルの重みとします。ROIの断面範囲外は0です。加重平均が所見kのシリーズ特徴です。
- ボックス内attention：ゼロ初期化の1×1畳み込みで各セル・各所見を採点し、重みを「重なり × exp(score)」として内部で正規化します。学習開始時は通常のbox poolingです。
- 各所見は専用特徴を1線形層で読み、検査確率はシリーズ平均にします。

病変ボックスとレポート：学習時だけの補助教師

- 病変head（損失重み1）：1×1畳み込みが各セルの所見別病変被覆を予測し、ボックスがある（断面、所見）の組にBCEを適用します。
- レポートhead（損失重み0.3）：シリーズ平均特徴から、線形層で検査のレポート埋め込み（タスク指示付きQwen3-Embedding-8B、4096次元）を予測します。損失は1 − cosine。テストにレポートがないため、この形で使います。
- 両方とも推論では使わず、推論コストは増えません。

学習

項目	設定
最適化	AdamW、全パラメータの学習率5e-5、weight decay 0.02。0.5 epoch線形warmup後は一定、8 epochs、EMA 0.999。
バッチ	1更新につき8シリーズ
データ拡張	GPU上でシリーズごとに拡大縮小0.9–1.1、移動8%、回転10°
損失	ソフトラベルBCEと2種類の補助教師
数値精度	fp16 + GradScaler, torch.compile

推論

左右（DICOM、なければ分類器）→検出器ROI→切り出し（左膝反転）→box pooling→シリーズ平均

評価

- 分割：検査単位5分割。Gold58は分離し参照だけに使用。
- 指標：モデルや手順の異なる複数ラベルに対してAUCを測りました。Public LBを20–30件集めて相関を調べ、AUC（OOF、@liushuzhiのAstraソフトラベル）を信頼することにしました。（@liushuzhi）

段階ごとの改善

256 pxで1要素ずつ追加。sakakuの未校正Astraラベルに対する4,349検査の5-fold OOF macro AUCです。softはラベル確率をそのまま使い、hardは0.5で二値化します。58 goldは5分割モデルの平均をGold58で評価しました。

段階	soft	hard	58 gold
12ラベルのみ：断面単位ConvNeXt-T	0.8721	0.9586	0.9319
+ ROI box pooling	0.8746	0.9605	0.9330
+ ROI中心112 mm切り出し	0.8756	0.9616	0.9386
+ ボックス内attention	0.8769	0.9623	0.9396
+ 温度校正ラベル	0.8777	0.9625	0.9410
+ 病変headとレポートhead	0.8789	0.9638	0.9432

- 温度校正ではGold58でp' = σ(k · logit p)を当てはめます（k ≈ 0.77）。過信した確率を直す狙いです。

3. 提出

効率部門：単一モデル

- ConvNeXt-T（256 px）1つ、学習ガイドのラベル、全学習データ、単一EMAチェックポイント。前述の検出器とbox poolingを使います。
- Public 0.964、Private 0.954。
- T4×2で各GPU1プロセス、TensorRT、C++でDICOMを読みます。液体強調シリーズだけでデータ量41%減。学習の先頭1,200検査をテスト形式にするとNotebook全体は230秒（約4分）でした。

提案した最適化は、ほぼすべてOpus 5.5が一度で実装しました。最大の難点はKaggleの読み込み速度が安定しないことです。混雑時は約30 MB/s、空いていれば500 MB/s超で、デバッグが非常に大変でした。Submit後の環境の特別な保証も不明です（おそらくありません）。そのため空いている可能性が高い締切直前まで待って提出しました。

推論Notebook （Inference notebook）

メイン部門：アンサンブル

主に入力384のConvNeXt-Tを使い、多様性のため少し異なる実験を加えました。

実験（すべて384 px）	ラベル	モデル	重み	Public LB	Private LB
ConvNeXt-T	学習ガイド	5分割	2	0.967	0.958
MambaOut-B+	校正したsakakuのAstraラベル。他モデル・手順のラベルごとに追加headも設置	全データ × 3 seeds	1		
MaxxViT-V2-B	同上	全データ × 3 seeds	1		
ConvNeXt-T、6チャネル	sakakuのAstra 2バージョンの平均を校正	全データ × 3 seeds	1		
MambaOut-B+、6チャネル	同上	全データ × 3 seeds	1		

- 6チャネル版は多様性用です。（方向 × 脂肪抑制）の固定6チャネルに対応するシリーズを入れ、患者座標を使い現在のシリーズの断面へ再標本化します。効果はbackboneのアンサンブルより大きかったです。
- 全backboneに同じbox poolingを使います。

推論Notebook （Inference notebook）

注記

私自身、パイプラインの細部、特にROI・病変ボックスの学習への使い方を完全には理解していません。たいていClaude Opus 5.5に「こうした注釈がある。使い方をいくつか提案して実験して」と大まかに頼み、その実験から改善が得られました。

詳細は公開学習Notebookを確認してください。

- RSNA 2026 Knee Side Classifier （RSNA 2026 Knee Side Classifier）
- RSNA 2026 Knee ROI Detector （RSNA 2026 Knee ROI Detector）
- RSNA 2026 Knee Box-Pooling Classifier （RSNA 2026 Knee Box-Pooling Classifier）
- ラベル （Labels）

補足Q&A

Takuya Mizutani（質問、3544678）: 優勝おめでとうございます。詳細な投稿をありがとうございます。可能なら、所見の確率、ROI、病変注釈を含むエージェントによるラベル付けに、合計どれほど費用がかかったか教えてください。API課金か定額プランでしょうか。再現費用を知るため、概算でも助かります。

Ilia Iliev（質問、3544766）: おめでとうございます。効率とメインの両部門での優勝は素晴らしいです。やはりラベルなのですね。費用を見積もると、全シリーズの15枚の画像を読み込むだけで約$220、ツールと出力を加えればAstra APIで$500–$1000程度と予想します。このくらいでしょうか。

tascj（回答、3544772）: @takuyamizutani、@iliailiev1。Codex 20xプランの週当たり利用枠に換算すると、概算で12ラベルが3、ROIが1.5、病変ボックスが1.5です。デバッグも含めた実際の合計は、その2倍を超えるはずです。Codexの利用枠はかなり頻繁にリセットされたため、できるだけ早く使い切り、次のアイデアを準備していました。