rsna-knee-abnormality-detection

2nd Place Solution（日本語訳）

Rank	2
Team	MURAD
Author	azamat1ch
Topic ID	752370
Version	Japanese Translation

Source: https://www.kaggle.com/competitions/rsna-knee-abnormality-detection/discussion/752370
Retrieved with Kaggle CLI on 2026-10-27.

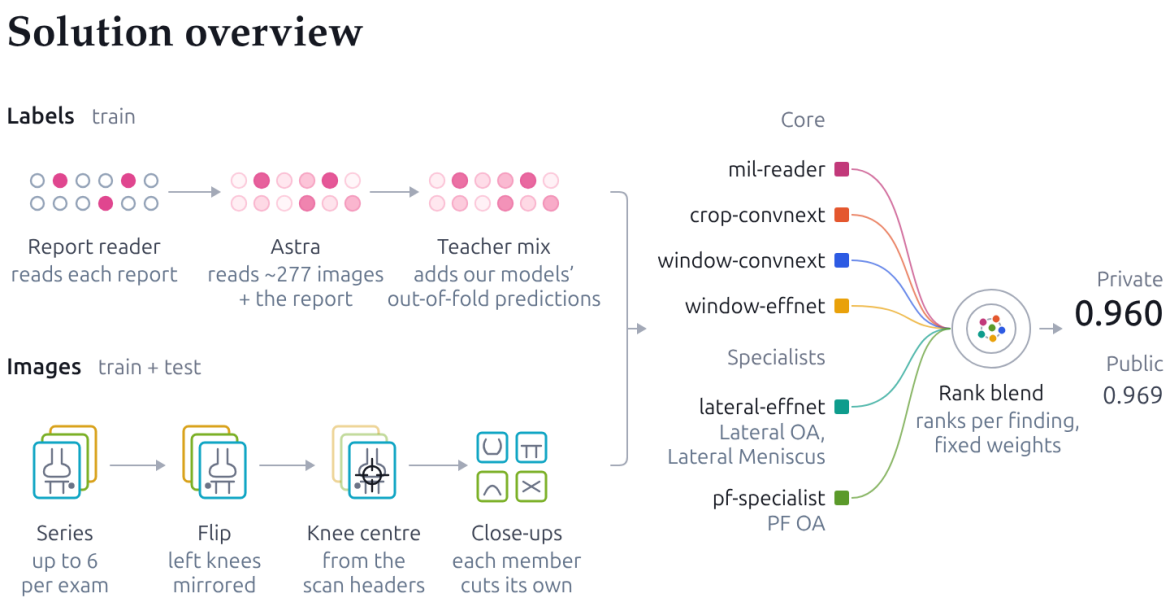
Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

2位。Private 0.960、Public 0.969。

データセットを作成したRSNA、テスト画像を評価した放射線科医、開催したKaggleに心から感謝します。初めて本格的に取り組んだコンペで、非公開テストでのクラッシュ、長く続く0.001刻みの改善、最終日の最後の枠で送った最終提出（入賞作）など、緊張の多い経験でした。

1. 解法の概要

- ラベル：LLMが各レポートを読み、別のLLM（Astra）がレポートと全学習検査の画像を読み、最後に自前モデルの予測もソフトラベルとして混ぜました。専門医ラベル58検査との比較で、レポートだけの0.899から0.956へ改善しました。
- モデル：6種類の2.5D MILモデルが、それぞれ膝の拡大画像を切り出し、所見ごとの1スコアに集約します。
- アンサンブル：手動設定の重みで順位を混合。中核4モデルは12所見すべてに投票し、専門モデル2つがPF OAと外側半月板・外側OAに0.20の比率で加わります。



上：一度だけ行う教師作成。下：学習・テストの各検査が通る処理。

構成モデル	Backbone	対象所見	単独のPublic / Private	混合重み
mil-reader	ConvNeXt-T、fastMRI事前学習	全12所見	0.966 / 0.957	0.35
crop-convnext	ConvNeXt-T	全12所見	0.964 / 0.955	0.25
window-convnext	ConvNeXt-T	全12所見	0.964 / 0.955	0.20
window-effnet	EfficientNetV2-S	全12所見	0.965 / 0.954	0.20
lateral-effnet	EfficientNetV2-S	外側半月板、外側OA	外側OAの個別評価：0.932 / 約0.944	0.20

構成モデル	Backbone	対象所見	単独のPublic / Private	混合重み
pf-specialist	ConvNeXt-T、fastMRI事前学習	PF OA	PF OAの個別評価：0.944 / 約0.932	0.20

2. 問題

学習では主にレポートしかありませんが、テストは専門医が画像を読んで採点します。専門医ラベル付き58検査では、レポートの陽性154件に対して専門医の陽性は240件（PF OAは2対21）。主に、レポートに書く理由のない軽症です。本当の課題は軽症と正常の区別で、レポートだけでは教えられませんでした。

3. ラベル

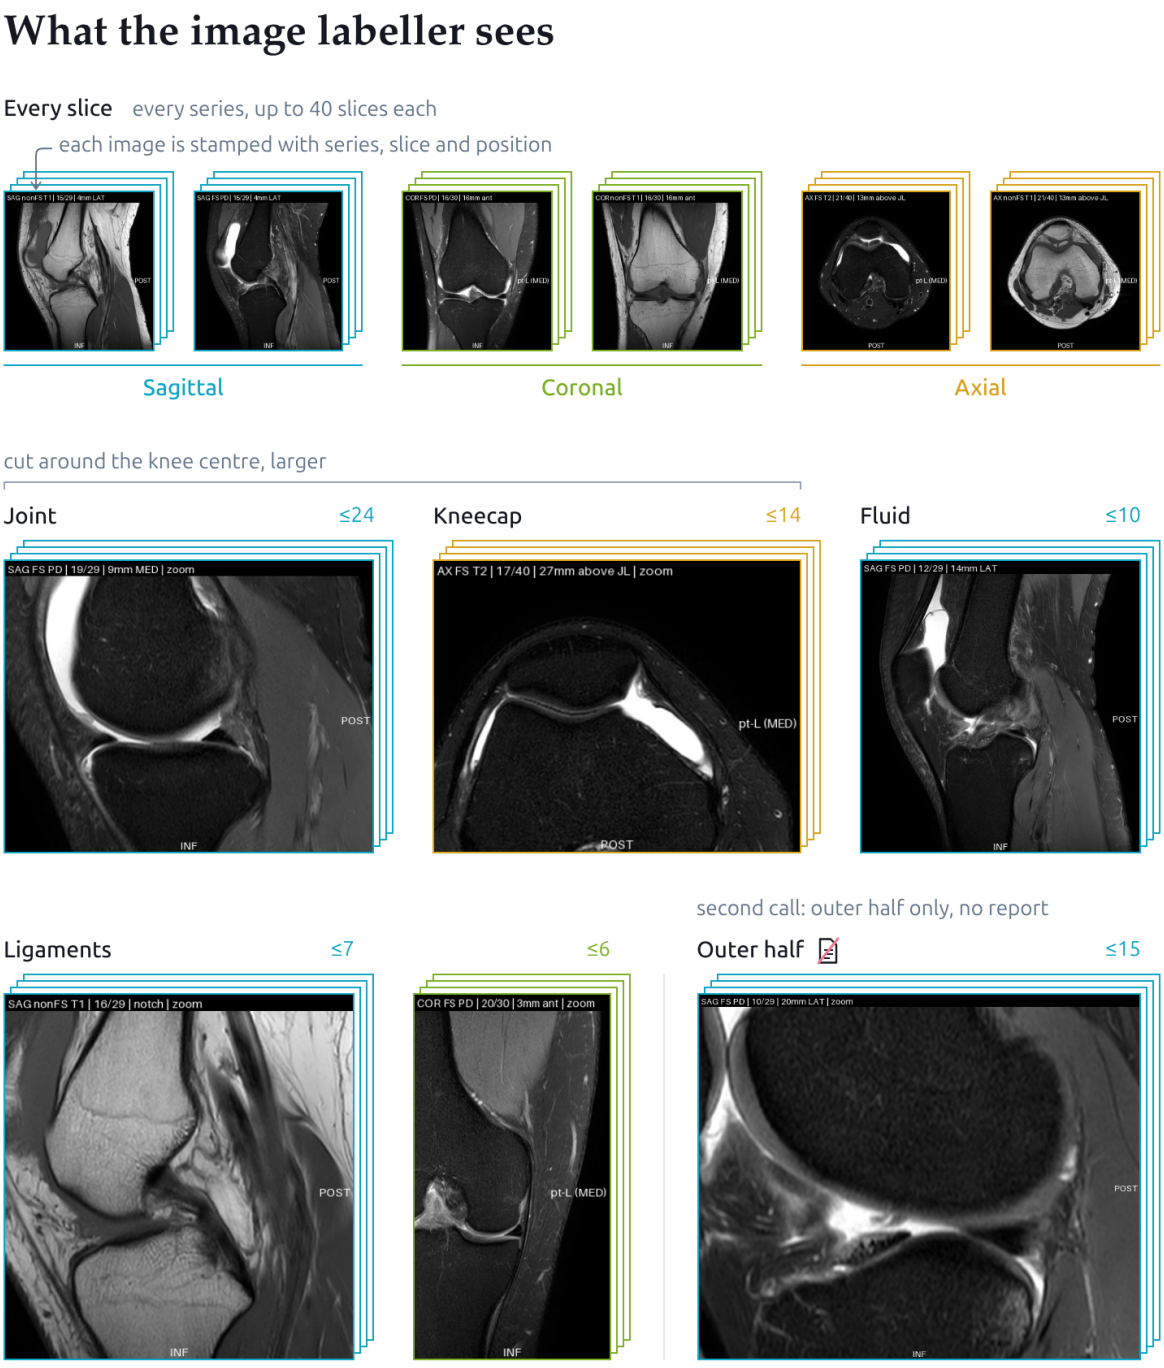
ラベル付けは学習検査だけで、推論ではLLMを使いません（商用LLM APIは主催者が投稿733965で許可）。各ラベル版をモデルと同様に58件で評価しました。偶然で約±0.02動くため24件で調整し、34件を固定版の確認用に残しました。後期のPF OA下限などは全58件を使ったので、その改善は示唆であり証明ではありません。

3.1 レポートを読む

GPT-6.1 Solで各レポートを原言語のまま読みました。言語はおおむね病院に対応し、翻訳ミスは膝ではなく病院を教えてしまいます。所見ごとに文章を引用し、6回答（あり、おそらくあり、不明、おそらくなし、なし、記載なし）から選び、0–100点を付けます。コードで回答と点数をソフトラベルに変換し、58件で0.899でした。

3.2 画像を読む

初期試験では画像は役立たないように見えましたが、134断面中44枚しか見せていませんでした。そこでAstra（GPT-6 Astra）へ全断面を渡しました。1検査1呼び出しで約277画像、レポート、文章読影器の回答を与え、レポートは既知の欠落がある同僚の読影として扱うよう指示しました。



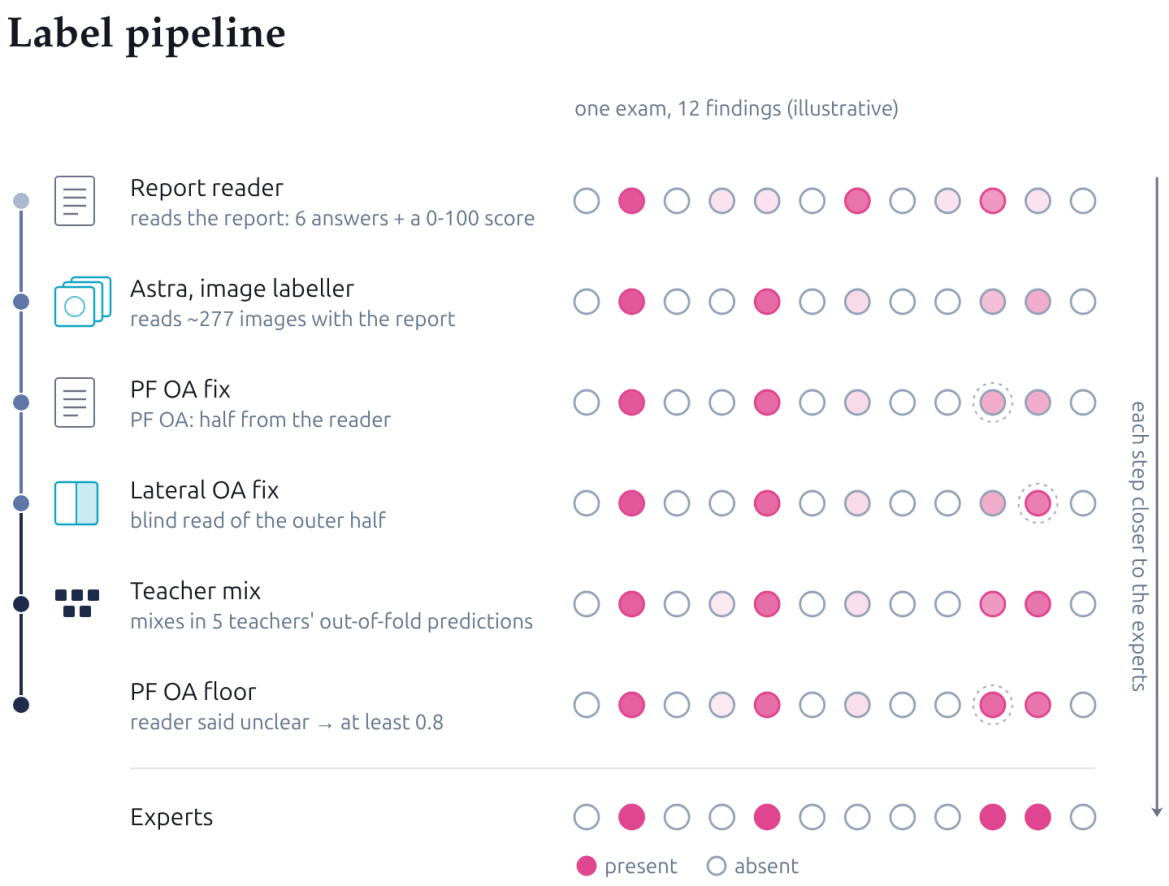
最初に全シリーズ、その後に拡大像。拡大スタック上の数値は最大断面数です。

Astraのラベルは0.942、文章読影器は0.899でした（+0.043、95%区間+0.025〜+0.063）。Gold58のラベル一致度では最大の改善でした。関節液貯留は0.806→0.975、ベーカー嚢腫は0.803→0.979でした。

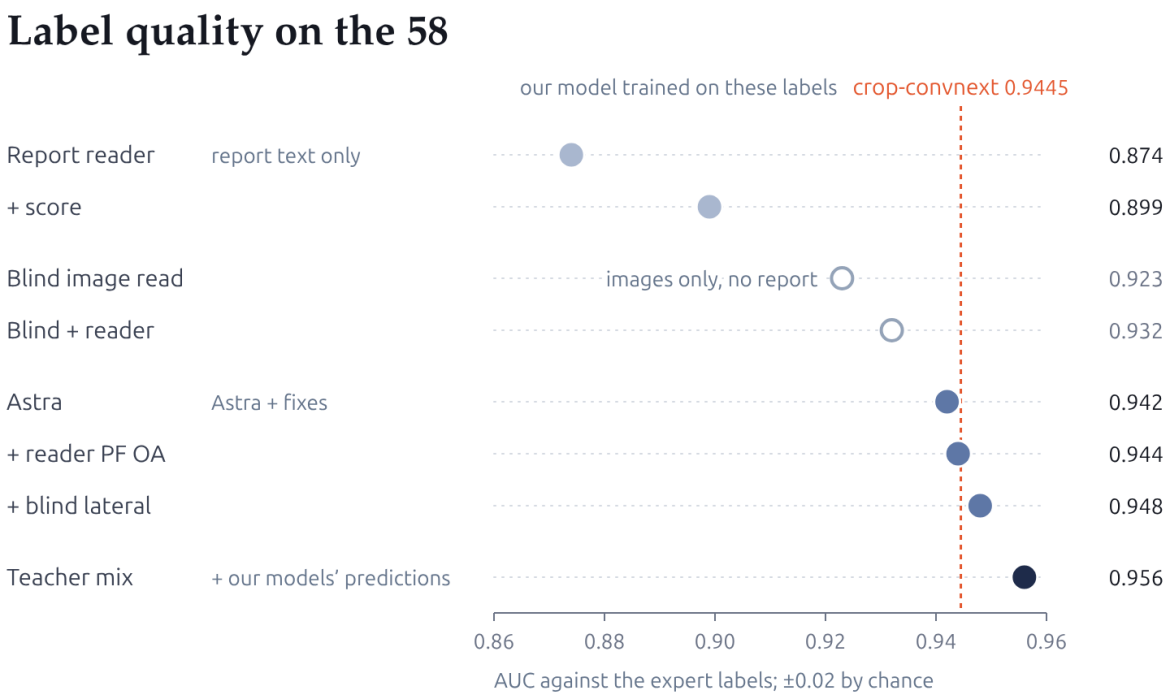
3.3 2つの修正と別の意見

PF OAでは文章読影器が0.960、Astraが0.930でした。専門医がPF OAとする膝蓋軟骨損傷がレポートに書かれているため、PF OAラベルの半分を文章読影器から取ります。外側OAはレポートを見せず膝外側半分を再読影し、0.856から0.898へ上がりました。

次に5つの教師モデルを学習し、OOF予測をラベルへ混ぜました。レポートがよい証人になるACL、MCL、両半月板、PF OA、外側OAでは元ラベルを0.7、その他は0.4残します。最後に58件からルールを追加しました。PF OAを「不明」とした12検査すべてが専門医では陽性だったため、学習でもそのケースは最低0.8としました。



検査の例。各点が1所見です。



各点は58件で評価した1ラベル版。破線はcrop-convnextの分割モデルです。

この時点で、ラベルはモデルが学べる以上の情報を持っていました。以後はモデルに見せるものを改善する必要がありました。

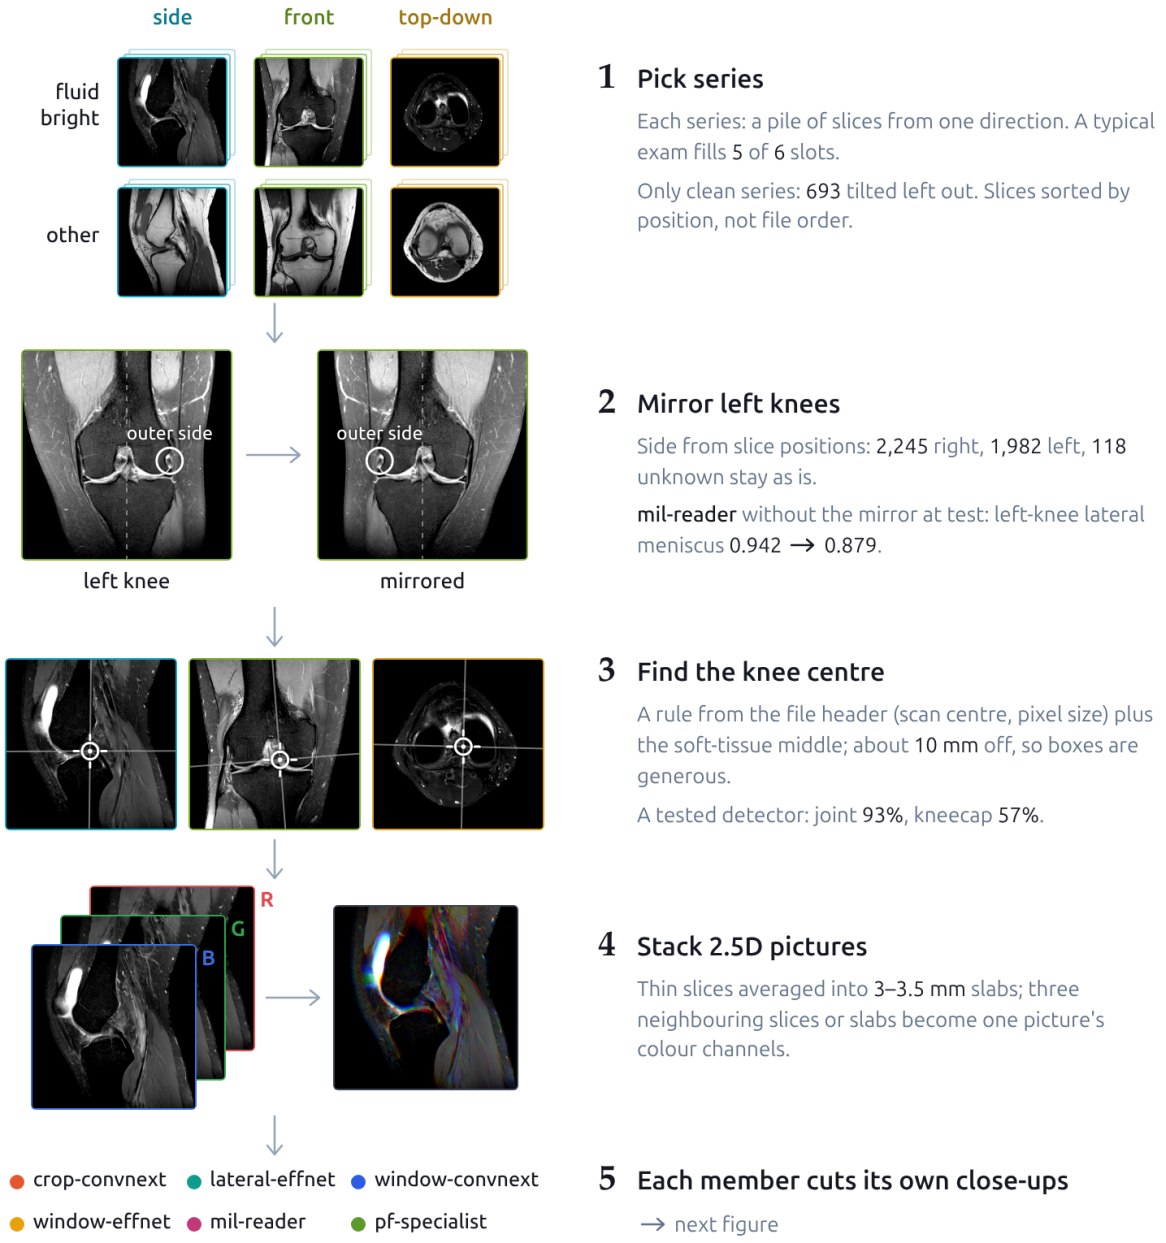
3.4 各モデルの教師

最終モデルは利用可能な4,403検査すべてで学習し、58件には専門医ラベルを使いました。lateral-effnetは58件を学習せず、そこで評価できるようにしました。

構成モデル	ラベル
crop-convnext, window-convnext	教師混合 + PF OA下限
lateral-effnet	2修正を加えたAstraラベル
pf-specialist	lateral-effnetのラベルに、緩やかなPF OA下限
window-effnet	pf-specialistのラベルに、mil-readerのOOF予測を0.3混合
mil-reader	Astraラベル

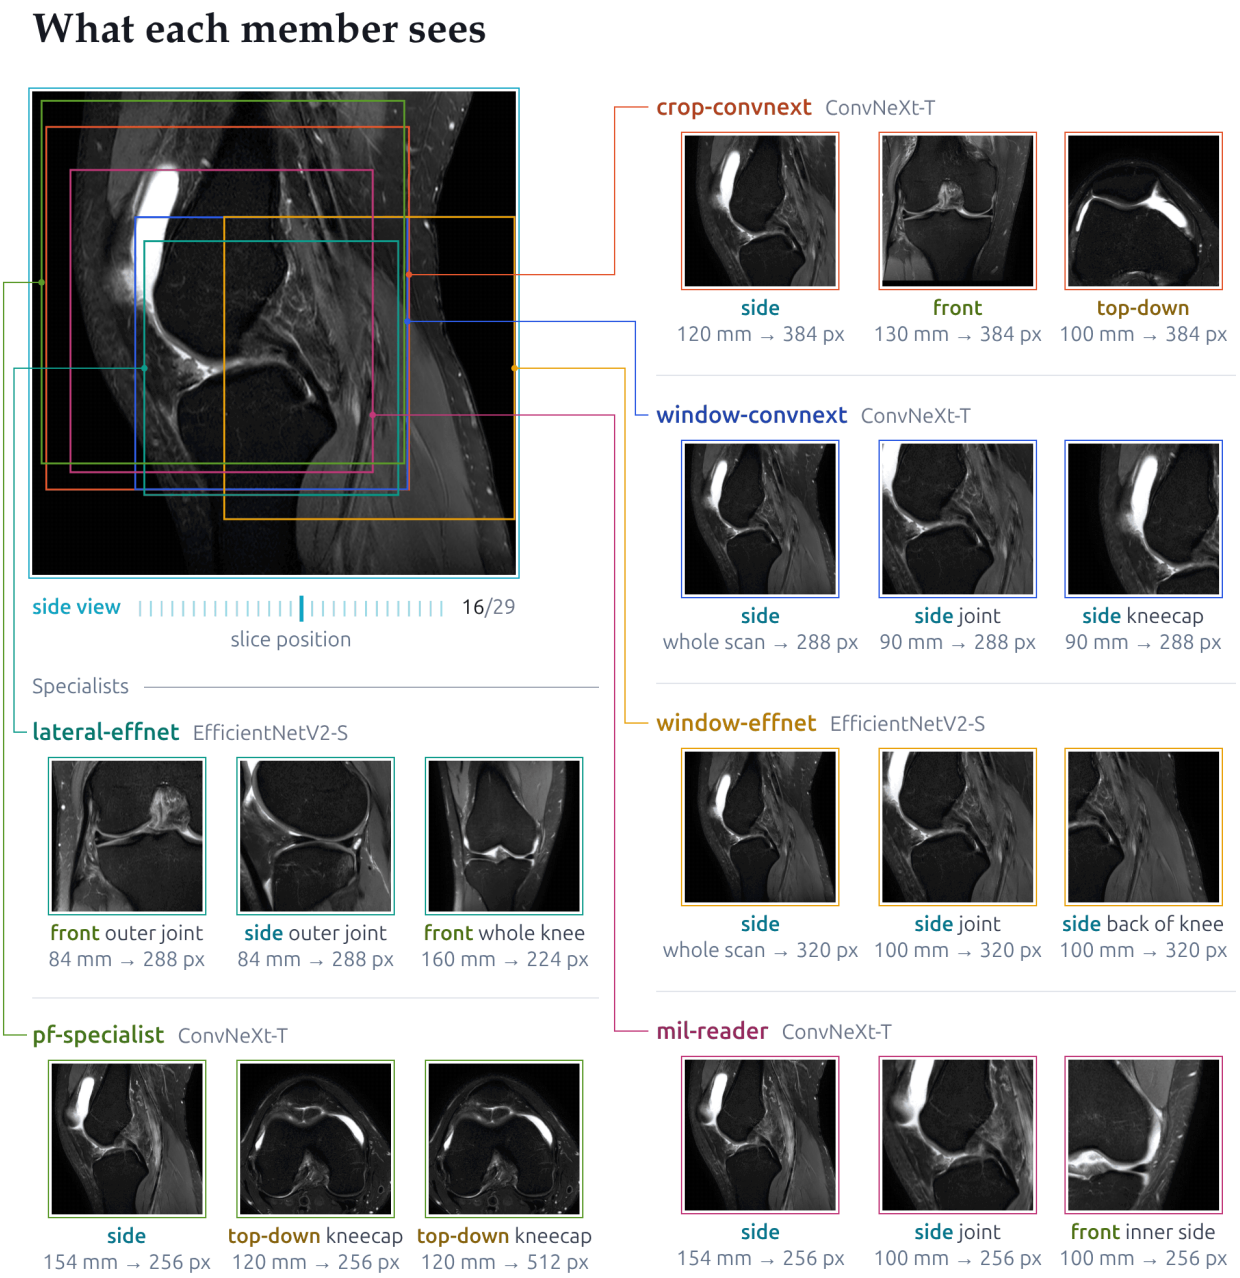
4. 入力

各モデルは共通の手順で検査を2.5D画像にし、それぞれ独自の拡大像を作ります。



学習時とテスト時の各検査の入力処理。

チーム合流で加わったmil-readerとpf-specialistは、最初の3段階を独自の方法で行います。脂肪抑制でシリーズを分け、タグから左右を読み（不明ならfastMRI学習の小型分類器）、ヘッダーだけで膝中心を取ります。拡大像はheliosliの公開手法に従います。



各モデルの切り出し位置を断面ごとに表示。各行はモデルが読む画像です。

最大の違いはここで、混合の価値もここから生まれます。入力の不具合は多くのモデル変更以上に効きました。初期は1シリーズ4画像しか読まず、15画像にすると58件で+0.033でした。以後、全ボックス範囲に画像を分散します。mil-readerは学習時1ビュー8群、テストは等間隔12群を使います。私たちの4モデルはテストで断面オフセット0、1、2の3通りを平均します。

5. モデル

6モデルとも2.5D画像を符号化し、所見別attentionで検査全体を集約します。mil-readerとpf-specialistは先に2層Transformerを通します。

5.1 中核4モデル

- mil-readerは最強単体モデル（5 seeds）。goodpjw2008の公開2.5D ConvNeXt-T MIL（Apache 2.0）を基にし、私たちのラベルではPublic 0.955でした。左膝反転、画像内の所見別attention、膝中心の拡大像を追加しました。エンコーダはfastMRIの膝画像とfastMRI+ボックスで事前学習しました。
- crop-convnextは自作の最も単純な強いモデルです。膝中心ルールから側面・前面・上面の関節拡大像を384 pxで切り出し、3 seedsを使います。
- window-convnextはheliosliの公開Notebookのウィンドウ（全シリーズと膝周辺の局所像）を使い、私たちのラベルと中心で、全ウィンドウ・全データ・3 seedsを学習します。58件で最強の分割モデル（0.9488）です。
- window-effnetは同じビューをEfficientNetV2-Sで読み、BatchNormを固定します。教師の一部はmil-reader由来でも、別のビューを見るため単に模倣せず異なる予測になります。

5.2 2つの専門モデル

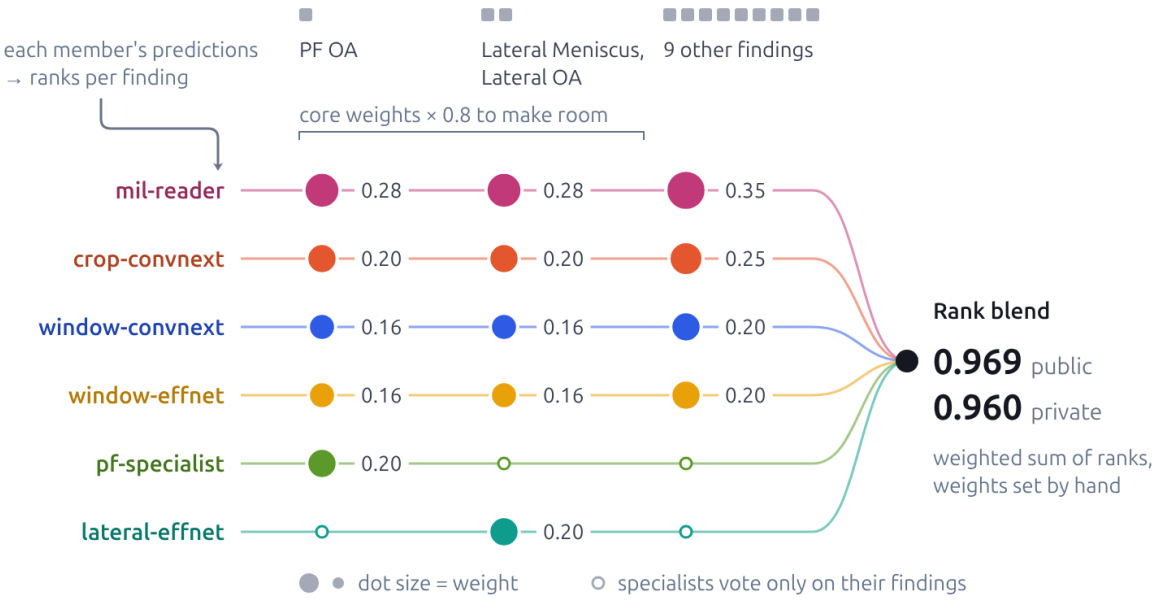
全モデルでPF OAと外側OAが弱く、Public約0.92でした。そこで専門モデルは担当所見だけに投票します。1所見だけを評価するため、その列以外の11列を0.5にした提出を使いました。

- lateral-effnetの外側OAはPublic個別評価0.932で、mil-readerの0.920より高い値でした。Privateでは約0.944対0.956と逆転しましたが、他との類似性は最も低いモデルです（順位相関約0.92）。
- pf-specialistはmil-readerのエンコーダに、OAIのMOAKS評価から膝蓋軟骨グレードを学ぶ第2headを追加したものです。PF OA個別評価はPublic 0.944、Private約0.932で、window-convnextの0.920、0.908を上回りました。重みは個別評価より前に固定しました。

6. アンサンブル

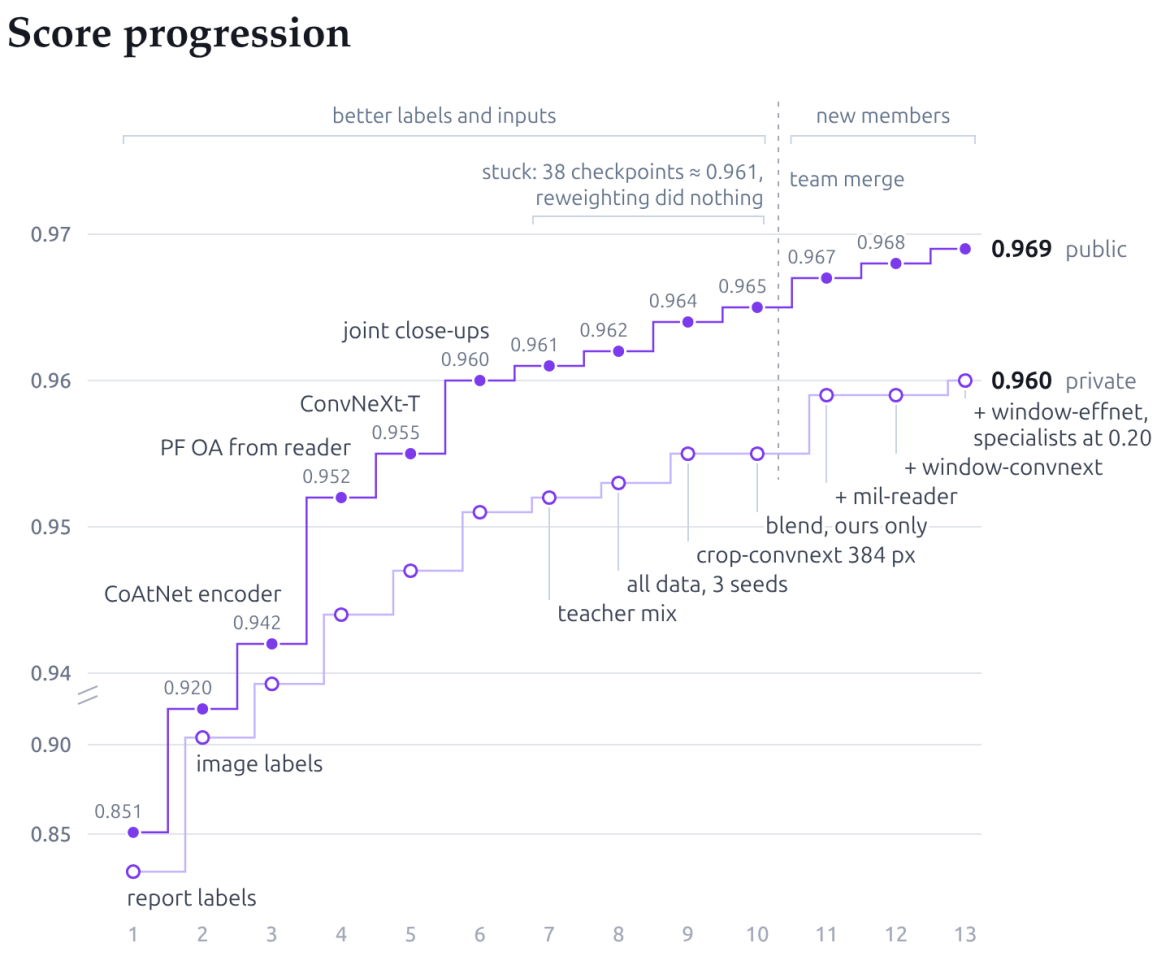
各予測を所見ごとにテスト集合内の順位へ変換し、概要表の手動重みで合計します。重み探索はしていません。専門所見は専門モデル0.20、中核の重みを0.8倍とします。中核4つの提出を先に保存し、専門モデルには時間予算を設け、失敗すれば除外します。読めない検査は既定値（私たちのモデルでは学習時の有病率）を使います。

Final ensemble



列を上から下へ読むと、各所見のモデル重みが分かります。

7. 結果



塗りつぶしはPublic、輪はPrivate。破線はチーム合流です。

教師と入力の改善で自前モデルはPublic 0.964へ到達し、それ以降は新たな構成モデルだけが効きました。Public 0.955以上の提出ではPublicとPrivateの順序が一致し、順位相関0.977でした。選択提出は全101提出中のPrivate最高でもありました。

8. うまくいかなかったこと

- 専門医の答えをAstraへ見せる：答えを写し、そこから書いたルールを答えなしで使うと0.80でした。
- 所見別の独立再読影を増やす：調整24件で+0.066、保留34件では−0.019でした。
- 混合重みの調整：保留検査で固定重みより0.002〜0.007低下しました。
- 拡大像だけにする：外側半月板で−0.010となり、膝全体を戻す必要がありました。
- 似たモデルを足す：単独Public 0.959のモデルでも、混合には寄与しませんでした。

9. コードと謝辞

6モデルの最終seedの学習は、研究実験を除いてレンタルGPU約100時間、合計約$100でした。推論はインターネットなしのKaggle NotebookでT4×2を使います。コード・Notebook・重みはProject Links、学習設定・プロンプト・教師生成コードはリポジトリにあります。

mil-readerの出発点となる公開2.5D MILの@goodpjw2008、window-convnext/window-effnetと拡大像の基礎となる公開手法（Apache 2.0）の@heliosliに感謝します。外部データはfastMRI膝画像とfastMRI+ボックス（mil-reader/pf-specialistの事前学習と左右分類）、OAIのMOAKS軟骨グレード（pf-specialist）です。（@goodpjw2008 / @heliosli）

出典

- 商用LLM APIを許可する主催者の回答：（https://www.kaggle.com/competitions/rsna-knee-abnormality-detection/discussion/733965）
- goodpjw2008、2.5D ConvNeXt MIL読影モデル（Apache 2.0）：（https://www.kaggle.com/code/goodpjw2008/rsna-knee-coatnet-2-5d-convnext-mil-lb-0-950）
- heliosli、ウィンドウ手法（Apache 2.0）：（https://www.kaggle.com/code/heliosli/0-9573-latest-public-dataset-score-in-one-click）
- Liu et al., A ConvNet for the 2020s, CVPR 2022. https://arxiv.org/abs/2201.03545 （https://arxiv.org/abs/2201.03545）
- Tan & Le, EfficientNetV2, ICML 2021. https://arxiv.org/abs/2104.00298 （https://arxiv.org/abs/2104.00298）
- Ilse, Tomczak & Welling, Attention-based Deep Multiple Instance Learning, ICML 2018. https://arxiv.org/abs/1802.04712 （https://arxiv.org/abs/1802.04712）
- Wightman, PyTorch Image Models (timm). https://github.com/huggingface/pytorch-image-models（https://github.com/huggingface/pytorch-image-models）
- Zbontar et al., fastMRI, 2018 (https://arxiv.org/abs/1811.08839); Zhao et al., fastMRI+, Scientific Data 2022.（https://arxiv.org/abs/1811.08839);）
- Osteoarthritis Initiative (https://nda.nih.gov/oai); Hunter et al., MOAKS, Osteoarthritis and Cartilage 2011.（https://nda.nih.gov/oai);）

OAIは、米国保健福祉省の一部であるNIHが資金提供する5契約（N01-AR-2-2258、N01-AR-2-2259、N01-AR-2-2260、N01-AR-2-2261、N01-AR-2-2262）からなる官民連携で、OAI研究者が実施しています。民間資金提供者はMerck Research Laboratories、Novartis Pharmaceuticals Corporation、GlaxoSmithKline、Pfizer, Inc.です。民間資金はFoundation for the National Institutes of Healthが管理します。本研究はOAI公開利用データで作成され、OAI研究者、NIH、民間資金提供者の意見や見解を必ずしも反映しません。

補足Q&A

Adel Zebiche（質問、3544119）: 2位おめでとうございます。詳細な投稿はとても参考になります。画像でのラベル付けが鍵だったようですが、約4,400検査、各約277画像のAstraによるラベル付けは、API料金でどれほどかかりましたか。

azamat1ch（回答、3544391）: ありがとうございます。月$200のCodex定額プランで、週の利用枠を約2回分、約400–500Mトークン（主に画像入力）使いました。API価格なら約$2–4kと推測します。