rsna-knee-abnormality-detection

3rd Place Solution: RSNA Knee Abnormality Detection 2026（日本語訳）

Rank	3
Team	DataTech Club
Author	Zhihong Li
Topic ID	752510
Version	Japanese Translation

Source: https://www.kaggle.com/competitions/rsna-knee-abnormality-detection/discussion/752510
Retrieved with Kaggle CLI on 2026-10-27.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

開催に尽力したRSNA、Kaggle、参加施設・放射線科医、オープンソースコミュニティに感謝します。

Zhengru Li、Zhihong Li、Guoqin Gu、Mutian Hong、Bufan Liの共同解法です。私たちは上海科技大学でデータサイエンス競技、機械学習、AIを探究する学生団体DataTechのメンバーです。参加者、研究者、協力者との交流を歓迎します。DataTech Clubもご覧ください。（DataTech Club）

Public 9位（0.968）・Private 3位（0.959）

概要

4,407学習検査のうち専門医ラベルは58件だけでした。残りに多言語レポートはありますが、評価対象は画像診断です。複数情報源のソフトラベルを作り、2.5D MRIモデルを学習し、補完的な構成を群別の確率混合で統合しました。レポートと注釈モデルは教師作成だけで、推論にはMRIのみを使います。

提出	構成	Public	Private
G36-Gold	36チェックポイント、群別確率混合	0.968	0.959
A21GT	26チェックポイント、3専門モデルへ固定振り分け	0.968	0.958

G36-Goldが3位となりました。選択した2提出は別々に評価され、平均していません。以下のLB値はKaggleの小数3桁表示です。

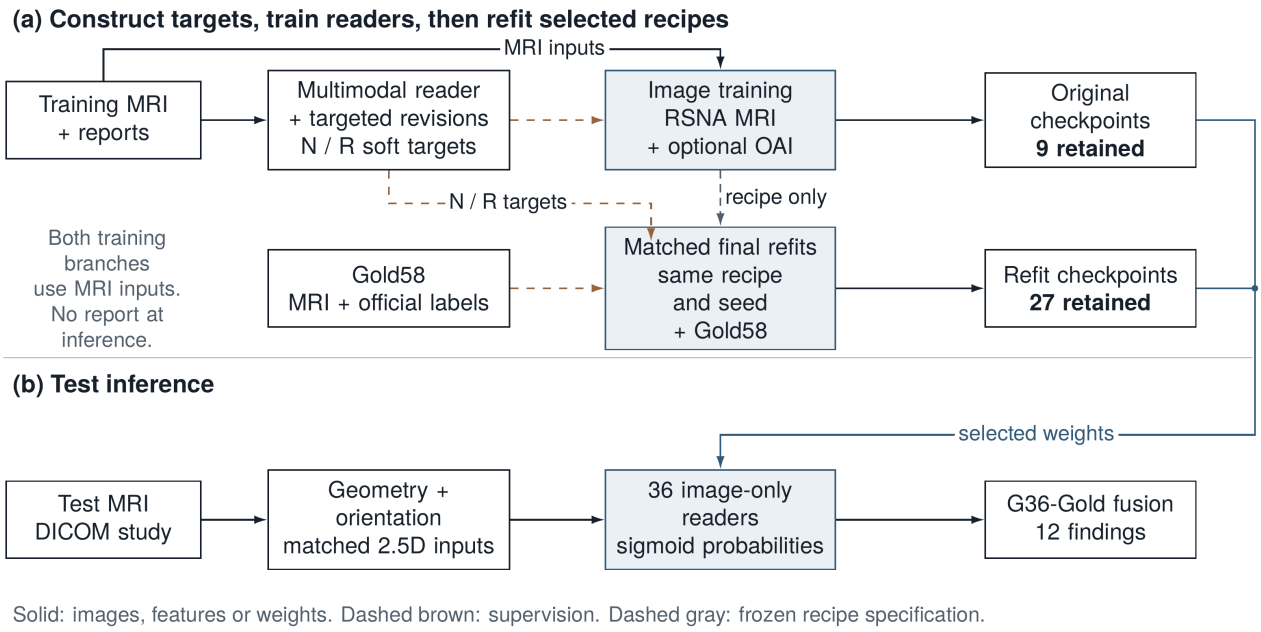


図1：学習と推論。固定した設定でGold58込み再学習または元のチェックポイントを使います。灰色破線は学習済み重みでなく設定の引き継ぎです。

1. 不完全なレポートから教師を作る

1.1 診断用語だけでなく画像を読む

レポートは所見を省略したり、陽性基準に届かない変化を書いたりします。GPT-6 AstraにMRIと文章を確認させ、12連続値を付けました。さらに所見専用読影器でPF OA、外側OA、滑膜炎を修正しました。

PF専用では1方向・撮像群の384 px断面を最大9枚、順序付きシートにしました。画像から位置・重症度・範囲を確認後、レポートと照合します。他の文章読影器の意見は票ではなく補助証拠です。採用した修正は対象所見だけ変えました。学生は固定ラベルで学び、文章や説明は使いません。

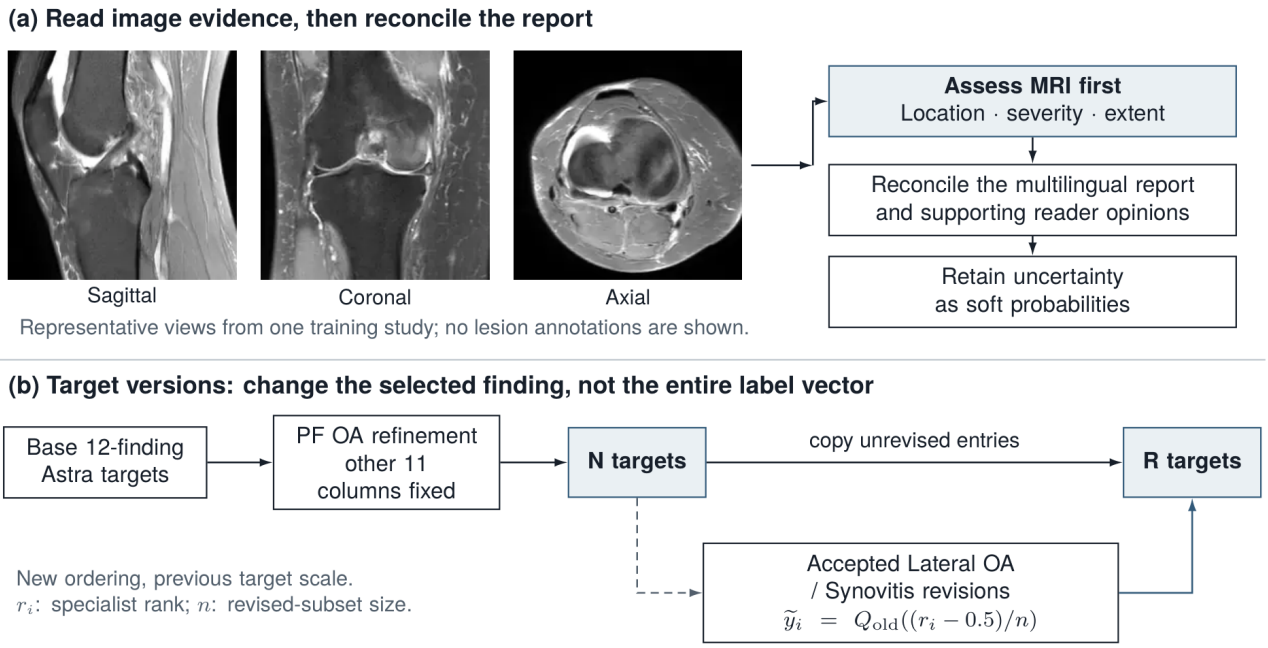


図2：画像根拠からラベル版へ。3実画像は1学習検査の固定入力キャッシュで、形式の例です。保存した注釈セッションや特定の診断所見ではありません。下段は実際の教師作成ルール。

1.2 補完的な教師を残す

NはPF OA修正版。Rはさらに、採用した外側OA・滑膜炎の修正に専門読影器の順位を使います。修正部分集合内で以前の教師の分位点に順位を対応させ、新順位を保ちつつ尺度変化を抑えます。未修正要素は固定です。新読影器が変える順位と尺度を分位点変換で分離します。これは採用部分集合だけに適用し、テスト予測全体への処理ではありません。両版をモデル群に含めます。Rは教師変換であり順位損失ではありません。

1.3 外部OAI教師

一部モデルには約9,440膝のOAI MRIも使いました。専門医評価はコンペ教師と完全には一致しません。主なv3kd50は確実に対応できるセルで、該当する専門医教師と10モデル教師を50:50に混ぜ、他セルは補完値や低い重みを維持します。（Osteoarthritis Initiative (OAI)）

混合前に教師の陽性BCE重みw_cを取り除き、t=p/[p+w_c(1-p)]とします。一部実験は学習logitへOAIだけの有病率補正を加えますが、テストには使いません。G36-GoldはRSNAのみ13、OAI混合23モデルで、epochあたりのOAI量も異なります（7節）。

2. 複数方向・断面からMRIを読む

2.1 幾何と局所文脈

DICOM物理座標で断面を並べ、膝方向を統一し、欠損ビューをマスクします。矢状液体強調・非強調、冠状液体強調・非強調、横断の5群です。約140 mmの視野を224、384、512 pxへ変換します。旧方式と1回だけ再標本化するnative方式は、それぞれ元のチェックポイントと組み合わせます。代表キャッシュは各群18、14、12、8、12中心位置、最大64で欠損をマスクします。各モデル固有の前処理・サンプリングを維持します。

2.5Dは同一シリーズの元の直近3断面を重ねます。BiT ResNetV2-50、ConvNeXt-Small、DINOv3 ViT-B/16、CoAtNetで符号化し、クラス別空間pooling、全体平均、attention MILで12検査logitsへ集約します。

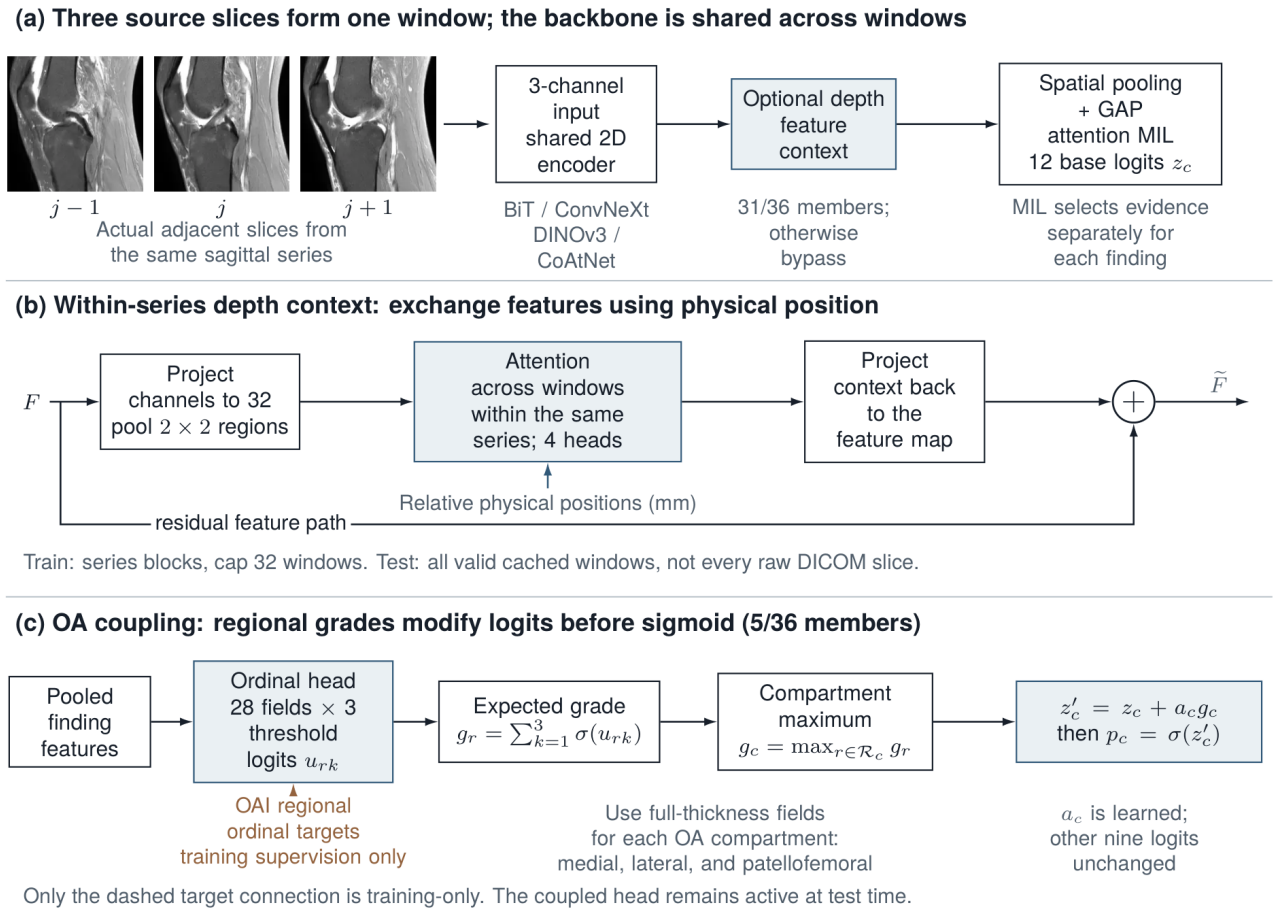


図3：(a)隣接矢状3断面の入力。(b)任意のシリーズ内深度文脈は物理位置で特徴を交換し残差接続を持ちます。(c)OA連結headは順序出力を区画別証拠に変え、sigmoid前の3logitsを修正します。図は概念で、測定したattentionではありません。

2.2 深度attentionとOA連結

深度文脈（31/36モデル）は32次元射影、2×2領域pooling、シリーズ内4attention headsを使います。学習集合はシリーズのまとまりを保ち最大32ウィンドウ。推論は有効な全キャッシュウィンドウで、元DICOMの全断面ではありません。

OA連結（5/36モデル）は病変ボックスでなく領域軟骨グレードを学びます。累積順序予測を区画別最大値と3OA logitsの残差へ変えます。他9logitsは不変です。OAIグレードは学習だけですが、連結headは推論にも残ります。

3. 学習と構成の多様性

陽性重み付きソフトBCEにmass-preserving正規化を使います。教師依存の陽性重み量の逆数をクラス別学習平均でスケールし、教師は連続値を保ちます。終了はGold58最良epochではなく25固定です。RK4Cは名目50-epoch OneCycleにepoch18–25の尾部を設け、ピーク学習率の2%で終え25で停止します。各モデル固有のscheduleを維持しました。最終は全データの設定・seed違いで、均一な5-fold構成ではありません。

要素	代表設定
最適化	AdamW、backbone LR 3e-5〜1e-4、head LR 1e-3
スケジュール	OneCycle系、epoch18–25の減衰尾部
実効バッチ / weight decay	通常8 / 0.01
拡張	濃度、アフィン、拡大縮小、gamma。補間は設定別
チェックポイント	EMA 0.999または固定終了時Raw
推論	FP16、ウィンドウを分割して符号化

G36-GoldはBiT 17、ConvNeXt 7、DINOv3 7、CoAtNet 5です。224/384/512 pxの数は4/23/9、EMA 32とRaw 4です。これらの数で最終重みが決まるわけではありません。

配分を決めて多様性を作る

Matrix20は各backboneに5設定を割り当て、解像度、N/R教師、OAI量、入力処理を変えます。全組み合わせ探索でなく選んだ集合です。詳細は付録。

(a) Model memberships by group

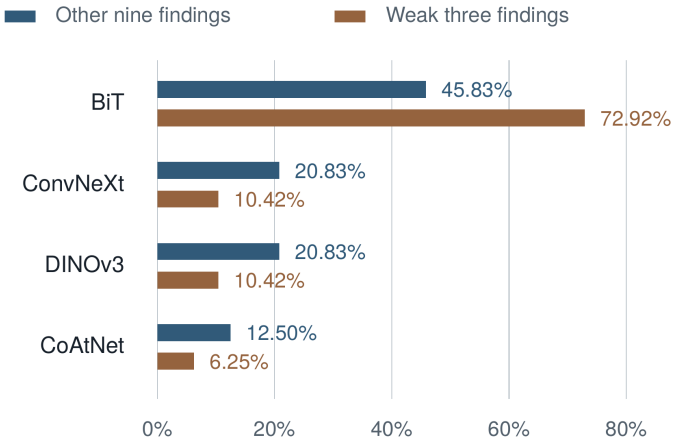
Counts include the Mature12/Expert8 overlap.

	BiT	CNX	DINO	CoAt
Mature12	8	2	2	0
Matrix20	**5**	**5**	**5**	**5**
Expert8	8	0	0	0

Only Matrix20 gives equal budget to each backbone. Mature12 and Expert8 deliberately favor BiT recipes.

Four shared checkpoints are computed once. Their two group contributions remain in the blend.

(b) Effective weight in each output



Linear blend coefficients; not model counts or causal attributions.

図4：群式を展開した実効重み。Matrix20はbackbone均等ですが、全体は特に弱い3所見でBiTを優先します。線形混合係数であり、因果的な特徴寄与ではありません。

同じ構造の実験・seed数で自動的に比率が決まるのを防ぐ仕組みです。全体がbackbone均等という意味ではありません。Mature12は成熟したBiT、Expert8はすべてBiTです。設定差は多様性候補であり、独立した誤りの証明ではありません。

4. G36-Gold：群別固定配分と所見別補助

Mature12は確立した強い設定、Matrix20はbackboneの均等な網羅、Expert8は外側OA・PF OA・滑膜炎にRK4/RK4C系列を補います。

専門モデルも通常12出力です。「専門」は追加重みを使う予測を指し、単一クラス学習とは限りません。Matrix20も個別チェックポイント重みを最適化せず、群内の構造比をそろえます。

sigmoid確率p[m,c]に対するベース予測：

```
B[c] = 0.5 * mean(p[m, c] for m in Mature12)
     + 0.5 * mean(p[m, c] for m in Matrix20)
```

他9所見はB[c]、弱い3所見は次式です。

```
P[c] = 0.5 * B[c] + 0.5 * mean(p[m, c] for m in Expert8)
```

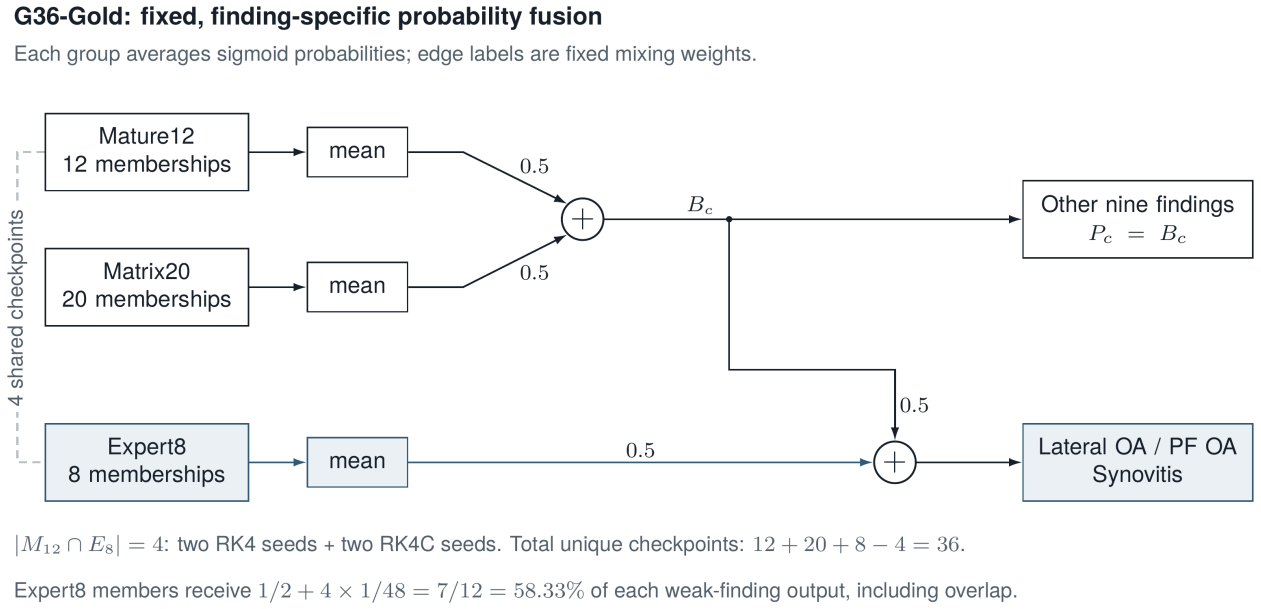


図5：G36融合。共有4モデルは推論1回ですが、Mature12とExpert8両方で寄与します。順位変換せず確率で融合します。

RK4の2 seedsとRK4Cの2 seedsが両群に属するため、12+20+8−4=36固有モデルです。専門8モデルはMature12側の寄与も含め、弱い所見の展開後重み58.33%を占めます。

最終Gold58込み再学習

G36固定後、設定・seed・入力・重み読み出しが一致するモデルをGold58込みで再学習しました。対応しないものは元の重みを残し、再学習27 + 元9、群と融合は固定です。

Gold58は既にプロンプト・モデル開発に使っています。再学習後の学習内Goldスコアで構成・重みを選び直さず、実行・一致確認だけに使いました。7節では開発値と事後LBを分けます。

5. 別提出：固定振り分けA21GT

A21の21モデルの等確率平均を9所見に使い、弱い各所見はベースを使わず独立した3専門モデルの平均にします。

所見	割当専門モデル
外側OA	U5組織認識RK4、RK4C、ConvNeXt-512 R
PF OA	ConvNeXt-512 R + OAI、RK4C-lib、ConvNeXt-512 R + 全OAI
滑膜炎	RK4Call, RK4C (seed 2027), RK4 (seed 2027)

RK4はR教師、epochあたりOAI 4,000膝のBiT-50深度モデル。RK4CはOA連結headを追加。RK4C-libは別のOAI PF-OA教師・重み対応、RK4Callは毎epoch全OAI、U5はRK4に17組織項目の学習専用補助タスクを追加します。

共有により計26モデル（再学習14、元12）。Public 0.968 / Private 0.958で、PrivateはG36-Goldより低い結果でした。構成と融合の両方が異なり、soft混合とhard振り分けだけの比較ではありません。

6. 推論・実装

T4の2workerでDICOM復号と再利用可能な前処理を共有し、各モデル固有の入力を保ちます。FP16と分割符号化でメモリを抑え、モデル識別、ローカルとKaggle例示テストの予測、クラス別融合を検証しました。両offline版とも制限内に採点されました。時間予測は非公開テストの実測ではありません。

7. 実験と結果

Privateは事後評価。以下のGold58は、Gold未学習モデルを繰り返し使った開発集合で測ったもので、盲検ではありません。LBは小数3桁です。

7.1 OAI教師と学習設定

全実験BiT-50深度、seed 2026、epoch25 EMA固定です。N/RはRSNA教師、専門医/教師比は対応できるOAIセルだけに適用します。

実験	RSNA教師	OAI / epoch	専門医 : 教師	Gold58	Public	Private
E1ベースライン	N	なし	—	0.9400	0.962	0.951
J-v3	N	2,000	70 : 30	0.9446	0.963	0.953
J-v3-all	N	9,440	70 : 30	0.9408	0.962	0.951
J-kd50-all	N	9,440	50 : 50	0.9453	0.963	0.952
RK4	R	4,000	50 : 50	0.9505	0.963	0.953
N3RK4-o18	R	epoch18まで4,000	50 : 50	0.9523	0.963	0.953

教師混合が最も明確な対比較です。J-v3-allとJ-kd50-allはOAI教師・重み経路が70:30対50:50で、ラベル依存offsetも再計算しました。手元AUCは0.9408→0.9453、両LB表示値は+0.001でした。

OAIを増やすほど良いわけではありません。70:30では全プールが2,000抽出に負けましたが、データ量と更新回数も同時に変わります。RK4は教師とOAI量を変更。N3RK4-o18は補助教師とOAIなしの終盤を追加し、手元は上がってもLB表示は同じでした。全要素の単独比較ではありません。

7.2 後期アンサンブルとGold58再学習

提出	チェックポイント数	Gold58再学習数	Public	Private
A21、Goldなし	21	0	0.968	0.959
A28、seed増量	28	0	0.968	0.958
A35、seed増量	35	0	0.967	0.958
F44、群混合	44	0	0.968	0.959
G36、Goldなし	36	0	0.968	0.959
G36-Gold（選択）	36	27	0.968	0.959
A21G、等重み再学習	30	24	0.968	0.958
A21GT（選択）	26	14	0.968	0.958

A28/A35はseed数と単純平均の設定比率を同時に変えたため、Private低下をseedだけに帰せません。G36は群配分を固定しました。

G36、G36-Gold、A21、F44はいずれもPrivate表示0.959です。この精度ではGold再学習や群分けの優位を証明できません。G36-Goldは選択2提出中の最良で3位でした。

コードと再現性

推論NotebookはG36-Gold、A21GT。学習コード、注釈プロンプト、設定、重みは後日公開します。（G36-Gold / A21GT）

参考文献

- コンペ：RSNA Knee Abnormality Detection。（RSNA Knee Abnormality Detection）
- 外部データ：Osteoarthritis Initiative。（Osteoarthritis Initiative）
- Backbone：Big Transfer（BiT）、ConvNeXt、DINOv3、CoAtNet。（Big Transfer (BiT) / ConvNeXt / DINOv3 / CoAtNet）
- モデルライブラリ：PyTorch Image Models（timm）。（PyTorch Image Models (timm)）

付録：Matrix20の正確な設定一覧

backboneごと5設定。固定したモデル枠を示し、Gold学習有無の由来を示すものではありません。N/Rは本文の教師系列。OAI=0は同時OAI学習なし、allは利用可能な全プールです。nativeは元画像からの処理、legacyは旧前処理を表します。

Backbone	解像度	教師	OAI / epoch	前処理
BiT	224	N	4000	native
BiT	384	R	0	legacy
BiT	384	N	4000	native
BiT	512	R	4000	native
BiT	512	N	2000	native
ConvNeXt-S	224	R	2000	native
ConvNeXt-S	384	N	0	legacy
ConvNeXt-S	384	R	4000	native
ConvNeXt-S	512	N	all	native
ConvNeXt-S	384	N	2000	native
DINOv3	224	N	all	native
DINOv3	384	R	2000	legacy
DINOv3	384	N	4000	native
DINOv3	512	R	0	native
DINOv3	384	R	all	legacy
CoAtNet	224	R	0	native
CoAtNet	384	N	all	legacy
CoAtNet	384	R	2000	native
CoAtNet	512	N	4000	native
CoAtNet	384	N	0	native