rsna-knee-abnormality-detection

5th Place Solution（日本語訳）

Rank	5
Team	RB & Matheus & Tucker & Tony
Author	Rashmi B
Topic ID	752190
Version	Japanese Translation

Source: https://www.kaggle.com/competitions/rsna-knee-abnormality-detection/discussion/752190
Retrieved with Kaggle CLI on 2026-10-27.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

開催したRSNAとKaggleに感謝します。

素晴らしいチームメイト✨ @tonylica、✨ @tuckerarrants、✨ @tomirolに感謝します。（@tonylica / @tuckerarrants / @tomirol）

1. 解法概要

専門医ラベルは58検査だけなので、残りの教師作成に注力しました。

検査単位CNNを、次の3情報源のソフトラベルで学習しました。

- 言語モデルによる読影レポートの解釈。
- 視覚モデルによる選択したMRI断面の解釈。
- 以前のモデルのOOF予測。

専門医ラベル58検査を参照し、学習ソフトラベルを校正・調整しました。

主モデルはMRI全体像と、膝関節・内側・外側・膝蓋大腿関節の局所切り出しを併用しました。

骨の領域分割モデルで切り出し位置を決めます。全体像は膝全体を示し、局所像は各領域を最大2倍の解像度で示します。

最終アンサンブルはまずEfficientNetV2-Mの2系列（M1、M2）とConvNeXt Base（M3）の確率を加重平均します。

次に別学習の領域専門モデル（M4）、外側半月板向けの4微調整モデル（M5）、ConvNeXt-Tiny（M6）を加えます。後半は予測順位を混ぜ、所見別に構成を選びます。

2. 問題：レポートからの教師

学習4,407検査は、同じ膝を異なる方向・コントラストで撮影した各3–14シリーズからなります。約1,300テスト検査の12所見（靭帯・半月板損傷、3区画のOA、関節液貯留、滑膜炎、ベーカー嚢腫、骨挫傷、骨折）を予測し、平均AUCで評価します。

専門医ラベルは58件だけで、残る4,349件は多言語の自由文レポートから教師を作ります。テストにレポートはありません。レポートの教師は3点で不完全です。

1. 情報欠落は負例ではありません。出発点の公開ラベル表2つのうち1つは、検査・所見の組の27%、滑膜炎の組の84%に回答がありませんでした。

2. 表現とコンペ定義が異なります。主催者ガイド（733343）は急性の高度部分断裂・完全断裂だけをMCL陽性としますが、低グレードMCLの199レポートに陽性ラベルがありました。専門医付き検査では該当5件中0件が陽性（その他のレポート陽性MCLは13件中9件）。少量の関節液も22件中10件だけが陽性でした（その他のレポート陽性は28件中24件）。（topic 733343）

3. ラベル値が過大で、過大さも一律ではありません。曖昧・軽度な記載から得た約0.75の「あり」は38%しか正しくありませんでした。関節液から推測した滑膜炎は、直接記載と同じ0.84でしたが、専門医確認率は38%対65%でした。AUCは順位を見るため、この不均一な誤りは順序を壊します。

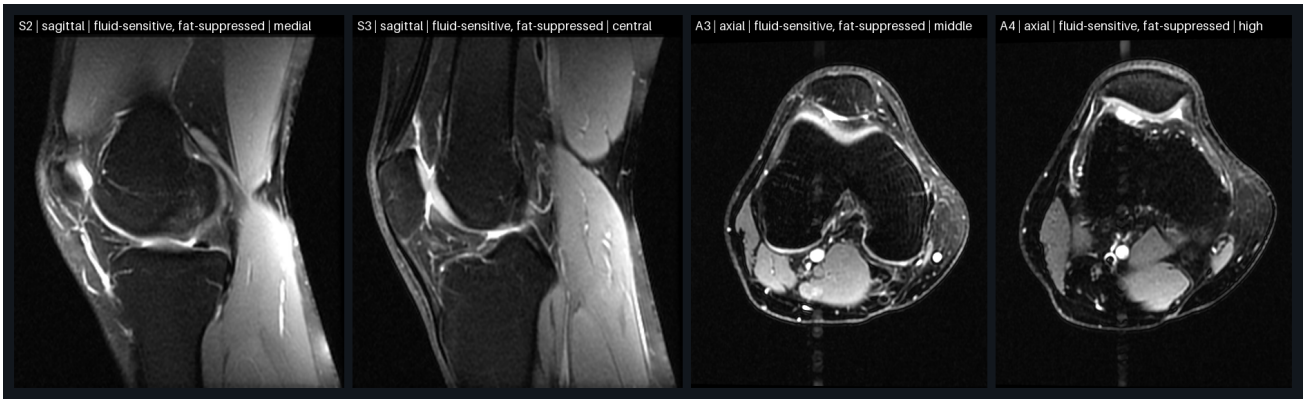
58件を使って教師を補正しました（3節）。選択にも使っているため、そのスコアは楽観的です。

3. 学習ラベル

各所見0〜1のソフトラベルでCNNを学習しました。3段階で改善し、専門医付き58件は元の正解を保持しました。

1. 公開レポートラベルの校正。Pilkwangとstevenの公開LLMラベル表から始め、専門医の陽性率に近づけるよう調整しました。各検証foldの調整は他foldの専門医付き検査だけで推定します。このラベルをcalAと呼びます。（Pilkwang / steven）

2. レポートと画像の新しい解釈。全レポートをClaude Opus 5.5で処理しました。関節液貯留、滑膜炎、ベーカー嚢腫は、骨マスク（4節）で選んだ検査あたり脂肪抑制10断面をgpt-6.1-solにも見せました。両解釈を合わせてFを作り、不一致例をさらに2回読み直してF2にしました。



視覚モデルが3所見を読む断面のうち4枚。

3. 以前のCNNの予測と混合。F2にCNNのOOF予測を加えてv3を作り、文章と選択断面に由来する教師へ画像予測を補いました。後のv5はF2、v3学習CNN、領域専門モデル入りの以前のアンサンブルの予測を混ぜます。混合係数は各検証fold以外の専門医付き検査で推定しました。領域モデルM1とM3はv5で学習しました。

Private AUCへの効果（コンペ後に測定）

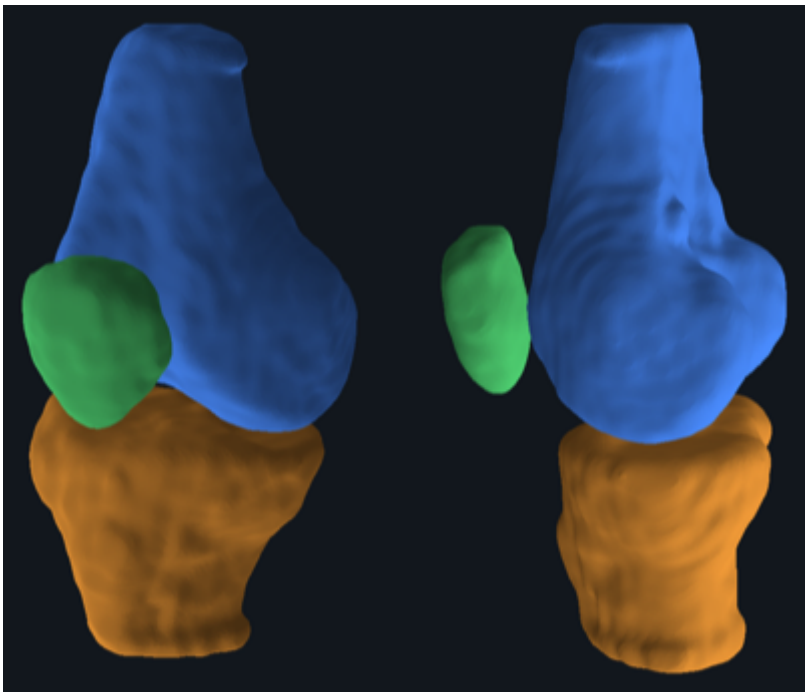
- レポートラベル校正：学習と推論を変えず、CoAtNetは0.916→0.926。
- 混合ラベルと長い学習：calA→v5、17→25 epochsへ変えるとEfficientNetV2-Mは0.946→0.954。両方を変えたため、ラベルだけの効果とはいえません。

検証上の注意：教師CNNが次のモデルの検証foldに含まれる検査を学習している可能性があり、その予測経由で検証情報が学習へ渡り得ます。手元スコアは開発用診断とし、未知検査への転移はPublicで確認しました（8節）。

4. 前処理と解剖に基づく切り出し

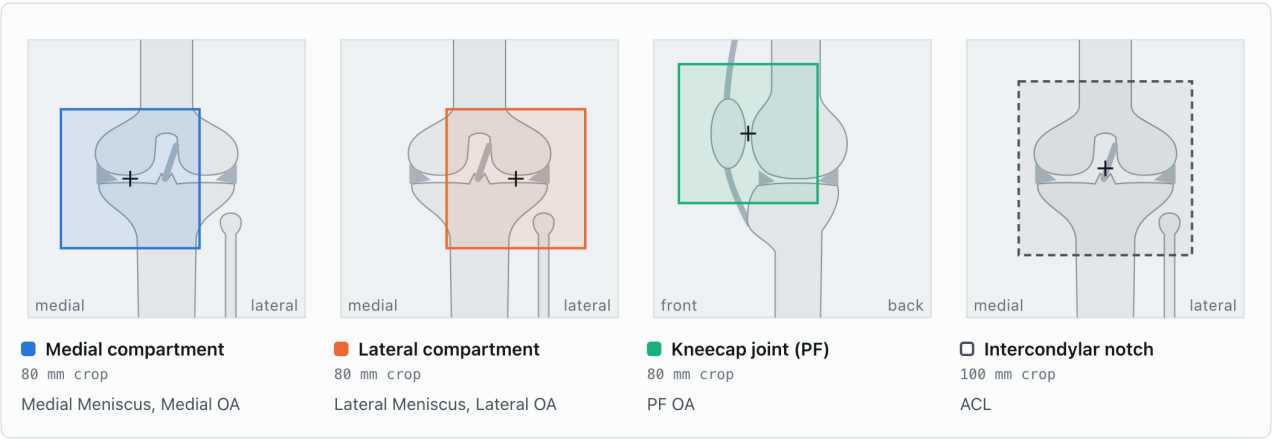
全体像：各シリーズの中央96%に等間隔な32断面を保存します。中央150 mmを384×384 px（約0.39 mm/px）へ変換。濃度はシリーズの1〜99パーセンタイル、脂肪抑制なら99.9までで調整します。左右が判定できれば右膝を左膝へ反転。テストの主モデルでは脂肪抑制なしの横断シリーズを除き、手元で小さな改善がありました。

骨の位置：エージェント支援で大腿骨・脛骨・膝蓋骨マスクを作った1,200シリーズで、TotalSegmentator-MRI初期化のnnU-Netを学習しました。左右は別の3D CNNで予測します。両モデルともテストで実行します。



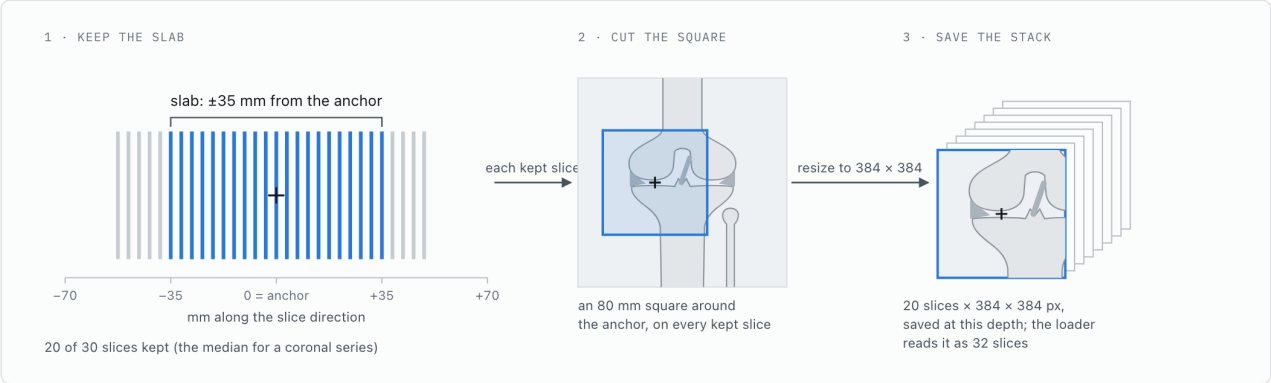
膝の骨領域分割、2方向。大腿骨は青、脛骨は橙、膝蓋骨は緑。

4領域の切り出し：全体像で解剖学的文脈を残し、局所像で同じ入力サイズ内の小領域に多くの画素を割り当てます。骨マスクから各領域の中心（anchor）を置き、周辺を正方形に切り出します。



4領域と選定理由となる所見。十字はanchorです。この対応は主モデルが予測に使えるビューを制限しません。

切り出し方法：anchor付近の断面を残し、各断面を正方形に切って384×384へ変換します。80 mmなら約0.21 mm/px、150 mm全体像は0.39 mm/px。同じ構造が各方向にほぼ2倍の画素を占めます。



冠状シリーズの内側切り出し例。anchorの±35 mm内の断面を残します。

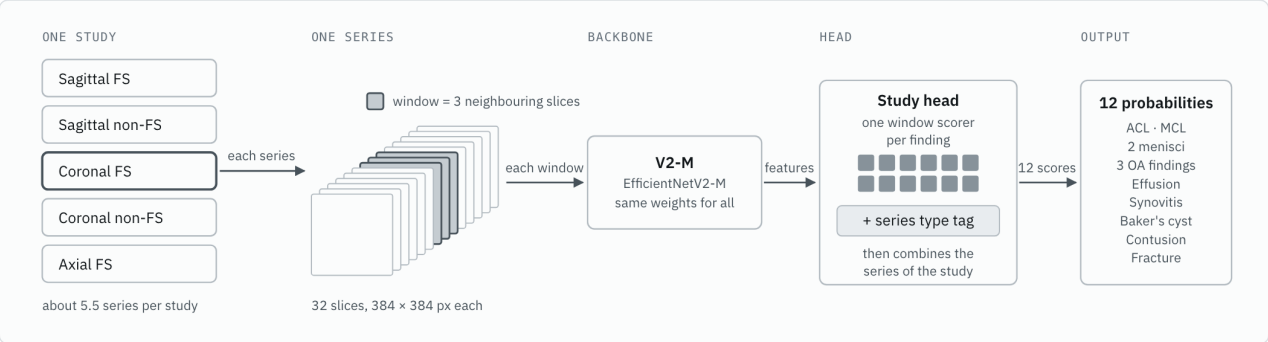


実例：矢状脂肪抑制の全体像（左）と100 mm関節切り出し（右）。

モデルへの入力：切り出しを加えると平均シリーズ数は約5.5→17.6です。各局所ボリュームは解剖領域と撮像条件のタグ付き追加シリーズです（5節）。全ビューから12所見を予測します。MCL、関節液、滑膜炎、ベーカー嚢腫、骨挫傷、骨折にはこの4領域中の専用切り出しはありませんが、全体像や関連情報を使えます。切り出し不能なら残るビューを使い、別学習の専門モデルが最終予測を補います（6節）。

5. 主モデル

主モデルは共通の2.5D CNNです。2D backboneが全体像と4つの骨基準の切り出しの3断面ウィンドウを読み、小さなheadで検査の12確率に集約します。



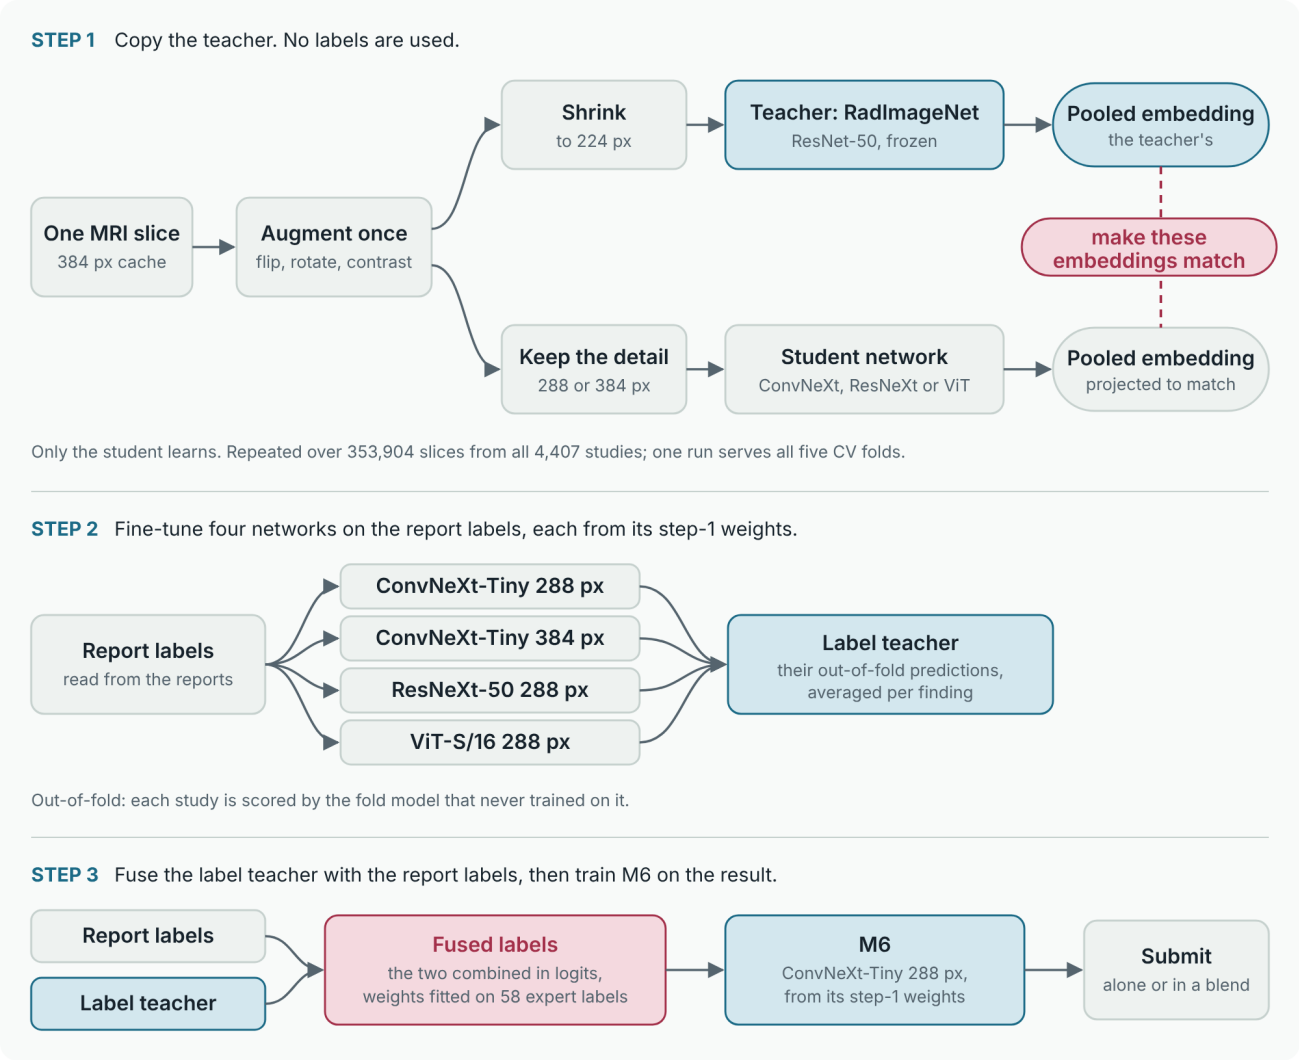
全体像を例にした検査の処理。4節の切り出しも追加シリーズとして同じ経路に入ります。

- ウィンドウ：全体像も局所像も隣接3断面を1つのRGB画像として読み、全シリーズでbackboneの重みを共有します。
- Head：所見ごとにシリーズ内のウィンドウ、次に検査内のシリーズに重みを付けます。学習可能なタグは60種類（全体像と4領域それぞれに12方向・コントラスト型）です。
- 事前学習：OAIの2,414膝で、専門医のMOAKS/WORMSから得た327の二値評価を予測させました。単体モデルの2試験でPublic +0.001でした。
- 学習：施設単位fold（8節）、25 epochs、AdamW、重みの指数移動平均。ランダム切り出し・回転・濃度変化を使いますが、左右が重要なため反転しません。
- 推論：1シリーズ15ウィンドウ、384 pxの中央336 px、5分割モデルの平均。

最終アンサンブルは、この構造または近い4モデルを使います。

モデル	Backbone	入力	分割数	ラベル（3節）	単独Private
M1	EfficientNetV2-M	全体像＋4切り出し	5	v5	0.957
M2	EfficientNetV2-M	全体像＋4切り出し	4	LLMのみとM1予測を半分ずつ	未提出
M3	ConvNeXt Base	全体像＋4切り出し	5	v5	0.958
M6	ConvNeXt-Tiny	1断面ずつ	5	教師を混合したラベル	0.947

M6のConvNeXt-Tiny系列は別構造です。288 pxで1断面ずつ読み（シリーズ16断面、9方向・コントラスト枠）、断面ごとに採点してから集約します。最初にラベルなしで固定RadImageNet ResNet-50を模倣し、12所見で微調整、さらに主モデル同様の混合教師で微調整します。



M6の3段階：固定RadImageNet教師を模倣→12所見を学習→混合教師で再学習。

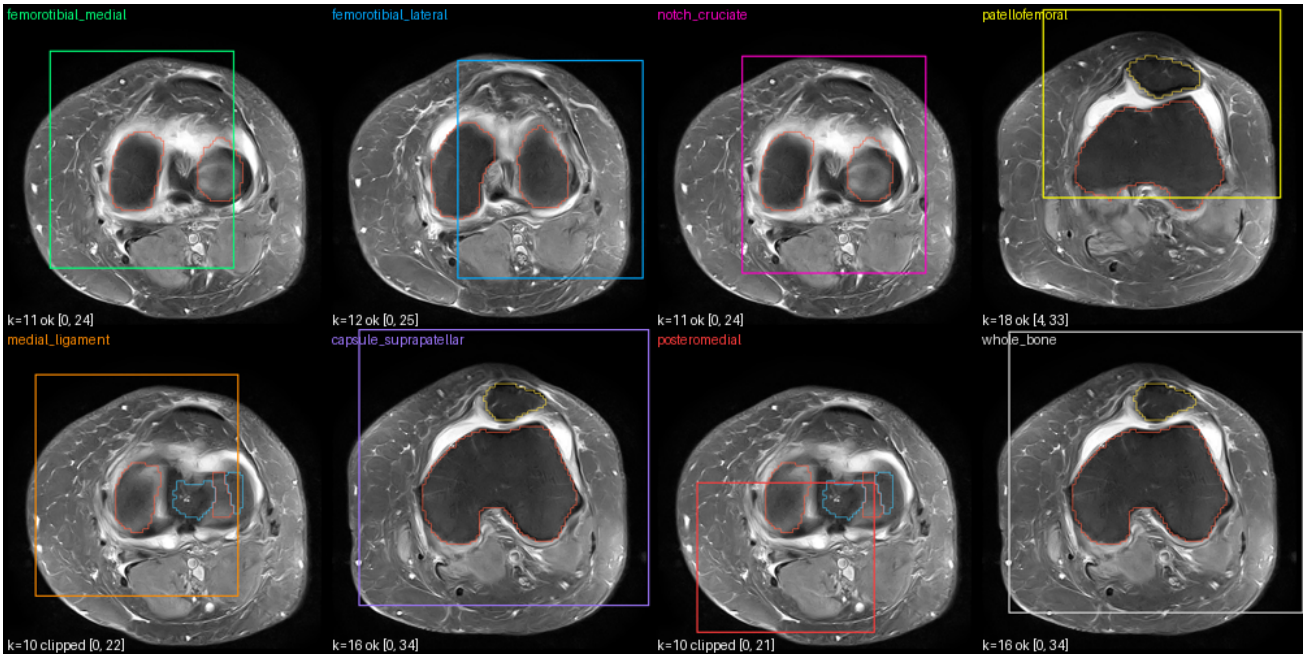
6. 領域専門モデルと対象を絞った追加

領域専門モデルM4は、主モデルを膝の1領域だけで追加6 epochs微調整したものです。7種類を作りました。各foldはConvNeXt V2 Tiny、ConvNeXt Small、EfficientNetV2-Mの同じfoldから開始します。12所見を予測しますが、混合には割り当てた所見だけ使います。



専門切り出し、80 mm・384 px：膝蓋大腿関節（横断脂肪抑制、矢状非脂肪抑制）と外側区画（冠状脂肪抑制・非脂肪抑制）。

専門モデルは2点を追加します。非脂肪抑制も読み、これはPF OAで最大の単独改善でした。また主モデルが切らない領域、120 mm骨（骨挫傷・骨折）、後内側（ベーカー嚢腫）、縦長の骨領域（関節液・滑膜炎）を読みます。



骨マスクから置いた領域ボックス。各1横断像（自前の解剖コード）。

各所見は1〜2専門モデルを使います。

所見	専門切り出し
ACL、外側半月板	外側区画
MCL、内側半月板	内側区画
内側OA	内側区画 + 顆間窩
外側OA	顆間窩
PF OA	膝蓋大腿関節
骨挫傷	骨 + 顆間窩
骨折	骨
関節液貯留、滑膜炎	縦長の骨切り出し
ベーカー嚢腫	骨 + 後内側

ACLに外側、外側OAに顆間窩という2経路は意外ですが、どちらも事前登録した保留foldの確認で勝ちました。

混合：各所見で主モデル順位0.5 + 専門モデル順位0.5。0.5は1foldずつ外す探索で選ばれました。

効果：弱いベースではPublic +0.003（0.963→0.966）、Private +0.002。領域モデルでは約0.001以下で、M1自身の切り出しが大半の信号を持っていたためです。

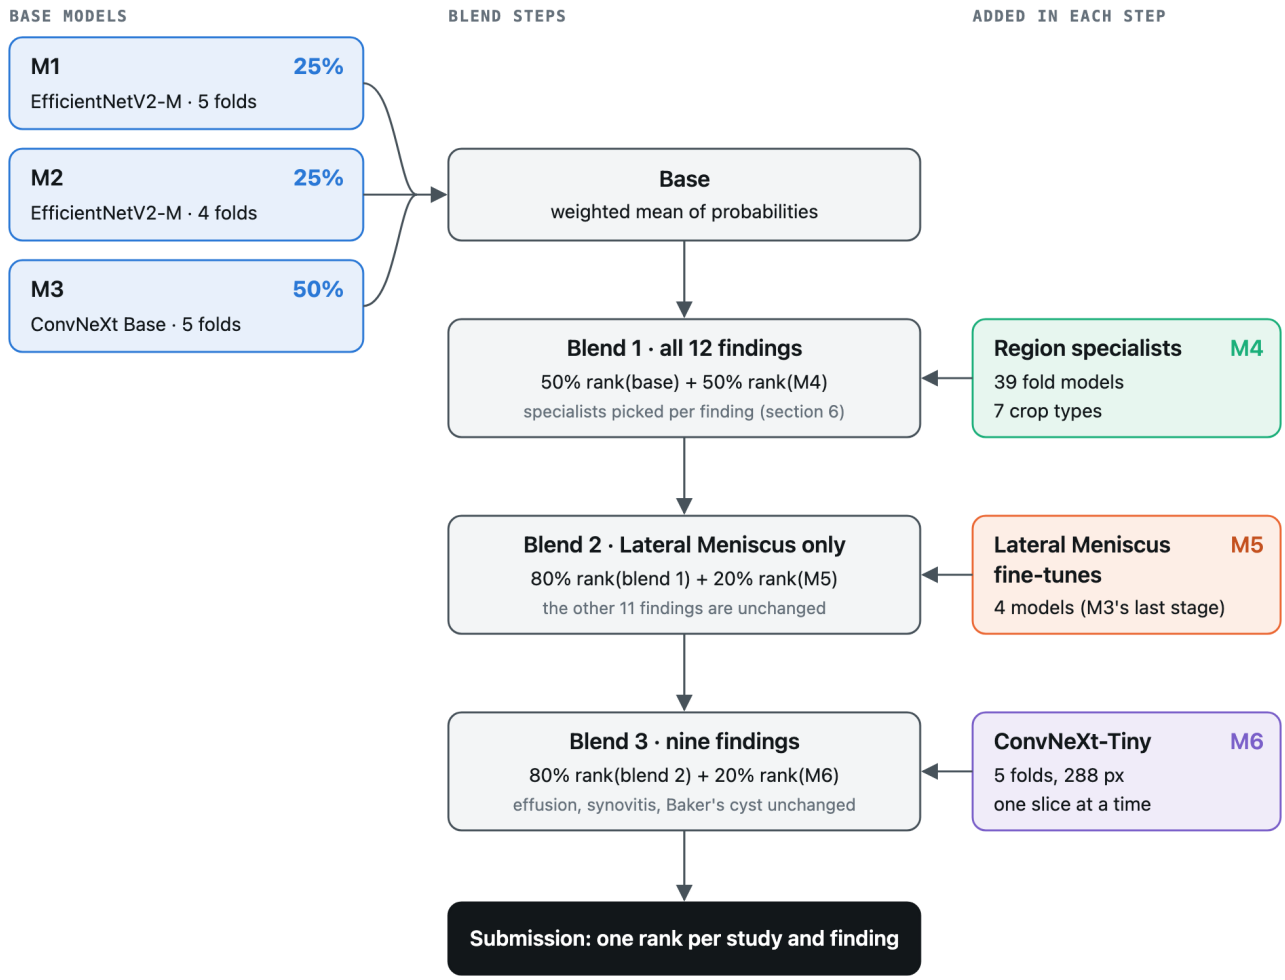
最終アンサンブルの2つの追加。

- 関節液・滑膜炎の縦長切り出し：旧範囲は引用断面の78–80%しか含まず、漏れはすべて上側だったため、横断スラブを上へ20 mm延長しました。

- 外側半月板微調整M5：弱い所見向けM3の短い微調整40試行で、通過したのは外側半月板だけでした。明示的レポート記述で最終段とheadを再学習し、順位20%で混ぜます。前段はM3の計算を再利用するため時間増は小さいです。

7. 最終アンサンブル

まず3モデルを平均し、次に順位混合を3回行います。各段階で所見ごとにテスト検査を順位化して混ぜます。



各段で順位を取り直すため、段階の重みを元の確率の単一平均にまとめることはできません。

- ベース：25% M1 + 25% M2 + 50% M3の確率平均。1カーネルで復号・切り出しを一度行い3モデルで共有します。
- 混合1、全12所見：ベース順位半分、所見に割り当てたM4順位半分（6節）。
- 混合2、外側半月板のみ：混合1の順位80%、4つのM5の順位20%。
- 混合3、9所見：混合2の順位80%、M6順位20%。関節液・滑膜炎・ベーカー嚢腫は除外。

AUCは所見内の順序だけを見るので、順位により確率校正の異なるモデルを共通尺度にできます。重みは単純ルールや手元fold確認で固定し、LBでは調整しませんでした。

Privateは0.958。最後の3追加（縦長骨切り出し、M5、M6）を除いた同じ構成は、2回の実行で0.958、0.957でした。

8. 検証と結果

検証方法。

- 施設fold：装置設定から病院が分かるため、モデルは膝でなく病院の有病率を学べます。20の病院に似たクラスタを作り、各クラスタを5分割の1つにまとめました。同施設が学習にもあるとレポートラベルAUCは0.019高くなりましたが、専門医58件では上がりませんでした。
- **ローカルスコア。** 2種類のローカル指標を追跡しましたが、どちらもラベル集合の選択には使えませんでした：
  - レポートラベルへのCV AUC：専門医でなく文章との一致を評価します（2節）。教師混合のモデルでは、教師が検証foldを学習していたため過大にもなります（3節）。B1/B2はここでは同じ0.873でも、B2はPublic +0.007、Private +0.008でした。
  - 専門医58件のAUC：定義は正しい一方、少数であり、教師・混合の選択にも使ったため、これも過大です。

改善の内訳：

モデル	前行からの変更	Public	Private
EfficientNetV2-M、校正レポートラベル（B1）	—	0.960	0.946
同モデル、混合教師v5、17→25 epochs（B2）	ラベルと学習期間	0.967	0.954
同モデル・教師 + 関節・区画・膝蓋大腿の切り出し（M1）	解剖に基づく切り出し	0.969	0.957
同じ切り出し・教師のConvNeXt Base（M3）	backbone	0.969	0.958
最終アンサンブル（M1–M6）	7節のアンサンブル	0.969	0.958

教師改善の段階が最大（Private +0.008）、解剖切り出しが次（+0.003）でした。別backbone、専門モデル、最後の混合は0.001以下で、最終は最良単体と並びます。

9. 制限時間内の推論

KaggleはT4×2、インターネットなしで9時間です。領域モデル単体はM1の2時間19分〜M3の2時間57分、全体は8時間18分でした。4つの工夫で時間と安全性を確保しました。

- 前処理共有：復号、骨分割、切り出しを一度行い、M1、M2、M3、M5で共有します。ベースモデルのGPU時間を約42%節約し、M5はM3前段も再利用します。
- 両GPU：T4ごとに1プロセス、検査を交互に割り当てます。
- 段階別時間予算：M6は90分、ベースは6.75時間まで、専門モデルは8.25時間で停止します。

10. コード・重み・謝辞

コードと重み：近日公開。

謝辞・参考文献

- コンペとデータを提供したRSNA、注釈者、Kaggle。

- 初期教師の基礎となるCC0の公開表：Pilkwangのreport_labels_v2、Stevenのllm_labels_v4_blend。（`report_labels_v2` / `llm_labels_v4_blend`）
- M6のレポート教師に使ったTejas NのClaude Opus 4.5公開ラベル表（NTejas-1/RSNA-Knee-Abnormality-Detection、MIT）。（NTejas-1/RSNA-Knee-Abnormality-Detection）
- 膝MRIとMOAKS/WORMS評価を事前学習に使ったOAI：

> 本稿で使用したデータ・研究ツールは、NIMH Data Archive（NDA）内のOAIが配布するアクセス管理付きデータから取得・解析しました。OAIはNIMHとNIAMSが作成した共同情報システムで、バイオマーカー発見、科学研究、OA治療薬開発を加速する世界的資源を提供します。データ識別子：NDA Collection 2343、DOI 10.15154/64dx-3822。（10.15154/64dx-3822）

- M6蒸留の教師ネットワークRadImageNet。（RadImageNet）
- 骨モデルの初期重みTotalSegmentator（MRI）、構造・学習のnnU-Net、骨マスク作成のnnInteractive。（TotalSegmentator / nnU-Net / nnInteractive）
- EfficientNetV2とConvNeXtのbackboneを提供するtimm。（timm）
- M6とM2の混合教師の着想：Furlanelloら、Born Again Neural Networks（ICML 2018）。（Born Again Neural Networks）

補足Q&A

Optimo（質問、3544046）：チームの皆さんとCompetition GrandmasterになったRashmi、おめでとうございます。Opus 5.5とgpt-6.1-solのラベル付けは、プロンプトと選択断面を渡すAPIですか。断面はどう選び、費用はどれほどでしたか。定額プランなら全症例をどう処理させましたか。プロンプトはどう書き、何版試し、どれが良いかはGT58だけで判断しましたか。

Rashmi B（回答、3544137）：ありがとうございます。APIはかなり高価でしょう。私のラベル付けはうまくいかず、@tomirolのものが良かったので、詳しく補足してくれると思います。`claude -p`や`codex exec`のheadlessモードを使えます。さらにエージェントに起動を任せると、ClaudeとCodexにまたがる何百ものサブエージェントを管理します。週枠を使い切りましたが、幸いリセットがありました。プロンプトもエージェントに書かせる方が、ラベル付け用の指示が詳細で良くなります。

matheus（回答、3544392）：質問をありがとうございます。基本的にはAPIではなくClaude CodeとCodexを直接使い、事前に分割した骨の形状に基づいて断面を選びました。多くのチームも何らかの形で似た方法を使ったようです。利用枠はあまり使わず、全体のラベル付けは数時間、high effortでCodexの週枠20–30%でした。