rsna-knee-abnormality-detection

7th place solution with no external training data（日本語訳）

Rank	7
Team	Barry
Author	BarryZhou
Topic ID	752217
Version	Japanese Translation

Source: https://www.kaggle.com/competitions/rsna-knee-abnormality-detection/discussion/752217
Retrieved with Kaggle CLI on 2026-10-27.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

単一モデルでPublic 1位0.969、Private 0.958。外部学習データなし

Private LB 0.957（7位）・Public LB 0.970・最良単体0.969 / 0.958・コンペデータだけで学習

まず、RSNA、データ提供施設、注釈した放射線科医、そして開催したKaggleへ心から感謝します。多言語レポートと専門医のGold評価を伴う多施設の膝MRIデータを作るには膨大な労力が必要です。そのおかげで難しく、やりがいのある課題になりました。Discussionでアイデアや発見を共有した皆さんにも感謝します。

背景

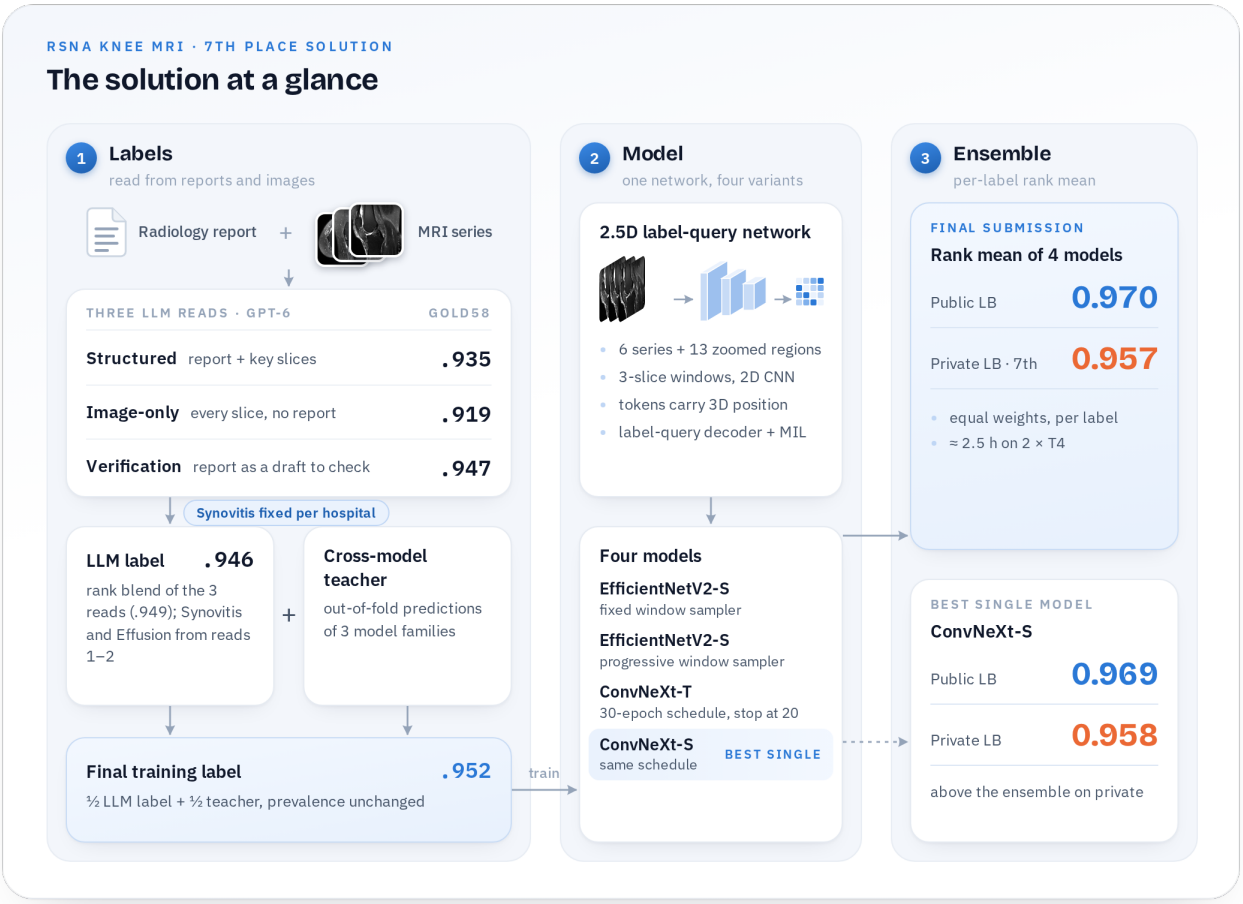
- 課題の背景：（https://www.kaggle.com/competitions/rsna-knee-abnormality-detection/overview）
- データの背景：（https://www.kaggle.com/competitions/rsna-knee-abnormality-detection/data）

手法の概要

テストにレポートがないため、モデルの力は学習レポートから読み取るラベルに左右されます。解法は3部分です。

1. ラベル：GPT-6 astraが3つのプロンプトでレポートとMRIを読みます。病院別の補正で滑膜炎を直し、異なるモデル群からなる教師と混ぜます。
2. モデル：1つの2.5D label-queryネットワークを4つのbackbone・学習設定で学習します。
3. アンサンブル：4モデルの所見別順位平均です。

改善の大半はラベルによるものでした。モデル自体はImageNet事前学習を出発点に、コンペ画像とコンペのレポートから得たラベルだけで学習しています。



提出の詳細

1. ラベル

4,349学習検査に8言語以上の自由文レポートがあり、画像ラベルはありません。別の58検査（gold58）には主催者ラベルがあり、ラベル品質の評価だけに使いました。

レポートは所見を省略したり曖昧に書いたりし、表現は病院に依存します。文章だけではgold58のmacro AUCが.89–.91にとどまったため、採用する読影はすべて画像も見ます。

3つのLLM読影：いずれもGPT-6 astraと、12所見の陽性条件を定義した共通の所見別手順を使い、JSONで回答します。

読影	入力	プロンプト	gold58 AUC
構造化読影	レポート + 主要断面（矢状9、冠状9、横断6）	手順に従い24属性を評価後、各ラベルの確率を回答	.935
画像のみ	全断面をそれぞれ384 px画像で提示、レポートなし	同じ手順で画像だけから判断	.919
検証読影	レポート + 画像	レポートは誤りを含み得る草稿とし、画像で各所見を確認	.947

読影の混合：所見の有病率を保って3読影の順位を混ぜます。gold58は.949で、単独の各読影を上回りました。

- 滑膜炎と関節液貯留は読影1–2の混合だけを使います。検証読影は両者を過剰に陽性とし、有病率を.24→.31、.37→.48へ増やすためです。
- gold58は少し下がって.947になります。これをLLM labelと呼びます。
- 検証プロンプトはこの58件で選んだので、.947は楽観的です。

病院別の滑膜炎補正：LLMはレポートにその単語があるとほぼ陽性にします（92%対6%）。用語の頻度は画像より病院に依存します。30検査以上ある施設で、装置モデルを病院の代用にしました。施設別に滑膜炎logitを一律シフトし、施設平均が画像の関節液貯留から予想される率になるよう解きます。関節液レベルはOOF画像モデルから得ます。施設内の検査順位は変わりません。

異なるモデルの教師：最終ラベルは½ × LLM label + ½ × teacherです。

- 教師の内容：類似した別版のLLMラベルで学習した、2種類のEfficientNetV2-SとConvNeXt-Tの3系列、各5分割のOOF予測です。各検査は、それを一度も見ていないモデルだけで評価します。
- 混合法：教師予測の順位をLLMラベルの値に対応付け、有病率を変えません。
- 効果：gold58のラベル評価は.947→.952。1系列の教師だけでPublic +.003 / Private +.002でした。3読影と3系列教師の最終設定にすると、ConvNeXt-Tでさらに+.002 / +.004でした（図3）。

公開ラベル：この節の全バージョンをRSNA Knee LLM Labelsに段階別ファイルで公開しています。学習検査ごとに1行、12所見の[0,1]のソフトラベルがあり、レポート本文は含みません。（RSNA Knee LLM Labels）

ファイル	内容	gold58 AUC
1_read_structured.csv	構造化読影：12確率 + 24属性の評価	.935
2_read_image_only.csv	画像のみの読影	.919
3_read_verification.csv	検証読影（gold58でプロンプト選択）	.947
4_read_structured_synovitis_fixed.csv	混合前に滑膜炎を補正した構造化読影	.937
5_blend_reads_1_2.csv	ファイル4 + 画像のみ、60 : 40	.943
6_blend_reads_1_2_3.csv	ファイル5 + 検証読影、1 : 1順位平均	.949
7_llm_label.csv	LLM label：ファイル6の滑膜炎・関節液貯留をファイル5で置換	.947
7a / 7b / 7c_llm_label_variant.csv	教師系列ごとに別の読影重みを使う類似LLMラベル	.946 / .947 / .946
8_final_label.csv	最終ラベル：½ LLM label + ½ teacher。最終4モデルの教師	.952
9_final_label_with_gold58_studies.csv	学習検査とGold58へファイル8の手法を適用。主催者ラベルは使わず、最終提出2の複製モデルに使用	–

2. モデル



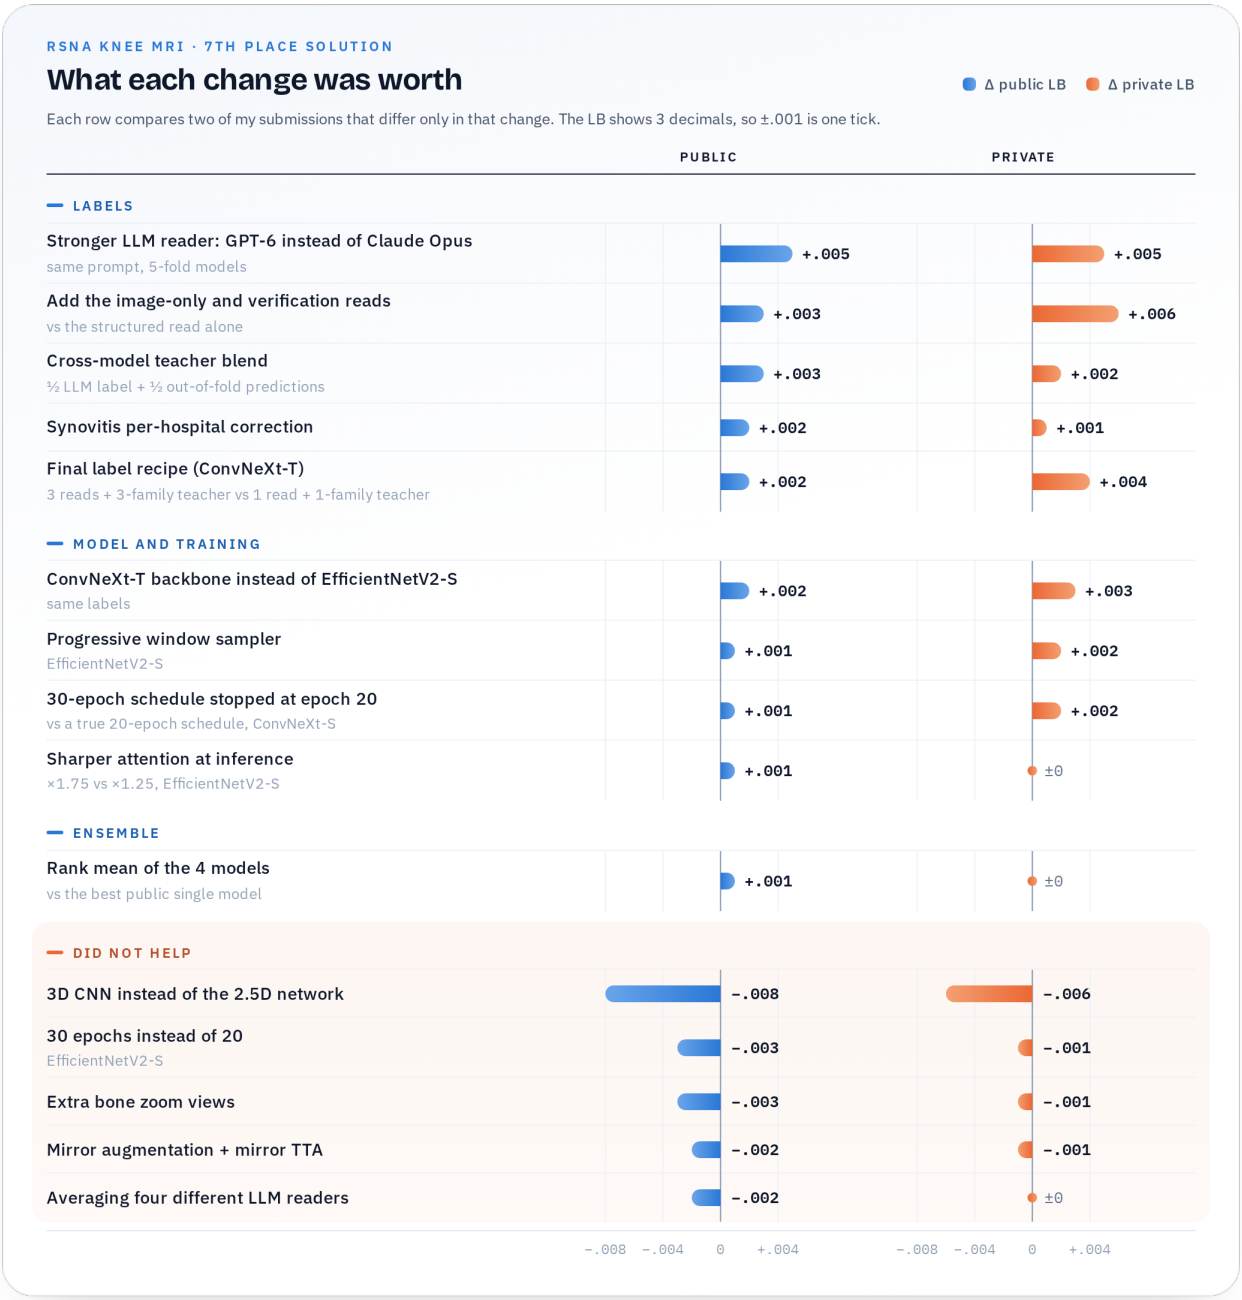
- **入力。**
  - 最大6シリーズ（矢状・冠状・横断、それぞれ脂肪抑制あり／なし）。
  - 各シリーズを140 mm、384 pxへ切り出し、右膝を反転。最大48断面を保持。
  - 隣接3断面を1ウィンドウとします。
  - 13の固定拡大領域（半月板、膝蓋大腿関節、各区画）を追加シリーズとして入力。
- トークン：共有2D CNNで各ウィンドウを12×12トークンに変換します。シリーズと、共通の膝座標系のmm単位3D位置を持たせ、全方向・切り出しを対応付けます。
- Head：ラベルごと2クエリが全ウィンドウの全トークンを参照するlabel-query decoderと、gated attention-MIL headを平均します。
- **学習。**
  - 陽性重み付きソフトラベルBCE（PF OA ×2）、AdamW、cosineスケジュール。
  - 最終5 epochsの重み平均（SWA）。
  - アフィン変換、MRI濃度の拡張、シリーズdropout。
  - 各モデルは全学習データを単一GPUで約6–10時間学習します。
- **推論。**
  - 全シリーズ・拡大領域の各断面にウィンドウを配置します。
  - 入力集合が大きくなるためattentionを鋭くし、EfficientNetV2-Sでは×1.75、ConvNeXtでは×1.25。
  - T4×2でfp16、1モデル約0.6時間。

3. 4モデルとアンサンブル

モデル	設定	Public	Private
EfficientNetV2-S	シリーズごとのウィンドウ数固定、20 epochs	.968	.954
EfficientNetV2-S	段階的ウィンドウサンプリング	.969	.954
ConvNeXt-T	30-epochスケジュールをepoch 20で停止	.969	.957
ConvNeXt-S	ConvNeXt-Tと同じ	.969	.958
4モデルの順位平均	最終提出1	.970	.957
8モデルの順位平均	4モデル + 各複製モデル、最終提出2	.970	.957

- アンサンブル：4モデルの所見別パーセンタイル順位を等重み平均します。カーネル全体は約2.5時間で、9時間制限に十分収まります。
- 最強単体：ConvNeXt-SだけでPublic 1位（.969）、Private .958で、アンサンブルを少し上回りました。
- 第2候補：各モデルのseed違いを追加し、学習データとGold58（主催者ではなく独自ラベル）で学習した計8モデルです。4モデルと同じスコアでした。

4. 効いたこと、効かなかったこと



ラベル変更が最大かつ最も一貫した改善を生み、Privateでも維持されました。

効果がなかったその他の試み：

- 複数スケールのトークン
- スライス軸のmixer
- 大型decoder
- 複数タスクの損失バランス調整
- 強いデータ拡張
- 大きな切り出し領域

検証：ラベル品質はGold58で判断しました。上図の各変更は、その変更だけが異なる2提出でLBを確認しました。

結論

私の実験では、モデル変更よりラベル変更の方がLBを動かしました（図3）。

- 画像読影は文章読影を上回りました。画像とレポートを並べ、写すのではなくレポートを検証させると、すべての文章のみの読影を上回りました。
- ラベルノイズには構造がありました。病院ごとの滑膜炎の記述習慣などの系統的なパターンの補正は、試した損失変更より有効でした。
- アンサンブルの多様性は不足していました。4モデルは教師・入力・headが同じで、backboneと学習設定だけが異なります。順位平均は最良単体に対しPublic +.001、Privateの改善なしで、おそらく似た誤りをしています。異なる構造・入力・教師を使う、より多様なアンサンブルが次の明確な方向です。

謝辞

コンペを通じた公開議論とNotebook共有について、Kaggleコミュニティに感謝します。

出典

- 上記の全バージョンのラベル：（https://www.kaggle.com/datasets/songqizhou/rsna-knee-llm-labels）
- 推論Notebook：（https://www.kaggle.com/code/songqizhou/rsna-knee-7th-place-inference）
- 学習コード：近日公開。
- レポートからのラベル抽出にLLM APIを許可する主催者回答：（https://www.kaggle.com/competitions/rsna-knee-abnormality-detection/discussion/733965）
- Tan & Le, EfficientNetV2: Smaller Models and Faster Training , ICML 2021. https://arxiv.org/abs/2104.00298（https://arxiv.org/abs/2104.00298）
- Liu et al., A ConvNet for the 2020s , CVPR 2022. https://arxiv.org/abs/2201.03545 （https://arxiv.org/abs/2201.03545）
- Liu et al., Query2Label: A Simple Transformer Way to Multi-Label Classification , 2021. https://arxiv.org/abs/2107.10834 （https://arxiv.org/abs/2107.10834）
- Ridnik et al., ML-Decoder: Scalable and Versatile Classification Head , WACV 2023. https://arxiv.org/abs/2111.12933 （https://arxiv.org/abs/2111.12933）
- Ilse, Tomczak & Welling, Attention-based Deep Multiple Instance Learning , ICML 2018. https://arxiv.org/abs/1802.04712 （https://arxiv.org/abs/1802.04712）
- Izmailov et al., Averaging Weights Leads to Wider Optima and Better Generalization , UAI 2018. https://arxiv.org/abs/1803.05407 （https://arxiv.org/abs/1803.05407）
- Wightman, PyTorch Image Models (timm) . https://github.com/huggingface/pytorch-image-models（https://github.com/huggingface/pytorch-image-models）

補足Q&A

Optimo（質問、3543854）：おめでとうございます。洗練された解法です。Astraの蒸留が鍵だったようですね。13の固定領域はどう定義したのでしょうか。

BarryZhou（回答、3543992）: ありがとうございます。ラベルが大部分を担いました。切り出しは位置推定器なしの全検査共通の固定ボックスです。各断面を固定方向で140 mm（384 px）に中心切り出しし、右膝を反転すると、画像比率で指定した箱がほぼ同じ解剖部位に重なります。13領域は以下です。

- 一般（1.7倍）：横断FSの前方（膝蓋大腿関節）、矢状FSの前方（膝蓋骨、膝蓋上陥凹、Hoffa脂肪体）、冠状FSの内側・外側半分。
- 半月板（2.2倍）：矢状FSの脛骨大腿関節の前半・後半、矢状non-FSの後半、冠状FSの内側・外側関節線。
- 膝蓋大腿（約2倍）：横断FS / non-FSと矢状FS / non-FSの膝蓋骨・滑車。

GPUで親シリーズのウィンドウから切り出して384 pxへ拡大します。独自のビュー埋め込みと実際の3D位置を付け、同じ入力集合へ追加するため、別headは不要です。学習ではランダムなアフィンずれを加え、構造の正確な中心である必要をなくします。ランドマーク推定器で中心を合わせても固定ボックスを上回りませんでした。正確な座標は推論Notebookの `ROIS` にあります。

Adel Zebiche（質問、3544123）: 詳細な投稿をありがとうございます。MRIとレポートが鍵だったようですが、約4,400検査・各約277画像のラベル付けのAPI費用はどれほどでしょうか。節約のため断面を間引きましたか。

BarryZhou（回答、3544386）: 料金を当てはめられるよう、トークンで示します。検査ごとの入出力合計は、構造化読影（レポート+24主要断面）が約4.7k、画像のみと検証読影（全断面）は各約20kです。全4,349検査・3読影で入力約193M、出力約5Mでした。Gold58のプロンプト試験は含みません。

構造化読影だけは、256 pxの矢状9・冠状9・横断6断面を3画像に並べて間引きます。他の2読影も約277画像全部は送りません。各方向1シリーズ（可能なら脂肪抑制）を使い、140 mm中心切り出しの384 px画像として全断面を個別に送り、平均約92フレームです。48断面を超えるシリーズ（4%）は等間隔で48枚にします。1フレーム約190入力トークンなので、費用の大半は画像です。