rsna-knee-abnormality-detection

8th Place Solution（日本語訳）

Rank	8
Team	joinT fusion
Author	Tomoki Hirose
Topic ID	752219
Version	Japanese Translation

Source: https://www.kaggle.com/competitions/rsna-knee-abnormality-detection/discussion/752219
Retrieved with Kaggle CLI on 2026-10-27.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

開催したRSNAとKaggle、チームメイト@nantohockと@wadakokiに感謝します。ソフトラベルを改善しつつ、撮像方向・条件をまたぐ全体特徴と局所特徴を組み合わせました。追加MRIデータは使っていません。
（@nantohock / @wadakoki）

1. DICOMキャッシュとデータ拡張

隣接断面の関係を保つため、撮像群ごとの保存断面数を増やしました。液体強調／非強調を優先する矢状・冠状の4群と横断1群、計5群です。

項目	設定
断面サンプリング	5群から32/32/32/32/40枚、最大168枚
切り出しサイズ	140×140 mm、110×110 mmも使用
画像サイズ	384×384画素
入力	同一シリーズの中心断面と直近の隣接断面を3チャネルに重ねる
断面間隔	上限内なら元の間隔を保持。通常3–5 mm

上限を超えるシリーズは等間隔で間引きました。終盤には候補30枚超のシリーズで抽出位置をずらした副シリーズも作りました。96枚から32枚なら、1,4,7,…,94、2,5,8,…,95、3,6,9,…,96の3版です。学習では通常の等間隔抽出も含め、ランダムに選びました。

キャッシュは約110 GB。64断面ではPublic 0.930、最大168断面では0.937でした。

1.1 データ拡張

拡張	設定	確率と範囲
明るさ	倍率0.9–1.1	毎回、検査全体で共通
鏡映	冠状・横断は左右反転、矢状は3チャネル順序を反転	検査ごと50%
回転・拡大縮小・移動	±15°、倍率0.9–1.1、画像幅の±5%移動	組み合わせ変換を撮像群ごと50%
低解像度化	各辺0.5–1.0倍に縮小し元サイズへ戻す	撮像群ごと25%
ガウスぼかし	σ=0.5–1.0画素	撮像群ごと20%
ガウスノイズ	0–1の画素値に標準偏差0–0.03	撮像群ごと10%
第1段階のシリーズ選択	各撮像群から1シリーズ	検査を抽出するたびランダム
第1段階の副シリーズ選択	通常抽出または位置をずらした版	候補から一様に選択

鏡映は反対側の膝として提示します。矢状像の左右は断面軸方向なので、画像内を反転せずチャネル順を反転しました。内側・外側ラベルは変えません。

2. ラベル改善

文章を正確に抽出しても、画像ベースの評価と一致する教師になるとは限りません。そのため画像評価とモデルのOOF予測を取り込みました。

2.1 レポートラベル

2種類のレポート教師を用意しました。

最初のLは3つのLLMラベルの平均です。

- 公開ラベル：dreaddevelopment/rsna-knee-labels。骨折と骨挫傷だけ、GPT-6 Astraのレポート再評価に置き換えました。（dreaddevelopment/rsna-knee-labels）
- Qwen/Gemma：Qwen3.8-27BとGemma 4 26B-A4Bが同じプロンプトで文章だけを読み、重症度・量・範囲を採点しました。記載なしの既定値は公開ラベルから推定し、尺度を合わせました。

3系列の順位は似ており、所見別Spearman相関の平均はQwen–Gemma 0.898、Qwen–公開0.863、Gemma–公開0.859でした。等重み平均をLとしました。

第2のAでは、Astraが文章を陽性・陰性・根拠不足などに分けソフトラベルを付けました。記載なしは定数ではなく、有病率、陽性・陰性の省略率、レポート形式、他所見から確率を推定しました。

2.2 画像ラベル

最初にAstraへDICOM画像だけを渡し、レポートと既存ラベルを伏せました。12所見が基準を満たす確信度を0〜1で回答させ、0.5以上は陽性として根拠断面とボックスを要求しました。その後レポートを確認し、不一致は画像を再確認して画像根拠を優先しました。

ラベル変更	Public LB
公開の骨折・骨挫傷をAstraレポート再評価で置換	0.937 → 0.943
Astra文章ラベルと一部の画像ラベルを追加	0.944 → 0.949
画像ラベルと校正済みモデル予測の寄与を増加	0.950 → 0.954

主要更新時点の比較で、一部は学習変更も含みます。Public 0.949時点で画像ラベルは約20%でした。最終的に4,407検査中4,406検査を画像評価しました。

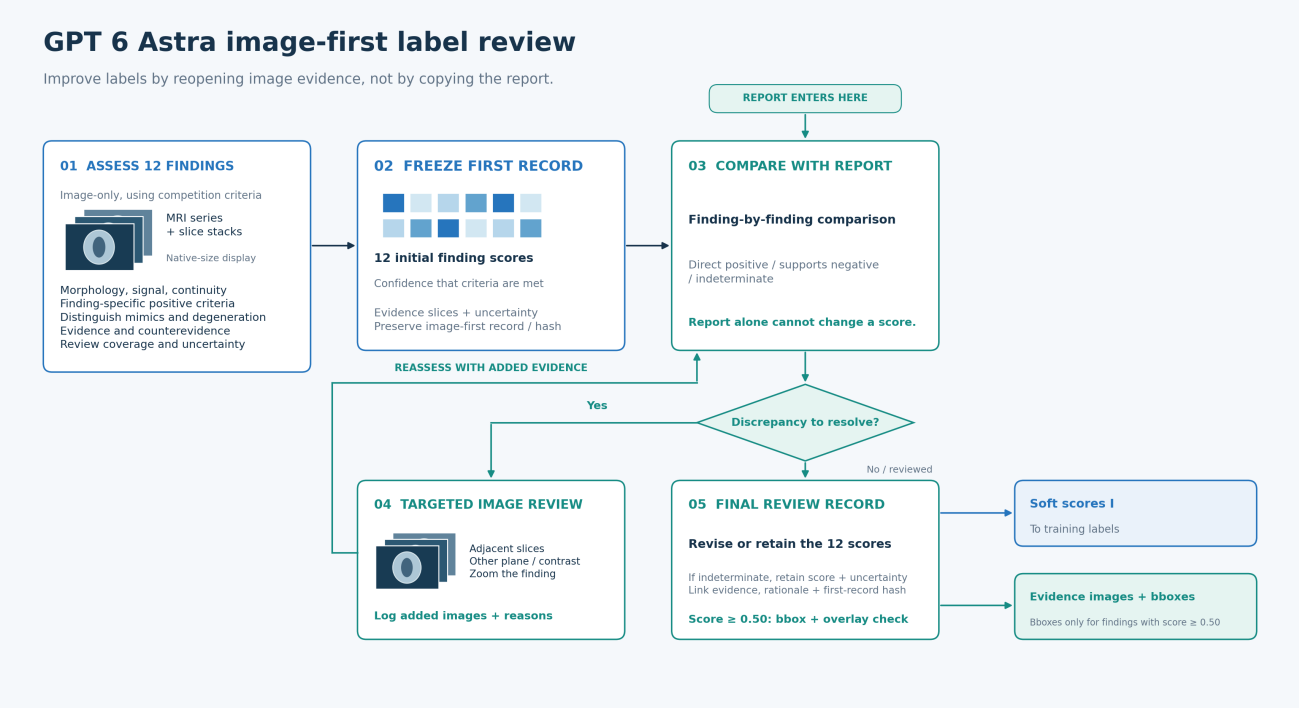


図1：Astraの画像先行ラベル付け。画像のみの判定後に文章と比較し、不一致を再読影で解決します。

2.3 文章と画像の混合

画像ラベルの範囲を広げ、所見別の比率を調整しました。最終教師は3情報源です。

記号	情報源
I	Astra画像評価
L	公開（骨折・骨挫傷はAstra再評価）、Qwen、Gemmaの等重み平均
A	Astra文章評価。記載なしは有病率などから推定

所見ごとの画像重みwを設定し、残りをLとAに等分しました。画像がない場合はLとAの等重み平均です。

$$ S = wI + \frac{1-w}{2}\,(L + A). $$

所見	画像重みw
骨折 / 滑膜炎 / ベーカー嚢腫	5/6
関節液貯留 / 骨挫傷	2/3
内側OA	1/2
ACL / 内側半月板 / 外側半月板	1/3
PF OA / 外側OA / MCL	1/6

全所見共通の画像重みを走査し、各所見のGold AUC最大点のwを採用しました。さらに各重み±1/6を調べても、Gold 0.9346対0.9348、Publicともに0.954で変更を正当化する差はなく、初期重みを維持しました。

両膝のシリーズを含む検査が8件ありました。検査ラベルでは反対側の所見を誤って付けるため、シリーズ中心の左右座標で7検査を14膝に分割しました。残り1件は反対膝が矢状像しかなく画像評価できず除外。各膝で画像と文章を所見別重みで混ぜました。提出推論は検査単位のままです。

2.4 擬似ラベル

Sを教師に、装置特性で群分けした4foldのOOFを作りました。陽性重みと順位損失によりOOF平均は所見別0.37–0.46となり、教師平均0.10–0.40より上振れしました。混合前にSの尺度へ校正し、各foldについて他3foldで所見別isotonic回帰を当てはめました。学習ラベルyは次式です。

$$ y = 0.6S + 0.4\,\mathrm{OOF}_{\mathrm{cal}}. $$

Sだけ／校正OOFだけで別モデルを学習し、Gold予測を混ぜると、OOF学習モデルの最良重みは0.4でした。この比率を教師に適用して再学習すると、Gold AUCはS単独0.9309から0.9346へ上がりました。

第2回自己蒸留では、1回目のyで教師を再学習し、そのOOFを校正して0.4で混ぜました。元情報Sの比率が0.6→0.36と減り続けるのを避けるため、前回のyでなく毎回Sと混ぜました。

4 seeds平均の学生Gold AUCは第1回0.9414→第2回0.9427で、4 seeds中3つが改善しました。提出直前に完成した、4.4節の「更新版」ラベルです。

Gold評価の実験では、擬似ラベル経由の漏洩を防ぐためGoldを教師学習とOOF生成の両方から除きました。

3. 損失関数

陽性重み付きBCEとLSE順位損失を、それぞれ係数1で足しました。順位損失は高いソフトラベルの検査の予測を高め、大きな順位逆転を指数的に強調します。

$$ \ell_i^{LSE}=\log\left(1+\frac{1}{M_i}\sum_{j\in J_i} q_{ij}\exp\left(\frac{s_j-s_i}{T}\right)\right), \qquad q_{ij}=\max(y_i-y_j,0),\quad T=1. $$

yはソフトラベル、sはlogit、J_iは検査iよりラベルが低い比較検査の集合、M_iはその個数です。現バッチと直近バッチのlogitキューから比較を作り、相手がある検査（M_i > 0）について所見ごとに平均しました。

最初はRankNetで順位損失の効果を試しました。

損失	Gold AUC	Public LB
BCEのみ	0.9261	0.943
BCE + RankNet順位損失	0.9300	0.944

RankNetとLSEの差は小さいものの、Publicがわずかに高いLSEを採用しました。

4. モデルとアンサンブル

中心断面と直近隣接断面を重ねてウィンドウと呼びます。CoAtNet-2（timmのcoatnet_rmlp_2_rw_384、ImageNet-12k事前学習）とCAFormer-S36を使いました。

各特徴マップからGAPで全体特徴、空間attention pooling（SAP）で12所見の局所特徴を得ました。SAP重みは所見と撮像条件に依存します。特徴の結合とウィンドウ集約を変えて比較しました。

4.1 シリーズ内GRUと2段階attention

全体特徴へシリーズ内の相対深度、隣接ウィンドウとの深度差、撮像条件の埋め込みを加え、深度順に双方向GRUへ通します。局所特徴はGRUを通しません。

シリーズ内で全体・局所を別々に所見別attention集約し、連結します。異なる断面が全体・局所判定に寄与できます。撮像条件を条件とする第2の所見別attentionでシリーズ間を集約し12所見を予測します。学習時は撮像方向別の補助headも使いました。

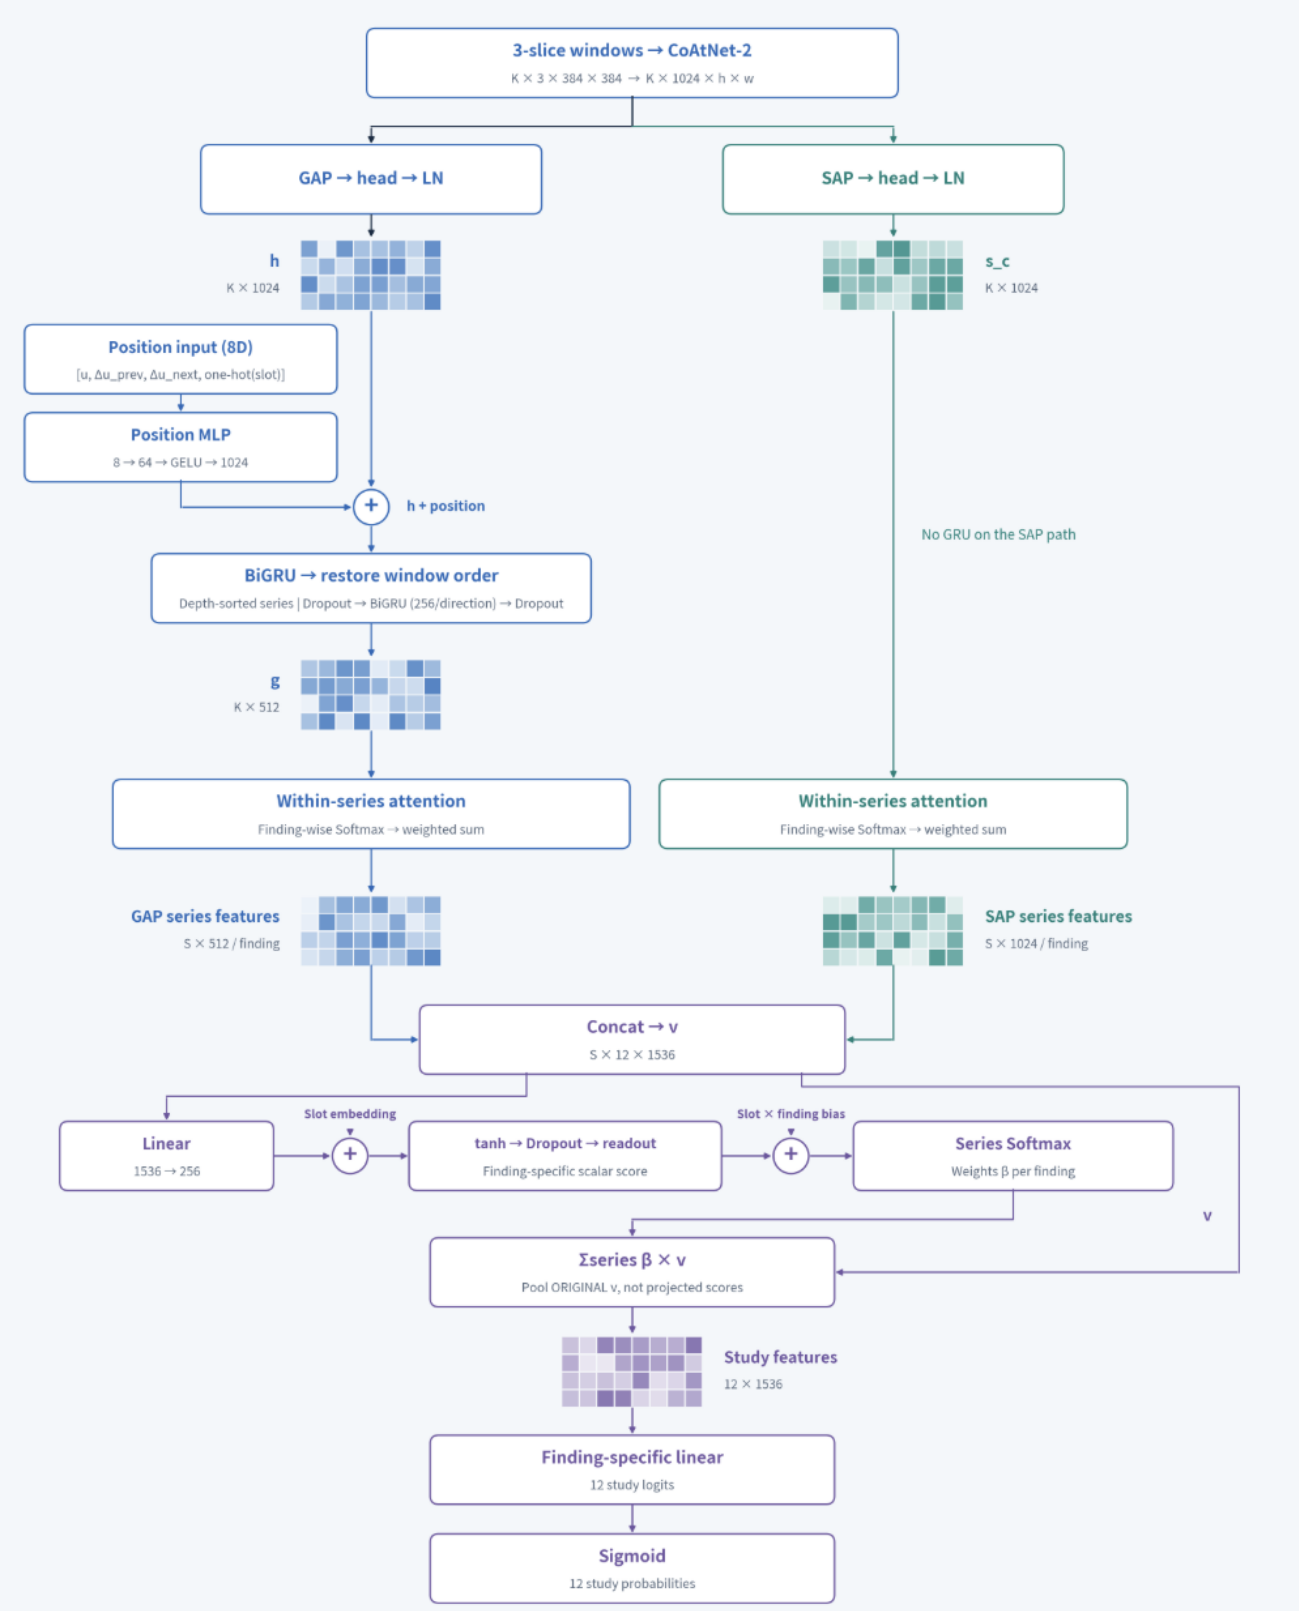


図2：シリーズ内GRUと2段階attention。左が全体GAP、右が局所SAP。

4.2 LSEと文脈attention head

全体ウィンドウ特徴のself-attentionから断面間の文脈を作り、それと各ウィンドウの全体・局所特徴で残差補正します。これをcontext attention + ctxと呼びます。+ slot版は撮像群内・群間の所見別attention文脈も加えます。

補正特徴からウィンドウごとの12 logitsを出し、所見別log-sum-exp（LSE）で検査予測へ集約します。

$$ z_c=\tau\log\left(\frac{1}{K}\sum_{k=1}^{K}\exp(z_{kc}/\tau)\right),\qquad\tau=1. $$

Kは有効ウィンドウ数、z_kcはウィンドウkの所見cのlogitです。attention-MILが予測前の特徴を集めるのに対し、このheadは断面logitを集めます。

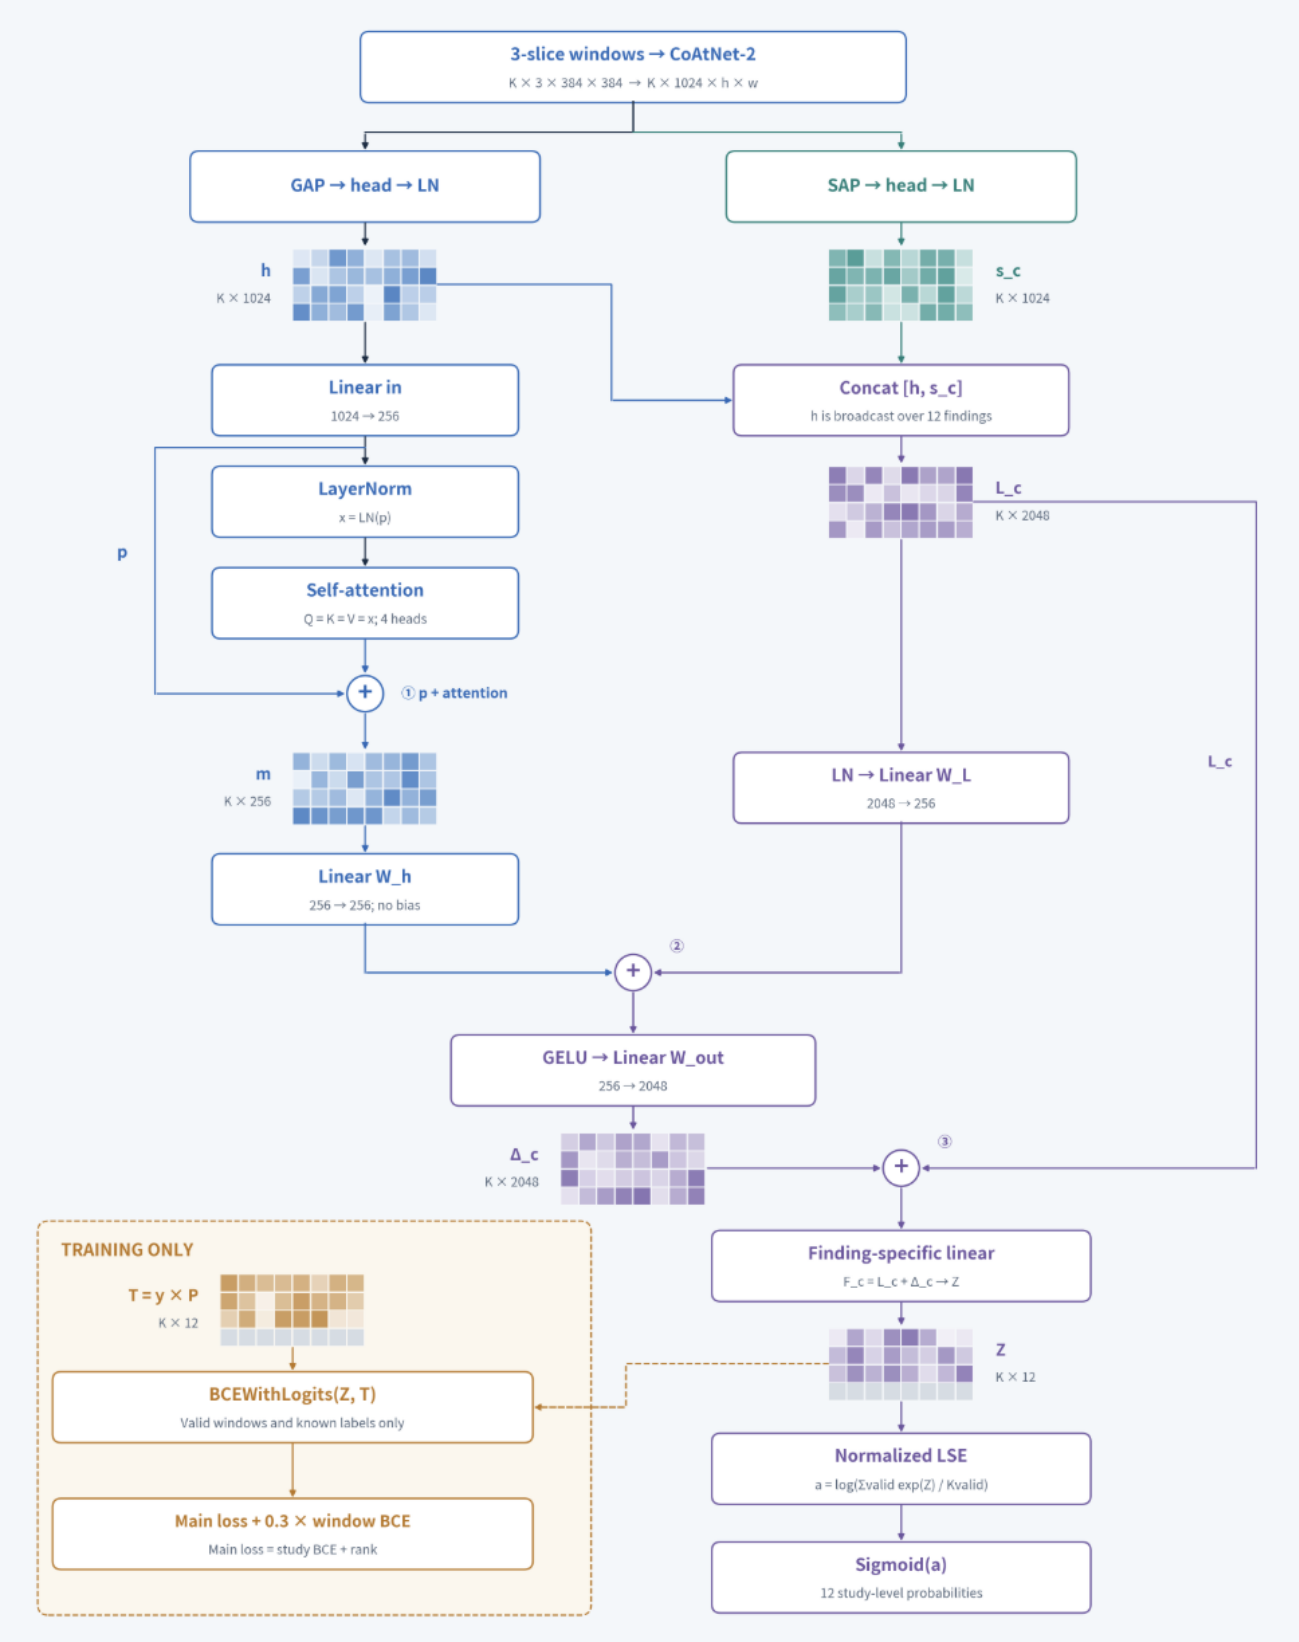


図3：LSEと文脈attention head。橙の枠は学習時のみのウィンドウ補助損失。

位置依存のウィンドウ教師に深度事前分布も使いました。教師OOFの全体分岐attention重みを、撮像条件・所見別に相対深度で集計し、ガウス混合で平滑化しました。

ピーク1に正規化し、「検査ソフトラベル × その位置の事前重み」に対するBCEを計算しました。病変位置の正解ではなく教師attentionのパターンです。

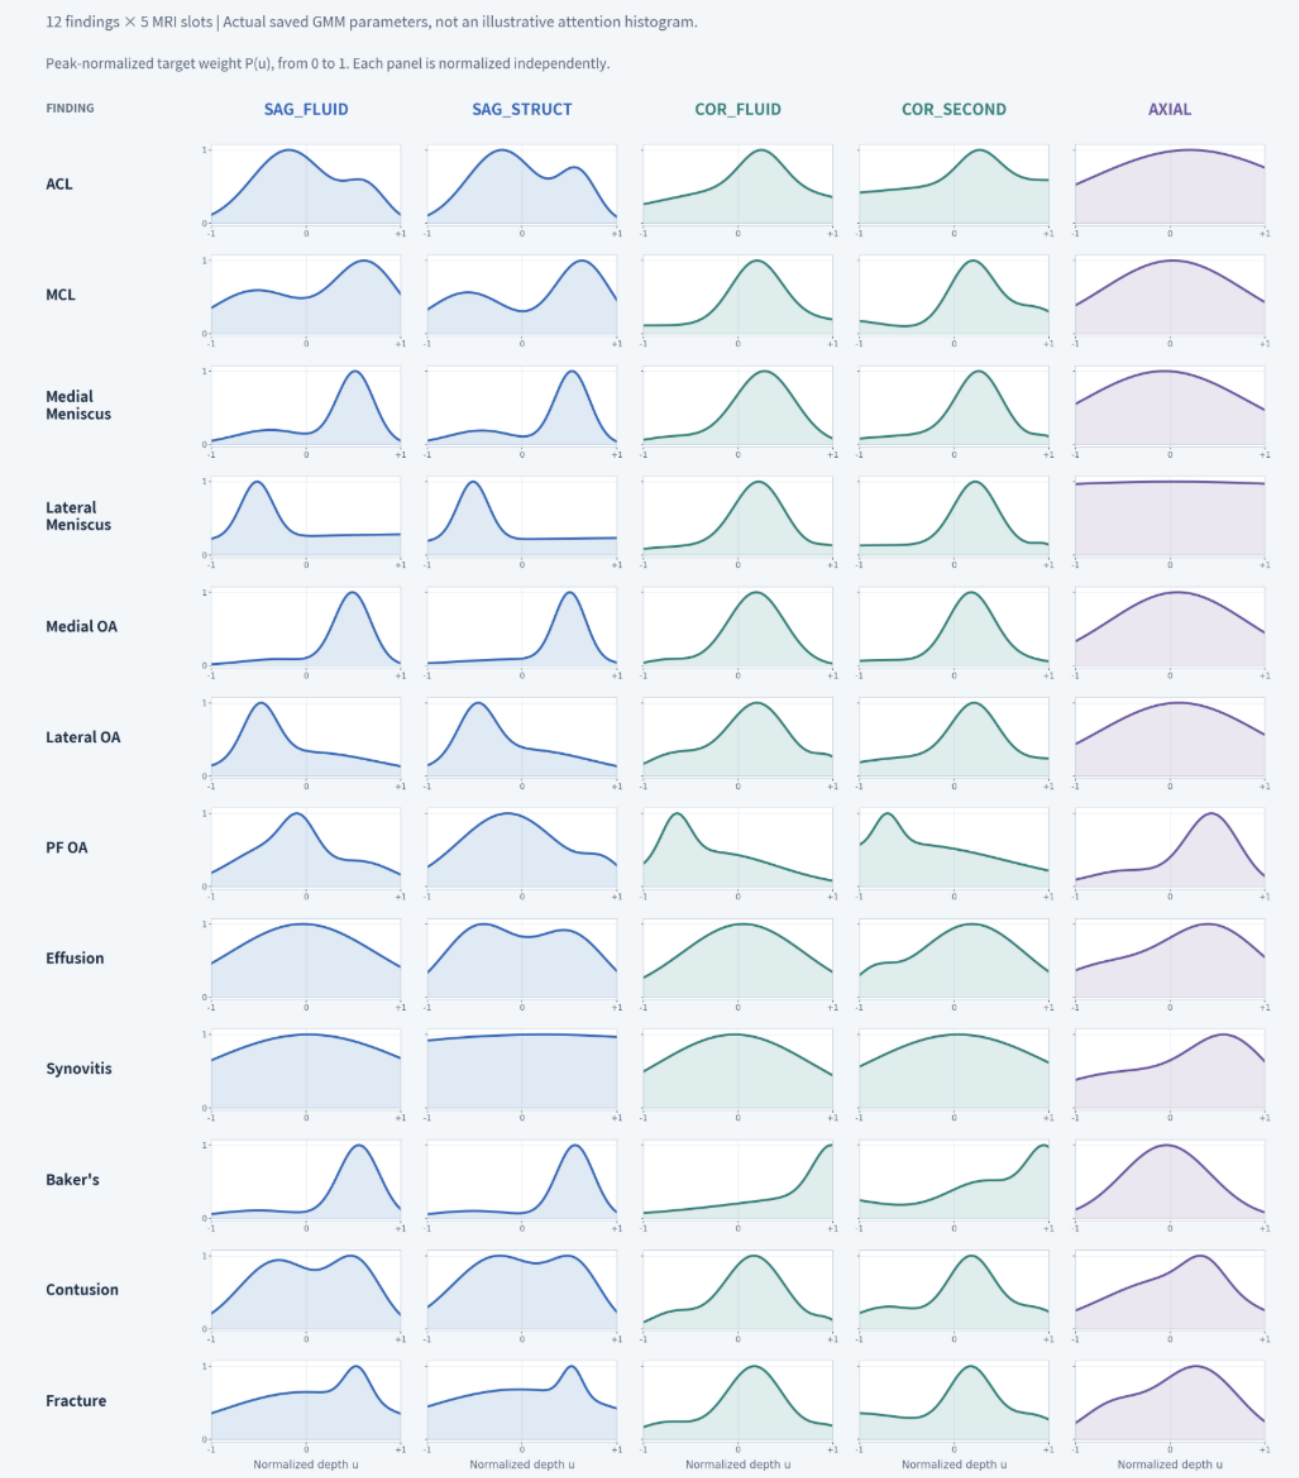


図4：所見・撮像条件別（列）の深度事前分布。横軸はシリーズ内相対深度、縦軸はピーク1の教師重み。

4.3 全候補集合での微調整（通常学習後）

第1段階は撮像群ごと1シリーズを選び、メモリ制約で24ウィンドウを学習。第2段階はbackboneと空間attentionを固定し、後段を微調整しました。

固定でメモリが減り、全キャッシュシリーズ・副シリーズの候補をまとめたunion bagを使えます。シリーズ数と抽出版をランダムに選び、32–352ウィンドウを抽出しました。

分類headの継続学習は早期に過学習しやすいため、初期化と学習率を比較しました。同じ学習済みCoAtNetから追加10 epochsの結果です。

設定	微調整学習率	Gold macro AUC
微調整前	—	0.9447
headを初期化せず継続	3e-5	0.9464
headを初期化して再学習	1e-4	0.9507

このため微調整前にheadを再初期化しました。

4.4 アンサンブル

backbone、neck、切り出し、seed、教師の異なるモデルを混ぜました。すべて384×384です。

提出直前の教師更新により旧版・更新版のモデルができました。AのCoAtNetは旧版のみ、Bのcontext-attention CoAtNetは両版を混ぜます。CAFormerは更新版です。

Backbone	Neck	切り出し	モデル数	教師	提出
CoAtNet-2	シリーズ内GRU + 2段階attention	140 mm	4	旧版：4	A
CoAtNet-2	シリーズ内GRU + 2段階attention	110 mm、前方へ10 mm移動	4	旧版：4	A
CoAtNet-2	文脈attention + ctx（LSE）	140 mm	4	旧版2、更新版2	B
CoAtNet-2	文脈attention + slot（LSE）	140 mm	4	旧版2、更新版2	B
CAFormer-S36	シリーズ内GRU + 2段階attention	140 mm	4	更新版：4	A/B共通
CAFormer-S36	シリーズ内GRU + 2段階attention	110 mm、前方へ10 mm移動	3	更新版：3	B

110 mm切り出しは中心から前方10 mm。140 mmのCAFormer 4モデルはA/B共通、110 mmの3モデルはBのみです。教師列の数はモデル数です。

選択提出A

Public最良はシリーズ内GRU + 2段階attentionの12モデル（CoAtNet 8 + CAFormer 4）の等確率平均です。Gold最高のEMAを選び、最高epochが4より前ならepoch 4 EMAを使いました。推論は384ウィンドウのunion bag、TTAなしです。

選択提出B

Gold macro AUC最高の組み合わせです。context attention + ctx、+ slot、CAFormer 140 mm、110 mmの4群。群内等確率平均後、4群を等重み平均します。

Goldでctxは0.9508、slotは0.9492、等重み平均は0.9527でした。

5. GoldとPublicによる検証

ソフトラベルへのOOFだけでは画像判定の正解への性能は分かりません。医師評価58検査をGold検証に使い、Publicとの一致を確認しました。

所見別評価は1列だけ予測を残し、他11列を0.5に固定します。その所見のPublic AUCを12 × LB − 5.5で推定しました。LBが小数3桁なので換算AUCの刻みは0.012です。

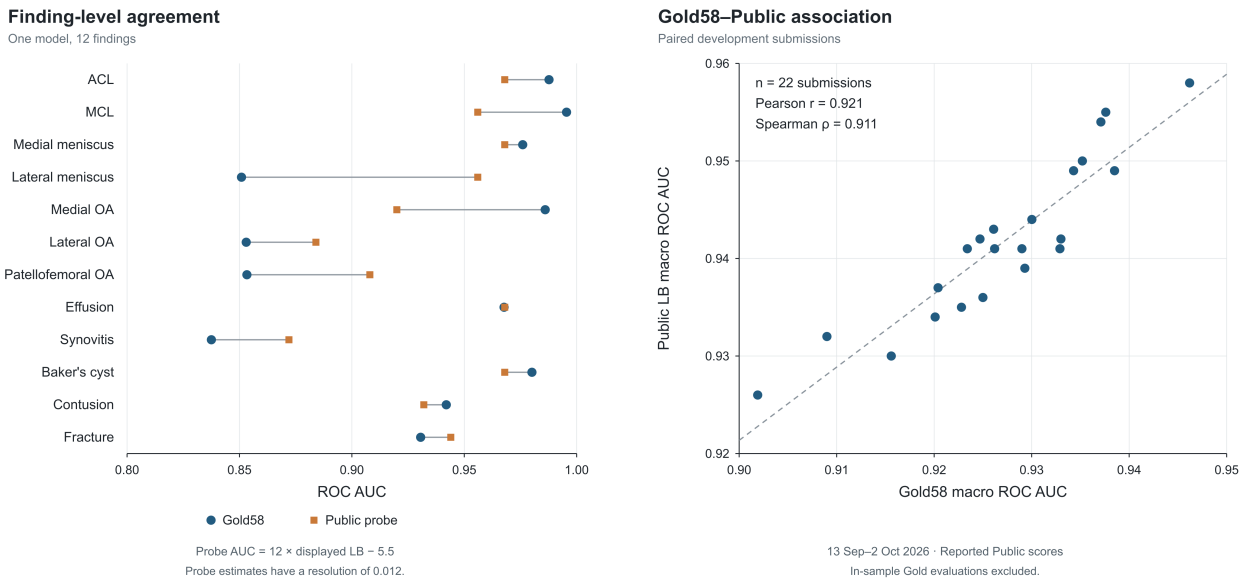


図5：左は1モデルのGoldとPublic個別推定AUC、右は22提出のGold macro AUCとPublic。

関節液と内側半月板はGold/Publicが近い一方、外側半月板と内側OAは約0.07–0.1違いました。22提出のGold/Publicは正相関（Pearson r=0.921、Spearman ρ=0.911）でした。

Goldの絶対値・小差は慎重に扱い、全体的な改善を見るために使いました。毎回4モデルで完全OOFを作るよりGoldの高速実験を優先し、Public過学習にも注意しました。

6. 最終結果

提出	Public	Private
Public最良（選択A）	0.968	0.957
Gold macro AUC優先（選択B）	0.967	0.957
Private最高（未選択）	0.967	0.958

現在表示されるスコアです。順位確定後、順位とより精密なスコアを追加します。

参考文献

1. Dai et al., CoAtNet: Marrying Convolution and Attention for All Data Sizes , NeurIPS 2021 （CoAtNet: Marrying Convolution and Attention for All Data Sizes）

2. Guan et al., Diagnose like a Radiologist: Attention Guided Convolutional Neural Network for Thorax Disease Classification , arXiv 2018 （Diagnose like a Radiologist: Attention Guided Convolutional Neural Network for Thorax Disease Classification）
3. Ilse et al., Attention-based Deep Multiple Instance Learning , ICML 2018 （Attention-based Deep Multiple Instance Learning）
4. Shao et al., TransMIL: Transformer based Correlated Multiple Instance Learning for Whole Slide Image Classification , NeurIPS 2021 （TransMIL: Transformer based Correlated Multiple Instance Learning for Whole Slide Image Classification）
5. Li et al., Dual-stream Multiple Instance Learning Network for Whole Slide Image Classification with Self-supervised Contrastive Learning , CVPR 2021 （Dual-stream Multiple Instance Learning Network for Whole Slide Image Classification with Self-supervised Contrastive Learning）
6. Pinheiro & Collobert, From Image-Level to Pixel-Level Labeling With Convolutional Networks , CVPR 2015 （From Image-Level to Pixel-Level Labeling With Convolutional Networks）
7. Burges et al., Learning to Rank using Gradient Descent , ICML 2005 （Learning to Rank using Gradient Descent）
8. Lin et al., Reference-Guided Gradient Balancing Loss for Long-Tailed Multi-Label Medical Image Classification , MICCAI 2026 （Reference-Guided Gradient Balancing Loss for Long-Tailed Multi-Label Medical Image Classification）