rsna-knee-abnormality-detection

10th-Place Solution（日本語訳）

Rank	10
Team	MEJAL
Author	LP
Topic ID	752730
Version	Japanese Translation

Source: https://www.kaggle.com/competitions/rsna-knee-abnormality-detection/discussion/752730
Retrieved with Kaggle CLI on 2026-10-27.

Kaggle Discussionの主投稿と、技術的補足を含む選定済みQ&Aを日本語へ翻訳した版です。code、URL、model名、識別子、数値は原文を保持しています。

10位解法：複数情報源のソフトラベルと複数シリーズ膝MRIアンサンブル

RSNA、Kaggle、画像・レポート提供施設、専門注釈者、モデル・コードを共有した皆さんに感謝します。教師、画像モデル、CoAtNet系統、最終統合を共同開発したチームにも感謝します。

最終はPublic 0.967、Private 0.957、10位。複数backbone・複数シリーズ群、CoAtNet-2群、公開R7を組み合わせました。

1. チーム概要：2つの開発経路、1つの画像課題

MRI検査からACL、MCL、内外半月板、3区画のOA、関節液貯留、滑膜炎、ベーカー嚢腫、骨挫傷、骨折の12異常を予測します。4,407学習検査は画像・レポート付き4,349と専門医正解58件。テストに文章はありません。12クラスROC AUCの単純平均なので、各クラス内の検査順位が中心です。（Competition overview）

主な構成は、陽性定義に合う教師、MRIの空間・断面・シリーズの証拠集約、異なる教師と構造のアンサンブルです。

2経路を開発しました。複数backbone・シリーズ系統は教師の整合と階層的集約、CoAtNet系統は反復ラベル蒸留とウィンドウMILを重視しました。まず別々に説明し、後の合流と最終統合へ進みます。

開発経路	主設計
複数情報源のソフト教師と複数シリーズの証拠集約	LLM/VLM教師混合、OAI対応付け、空間・断面・シリーズ集約、backbone横断検証。
反復ラベル蒸留とCoAtNet MIL	画像のみの読影、反復OOF教師、ウィンドウattention MIL、全データseed、全ウィンドウ微調整。

これは開発・実装の境界で、最終教師が独立という主張ではありません。後期は両経路のラベルと予測を混ぜました（4節）。

2. 経路1：複数情報源ソフト教師と複数シリーズ集約

Evan zhu、LP、minmin andy、Jak maが共同開発しました。

Evan zhuは主にプロンプト、教師、全体技術計画を担当。文章解釈、画像・文章統合、OAI対応付けを通じて教師を改善し、定義をコンペへ合わせ、最終段階の改善の主要案を提案しました。

LPは全体手法、データ品質解析、処理最適化を担当。複数シリーズ画像モデル、主要部品の設計・最適化、異種教師の補完学習、多段反復蒸留を改善しました。学習を実行し、調整・アブレーション・統合を主導、後処理も支援し、チーム手法の統合と最終判断に関わりました。

minmin andyとJak maは複数backboneの学習と反復実験を共同担当。構造・学習設定を変え、調整・結果検証・推論最適化・高速化を支援し、候補準備から最終改善まで貢献しました。

中心の問いは、推論がMRIだけで教師の大半は文章という条件で、学習目標と見える証拠をコンペへどう合わせるかです。記載なしは画像陰性とは限らず、記載された異常も陽性条件を満たすとは限りません。証拠は局所、少数断面、特定シリーズにしかないこともあります。教師が学ぶ内容を、構造が証拠のまとめ方を決め、その価値は下流実験で確認する必要があります。

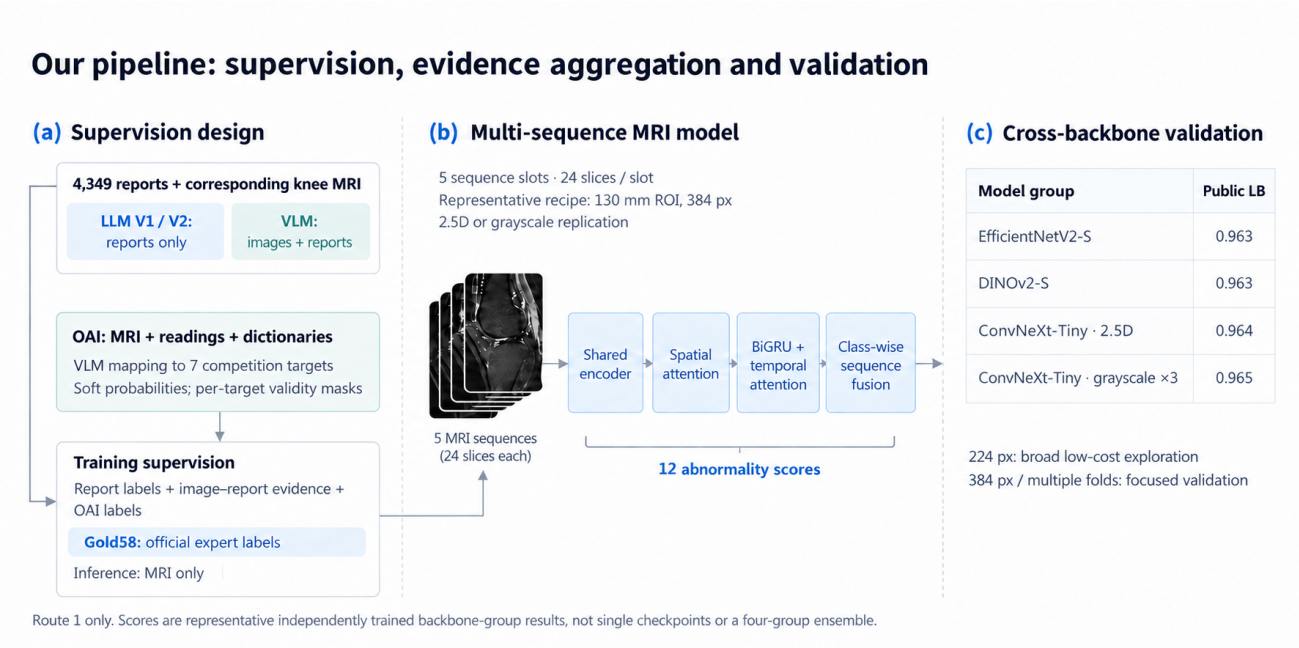


図1：教師設計、複数シリーズ、backbone横断検証。RSNAとOAIは別教師源、LLMは文章のみです。右の値は異なる段階の独立学習backbone群の代表Publicで、単体checkpoint、4群平均、最終結果ではありません。MaxのCoAtNetとR7は含まず、MRI縮小画像は模式例です。

2.1 方法：広く探索し、絞って検証

総計算資源を使って低コスト実験を多く並行し、少数の高価な検証へ集中しました。初期は主に224 pxで入力、集約、教師方針を選び、有望な設定を384 px・複数foldで検証し、EfficientNet、ConvNeXt、DINOへ移しました。各backboneは同じ発展経路をたどりました。

224は方向探索、384は改善確認です。高解像度でも同じ効果とは仮定しません。品質は鮮明さ・欠損だけでなく、解剖順序、定義一致、不確実さと根拠不足の区別も含みます。外部データ、モデル、蒸留の追加が一貫して効かなければ、検証で支持された設定を残しました。

2.2 教師設計：文章抽出から画像・文章の整合へ

LLM文章ソフトラベル→2版の混合→VLMによる画像・文章確認と混合→OAI対応付けと進み、前段の情報・定義の不足を埋めました。

文章LLMはGemma 4B、Opus 5、ChatGPT 6 Astra。RSNA画像・文章VLMはChatGPT 6.1 SolとOpus 5.5、OAI対応付けはローカルGemma 3 4Bです。使用範囲の一覧で、全例に全モデルを使った意味ではありません。V1/V2はプロンプト・教師版で、特定モデルとの1対1対応ではありません。

まず文章の不確実さを保持。疑い、軽度、境界例を確実に0/1へ落とせません。V1は所見、位置、重症度、否定範囲、根拠を抽出し、記載なしと明示的陰性・陽性を分けました。MRIなしで文章だけを読み、曖昧な文の二値化による情報損失をソフト値で抑えました。校正確率とは仮定していません。

次に重症度と陽性基準を満たす確率を区別。V2は単なる重症度でなく、専門医がコンペ定義で陽性とする確率をより直接推定しました。異なる観点の2プロンプトを混合して下流学習で比べ、対応実験のPublicは約+0.001でした。

VLMで文章教師の限界を補います。忠実な抽出でも省略や診療表現と画像評価基準の違いは残ります。同検査MRI、元レポート、対象注釈基準を使って、可視所見が定義を満たすか確認しました。不一致なら無理に一致させず画像証拠を調べる指示です。教師と課題を合わせるため画像を導入しました。

LLMとVLMの両方を残しました。文章は臨床医の全検査レビュー、VLMは抽出画像の証拠です。文章は省略、抽出画像は見落とし、モデル自体にも不確実さがあり、どちらも絶対正解にしません。下流結果で補完混合を選び、代表実験でPublic約+0.002–0.003。224 px VLM単独0.951→0.953、初期384 px EfficientNet 0.957→0.960でした。段階の異なる下流比較で、教師正解率ではありません。

成熟した設定の一例：

L = 0.7 × LLM_V1 + 0.3 × LLM_V2 Y = 0.7 × VLM + 0.3 × L = 0.70 × VLM + 0.21 × V1 + 0.09 × V2

モデルごとに情報源・混合も変えました。新Convは0.7 × Opus VLM + 0.3 × L、新DINOは0.5 × Opus VLM + 0.5 × L。Gold58は最後に専門医正解で置換します。これは教師混合係数で、RSNA/OAI抽出比や最終モデル重みとは別です。混合済み教師を生情報源として再度混ぜてはいけません。

教師段階	対処した問題	代表結果・検証
LLM V1ソフト教師	否定、場所、重症度、境界表現の構造化。	初期教師。二値教師に対する単独改善推定なし。
LLM 2版混合	重症度と陽性確率の混同、単一プロンプトの解釈偏り。	対応実験で約+0.001。
VLM/LLM画像・文章混合	両情報を残し、省略、不一致、定義差へ対処。	対応実験で約+0.002–0.003。上の224/384比較は同じ改善の例で、重複計上不可。
OAIラベル対応付け	外部評価尺度とコンペ陽性定義は同一ではない。	元の規則対応より実験記録で約+0.002–0.003。詳細は後述。

段階が異なり設定変更もあるため、改善は単純加算できません。もっともらしい説明だけでなく、固定教師と下流性能で品質を判断しました。

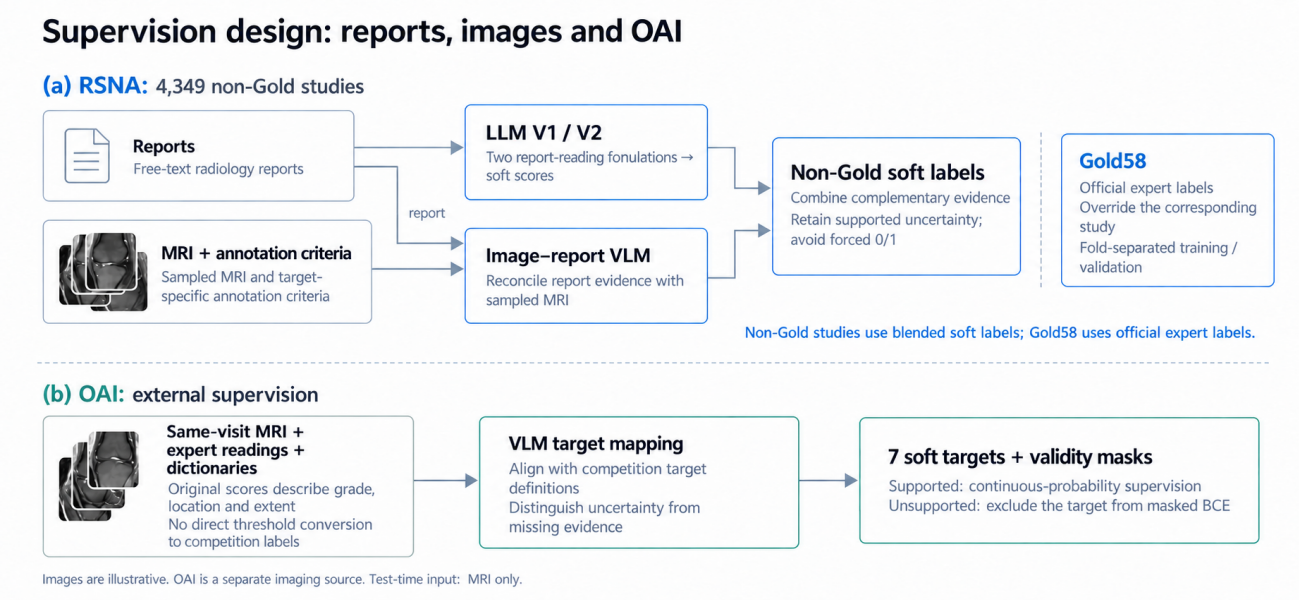


図2：RSNA/OAI教師。文章LLMはテキストのみ、VLMは文章・抽出MRI・定義を受けます。非Goldは混合教師、Gold58は専門医正解でfold分離。OAIの7教師は同来院MRI・専門評価・辞書で対応付け。有効マスクは対象別BCEに適用しますが、過去の全補助損失も同マスクだった意味ではありません。MRIは模式図、OAIは別画像源です。

2.3 OAI：量を増やす前に定義を合わせる

詳細な元評価が自動でコンペ教師になるわけではありません。OAIは位置・範囲・重症度、コンペは特定異常の陽性条件です。初期の閾値対応は弱く、定義がずれたまま増やすと教師偏りを増幅し得ます。

Evanは同来院のMRI、元専門医評価、項目辞書で対応付けを開発。内外半月板、内外OA、PF OA、関節液、滑膜炎の7ソフト教師と対象別有効マスクを作り、元の規則対応よりPublic約0.002–0.003改善しました。

根拠はあるが曖昧なものと、根拠不足を分けました。前者は連続値、後者は陰性で埋めずBCEの有効フラグで制御します。RSNAの完全12教師表、OAI対象有効マスク、画像枠の存在マスクは別情報です。

OAI候補は初回2,399検査と追跡6,250検査で、独立8,649人ではありません。代表epochはRSNA約3,305、OAI約2,393、約58%/42%です。epoch単位の露出で、固定バッチ比・教師混合比ではありません。同じ人の追跡を含むため件数は独立情報数ではありません。OAIの3シリーズは矢状・冠状・横断の最初3枠へ入り、他は欠損。有効ラベルだけを監督します。

ある384 px EfficientNetの発展では、混合教師、初回OAI、7対象への拡張でPublic 0.960、0.962、0.963でした。対応・対象範囲・候補群が同時に変わり得るため、前の対応改善に加算できません。追跡追加や4対7対象も常に効きませんでした。結論は、量を決める前に外部教師の意味を検証することです。

2.4 入力と構造：階層的な証拠集約

元DICOMをSAG_FLUID_FS、COR_FLUID_FS、AX_FLUID_FS、COR_T1、SAG_T1の5枠へ割り当てます。物理順序、中央深度抽出、実寸中心切り出し、濃度正規化、左右統一、欠損マスクを使います。成熟384 px設定は通常130 mm中心切り出しで枠ごと24断面を保存し、検査IDで分割ファイルを結合します。

成功群には2入力があります。2.5Dは隣接3断面を3チャネルとし、24枚からstride2で11重複ウィンドウ。単一濃淡画像の複製は1断面を3チャネルへコピーし、24トークンを残します。各checkpointは学習時の方式を使います。DINOv2は392 px、RadImageNetは224 pxです。

共通経路は共有視覚encoder→所見別空間attention→シリーズ内BiGRUと断面attention→5シリーズのクラス別融合→12出力。欠損枠は符号化、補助BCE、融合から除外します。

空間段階は所見別に関連領域を集め、全体平均による局所信号の希釈を抑えます。断面段階はシリーズ別BiGRUで文脈を残し、所見別attentionで関連断面を選びます。シリーズ段階は方向・コントラストへの所見別の好みを学びます。症例依存gateでなく全体共通のクラス別重みを、存在枠で再正規化します。

encoderは共有し、各シリーズの集約分岐は残して撮像差に対応します。病変ボックスなしでも検査教師から所見別の重みを学べますが、attention位置を病変局在として検証したわけではありません。ChatGPTとClaudeで議論・実装し、コード確認と実験選択を行いました。同じ発展設定をEfficientNet、ConvNeXt、DINOへ移し、補完的な入力・教師版を作りました。

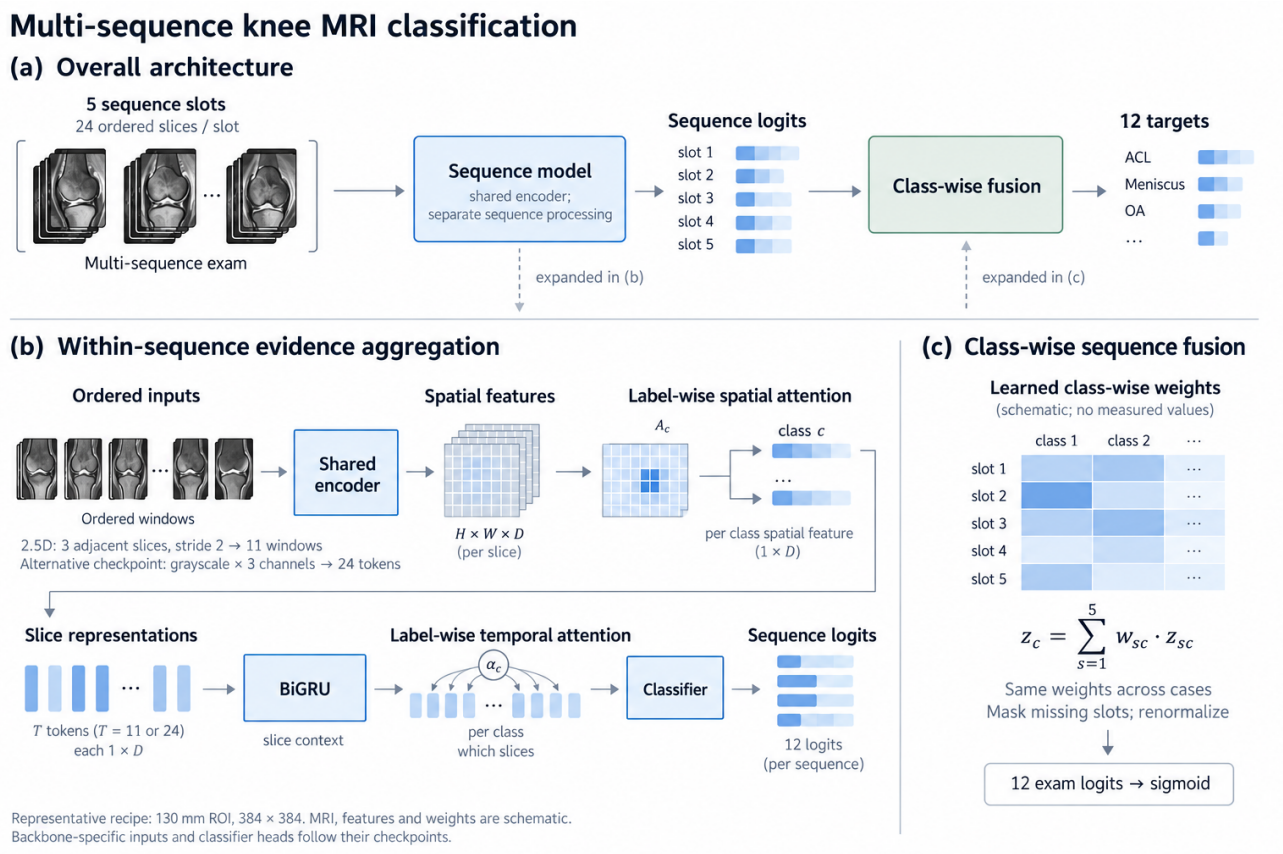


図3：(a)共有encoderで各シリーズを処理し、分類結果をクラス別融合。(b)所見別空間集約、BiGRU、所見別断面集約。(c)症例共通クラス重みでシリーズlogitsを融合し、欠損をマスク・再正規化。2.5Dと濃淡複製はcheckpoint別の代替入力。MRI・特徴・重みは模式図で、実症例、病変位置、実測重みではありません。正確なサイズとheadはコードに従います。

2.5 学習設定と主な改善

成熟ConvNeXtはAdamW、bf16、EMA、batch4・勾配蓄積4、代表的な一律LR 2e-4、12 epochs。DINO等は初期重みに合うLR・固定設定を使います。幾何変換は検査内で共通、濃度拡張はシリーズ内共通。EMAを評価・保存し、補助専門head BCEは存在枠だけに適用します。

分類	目的	代表実験結果
有効入力と解剖の一貫性	物理順序、方向統一、小範囲切り出し、高解像度で詳細を残す。	EfficientNet 224 px/crop160→320 px/crop130でPublic 0.925→0.937。範囲と解像度を同時変更。

分類	目的	代表実験結果
階層的証拠選択	クラス別空間・断面選択後にシリーズ融合。	224 px attention設定：0.939→0.943、約+0.004。
断面網羅と重複ウィンドウ	証拠を増やし、ウィンドウ境界の不連続を減らす。	網羅変更で約+0.001、重複設定で約+0.003。
頑健な学習	幾何・濃度・撮像の変動へ対処。	初期幾何拡張0.937→0.942、濃度拡張のある設定で約+0.003。
最適化と安定性	EMAで重みを安定化、補助BCE・順位損失で制約を追加。	実験メモではEMA約+0.002、順位約+0.001。同程度に厳密な単独比較ではありません。
教師設計	LLM 2版、画像・文章混合、OAI対応付け。	教師表参照。OAI追加や別設定変更の独立改善として再計上しません。
限定的TTA	効果と計算量を考え、固定変換ビューを平均。	後期3角度比較はPublic/Private約+0.001。初期+0.003推定は高価な9ビュー設定。

表は異なる段階の代表比較で、加算できません。物理順序はPublic約+0.001でもPrivateに同じ改善はなく、動機と実測汎化を分ける必要があります。24断面濃淡版は224 pxのPublic/Private 0.951/0.936から384 pxで0.956/0.943でした。高解像度確認の価値はありますが、全工夫が同じだけ転移する証明ではありません。

2.6 主要段階と一貫して効かなかった方向

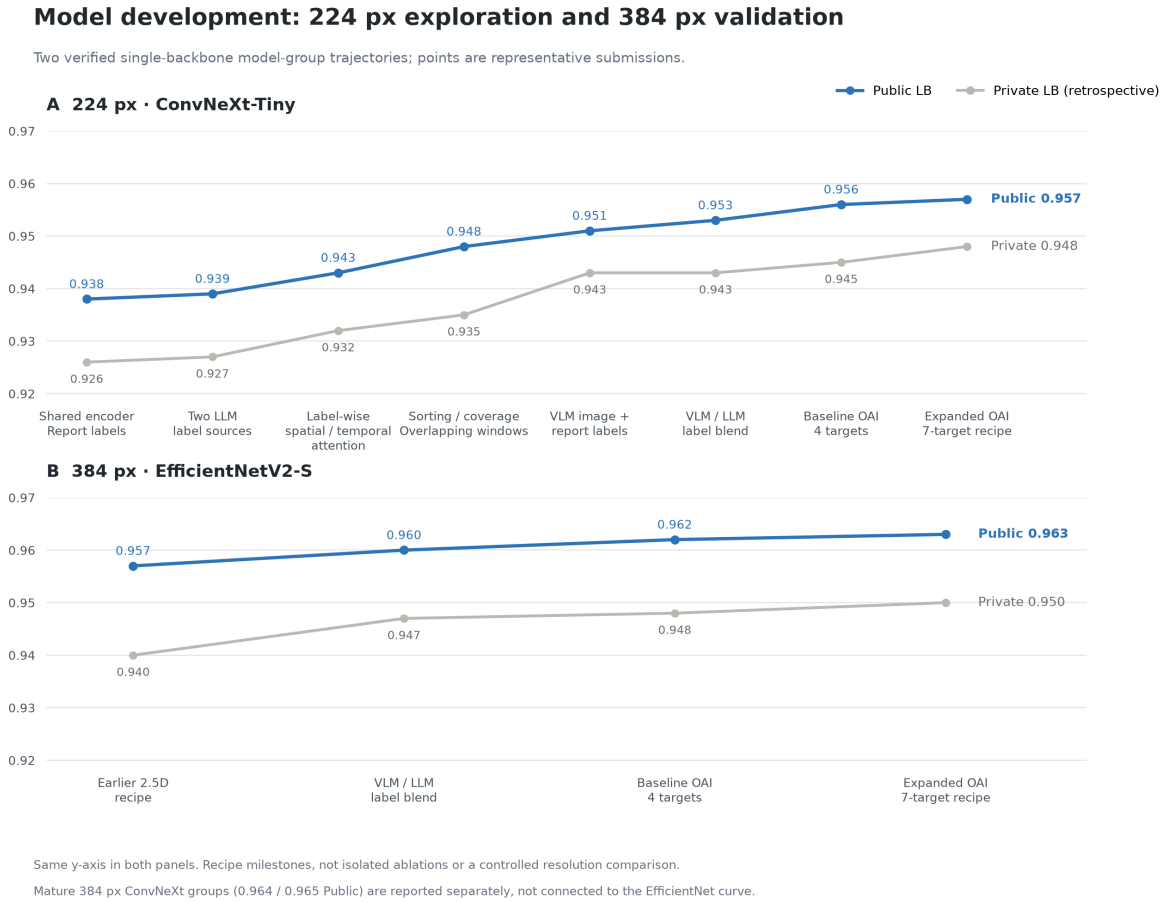


図4：上は224 px ConvNeXt-Tiny、下は384 px EfficientNetV2-S。青Public、灰は事後Private、縦軸共通。線は経路内代表提出で、統制した解像度比較・単独アブレーションではありません。224は0.938/0.926→0.957/0.948、

384 EfficientNetは0.957/0.940→0.963/0.950。各提出リンクは図4データ記録にあります。（Figure 4 data record）

全実験や全変更の成功を示すものではありません。別の初期LLM混合は0.937/0.925で、基準0.938/0.926より低い結果でした。後の成功は混合の常勝を意味しません。成熟384 ConvNeXtの0.964/0.965は下に別掲し、EfficientNet曲線にはつなぎません。

成熟設定の転移後、ConvNeXt-Tinyの2.5D・濃淡複製群はPublic 0.964・0.965、EfficientNetV2-SとDINOv2-Sは0.963でした。通常は複数fold群で、単一checkpointではありません。異なる段階の結果で、最終構成の統一条件比較ではありません。

代表モデル群	Public LB	Private LB
ConvNeXt-Tiny 384, 2.5D	0.964	0.954
ConvNeXt-Tiny 384、濃淡複製	0.965	0.954
EfficientNetV2-S 384	0.963	0.950
DINOv2-S、392 px入力	0.963	0.950
TinyViT-21M 384	0.961	0.949
RadImageNet ResNet50、224 px入力	0.957	0.943

初期TinyViT・RadImageNetも同じ経路ですが、すべてが最終4群に入ったわけではありません。

OAI増量、対象変更、教師予測追加、モデル増量は段階を通じ一貫して効きませんでした。4対7対象は候補と教師版に依存し、蒸留は教師品質・定義一致・検証独立性に依存します。選択根拠を説明するため失敗も残します。別の教師系統のCoAtNetの蒸留改善を否定する結果ではありません。

3. 経路2：反復ラベル蒸留とCoAtNet MIL

Maxは反復蒸留、合意教師、CoAtNet-2学習、全ウィンドウ微調整を主導し、統合・後処理も改善しました。補完モデルと統合支援を提供しました。この系統の教師・入力・学習を分けて説明し、分割・指標を2節と混同しないでください。

主な改善：ラベルをラウンドで更新し、多くの場合、未学習検査のOOF予測を次の教師に使いました。下の最初2結果はラウンド全体の比較で、厳密な単独変更試験ではありません。

- 文章なしのGPT-6 Astra画像読影を混ぜたラウンドが最大で、Public約+0.019、Private約+0.017。ただしcheckpoint選択も変更しています（3.1節）。
- ラウンド全体ではPublic 0.924→0.964で、前述の段階を含みます。後期はR7予測と他系統のVLM/LLM教師・モデル予測も使い（4.1節）、途中でbackbone、画像準備、学習データも変えました（図6）。
- 最後の短い全ウィンドウ微調整：4つの全データCoAtNetはepoch選択用100件以外をseed違いで学び、ランダム12ウィンドウの代わりに保持シリーズの全3断面ウィンドウで追加4 epochs学習しました（3.4節）。4fold版で評価するとOOF約+0.0021、チーム平均約+0.0006。全データ版にOOFはありません。

Public約390検査、小数3桁なので、この節の約0.001の段差は偶然の範囲と扱います。最初2改善はそれより大きく、第3はOOFで測りました。

3.1 教師反復：文章、独立画像読影、OOF

MaxはRaptor公開文章教師から始め、他の文章2源、次に文章なしAstra画像読影を追加しました。画像・文章VLMとは別の証拠です。各ラウンドのOOFを教師尺度へ戻し、文章・画像スコアと混ぜて次の学習へ渡します。新モデルは毎回ImageNetから開始し、オンライン教師や追加の温度蒸留損失は使いません。

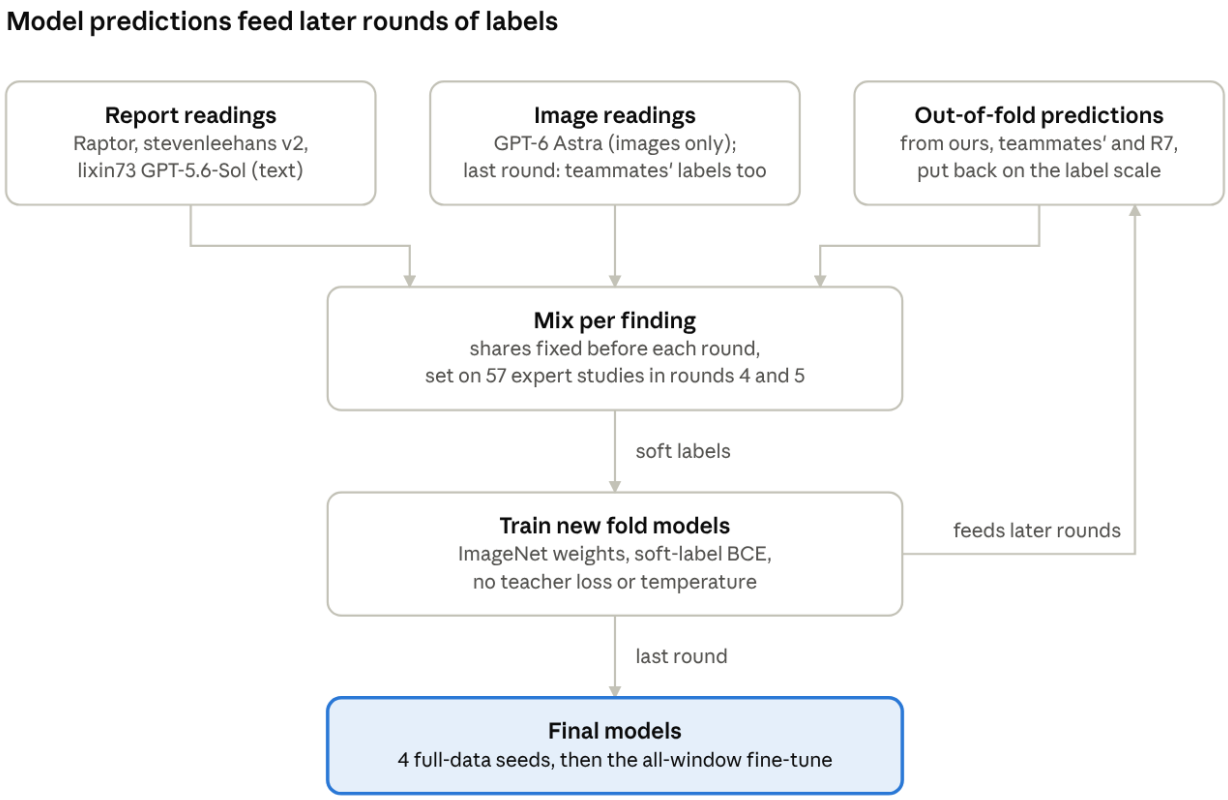


図5：教師蒸留。原図のoursはCoAtNet、teammatesは複数backbone系統。

第5回蒸留をv7と呼びます。その後の合意教師は両系統の教師・予測を混ぜます（4.1節）。

文章教師Public 0.924から全データseedsの0.964へ改善しました。画像読影導入ラウンドはPublic約0.019、Private約0.017改善。ただしcheckpoint選択も変わり、ラウンド全体の結果です。

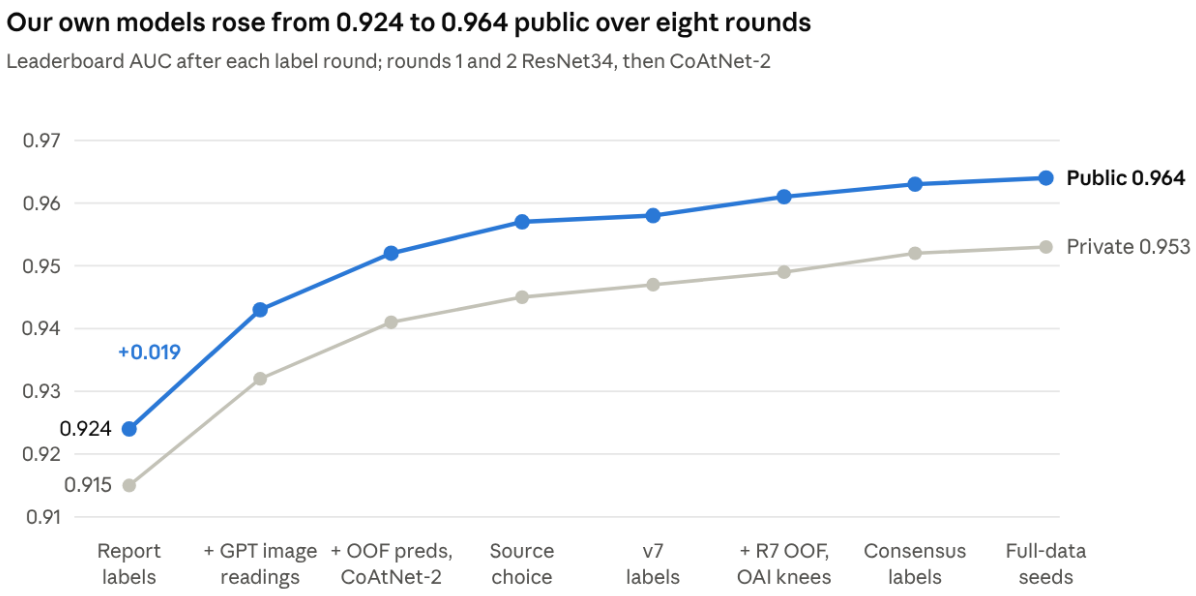


図6：蒸留ラウンド別結果。一部の間では教師、backbone、キャッシュも変わります。

3.2 入力と構造：ウィンドウMIL

約73Mパラメータのcoatnet_rmlp_2_rw_384.sw_in12k_ft_in1kを使い、Raptor前処理とattention-MILを調整しました。矢状液体強調/その他、冠状液体強調/その他、横断の5枠です。物理順序後に深度6%–94%を保持、140 mm中心crop、336 px保存後384へ変換。隣接キャッシュ3断面を1ウィンドウとし、検査あたり最大約134です。

各ウィンドウのクラススコアを計算し、所見別attention MILで集約します。5シリーズを同じbagに入れ、headに追加の方向・位置符号化はありません。シリーズ内BiGRUとシリーズ融合とは異なる集約です。

3.3 OAI：初回膝を外部教師にする

初回OAI 2,398膝、追跡なしです。まずMOAKS（MRI Osteoarthritis Knee Score）を固定規則で対応付け、共通7所見（両半月板、3OA、関節液、滑膜炎）はMRIとMOAKSをモデルが読む他系統のOAI教師と50/50平均しました（2.3節）。ACLとベーカー嚢腫は規則値、MCL・骨挫傷・骨折は空欄です。50/50前の規則教師のみの2試験ではOAI追加でPublic各約0.001（単独0.957→0.958、R7混合0.962→0.963）。偶然範囲の差なので、2試験だけではOAIの効果量を示せません。

3.4 学習、全データseed、全ウィンドウ微調整

通常はソフトBCE、固定クラス陽性重み、AdamW、OneCycle。encoderピーク3e-5、head1e-3、実効batch8、24 epochs、検査ごとランダム12ウィンドウです。最終4 seeds（42–45）を追加4 epochs、保持シリーズの全ウィンドウ、低LR、BatchNorm固定で微調整し、選択3epochの重みを平均。4fold合意教師比較でOOF約+0.0021、チーム平均約+0.0006でした。

推論は全候補から一様に56ウィンドウを選びます。56はモデル数でなく1検査の予測窓数です。通常の12ランダム学習、全窓微調整とは別です。

4. 共同作業：教師共有と補完的アンサンブル

両系統は教師、入力、集約が異なります。後期は教師・OOFの合意ラベル化と、推論での学習済みモデル群の統合という、別の2段階で協力しました。

設計	複数backbone・複数シリーズ群	CoAtNet-2系統
断面入力	枠ごと重複2.5D 11窓、または濃淡複製24トークン。	検査全体の3断面窓。通常学習は検査ごとランダム12窓。
空間・深度集約	所見別空間attention、BiGRU、断面attention。	ウィンドウ特徴のクラス別attention MIL。
シリーズの扱い	欠損マスク付き標準5枠のクラス別融合。	5シリーズのウィンドウを同じ集合へ。
代表的な視野	130 mm、384 px。一部backboneは別サイズ。	140 mm、336 px保存後384 pxへ。

4.1 後期の合意教師：両経路の合流

CoAtNet第5回をv7と呼びます。最終合意教師はv7、VLM/LLM教師、複数backbone・CoAtNet・R7のOOFという3源です。予測源をクラス別順位で混ぜ、ソフト教師範囲へ戻します。その内部比は複数backbone 0.45、CoAtNet 0.30、R7 0.25。Gold58は公式正解、OAIは別教師・マスクを使います。得られたモデルの予測は統計的に独立ではなく、共有教師へのOOF一致を独立テストとは扱えません。

0.45/0.30/0.25は合意ラベルを作る内部OOF混合比です。最終提出重みでも経路1のLLM/VLM比でもありません。

4.2 モデル群、融合、結果

複数backboneはDINOv2-Small、EfficientNetV2-S、DINOv3蒸留ConvNeXt-Tiny、ConvNeXt-Tinyの4群。群内でfold・seed・テストビューを集約後、全データCoAtNet-2の4 seedsと公開R7を混ぜます。

4画像群の確率を等平均し、複数backbone70%、CoAtNet21%、R7 9%とします。クラス別パーセンタイル順位をnoisy-OR型で混合し、外側OA、PF OA、滑膜炎から順に0.10×内側OA、0.10×内側OA、0.20×関節液を引いて最終順位を出します。順序を変える後処理で、確率校正ではありません。

別提出の50%/30%/20%はPublic 0.967 / Private 0.956。選択した70%/21%/9%は0.967 / 0.957で10位でした。

50/30/20提出の後処理：

1. 順位：各所見・系統の予測を、採点したm検査内の0〜1のパーセンタイル順位rへ変換。
2. Noisy-OR：−log(1−r+0.5/m)へ変換し、系統重みで平均。大半では小さく上位付近で急増するので、いずれかの系統で上位なら、独立の「あり」の票を得たように上昇します。
3. 正規分布スコア：混合列を再順位化し、標準正規分布の対応値へ変換。
4. 補正：前述3減算を適用。外側OA、PF OA、滑膜炎には内側OAや関節液と共通の一般的な関節症・液体信号が含まれるという考えで、一部を除きます。臨床的に無関係な所見を相手にしても改善しませんでした。
5. 出力：結果のパーセンタイル順位。

4,296検証検査をランダム50/50で5回分け、各半分を別採点しました。OOFのない全データ4モデルの代わりに4fold CoAtNetを使います。片側で減算量を選び他側で測ると、段階2–4は単純順位加重平均より約+0.0004で、全

10半分で正でした。以前の提出版のLBは有無ともPublic 0.966 / Private 0.955で、この小さな差なら予想どおりです。

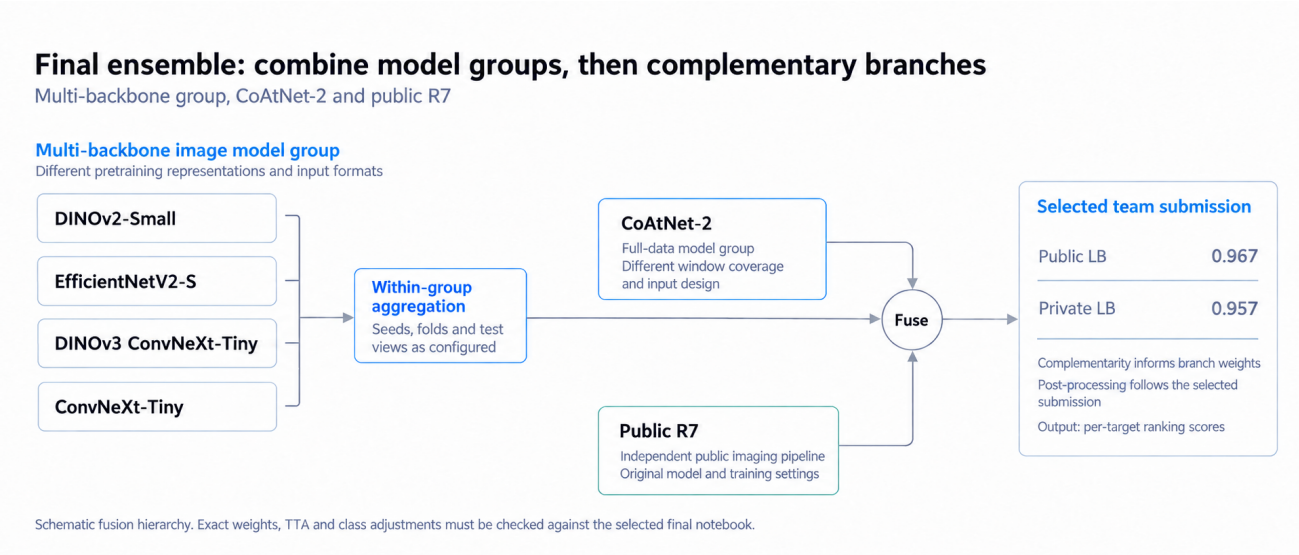


図7：最終は複数backbone70%、CoAtNet-2 21%、公開R7 9%。選択提出はPublic 0.967、Private 0.957。

段階	Public LB	Private LB
成熟ConvNeXt-Tiny群、224→384 px	0.957 → 0.964	—
後期ConvNeXt-Tiny群	約0.965	—
全窓微調整前の全データCoAtNet-2 4 seeds	0.964	0.953
チームアンサンブル提出	0.967	0.956
最終選択提出（70/21/9）	0.967	0.957

全窓微調整、56窓推論、T4×2配分で、画像網羅と9時間制限を両立しました。DICOM並列読込、キャッシュ、限定TTAも使い、各モデルの学習時入力・正規化・checkpoint設定を維持します。文章LLMも画像・文章VLMもテストでは実行しません。

5. 検証、再現、資源

5.1 2経路の検証を別々に解釈する

両経路のOOF、Gold58、Publicは交換可能な測定ではありません。役割は次のとおりです。

項目	複数backbone・シリーズ経路	CoAtNet経路
分割	患者・病院IDでなく、正規化レポートhashの群で4fold。	最終4fold検証は4,296検査。専門医58件と、対象異常の記載がない53件は常に学習側。
Gold58	公式正解。自身の検証foldでは学習除外、他foldでは学習。主に小標本の診断用。	後期学習に常に含む。情報源重み選択にも使い、独立テストではない。
手元指標		

項目	複数backbone・シリーズ経路	CoAtNet経路
	現在の文章・画像文章教師に対する順位を測る派生AUC。Goldは少数。	別教師・選択手順。全データseedsは微調整選択用100検査を追加保留。
後期教師の依存関係	教師と予測がチーム合意教師に寄与。	複数backbone、CoAtNet、R7の予測を合意に使用し、後期結果は統計的に独立ではない。

Publicはコンペ中の未知データのフィードバック、Privateは事後解析だけに使用。異なる段階の改善を足すことはできず、共有教師下のOOF一致は独立テスト値ではありません。選択には実推論コストも重要です。

5.2 コード・モデル・データ

資源	用途	リンク
複数backboneのコードとラベル	224/384前処理、学習、プロンプト、過去6/8モデル推論、固定RSNA教師7ファイル。	[準備中]、[準備中]
RSNA Kneeデータ	学習・テストMRI、レポート、公式Gold58。	コンペデータ （Competition data）
OAI	膝MRIとMOAKS評価。	OAI。CoAtNet DOI:10.15154/wfxg-g926。複数backbone:NDA Collection 2343、NDA Study S3430、DOI:10.15154/vgnc-0x45。 （OAI / 10.15154/wfxg-g926 / 10.15154/vgnc-0x45）
Raptor	蒸留経路の初期文章教師、画像前処理・MIL headの公開参照。	レポートラベル、学習コード （Report labels / Training code）
公開R7	アンサンブル系統。OOFも後期蒸留教師に寄与。	重み、推論コード （Weights / Inference code）
その他の公開レポートラベル	追加の文章読影情報源。	stevenleehans , lixin73 , Pilkwang （stevenleehans / lixin73 / Pilkwang）

公開リポジトリの4つの元ラベルはスクリプトが一度読み混ぜます。3つの*_labels_used.csvは実学習教師のスナップショットで、生の混合入力として再利用してはいけません。元プロンプトと必要処理を含みます。学習済み重みは未公開で、主催者要件と資産権限に従って公開方法を決めます。OAI画像・教師は該当するアクセス条件で別途準備が必要です。

公開分岐は過去224/384複数backboneのコードと教師です。完全CoAtNetと最終チーム提出コードは含みません。

5.3 Backbone初期化と事前学習重み

画像モデル初期化の公開重み一覧です。識別子はtimm重み版でモデルカードへリンクします。入力サイズは私たちのタスク設定で、元の事前学習で共通という意味ではありません。

モデル群	事前学習重み識別子	事前学習データ・方法	使用入力	重みの出典
ConvNeXt-Tiny				

モデル群	事前学習重み識別子	事前学習データ・方法	使用入力	重みの出典
	convnext_tiny.fb_in22k_ft_in1k_384	教師あり ImageNet-22k→ImageNet-1k微調整	384 × 384	モデルカード（Model card）
EfficientNetV2-S	tf_efficientnetv2_s.in21k_ft_in1k	教師あり ImageNet-21k→ImageNet-1k微調整	384 × 384	モデルカード（Model card）
DINOv2-Small / ViT-S/14	vit_small_patch14_dinov2.lvd142m	LVD-142M、DINOv2自己教師あり事前学習	392 × 392	モデルカード（Model card）
DINOv3 ConvNeXt-Tiny	convnext_tiny.dinov3_lvd1689m	LVD-1689M、DINOv3 ViT-7Bから蒸留した公式特徴重み	384 × 384	モデルカード（Model card）
CoAtNet-2	coatnet_rmlp_2_rw_384.sw_in12k_ft_in1k	教師あり ImageNet-12k→ImageNet-1k微調整	384 × 384	モデルカード（Model card）

これらはコンペ教師と各OAI設定でのタスク学習前の初期encoderです。推論時のfold0_final.ptなどのRSNA checkpointとは別。DINOv3行の蒸留は公式の視覚事前学習で、文章ソフト教師、OOF合意、反復蒸留とは異なります。ImageNet-12kは全ImageNet-22kの部分集合です。

公開R7は5.2節の著者公開MRIタスク重みを直接使います。上記初期化から自分たちが追加学習した群ではありません。

6. 謝辞・参考文献

6.1 公開資源と基礎手法

- コンペとデータを提供したRSNA、専門注釈者、Kaggleに感謝します。
- 公開レポートラベルのdreaddevelopment、Pilkwang、stevenleehans、lixin73に感謝します。蒸留経路の初期教師と情報源比較を支えました。（dreaddevelopment / Pilkwang / stevenleehans / lixin73）
- CoAtNetの画像前処理・attention-MIL実装を参照したRaptor学習Notebookのdreaddevelopmentに感謝します。（Raptor training notebook）
- R7推論・重みのheliosliに感謝します。最終平均と、後期合意教師へのOOFで貢献しました。（R7 inference code / weights）
- backbone実装と重みinterfaceのtimm、事前学習モデルと公開研究のDINOv2/DINOv3チームに感謝します。（timm / DINOv2 / DINOv3）
- 初期ResNet50に使った事前学習重みのRadImageNetに感謝します。（RadImageNet）

6.2 OAIデータ謝辞

OAIの膝MRIと専門医評価を外部教師に使いました。複数backboneはNDA Collection 2343、NDA Study S3430、DOI 10.15154/vgnc-0x45。CoAtNetは別のNDA Study DOI 10.15154/wfxg-g926です。（10.15154/vgnc-0x45 / 10.15154/wfxg-g926）

> 本稿のデータ・研究ツールは、NIMH Data Archive（NDA）内のOAIが配布するアクセス管理付きデータから取得・解析しました。OAIはNIMHとNIAMSの共同情報システムで、バイオマーカー発見、科学研究、OA薬開発を加速する世界的資源です。識別子：NDA Collection 2343、NDA Study S3430、DOI

> 10.15154/vgnc-0x45（複数backbone）、DOI 10.15154/wfxg-g926（CoAtNet）。（10.15154/vgnc-0x45 / 10.15154/wfxg-g926）

OAI謝辞はNDA公式文面に従っています。（official NDA wording）

6.3 手法の参考文献

[1] Tan M, Le QV. EfficientNetV2: Smaller Models and Faster Training . ICML, 2021.（EfficientNetV2: Smaller Models and Faster Training）

[2] Liu Z, et al. A ConvNet for the 2020s . CVPR, 2022.（A ConvNet for the 2020s）

[3] Oquab M, et al. DINOv2: Learning Robust Visual Features without Supervision . arXiv:2304.07193, 2023.（DINOv2: Learning Robust Visual Features without Supervision）

[4] Siméoni O, et al. DINOv3 . arXiv:2508.10104, 2025.（DINOv3）

[5] Dai Z, Liu H, Le QV, Tan M. CoAtNet: Marrying Convolution and Attention for All Data Sizes . NeurIPS, 2021.（CoAtNet: Marrying Convolution and Attention for All Data Sizes）

[6] Ilse M, Tomczak JM, Welling M. Attention-based Deep Multiple Instance Learning . ICML, 2018.（Attention-based Deep Multiple Instance Learning）

[7] Hunter DJ, Guermazi A, Lo GH, et al. Evolution of semi-quantitative whole joint assessment of knee OA: MOAKS (MRI Osteoarthritis Knee Score) . Osteoarthritis and Cartilage, 19(8):990–1002, 2011.（Evolution of semi-quantitative whole joint assessment of knee OA: MOAKS (MRI Osteoarthritis Knee Score)）

[8] Mei X, et al. RadImageNet: An Open Radiologic Deep Learning Research Dataset for Effective Transfer Learning . Radiology: Artificial Intelligence, 4(5):e210315, 2022.（RadImageNet: An Open Radiologic Deep Learning Research Dataset for Effective Transfer Learning）